“十二五”普通高等教育本科国家级规划教材
普通高等教育“十一五”国家级规划教材

生物统计学

（第五版）

李春喜　姜丽娜　邵　云　张黛静　编著

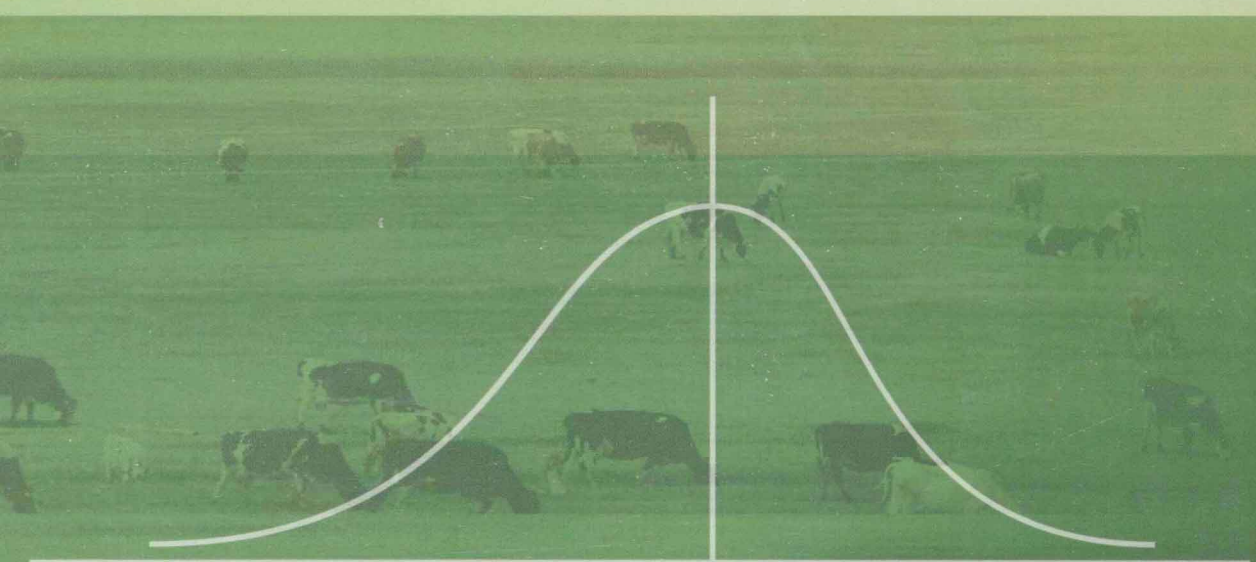

科学出版社

“十二五”普通高等教育本科国家级规划教材

普通高等教育“十一五”国家级规划教材

生物统计学

（第五版）

李春喜　姜丽娜　邵　云　张黛静　编著

科学出版社

北　京

内 容 简 介

本书较为系统地介绍了生物统计学的基本原理和方法，在简要叙述了生物统计学的产生、发展及其研究对象与作用以及生物学研究中抽样方法、试验资料的整理、特征数的计算、概率和概率分布、抽样分布的基础上，着重介绍平均数的统计推断、χ^2 检验、方差分析、直线回归与相关分析、可直线化的非线性回归分析、协方差分析、多元线性回归与多元相关分析、逐步回归与通径分析和多项式回归分析，同时对试验设计原理及对比设计、随机区组设计、拉丁方设计、裂区设计、正交设计等常用试验设计及其统计分析也进行了详细叙述。

本书可供综合性大学、师范院校生物类及其相关专业的本科生作为教材使用，也可作为从事生命科学、生物工程、农业科学、林业科学、医学、畜牧兽医、水产科学等专业的科研工作者、教师和研究生的参考书。

图书在版编目(CIP)数据

生物统计学/李春喜等编著.—5 版.—北京：科学出版社，2013

"十二五"普通高等教育本科国家级规划教材·普通高等教育"十一五"国家级规划教材

ISBN 978-7-03-037502-5

Ⅰ.①生… Ⅱ.①李… Ⅲ.①生物统计-高等学校-教材 Ⅳ.①Q-332

中国版本图书馆 CIP 数据核字(2013)第 103373 号

责任编辑：丛 楠 贺窑青/责任校对：桂伟利

责任印制：阎 磊/封面设计：迷底书装

科学出版社出版

北京东黄城根北街16号

邮政编码：100717

http://www.sciencep.com

化学工业出版社印刷厂印刷

科学出版社发行 各地新华书店经销

*

1997 年 8 月第 一 版 开本：787×1092 1/16

2013 年 6 月第 五 版 印张：19 1/4

2013 年 6 月第一次印刷 字数：442 000

定价：38.00 元

（如有印装质量问题，我社负责调换）

第五版前言

作为研究生命科学最基础的工具性课程之一，生物统计学越来越被从事生物学基础教学、生命科学研究的教师和科技工作者所高度重视。生物学研究中会产生大量试验与调查数据资料，这些资料在计算机出现之前是很难进行系统整理和深入分析的。计算机的普及应用，不仅能够将生命科学问题推向深化和精确化，而且还能对其理论及其假说进行论证和说明。尽管数据计算手段已不是限制因素，但不少学生在学习生物统计学时仍然存在很大焦虑，面对大量数学公式和统计数据无所适从。多年的生物统计学教学实践经验表明，上述现象是由于学生没有真正掌握生物统计学基本知识和框架内容所致。针对上述问题，本书按照“循序渐进、强化基础、先易后难、注重实践”的基本思路从生物统计学的概念、发展历史、基本作用出发，在介绍抽样方法、数据资料整理、特征数计算、概率和概率分布、统计推断的基础上，重点对方差分析、回归与相关分析及常用试验设计与统计分析进行详细叙述，以加强高校生物学类专业生物统计学的教学工作，为促进新型生物学高级人才的培养提供基础性知识和工具性方法。

本书在前四版的基础上，对全书内容进行了调整和精编，并获教育部“十二五”普通高等教育本科国家级规划教材立项。本书在第四版的基础上进行了系统修编，主要修编内容有以下几个方面：一是将第四版的 14 章缩编为 13 章，取消了第四版第九章抽样原理和方法，将该章部分概念移至第一章，将抽样方法放在第二章中进行介绍；二是在常用试验设计与统计分析中增加了拉丁方设计，兼顾了诸如动物实验等来自双向系统误差试验设计的需要；三是更换了部分例题，使其对相关方法实际运用的介绍更具有代表性；四是对各章部分内容进行了修改，补充了一些难点分析，统一了各章相同术语的表述，订正了个别错误内容；五是配合本书的出版，编写了《生物统计学》(第五版)立体化教材《生物统计学学习指导》一书，为进一步帮助读者理解和学习生物统计学课程内容提供了学习资料。

本书在编写和出版过程中，得到了河南省教育厅、河南师范大学和科学出版社的大力支持。科学出版社的王国栋先生、甄文全先生为书稿的内容编排提出了建设性建议，丛楠女士在本书编审方面作了大量工作。河南省教育厅在规划教材申报立项方面给予了指导和支持。河南师范大学教务处、生命科学学院在适应新形势生物统计学教学改革和教材建设方面给予了指导性意见，对本书再版修订给予了大力支持。在此一并感谢。

本书的再版，离不开广大读者的支持和帮助。恳请各位读者继续对本书给予关心和帮助，对本书存在的不足之处及时提出意见，以便进一步完善。

李春喜

2013 年 3 月于河南师范大学

第一版前言

生物统计学是运用数理统计的原理和方法来分析和解释生物界各种现象和试验调查资料的一门科学。随着生物学的不断发展，对生物体的研究和观察已不再局限于定性的描述，而是需要从大量调查和测定数据中，应用统计学方法，分析和解释其数量上的变化，以正确制订试验计划，科学地对试验结果进行分析，从而作出符合科学实际的推断。目前，生物统计学在农学、林学、畜牧、医药、卫生、生态、环保等领域已有广泛应用，但在纯生物学研究方面的应用，不管是在深度上还是广度上都不及上述领域。有鉴于此，在生物学研究中，迫切需要加强生物统计学的应用，对高校生物类专业，它也是一门应被十分重视的工具课程。本书正是为了满足这些需要而编写的。

本书的写作是在作者多年从事生物统计学教学和应用研究的基础上完成的。书中的内容主要侧重于各种统计方法的应用，在统计原理方面，一般只作概念上的介绍和公式的简单推导，对有些较复杂的统计公式则只给出公式，其目的主要是为让读者不但对统计学原理有较全面的了解，更重要的是结合实例了解和掌握各种常用统计方法。在本书的安排上，全书共分 12 章，概括起来主要有五个方面：第一章至第三章介绍统计和概率的基础知识，包括生物统计学的概念和内容、数据的搜集与整理、平均数和变异数的计算、概率和概率分布等；第四章、第五章介绍统计推断，包括样本平均数的检验、样本频率的检验、方差同质性检验、非参数检验和 χ^2 检验；第六章至第九章介绍统计分析方法，主要内容有方差分析、直线回归与相关分析、可直线化的曲线回归分析、多元回归与相关分析、逐步回归分析、多项式回归、协方差分析；第十章、第十一章介绍抽样与试验设计，主要包括抽样误差估计、抽样方法、抽样方案制订及常见的试验设计，如对比设计、随机区组设计、正交设计及其相应的统计分析方法；第十二章对近年来应用越来越多的多元统计分析进行了简单介绍。每章都附有一定数量的思考练习题，供读者参考。

本书中的例子主要有两个来源，一个是近年来有关生物学、农学、林学、医学、畜牧、水产、环保等领域或学科的实际研究资料，另一个是有关著作中的一些例题。崔党群教授在百忙中通审了全书，并提出了富有建设性的建议。贾玉书同志承担了本书的大部分绘图工作。姜丽娜同志在本书的录排中做了大量工作。在本书的出版过程中，得到了科学出版社的大力支持，特别是张晓春同志在书稿的编审和发行方面作了大量工作，在此一并表示谢意。

本书通俗易懂，具有一定的深度和广度，适合生物学、农学、医学、畜牧、水产、环保等领域或学科的科学工作者阅读，也可供本、专科院校生物类专业作为教材使用。

由于作者水平的限制和资料占有的局限性，本书难免会有错误和不妥之处，敬请读者批评指正，以便日后修订完善。

李春喜　王文林

1997 年 3 月

目　录

第五版前言
第一版前言
第一章　概论 …… 1
第一节　生物统计学的概念 …… 1
第二节　统计学发展概况 …… 2
一、古典记录统计学 …… 2
二、近代描述统计学 …… 2
三、现代推断统计学 …… 3
第三节　常用统计学术语 …… 4
一、总体与样本 …… 4
二、参数与统计数 …… 4
三、变量与资料 …… 5
四、因素与水平 …… 5
五、处理与重复 …… 6
六、效应与互作 …… 7
七、准确性与精确性 …… 7
八、误差与错误 …… 7
第四节　生物统计学的内容与作用 …… 8
思考练习题 …… 8
第二章　试验资料整理与特征数计算 …… 9
第一节　试验资料的搜集与整理 …… 9
一、试验资料的类型 …… 9
二、试验资料的搜集 …… 10
三、试验资料的整理 …… 15
第二节　试验资料特征数的计算 …… 20
一、平均数 …… 21
二、变异数 …… 24
思考练习题 …… 27
第三章　概率与概率分布 …… 29
第一节　概率基础知识 …… 29
一、概率的概念 …… 29
二、概率的计算 …… 31
三、概率分布 …… 32

四、大数定律 …… 34
第二节　几种常见的理论分布 …… 35
一、二项分布 …… 35
二、泊松分布 …… 39
三、正态分布 …… 41
第三节　统计数的分布 …… 46
一、抽样试验与无偏估计 …… 46
二、样本平均数的分布 …… 47
三、样本平均数差数的分布 …… 49
四、t 分布 …… 50
五、χ^2 分布 …… 51
六、F 分布 …… 52
思考练习题 …… 53
第四章　统计推断 …… 54
第一节　假设检验的原理与方法 …… 54
一、假设检验的概念 …… 54
二、假设检验的步骤 …… 55
三、双尾检验与单尾检验 …… 57
四、假设检验中的两类错误 …… 58
第二节　样本平均数的假设检验 …… 59
一、一个样本平均数的假设检验 …… 59
二、两个样本平均数的假设检验 …… 62
第三节　样本频率的假设检验 …… 69
一、一个样本频率的假设检验 …… 69
二、两个样本频率的假设检验 …… 71
第四节　参数的区间估计与点估计 …… 73
一、参数区间估计与点估计的原理 …… 73
二、一个总体平均数 μ 的区间估计与点估计 …… 74
三、两个总体平均数差数 $\mu_1-\mu_2$ 的区间估计与点估计 …… 75
四、一个总体频率 p 的区间估计与点估计 …… 76
五、两总体频率差数 p_1-p_2 的区间估计与点估计 …… 77
第五节　样本方差的同质性检验 …… 78
一、一个样本方差的同质性检验 …… 78
二、两个样本方差的同质性检验 …… 79
三、多个样本方差的同质性检验 …… 80
思考练习题 …… 81
第五章　χ^2 检验 …… 83
第一节　χ^2 检验的原理与方法 …… 83

第二节　适合性检验 …… 85
第三节　独立性检验 …… 88
一、2×2 列联表的独立性检验 …… 88
二、2×c 列联表的独立性检验 …… 90
三、r×c 列联表的独立性检验 …… 91
思考练习题 …… 92
第六章　方差分析 …… 94
第一节　方差分析的基本方法 …… 95
一、方差分析的基本原理 …… 95
二、数学模型 …… 95
三、平方和与自由度的分解 …… 97
四、统计假设的显著性检验——F 检验 …… 99
五、多重比较 …… 100
第二节　单因素方差分析 …… 105
一、组内观测次数相等的方差分析 …… 105
二、组内观测次数不相等的方差分析 …… 107
第三节　二因素方差分析 …… 109
一、无重复观测值的二因素方差分析 …… 109
二、具有重复观测值的二因素方差分析 …… 113
第四节　多因素方差分析 …… 119
第五节　方差分析缺失数据的估计 …… 124
一、缺失一个数据的估计方法 …… 124
二、缺失两个数据的估计方法 …… 125
第六节　方差分析的基本假定和数据转换 …… 126
一、方差分析的基本假定 …… 126
二、数据转换 …… 126
思考练习题 …… 130
第七章　直线回归与相关分析 …… 132
第一节　回归和相关的概念 …… 133
第二节　直线回归分析 …… 134
一、直线回归方程的建立 …… 134
二、直线回归的数学模型和基本假定 …… 137
三、直线回归的假设检验 …… 138
四、直线回归的区间估计 …… 140
五、直线回归的应用及注意问题 …… 144
第三节　直线相关 …… 145
一、相关系数和决定系数 …… 145
二、相关系数的假设检验 …… 146

三、相关系数的区间估计 …… 147
四、应用直线相关的注意事项 …… 148
思考练习题 …… 149
第八章　可直线化的非线性回归分析 …… 150
第一节　非线性回归的直线化 …… 151
一、曲线类型的确定 …… 151
二、数据变换的方法 …… 152
第二节　倒数函数曲线 …… 153
第三节　指数函数曲线 …… 156
第四节　对数函数曲线 …… 158
第五节　幂函数曲线 …… 160
第六节　Logistic 生长曲线 …… 163
一、Logistic 生长曲线的由来和基本特征 …… 163
二、Logistic 生长曲线方程的配合 …… 164
思考练习题 …… 166
第九章　试验设计及其统计分析 …… 167
第一节　试验设计的基本原理 …… 167
一、试验设计的意义 …… 168
二、生物学试验的基本要求 …… 168
三、试验设计的基本要素 …… 169
四、试验误差及其控制途径 …… 169
五、试验设计的基本原则 …… 171
第二节　对比设计及其统计分析 …… 172
一、对比设计 …… 172
二、对比设计试验结果的统计分析 …… 173
第三节　随机区组设计及其统计分析 …… 175
一、随机区组设计 …… 175
二、随机区组设计试验结果的统计分析 …… 176
第四节　拉丁方设计及其统计分析 …… 182
一、拉丁方设计 …… 182
二、拉丁方设计试验结果的统计分析 …… 184
第五节　裂区设计及其统计分析 …… 187
一、裂区设计 …… 187
二、裂区设计试验结果的统计分析 …… 187
第六节　正交设计及其统计分析 …… 194
一、正交表及其特点 …… 194
二、正交试验的基本方法 …… 196
三、正交设计试验结果的统计分析 …… 198

思考练习题…… 201
第十章 协方差分析…… 204
第一节 协方差分析的作用…… 205
一、降低试验误差,实现统计控制 …… 205
二、分析不同变异来源的相关关系 …… 205
三、估计缺失数据 …… 206
第二节 单因素试验资料的协方差分析…… 206
一、计算变量各变异来源的平方和、乘积和与自由度 …… 208
二、检验 x 和 y 是否存在直线回归关系 …… 209
三、检验矫正平均数 $\bar{y}_{i(x=\bar{x})}$ 间的差异显著性 …… 210
四、矫正平均数 $\bar{y}_{i(x=\bar{x})}$ 间的多重比较…… 211
第三节 二因素试验资料的协方差分析…… 213
一、乘积和与自由度的分解 …… 215
二、检验 x 和 y 是否存在直线回归关系 …… 216
三、检验矫正平均数 $\bar{y}_{i(x=\bar{x})}$ 间的差异显著性 …… 216
第四节 协方差分析的数学模型和基本假定…… 217
一、协方差分析的数学模型 …… 217
二、协方差分析的基本假定 …… 217
思考练习题…… 218
第十一章 多元线性回归与多元相关分析…… 219
第一节 多元线性回归分析…… 219
一、多元线性回归模型 …… 220
二、多元线性回归方程的建立 …… 220
三、多元线性回归的假设检验和置信区间 …… 226
第二节 多元相关分析…… 230
一、多元相关分析 …… 230
二、偏相关分析…… 231
思考练习题…… 235
第十二章 逐步回归与通径分析…… 237
第一节 逐步回归分析…… 237
一、逐个淘汰不显著自变量的回归方法 …… 238
二、逐个选入显著自变量的回归方法 …… 243
第二节 通径分析…… 247
一、通径与通径系数的概念 …… 247
二、通径系数的求解方法 …… 248
三、通径分析的假设检验 …… 251
思考练习题…… 253

第十三章　多项式回归分析…… 255
第一节　多项式回归的数学模型…… 255
第二节　多项式回归方程的建立…… 256
一、多项式回归方程的建立与求解 …… 256
二、多项式回归方程的图示 …… 259
第三节　多项式回归方程的假设检验…… 259
第四节　相关指数…… 261
第五节　正交多项式回归分析…… 261
一、正交多项式回归分析原理 …… 261
二、正交多项式回归分析示例 …… 263
思考练习题…… 265
主要参考文献…… 266
附表…… 268
索引…… 293

第一章

概　论

本章提要

生物统计学是把数学的语言引入具体的生命科学领域，运用数理统计的原理和方法对生物有机体开展调查和试验，目的是以样本的统计数估计总体的参数，对所研究的总体进行合理的推论。生物统计学主要包括试验设计和统计分析两部分内容，其作用主要有4个方面：提供整理、描述数据资料的科学方法并确定其数量特征，判断试验结果的可靠性，提供由样本推断总体的方法，提供试验设计的原则。统计学的发展经历了古典记录统计学、近代描述统计学和现代推断统计学3个阶段。本章还介绍了统计学中几组常用的术语。

第一节　生物统计学的概念

统计学(statistics)是把数学的语言引入具体的科学研究领域，将所研究的问题抽象为数学问题的过程，是搜集、分析和解释数据的一门科学。生物统计学(biostatistics)是数理统计(mathematical statistics)在生物学研究中的应用，它是用数理统计的原理和方法来分析和解释生物界各种现象和试验调查资料的一门学科，属于应用统计学的一个分支。随着生物学研究的不断发展，生物统计学的应用也越来越广泛。

生物学研究的对象是生物有机体，与非生物相比，它具有特殊的变异性、随机性和复杂性。生物有机体的生长发育、生理活动、生化变化及有机体受外界各种随机因素的影响等，都使生物学研究的试验结果有较大的差异性，这种差异性往往会掩盖生物体本身的特殊规律。在生物学研究中，大量试验资料内在的规律性也容易被杂乱无章的数据所迷惑，从而被人们忽视。因此，在生物学研究中，应用生物统计学就显得特别重要。生物学研究的实践证明，只有正确地应用生物统计学的原理和分析方法对生物学试验进行合理设计，对数据进行客观分析，才能得出科学的结论。

生物统计学是在生物学研究过程中，逐渐与数学的发展相结合而形成的，它是应用数学的一个分支，属于生物数学的范畴。生物统计学是把数学的方法引入具体的生命科学

领域，把生命科学领域中具体的研究问题抽象为数学问题，从大量试验数据中探寻其规律的过程，以数学的概率论和数理统计为基础，涉及数列、排列、组合、矩阵、微积分等知识。作为一门工具课，生物统计学一般不过多讨论数学原理，而主要偏重于统计原理的介绍和具体分析方法的应用。

第二节　统计学发展概况

人类的统计实践是随着记数活动而产生的。因此，对统计发展的历史可追溯到远古的原始社会。但是，使人类的统计实践上升到理论予以总结和概括成一门系统的统计学，起源于17世纪英国，其代表人物W. Petty (1623～1687)是政治算术学派的奠基人，代表作是《政治算术》。政治算术学派主张用大量观察和数量分析等方法对社会经济现象进行研究，为统计学的发展开辟了广阔的前景。由于W. Petty对统计学的形成有着巨大的贡献，马克思称他为“统计学的创始人”。统计学的发展经历了古典记录统计学、近代描述统计学和现代推断统计学3个阶段。

一、古典记录统计学

古典记录统计学(record satistics)形成于17世纪中叶至19世纪中叶。在最初兴起时，通过用文字或数字如实记录与分析国家社会经济状况，初步建立了统计研究的方法和规则。概率论被引进之后，逐渐成为一种较为成熟的方法。

瑞士数学家J. Bernoulli(1654～1705)系统论证了大数定律。后来，J. Bernoulli的后代D. Bernoulli(1700～1782)将概率论的理论应用到医学和人类保险。

法国天文学家、数学家、统计学家P. S. Laplace(1749～1827)发展了概率论的研究，建立了严密的概率数学理论，并在天文学、物理学的研究中进行了推广应用。他研究了最小二乘法，提出了“拉普拉斯定理”(中心极限定理的一部分)，初步建立了大样本推断的理论基础，为后人开创了抽样调查的方法。

正态分布理论对研究生物统计学的理论十分重要，它最早是由法国数学家De Moiver于1733年发现的。德国天文学家和数学家G. F. Gauss(1777～1855)在研究观察误差理论时，也独立推导出测量误差的概率分布方程，并提出了“误差分布曲线”。这条分布曲线称为Gauss分布曲线，也就是正态分布曲线。

二、近代描述统计学

近代描述统计学(description statistics)形成于19世纪中叶至20世纪上半叶，这个时期也是统计学应用于生物学研究的开始和发展时期，其“描述”特色是由一批原来研究生物进化的学者们提炼而成的。英国遗传学家F.Galton(1822～1911) 自1882年起开设“人体测量实验室”，分析父母与子女的变异，探寻其遗传规律，应用统计方法研究人种特性和遗传，探索了能把大量数据加以描述与比较的方法和途径，引入了中位数、百分位数、四分位数，以及分布、相关、回归等重要的统计学概念与方法，开辟了生物学研究的新领域。尽管他的研究当时并未成功，但由于他开创性地将统计方法应用于生物学研究，后人推崇他为生物统计学的创始人。

F.Galton 和他的继承人 K. Pearson(1857～1936)经过共同努力于 1895 年成立了伦敦大学生物统计实验室,1889 年发表了《自然界的遗传》一文,并于 1901 年创办了 *Biometrika*(《生物统计学报》或《生物计量学报》)这一权威杂志。在该杂志的创刊词中,F.Galton和 K.Pearson 首次为他们所运用的统计方法明确提出了"生物统计"(biometry)一词,F.Galton 解释为:所谓生物统计学,就是应用于生物学科中的统计方法。在《自然界的遗传》一文中,K. Pearson 提出了相关与回归分析问题,并给出了简单相关系数和复相关系数的计算公式。1900 年,K. Pearson 在研究样本误差效应时,提出了 χ^2 检验,它在属性资料的统计分析中有着广泛的应用。

三、现代推断统计学

现代推断统计学(inference statistics)形成于 20 世纪初至 20 世纪中叶。随着社会科学和自然科学领域研究的不断深入,各种事物与现象之间繁杂的数量关系以及一系列未知的数量变化,单靠记录或描述的统计方法已难以奏效。因此,要求采用推断的方法来掌握事物之间的真正联系并对事物进行预测。从描述统计学到推断统计学,这是统计学发展过程中的一个巨大飞跃。

K. Pearson 的学生 W. S. Gosset(1876～1937)对样本标准差进行了大量研究,于 1908 年以笔名"Student"在 *Biometrika* 杂志上发表了论文《平均数的概率误差》,创立了小样本检验的理论和方法,即 t 分布和 t 检验法。t 检验已成为当代生物统计工作的基本工具之一,它也为多元分析的理论形成和应用奠定了基础。因此,许多统计学家把 1908 年看成是统计推断理论发展史上的里程碑,也有人推崇 W.S.Gosset 为推断统计学(尤其是小样本研究理论)的先驱者。

英国统计学家 R. A. Fisher(1890～1962)于 1923 年发展了显著性检验及估计理论,提出了 F 分布和 F 检验,创立了方差和方差分析。在从事农业试验及数据分析研究时,他提出了随机区组法、拉丁方法和正交试验的方法。1915 年,R.A.Fisher 在 *Biometrika* 上发表论文《无限总体样本相关系数值的频率分布》,被称为现代推断统计学的第一篇论文。1925 年,R.A.Fisher 发表了《试验研究工作中的统计方法》,对方差分析及协方差分析进一步作了完整的解释,从而推动和促进了农业科学、生物学及遗传学的研究与发展。自方差分析问世以来,各种数理统计方法不但在实验室中成为研究人员的析因工具,而且在田间试验、饲养试验、临床试验等农学、医学和生物学领域也得到了广泛应用。

J. Newman(1894～1981)和 E. S. Pearson 进行了统计理论的研究工作,分别于 1936 年和 1938 年提出了一种统计假设检验学说。假设检验和区间估计作为数学上的最优化问题,对促进统计理论研究和对试验作出正确结论具有非常实用的价值。

另外,P. C. Mabeilinrobis 对作物抽样调查、A. Waecl 对序贯抽样、K. Mather 对群体遗传学、F. Yates 对田间试验设计等都作出了杰出的贡献。

我国对生物统计学的应用始于 1913 年顾澄教授翻译的英国统计学家 G.U.Yule 在 1911 年出版的关于描述统计学的名著《统计学之理论》,这标志着英国、美国数理统计学传入中国的开始。之后,许多生物学研究工作者积极从事统计学理论和实践的应用研究,使生物统计学在农业科学、医学科学、生物学、遗传学、生态学等学科领域发挥了重要作

用。应用试验设计方法和统计分析理论,进行农作物品种产量比较试验、病虫害的预测预报、动物饲养试验、饲料配方、毒理试验、动植物资源的调查与分析、动植物育种中遗传资源及亲代和子代遗传的分析等都取得了较好成果。

近年来,生物统计学发展迅速,从中又分支出群体遗传学、生态统计学、生物分类统计学、毒理统计学等。由于数学与生物学、医学和农学的应用,使生物数学成为一门新的学科,生物统计学只是它的一个分支学科。1974 年,联合国教育、科学及文化组织在编制学科分类目录时,第一次把生物数学作为一门独立的学科列入生命科学类中。随着计算机的普及和网络技术的发展,SAS(statistical analysis system)、SPSS(statistical package for the social science)等国际通用统计软件的开发和应用,以及生命科学研究领域的不断深入,生物统计学的研究和应用必将越来越广泛,越来越深入。

第三节　常用统计学术语

一、总体与样本

具有相同性质的个体所组成的集合称为总体(population),它是指研究对象的全体,而组成总体的基本单元称为个体(individual)。

总体按所含个体的数目可分为有限总体和无限总体。个体极多或无限多的总体称为无限总体(infinite population)。例如,某一棉田棉铃虫的头数,可以认为是无限总体。另外,也可从抽象意义上来理解无限总体。例如,通过临床试验来推断某种药品比另一种药品治愈率高,这里无限总体是指一个理论性总体。个体有限的总体称为有限总体(finite population)。例如,对某一班学生身高进行调查,这时总体是指这一班中每位学生的身高。

要研究总体的性质,一般情况下我们无法对总体中的个体全部取出进行调查或研究。因为在实际研究过程中,常会遇到两种难以克服的困难:一是总体的个体数目较多,甚至无限多;二是总体的数目虽然不多,但试验具有破坏性,或者试验费用很高,不允许做更多的试验。在这种情况下,只能采取抽样的方法,从总体中抽取一部分个体进行研究。

从总体中抽出的若干个体所构成的集合称为样本(sample),构成样本的每个个体称为样本单位(sample unit),样本中个体的数目称为样本容量(sample size),记为 n 。样本的作用在于估计总体。例如,可以调查某一地区棉田 100 株棉花上的棉铃虫头数,来推断该地区棉铃虫的发生状况,以采取相应的对策。一般在生物学研究中,$n < 30$ 的样本称为小样本,$n \geqslant 30$ 的样本称为大样本。在一些计算和分析检验方法上,大、小样本是不同的。

在对事物的研究过程中,人们常通过某事物的一部分(样本)来估计事物全部(总体)的特征,目的是为了以样本的特征对未知总体进行推断,从特殊推导一般,对所研究的总体作出合乎逻辑的推论,得到对客观事物的本质和规律性的认识。在生物学研究中,我们所期望的是总体,而不是样本。但是在具体的试验过程中,我们所得到的却是样本而不是总体。因此,从某种意义上讲,生物统计学是研究生命过程中以样本来推断总体的一门学科。

二、参数与统计数

参数(parameter)也称为参量,是对一个总体特征的度量,常用希腊字母表示,如总体

平均数 μ、总体标准差 σ 等均为参数。统计数(statistic)也称为统计量,是由样本计算所得的数值,它是描述样本特征的数量,常用英文字母表示,如样本平均数 $\bar{x}$、样本标准差 s 等。由于总体一般都很大,有的甚至不可能取得,所以总体参数通常是未知的。正因为如此,我们才进行抽样,由于样本是已经抽出来的,所以统计数是可以计算出来的,我们可以根据样本统计数来估计总体的参数。此外,还有一些统计量是为了进行统计分析而构造出来的,如后续章节中的 u 统计量、t 统计量及 F 统计量等。

三、变量与资料

相同性质的事物间表现差异性的某项特征或性状称为变量或变数(variable),是研究者在确定了研究目的之后,所观测的试验指标。由于试验目的不同,所选择的变量也不相同,如植物叶片叶绿素的含量,人体身高、体重、血糖含量、血型等。变量通常记为 x,如10个人的身高为155～180cm,共有158,167,173,155,180,165,175,178,170,162(cm)10个变量值,记作 $x_i(i=1,2,\cdots,10)$,表示 x_1 到 x_{10} 之间任一数值。变量的观察结果可以是定量的,也可以是定性的,其结果称为变量值(value of variable)或观测值(observed value),也称为数据、资料(data)。

根据获取观测值的方式及测量方法所提供的数值信息的差异,变量可以分为定量变量和定性变量。通过测量所获得的、用具体数值与特定计量单位表达的数据称为定量变量(quantitative variable),也称为数值变量(numerical variable)。其变量值是定量的,表现为数值大小,一般有度量衡单位,如人的身高(cm)、体重(kg)、脉搏计数(次/min)等。定量变量根据取值的不同,可以分为连续变量和非连续变量。连续变量(continuous variable)表示在变量范围内可抽出某一范围的所有值,变量之间是连续的、无限的。例如,小麦的株高为80～90cm,在此范围内可以取得无数个变量。非连续变量(discontinuous variable)也称为离散型变量(discrete variable),表示在变量数列中仅能取得固定数值,并且通常是整数,如菌落中的菌数、单位面积水稻的茎数、小白鼠每胎产仔数等。

定性变量(qualitative variable)也称为分类变量(categorical variable)、名义变量(nominative variable),其变量值是定性的,表示某个体属于几种互不相容的类型中的一种。例如,果蝇的翅有长翅与残翅,人的血型有A、B、AB和O型,豌豆花的颜色有白色、红色和紫色,等等。

变量的类型是根据研究目的而确定的。根据需要,各类变量可以互相转化。例如,以人作为研究对象,观察某人群成年男子的血红蛋白含量(mg/L),属于定量变量;若按血红蛋白含量正常与偏低分为两类,则属于定性变量。

对应于变量,常量(constant)是不能给予不同数值的变量,它是代表事物特征和性质的数值,通常由变量计算而来,在一定过程中是不变的,如总体平均数、标准差、变异系数等。只有在事物的总体发生变动时,常量才随之变化。

四、因素与水平

试验中所研究的影响试验指标的原因或原因组合称为试验因素(experimental factor)或处理因素(treatment factor),简称为因素或因子(factor)。试验因素常用大写字

母，如 A、B、C 等来表示。

每个试验因素的不同状态(处理的某种特定状态或数量上的差别)称为因素水平(level of factor)，简称为水平(level)。例如，研究温度对某种酶活性的影响，所设置的15℃、20℃、25℃、30℃ 分别称为温度因素的一个水平。可见，因素是一个抽象的概念，而水平则是一个较为具体的概念。水平常用代表该因素的字母添加下标(如1、2、3等)来表示，如 A_1、A_2、B_1、B_2 等。

按照性质不同，因素可以分为可控因素和非控因素。在试验中可以人为调控的因素称为可控因素(controllable factor)或固定因素(fixed factor)。该因素的水平可准确控制，且水平固定后，其效应也固定，同时在试验进行重复时可以得到相同的结果。例如，研究3种温度对胰蛋白酶水解产物的影响，因为温度是可以严格控制的，所以在重复该试验时对于相同的温度其水解产物的量也是固定的。温度在此例中即为固定因素。

在试验中不能人为调控的因素称为非控因素(uncontrollable factor)或随机因素(random factor)。该因素的水平不能严格控制，或虽水平能控制，但其效应仍为随机变量，同时在试验进行重复时不易得到相同的结果。例如，研究农家肥不同施用量对作物产量的影响，由于农家肥有效成分较为复杂，不能像控制温度那样，将农家肥有效成分严格地控制在某一固定值上，在重复试验时即使施用相同数量的农家肥，也得不到一个固定的效应值。农家肥在此例中即为随机因素。

五、处理与重复

试验处理(experimental treatment)通常也称为处理(treatment)，是指对受试对象给予的某种外部干预(或措施)。其中受试对象(tested subject)又称为试验单位或试验单元(experimental unit)，是指在试验中能接受不同试验处理的独立的试验载体。植物个体、动物个体，以及不同的组织、器官等都可以作为试验单位。

处理根据所涉及的因素数可以分为单因素处理和多因素处理。当试验中涉及的因素只有一个时，称为单因素处理(single factor treatment)。在单因素处理中，实施在试验单位上的具体项目就是试验因素的某一水平。例如，饲料的比较试验，实施在试验单位(如某种畜禽)上的具体项目就是饲喂某一种饲料。进行单因素试验时，试验因素的一个水平就是一个处理。

如果试验中涉及两个或两个以上的因素，则称为多因素处理(multiple factors treatment)。可依处理因素数进行具体命名，如二因素试验处理、三因素试验处理等。在多因素试验处理中，实施在试验单位上的具体项目是各因素的某一水平组合。例如，3个播种密度对4个小麦品种的产量影响试验，就是一个二因素试验处理，试验共有 $3\times4=12$ 个水平组合，实施在试验单位(小麦)上的具体项目就是某个种植密度与某个小麦品种的组合。进行多因素试验时，试验因素的一个水平组合就是一个处理。相对于单因素试验，多因素试验不但可以研究因素的主效，同时也可研究因素之间的交互作用。

重复(repetition)是指在试验中，将一个处理实施在两个或两个以上的试验单位上。处理实施的试验单位数即为处理的重复数。例如，研究某种饲料对猪的增重效果，将该种饲料饲喂5头猪，则表明这个处理(饲料)有5次重复。

六、效应与互作

试验因素相对独立的作用称为该因素的主效应(main effect),简称为主效或效应(effection)。例如,不同饲料使动物的体重增加表现出差异,不同品种的玉米产量不同等。两个或两个以上处理因素间相互作用所产生的效应,称为互作效应(interaction effect),简称为互作或连应(interaction),如氮、磷肥共施会对作物产量产生互作效应。互作效应有正效应,也有负效应。如果氮、磷肥共施的产量效应大于氮、磷肥单施效应之和,说明氮磷肥互作效应为正效应;如果氮、磷肥共施的产量效应小于氮、磷肥单施效应之和,说明氮磷肥互作效应为负效应。互作效应为零,则称因素间无交互作用,没有交互作用的因素是相互独立的因素。应该注意的是,有时交互作用相当大,甚至可以忽略主效。因素间是否存在交互作用有专门的统计推断方法,有时也可根据专业知识或经验加以判断。

七、准确性与精确性

准确性也称为准确度(accuracy),是指在调查或试验中某一试验指标或性状的观测值与真值接近的程度。精确性也称为精确度(precision),是指调查或试验中同一试验指标或性状的重复观测值彼此接近程度的大小。统计学是以样本的统计数来推断总体参数的。我们用统计数接近参数真值的程度来衡量统计数准确性的高低,用样本中各变量间变异程度的大小来衡量该样本统计数精确性的高低。因此,准确性不等于精确性。准确性反映测定值与真值符合程度的大小,而精确性则是反映多次测定值的变异程度。

不同研究对精确度的要求是不一样的。一般来说,化学测量应当有较高的精确性,动物实验或医学临床试验由于试验对象个体差异及测定条件的影响,较难控制精确性,但应尽量将其控制在专业规定的允许范围内。

八、误差与错误

误差(error)也称为试验误差(experimental error),是指观测值偏离真值的差异。试验误差可以分为随机误差和系统误差两类。随机误差(random error)也称为抽样误差(sampling error)、偶然误差(accidental error),是由于试验中许多无法控制的偶然因素所造成的试验结果与真实值之间的差异,是不可避免的。统计上的试验误差通常就是指随机误差。我们可以通过增加抽样或试验次数降低随机误差,但不能完全消除随机误差。系统误差(systematic error)也称为片面误差(lopsided error),是由于试验处理以外的其他条件明显不一致所产生的带有倾向性的或定向性的偏差。系统误差主要由一些相对固定的因素引起,如仪器调校的差异、各批次药品间的差异、不同操作者操作习惯的差异等。系统误差在某种程度上是可以控制的,只要试验工作做得精细,在试验过程中是可以避免的。

错误(mistake)又称为过失性误差(gross error),是指在试验过程中,人为因素所引起的差错。例如,试验人员粗心大意,使仪器校正不准、药品配制比例不当、称量不准确、数据抄错、计算出现错误等。在科学研究过程中,这类错误是不允许产生的。

第四节　生物统计学的内容与作用

生物统计学的基本内容，概括起来主要包括试验设计(experimental design)和统计分析(statistical analysis)两大部分。试验设计是指应用统计的原理与方法制订试验方案、选择试验材料并进行合理分组，使我们可以用较少的人力、物力和时间获得较多而可靠的数据资料。统计分析是指应用数理统计的原理与方法对数据资料进行分析与推断，主要包括统计描述和统计推断，涉及数据资料的搜集和整理、特征数的计算、假设检验、方差分析、回归和相关分析、协方差分析等。从二者的关系来看，统计分析可以为试验设计提供合理的依据，而试验设计又是统计分析方法的进一步运用。合理地进行调查或试验设计，科学地整理、分析所得到的资料是生物统计学的根本任务。

生物统计学的基本作用可以概括为以下 4 个方面。

(1) 提供整理和描述数据资料的科学方法，确定某些性状和特性的数量特征。一批试验或数据资料，若不整理则杂乱无章，不能说明任何问题。统计方法提供了整理资料、化繁为简的科学程序，它可以从众多的数据资料中，归纳出几个特征数或绘制出一定形式的图表，使研究者从少数的特征数或一些简单的图表中了解大批资料所蕴藏的信息。

(2) 判断试验结果的可靠性。一般在试验中要求除试验因素以外，其他条件都应控制一致，但在实践中无论试验条件控制得如何严格，其试验结果总是受试验因素和其他偶然因素的影响，这是造成试验误差的重要原因。要正确判断一个试验结果是由试验因素造成的还是由试验误差造成的，就必须运用统计分析的方法。

(3) 提供由样本推断总体的方法。试验的目的在于认识总体规律，但由于总体庞大，一般无法实施，在研究过程中都是抽取总体中的部分作为样本，用统计方法以样本来推断总体的规律性。在这种推断中，统计学原理和方法起到了理论上的保证作用。

(4) 提供试验设计的一些重要原则。为了以较少的人力、物力和财力取得较多的试验资料和较好的试验结果，在一些生物学研究中，就需要以统计原理为依据，科学地进行试验设计。以往有一些试验资料，由于设计不当而丧失了大量的试验信息，究其原因多是由于缺乏科学的统计学知识，从而使试验的效率大大降低。尽管统计学原理和分析方法对试验设计有着积极的指导意义，但它绝对不可能代替试验设计。如果试验目的、要求不明确，设计不合理，试验条件不合适，统计数据不准确，这种试验绝对不会成功，统计学原理和分析方法也不可能挽救试验的这种失败。

思考练习题

习题 1.1　什么是生物统计学？生物统计学的主要内容和作用是什么？

习题 1.2　解释以下概念：

总体、个体、样本、样本容量、变量、参数、统计数、因素、水平、处理、重复、效应、互作、试验误差。

习题 1.3　随机误差与系统误差有何区别？

习题 1.4　准确性与精确性有何区别？

第二章

试验资料整理与特征数计算

本章提要

试验资料的搜集与整理是数据资料处理的首要环节。资料搜集常用的方法有调查和试验，资料的整理一般需要通过对原始资料进行检查、核对，制作次数分布表和次数分布图来完成。试验资料具有集中性和离散性两种基本特征。平均数是反映集中性的特征数，主要包括算术平均数、中位数、众数、几何平均数等；而反映离散性的特征数是变异数，主要包括极差、方差、标准差和变异系数等。

在生物学试验及调查中能够获得大量的原始数据，这是在一定条件下对某种具体事物或现象观察的结果，我们称之为资料(data)。这些资料在未整理之前，一般是分散的、零星的和孤立的，是一堆无序的数字。统计分析就是要依靠这些资料，通过整理分析进行归类，使其条理化，然后列成统计表，绘出统计图，计算出平均数、变异数等特征数。

第一节　试验资料的搜集与整理

一、试验资料的类型

对试验资料进行分类是统计归纳的基础，若不进行分类，大量的原始资料就不能系统化、规范化。对试验资料进行分类整理时，必须坚持“同质”的原则。只有“同质”的试验数据，才能根据科学原理来分类，使试验资料能正确反映事物的本质和规律。

由于使用方法和研究的性状特性不同，生物学试验及调查所得资料的性质也不同。生物的性状，按其特性可分为数量性状(quantitative character)和质量性状(qualitative character)两大类。我们所得到的资料有些是定量的，有些是定性的，这些资料可以分为数量性状资料和质量性状资料。

(一) 数量性状资料

数量性状资料(data of quantitative character)一般是由计数和测量或度量得到的。由计数法得到的数据称为计数资料(enumenation data)，也称为非连续变量资料(data of

discontinous variable),如鱼的尾数、玉米果穗上籽粒行数、种群内的个体数、人的白细胞计数等。计数资料的变量值以正整数出现,不可能带有小数。例如,鱼的尾数只可能是 $1,2,\cdots,n$,绝对不会出现 2.5,4.8 等这样的数据。

由测量或度量所得的数据称为计量资料(measurement data),也称为连续变量资料(data of continuous variable),数据通常用长度、重量、体积等单位表示,如人的身高、玉米的果穗重量、仔猪的体重、奶牛的产奶量等。计量资料不一定是整数,在相邻值之间有微小差异的数值存在。例如,小麦的株高为 80～95cm,可以是 85cm,也可以是 86cm,甚至可以是 86.5cm 或 86.54cm 等变量值,随小数位数的增加,可以出现无限个变量值。至于小数位数的多少,要依试验的要求和测量仪器或工具的精度而定。

(二) 质量性状资料

质量性状资料(data of qualitative character)也称为属性资料(attribute data),是指对某种现象只能观察而不能测量的资料。例如,水稻花药、籽粒、颖壳的颜色,小麦芒的有无,茸毛的有无,果蝇的长翅与残翅,人血型的 A、B、AB、O 型,动物的雌、雄,疾病治疗的疗效有痊愈、好转、无效等。为了便于统计分析,一般需先把质量性状资料数量化,可以采取下面两种方法。

1. 统计次数法

统计次数法(frequency counting)是于一定总体内,根据某一质量性状的类别统计其次数或频数(frequency),以次数或频数作为该质量性状的数据。在分组统计时可按质量性状的类别进行分组,然后统计各组出现的次数。因此,这类资料也称为次数资料(frequency data)。例如,红花豌豆与白花豌豆杂交,统计 F_2 代不同花色的植株时,在 1000 株植株中,有红花 266 株、紫花 494 株、白花 240 株,可以计算出 3 种颜色花出现的次数百分率分别为:26.6%、49.4%和 24.0%。

2. 评分法

评分法(point system)是用数字级别表示某现象在表现程度上的差别。例如,小麦感染锈病的严重程度可划分为 0 级(免疫)、1 级(高度抵抗)、2 级(中度抵抗)、3 级(感染);家畜肉质品质可以评为三级,好的评为 10 分,较好的评为 8 分,差的评为 5 分。这样,就可以将质量性状资料进行数量化。经过数量化的质量性状资料的处理方法可以参照计数资料的处理方法进行。

二、试验资料的搜集

从统计学意义上讲,生物学所研究的一切问题,归根结底是用样本来估计总体的问题。因此,样本资料的搜集(collection)是统计分析的第一步,也是全部统计工作的基础。资料的来源一般有两个,即调查和试验。无论是调查还是试验,统计学对原始资料都要求完整和准确。

(一) 调查

资料的调查(survey)是对已有的事实通过各种方式进行了解,然后用统计的方法对

所得数据进行分析，从而找出其中的规律。调查有两种方法，一种是普查，另一种是抽样调查。

1. 普查

普查(census)是指对研究对象的每一个个体逐一进行调查，也称为全面调查(complete survey)。普查涉及的范围广、时间长、工作量大，因而需要消耗大量的人力、物力和时间。普查的目的主要是摸清研究对象的基本情况，如人口普查、土壤普查等。

在生物学研究中，普查仅仅是在极少数情况下才能进行的调查，多数情况还是抽样调查，如某一地区的生物资源调查、棉田某一病害发病率调查等，都需要抽样调查。

2. 抽样调查

抽样调查(sampling survey)是一种非全面调查，它是根据一定的原则对研究对象抽取一部分个体进行测量或度量，把得到的数据资料作为样本进行统计处理，然后利用样本特征数对总体参数进行推断。要使样本无偏差地估计总体，除了样本容量要尽量大之外，重要的是采用科学的抽样方法，抽取有代表性的样本，取得完整而准确的数据资料。实践证明，正确的抽样方法不仅能节约人力、物力和财力，而且与相应的统计分析方法相结合，可以做出比较准确的估计和推断。

生物学研究中，由于研究的目的和性质不同，所采取的抽样方法也各不相同。常用的抽样方法有随机抽样、顺序抽样和典型抽样。

1) 随机抽样

随机(random)是指在试验过程中对试验单位的抽样、分组、实施处理及其试验顺序等都必须遵守随机原则，避免人为主观因素的影响。也就是说，随机是指一个重复中的某一处理或处理组合被安排在哪一个试验单位，不要有主观成见。随机抽样(random sampling)要求在进行抽样过程中，总体内所有个体都具有相同的被抽取的概率，因此随机抽样又称为概率抽样(probability sampling)。由于抽样的随机性，可以正确地估计试验误差，从而推出科学合理的结论。随机抽样必须满足两个条件：① 总体中每个个体被抽中的机会是均等的；② 总体中任意一个个体是否被抽中是相互独立的，即个体是否被抽中不受其他个体的影响。其中第二条适合于无限总体，但对生物学研究来说，部分研究的抽样对象属于有限总体，要完全符合随机样本的理论要求就非常困难。随机抽样有以下几种方法：简单随机抽样、分层随机抽样、整体抽样、双重抽样。

(1) 简单随机抽样。简单随机抽样(simple random sampling)是最简单、最常用的一种抽样方法，要求被抽总体内每一个体被抽取的机会完全相等。随机抽样的结果可用统计方法进行分析，从而对总体作出推断，并对推断的可靠性作出度量。

简单随机抽样就是采用随机的方法直接从总体中抽选若干个抽样单位构成样本。其方法是将总体内所有抽样单位全部编号，采用随机方法确定被抽单位编号，这些编号所对应的抽样单位抽出来放在一起就构成一个随机样本。简单随机抽样适用于个体间差异较小、所需抽取的样本单位数较少的情况。对于那些具有某种趋向或差异明显和点片式差异的总体不宜使用。

【例 2.1】 表 2-1 为 30 头仔猪的断奶体重(kg)资料，试将其作为一个总体，采用简单随机抽样的方法，从中抽出一个含有 10 个抽样单位的随机样本。

首先,将 30 头仔猪断奶体重资料依次编号 1～30(表 2-1)。

表 2-1　30 头仔猪断奶体重资料及其编号

编号	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
体重/kg	19.0	15.2	15.5	19.0	19.5	20.0	23.5	19.0	19.5	21.5	21.0	16.5	15.6	20.5	14.0
编号	16	17	18	19	20	21	22	23	24	25	26	27	28	29	30
体重/kg	17.7	14.7	15.7	19.0	22.0	18.7	16.7	21.5	17.0	20.0	16.0	22.2	23.5	17.0	20.0

其次,随机法确定被抽单位编号。用随机发生器、查随机数字表或其他方法得到若干随机数字(random digit)。对本例,如得到一组随机数字:43、65、71、05、89、03、68、44、10、42 和 25,把大于 30 的数字除以 30 记其余数,然后划去重复的数字,得:13、05、11、29、03、08、14、10、12 和 25,即为被抽单位编号。若采用抽签法(lottery),由于这是一个较小的有限总体,应采用复置抽样。复置抽样(sampling with replacement)又称为放回抽样,是指在每次抽样时抽出一个个体后,该个体复返原总体,继续参与抽样的方法。

(2) 分层随机抽样。分层随机抽样(stratified random sampling)是一种混合抽样。其特点是将总体按变异原因或程度划分成若干区层(strata),然后再用简单随机抽样方法,从各区层按一定的抽样分数(sampling fraction)(即一个样本所包括抽样单位数与其总体所包括的抽样单位数的比值)抽选抽样单位。

分层随机抽样的具体方法可分两步进行:① 总体按变异原因与程度划分成若干区层(可以是地段、地带、生物的一个品种等),使区层内部变异尽可能小或者变异原因相同,而区层之间变异比较大或者变异原因不同;② 在每个区层按一定的抽样分数独立随机抽样。

将总体划分区层时,从各区层抽选的抽样单位数可以相等,也可以不等。一般采用 3 种方法配置各区层应抽选的抽样单位数。

相等配置(equal allocation):如果各区层的抽样单位数相等,可采用相等配置。

比例配置(proportional allocation):如果各区层抽样单位数不等,可按相同的抽样分数,把欲抽取的抽样单位总数分配到各区层。

最优配置(optimum allocation):根据各区层的抽样单位数、抽样误差和抽样费用,确定各区层应抽取的抽样单位数。这种配置方式可在抽样费用一定时,抽样误差最小。与比例配置相比较,最优配置在一个区层应抽取多少单位数,要根据该区的变异和抽样费用综合考虑。即在变异范围较大的区层,抽样分数应大一些;在变异范围较小的区层,抽样分数可小一些。而在抽样费用较高的区层,抽样分数应小一些;在抽样费用较低的区层,抽样分数可大一些。

分层随机抽样具有以下两个优点:一是若总体内各抽样单位间的差异比较明显,可以把总体分为几个比较同质的区层,从而提高抽样的准确度;二是分层随机抽样类似于随机区组设计,既运用了随机原理,也运用了局部控制原理,这样不仅可以降低抽样误差,也可以运用统计方法来估算抽样误差。

【例 2.2】 现有一块麦田,其长势呈单向趋向式变化,欲抽样估产,如何进行抽样?

由于长势存在趋向式变化，可将麦田分为若干区层，区层数则要视变异大小而定。变异大可多分几个区层，变异小可少分几个区层。各区层可以相等，也可以不等。图 2-1 表示将该麦田划分为 3 个相等的区层。区层划分后，可将各区层再划分成面积大小相等的抽样单位（如 $1m^2$ 或 $2m^2$），即可在各区层内以规定的抽样分数进行随机抽样。

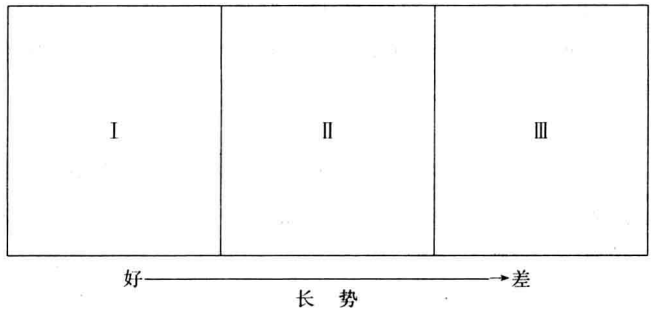

图 2-1　长势具有趋向式变化麦田的分层抽样

（3）整体抽样。整体抽样（cluster sampling）是把总体分成若干群，以群为单位进行随机抽样，对抽到的样本作全面调查，因此也称为整群抽样。整体抽样是以“群”为基本抽样单位。因此，“群”间差异越小，抽取的“群”越多，抽样误差越小。与简单随机抽样相比较，在相等的抽样分数下，它减少了所抽查单位的数目，却增大了每个调查单位。若总体内主要变异来源明显来自地段间，且每个地段占有较大的面积，则应采用分层抽样；若主要变异来源明显来自地段内各单位间，且每个地段所占面积较小，宜采用整体抽样。

整体抽样具有以下优点：① 一个群只要一个编号，因而减少了抽样单位编号数，且因调查单位数减少，工作方便；② 与简单随机抽样相比较，它常常提供较为准确的总体估计值，特别是害虫危害作物这类不均匀分布的研究对象，采用整体抽样更为有利；③ 只要各群抽选单位相等，整体抽样也可提供总体平均数的无偏估计。

进行整体抽样，样本容量一定时，其抽样误差一般大于简单随机抽样，这是因为样本观察单位并非广泛地散布在总体中。为降低抽样误差，可采用增加抽取的“群”数，减少“群”内观察单位数的方法进行抽样，即重新划分“群”组，使每个“群”更小。例如，调查农村儿童生长发育状况，一般而言，以乡为抽样的基本单位（群），比以村为抽样单位的抽样误差大，但后者提高了调查和质量控制的难度，研究者应根据实际情况在两种划分中作出选择。在实际工作中，往往缺乏现存可靠的观察单位名单，而地域区划、业务单位、社会集团等则是范围清楚的可加以利用的“群”组，故整体抽样还是较为常用的。

（4）双重抽样。如果所研究的性状是不容易观察测定的，或必须有较高费用，或要求有精密设备、复杂计算过程与耗费较多调查时间的，或必须进行破坏性测定才能获得观察结果的，由于上述种种原因，直接调查研究这一类型性状是有困难的。为了调查这类性状，有时可以找出另一种易于观察测定而且节省时间和经费的性状，利用这两种性状客观存在的关系，通过测定后一种性状结果从而推算前一种性状的测定结果。前一种性状一般称为复杂性状或直接性状，后一种性状称为简单性状或间接性状。在抽样调查时要求随机抽出两个样本，这种抽样方法称为双重抽样（double sampling）。在双重抽样中涉及两个变量，通常将易于观测的变量作为简单性状的变量，不易观测的变量作为复杂性状的

变量。例如,估计生长期中的甘蔗产量,甘蔗体积为简单性状而甘蔗重量则为复杂性状。在林学研究中,木材体积是一个较复杂的性状,而树干基部横剖面积则为较简单的性状。另外,在害虫密度调查中也经常采用这种方法。例如,从玉米茎上的蛀孔数(简单性状)来推算玉米螟的幼虫数(复杂性状)。

双重抽样具有以下两个优点:① 对于复杂性状的调查研究可以通过仅测定少量抽样单位而获得相应于大量抽样单位的精确度;② 当复杂性状必须通过破坏性测定才能调查时,则仅有这种双重抽样方法可用。

2) 顺序抽样

顺序抽样(ordinal sampling)又称为系统抽样、机械抽样、等距抽样(systematic sampling),是按某种既定顺序从总体(有限总体)中抽取一定数量的个体构成样本。具体方法是,将总体的观察单位按某一顺序分成 n 个部分,再从第一部分随机抽取第 k 号观察单位,依次用相等间隔,从每一部分各抽取一个观察单位组成样本。例如,欲求 100 匹马的体重,拟抽出 20 匹马作为样本来称重,就可以采用逢 5 抽 1 的顺序抽样法。对 100 匹马进行编号,则 5,10,…,100 这 20 个个体组成一个样本。

顺序抽样具有以下优点:① 可避免抽样时受人们主观偏见的影响,且简便易行;② 容易得到一个按比例分配的样本;③ 如果样本的观察单位在总体内分布均匀,其取样个体在总体内分布较均匀,这时采用顺序抽样,其抽样误差一般小于简单随机抽样,能得到较准确的结果。同时顺序抽样具有以下缺点:① 如果总体内存在周期性变异或单调增(减)趋势时,则很可能会得到一个偏差很大的样本,产生明显的系统误差;② 顺序抽样得到的样本并不是彼此独立的,因此,对抽样误差的估计只是近似的。通过顺序抽样的方法不能计算抽样误差、估计总体平均数的置信区间。同时应该注意,采用顺序抽样时,一旦确定了抽样间隔,必须严格遵守,不得随意更改,否则可能造成另外的系统误差。

3) 典型抽样

根据初步资料或经验判断,有意识、有目的地选取一个典型群体作为代表(即样本)进行调查记载,以估计整个总体,这种方法就称为典型抽样(typical sampling),也称为主观抽样(subjective sampling)。典型样本代表着总体的绝大多数,如果选择合适,能够得到可靠的结果,尤其从容量很大的总体中选取较小数量的抽样单位时,往往采用这种方法。这种抽样方法完全依赖于调查工作者的经验和技能,结果不稳定,且没有运用随机原理,因而无法估计抽样误差。典型抽样多用于大规模社会经济调查,而在总体相对较小或要求估算抽样误差时一般不采用这种方法。

应该注意的是,在抽样过程中可以混合地采用以上几种抽样方法。例如,从总体内有意识地选取典型单位群,然后再随机从群中抽取所需观察(调查)的单位;有时也将顺序抽样和整群抽样配合使用。

(二) 试验

试验(experiment)是通过一定数量的有代表性的试验单位,在一定的条件下进行的带有探索性的研究工作。在生物学研究中,对于一些理论性的无限总体,一般需要通过设

置各种类型的试验来获取样本资料。安排这些试验时，要设置试验处理，遵循随机、重复和局部控制 3 项基本原则。常见的试验设计方法主要有对比设计、随机区组设计、拉丁方设计、裂区设计、正交设计等，其相关内容将在第九章介绍。

三、试验资料的整理

（一）原始资料的检查与核对

通过调查或试验取得原始资料(row data)后，要对全部数据进行检查与核对，才能进行数据的整理(collation)。对原始资料进行检查与核对应从数据本身是否有错误、取样是否有差错和不合理数据的订正 3 个方面进行。主要核对原始资料的测量和记载有无差错、检查原始资料有无遗失、重复的归并是否合理，以及是否有特大、特小等异常值的出现。对个别缺失的数据，可以进行缺失数据估计，对重复、错误和异常值应予以删除或订正，但不能随意改动，必要时要进行复查或重新试验。数据的检查与核对在统计处理工作中是非常重要的。只有经过检查和核对的数据资料，保证数据资料的完整、真实和可靠，才能通过统计分析，真实地反映调查或试验的客观情况。

（二）次数(频数)分布表

经过检查与核对后的数据资料，根据样本资料的多少确定是否分组。一般样本容量在 30 以下的小样本不必分组，可直接进行统计分析。样本容量在 30 以上时，就需将数据分成若干组，以便进行统计分析。数据经过分组归类后，可以制成有规则的次数(频数)分布表(frequency table)，作出次数(频数)分布图(frequency chart)。次数(频数)分布表是指对一组大小不同的数据分成若干组，然后将数据按其数值大小列入各个相应的组别内所形成的表。资料的类型不同，其进行分组整理的方法也不同。

1. 计数资料的整理

计数资料基本采用单项式分组法(grouping method of monomial)进行整理。它的特点是用样本变量自然值进行分组，每组均用一个或几个变量值来表示。分组时，可将数据资料中每个变量值分别归入相应的组内，然后制成次数分布表。

【例 2.3】 在某鸡场调查 100 只来亨鸡每月的产蛋数，数据见表 2-2。

表 2-2　100 只来亨鸡每月的产蛋数　　(单位：枚)

15	17	12	14	13	14	12	11	14	13
16	14	14	13	17	15	14	14	16	14
14	15	15	14	14	14	11	13	12	14
13	14	13	15	14	13	15	14	13	14
15	16	16	14	13	14	15	13	15	13
15	15	15	14	14	16	14	15	17	13
16	14	16	15	13	14	14	14	14	16
12	13	12	14	12	15	16	15	16	14
13	14	16	15	15	15	13	13	14	14
13	15	17	14	13	14	12	17	14	15

每月产蛋数为 11～17 枚，把 100 个观测值按照每月产蛋数加以归类，共分 7 组，将各组所属数据进行统计，得出各组次数，计算出各组的频率(frequency)和累积频率(cumulative frequency)，这样经整理后可得出每月产蛋数的次数分布表，见表 2-3。

表 2-3　100 只来亨鸡每月产蛋数的次数分布表

每月产蛋数/枚	次数	频率	累积频率
11	2	0.02	0.02
12	7	0.07	0.09
13	19	0.19	0.28
14	35	0.35	0.63
15	21	0.21	0.84
16	11	0.11	0.95
17	5	0.05	1.00

从表 2-3 可以知道，一堆杂乱无章的原始数据资料，经初步整理后，就可了解这些资料的大概情况，其中以每月产蛋数为 14 枚的最多。这样，经过整理的资料也就便于进一步分析。

对于变量较多而变异范围较大的计数资料，若以每一变量值划分一组，则显得组数太多而每组变量数目较少，看不出数据分布的规律性。例如，研究 5 个不同小麦品种的 300 个麦穗的每穗穗粒数，观察其穗粒数为 18～62 粒。如果按一个变量值分为一组，需要分 45 组，数据仍显得十分分散。为了使次数分布表表现出规律性，可以按 5 个变量值分为一组，分 18～22、23～27、28～32、33～37、38～42、43～47、48～52、53～57、58～62 共 9 个组，将 300 个麦穗的资料进行归组，计算出各组的次数、频率和累积频率(表 2-4)。表 2-4可明显表示数据分布情况，即大部分麦穗的穗粒数为 28～52。

表 2-4　不同小麦品种 300 个麦穗穗粒数的次数分布表

穗粒数/粒	次数	频率	累积频率
18～22	3	0.0100	0.0100
23～27	18	0.0600	0.0700
28～32	38	0.1267	0.1967
33～37	51	0.1700	0.3667
38～42	68	0.2267	0.5934
43～47	53	0.1766	0.7700
48～52	41	0.1367	0.9067
53～57	22	0.0733	0.9800
58～62	6	0.0200	1.0000

2. 计量资料的整理

计量资料的整理不能按计数资料的归组方法进行，一般采用组距式分组法(grouping method of class interval)。分组时需先确定全距、组数、组距、各组上下限，然后按观测值的大小进行归组。

【例 2.4】 调查了 150 尾鲢鱼的体长(cm)资料，其结果列于表 2-5。

表 2-5　150 尾鲢鱼的体长资料　　(单位：cm)

56	49	62	78	41	47	65	45	58	55
52	52	60	51	62	78	66	45	58	58
56	46	58	70	72	76	77	56	66	58
63	57	65	85	59	58	54	62	48	63
58	52	54	55	66	52	48	56	75	55
63	75	65	48	52	55	54	62	61	62
54	53	65	42	83	66	48	53	58	57
60	54	58	49	52	56	82	63	61	48
70	69	40	56	58	61	54	53	52	43
58	52	56	61	59	54	59	64	68	51
55	47	56	58	64	67	72	58	54	52
46	57	38	39	64	62	63	67	65	52
59	60	58	46	53	57	37	62	52	59
65	62	57	51	50	48	46	58	64	68
69	73	52	48	65	72	76	56	58	63

(1) 计算全距。全距(range)也称为极差，是样本数据资料中最大观测值与最小观测值的差值。它是整个样本的变异幅度。由表 2-5 可以看出，鲢鱼体长最大值为 85cm，最小值为 37cm，因此，全距为 85－37＝48(cm)。

(2) 确定组数和组距。组数(number of classes)是根据样本观测值的多少及组距的大小来确定的，同时也考虑到对资料要求的精确度以及进一步计算是否方便。组数与组距有密切的关系。组数多，组距相应就变小，组数越多，所求得的统计数就越精确，但不便于计算；组数太少，组距就相应增大，虽然计算方便，但所计算的统计数的精确度较差。为了使两方面都能够协调，组数不宜太多或太少。在确定组数和组距时，应考虑样本容量的大小、全距的大小、便于计算、能反映资料的真实面貌等因素。通常划分组数可参照表 2-6 样本容量与分组数的关系来确定。

表 2-6　样本容量与分组数的关系

样本容量	分组数
30～60	5～8
60～100	7～10
100～200	9～12
200～500	10～18
500 以上	15～30

组数确定好后，还需确定组距(class interval)。组距是指每组内的上下限范围。分组时要求各组的距离相同。组距的大小是由全距和组数所确定的：

$$\text{组距}=\frac{\text{全距}}{\text{组数}}$$

表 2-5 鲢鱼体长资料的样本容量为 150，查表 2-6，可分为 9～12 组，这里取 10 组，则组距为

$$\frac{48}{10}=4.8(\text{cm})$$

为分组方便，以 5cm 作为组距。

(3) 确定组限和组中值。组限(class limit)是指每个组变量值的起止界限。每个组有两个组限,一个下限和一个上限。在确定最小一组的下限时,必须把资料中最小的数值包括在内,因此,下限要比最小值小一些。为了计算方便,组限可取到 10 分位或 5 分位数上,如表 2-5 中最小值为 37cm,第一组的下限可定为 35cm,上限定为 40cm,即 35～40cm 为第一组,凡大于 35cm 小于 40cm 的变量值均归于这一组,等于或大于 40cm 的变量值列入下一组。确定最大一组的上限时,必须大于资料中的最大值。为了使各组界限明确,避免重叠,目前在写法上,每组只写下限、不写上限,如表 2-5 资料分组写成 35～,40～,…,85～。

组中值(class midvalue)是每组两个组限(下限和上限)的中间值。在资料分组时,为了避免第一组中观测值过多,一般第一组的组中值最好接近或等于资料中的最小值。其计算公式为

$$\text{组中值}=\frac{\text{下限}+\text{上限}}{2}$$

或

$$\text{组中值}=\text{下限}+\frac{1}{2}\text{组距}=\text{上限}-\frac{1}{2}\text{组距}$$

(4) 分组,编制次数分布表。确定好组数和各组上下限后,可按原始资料中各观测值的次序,把各个数值归于各组,即进行分组(class fication)。一般用"正"字划计法或卡片法来计算各组的观测值次数。全部观测值归组后,即可求出各组的次数、频率和累积频率,制成一个次数分布表(表 2-7)。这种次数分布表不仅便于观察,而且可根据它绘制成次数分布图,计算平均数和标准差等特征数。

表 2-7　150 尾鲢鱼体长的次数分布表

组限/cm	组中值/cm	次数	频率	累积频率
35～	37.5	3	0.0200	0.0200
40～	42.5	4	0.0267	0.0467
45～	47.5	17	0.1133	0.1600
50～	52.5	28	0.1867	0.3467
55～	57.5	40	0.2666	0.6133
60～	62.5	25	0.1667	0.7800
65～	67.5	17	0.1133	0.8933
70～	72.5	6	0.0400	0.9333
75～	77.5	7	0.0467	0.9800
80～	82.5	2	0.0133	0.9933
85～	87.5	1	0.0067	1.0000

(三) 次数(频数)分布图

次数(频数)分布图(frequency chart)就是把资料的次数(频数)分布画成统计图形。次数分布图可以更直观地观察各组变量次数分布的情况,形象地把资料特征表达出来。常用的统计图有条形图、饼图、直方图、多边形图和散点图等。

1. 条形图

条形图又称为柱形图(bar chart),适合于表示计数资料和属性资料的次数分布。作图时,用横坐标表示变量的自然值,纵坐标表示次数,每一个次数数据于相应自然值的位置分别截取一定的宽度和相应次数高度的长方形。每个长方形之间要隔出一定距离,以区别于下面要介绍的直方图。以 100 只来亨鸡每月产蛋数的次数分布为例作出条形图(图 2-2)。

2. 饼图

饼图(pie chart)适合于表示计数资料和属性资料的次数分布。作图时,把饼图的全面积看成 1,求出各观测值次数占观测值总次数的百分比,即构成比(或频率)。按构成比将圆饼分成若干份,以扇形面积大小分别表示各个观测值的比例。以 100 只来亨鸡每月产蛋数的次数分布为例作出饼图(图 2-3)。

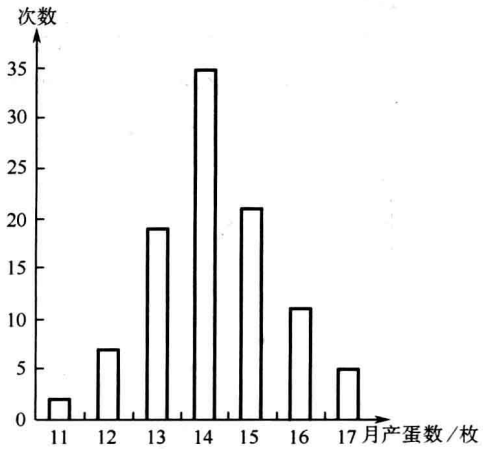

图 2-2　来亨鸡月产蛋数次数分布条形图

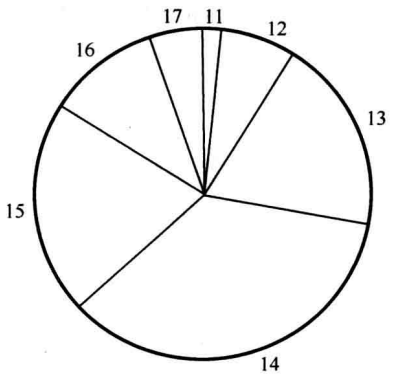

图 2-3　来亨鸡月产蛋数次数分布饼图

3. 直方图

直方图(histogram)又称为矩形图,适合于表示计量资料的次数分布。其作图方法与条形图相似,以横坐标表示各组组限,纵坐标表示次数,截取一定距离代表组限大小和次数多少,用直线连接起来,构成一个个长方形。各组之间一般没有距离,前一组上限与后一组下限可合并共用。以 150 尾鲢鱼体长的次数分布为例作出直方图(图 2-4)。

4. 多边形图

多边形图(polygon chart)又称为折线图(broken-line chart),也是表示计量资料次数分布的一种方法。作折线图时,以横坐标表示各组组中值,纵坐标表示次数。在各组组中值的垂线上,按该组次数应占高度标记一个点,把相邻的点用直线段顺次连接起来,即成多边形图。以 150 尾鲢鱼体长的次数分布为例作出多边形图(图 2-5)。

5. 散点图

散点图(scatter chart)又称为散布图,适合于表示计数资料和计量资料的次数分布。图中横坐标表示 x 变量,纵坐标表示 y 变量。它是以点的分布反映变量之间的相关情况,根据图中的各点分布走向和密集程度来判断变量之间关系的。以 100 只来亨鸡每月产蛋

数的次数分布和 150 尾鲢鱼体长的次数分布为例作出散点图(图 2-6、图 2-7)。

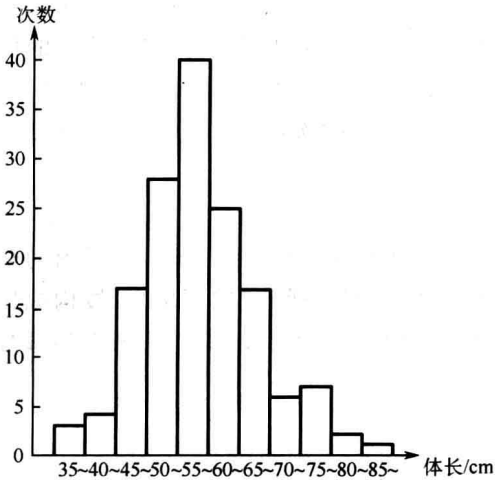

图 2-4　鲢鱼体长次数分布直方图

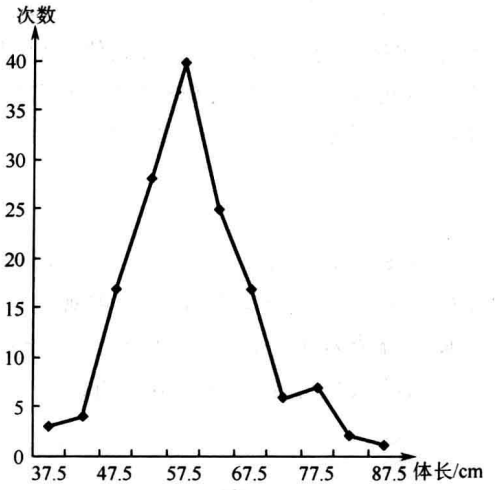

图 2-5　鲢鱼体长次数分布多边形图

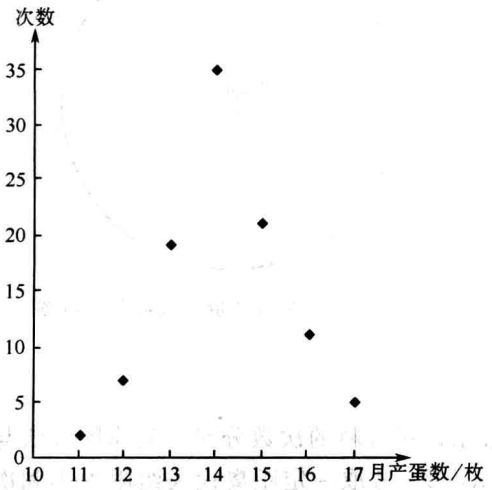

图 2-6　来亨鸡月产蛋数次数分布散点图

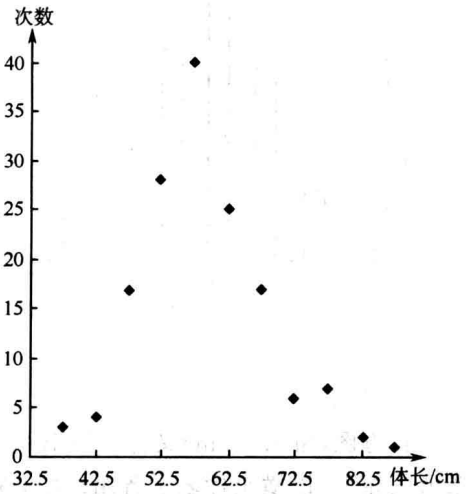

图 2-7　鲢鱼体长次数分布散点图

通过以上统计分布图,我们可以比次数分布表更直观地看出各观测资料的变化趋势,各资料的分布中心及其变异趋势均可以很直观地得到描述。同样,也可以按照资料分组的频率值绘制成频率分布图。

第二节　试验资料特征数的计算

由上节所述的次数分布,我们可以看出变量的分布具有两个明显的基本特征,即集中性和离散性。集中性(centrality)是变量在趋势上有着向某一中心聚集,或者说以某一数值为中心而分布的性质。离散性(discreteness)是变量有着离中分散变异的性质。为了

反映变量分布的这两个基本性质，必须计算它们的特征数(eigenvalue)。反映集中性的特征数是平均数，其中应用最普遍的是算术平均数。此外，还有几何平均数、中位数和众数等。反映离散性的特征数为变异数，常用的指标是极差、方差、标准差和变异系数等，其中最为常用的是标准差，它是变量的平均变异程度的度量。

一、平　均　数

平均数(mean)也称为均数，是计量资料的代表值，表示资料中观测值的中心位置，并且可作为资料的代表与另一组资料相比较，以确定二者相差的情况。

(一) 平均数的种类

平均数的种类较多，主要有以下 4 种。

1. 算术平均数

总体或样本资料中各个观测值的总和除以观测值的个数所得的商，称为算术平均数(arithmetic mean)。对于一个具有 N 个观测值的有限总体，其观测值为 $x_1, x_2, \cdots, x_N$，则该总体算术平均数(arithmetic mean of the population)为

$$\mu = \frac{x_1 + x_2 + \cdots + x_N}{N} = \frac{1}{N}\sum_{i=1}^{N} x_i \tag{2.1}$$

对于具有 n 个观测值 $x_1, x_2, \cdots, x_n$ 的样本，其样本算术平均数(arithmetic mean of the sample)为

$$\bar{x} = \frac{x_1 + x_2 + \cdots + x_n}{n} = \frac{1}{n}\sum_{i=1}^{n} x_i \tag{2.2}$$

式(2.1)和式(2.2)中，$\sum$ 为求和符号；$\sum_{i=1}^{n} x_i$ 为 x_i 从 $i=1$ 一直加到 $i=n$，也可简写为 $\sum_{i} x_i$ 或 $\sum x$；$\bar{x}$ 为 μ 的估计值，因 $\bar{x}$ 应用广泛，常简称为平均数或均数。

2. 中位数

将试验或调查资料中所有观测值依大小顺序排列，居于中间位置的观测值称为中位数(median)，以 M_d 表示。当观测值个数 n 为奇数时，中位数是第 $\frac{n+1}{2}$ 位置的观测值；当观测值个数 n 为偶数时，中位数是第 $\frac{n}{2}$ 和 $\frac{n}{2}+1$ 位置的两个观测值之和的 $\frac{1}{2}$。

3. 众数

资料中出现次数最多的那个观测值或出现次数最多一组的中点值(组中值)，称为众数(mode)，以 M_o 表示。

4. 几何平均数

资料中有 n 个观测值，其乘积开 n 次方所得的数值称为几何平均数(geometric mean)，以 G 表示。几何平均数适用于变量 x 为对数正态分布，经对数转换后呈正态分布的资料。其计算公式为

$$G=\sqrt[n]{x_1 \cdot x_2 \cdot \cdots \cdot x_n}=\sqrt[n]{\prod_{i=1}^{n} x_i} \tag{2.3}$$

式中，$\prod$ 为求积符号。

上述平均数中，算术平均数是最常用的平均数，中位数、众数和几何平均数使用较少。

(二) 算术平均数的计算方法

1. 直接计算法

当样本容量较小时可根据算术平均数的定义直接进行计算。

【例 2.5】 随机抽取 20 株小麦，其株高分别为 82,79,85,84,86,84,83,82,83,83,84,81,80,81,82,81,82,82,82,80(cm)，计算小麦的平均株高。

根据平均数的定义，由式(2.2)，得

$$\bar{x}=\frac{1}{n}\sum x=\frac{1}{20}\times(82+79+\cdots+80)=82.3(\text{cm})$$

2. 减去(或加上)常数法

若变量 x_i 的值都较大(或较小)，且接近某一常数 a 时，可将它们的值都减去(或加上)常数 a，得到一组新的数据，然后再计算平均数，最后重新加上(或减去)常数 a 即得到 $\bar{x}$。以减去常数 a 为例，设 $y_1=x_1-a$，$y_2=x_2-a$，$\cdots$，$y_n=x_n-a$，则有 $x_1=y_1+a$，$x_2=y_2+a$，$\cdots$，$x_n=y_n+a$，于是有

$$\bar{x}=\frac{1}{n}\sum_{i=1}^{n}x_i=\frac{1}{n}\sum_{i=1}^{n}(y_i+a)=\frac{1}{n}\sum_{i=1}^{n}y_i+\frac{1}{n}(na)=\frac{1}{n}\sum y+a \tag{2.4}$$

【例 2.6】 利用减去常数法，计算例 2.5 的平均数 $\bar{x}$。

设 $a=80$，则有 $y_1=82-80=2$，$y_2=79-80=-1$，$\cdots$，$y_{20}=80-80=0$，代入式(2.4)，得

$$\bar{x}=\frac{1}{20}\times[2+(-1)+\cdots+0]+80=82.3(\text{cm})$$

3. 加权平均法

在具有 n 个观测数的样本中，如果观测数 x_1 出现 f_1 次，观测数 x_2 出现 f_2 次，$\cdots$，观测数 x_m 出现 f_m 次，且 $f_1+f_2+\cdots+f_m=n$，这时则有

$$\bar{x}=\frac{f_1x_1+f_2x_2+\cdots+f_mx_m}{f_1+f_2+\cdots+f_m}=\frac{1}{n}\sum_{i=1}^{m}f_ix_i \tag{2.5}$$

式中，f_i 可理解为 x_i 在平均数中的“权数”(weight)，即数值相同的观测数出现的次数，因而式(2.5) 所求得的 $\bar{x}$ 称为加权平均数(weighted mean)。

【例 2.7】 利用加权平均法，计算例 2.5 的加权平均数。

先整理 20 株小麦株高数据如表 2-8 所示。由式(2.5)，得

$$\bar{x}=\frac{1}{20}\times(79\times1+80\times2+\cdots+86\times1)=82.3(\text{cm})$$

表 2-8　20 株小麦株高数据的次数分布

株高 (x)/cm	次数 (f)	fx	fx^2
79	1	79	6241
80	2	160	12800
81	3	243	19683
82	6	492	40344
83	3	249	20667
84	3	252	21168
85	1	85	7225
86	1	86	7396
总和	$\sum f = 20$	$\sum fx = 1646$	$\sum fx^2 = 135524$

(三) 算术平均数的重要特性

(1) 样本中各观测值与其平均数之差称为离均差(deviation from mean),其总和等于零。证明如下:

$$\begin{aligned}\sum(x-\bar{x}) &= (x_1-\bar{x})+(x_2-\bar{x})+\cdots+(x_n-\bar{x})\\ &= (x_1+x_2+\cdots+x_n)-n\bar{x}\\ &= \sum x-n\bar{x}\end{aligned}$$

因为 $\bar{x}=\dfrac{\sum x}{n}$，所以 $\sum x = n\bar{x}$，故:

$$\sum(x-\bar{x}) = \sum x - n\bar{x} = 0 \tag{2.6}$$

(2) 样本中各观测值与其平均数之差平方的总和,较各观测值与任一数值(不包括平均数)之差的平方和为小,即离均差平方和(mean deviation sum of square)为最小。设 a 为 $\bar{x}$ 以外的任何数值,则 $\sum(x-\bar{x})^2 < \sum(x-a)^2$。证明如下:

$$\begin{aligned}\sum(x-a)^2 &= \sum[(x-\bar{x})+(\bar{x}-a)]^2\\ &= \sum[(x-\bar{x})^2+2(x-\bar{x})(\bar{x}-a)+(\bar{x}-a)^2]\\ &= \sum(x-\bar{x})^2+2\sum(x-\bar{x})(\bar{x}-a)+\sum(\bar{x}-a)^2\\ &= \sum(x-\bar{x})^2+2\sum(x-\bar{x})(\bar{x}-a)+n(\bar{x}-a)^2\end{aligned}$$

已知 $\sum(x-\bar{x})=0$，因此 $2\sum(x-\bar{x})(\bar{x}-a)=0$。

因为 $n(\bar{x}-a)^2$ 必大于 0,所以,有

$$\sum(x-\bar{x})^2 < \sum(x-a)^2 \tag{2.7}$$

(四) 算术平均数的作用

算术平均数是描述观测资料的重要特征数,它的作用主要有以下两点:

(1) 指出一组数据资料中心位置,标志着资料所代表性状的数量水平和质量水平。

(2) 作为样本或资料的代表数据与其他资料进行比较。

二、变 异 数

前已述知,变量的分布具有集中性和离散性两方面特征,因而只有表示集中性的平均数是不够的,还必须计算变异数(variance)以度量其变量的离散性,或称为变异性(variability)。用来表示变异性的指标较多,常用的有极差、标准差、方差和变异系数等,其中以标准差和变异系数应用最为广泛。

(一) 极差

极差(range)又称为全距,是样本资料中最大值和最小值之差,一般用 R 表示。

$$R=\max\{x_1,x_2,\cdots,x_n\}-\min\{x_1,x_2,\cdots,x_n\} \tag{2.8}$$

例如,表 2-5 资料中,150 尾鲢鱼体长的极差为 $R=85-37=48$(cm)。极差在一定程度上能说明样本波动幅度的大小,但它只受样本中两个极端个体数值大小的影响,不能反映样本中各个观测值的变异程度。因此,极差在表示数据的变异特性时只能在研究样本的波动时使用,具有一定的局限性。

(二) 方差

为了度量变量的变异程度,对含有 n 个观测值 $x_1,x_2,\cdots,x_n$ 的样本,可以用各观测值离均差的大小来表示,但由于 $\sum(x-\bar{x})=0$,不能反映样本的总变异程度。若将离均差先平方再求和,即 $\sum(x-\bar{x})^2$,就可消除上述弊病。但这样还有一个缺点,就是离均差平方和常随样本容量大小而改变。为便于比较,用样本容量 n 来除离均差平方和,得到平均的平方和,简称为方差(variance) 或均方(mean square,MS)。对于样本来说,其样本方差(sample variance)s^2 为

$$s^2=\frac{\sum(x-\bar{x})^2}{n-1} \tag{2.9}$$

对于总体,其总体方差(population variance) σ^2 为

$$\sigma^2=\frac{\sum(x-\mu)^2}{N} \tag{2.10}$$

式中,$n-1$ 为自由度(degree of freedom,df);N 为有限总体容量;s^2 是 σ^2 的最好估计值。

比较式(2.9)和式(2.10),样本方差不用 n 为除数,而是用 $n-1$ 为除数,是因为 $\sum(x-\bar{x})^2$ 是最小平方和,如果以 n 为除数,则所得 s^2 是 σ^2 的偏小估计。如果用 $n-1$ 替代 n,则可避免偏小估计的弊端,提高用样本估计总体变异的精度 。

方差是度量资料变异的常用指标,在分析数据资料的变异特征和统计推断中有广泛的应用。

(三) 标准差

1. 标准差的定义

方差虽能反映变量的变异程度，但由于离均差取了平方值，使得它与原始数据的数值和单位都不相适应，需要将方差开方还原，方差的平方根值就是标准差（standard deviation，Sd）。样本标准差（standard deviation of the sample）s 为

$$s=\sqrt{\frac{\sum(x-\bar{x})^2}{n-1}} \tag{2.11}$$

总体标准差（standard deviation of the population）σ 为

$$\sigma=\sqrt{\frac{\sum(x-\mu)^2}{N}} \tag{2.12}$$

2. 标准差的计算

在计算标准差时，首先求出平均数，然后求出 $\sum(x-\bar{x})^2$，再按式(2.11)进行计算。这样不仅麻烦，而且当 $\bar{x}$ 为约数时，容易引起计算误差。所以通常把 $\sum(x-\bar{x})^2$ 进行下面的变形，用原始数据进行计算：

$$\begin{aligned}\sum(x-\bar{x})^2&=\sum(x^2-2x\bar{x}+\bar{x}^2)\\&=\sum x^2-2\bar{x}\sum x+n\bar{x}^2\\&=\sum x^2-2\frac{\sum x}{n}\sum x+n\left(\frac{\sum x}{n}\right)^2\\&=\sum x^2-2\frac{\left(\sum x\right)^2}{n}+\frac{\left(\sum x\right)^2}{n}\\&=\sum x^2-\frac{\left(\sum x\right)^2}{n}\end{aligned} \tag{2.13}$$

代入式(2.11)，得

$$s=\sqrt{\frac{\sum x^2-\frac{\left(\sum x\right)^2}{n}}{n-1}} \tag{2.14}$$

在实际计算时，当遇到数值较大（或较小）的数据资料时，为了简化计算过程，可将各观测值都减去（或加上）一个常数，所得的 s 不变。

【例 2.8】 测得 9 名男子前臂长（cm）的样本数据，列于表 2-9，试计算其标准差（设 $x'=x-45$）。

表 2-9　9 名男子前臂长数据

前臂长 (x)/cm	x^2	$x'=x-45$	x'^2
45	2025	0	0
42	1764	−3	9
44	1936	−1	1

续表

前臂长 (x)/cm	x^2	$x'=x-45$	x'^2
41	1681	−4	16
47	2209	2	4
50	2500	5	25
47	2209	2	4
46	2116	1	1
49	2401	4	16
$\sum x=411$	$\sum x^2=18841$	$\sum x'=6$	$\sum x'^2=76$

将表 2-9 资料按两种算法的数据代入式(2.14),得

$$s=\sqrt{\frac{\sum x^2-\frac{\left(\sum x\right)^2}{n}}{n-1}}=\sqrt{\frac{18841-\frac{411^2}{9}}{9-1}}=3.0(\text{cm})$$

$$s=\sqrt{\frac{\sum x'^2-\frac{\left(\sum x'\right)^2}{n}}{n-1}}=\sqrt{\frac{76-\frac{6^2}{9}}{9-1}}=3.0(\text{cm})$$

两种算法相比,其结果是一样的,但第二种算法更为简便易行。因此,当样本的变量数值较大时,用简化后的数据计算标准差 s 可以大大节约计算工作量。

对于已分组的资料,可采用加权的公式进行计算,其公式为

$$s=\sqrt{\frac{\sum f(x-\bar{x})^2}{n-1}}=\sqrt{\frac{\sum fx^2-\frac{\left(\sum fx\right)^2}{n}}{n-1}} \tag{2.15}$$

【例 2.9】 根据表 2-8 数据,计算 20 株小麦株高的标准差。

由表 2-8 可知,$\sum fx=1646$,$\sum fx^2=135524$,代入式(2.15),得

$$s=\sqrt{\frac{135524-\frac{1646^2}{20}}{20-1}}=1.7502(\text{cm})$$

3. 标准差的特性及其作用

标准差是衡量变量资料变异程度的最好指标,它具有以下几个特性:

(1) 标准差的大小受多个观测值的影响,如果观测值与观测值间差异较大,其离均差也大,因而标准差也大,反之则小。

(2) 在计算标准差时,如果将各观测值加上或减去一个常数 a,其标准差不变;如果将各观测值乘以或除以一个常数 a,则所得的标准差扩大或缩小了 a 倍。

(3) 在正态分布情况下,一个样本变量的分布情况可作如下估计:在平均数 $\bar{x}$ 两侧的 $1s$ 范围内,即 $\bar{x}\pm s$ 内的观测值个数约为观测值总个数的 68.26%;在平均数 $\bar{x}$ 两侧的 $2s$ 范围内,即 $\bar{x}\pm 2s$ 内的观测值个数约为观测值总个数的 95.45%;在平均数 $\bar{x}$ 两侧的 $3s$ 范围内,即 $\bar{x}\pm 3s$ 内的观测值个数约为观测值总个数的 99.73%。

根据标准差的性质,它可以起到以下几种作用。

（1）表示变量分布的离散程度。标准差小，说明变量的分布比较密集在平均数附近；标准差大，则表明变量的分布比较离散。因此，可以用标准差的大小判断平均数代表性的强弱。

（2）利用标准差的大小，可以概括地估计出变量的次数分布及各类观测值在总体中所占的比例。

（3）估计平均数的标准误。在计算平均数的标准误时，可根据样本标准差代替总体标准差进行计算。

（4）进行平均数的区间估计和变异系数计算。

（四）变异系数

标准差是衡量一个样本变量分布变异程度的重要特征数。但当比较两个样本时，由于平均数相差悬殊或单位不同，用标准差来说明它们的变异程度就不合适。为了克服这一缺点，将样本标准差除以样本平均数，得出的百分比就是变异系数（coefficient of variability，CV），其计算公式为

$$CV=\frac{s}{\bar{x}}\times 100\% \tag{2.16}$$

变异系数是样本变量的相对变异量，是不带单位的纯数。用变异系数可以比较不同样本相对变异程度的大小。

【例 2.10】 某品种水稻在大田栽植，其穗粒数为 44.6 粒，标准差为 17.9 粒；在丰产田栽植，其穗粒数为 65.0 粒，标准差为 18.3 粒，问哪种栽植田水稻穗粒数变异程度较大？

将两种栽植田水稻穗粒数的平均数、标准差分别代入式(2.16)，得出：

大田水稻穗粒数的变异系数为

$$CV_1=\frac{s}{\bar{x}}\times 100\%=\frac{17.9}{44.6}\times 100\%=40.13\%$$

丰产田水稻穗粒数的变异系数为

$$CV_2=\frac{s}{\bar{x}}\times 100\%=\frac{18.3}{65.0}\times 100\%=28.15\%$$

从两种栽植田水稻穗粒数的变异系数可以看出，虽然大田水稻穗粒数的标准差较小，但其变异系数比丰产田大，说明丰产田水稻穗粒数的整齐度优于大田水稻穗粒数。

思考练习题

习题 2.1　什么是抽样调查？常用的抽样调查有哪些基本方法？试比较其优缺点和适用对象。

习题 2.2　什么是次数分布表？什么是次数分布图？制表和绘图的基本步骤有哪些？

习题 2.3　算术平均数与加权平均数形式上有何不同？为什么说它们的实质是一致的？

习题 2.4　平均数与标准差在统计分析中有什么用处？它们各有哪些特性？

习题 2.5　总体和样本的平均数、标准差有什么共同点？又有什么联系和区别？

习题 2.6　某地 100 例 30～40 岁健康男子血清总胆固醇含量(mol/L)测定结果如下：

4.77	3.37	6.14	3.95	3.56	4.23	4.31	4.71	5.69	4.12
4.56	4.37	5.39	6.30	5.21	7.22	5.54	3.93	5.21	6.51

5.18	5.77	4.79	5.12	5.20	5.10	4.70	4.74	3.50	4.69
4.38	4.89	6.25	5.32	4.50	4.63	3.61	4.44	4.43	4.25
4.03	5.85	4.09	3.35	4.08	4.79	5.30	4.97	3.18	3.97
5.16	5.10	5.85	4.79	5.34	4.24	4.32	4.77	6.36	6.38
4.88	5.55	3.04	4.55	3.35	4.87	4.17	5.85	5.16	5.09
4.52	4.38	4.31	4.58	5.72	6.55	4.76	4.61	4.17	4.03
4.47	3.40	3.91	2.70	4.60	4.09	5.96	5.48	4.40	4.55
5.38	3.89	4.60	4.47	3.64	4.34	5.18	6.14	3.24	4.90

试根据所给资料编制次数分布表。

习题 2.7　根据习题 2.6 的次数分布表，绘制直方图和多边形图，并简述其分布特征。

习题 2.8　根据习题 2.6 的资料，计算平均数、标准差和变异系数。

习题 2.9　根据习题 2.6 的资料，计算中位数，并与平均数进行比较。

习题 2.10　某海水养殖场进行贻贝单养和贻贝与海带混养的对比试验，收获时各随机抽取 50 绳测其毛重(kg)，结果分别如下：

单养 50 绳重量数据：45，45，33，53，36，45，42，43，29，25，47，50，43，49，36，30，39，44，35，38，46，51，42，38，51，45，41，51，50，47，44，43，46，55，42，27，42，35，46，53，32，41，48，50，51，46，41，34，44，46；

混养 50 绳重量数据：51，48，58，42，55，48，48，54，39，58，50，54，53，44，45，50，51，57，43，67，48，44，58，57，46，57，50，48，41，62，51，58，48，53，47，57，51，53，48，64，52，59，55，57，48，69，52，54，53，50。

试从平均数、极差、标准差、变异系数几个指标来评估单养与混养的效果，并给出分析结论。

第三章

概率与概率分布

本章提要

概率和概率分布是统计推断的基础。根据大数定律，当样本容量 n 充分大时，可用样本统计数对总体参数作出估计。常见的理论分布主要有离散型随机变量的二项分布、泊松分布和连续型随机变量的正态分布。当 n 值较大或 p 与 q 基本接近时，二项分布趋近于正态分布；当 λ 较大时，泊松分布也接近正态分布。从总体中进行抽样必须符合随机的原则进行放回式或非放回式抽样，所抽取样本的统计数分布主要有平均数的分布、平均数差数的分布、t 分布、χ^2 分布和 F 分布等。

第二章详细叙述了如何进行样本数据资料的搜集和整理，如何编制次数分布表和次数分布图，并介绍了如何用平均数和变异数来描述样本的特征。但是，进行资料统计的目的不在于单纯描述一个样本，而是要用样本统计数来推断其所属总体的参数，即统计推断(statistical inference)。在叙述统计推断之前，首先介绍统计推断的基础知识——概率(probability)和概率分布(probability distribution)，其后介绍抽样试验和统计数的分布。

第一节　概率基础知识

一、概率的概念

(一) 事件

在自然界中，有许多现象是可以预知在一定条件下是否出现的。例如，水在标准大气压条件下，温度加热到100℃时肯定会沸腾。这种在一定条件下必然出现的现象称为必然事件(certain event)，以 U 表示。必然事件的反面，如种子的发芽率不可能超过100%，这种在一定条件下必然不出现的事件，称为不可能事件(impossible event)，以 V 表示。

在自然界中还有另外许多现象，它们在一定条件下可能发生，也可能不发生。例如，小麦种子在播种后可能发芽也可能不发芽；投掷一枚质地均匀的硬币，其结果可能是硬币正面朝上也可能是反面朝上。像这种在某些确定条件下，可能出现也可能不出现的现象，

称为随机事件(random event),简称事件(event)。

(二) 频率

设事件 A 在 n 次重复试验中发生了 m 次,其比值 $\frac{m}{n}$ 称为事件 A 发生的频率(frequency),记为

$$W(A)=\frac{m}{n} \tag{3.1}$$

显然 $W(A)$ 是介于 0 和 1 之间的一个数,即

$$0 \leqslant W(A) \leqslant 1$$

【例 3.1】 为测定某批玉米种子的发芽率,分别取 10,20,50,100,200,500,1000(粒)种子,在相同条件下进行发芽试验,其结果如表 3-1 所示。

表 3-1　某批玉米种子的发芽试验结果

种子总数 (n)	10	20	50	100	200	500	1000
发芽种子数 (m)	9	19	47	91	186	459	920
种子发芽率 $\left(\frac{m}{n}\right)$	0.900	0.950	0.940	0.910	0.930	0.918	0.920

从表 3-1 清楚地看出,试验中随 n 值的不同,其种子发芽率也不同。当 n 较小,其发芽率波动较大;随 n 值增大,发芽率的波动性逐渐减小。当 n 充分大时,其频率值就稳定在 0.92 这个数值上。当 n 为 1000 时,玉米的发芽频率为

$$W(A)=\frac{m}{n}=\frac{920}{1000}=0.92$$

(三) 概率

由例 3.1 可以引出概率的定义:某事件 A 在 n 次重复试验中,发生了 m 次,当试验次数 n 不断增大时,事件 A 发生的频率 $W(A)$ 越来越接近某一确定值 p,于是定义 p 为事件 A 发生的概率(probability),记为

$$P(A)=p \tag{3.2}$$

显然,在一般情况下,不可能完全准确地得到 p,常以在 n 充分大时,事件 A 发生的频率作为事件 A 发生概率 p 的近似值,即

$$P(A)=p=\lim_{n\to\infty}\frac{m}{n} \tag{3.3}$$

例 3.1 中 n 为 1000 时,我们可以认为 n 是充分大,则玉米发芽概率 p 可认为是 0.920。p 表示了事件 A 发生可能性的大小。根据概率的定义,概率有如下基本性质:

(1) 任何事件的概率都在 0 和 1 之间,即 $0 \leqslant P(A) \leqslant 1$;

(2) 必然事件的概率等于 1,即 $P(U)=1$;

(3) 不可能事件的概率等于 0,即 $P(V)=0$。

二、概率的计算

(一) 事件的相互关系

1. 和事件(sum event)

事件 A 和事件 B 至少有一件发生而构成的新事件称为事件 A 和事件 B 的和事件，以 $A+B$ 表示。例如，在检验小麦面粉品质时，随机抽取一个样品的出粉率为81%以下称为事件 A，随机抽取另一个样品的出粉率为 81% ～ 85% 称为事件 B，现抽取一个新样品的出粉率为85%以下，则这一新事件即为事件 A 和事件 B 的和事件。和事件的定义可推广到多个事件的和，可表示为 $A_1+A_2+\cdots+A_n$ 。

2. 积事件(product event)

事件 A 和事件 B 同时发生而构成的新事件称为事件 A 和事件 B 的积事件，以 $A \cdot B$ 表示。例如，在调查棉田病虫害发生情况时，以棉铃虫的发生为事件 A，以黄萎病的发生为事件 B，则棉铃虫和黄萎病同时发生这一新事件为事件 A 和事件 B 的积事件。积事件的定义也可推广到多个事件的积，可表示为 $A_1 \cdot A_2 \cdot \cdots \cdot A_n$ 。

3. 互斥事件(mutually exclusive event)

事件 A 和事件 B 不能同时发生，即 $A \cdot B=V$，那么称事件 A 和事件 B 互斥。例如，豌豆的花色分为红花和白花，开红花为事件 A，开白花为事件 B，现一株 F_1 代豌豆，不可能既开红花又开白花，所以开红花和开白花为互斥事件。这一定义也可推广到 A_1、A_2、…、A_n 多个事件。

4. 对立事件(contrary event)

事件 A 和事件 B 必有一个事件发生，但二者不能同时发生，即 $A+B=U$，$A \cdot B=V$，则称事件 A 与事件 B 互为对立事件，事件 B 可表示为 $\bar{A}$，事件 A 可表示为 $\bar{B}$。例如，新生婴儿是男孩为事件 A，新生婴儿是女孩为事件 B，现有一个刚出生的婴儿，要么是男孩要么是女孩，即 $A+B=U$，是必然事件，同时又不可能既是男孩又是女孩，即 $A \cdot B=V$，是不可能事件，所以新生婴儿是男孩和新生婴儿是女孩互为对立事件，新生婴儿是女孩也可记为 $\bar{A}$，新生婴儿是男孩也可记为 $\bar{B}$。

5. 独立事件(independent event)

事件 A 的发生与事件 B 的发生毫无关系，反之，事件 B 的发生也与事件 A 的发生毫无关系，则称事件 A 和事件 B 为独立事件。例如，播种两粒玉米，第一粒发芽为事件 A，第二粒发芽为事件 B，第一粒是否发芽不影响第二粒的发芽，第二粒是否发芽也不影响第一粒发芽，则事件 A 和事件 B 相互独立。如果多个事件 A_1、A_2、…、A_n 彼此独立，则称之为独立事件群 (independent event group)。

6. 完全事件系(complete event system)

如果多个事件 A_1、A_2、…、A_n 两两相斥，且每次试验结果必然发生其一，则称事件 A_1、A_2、…、A_n 为一个完全事件系。例如，抽取一位阿拉伯数字，抽取数字为 0，1，…，9 就构成了完全事件系。

(二) 概率计算法则

1. 加法定理(additive theorem)

互斥事件 A 和 B 的和事件的概率等于事件 A 和事件 B 的概率之和称为加法定理,即

$$P(A+B)=P(A)+P(B) \tag{3.4}$$

【例 3.2】 调查某玉米田,一穗株占 67.2%,双穗株占 30.7%,空穗株占 2.1%,试计算一穗株和双穗株的概率。

已知:一穗株占 67.2%,即 $P(A)=0.672$;双穗株占 30.7%,即 $P(B)=0.307$,故所要计算的和事件概率为

$$P(A+B)=P(A)+P(B)=0.672+0.307=0.979$$

推理 1 如果 A_1、A_2、…、A_n 为 n 个互斥事件,则其和事件的概率为

$$P(A_1+A_2+\cdots+A_n)=P(A_1)+P(A_2)+\cdots+P(A_n) \tag{3.5}$$

推理 2 对立事件 $\bar{A}$ 的概率为

$$P(\bar{A})=1-P(A) \tag{3.6}$$

推理 3 完全事件系和事件的概率等于 1。

2. 乘法定理(multiplicative theorem)

如果事件 A 和事件 B 为独立事件,则事件 A 与事件 B 同时发生的概率等于事件 A 和事件 B 各自概率的乘积称为乘法定理,即

$$P(A\cdot B)=P(A)\cdot P(B) \tag{3.7}$$

【例 3.3】 播种玉米时,每穴播种两粒种子,已知玉米种子的发芽率为 90%,试求每穴两粒种子均发芽的概率和一粒种子发芽的概率。

设第一粒种子发芽为事件 A,第二粒发芽为事件 B,于是有 $P(A)=P(B)=0.90$,$P(\bar{A})=P(\bar{B})=0.10$,那么两粒种子均发芽的概率为

$$P(A\cdot B)=P(A)\cdot P(B)=0.90\times 0.90=0.81$$

一粒种子发芽的概率为

$$\begin{aligned}P(A\cdot\bar{B})+P(\bar{A}\cdot B)&=P(A)\cdot P(\bar{B})+P(\bar{A})\cdot P(B)\\&=0.90\times 0.10+0.10\times 0.90=0.18\end{aligned}$$

推理 如果 A_1、A_2、A_3、…、A_n 彼此独立,则

$$P(A_1\cdot A_2\cdot\cdots\cdot A_n)=P(A_1)\cdot P(A_2)\cdot\cdots\cdot P(A_n) \tag{3.8}$$

三、概率分布

研究随机变量主要是研究它的取值范围,即取值的概率。随机变量的取值与取这些值的概率之间的对应关系称为随机变量的概率分布(probability distribution)。

(一) 离散型随机变量的概率分布

设离散型随机变量(discrete random variable)x 所有可能的取值为 $x=x_i(i=1,2,\cdots,n)$,对于任意一个 x_i 都有一个相应的概率为 $p_i(i=1,2,\cdots,n)$,可用下式表示为

$$P(x=x_i)=p_i \qquad (i=1,2,\cdots,n) \tag{3.9}$$

式中，x_i 与 p_i 为数值，表示事件“变量 x 取值为 x_i 时”的概率等于 p_i。这就是离散型随机变量 x 的概率分布。并且，

$$\sum_{i=1}^{n} p_i = 1 \tag{3.10}$$

离散型随机变量的概率分布也可用表格的形式表示，如表 3-2 所示。

表 3-2　离散型随机变量的概率分布

变量(x)	x_1	x_2	x_3	…	x_n
概率(p)	p_1	p_2	p_3	…	p_n

一般离散型随机变量，如 n 粒棉花种子的发芽数、n 枚种蛋的出雏数、n 尾鱼苗的成活数等，其概率分布均可用表 3-2 的格式表示出来。例如，投掷一枚质地均匀的骰子，以向上一面所得点数为随机变量，其概率分布如表 3-3 所示。

表 3-3　投掷一枚质地均匀骰子可能得到点数的概率分布

可能得到的点数(x)	1	2	3	4	5	6
概率(p)	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6}$

(二) 连续型随机变量的概率分布

当试验资料为连续型随机变量(continuous random variable)，一般通过分组整理成次数分布表(表 2-7)。如果从总体中抽取样本的容量 n 相当大，则频率分布就趋于稳定，我们将它近似地看成总体的概率分布。下面通过频率分布曲线进行讨论。

根据表 2-6 鲢鱼体长的频率密度$\left(\frac{\text{频率}}{\text{组距}}\right)$作直方图，如图 3-1 所示。在直方图中同一组内的频率密度是相等的，因此直方图中每一个小矩形的上边中点连接起来就得到一条阶梯形曲线，每一个直方图的矩形面积就表示该组的频率。可以想象，当样本容量 n 不断增加，相应的组距不断减少，那么直方条越来越多、越来越细，阶梯形曲线逐渐趋于光滑。当 n 无限大时，频率就转化为概率，频率密度转化为概率密度，阶梯形曲线也就转化为一条光滑的连续曲线，这时频率密度分布也就转化为概率密度分布了，此曲线称为总体的概率密度曲线 (probability density curve)，如图 3-2 所示。表示这一曲线的函数 $f(x)$ 称为概率密度函数(probability density function)。

对于一个连续型随机变量 x，取值于区间$[x_1,x_2]$内的概率即为图 3-2 中阴影部分的面积，这一面积可表示为函数 $f(x)$ 的积分，即

$$P(x_1 \leqslant x \leqslant x_2)=\int_{x_1}^{x_2} f(x)\mathrm{d}x \tag{3.11}$$

式(3.11)即为连续型随机变量概率分布的表达式。由此可见，连续型随机变量概率的分

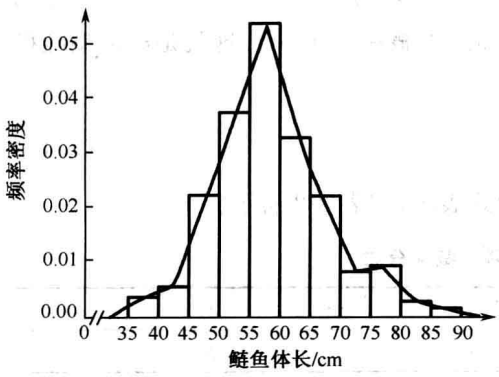

图 3-1　鲢鱼体长的频率密度分布图

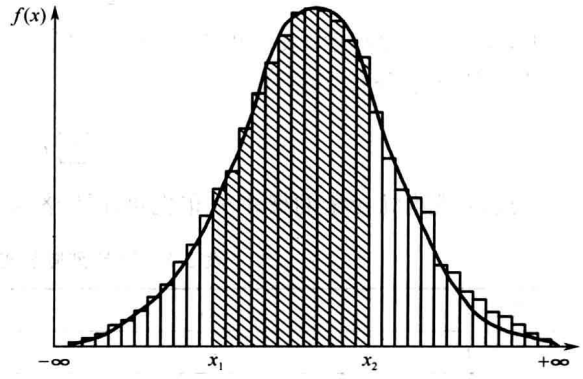

图 3-2　连续型随机变量概率密度函数曲线

布由概率密度函数所确定。

对于随机变量 x 在区间$(-\infty,+\infty)$内进行抽样，事件“$-\infty<x<+\infty$”为必然事件，所以有

$$P(-\infty<x<\infty)=\int_{-\infty}^{+\infty}f(x)\mathrm{d}x=1 \tag{3.12}$$

式(3.12)表示概率密度函数 $f(x)$ 曲线与 x 轴所围成的面积为 1。

四、大数定律

前面已经指出，当 n 充分大时，事件 A 发生的频率 $W(A)$ 就可代替概率 $P(A)$。频率和概率之间的关系，实际上就是统计数与参数的关系，频率 $W(A)$ 是一个统计数，概率 $P(A)$ 是一个参数。为什么可以用频率 $W(A)$ 来代替概率 $P(A)$？这是由于大数定律在起作用。

大数定律(law of large number)是概率论中用来阐述大量随机现象平均结果稳定性的一系列定律的总称，最常用的是伯努利大数定律(Bernoulli theorem)，可描述为：设 m 是 n 次独立试验中事件 A 出现的次数，而 p 是事件 A 在每次试验中出现的概率，则对于任意小的正数 ε，有如下关系：

$$\lim_{n\to\infty}P\left\{\left|\frac{m}{n}-p\right|<\varepsilon\right\}=1 \tag{3.13}$$

式中，P 为实现 $\left|\frac{m}{n}-p\right|<\varepsilon$ 这一事件的概率，$P=1$ 为必然事件。

伯努利大数定律说明：若试验条件不变，重复次数 n 接近无限大时，频率 $\frac{m}{n}$ 与理论概率 p 的差值必定要小于一个任意小的正数 ε，即这两者可以基本相等，这几乎是一个必然要发生的事件，即 $P=1$。

在大数定律中，辛钦大数定律(Khinchine theorem)是用来说明为什么可以用算术平均数 $\bar{x}$ 来推断总体平均数 μ 的。它可描述为：设 $x_1,x_2,\cdots,x_n$ 是来自同一总体的随机变量，对于任意小的正数 ε，有如下关系：

$$\lim_{n\to\infty} P\left\{\left|\frac{1}{n}\sum_{i=1}^{n}x_i-\mu\right|<\varepsilon\right\}=1 \tag{3.14}$$

式(3.14)阐述了当试验重复次数 n 无限增大，随机变量的算术平均数与总体平均数之间的差一定小于任意小的正数 ε，也就是 $\bar{x}$ 基本上与 μ 相等，这几乎是一个必然要发生的事件，即 $P=1$。

实际上，我们可以这样来理解大数定律：设一个随机变量 x_i 是由一个总体平均数 μ 和一个随机误差 ε_i 所构成，可以用下面的线性模型(linear model) 来表达：

$$x_i=\mu+\varepsilon_i \tag{3.15}$$

如果从同一总体抽取 n 个随机变量构成一个样本，那么样本平均数可表示为

$$\bar{x}=\frac{1}{n}\sum_{i=1}^{n}x_i=\frac{1}{n}\sum_{i=1}^{n}(\mu+\varepsilon_i)=\mu+\frac{1}{n}\sum_{i=1}^{n}\varepsilon_i$$

从上式可以看出，当试验次数 n 越来越大时，$\frac{1}{n}\sum_{i=1}^{n}\varepsilon_i$ 部分会变得越来越小。因为 ε_i 有正有负，正负相互抵消，且随着 n 的增大，$\frac{1}{n}\sum_{i=1}^{n}\varepsilon_i$ 会变得非常小，使 $\bar{x}$ 越来越接近 μ。

从以上解释，我们可以将大数定律通俗地表达为：样本容量越大，样本统计数与总体参数之差越小。有了大数定律作为理论基础，只要是从总体中抽取的随机变量相当多，就可以用样本的统计数来估计总体参数。尽管存在随机误差，但通过进行大量的重复试验，其总体特征可以透过个别的偶然现象显示出其必然性，而且这种随机误差可以用数学方法进行估计，在一定范围内也可以得到人为控制，因此完全可以根据样本的统计数来估计总体的参数。

第二节　几种常见的理论分布

随机变量的概率分布可用分布函数(distribution function)来表述。常见的几种理论分布(theoretical distribution)有：离散型变量的概率分布，如二项分布、泊松分布；连续型变量的概率分布，如正态分布等。

一、二项分布

二项分布是一种离散型随机变量的分布，生物学研究中经常碰到这种离散型的变量。对于植物、动物、微生物等生物体的某个性状，常常可以把其资料分成两个类型。例如，哺乳动物是雄性还是雌性、种子的发芽与不发芽、穗子的有芒与无芒、后代的成活与死亡等。这样的结果只能是“非此即彼”两种情况，彼此构成对立事件，我们把这种“非此即彼”事件所构成的总体称为二项总体(binomial population)，其概率分布称为二项分布(binomial distribution)。

(一) 二项分布的概率函数

二项总体在进行重复抽样试验中都具有如下共同特征：

(1) 每次试验只有两个对立结果，如种子的发芽或不发芽，分别记作 A 与 $\bar{A}$，它们出

现的概率分别为 p 与 $q(q=1-p)$。

(2) 试验具有重复性和独立性。重复性(repeatability)是指每次试验条件不变,在每次试验中事件 A 出现的概率皆为 p。独立性(independence)是指任何一次试验中事件 A 的出现与其余各次试验中出现何种结果无关。

以 x 表示在 n 次试验中事件 A 出现的次数。x 是一个离散型随机变量,它的所有可能取值为 0,1,2,…,n,其概率分布函数为

$$P(x)=C_n^x p^x q^{n-x} \tag{3.16}$$

式中,$C_n^x=\dfrac{n!}{x!\ (n-x)!}$,我们称 $P(x)$ 为随机变量 x 的二项分布,记作 $B(n,p)$。之所以把这个分布称为二项分布,是因为 $C_n^x p^x q^{n-x}$ 恰好等于 $(p+q)^n$ 牛顿二项式(Newton binomial)展开式中含有 p^x 的第 $x+1$ 项,这一分布也称为伯努利分布(Bernoulli distribution)。$(p+q)^n$ 展开后有下式:

$$\begin{aligned}(p+q)^n &=C_n^0 q^n+C_n^1 p^1 q^{n-1}+C_n^2 p^2 q^{n-2}+\cdots+C_n^x p^x q^{n-x}+\cdots+C_n^n p^n\\ &=\sum_{x=0}^{n} C_n^x p^x q^{n-x}\end{aligned} \tag{3.17}$$

由于 $(p+q)^n=1$,式(3.17)可写为

$$\sum_{x=0}^{n} P(x)=1$$

若将以上试验重复 N 次,每次在 n 个试验中出现事件 A 为 x 次的理论次数则等于 N 乘以事件 A 出现 x 次的相应概率:

$$\text{理论次数}=N\cdot P(x) \tag{3.18}$$

二项分布的概率累积函数(probability cumulative function)可用下式表示:

$$F(x)=\sum_{x=0}^{i} P(x) \tag{3.19}$$

(二) 二项分布概率的计算

【例 3.4】 豌豆的红花纯合基因型和白花纯合基因型杂交后,在 F_2 代红花植株与白花植株出现的比率为 3∶1。若每次随机观察 4 株,共观察 100 次,问得红花为 0 株、1 株、2 株、3 株和 4 株的概率各是多少?

根据题意,由于红花植株与白花植株在 F_2 代出现的比率为 3∶1,那么出现红花植株的概率 $p=0.75$,出现白花植株的概率 $q=0.25$,观察株数 $n=4$,代入式(3.16),其计算结果如表 3-4 所示。

表 3-4　观察 4 株出现红花植株的概率分布表($p=0.75$, $q=0.25$)

红花植株概率函数 $f(x)$	$C_n^x p^x q^{n-x}$	$P(x)$	$F(x)$	$N\cdot P(x)$
$f(0)$	$C_4^0 p^0 q^4=1\times 0.75^0\times 0.25^4$	0.0039	0.0039	0.39
$f(1)$	$C_4^1 p^1 q^3=4\times 0.75^1\times 0.25^3$	0.0469	0.0508	4.69

续表

红花植株概率函数 $f(x)$	$C_n^x p^x q^{n-x}$	$P(x)$	$F(x)$	$N \cdot P(x)$
$f(2)$	$C_4^2 p^2 q^2 = 6 \times 0.75^2 \times 0.25^2$	0.2109	0.2617	21.09
$f(3)$	$C_4^3 p^3 q^1 = 4 \times 0.75^3 \times 0.25^1$	0.4219	0.6836	42.19
$f(4)$	$C_4^4 p^4 q^0 = 1 \times 0.75^4 \times 0.25^0$	0.3164	1.0000	31.64
总和		1.0000		100.00

【例 3.5】 某批鸡种蛋的孵化率是 0.90，今从该批种蛋中每次任选 5 枚进行孵化，试求孵出小鸡的各种可能概率。

在此问题中，$n=5$，$p=0.90$，$q=1-p=1-0.90=0.10$，每次孵化 5 枚种蛋得到小鸡数服从二项分布 $B(5,0.90)$。

获得 0 只小鸡的概率为

$$P(0)=C_5^0 p^0 q^5 = 1 \times 0.90^0 \times 0.10^5 = 0.00001$$

获得 1 只小鸡的概率为

$$P(1)=C_5^1 p^1 q^4 = 5 \times 0.90^1 \times 0.10^4 = 0.00045$$

获得 2 只小鸡的概率为

$$P(2)=C_5^2 p^2 q^3 = 10 \times 0.90^2 \times 0.10^3 = 0.00810$$

获得 3 只小鸡的概率为

$$P(3)=C_5^3 p^3 q^2 = 10 \times 0.90^3 \times 0.10^2 = 0.07290$$

获得 4 只小鸡的概率为

$$P(4)=C_5^4 p^4 q^1 = 5 \times 0.90^4 \times 0.10^1 = 0.32805$$

获得 5 只小鸡的概率为

$$P(5)=C_5^5 p^5 q^0 = 1 \times 0.90^5 \times 0.10^0 = 0.59049$$

显然，$F(x)=\sum_{x=0}^{5} C_n^x p^x q^{n-x}$

$$=0.00001+0.00045+0.00810+0.07290+0.32805+0.59049$$

$$=1$$

【例 3.6】 某小麦品种在田间出现自然变异植株的概率为 0.0045，试计算：

(1) 调查 100 株，获得两株或两株以上变异植株的概率是多少？

(2) 期望有 0.99 的概率获得 1 株或 1 株以上的变异植株，至少应调查多少株？

本例中，出现变异植株的概率 $p=0.0045$，出现非变异植株的概率 $q=1-p=1-0.0045=0.9955$，$n=100$。

(1) 获得两株或两株以上变异植株的概率计算。

获得 0 株变异植株的概率为

$$P(0)=C_{100}^0 p^0 q^{100} = 1 \times 0.0045^0 \times 0.9955^{100} = 0.6370$$

获得 1 株变异植株的概率为

$$P(1)=C_{100}^1 p^1 q^{99} = 100 \times 0.0045^1 \times 0.9955^{99} = 0.2879$$

由于 $x=0, x=1, x=2, \cdots, x=100$ 是互斥事件，且构成一个完全事件系，故得到两株或两株以上变异植株的概率为

$$P(x \geqslant 2)=1-P(0)-P(1)=1-0.6370-0.2879=0.0751$$

(2) 应调查的株数 n 应满足 $P(0)=1-0.99=0.01$，即满足：

$$P(0)=C_n^0 p^0 q^n=0.01$$

对于本例，有

$$0.9955^n=0.01$$

$$n\lg 0.9955=\lg 0.01$$

$$n=\frac{\lg 0.01}{\lg 0.9955}=\frac{-2}{-0.001959}=1021(\text{株})$$

因此，期望有 0.99 的概率得到 1 株或 1 株以上变异植株至少应调查 1021 株。

(三) 二项分布的形状和参数

1. 二项分布的形状

二项分布的形状是由 n 和 p 两个参数决定的。

(1) 当 p 值较小且 n 值不大时，图形是偏倚的。随着 n 值的增大，分布逐渐趋于对称，如图 3-3 所示。

(2) 当 p 值趋于 0.5 时，分布趋于对称，如图 3-4 所示 。

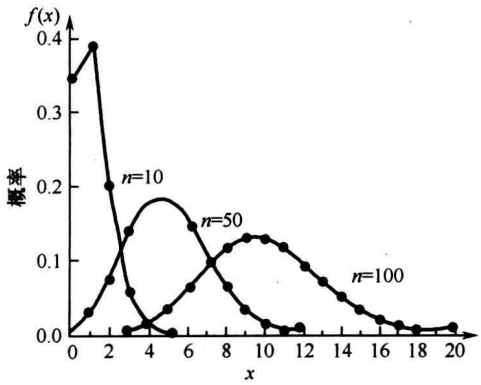

图 3-3　n 值不同的二项分布

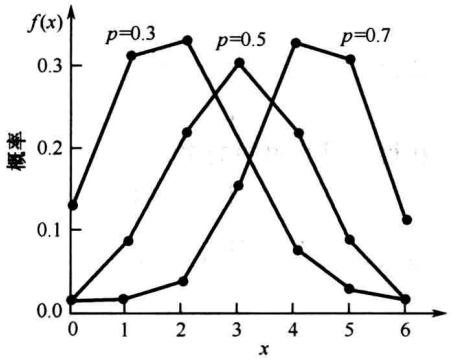

图 3-4　p 值不同的二项分布

2. 二项分布的参数

若随机变量 x 服从二项分布，则有二项分布的总体平均数(次数) 为

$$\mu_x=\sum x_i p(x_i)=np \tag{3.20}$$

二项分布的总体标准差(次数)为

$$\sigma_x=\sqrt{\sum (x_i-\mu)^2 p(x_i)}=\sqrt{npq} \tag{3.21}$$

例 3.4 对红花植株与白花植株的观察，$n=4$，$p=0.75$，可求得红花出现的平均数 $\mu=np=4\times 0.75=3.0$(株)，标准差 $\sigma=\sqrt{npq}=\sqrt{4\times 0.75\times 0.25}=0.8660$(株)。

从式(3.20)和式(3.21)可以推出二项成数，即百分数(percentage)分布的平均数和标准差。由于二项分布中变量 x(次数) 除以样本容量 n 就可得到成数 p，因而二项成数分布的平均数可由下式得出：

$$\mu_p = \frac{\mu_x}{n} = \frac{np}{n} = p \tag{3.22}$$

二项成数(百分数)分布的标准差为

$$\sigma_p = \frac{\sigma_x}{n} = \frac{\sqrt{npq}}{n} = \sqrt{\frac{pq}{n}} \tag{3.23}$$

例 3.4 中红花出现的二项成数的平均数 $\mu_p = p = 0.75$，标准差 $\sigma_p = \sqrt{\frac{pq}{n}} = \sqrt{\frac{0.75 \times 0.25}{4}} = 0.2165$。

二、泊松分布

在生物学研究中，有许多事件出现的概率很小，而样本容量或试验次数却很大，即有很小的 p 值和很大的 n 值。这时，二项分布就变成另外一种特殊的分布，即泊松分布(Poisson distribution)。例如，显微镜视野内染色体有变异的细胞计数、由突变而引起的遗传病患者的分布、田间小区内出现变异植株的计数、作物种子田内杂草的计数、单位容积的水或牛奶中细菌数目分布、家畜产怪胎数、样方内少见植物的个体数等都属于泊松分布。

泊松分布也是一种离散型随机变量的分布，其分布的概率函数为

$$P(x) = \frac{e^{-\lambda}\lambda^x}{x!} \tag{3.24}$$

且有

$$\sum_{x=0}^{\infty} P(x) = e^{-\lambda} \sum_{x=0}^{\infty} \frac{\lambda^x}{x!} = e^{-\lambda} e^{\lambda} = 1$$

式中，λ 为参数，$\lambda = np$；e 为自然对数底，近似值为 2.71828…；$x = 0, 1, 2, \cdots$。

泊松分布的平均数、方差、标准差为

$$\mu = \lambda \tag{3.25}$$

$$\left.\begin{aligned} \sigma^2 &= \lambda \\ \sigma &= \sqrt{\lambda} \end{aligned}\right\} \tag{3.26}$$

从式(3.25)和式(3.26)可以知道，泊松分布的参数 λ 不但是其分布的平均数 μ，而且还是方差 σ^2。我们把具有参数 λ 的泊松分布记作 $P(\lambda)$。

泊松分布的形状由参数 λ 所确定。当 λ 较小时，泊松分布是偏倚的，如图 3-5 所示。随 λ 增大，分布逐渐对称。当 λ 无限增大时，泊松分布逼近正态分布 $N(\lambda, \lambda)$；当 $\lambda = 20$ 时，泊松分布逼近正态分布 $N(\lambda, \lambda)$；当 $\lambda = 30$ 时，泊松分布已和正态分布非常接近；当 $\lambda = 50$ 时，这两种分布除一种是离散型的和一种是连续型的之外，已没有多大区别。

泊松分布在生物学研究中有广泛的应用。① 在生物学研究中，有许多小概率事件，

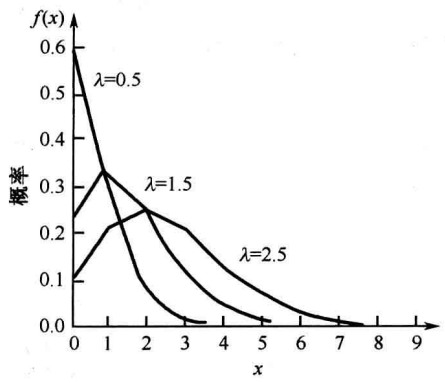

图 3-5　λ 值不同的泊松分布

其发生概率 p 往往小于 0.1，甚至小于 0.01。例如，两对交换率为 0.1 的连锁基因在 F_2 代出现纯合新个体的概率只有 $2\times0.05^2=0.0050$；自花授粉植物出现天然异交或突变的概率往往小于 0.01；等等。对于这些小概率事件，都可以用泊松分布描述其概率分布，从而作出需要的频率预期。② 由于泊松分布是描述小概率事件的，因而二项分布当 $p<0.1$ 和 $np<5$ 时，可用泊松分布来近似。

【例 3.7】 用显微镜检查某食品样本内结核菌的数目，对在某些视野内各小方格中的细菌数目加以计数，然后按不同的细菌数把格子分类，记录每类中的格子数目。结果如表 3-5 所示，试求各种细菌数的理论格子数。

表 3-5　细菌计数的泊松分布

细菌数(x)	0	1	2	3	4	5	6	7	8	9	总计
实际格子数	5	19	26	26	21	13	5	1	1	1	118
$P(x)$	0.0506	0.1511	0.2253	0.2240	0.1671	0.0997	0.0496	0.0211	0.0079	0.0026	0.9990
理论格子数	5.97	17.83	26.59	26.43	19.72	11.76	5.85	2.49	0.93	0.31	117.88

各小方格中出现细菌是小概率事件，服从泊松分布。现从样本数据中计算出每个格子中的细菌平均数 $\bar{x}$：

$$\bar{x}=\frac{\sum fx}{n}=\frac{1}{118}\times(0\times5+1\times19+\cdots+9\times1)=2.9831$$

用样本平均数 $\bar{x}$ 估计总体平均数 μ，即 λ，代入式(3.24)，计算当 $x=0,1,2,\cdots,9$ 时的概率 $P(x)$，填入表 3-5 中。根据理论次数 $=N\cdot P(x)$ 计算各个细菌数的理论格子数，结果列入表 3-5。

【例 3.8】 例 3.6 资料中小麦品种中出现变异植株的概率 $p=0.0045$，可以看成小概率事件。试用泊松分布求解例 3.6 所提的两个问题。

(1) 先求 λ：

$$\lambda=np=100\times0.0045=0.45$$

代入式(3.24)，有

$$P(0)=\frac{0.45^0e^{-0.45}}{0!}=e^{-0.45}=0.6376$$

$$P(1)=\frac{0.45^1e^{-0.45}}{1!}=0.45\times e^{-0.45}=0.2869$$

所以，调查 100 株获得两株或两株以上变异植株的概率为

$$P(x\geqslant2)=1-P(0)-P(1)=1-0.6376-0.2869=0.0755$$

(2) 应调查的株数 n 应满足：

$$e^{-\lambda}=e^{-np}=0.01$$

因此，有

$$n=\frac{\lg 0.01}{-p\lg e}=\frac{-2}{-0.0045\times 0.43429}=1023(\text{株})$$

上述结果与例 3.6 的结果很接近。

三、正 态 分 布

正态分布(normal distribution)也称为高斯分布(Gauss distribution)，是一种连续型随机变量的概率分布。它的分布状态是多数变量都围绕在平均值左右，由平均值到分布的两侧，变量数减少。正态分布是一种在统计理论和应用上最重要的分布。试验误差的分布一般服从于这种分布，许多生物现象的计量资料均近似服从这种分布。同时，在一定条件下，正态分布还可作为离散型随机变量或其他连续型随机变量的近似分布。例如，当 n 相当大或 p 与 q 基本接近时，二项分布接近于正态分布；当 λ 较大时，泊松分布也接近正态分布。有些总体虽然并不服从正态分布，但从总体中随机抽取的样本容量相当大时，其样本平均数的分布也近似于正态分布。这样，就能用正态分布代替其他分布进行概率计算和统计推断。

(一) 正态分布的概率函数

正态分布的概率函数可由二项分布的概率函数在 $n\to\infty$ 时导出，其方程为

$$f(x)=\frac{1}{\sigma\sqrt{2\pi}}e^{-\frac{1}{2}(\frac{x-\mu}{\sigma})^2} \tag{3.27}$$

式中，$f(x)$ 为正态分布的概率密度函数，表示某一定 x 值出现的概率密度函数值；μ 为总体平均数；σ 为总体标准差；π 为圆周率，近似值为 3.14159…；e 为自然对数底，近似值为 2.71828…。

正态分布记为 $N(\mu,\sigma^2)$，表示具有平均数为 μ、方差为 σ^2 的正态分布。μ 和 σ 是正态分布的两个主要参数，一个正态分布完全由参数 μ 和 σ 来决定。正态分布曲线(normal distribution curve)如图 3-6 所示。

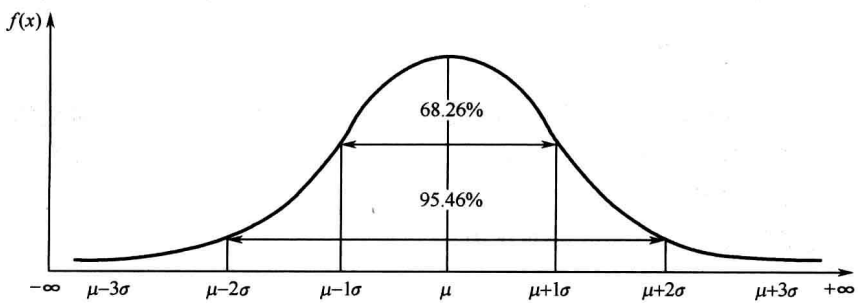

图 3-6　正态分布曲线

(二) 正态分布的特征

正态分布具有以下特征。

(1) 当$x=\mu$时，$f(x)$有最大值$\frac{1}{\sigma\sqrt{2\pi}}$，所以，正态分布曲线是以平均数$\mu$处为峰值的曲线。

(2) 当$x-\mu$的绝对值相等时，$f(x)$值也相等，所以正态分布是以μ为中心向左右两侧对称的分布。

(3) $\frac{x-\mu}{\sigma}$的绝对值越大，$f(x)$值就越小，但$f(x)$永远不会等于0，所以正态分布以x轴为渐近线，x的取值区间为$(-\infty,+\infty)$。

(4) 正态分布曲线完全由参数μ和σ来决定。μ确定正态分布曲线在x轴上的中心位置，μ减小，曲线左移；μ增大，曲线右移。σ确定正态分布曲线的展开程度，σ越小，曲线展开程度越小，曲线越陡高；σ越大，曲线展开程度越大，曲线越矮宽。不同μ值和不同σ值的正态分布曲线比较见图 3-7 和图 3-8。

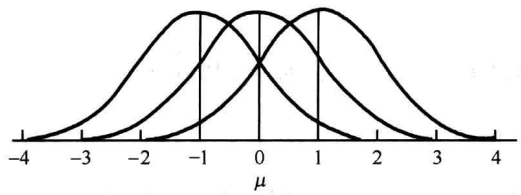

图 3-7　μ值不同、σ值相同的 3 条正态曲线

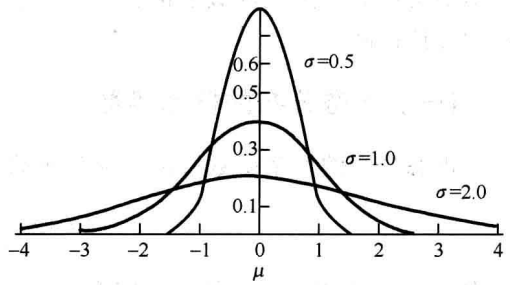

图 3-8　μ值相同、σ值不同的 3 条正态曲线

(5) 正态分布曲线在$x=\mu\pm\sigma$处各有一个拐点(knee point)，曲线通过拐点时改变弯曲方向。

(6) 正态分布曲线的x在区间$(-\infty,+\infty)$皆可取值，这样就构成了x取值的完全事件系，因此，正态分布的概率密度曲线与渐近线x轴所围成的全部面积必然等于 1。

(三) 标准正态分布

对于一个正态分布，μ确定了分布曲线的中心位置，σ则确定了分布曲线的变异度。但不同的正态分布有不同的μ和σ，所以对$N(\mu,\sigma^2)$来说不是一条曲线，而是一个曲线系统。为便于一般化应用，需将正态分布标准化(standardization)。令$\mu=0,\sigma^2=1$，则正态分布概率密度函数式(3.27)即可标准化为

$$f(u)=\frac{1}{\sqrt{2\pi}}e^{-\frac{1}{2}u^2} \tag{3.28}$$

从几何意义上说，正态分布的标准化实质上是作出了坐标轴的平移和尺度转换，使正态分布具有平均数 $\mu=0$，标准差 $\sigma=1$。将随机变量 u 服从于 $\mu=0$，$\sigma=1$ 的正态分布称为标准正态分布（standard normal distribution），又称为 u 分布（u-distribution），记作 $N(0,1)$。$f(u)$ 称为标准正态分布方程（standard normal distribution equation）或 u 分布方程（u-distribution equation），标准正态分布曲线见图 3-9。

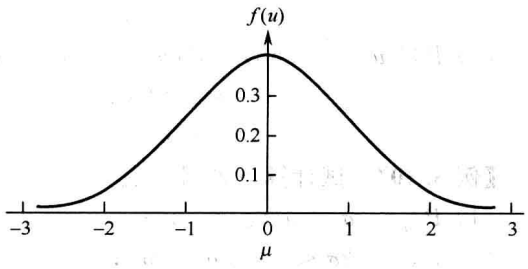

图 3-9　标准正态分布的曲线

对于任何一个服从正态分布 $N(\mu,\sigma^2)$ 的随机变量 x，都可以进行标准化变换：

$$u=\frac{x-\mu}{\sigma} \tag{3.29}$$

式中，u 为标准正态离差（standard normal deviate），它表示离开平均数 μ 有几个标准差 σ。

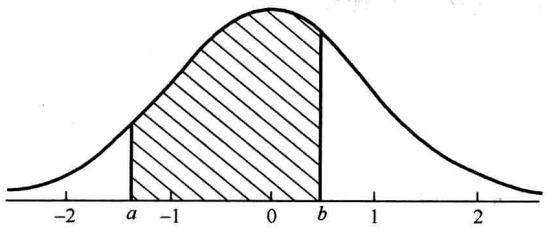

图 3-10　标准正态分布的概率计算

标准正态分布的概率累积函数记作 $F(u)$，它是变量 u 小于某一定值 u_i 的概率，这需要对式（3.28）计算从 $-\infty$ 到 u_i 的定积分，即

$$F(u_i)=P(u<u_i)=\int_{-\infty}^{u_i} f(u)\mathrm{d}u \tag{3.30}$$

对于 u 落在区间 $[a,b]$ 的概率（即图 3-10 中的阴影部分），有下式：

$$P(a\leqslant u\leqslant b)=\int_a^b \frac{1}{\sqrt{2\pi}}\mathrm{e}^{-\frac{1}{2}u^2}\mathrm{d}u \tag{3.31}$$

（四）正态分布的概率计算

由于正态分布的概率累积函数具有广泛的应用，统计学家已计算好实际需要的各个 $F(u)$ 值，列于附表 1。在计算一般正态分布的概率时，只需将服从正态分布的随机变量 x 取值区间的上、下限按式（3.29）转换成 u 取值区间的上、下限，再查附表 1 即可。例如，查附表 1，$F(-1.0)=0.1587$，$F(2.0)=0.97725$。

【例 3.9】　设 u 服从正态分布 $N(0,1)$，试求：

（1）$P(u\leqslant 1)$；

（2）$P(u>1)$；

（3）$P(-2.0<u\leqslant 1.5)$；

（4）$P(|u|>2.58)$。

查附表 1，得

（1）$P(u\leqslant 1)=F(u=1)=0.8413$

（2）$P(u>1)=1-P(u<1)=1-F(u=1)=1-0.8413=0.1587$

（3）$P(-2.0<u\leqslant 1.5)=F(u=1.5)-F(u=-2.0)$

$$=0.93319-0.02275=0.91044$$

(4) $P(|u|>2.58)=P(u>2.58)+P(u<-2.58)$

$$=1-F(u=2.58)+F(u=-2.58)=1-0.99506+0.00494$$

$$=0.00988$$

【例 3.10】 试计算下列概率值：

(1) $P(\mu-\sigma<x\leqslant\mu+\sigma)$；

(2) $P(\mu-2\sigma<x\leqslant\mu+2\sigma)$；

(3) $P(\mu-3\sigma<x\leqslant\mu+3\sigma)$；

(4) $P(\mu-1.96\sigma<x\leqslant\mu+1.96\sigma)$；

(5) $P(\mu-2.58\sigma<x\leqslant\mu+2.58\sigma)$；

(6) $P(x>\mu+1.96\sigma,x\leqslant\mu-1.96\sigma)$；

(7) $P(x>\mu+2.58\sigma,x\leqslant\mu-2.58\sigma)$。

首先根据式(3.29)求 u 值，然后查附表 1，进行概率计算：

(1) $u_1=\dfrac{x-\mu}{\sigma}=\dfrac{(\mu-\sigma)-\mu}{\sigma}=-1$

$u_2=\dfrac{x-\mu}{\sigma}=\dfrac{(\mu+\sigma)-\mu}{\sigma}=1$

$P(\mu-\sigma<x\leqslant\mu+\sigma)=P(-1<u\leqslant1)$

$=F(u=1)-F(u=-1)$

$=0.8413-0.1587=0.6826$

(2) $u_1=\dfrac{x-\mu}{\sigma}=\dfrac{(\mu-2\sigma)-\mu}{\sigma}=-2$

$u_2=\dfrac{x-\mu}{\sigma}=\dfrac{(\mu+2\sigma)-\mu}{\sigma}=2$

$P(\mu-2\sigma<x\leqslant\mu+2\sigma)=P(-2<u\leqslant2)$

$=F(u=2)-F(u=-2)$

$=0.97725-0.02275=0.9545$

(3) $u_1=\dfrac{x-\mu}{\sigma}=\dfrac{(\mu-3\sigma)-\mu}{\sigma}=-3$

$u_2=\dfrac{x-\mu}{\sigma}=\dfrac{(\mu+3\sigma)-\mu}{\sigma}=3$

$P(\mu-3\sigma<x\leqslant\mu+3\sigma)=P(-3<u\leqslant3)$

$=F(u=3)-F(u=-3)$

$=0.99865-0.00135=0.9973$

(4) $u_1=\dfrac{x-\mu}{\sigma}=\dfrac{(\mu-1.96\sigma)-\mu}{\sigma}=-1.96$

$u_2=\dfrac{x-\mu}{\sigma}=\dfrac{(\mu+1.96\sigma)-\mu}{\sigma}=1.96$

$P(\mu-1.96\sigma<x\leqslant\mu+1.96\sigma)=P(-1.96<u\leqslant1.96)$

$=F(u=1.96)-F(u=-1.96)$

$$=0.9750-0.0250=0.95$$

(5) $u_1=\dfrac{x-\mu}{\sigma}=\dfrac{(\mu-2.58\sigma)-\mu}{\sigma}=-2.58$

$$u_2=\frac{x-\mu}{\sigma}=\frac{(\mu+2.58\sigma)-\mu}{\sigma}=2.58$$

$$P(\mu-2.58\sigma<x\leqslant\mu+2.58\sigma)=P(-2.58<u\leqslant 2.58)$$
$$=F(u=2.58)-F(u=-2.58)$$
$$=0.99506-0.00494=0.99012$$

(6) $P(x>\mu+1.96\sigma,x\leqslant\mu-1.96\sigma)=P(u>1.96)+P(u\leqslant-1.96)$
$$=1-F(u=1.96)+F(u=-1.96)$$
$$=1-0.9750+0.0250=0.05$$

(7) $P(x>\mu+2.58\sigma,x\leqslant\mu-2.58\sigma)=P(u>2.58)+P(u\leqslant-2.58)$
$$=1-F(u=2.58)+F(u=-2.58)$$
$$=1-0.99506+0.00494=0.00988\approx 0.01$$

上述计算结果参见图 3-6。从上述计算可知，虽然标准正态分布 u 的取值区间为 $(-\infty,+\infty)$，但实际上 $|u|>2.58$ 的概率只有 0.01，$|u|>1.96$ 的概率也只有 0.05，也就是说，在 $\mu\pm1.96\sigma$ 和 $\mu\pm2.58\sigma$ 范围内已分别包含了 95% 和 99% 的变量，即 $|x-\mu|>1.96\sigma$ 和 $|x-\mu|>2.58\sigma$ 的概率只有 5% 和 1%。

以上在计算 $|x-\mu|>1.96\sigma$ 和 $|x-\mu|>2.58\sigma$ 的概率时均为双尾概率 (two-tailed probability)，即左尾概率和右尾概率之和。由于双尾概率值经常使用，为减少计算的麻烦，附表 2(正态离差 u 值表) 列出了两尾概率取某一显著水平 α 时的 u 临界值(critical value)，即分位数(fractile)，记为 u_α，可直接查用。例如，可查得 $p=0.05$ 时，$u_{0.05}=1.96$；$p=0.01$ 时，$u_{0.01}=2.58$。

【例 3.11】 调查某玉米品种穗长(单位：cm)，其资料服从正态分布 $N(15.7,1.04)$。试计算：

(1) 玉米穗长的 95% 正常值范围；

(2) 穗长>16cm 的概率。

(1) 已知玉米穗长服从正态分布，$\mu=15.7(\text{cm})$，$\sigma^2=1.04(\text{cm}^2)$，则 $\sigma=\sqrt{1.04}=1.02(\text{cm})$。

查附表 2，双尾概率 $u_{0.05}=1.96$，则

上限为：$15.7+1.96\times1.02=17.70(\text{cm})$

下限为：$15.7-1.96\times1.02=13.70(\text{cm})$

(2) 已知 $x>16\text{cm}$，求得 $u=\dfrac{16-15.7}{1.02}=0.29$，查附表 1，$F(0.29)=0.6141$，因此，有

$$P(x>16)=P(u>0.29)=1-F(0.29)=1-0.6141=0.3859$$

对应于双尾概率，$x\leqslant\mu-1.96\sigma$ 或 $x>\mu+1.96\sigma$ 的概率称为单尾概率 (one-tailed probability)。例如，

$$P(x\leqslant\mu-1.96\sigma)=P(x>\mu+1.96\sigma)=0.025$$
$$P(x\leqslant\mu-1.64\sigma)=P(x>\mu+1.64\sigma)=0.05$$
$$P(x\leqslant\mu-2.33\sigma)=P(x>\mu+2.33\sigma)=0.01$$

此时，$u_{0.025}=1.96$，$u_{0.05}=1.64$，$u_{0.01}=2.33$。

第三节　统计数的分布

统计学中的主要问题就是研究总体与由总体中所取样本的关系，这种关系可从两个方向来研究，如图 3-11 所示。第一个方向是由总体到样本，即从一般到特殊，主要是要了解从总体到从总体中所抽取样本的变异特点，这就需要从总体中随机抽取若干或全部样本，研究其样本分布及其统计数。这是本节所讨论的问题。第二个方向是从样本到总体，也就是从特殊到一般，是要从一个样本或一系列样本的统计数去推断总体，即统计推断问题，这将在第四章中详细讨论。

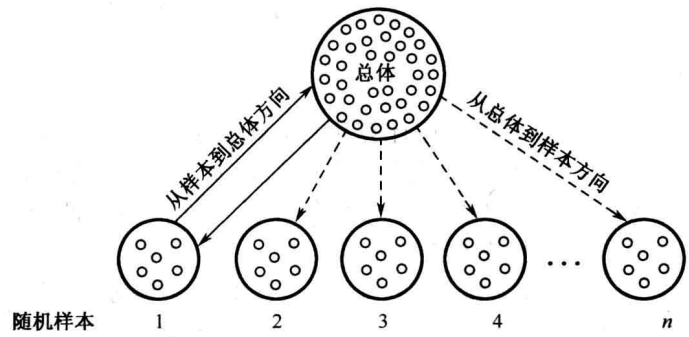

图 3-11　总体与样本的关系

一、抽样试验与无偏估计

从总体中抽样必须符合随机的原则，即保证总体中的每一个个体在每一次抽样中都有相同的概率被抽取为样本。从理论上讲，从一个总体中抽取所有可能的样本，就能获得有关统计数变异的全部信息。但是，这样的抽样试验(sampling experiment)不仅在无限总体中无法做到，就是在许多有限总体中也难以做到。解决这一矛盾的方法是，仅抽取一部分样本进行研究，或对小的有限总体进行放回式抽样，又称为复置抽样(sampling with replacement)。实践证明，部分抽样比较接近实际。在有放回的小总体中抽样，样本可以从不会耗尽的总体中获得，所以从理论上可以看成容量是无限的，因此具有无限总体抽样的性质，即所获得样本是等概率的和随机的。

设有一个 $N=3$ 的近似正态总体，具有变量 3、4、5，由式(2.1)、式(2.10)和式(2.12)可求得 $\mu=4$、$\sigma^2=0.6667$、$\sigma=0.8165$。现以 $n=2$ 作独立的放回式抽样，总共可得 $N^n=3^2=9$ 个样本，其抽样结果列于表 3-6。

根据表 3-6 的资料，可以求出：

$$\text{样本平均数}\bar{x}\text{ 的平均数 }\mu_{\bar{x}}=\frac{36}{9}=4=\mu$$

表 3-6　$N=3, n=2$ 放回式抽样时所有样本的平均数、方差和标准差

样本编号	样本值	$\bar{x}$	s^2	s
1	3，3	3.0	0.0	0.0000
2	3，4	3.5	0.5	0.7071
3	3，5	4.0	2.0	1.4142
4	4，3	3.5	0.5	0.7071
5	4，4	4.0	0.0	0.0000
6	4，5	4.5	0.5	0.7071
7	5，3	4.0	2.0	1.4142
8	5，4	4.5	0.5	0.7071
9	5，5	5.0	0.0	0.0000
$\sum$		36.0	6.0	5.6568

$$\text{样本方差 } s^2 \text{ 的平均数 } \mu_{s^2}=\frac{6}{9}=0.6667=\sigma^2$$

$$\text{样本标准差 } s \text{ 的平均数 } \mu_s=\frac{5.6568}{9}=0.6285\neq\sigma$$

在统计上，如果所有可能样本的某一统计数的平均数等于总体的相应参数，则称该统计数为总体相应参数的无偏估计值(unbiased estimated value)。根据上述计算结果，可知道：

(1) 样本平均数$\bar{x}$ 是总体平均数 μ 的无偏估计值；

(2) 样本方差 s^2 是总体方差 σ^2 的无偏估计值；

(3) 样本标准差 s 不是总体标准差σ 的无偏估计值 。

二、样本平均数的分布

对上述 $N=3$，$n=2$ 抽样试验所得的 9 个样本平均数，可整理成次数分布表，列于表 3-7。如果对这个 3、4、5 组成的总体再进行 $n=4$ 的抽样试验，则共可得 $N^n=3^4=81$ 个样本平均数，其平均数的次数分布也列于表 3-7。由于从总体中抽出的样本为每一个可能样本，且每个样本中的变量均为随机变量，所以其样本平均数也为随机变量，也形成一定的理论分布，这种理论分布称为样本平均数的概率分布，或称样本平均数的分布 (distribution of the sample mean)。

样本平均数的分布与其他分布一样有两个重要参数，一个是样本平均数的平均数，记作$\mu_{\bar{x}}$；另一个是样本平均数的方差，记作$\sigma^2_{\bar{x}}$。根据表 3-7，可求得 $n=2$ 的样本平均数的平均数 $\mu_{\bar{x}}$ 和方差 $\sigma^2_{\bar{x}}$ 为

$$\mu_{\bar{x}}=\frac{\sum f\bar{x}}{N^n}=\frac{36}{9}=4=\mu$$

$$\sigma^2_{\bar{x}}=\frac{1}{N^n}\left[\sum f\bar{x}^2-\frac{\left(\sum f\bar{x}\right)^2}{N^n}\right]=\frac{1}{9}\times\left(147-\frac{36^2}{9}\right)=0.3333=\frac{\sigma^2}{n}$$

同样，可求得 $n=4$ 时样本平均数的平均数 $\mu_{\bar{x}}$ 和方差 $\sigma^2_{\bar{x}}$ 为

表 3-7　样本容量不同的样本平均数的次数分布

$n=2$				$n=4$			
$\bar{x}$	f(次数)	$f\bar{x}$	$f\bar{x}^2$	$\bar{x}$	f(次数)	$f\bar{x}$	$f\bar{x}^2$
3.0	1	3	9.0	3.00	1	3	9.00
				3.25	4	13	42.25
3.5	2	7	24.5	3.50	10	35	122.50
				3.75	16	60	225.00
4.0	3	12	48.0	4.00	19	76	304.00
				4.25	16	68	289.00
4.5	2	9	40.5	4.50	10	45	202.50
				4.75	4	19	90.25
5.0	1	5	25.0	5.00	1	5	25.00
$\sum$	9	36	147.0	$\sum$	81	324	1309.50

$$\mu_{\bar{x}}=\frac{324}{81}=4=\mu$$

$$\sigma_{\bar{x}}^2=\frac{1}{81}\times\left(1309.50-\frac{324^2}{81}\right)=0.1667=\frac{\sigma^2}{n}$$

由以上抽样试验,可得出样本平均数分布有以下基本性质:

(1) 样本平均数分布的平均数等于总体平均数,即

$$\mu_{\bar{x}}=\mu \tag{3.32}$$

(2) 样本平均数分布的方差等于总体方差除以样本容量,即

$$\sigma_{\bar{x}}^2=\frac{\sigma^2}{n} \tag{3.33}$$

进而,有样本平均数的标准误差(standard error),简称平均数的标准误(standard error of mean):

$$\sigma_{\bar{x}}=\frac{\sigma}{\sqrt{n}} \tag{3.34}$$

(3) 如果从正态总体 $N(\mu,\sigma^2)$ 进行抽样,其样本平均数 $\bar{x}$ 是一个具有平均数 μ、方差 $\frac{\sigma^2}{n}$ 的正态分布,记作 $N\left(\mu,\frac{\sigma^2}{n}\right)$。

(4) 如果被抽样总体不是正态总体,但具有平均数 μ 和方差 σ^2,当样本容量 n 不断增大,样本平均数 $\bar{x}$ 的分布也越来越接近正态分布,且具有平均数 μ、方差 $\frac{\sigma^2}{n}$,这称为中心极限定理(central-limit theorem)。这个性质对于连续型变量或非连续型变量都能适用。不论总体为何种分布,一般只要样本容量 $n\geqslant 30$,属于大样本,就可应用中心极限定理,认为样本平均数 $\bar{x}$ 的分布是正态分布。在计算样本平均数出现的概率时,样本平均数 $\bar{x}$ 可按下式进行标准化:

$$u=\frac{\bar{x}-\mu_{\bar{x}}}{\sigma_{\bar{x}}}=\frac{\bar{x}-\mu}{\frac{\sigma}{\sqrt{n}}} \tag{3.35}$$

三、样本平均数差数的分布

设有两个相互独立的正态总体，总体一为 $N_1=2$，具变量 3、6，其平均数 $\mu_1=4.5$，方差 $\sigma_1^2=2.25$，当以 $n_1=3$ 进行抽样试验，共可得 $2^3=8$ 个样本，求得 $\mu_{\bar{x}_1}=4.5$，$\sigma_{\bar{x}_1}^2=0.75$；总体二为 $N_2=3$，具变量 2、4、6，其平均数 $\mu_2=4$，方差 $\sigma_2^2=2.6667$，当以 $n_2=2$ 进行抽样试验，共可得 $3^2=9$ 个样本，求得 $\mu_{\bar{x}_2}=4$，$\sigma_{\bar{x}_2}^2=1.3333$。将来自两个总体的样本平均数进行所有可能的比较，得出 72 个样本平均数差数 $(\bar{x}_1-\bar{x}_2)$，其次数分布表如表 3-8 所示。

表 3-8　样本平均数差数 $(\bar{x}_1-\bar{x}_2)$ 次数分布表

$\bar{x}_1-\bar{x}_2$	f	$f(\bar{x}_1-\bar{x}_2)$	$f(\bar{x}_1-\bar{x}_2)^2$
4	1	4	16
3	5	15	45
2	12	24	48
1	18	18	18
0	18	0	0
−1	12	−12	12
−2	5	−10	20
−3	1	−3	9
$\sum$	72	36	168

根据表 3-8，可求出样本平均数差数分布（distribution of the sample mean difference）的平均数 $\mu_{\bar{x}_1-\bar{x}_2}$ 和方差 $\sigma_{\bar{x}_1-\bar{x}_2}^2$：

$$\mu_{\bar{x}_1-\bar{x}_2}=\frac{\sum f(\bar{x}_1-\bar{x}_2)}{N_1^{n_1}N_2^{n_2}}=\frac{36}{72}=0.5=\mu_{\bar{x}_1}-\mu_{\bar{x}_2}=\mu_1-\mu_2$$

$$\sigma_{\bar{x}_1-\bar{x}_2}^2=\frac{1}{N_1^{n_1}N_2^{n_2}}\left\{\sum f(\bar{x}_1-\bar{x}_2)^2-\frac{\left[\sum f(\bar{x}_1-\bar{x}_2)\right]^2}{N_1^{n_1}N_2^{n_2}}\right\}$$

$$=\frac{1}{72}\times\left(168-\frac{36^2}{72}\right)=2.0833=\sigma_{\bar{x}_1}^2+\sigma_{\bar{x}_2}^2=\frac{\sigma_1^2}{n_1}+\frac{\sigma_2^2}{n_2}$$

根据上述计算，可得样本平均数差数分布的基本性质为：

（1）样本平均数差数的平均数等于总体平均数的差数（或样本平均数分布的平均数的差数），即

$$\mu_{\bar{x}_1-\bar{x}_2}=\mu_1-\mu_2=\mu_{\bar{x}_1}-\mu_{\bar{x}_2} \tag{3.36}$$

（2）样本平均数差数的方差等于总体方差除以各自样本容量之和（或两样本平均数方差之和），即

$$\sigma_{\bar{x}_1-\bar{x}_2}^2=\frac{\sigma_1^2}{n_1}+\frac{\sigma_2^2}{n_2}=\sigma_{\bar{x}_1}^2+\sigma_{\bar{x}_2}^2 \tag{3.37}$$

进而，有样本平均数差数标准误（standard error of the sample mean difference）：

$$\sigma_{\bar{x}_1-\bar{x}_2}=\sqrt{\frac{\sigma_1^2}{n_1}+\frac{\sigma_2^2}{n_2}} \tag{3.38}$$

当 $\sigma_1^2=\sigma_2^2=\sigma^2$ 时，式(3.37) 可简化为

$$\sigma^2_{\bar{x}_1-\bar{x}_2}=\sigma^2\left(\frac{1}{n_1}+\frac{1}{n_2}\right) \tag{3.39}$$

当 $n_1=n_2=n$ 时，式(3.37)可简化为

$$\sigma^2_{\bar{x}_1-\bar{x}_2}=\frac{\sigma_1^2+\sigma_2^2}{n} \tag{3.40}$$

当 $\sigma_1^2=\sigma_2^2=\sigma^2$ 且 $n_1=n_2=n$ 时，式(3.37)可进一步简化为

$$\sigma^2_{\bar{x}_1-\bar{x}_2}=\frac{2\sigma^2}{n} \tag{3.41}$$

(3) 从两个独立正态总体中抽出的样本平均数差数的分布也是正态分布，并具有平均数 $\mu_1-\mu_2$ 和方差 $\sigma^2_{\bar{x}_1-\bar{x}_2}$，记作 $N(\mu_1-\mu_2,\sigma^2_{\bar{x}_1-\bar{x}_2})$。

四、t 分 布

前面计算样本平均数分布和样本平均数差数分布的概率时，需要总体方差 σ^2 已知，或者 σ^2 未知但样本容量较大($n\geqslant 30$)，此时用样本方差 s^2 估计 σ^2。但在实际研究中经常遇到总体方差 σ^2 未知且样本容量不大($n<30$)的情况，如果仍用 s^2 来估计 σ^2，这时 $\dfrac{\bar{x}-\mu}{\dfrac{s}{\sqrt{n}}}$ 就不再服从正态分布了，而是服从自由度 $df=n-1$ 的 t 分布(t-distribution)，即

$$t=\frac{\bar{x}-\mu}{s_{\bar{x}}}=\frac{\bar{x}-\mu}{\dfrac{s}{\sqrt{n}}} \tag{3.42}$$

式中，$s_{\bar{x}}$ 为样本平均数的标准误，其计算公式为

$$s_{\bar{x}}=\frac{s}{\sqrt{n}} \tag{3.43}$$

$s_{\bar{x}}$ 为 $\sigma_{\bar{x}}$ 的估计值。

t 分布是英国统计学家 Gosset 于 1908 年以笔名“Student”所发表的论文中提出的，因此亦称学生氏 t 分布，简称 t 分布。t 分布的概率密度函数为

$$f(t)=\frac{\Gamma\left(\dfrac{df+1}{2}\right)}{\sqrt{\pi df}\,\Gamma\left(\dfrac{df}{2}\right)}\left(1+\frac{t^2}{df}\right)^{-\frac{df+1}{2}} \tag{3.44}$$

式中，Γ 为 Γ 函数。

t 分布的平均数 μ_t 和方差 σ_t^2 为

$$\mu_t=0 \quad (df>1) \tag{3.45}$$

$$\sigma_t^2=\frac{df}{df-2} \quad (df>2) \tag{3.46}$$

t 分布具有以下特征：

(1) t 分布曲线是左右对称的，围绕平均数 $\mu_t=0$ 向两侧递降。

(2) t 分布受自由度 $df=n-1$ 的制约，每个自由度都有一条 t 分布曲线。

(3) 和正态分布相比，t 分布的顶部偏低，尾部偏高，自由度 $df \geqslant 30$ 时，其曲线就比较接近正态分布曲线，当 $df \to \infty$ 时则和正态分布曲线重合(图 3-12)。

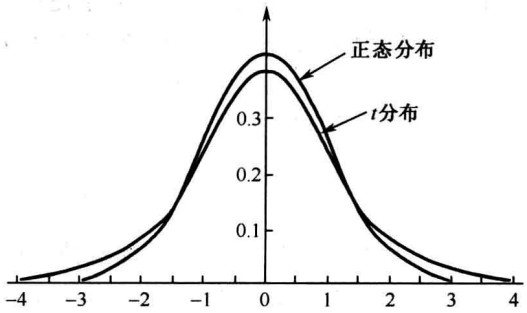

图 3-12　正态分布曲线与 t 分布曲线的比较

和正态分布一样，t 分布曲线与横轴所围成的面积也等于 1。各种自由度下的 t 值，可从附表 3 中查到。例如，可查得 $df=10$、$P=0.05$ 的 t 值为 2.228，$P=0.01$ 的 t 值为 3.169，分别记作 $t_{0.05(10)}=2.228$ 和 $t_{0.01(10)}=3.169$。因此，t 落在区间$[-t_{0.05}, +t_{0.05}]$ 内的概率为 0.95，落在区间$[-t_{0.01}, +t_{0.01}]$ 内的概率为 0.99，其中 $t_{0.05}$、$t_{0.01}$ 分别称为置信度为 5% 和 1% 的 t 临界值(分位数)。

五、χ^2 分　布

在第二节，我们已经知道标准正态离差 $u=\dfrac{x-\mu}{\sigma}$ 服从 $N(0,1)$。假设从标准正态总体中抽取 k 个独立样本，就会得到 $u_1^2, u_2^2, \cdots, u_k^2$，则定义它们的和为 χ^2(chi-square)，即

$$\chi^2 = u_1^2 + u_2^2 + \cdots + u_k^2 = \sum_{i=1}^{k} u_i^2 = \sum_{i=1}^{k} \left(\frac{x-\mu}{\sigma}\right)^2 \tag{3.47}$$

式中，χ^2 分布的自由度 $df=k-1$。

χ^2 的概率密度函数为

$$f(\chi^2) = \frac{(\chi^2)^{\frac{df}{2}-1}}{2^{\frac{df}{2}}\Gamma\left(\dfrac{df}{2}\right)} e^{-\frac{1}{2}\chi^2} \tag{3.48}$$

χ^2 分布(chi-square distribution) 的概率累积函数为

$$F(\chi^2) = \int_0^{\chi^2} f(\chi^2)\mathrm{d}(\chi^2) \tag{3.49}$$

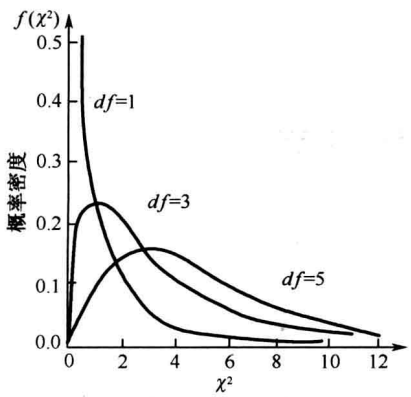

图 3-13　不同自由度的 χ^2 分布曲线

χ^2 分布是连续型变量的分布，每个不同的自由度都有一个相应的 χ^2 分布曲线，所以 χ^2 分布是一组曲线。

χ^2 分布的特征为：

(1) χ^2 分布于区间$[0, +\infty)$，并且呈反 J 形的偏斜分布 (skewed distribution)。

(2) χ^2 分布的偏斜度(skewness) 随自由度降低而增大，当自由度 $df=1$ 时，曲线以纵轴为渐近线。

(3) 随自由度 df 增大，χ^2 分布曲线渐趋左右对称，当 $df \geqslant 30$ 时，χ^2 分布已接近正态分布(图 3-13)。

附表 4 列出了各种自由度下不同单尾(右尾)概率的 χ^2 值。例如,当 $df=2$ 时,查得 $P=0.05$ 的 χ^2 值为 5.99,$P=0.01$ 的 χ^2 值为 9.21,分别记作 $\chi^2_{0.05(2)}=5.99$、$\chi^2_{0.01(2)}=9.21$,表示 $P(\chi^2\geqslant 5.99)=0.05$、$P(\chi^2\geqslant 9.21)=0.01$,即所得 χ^2 值大于 5.99 的概率仅有 5%,大于 9.21 的概率仅有 1%。

六、F 分 布

设从一正态总体 $N(\mu,\sigma^2)$ 中随机抽取样本容量为 n_1 和 n_2 的两个独立样本,其样本方差为 s_1^2 和 s_2^2,则定义 s_1^2 和 s_2^2 的比值为 F:

$$F=\frac{s_1^2}{s_2^2} \tag{3.50}$$

此 F 值具有 s_1^2 的自由度 $df_1=n_1-1$ 和 s_2^2 的自由度 $df_2=n_2-1$。如果对一正态总体在特定的 df_1 和 df_2 下进行一系列随机独立抽样,则所有可能的 F 值就构成一个 F 分布(F-distribution)。F 分布的概率密度函数是由两个独立 χ^2 变量的概率密度所构成的联合概率密度函数(joint probability density function),其方程为

$$f(F)=\frac{\Gamma\left(\frac{df_1+df_2}{2}\right)}{\Gamma\left(\frac{df_1}{2}\right)\Gamma\left(\frac{df_2}{2}\right)}df_1^{\frac{df_1}{2}}df_2^{\frac{df_2}{2}}\frac{F^{\frac{df_1}{2}-1}}{(df_1F+df_2)^{\frac{df_1+df_2}{2}}} \tag{3.51}$$

式中,Γ 为 Γ 函数;df_1 和 df_2 分别为 s_1^2 和 s_2^2 的自由度。由式(3.51)可知,F 分布是随自由度 df_1 和 df_2 变化而变化的一组曲线。

F 分布的概率累积函数为

$$F(F)=\int_0^F f(F)\mathrm{d}F \tag{3.52}$$

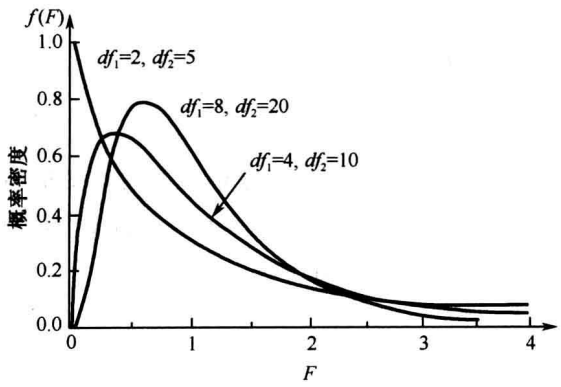

图 3-14　不同自由度 df_1 和 df_2 的 F 分布曲线

F 分布有以下特征:

(1) F 的取值区间为$[0,+\infty)$。

(2) F 分布的平均数 $\mu_F=1$(因为构成 F 值的 s_1^2 和 s_2^2 都是同一 σ^2 的无偏估计值)。

(3) F 分布曲线的形状仅取决于 df_1 和 df_2。在 $df_1=1$ 或 $df_1=2$ 时,F 分布曲线呈

严重倾斜的反向J形，当$df_1 \geqslant 3$时转为左偏曲线(图3-14)。

附表5列出的是F分布在不同df_1、df_2下，$P=0.05$和$P=0.01$时的F值(右尾)。例如，$df_1=4$，$df_2=10$时，可查得$P=0.05$的F值为3.48，$P=0.01$的F值为5.99，分别记作$F_{0.05(4,10)}=3.48$，$F_{0.01(4,10)}=5.99$，表示$P(F \geqslant 3.48)=0.05$，$P(F \geqslant 5.99)=0.01$，即所得F值大于3.48的概率仅有5%，大于5.99的概率仅有1%。

思考练习题

习题3.1　试解释必然事件、不可能事件和随机事件，并分别举例。

习题3.2　什么是互斥事件？什么是对立事件？什么是独立事件？试举例说明。

习题3.3　什么是频率？什么是概率？频率如何转化为概率？

习题3.4　什么是正态分布？什么是标准正态分布？正态分布曲线有什么特点？μ和σ对正态分布曲线有何影响？

习题3.5　已知u服从标准正态分布$N(0,1)$，试查$F(u)$值表计算下列概率值：

(1) $P(0.3 < u < 1.8)$；

(2) $P(-1 < u < 1)$；

(3) $P(-2 < u < 2)$；

(4) $P(-1.96 < u < 1.96)$；

(5) $P(-2.58 < u < 2.58)$。

习题3.6　设x服从正态分布$N(4,16)$，试通过标准化变换后查$F(u)$值表计算下列概率值：

(1) $P(-3 < x < 4)$；

(2) $P(x < 2.44)$；

(3) $P(x > -1.48)$；

(4) $P(x > -1)$。

习题3.7　水稻糯和非糯为一对等位基因控制，糯稻纯合体为ww，非糯稻纯合体为WW，两个纯合亲本杂交后，其F_1代为非糯稻杂合体Ww。

(1) 现以F_1代回交于糯稻亲本，在后代200株中预期有多少株为糯稻，多少株为非糯稻？试列出糯稻和非糯稻的概率；

(2) 当F_1代自交，F_2代性状分离，其中3/4为非糯稻，1/4为糯稻。假定F_2代播种了2000株，试问糯稻株和非糯稻株各有多少株？

习题3.8　大麦的矮生基因和抗锈基因连锁，以矮生基因与正常感锈基因杂交，在F_2代出现纯合正常抗锈植株的概率仅0.0036。试计算：

(1) 在F_2代种植200株时，纯合正常抗锈植株的各种可能株数的概率；

(2) 若希望有0.99的概率保证获得1株或1株以上纯合正常抗锈植株，则F_2代至少应种植多少株？

习题3.9　设对同性别、同月龄的小白鼠接种某种病菌，假定接种后经过一段时间生存的概率为0.425，若5只一组进行随机抽样，试问其中“四生一死”的概率有多大？

习题3.10　有一正态分布的平均数为16，方差为4，试计算：

(1) 落于10到20之间的数据的百分数；

(2) 小于12或大于20的数据的百分数。

习题3.11　查表计算：

(1) $df=5$时，$P(t<-2.571)=?$　$P(t>4.032)=?$

(2) $df=2$时，$P(\chi^2<0.05)=?$　$P(\chi^2>5.99)=?$　$P(0.05<\chi^2<7.38)=?$

(3) $df_1=3$，$df_2=10$时，$P(F>3.71)=?$　$P(F>6.55)=?$

第四章

统计推断

本章提要

统计推断是根据总体理论分布，从样本的统计数对总体参数作出的推断。统计推断包括假设检验和参数估计。假设检验是在总体理论分布和小概率原理基础上，通过提出假设、确定显著水平、计算统计数、作出推断等步骤来完成的在一定概率意义上的推断。假设检验会出现两类错误。常见的样本假设检验有平均数的检验、频率的检验、方差的检验等。根据条件不同应采用不同的检验方法，如 u 检验、t 检验、χ^2 检验、F 检验等。总体参数估计又分为区间估计和点估计，与假设检验比较，二者主要是表示结果的形式不同，其本质是一样的。

第三章讨论了从总体到样本的方向，即抽样分布问题。本章将讨论从样本到总体的方向，就是根据这些理论分布由一个样本或一系列样本所得的结果来推断总体的特征，即统计推断(statistical inference)问题。统计推断主要包括假设检验和参数估计两个方面。它们的任务是分析误差产生的原因、确定差异的性质、排除误差干扰，从而对总体的特征作出正确的判断。

第一节　假设检验的原理与方法

一、假设检验的概念

在生物学试验和研究中，当检验一种试验方法的效果、一个品种的优劣、一种药品的疗效等时，所得试验数据往往存在着一定差异，这种差异是由随机误差造成的，还是由试验处理所引起的？例如，在同一饲养条件下喂养甲、乙两个品系的肉鸡各 20 只，在 2 月龄时测得甲品系的平均体重 $\bar{x}_1=1.5\text{kg}$，乙品系的平均体重 $\bar{x}_2=1.4\text{kg}$，甲、乙两个品系相差 0.1kg。这个 0.1kg 的差值，究竟是由于甲、乙两个品系来自两个不同的总体，还是由于抽样时的随机误差所致？这个问题必须进行一番分析才能得出结论。因为试验结果中处理效应和随机误差往往混淆在一起，从表面上是不容易分开的，因此必须通过概率的计算，采用假设检验的方法，才能作出正确的推断。

假设检验(hypothesis test)又称为显著性检验(significance test),是根据总体的理论分布和小概率原理,对未知或不完全知道的总体提出两种彼此对立的假设,然后由样本的实际结果,经过一定的计算,作出在一定概率意义上应该接受的那种假设的推断。如果抽样结果使小概率事件发生,则拒绝假设;如果抽样结果没有使小概率事件发生,则接受假设。统计学中,一般认为等于或小于0.05或0.01的概率为小概率(little probability),而概率等于或小于0.05或0.01的事件则为小概率事件。通过假设检验,可以正确辨别处理效应和随机误差的效应,从而作出可靠的结论。

二、假设检验的步骤

在进行假设检验时,一般应包括以下4个步骤。

(一)提出假设

假设检验首先要对总体提出假设,一般应作两个彼此对立的假设,一个是无效假设(ineffective hypothesis)或零假设(null hypothesis),记作 H_0;另一个是备择假设(alternative hypothesis),记作 H_A。无效假设是直接检验的假设,是对总体提出的一个假想目标。所谓"无效"意指处理效应与总体参数之间没有真实的差异,试验结果中的差异乃误差所致,即处理"无效"。备择假设是与无效假设相反的一种假设,即认为试验结果中的差异是由于总体参数不同所引起的,即处理"有效"。因此,无效假设与备择假设是对立事件。在检验中,如果接受 H_0 则否定 H_A;否定 H_0 则接受 H_A。无效假设的形式是多种多样的,随研究内容不同而不同,但必须遵循两个原则:① 无效假设必须是有意义的,根据无效假设是否成立,可以对问题作出回答;② 根据无效假设可以算出因抽样误差而获得样本结果的概率。

以样本平均数的假设为例。

1. 对一个样本平均数的假设

假设一个样本平均数 $\bar{x}$ 来自于一具有平均数 μ 的总体,可提出:

无效假设 $H_0:\mu=\mu_0$;

备择假设 $H_A:\mu\neq\mu_0$。

例如,设矽肺病患者的血红蛋白含量为具平均数 $\mu_0=126(\text{mg/L})$,$\sigma^2=240(\text{mg/L})^2$ 的正态分布,即 $N(126,240)$。现用克矽平对6位矽肺病患者进行治疗,治疗后化验测得其平均血红蛋白含量 $\bar{x}=136(\text{mg/L})$。试问用克矽平治疗矽肺病是否能提高血红蛋白含量。

这是一个样本平均数的假设检验,是要检验治疗后的血红蛋白含量的总体平均数 μ 是否还是治疗前的126(mg/L),即 $\bar{x}-\mu_0=136-126=10(\text{mg/L})$ 这一差数是由克矽平治疗造成的,还是由抽样误差所致?这就需要首先提出无效假设 $H_0:\mu=\mu_0=126(\text{mg/L})$,同时给出对应的备择假设 $H_A:\mu\neq\mu_0$。因为在无效假设 $H_0:\mu=\mu_0$ 的条件下,就有一个平均数 $\mu_{\bar{x}}=\mu=\mu_0=126(\text{mg/L})$,$\sigma_{\bar{x}}^2=\dfrac{240}{6}=40(\text{mg/L})^2$ 的正态分布,即 $N(126,40)$,而样本 $\bar{x}=136(\text{mg/L})$ 则是此分布中的一个随机变量。

2. 对两个样本平均数相比较的假设

假设两个样本平均数 $\bar{x}_1$ 和 $\bar{x}_2$ 分别来自具有平均数 μ_1 和 μ_2 的两个总体，则提出：

无效假设 $H_0:\mu_1=\mu_2$；

备择假设 $H_A:\mu_1\neq\mu_2$。

例如，要检验两种制剂的疗效是否相同，两个水稻品种的株高是否一致，成年男女的肺活量是否一样，等等，都属于两个样本平均数相比较的假设。其无效假设认为两个样本所属各自总体的平均数是相等的，即这两个总体是同一个总体，两个样本平均数之间的差值 $\bar{x}_1-\bar{x}_2$ 是由随机误差所引起的；其备择假设则认为两个样本所属各自总体的平均数是不相同的，即这两个总体不是同一个总体，其分别抽样所得样本的平均数差值 $\bar{x}_1-\bar{x}_2$ 除随机误差之外，还包含真实的差异。

此外，样本频率、变异数及多个平均数的假设检验也应根据试验目的提出相应的无效假设和备择假设。

提出上述无效假设的目的在于：可从假设的总体中推论其平均数的随机抽样分布，从而可以算出某一个样本平均数指定值出现的概率，这样就可以根据样本与总体的关系，作为假设检验的理论依据。

(二) 确定显著水平

在提出无效假设和备择假设后，要确定一个否定 H_0 的概率标准，这个概率标准称为显著水平(significance level)或概率水平(probability level)，记作 α。显著水平是人为规定的小概率界限，统计学中常取 $\alpha=0.05$ 和 $\alpha=0.01$ 两个显著水平。

(三) 计算统计数与相应概率

在假设 H_0 正确的前提下，根据样本平均数的抽样分布计算出由抽样误差造成的概率。对于上面一个样本平均数的例子，在 $H_0:\mu=\mu_0$ 的前提下，根据式(3.35)可求得

$$u=\frac{\bar{x}-\mu}{\sigma_{\bar{x}}}=\frac{136-126}{\sqrt{40}}=1.58$$

查附表1，$P(|u|>1.58)=2\times0.05705=0.1141$，即在 $N(126,240)$ 的总体中，以 $n=6$ 进行随机抽样，所得平均数 $\bar{x}=136$ 与126相差为10以上的概率为0.1141。这里需要指出的是，假设检验所计算的并不是实得差异本身的概率，而是超过实得差异的概率。概率的大小是推断 H_0 是否正确的依据。此例中，在 H_0 假设下，由于 $\bar{x}$ 有可能大于 μ，也有可能小于 μ，因此需要考虑差异的正和负两个方面，所以计算的是双尾概率。

(四) 推断是否接受假设

根据小概率原理作出是否接受 H_0 的判断。小概率原理(little probability principle)指出：如果假设一些条件，并在假设的条件下能够准确地算出事件 A 出现的概率 α 为很小，则在假设条件下的 n 次独立重复试验中，事件 A 将按预定的概率发生，而在一次试验中则几乎不可能发生。简言之，小概率事件在一次抽样试验中几乎是不可能发生

的。如果计算的概率大于 0.05 或 0.01，则认为不是小概率事件，H_0 的假设可能是正确的，应该接受，同时否定 H_A；反之，如果所计算的概率等于或小于 0.05 或 0.01，则否定 H_0，接受 H_A。通常把概率等于或小于 0.05 称为差异(difference)显著标准(significance standard)，或差异显著水平(significance level)；概率等于或小于 0.01 称为差异极显著标准(highly significance standard)，或差异极显著水平(highly significance level)。一般差异达到显著水平，则在资料的右上方标以“*”；差异达到极显著水平，则在资料右上方标以“**”。

上例中，所计算的概率为 0.1141，大于 0.05 的显著水平，应接受 H_0，可以推断治疗前后的血红蛋白含量未发现有显著差异，其差值 10(mg/L) 应归于误差所致。

在实际检验时，可将上述计算简化。由第三章知 $P(|u|>1.96)=0.05$，$P(|u|>2.58)=0.01$。因此，在用 u 分布进行检验时，如果算得 $|u|>1.96$，就是在 $\alpha=0.05$ 的水平上达到显著；如果 $|u|>2.58$，就是在 $\alpha=0.01$ 的水平上达到显著，即达到极显著水平，无需再计算 u 值的概率。因此，在 H_0 成立的条件下，由计算得到的概率与显著水平的比较就转变为检验统计数与某一显著水平下的分位数(附表 2)的比较了。本例中 $u=1.58<1.96$，所以差异未达到显著水平。

综上所述，假设检验的步骤可概括为：

(1) 对样本所属总体提出无效假设 H_0 和备择假设 H_A。

(2) 确定检验的显著水平 α。

(3) 在 H_0 正确的前提下，计算抽样分布的统计数或相应的概率值。

(4) 根据小概率原理，进行差异是否显著的推断，并得出结论。

三、双尾检验与单尾检验

进行假设检验时，需要提出无效假设和备择假设。提出的这种假设，其总体平均数 μ 可能大于 μ_0，也可能小于 μ_0。在样本平均数的抽样分布中，对于 $\alpha=0.05$ 时，落在区间 $(\mu-1.96\sigma_{\bar{x}},\mu+1.96\sigma_{\bar{x}})$ 的 $\bar{x}$ 有 95%，落在这一区间之外(即 $\bar{x}\leqslant\mu-1.96\sigma_{\bar{x}}$ 和 $\bar{x}\geqslant\mu+1.96\sigma_{\bar{x}}$) 的 $\bar{x}$ 只有 5%。同理，对于 $\alpha=0.01$ 时，落在区间 $(\mu-2.58\sigma_{\bar{x}},\mu+2.58\sigma_{\bar{x}})$ 的 $\bar{x}$ 有 99%，落在这一区间之外(即 $\bar{x}\leqslant\mu-2.58\sigma_{\bar{x}}$ 和 $\bar{x}\geqslant\mu+2.58\sigma_{\bar{x}}$) 的 $\bar{x}$ 只有 1%。一般在进行假设检验时，对一定的 α，落在区间 $(\mu-u_\alpha\sigma_{\bar{x}},\mu+u_\alpha\sigma_{\bar{x}})$ 的 $\bar{x}$ 有 $1-\alpha$，落在这一区间之外(即 $\bar{x}\leqslant\mu-u_\alpha\sigma_{\bar{x}}$ 和 $\bar{x}\geqslant\mu+u_\alpha\sigma_{\bar{x}}$) 的 $\bar{x}$ 只有 α，前者相当于接受 H_0 的区域，简称为接受区(acceptance region)；后者相当于否定 H_0 的区域，简称为否定区(rejection region)(图 4-1)。即当 $\mu-u_\alpha\sigma_{\bar{x}}\leqslant\bar{x}\leqslant\mu+u_\alpha\sigma_{\bar{x}}$ 为 H_0 的接受区，而 $\bar{x}\leqslant\mu-u_\alpha\sigma_{\bar{x}}$ 和 $\bar{x}\geqslant\mu+u_\alpha\sigma_{\bar{x}}$ 为 H_0 的两个否定区，其中 $\bar{x}\leqslant\mu-u_\alpha\sigma_{\bar{x}}$ 为左尾否定区(left-tailed rejection region)，$\bar{x}\geqslant\mu+u_\alpha\sigma_{\bar{x}}$ 为右尾否定区(right-tailed rejection region)。接受区和否定区的两个临界值(critical value)则写成 $\mu\pm u_\alpha\sigma_{\bar{x}}$。

上述假设检验的两个否定区分别位于分布的两尾，这种具有两个否定区的检验称为双尾检验(two-tailed test)。当假设检验的 $H_0:\mu=\mu_0$ 时，则 $H_A:\mu\neq\mu_0$，这时备择假设就有两种可能，或 $\mu>\mu_0$，或 $\mu<\mu_0$，也就是说在 $\mu\neq\mu_0$ 的情况下，样本平均数 $\bar{x}$ 有可能

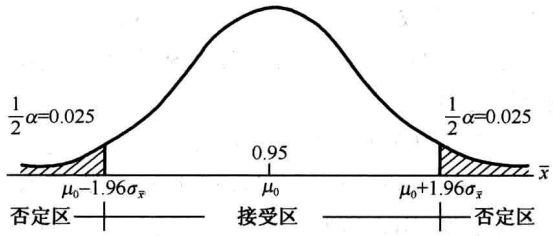

图 4-1　$\alpha = 0.05$ 时假设检验的接受区和否定区

落入左尾否定区，也有可能落入右尾否定区，这两种情况都属于 $\mu \neq \mu_0$ 的情况。例如，检验某种新药与旧药的治病疗效是否有差别，就是说新药疗效比旧药好还是旧药疗效比新药好两种可能性都存在，相应的假设检验就应该用双尾检验。在生物学研究中，双尾检验的应用是非常广泛的。

但在某些情况下，双尾检验不一定符合实际。例如，根据实际工作情况，我们已经知道新药疗效不可能不如旧药，于是提出其无效假设 $H_0:\mu \leqslant \mu_0$，备择假设 $H_A:\mu > \mu_0$，这时仅有一种可能性，其否定区也只有一个，相应的检验也只能考虑一侧的概率。像这种具有左尾或右尾一个否定区的检验称为单尾检验(one-tailed test)。单尾检验的步骤与双尾检验的相同，查 u 分布表或 t 分布表时，需将双尾概率乘以 2，再进行查表。例如，进行 $\alpha = 0.05$ 的单尾检验时，对 $H_0:\mu \geqslant \mu_0$，需进行左尾检验，其否定区为 $\bar{x} \leqslant \mu - 1.64\sigma_{\bar{x}}$；对 $H_0:\mu \leqslant \mu_0$，需进行右尾检验，其否定区为 $\bar{x} \geqslant \mu + 1.64\sigma_{\bar{x}}$。同理，进行 $\alpha = 0.01$ 的单尾检验时，对 $H_0:\mu \geqslant \mu_0$，其否定区为 $\bar{x} \leqslant \mu - 2.33\sigma_{\bar{x}}$；对 $H_0:\mu \leqslant \mu_0$，其否定区为 $\bar{x} \geqslant \mu + 2.33\sigma_{\bar{x}}$。

在实际应用中，根据检验要求和专业知识的判断，尽量作单尾检验，以提高假设检验的灵敏度。

四、假设检验中的两类错误

假设检验是根据一定概率显著水平对总体特征进行的推断。在一定 α 下，否定了 H_0，并不等于已证明 H_0 不真实；接受了 H_0，也不等于已证明 H_0 是真实的。如果 H_0 是真实的，假设检验却否定了它，就犯了一个否定真实假设的错误，这类错误称为第一类错误(type Ⅰ error)，或称为 α 错误(α error)，也称为弃真错误(error of abandoning trueness)。例如，对样本平均数的抽样分布，当取概率显著水平 $\alpha = 0.05$ 时，$\bar{x}$ 落在区间 $(\mu - 1.96\sigma_{\bar{x}}, \mu + 1.96\sigma_{\bar{x}})$ 的概率为 0.95，$\bar{x}$ 落在区间 $(\mu - 1.96\sigma_{\bar{x}}, \mu + 1.96\sigma_{\bar{x}})$ 之外的概率为 0.05，当 $\bar{x}$ 一旦落在区间 $(\mu - 1.96\sigma_{\bar{x}}, \mu + 1.96\sigma_{\bar{x}})$ 之外，假设检验时就会否定 H_0，接受 H_A，这样就会导致错误的结论。不过，犯这类错误的概率很小，只有 0.05。如果取概率显著水平为 $\alpha = 0.01$，则 $\bar{x}$ 落在区间 $(\mu - 2.58\sigma_{\bar{x}}, \mu + 2.58\sigma_{\bar{x}})$ 的概率为 0.99，落在区间 $(\mu - 2.58\sigma_{\bar{x}}, \mu + 2.58\sigma_{\bar{x}})$ 之外的概率只有 0.01，即犯 α 错误的可能性更小，只有 0.01。所以，犯第一类错误的概率等于相应的显著水平 α。

如果 H_0 不是真实的，假设检验时却接受了 H_0，否定了 H_A，这样就犯了接受不真实假设的错误，这类错误称为第二类错误(type Ⅱ error)，或称为 β 错误(β error)，也称为纳

伪错误(error of accepting mistake)。

第一类错误和第二类错误既有区别又有联系。二者的区别是,第一类错误只有在否定 H_0 时才会发生,而第二类错误只有在接受 H_0 时才会发生,二者不会同时发生。二者的联系是,在样本容量相同的情况下,犯第一类错误的概率减少,第二类错误就会增加;反之,犯第二类错误的概率减少,第一类错误就会增加(图4-2)。例如,将概率显著水平 α 从0.05提高到0.01,就更容易接受 H_0,因此犯第一类错误的概率就减少,但相应地增加了犯第二类错误的概率。所以显著水平如果定得太高,虽然在否定 H_0 时减少了犯第一类错误的概率,但在接受 H_0 时却可能增大犯第二类错误的概率。

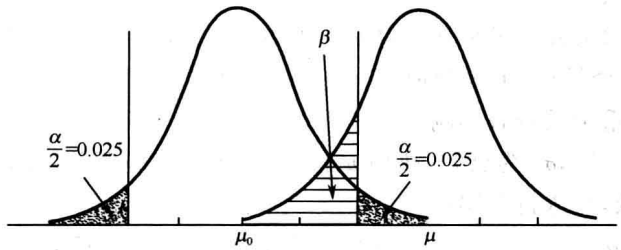

图4-2　假设检验中两类错误的关系

以上说明,在假设检验时,一个假设的接受或否定,不可能保证百分之百的正确,可能会出现一些错误的推断。

第二节　样本平均数的假设检验

一、一个样本平均数的假设检验

一个样本平均数的假设检验适用于判断一个样本平均数 $\bar{x}$ 所属总体平均数 μ 与已知总体平均数 μ_0 是否有真实差异的检验。

(一) 总体方差 σ^2 已知时的检验

当总体方差 σ^2 已知,无论样本是大样本($n \geqslant 30$)还是小样本($n < 30$),样本平均数的分布均服从于正态分布,标准化后则服从于标准正态分布,即 u 分布。因此,用 u 检验(u-test)法进行假设检验。

【例4.1】 某渔场按常规方法所育鲢鱼苗1月龄的平均体长为7.25cm,标准差为1.58cm。为提高鱼苗质量,现采用一个新方法进行育苗,1月龄时随机抽取100尾进行测量,测得其平均体长为7.65cm。试问新育苗方法与常规育苗方法所育鲢鱼苗1月龄体长有无显著差异?

这里总体 $\sigma = 1.58$cm,σ^2 为已知,故采用 u 检验;又因新育苗方法的鱼苗体长可能高于常规方法,也可能低于常规方法,故进行双尾检验。

(1) 假设 $H_0: \mu = \mu_0 = 7.25$cm,即新育苗方法与常规育苗方法所育鱼苗1月龄体长相同;$H_A: \mu \neq \mu_0$。

(2) 选取显著水平 $\alpha=0.05$。

(3) 检验计算：

$$\sigma_{\bar{x}}=\frac{\sigma}{\sqrt{n}}=\frac{1.58}{\sqrt{100}}=0.158$$

$$u=\frac{\bar{x}-\mu}{\sigma_{\bar{x}}}=\frac{7.65-7.25}{0.158}=2.532$$

(4) 推断：u 分布中，当 $\alpha=0.05$ 时，$u_{0.05}=1.96$。实得 $|u|>1.96$，$P<0.05$，故在 0.05 显著水平上否定 H_0，接受 H_A。又因 $\bar{x}>\mu_0$，故认为新育苗方法鱼苗 1 月龄体长显著大于常规育苗方法。

【例 4.2】 已知某种玉米平均穗重 $\mu_0=300$g，标准差 $\sigma=9.5$g。喷施某种植物生长调节剂后，随机抽取 9 个果穗，重量分别为 308，305，311，298，315，300，321，294，320(g)。问这种调节剂对果穗重量是否有影响？

由题可知，$\sigma=9.5$g，σ^2 为已知，故用 u 检验；又由于喷施调节剂后玉米果穗重量有可能增加，也可能降低，故进行双尾检验。

(1) 假设 H_0：$\mu=\mu_0=300$g，即喷施调节剂后玉米果穗重量无显著变化；H_A：$\mu\neq\mu_0$。

(2) 选取显著水平 $\alpha=0.05$。

(3) 检验计算：

$$\bar{x}=\frac{1}{n}\sum x=\frac{1}{9}\times(308+305+\cdots+320)=308$$

$$\sigma_{\bar{x}}=\frac{\sigma}{\sqrt{n}}=\frac{9.5}{\sqrt{9}}=3.167$$

$$u=\frac{\bar{x}-\mu}{\sigma_{\bar{x}}}=\frac{308-300}{3.167}=2.526$$

(4) 推断：当 $\alpha=0.05$ 时，$u_{0.05}=1.96$。实得 $|u|>1.96$，$P<0.05$，故在 0.05 显著水平上否定 H_0，接受 H_A。又由于 $\bar{x}>\mu_0$，故认为喷施调节剂能够显著增加玉米果穗的重量。

(二) 总体方差 σ^2 未知时的检验

1. 总体方差 σ^2 未知，但 $n\geqslant 30$，用 u 检验

当总体方差 σ^2 未知时，只要样本为样本容量 $n\geqslant 30$，根据中心极限定理，样本平均数的分布均近似服从于正态分布，因此，可用样本方差 s^2 来估计总体方差 σ^2，仍然用 u 检验法。

【例 4.3】 生产某种纺织品，要求棉花纤维长度平均为 30mm 以上。现有一棉花品种，以 $n=400$ 进行抽查，测得其纤维平均长度为 30.2mm，标准差为 2.5mm。问该棉花品种的纤维长度是否符合纺织品的生产？

由题可知，$\mu_0=30$mm，$\bar{x}=30.2$mm，$s=2.5$mm，而 σ^2 未知，但由于 $n=400$，属于大样本，故可用 s^2 来估计 σ^2 进行 u 检验；又由于棉花纤维只有大于 30mm 才符合纺织品生产

的要求，故用单尾检验。

（1）假设 H_0：$\mu \leqslant 30\text{mm}$，即该棉花品种纤维长度达不到纺织品生产的要求；$H_A$：$\mu > 30\text{mm}$。

（2）确定显著水平 $\alpha = 0.05$。

（3）检验计算：

$$s_{\bar{x}} = \frac{s}{\sqrt{n}} = \frac{2.5}{\sqrt{400}} = 0.125$$

$$u = \frac{\bar{x} - \mu}{s_{\bar{x}}} = \frac{30.2 - 30}{0.125} = 1.600$$

（4）推断：当 $\alpha = 0.05$ 时，单尾检验临界值 $u_{0.05} = 1.64$。实得 $|u| < 1.64$，$P > 0.05$，故接受 H_0，否定 H_A，认为该棉花品种纤维长度不符合纺织品生产的要求。

2. 总体方差 σ^2 未知，且 $n < 30$，用 t 检验

当样本容量 $n < 30$ 且总体方差 σ^2 未知时，就无法使用 u 检验法对样本平均数进行假设检验。这时，要检验样本平均数 $\bar{x}$ 与指定总体平均数 μ_0 的差异显著性，就必须使用 t 检验（t-test）法。事实上，在生物学研究中，由于试验条件和研究对象的限制，有许多研究的样本容量都很难达到 30 以上，因此，t 检验法在生物学研究中具有重要的意义。因为小样本的 s^2 和 σ^2 相差较大，故 $\frac{\bar{x} - \mu}{s_{\bar{x}}}$ 遵循自由度 $df = n - 1$ 的 t 分布。

【例 4.4】 某鱼塘水中的含氧量多年平均为 4.5mg/L。现在该鱼塘设 10 个点采集水样，测定水中含氧量分别为 4.33，4.62，3.89，4.14，4.78，4.64，4.52，4.55，4.48，4.26（mg/L）。试检验该次抽样测定的水中含氧量与多年平均值有无显著差别。

此题 σ^2 未知，且 $n = 10$，为小样本，故用 t 检验；又因该次测定的水中含氧量可能高于也可能低于多年平均值，故用双尾检验。

（1）假设 H_0：$\mu = \mu_0 = 4.5\text{mg/L}$，即该次测定的水中含氧量与多年平均值没有显著差别；H_A：$\mu \neq \mu_0$。

（2）选取显著水平 $\alpha = 0.05$。

（3）检验计算：

$$\bar{x} = \frac{1}{n}\sum x = \frac{1}{10} \times (4.33 + 4.62 + \cdots + 4.26) = \frac{44.21}{10} = 4.421$$

$$s = \sqrt{\frac{\sum x^2 - \frac{\left(\sum x\right)^2}{n}}{n-1}} = \sqrt{\frac{4.33^2 + 4.62^2 + \cdots + 4.26^2 - \frac{44.21^2}{10}}{10-1}} = 0.267$$

$$s_{\bar{x}} = \frac{s}{\sqrt{n}} = \frac{0.267}{\sqrt{10}} = 0.084$$

$$t = \frac{\bar{x} - \mu}{s_{\bar{x}}} = \frac{4.421 - 4.5}{0.084} = -0.940$$

（4）推断：查附表 3，当 $df = n - 1 = 9$ 时，$t_{0.05} = 2.262$。实得 $|t| < t_{0.05}$，$P > 0.05$，故接受 H_0，否定 H_A，认为该次抽样测定的鱼塘水中含氧量与多年平均含氧量没有显著差

别，$\bar{x}$ 与 μ 相差 0.079mg/L 属于随机误差所致。

二、两个样本平均数的假设检验

两个样本平均数比较的 u 检验是检验两个样本平均数 $\bar{x}_1$ 和 $\bar{x}_2$ 所属的总体平均数 μ_1 和 μ_2 是否来自同一个总体。

(一) 总体方差 σ_1^2、σ_2^2 已知时的检验

在两个总体方差 σ_1^2 和 σ_2^2 已知时，不论其样本容量是否大于 30，样本平均数差数的分布都服从于正态分布，故用 u 检验法。

在进行两个样本平均数的比较时，需要计算样本平均数差数的标准误 $\sigma_{\bar{x}_1-\bar{x}_2}$ 和 u 值。当两样本方差 σ_1^2 和 σ_2^2 已知，两个样本平均数差数的标准误为

$$\sigma_{\bar{x}_1-\bar{x}_2}=\sqrt{\frac{\sigma_1^2}{n_1}+\frac{\sigma_2^2}{n_2}} \tag{4.1}$$

当 $\sigma_1^2=\sigma_2^2=\sigma^2$ 时，式(4.1) 则为

$$\sigma_{\bar{x}_1-\bar{x}_2}=\sigma\sqrt{\frac{1}{n_1}+\frac{1}{n_2}} \tag{4.2}$$

当 $n_1=n_2=n$ 时，式(4.1) 则为

$$\sigma_{\bar{x}_1-\bar{x}_2}=\sqrt{\frac{\sigma_1^2+\sigma_2^2}{n}} \tag{4.3}$$

当 $\sigma_1^2=\sigma_2^2=\sigma^2$，且 $n_1=n_2=n$ 时，式(4.1) 则为

$$\sigma_{\bar{x}_1-\bar{x}_2}=\sigma\sqrt{\frac{2}{n}} \tag{4.4}$$

u 值的计算公式为

$$u=\frac{(\bar{x}_1-\bar{x}_2)-(\mu_1-\mu_2)}{\sigma_{\bar{x}_1-\bar{x}_2}} \tag{4.5}$$

在假设 $H_0:\mu_1=\mu_2=\mu$ 的条件下，u 值为

$$u=\frac{\bar{x}_1-\bar{x}_2}{\sigma_{\bar{x}_1-\bar{x}_2}} \tag{4.6}$$

1. 总体方差 σ_1^2、σ_2^2 已知，且 $n_1\geqslant 30$ 和 $n_2\geqslant 30$，用 u 检验

【例 4.5】 根据多年的资料，某杂交黑麦从播种到开花的天数的标准差为 6.9d，现在相同试验条件下采取两种方法取样调查，A 法调查 400 株，得出从播种到开花的平均天数为 69.5d；B 法调查 200 株，得出从播种到开花的平均天数为 70.3d。试比较两种调查方法所得黑麦从播种到开花的天数有无显著差别。

根据题意，总体方差已知，$\sigma_1^2=\sigma_2^2=\sigma^2=(6.9\text{d})^2$，$n_1=400$，$n_2=200$，故用 u 检验；又因事先不知 A、B 两法所得从播种到开花的天数是否相同，需用双尾检验。

(1) 假设 $H_0:\mu_1=\mu_2$，即 A、B 两法所得从播种到开花的天数相同；$H_A:\mu_1\neq\mu_2$。

(2) 取显著水平 $\alpha=0.05$。

(3) 检验计算：

$$\sigma_{\bar{x}_1-\bar{x}_2}=\sigma\sqrt{\frac{1}{n_1}+\frac{1}{n_2}}=6.9\times\sqrt{\frac{1}{400}+\frac{1}{200}}=0.598$$

$$u=\frac{\bar{x}_1-\bar{x}_2}{\sigma_{\bar{x}_1-\bar{x}_2}}=\frac{69.5-70.3}{0.598}=-1.338$$

(4) 推断：由于实得 $|u|<u_{0.05}=1.96$，$P>0.05$，故在0.05显著水平上接受 H_0，否定 H_A，即 A、B 两种调查方法所得黑麦从播种到开花的天数没有显著差别。

2. 总体方差 σ_1^2、σ_2^2 已知，当 n_1 或(和)n_2 小于30时，用 u 检验

【例 4.6】 现用甲、乙两种发酵法生产青霉素，其产品收率的方差分别为 $\sigma_1^2=0.46(g/L)^2$，$\sigma_2^2=0.37(g/L)^2$。现甲方法测得25个数据，$\bar{x}_1=3.71g/L$；乙方法测得30个数据，$\bar{x}_2=3.46g/L$。问甲、乙两种方法的收率是否相同？

本题中，由于总体方差 σ_1^2 和 σ_2^2 已知，故采用 u 检验。因预先不知甲、乙两种方法的青霉素收率孰高孰低，应进行双尾检验。

(1) 假设 $H_0:\mu_1=\mu_2$，即甲、乙两种方法的青霉素收率相同；$H_A:\mu_1\neq\mu_2$。

(2) 确定显著水平 $\alpha=0.05$。

(3) 检验计算：

$$\sigma_{\bar{x}_1-\bar{x}_2}=\sqrt{\frac{\sigma_1^2}{n_1}+\frac{\sigma_2^2}{n_2}}=\sqrt{\frac{0.46}{25}+\frac{0.37}{30}}=0.175$$

$$u=\frac{\bar{x}_1-\bar{x}_2}{\sigma_{\bar{x}_1-\bar{x}_2}}=\frac{3.71-3.46}{0.175}=1.429$$

(4) 推断：查正态分布表得 $|u|<u_{0.05}=1.96$，$P>0.05$，故在0.05显著水平上接受 H_0，否定 H_A，即甲、乙两种方法的青霉素收率相同，没有显著差异。

(二) 总体方差 σ_1^2、σ_2^2 未知时的检验

1. 总体方差 σ_1^2、σ_2^2 未知，$n_1\geqslant30$ 和 $n_2\geqslant30$，用 u 检验

当两总体方差 σ_1^2 和 σ_2^2 未知，在 n_1、n_2 都是大样本的条件下，根据中心极限定理，其平均数差数的分布近似服从正态分布，因此仍可用 u 检验。这时，需用样本平均数差数的标准误 $s_{\bar{x}_1-\bar{x}_2}$ 估计 $\sigma_{\bar{x}_1-\bar{x}_2}$，其计算公式为

$$s_{\bar{x}_1-\bar{x}_2}=\sqrt{\frac{s_1^2}{n_1}+\frac{s_2^2}{n_2}} \tag{4.7}$$

u 值的计算公式为

$$u=\frac{(\bar{x}_1-\bar{x}_2)-(\mu_1-\mu_2)}{s_{\bar{x}_1-\bar{x}_2}} \tag{4.8}$$

在假设 $H_0:\mu_1=\mu_2=\mu$ 的情况下，u 值计算公式为

$$u=\frac{\bar{x}_1-\bar{x}_2}{s_{\bar{x}_1-\bar{x}_2}} \tag{4.9}$$

【例 4.7】 为了比较‘42-67×RRIM603’和‘42-67×PB86’两个橡胶品种的割胶产

量,两个橡胶品种分别随机抽样 55 株和 107 株进行割胶,割胶平均产量分别为 95.4mL/株和 77.6mL/株,割胶产量的方差分别为 936.36(mL/株)^2 和 800.89(mL/株)^2。试检验两个橡胶品种在割胶产量上是否有显著差别。

由题意,$\bar{x}_1=95.4$mL/株,$\bar{x}_2=77.6$mL/株,$s_1^2=936.36$(mL/株)^2,$s_2^2=800.89$(mL/株)^2,$n_1=55$,$n_2=107$,总体方差未知,但为大样本,可用 u 检验法。又因事先不知道两个橡胶品种割胶产量孰高孰低,故用双尾检验。

(1) 假设 $H_0:\mu_1=\mu_2$,即两个橡胶品种的割胶产量没有显著差别;$H_A:\mu_1\neq\mu_2$。

(2) 选取显著水平 $\alpha=0.01$。

(3) 检验计算:

$$s_{\bar{x}_1-\bar{x}_2}=\sqrt{\frac{s_1^2}{n_1}+\frac{s_2^2}{n_2}}=\sqrt{\frac{936.36}{55}+\frac{800.89}{107}}=4.951$$

$$u=\frac{\bar{x}_1-\bar{x}_2}{s_{\bar{x}_1-\bar{x}_2}}=\frac{95.4-77.6}{4.951}=3.595$$

(4) 推断:现实得 $|u|>u_{0.01}=2.58$,$P<0.01$,故否定 H_0,接受 H_A,即两个橡胶品种的割胶产量存在极显著的差别。由于 $\bar{x}_1>\bar{x}_2$,所以可以得出'42-67×RRIM603'的割胶产量极显著高于'42-67×PB86'的结论。

2. 总体方差 σ_1^2、σ_2^2 未知,n_1 或(和)n_2 小于 30 时,用 t 检验

当两个总体方差 σ_1^2 和 σ_2^2 未知,而 n_1 或(和)n_2 小于 30,其平均数差数不再服从于正态分布,而是服从 t 分布,因此用 t 检验。

t 值的计算公式为

$$t=\frac{(\bar{x}_1-\bar{x}_2)-(\mu_1-\mu_2)}{s_{\bar{x}_1-\bar{x}_2}} \tag{4.10}$$

在假设 $H_0:\mu_1=\mu_2=\mu$ 的情况下,t 值计算公式为

$$t=\frac{\bar{x}_1-\bar{x}_2}{s_{\bar{x}_1-\bar{x}_2}} \tag{4.11}$$

在两个样本平均数的比较中,根据试验设计不同,又分为两类情况,即成组数据平均数比较的假设检验和成对数据平均数比较的假设检验,二者都是检验两个样本平均数 $\bar{x}_1$ 和 $\bar{x}_2$ 所属总体平均数 μ_1 和 μ_2 是否相等的检验方法。这两类检验经常被用于比较生物学研究中不同处理效应的差异显著性。

1) 成组数据平均数比较的 t 检验

成组数据(pooled data)是两个样本的各个变量从各自总体中抽取,两个样本之间的变量没有任何关联,即两个抽样样本彼此独立。这样,不论两个样本容量是否相同,所得数据皆为成组数据。两组数据以组平均数进行相互比较,来检验其差异的显著性。当总体方差 σ_1^2 和 σ_2^2 已知,或总体方差 σ_1^2 和 σ_2^2 未知,但两个样本均为大样本时,采用 u 检验法检验两组平均数的差异显著性,这已在本节前面作了介绍。这里介绍当总体方差 σ_1^2 和 σ_2^2 未知,且两样本为小样本($n_1<30$,$n_2<30$)时,进行两组平均数差异显著性检验的 t 检验。

A. 两个总体方差 σ_1^2 和 σ_2^2 未知，但通过方差的同质性检验 $\sigma_1^2=\sigma_2^2=\sigma^2$ 时的检验。首先，用样本方差 s_1^2 和 s_2^2 进行加权求出平均数差数的方差 s_e^2，作为对 σ^2 的估计，计算公式为

$$s_e^2=\frac{s_1^2(n_1-1)+s_2^2(n_2-1)}{(n_1-1)+(n_2-1)} \tag{4.12}$$

其次，得出两样本平均数差数的标准误 $s_{\bar{x}_1-\bar{x}_2}$：

$$s_{\bar{x}_1-\bar{x}_2}=\sqrt{\frac{s_e^2}{n_1}+\frac{s_e^2}{n_2}} \tag{4.13}$$

当 $n_1=n_2=n$ 时，式(4.13)可变为

$$s_{\bar{x}_1-\bar{x}_2}=\sqrt{\frac{2s_e^2}{n}} \tag{4.14}$$

此时，t 值具有自由度 $df=(n_1-1)+(n_2-1)=n_1+n_2-2$。

【例 4.8】 用高蛋白和低蛋白两种饲料饲养 1 月龄大白鼠，在 3 个月时，测定两组大白鼠的增重量(g)，两组的数据分别为

高蛋白组：134，146，106，119，124，161，107，83，113，129，97，123；

低蛋白组：70，118，101，85，107，132，94。

试问两种饲料饲养的大白鼠增重量是否有差别？

本题 σ_1^2 和 σ_2^2 未知，经 F 检验 $\sigma_1^2=\sigma_2^2$，且为小样本，用 t 检验；又因事先不知两种饲料饲养的大白鼠增重量孰高孰低，故用双尾检验。

(1) 假设 $H_0:\mu_1=\mu_2$，即两种饲料饲养的大白鼠增重量没有差别；$H_A:\mu_1\neq\mu_2$。

(2) 取显著水平 $\alpha=0.05$。

(3) 检验计算：

$$\bar{x}_1=120.17,s_1^2=451.97,n_1=12$$

$$\bar{x}_2=101.00,s_2^2=425.33,n_2=7$$

$$s_e^2=\frac{s_1^2(n_1-1)+s_2^2(n_2-1)}{(n_1-1)+(n_2-1)}=\frac{451.97\times(12-1)+425.33\times(7-1)}{(12-1)+(7-1)}=442.568$$

$$s_{\bar{x}_1-\bar{x}_2}=\sqrt{\frac{s_e^2}{n_1}+\frac{s_e^2}{n_2}}=\sqrt{\frac{442.568}{12}+\frac{442.568}{7}}=10.005$$

$$t=\frac{\bar{x}_1-\bar{x}_2}{s_{\bar{x}_1-\bar{x}_2}}=\frac{120.17-101.00}{10.005}=1.916$$

(4) 推断：查附表 3，$df=12+7-2=17$，$t_{0.05}=2.110$。现实得 $|t|<t_{0.05}$，$P>0.05$，故接受 H_0，认为两种饲料饲养大白鼠的增重量没有显著差别。

B. 两个总体方差 σ_1^2 和 σ_2^2 未知，且 $\sigma_1^2\neq\sigma_2^2$(由 F 检验得知)，但 $n_1=n_2=n$ 时的检验。这种情况仍可用 t 检验法，其计算也与假设两个总体方差 $\sigma_1^2=\sigma_2^2$ 的情况一样，只是在查 t 值表时，所用自由度 $df=n-1$，而不是 $2(n-1)$。

【例 4.9】 两个小麦品种千粒重(g)的调查结果如下所示。

品种甲：50，47，42，43，39，51，43，38，44，37；

品种乙：36，38，37，38，36，39，37，35，33，37。

试检验两个品种的千粒重有无显著差异。

此题 $n_1=n_2=10$，经 F 检验，得知两个品种千粒重的方差有显著的不同，即 $\sigma_1^2 \neq \sigma_2^2$。又因事先不知道甲、乙两个品种千粒重孰高孰低，故使用双尾检验。

(1) 假设 $H_0:\mu_1=\mu_2$，两个品种千粒重没有显著差异；$H_A:\mu_1 \neq \mu_2$。

(2) 取显著水平 $\alpha=0.01$。

(3) 检验计算：

$$\bar{x}_1=43.4, s_1^2=22.933$$

$$\bar{x}_2=36.6, s_2^2=2.933$$

$$s_e^2=\frac{s_1^2(n_1-1)+s_2^2(n_2-1)}{(n_1-1)+(n_2-1)}=\frac{22.933\times(10-1)+2.933\times(10-1)}{(10-1)+(10-1)}=12.933$$

$$s_{\bar{x}_1-\bar{x}_2}=\sqrt{\frac{s_e^2}{n_1}+\frac{s_e^2}{n_2}}=\sqrt{\frac{2\times 12.933}{10}}=1.608$$

$$t=\frac{\bar{x}_1-\bar{x}_2}{s_{\bar{x}_1-\bar{x}_2}}=\frac{43.4-36.6}{1.608}=4.229$$

(4) 推断：查附表 3，$df=10-1=9$，$t_{0.01}=3.250$。现实得 $|t|>t_{0.01}$，$P<0.01$，故否定 H_0，接受 H_A，可以认为两个品种千粒重有极显著差异。因 $\bar{x}_1>\bar{x}_2$，故品种甲的千粒重极显著高于品种乙。

C. 两总体方差 σ_1^2 和 σ_2^2 未知，且 $\sigma_1^2 \neq \sigma_2^2$，$n_1 \neq n_2$ 时的检验。这种情况所构成的统计数 $\dfrac{\bar{x}_1-\bar{x}_2}{s_{\bar{x}_1-\bar{x}_2}}$ 不再服从相应的 t 分布，因而只能进行近似的 t 检验。由于 $\sigma_1^2 \neq \sigma_2^2$，所以计算两个样本平均数差数的标准误时不能使用加权方差，需用两个样本方差 s_1^2 和 s_2^2 分别估计总体方差 σ_1^2 和 σ_2^2，即

$$s_{\bar{x}_1-\bar{x}_2}=\sqrt{\frac{s_1^2}{n_1}+\frac{s_2^2}{n_2}} \tag{4.15}$$

作 t 检验时，需先计算 R 和 df'：

$$R=\frac{s_{\bar{x}_1}^2}{s_{\bar{x}_1}^2+s_{\bar{x}_2}^2} \tag{4.16}$$

$$df'=\frac{1}{\dfrac{R^2}{n_1-1}+\dfrac{(1-R)^2}{n_2-1}} \tag{4.17}$$

$$t_{df'}=\frac{\bar{x}_1-\bar{x}_2}{s_{\bar{x}_1-\bar{x}_2}} \tag{4.18}$$

式中的 $t_{df'}$ 近似服从于 t 分布，其自由度为 df'，查 t 值表得 $t_{\alpha(df')}$ 临界值。

【例 4.10】 测定冬小麦'东方红 3 号'的蛋白质含量(%)10 次，得 $\bar{x}_1=14.3, s_1^2=1.621$；测定'农大 193'的蛋白质含量(%)5 次，得 $\bar{x}_2=11.7, s_2^2=0.135$。试检验两个品种蛋白质含量是否有显著差异。

经 F 检验，得知两个品种蛋白质含量的方差有显著的不同，即 $\sigma_1^2 \neq \sigma_2^2$；又由于 $n_1 \neq n_2$，且均小于 30，故需计算 $t_{df'}$，作近似的 t 检验。因预先不知两个品种的蛋白质含量孰高孰低，故使用双尾检验。

(1) 假设 $H_0:\mu_1=\mu_2$，即两个品种蛋白质含量没有显著差异；$H_A:\mu_1\neq\mu_2$。

(2) 取显著水平 $\alpha=0.01$。

(3) 检验计算：

$$s_{\bar{x}_1}^2=\frac{s_1^2}{n_1}=\frac{1.621}{10}=0.162$$

$$s_{\bar{x}_2}^2=\frac{s_2^2}{n_2}=\frac{0.135}{5}=0.027$$

$$R=\frac{s_{\bar{x}_1}^2}{s_{\bar{x}_1}^2+s_{\bar{x}_2}^2}=\frac{0.162}{0.162+0.027}=0.857$$

$$df'=\frac{1}{\frac{R^2}{n_1-1}+\frac{(1-R)^2}{n_2-1}}=\frac{1}{\frac{0.857^2}{10-1}+\frac{(1-0.857)^2}{5-1}}=11.532\approx 12$$

$$s_{\bar{x}_1-\bar{x}_2}=\sqrt{\frac{s_1^2}{n_1}+\frac{s_2^2}{n_2}}=\sqrt{\frac{1.621}{10}+\frac{0.135}{5}}=0.435$$

$$t_{df'}=\frac{\bar{x}_1-\bar{x}_2}{s_{\bar{x}_1-\bar{x}_2}}=\frac{14.3-11.7}{0.435}=5.977$$

(4) 推断：查附表3，当 $df'=12$ 时，$t_{0.01}=3.056$。现实得 $|t_{df'}|>t_{0.01}$，$P<0.01$，故否定 H_0，接受 H_A，认为两个品种蛋白质含量有极显著差异；因 $\bar{x}_1>\bar{x}_2$，故‘东方红3号’的蛋白质含量极显著高于‘农大193’。

2) 成对数据平均数比较的 t 检验

成对数据(paried data) 的比较要求两个样本间配偶成对，每一对样本除随机地给予不同处理外，其他试验条件应尽量一致。成对数据，由于同一配对样本内两个供试单位的试验条件非常接近，而不同配对样本间的条件差异又可以通过各个配对样本差数予以消除，因而，可以较大程度地控制试验误差，具有较高的精确度。所以在试验研究中，为加强某些试验条件的控制，以做成成对数据的比较效果较好。在进行假设检验时，只要假设两个样本的总体差数 $\mu_d=\mu_1-\mu_2=0$，而不必假定两个样本的总体方差 σ_1^2 和 σ_2^2 相同。但对于一些成组数据，即使 $n_1=n_2$，也不能用做成对数据的比较，因为成组数据的每一变量都是独立的，没有配对的基础。

设两个样本的变量分别为 x_1 和 x_2，共配成 n 对，各对的差数为 $d=x_1-x_2$，则样本差数平均数 $\bar{d}$ 为

$$\bar{d}=\frac{\sum d}{n}=\frac{\sum(x_1-x_2)}{n}=\frac{\sum x_1}{n}-\frac{\sum x_2}{n}=\bar{x}_1-\bar{x}_2 \tag{4.19}$$

样本差数方差 s_d^2 为

$$s_d^2=\frac{\sum(d-\bar{d})^2}{n-1}=\frac{\sum d^2-\frac{\left(\sum d\right)^2}{n}}{n-1} \tag{4.20}$$

样本差数平均数标准误(standard error of the sample difference mean) $s_{\bar{d}}$ 为

$$s_{\bar{d}}=\sqrt{\frac{s_d^2}{n}}=\sqrt{\frac{\sum(d-\bar{d})^2}{n(n-1)}}=\sqrt{\frac{\sum d^2-\frac{\left(\sum d\right)^2}{n}}{n(n-1)}} \tag{4.21}$$

因而，t 值为

$$t=\frac{\bar{d}-\mu_d}{s_{\bar{d}}} \tag{4.22}$$

在假设 $H_0:\mu_d=0$ 的情况下，式(4.22)则为

$$t=\frac{\bar{d}}{s_{\bar{d}}} \tag{4.23}$$

它具有自由度 $df=n-1$。

【例 4.11】 在研究动物饮食中缺乏维生素 E 与肝中维生素 A 含量的关系时，将试验动物按性别、体重等配成 8 对，并将每对中的两头试验动物用随机分配法分配在正常饲料组和维生素 E 缺乏组，一定时间后将试验动物处死，测定其肝中维生素 A 的含量，结果如表 4-1 所示，试检验两组饲料对试验动物肝中维生素 A 含量的作用是否有显著差异。

表 4-1　不同饲料饲养下试验动物肝中的维生素 A 含量　　(单位：IU/g)

动物配对	正常饲料组	维生素 E 缺乏组	差数(d)	d^2
1	3550	2450	1100	1210000
2	2000	2400	−400	160000
3	3000	1800	1200	1440000
4	3950	3200	750	562500
5	3800	3250	550	302500
6	3750	2700	1050	1102500
7	3450	2500	950	902500
8	3050	1750	1300	1690000
$\sum$			6500	7370000

此题 $n=8$，为成对数据的 t 检验，因事先不知两组饲料对试验动物肝中维生素 A 含量的作用孰大孰小，故用双尾检验。

(1) 假设 $H_0:\mu_d=0$，即两组饲料对试验动物肝中维生素 A 含量的作用没有显著差异；$H_A:\mu_d\neq 0$。

(2) 确定显著水平 $\alpha=0.01$。

(3) 检验计算：

$$\bar{d}=\frac{\sum d}{n}=\frac{6500}{8}=812.500$$

$$s_d^2=\frac{\sum d^2-\frac{\left(\sum d\right)^2}{n}}{n-1}=\frac{7370000-\frac{6500^2}{8}}{8-1}=298392.857$$

$$s_{\bar{d}}=\sqrt{\frac{s_d^2}{n}}=\sqrt{\frac{298392.857}{8}}=193.130$$

$$t=\frac{\bar{d}}{s_{\bar{d}}}=\frac{812.500}{193.130}=4.207$$

(4) 推断：查附表3，当$df=8-1=7$时，$t_{0.01}=3.499$。现实得$|t|>t_{0.01}$，$P<0.01$，故否定H_0，接受H_A，即两组饲料对试验动物肝中维生素A含量的作用有极显著差异。用正常饲料饲养的试验动物肝中的维生素A含量极显著高于维生素E缺乏组饲养的试验动物肝中的维生素A含量。

第三节　样本频率的假设检验

在生物学研究中，有许多数据资料是用频率（或百分数、成数）表示的。当总体或样本中的个体分属两种属性，如药剂处理后害虫的死与活、种子的发芽与不发芽、动物的雌与雄等，类似这些性状组成的总体通常服从二项分布，因此称为二项总体，即由“非此即彼”性状的个体组成的总体。有些总体中的个体有多个属性，但可根据研究目的经适当的统计处理分为“目标性状”和“非目标性状”两种属性，也可看成为二项总体。在二项总体中抽样，样本中的“此”性状出现的情况可用次数表示，也可用频率表示。设二项总体中具有“目标性状”个体的频率为p，具“非目标性状”个体的频率为q，则$p+q=1$。因此频率的假设检验可按二项分布进行，即从二项式$(p+q)^n$的展开式中求出“此”性状的概率，然后作出统计推断。但是，如果样本容量n较大，$0.1\leqslant p\leqslant 0.9$时，$np$和$nq$又均不小于5，$(p+q)^n$的分布就趋于正态分布，因而可将频率资料作正态分布处理，从而作出近似的检验。

一、一个样本频率的假设检验

适用于检验一个样本频率$\hat{p}$的总体频率p与某一理论频率p_0差异显著性。根据n和p的大小，其检验方法是不一样的。当np或nq小于5，则由二项式$(p+q)^n$展开式直接检验；当$5<np$或$nq<30$时，二项分布趋近正态分布，可用u检验（$n\geqslant 30$）或t检验（$n<30$），但需进行连续性矫正（continuity correction）；如果np、nq均大于30时，则不需进行连续性矫正，用u检验。

从一个总体中抽取容量为n的样本，其中具有“目标性状”的个数为x，则该性状的概率估计值为

$$\hat{p}=\frac{x}{n} \tag{4.24}$$

总体频率的标准误（standard error of the population frequency）σ_p为

$$\sigma_p=\sqrt{\frac{pq}{n}} \tag{4.25}$$

在不需进行连续性矫正时，u值的计算公式为

$$u=\frac{\hat{p}-p}{\sigma_p} \tag{4.26}$$

需要进行连续性矫正时，u_c值的计算公式为

$$u_c=\frac{(\hat{p}-p)\mp\frac{0.5}{n}}{\sigma_p}=\frac{|\hat{p}-p|-\frac{0.5}{n}}{\sigma_p} \tag{4.27}$$

式中的"∓"表示在$\hat{p}>p$时取"−"号,在$\hat{p}<p$时取"+"号。

如果σ_p未知,可用$\hat{p}$的标准误$s_{\hat{p}}$来估计,$s_{\hat{p}}$的计算公式为

$$s_{\hat{p}}=\sqrt{\frac{\hat{p}\hat{q}}{n}} \tag{4.28}$$

当$n<30$时,式(4.26)和式(4.27)中的u值应以t值($df=n-1$)取代。

【例 4.12】 有一批蔬菜种子的平均发芽率$p_0=0.85$。现随机抽取500粒种子,用种衣剂进行浸种处理,结果有445粒发芽。试检验种衣剂对种子发芽有无效果。

本题中,$p_0=0.85$,$n=500$,由于np和nq都大于30,故用u检验,不需进行连续性矫正。又因未知种衣剂浸种处理效果,故用双尾检验。

(1) 假设$H_0:p=p_0=0.85$,即用种衣剂浸种后的种子发芽率仍为0.85;$H_A:p\neq p_0$。

(2) 确定显著水平$\alpha=0.05$。

(3) 检验计算:

$$q=1-p=1-0.85=0.15$$

$$\hat{p}=\frac{x}{n}=\frac{445}{500}=0.89$$

$$\sigma_p=\sqrt{\frac{pq}{n}}=\sqrt{\frac{0.85\times0.15}{500}}=0.016$$

$$u=\frac{\hat{p}-p}{\sigma_p}=\frac{0.89-0.85}{0.016}=2.500$$

(4) 推断:由于$|u|>u_{0.05}=1.96$,$P<0.05$,故否定H_0,接受H_A,又因$\hat{p}>p$,认为用种衣剂浸种能够显著提高蔬菜种子的发芽率。

【例 4.13】 某养鸡场规定种蛋的孵化率$p_0>0.80$为合格。现对一批种蛋随机抽取100枚进行孵化检验,结果有78枚孵出。问这批种蛋是否合格?

此题中,$n=100$,np、nq都大于5,但$nq<30$,故用u检验,需进行连续性矫正。又因只有孵化率>0.80才认为是合格,故采用单尾检验。

(1) 假设$H_0:p\leqslant p_0$,即该批种蛋不合格;$H_A:p>p_0$。

(2) 确定显著水平$\alpha=0.05$。

(3) 检验计算:

$$q=1-p=1-0.80=0.20$$

$$\hat{p}=\frac{x}{n}=\frac{78}{100}=0.78$$

$$\sigma_p=\sqrt{\frac{pq}{n}}=\sqrt{\frac{0.80\times0.20}{100}}=0.04$$

$$u_c=\frac{|\hat{p}-p|-\frac{0.5}{n}}{\sigma_p}=\frac{|0.78-0.80|-\frac{0.5}{100}}{0.04}=0.375$$

(4) 推断：由于 $|u_c| < u_{0.05} = 1.64$，$P > 0.05$，故接受 H_0，认为这批种蛋不合格。

二、两个样本频率的假设检验

适用于检验两个样本频率 $\hat{p}_1$ 和 $\hat{p}_2$ 所属总体频率 p_1 和 p_2 差异的显著性。一般假定两个样本所属总体的方差是相等的，即 $\sigma^2_{p_1} = \sigma^2_{p_2}$。这类检验在实际应用中具有更重要的意义。由于在抽样试验中，其理论频率 p_0 常为未知数，就无法将样本某属性出现的频率与理论频率进行比较，只能进行两个样本频率的比较。与单个样本频率的假设检验一样，当 np 或 nq 小于 5，则按二项分布直接进行检验；当 $5 < np$ 或 $nq < 30$ 时，用 u 检验($n \geqslant 30$) 或 t 检验($n < 30$)，并需要进行连续性矫正；当 np、nq 均大于 30 时，则不需要进行连续性矫正，用 u 检验。

若从两个总体中分别抽取容量为 n_1、n_2 的样本，其中具“目标性状”的个数分别为 x_1、x_2，则该性状的概率估计值分别为

$$\hat{p}_1 = \frac{x_1}{n_1}, \hat{p}_2 = \frac{x_2}{n_2} \tag{4.29}$$

因总体频率的方差未知，故用样本统计数来估计。两个样本频率差数标准误 (standard error of the sample frequency difference) $s_{\hat{p}_1 - \hat{p}_2}$ 为

$$s_{\hat{p}_1 - \hat{p}_2} = \sqrt{\frac{\hat{p}_1 \hat{q}_1}{n_1} + \frac{\hat{p}_2 \hat{q}_2}{n_2}} \tag{4.30}$$

在 $H_0: p_1 = p_2$ 的条件下，两个样本频率差数标准误 $s_{\hat{p}_1 - \hat{p}_2}$ 为

$$s_{\hat{p}_1 - \hat{p}_2} = \sqrt{\bar{p}\,\bar{q}\left(\frac{1}{n_1} + \frac{1}{n_2}\right)} \tag{4.31}$$

式中，$\bar{p} = \dfrac{x_1 + x_2}{n_1 + n_2}$，$\bar{q} = 1 - \bar{p}$。当 $n_1 = n_2 = n$ 时，式(4.31) 可简化为

$$s_{\hat{p}_1 - \hat{p}_2} = \sqrt{\frac{2\,\bar{p}\,\bar{q}}{n}} \tag{4.32}$$

不需进行连续性矫正的 u 值为

$$u = \frac{(\hat{p}_1 - \hat{p}_2) - (p_1 - p_2)}{s_{\hat{p}_1 - \hat{p}_2}} \tag{4.33}$$

在 $H_0: p_1 = p_2$ 条件下，u 值为

$$u = \frac{\hat{p}_1 - \hat{p}_2}{s_{\hat{p}_1 - \hat{p}_2}} \tag{4.34}$$

此时，需要进行连续性矫正的 u_c 值为

$$u_c = \frac{|\hat{p}_1 - \hat{p}_2| - \dfrac{0.5}{n_1} - \dfrac{0.5}{n_2}}{s_{\hat{p}_1 - \hat{p}_2}} \tag{4.35}$$

当 n_1 或 n_2 小于 30 时，式(4.33)～式(4.35)中的 u 值应以 t 值($df = n_1 + n_2 - 2$)取代。

【例 4.14】 现研究地势对小麦锈病发病率的影响。调查低洼地麦田 378 株，其中锈病株 342 株；调查高坡地麦田 396 株，其中锈病株 313 株。试比较两块麦田锈病发病率是

否有显著性差异。

本题 $n_1=378$、$n_2=396$，且 np 和 nq 均大于30，故用 u 检验，不需进行连续性矫正。又因事先不知两块麦田的锈病发病率孰高孰低，故进行双尾检验。

(1) 假设 $H_0:p_1=p_2$，即两块麦田锈病发病率没有显著差异；$H_A:p_1\neq p_2$。

(2) 确定显著水平 $\alpha=0.01$。

(3) 检验计算：

$$\hat{p}_1=\frac{x_1}{n_1}=\frac{342}{378}=0.905$$

$$\hat{p}_2=\frac{x_2}{n_2}=\frac{313}{396}=0.790$$

$$\bar{p}=\frac{x_1+x_2}{n_1+n_2}=\frac{342+313}{378+396}=0.846$$

$$\bar{q}=1-\bar{p}=1-0.846=0.154$$

$$s_{\hat{p}_1-\hat{p}_2}=\sqrt{\bar{p}\,\bar{q}\left(\frac{1}{n_1}+\frac{1}{n_2}\right)}=\sqrt{0.846\times0.154\times\left(\frac{1}{378}+\frac{1}{396}\right)}=0.026$$

$$u=\frac{\hat{p}_1-\hat{p}_2}{s_{\hat{p}_1-\hat{p}_2}}=\frac{0.905-0.790}{0.026}=4.423$$

(4) 推断：由于 $|u|>u_{0.01}=2.58$，$P<0.01$，故否定 H_0，接受 H_A；又 $\hat{p}_1>\hat{p}_2$，认为低洼地麦田锈病发病率极显著高于高坡地麦田。

【例 4.15】 某养鱼场发生了药物中毒，抽查甲池29尾鱼中有20尾死亡，抽查乙池28尾鱼中有21尾死亡。试检验甲、乙两池发生药物中毒后，鱼的死亡率是否有差异。

本题 $n_1=29$、$n_2=28$，且 np、nq 均小于30，用 t 检验，需进行连续性矫正。又因事先不知两池鱼的死亡率孰高孰低，故采用双尾检验。

(1) 假设 $H_0:p_1=p_2$，即甲、乙两池鱼的死亡率没有显著差异；$H_A:p_1\neq p_2$。

(2) 确定显著水平 $\alpha=0.05$。

(3) 检验计算：

$$\hat{p}_1=\frac{x_1}{n_1}=\frac{20}{29}=0.690$$

$$\hat{p}_2=\frac{x_2}{n_2}=\frac{21}{28}=0.750$$

$$\bar{p}=\frac{x_1+x_2}{n_1+n_2}=\frac{20+21}{29+28}=0.719$$

$$\bar{q}=1-\bar{p}=1-0.719=0.281$$

$$s_{\hat{p}_1-\hat{p}_2}=\sqrt{\bar{p}\,\bar{q}\left(\frac{1}{n_1}+\frac{1}{n_2}\right)}=\sqrt{0.719\times0.281\times\left(\frac{1}{29}+\frac{1}{28}\right)}=0.119$$

$$t_c=\frac{|\hat{p}_1-\hat{p}_2|-\frac{0.5}{n_1}-\frac{0.5}{n_2}}{s_{\hat{p}_1-\hat{p}_2}}=\frac{|0.690-0.750|-\frac{0.5}{29}-\frac{0.5}{28}}{0.119}=0.209$$

(4) 推断：当 $df=29+28-2=55$ 时，$t_{0.05}=2.004$，$|t_c|<t_{0.05}$，$P>0.05$，故接受

H_0，认为发生药物中毒后，甲、乙两鱼池鱼的死亡率没有显著差异。

第四节　参数的区间估计与点估计

参数估计(estimation of parameter)是统计推断的另一个方面，它是指由样本结果对总体参数在一定概率水平下所作出的估计。参数估计包括区间估计(interval estimation)和点估计(point estimation)。

一、参数区间估计与点估计的原理

参数的区间估计和点估计是建立在一定理论分布基础上的一种方法。由中心极限定理和大数定律得知，只要抽样为大样本，不论其总体是否为正态分布，其样本平均数都近似服从 $N(\mu,\sigma_{\bar{x}}^2)$ 的正态分布，因而，当概率水平 $\alpha=0.05$ 或 $\alpha=0.01$ 时，即置信度(degree of confidence) 为 $P=1-\alpha=0.95$ 或 0.99 的条件下，有

$$P(\mu-1.96\sigma_{\bar{x}}\leqslant\bar{x}\leqslant\mu+1.96\sigma_{\bar{x}})=0.95 \tag{4.36}$$

$$P(\mu-2.58\sigma_{\bar{x}}\leqslant\bar{x}\leqslant\mu+2.58\sigma_{\bar{x}})=0.99 \tag{4.37}$$

由式(4.36)、式(4.37)可得

$$P(\bar{x}-1.96\sigma_{\bar{x}}\leqslant\mu\leqslant\bar{x}+1.96\sigma_{\bar{x}})=0.95 \tag{4.38}$$

$$P(\bar{x}-2.58\sigma_{\bar{x}}\leqslant\mu\leqslant\bar{x}+2.58\sigma_{\bar{x}})=0.99 \tag{4.39}$$

因此，对于某一概率水平 α，则有通式：

$$P(\bar{x}-u_\alpha\sigma_{\bar{x}}\leqslant\mu\leqslant\bar{x}+u_\alpha\sigma_{\bar{x}})=1-\alpha \tag{4.40}$$

式中，u_α 为正态分布下置信度 $P=1-\alpha$ 时的 u 临界值。

上面式子表明，尽管我们只知道 $\bar{x}$ 而不知道 μ，但知道区间 $(\bar{x}-u_\alpha\sigma_{\bar{x}},\bar{x}+u_\alpha\sigma_{\bar{x}})$ 内包含 μ 在内的可靠程度为 $1-\alpha$。其中，$(\bar{x}-u_\alpha\sigma_{\bar{x}},\bar{x}+u_\alpha\sigma_{\bar{x}})$ 被称为 μ 的 $1-\alpha$ 置信区间(confidence interval)。因此，对于 μ 的 $1-\alpha$ 置信区间的下限 L_1 和上限 L_2 可以写为

$$(L_1=\bar{x}-u_\alpha\sigma_{\bar{x}},L_2=\bar{x}+u_\alpha\sigma_{\bar{x}}) \tag{4.41}$$

区间 (L_1,L_2) 便是用样本平均数 $\bar{x}$ 对总体平均数 μ 的置信度为 $P=1-\alpha$ 的区间估计。那么，可用

$$L=\bar{x}\pm u_\alpha\sigma_{\bar{x}} \tag{4.42}$$

表示样本平均数 $\bar{x}$ 对总体平均数 μ 的置信度为 $P=1-\alpha$ 的点估计。

当 $\alpha=0.05$ 时，包含有 μ 的置信度为 0.95 的区间估计和点估计为

$$(L_1=\bar{x}-1.96\sigma_{\bar{x}},L_2=\bar{x}+1.96\sigma_{\bar{x}}) \tag{4.43}$$

$$L=\bar{x}\pm1.96\sigma_{\bar{x}} \tag{4.44}$$

当 $\alpha=0.01$ 时，包含有 μ 的置信度为 0.99 的区间估计和点估计为

$$(L_1=\bar{x}-2.58\sigma_{\bar{x}},L_2=\bar{x}+2.58\sigma_{\bar{x}}) \tag{4.45}$$

$$L=\bar{x}\pm2.58\sigma_{\bar{x}} \tag{4.46}$$

实际上，参数的区间估计也可用于假设检验，因为置信区间是在一定置信度 $P=1-\alpha$ 下总体参数的所在范围，故对参数所进行的假设如果落在该区间内，就说明这个假设与真

实情况没有不同，因而就可以接受 H_0；反之，如果对参数所进行的假设落在区间之外，则说明假设与真实情况有本质的不同，就应否定 H_0，接受 H_A。

需要指出的是，无论是区间估计还是点估计，都与概率显著水平 α 的大小联系在一起。α 越小，则相应的置信区间就越大，也就是说用样本平均数对总体平均数估计的可靠程度越高，但这时估计的精度就降低了。在实际应用中，应合理选取概率显著水平 α 的大小，不能认为 α 取值越小越好。

二、一个总体平均数 μ 的区间估计与点估计

当总体方差 σ^2 为已知或总体方差 σ^2 未知但为大样本时，可以利用样本平均数 $\bar{x}$ 和总体方差 σ^2 或样本方差 s^2 作出在置信度为 $P=1-\alpha$ 的总体平均数 μ 的区间估计为

$$(\bar{x}-u_\alpha\sigma_{\bar{x}},\bar{x}+u_\alpha\sigma_{\bar{x}})$$

由式(4.41)，其置信区间的下限 L_1 和上限 L_2 为

$$(L_1=\bar{x}-u_\alpha\sigma_{\bar{x}},L_2=\bar{x}+u_\alpha\sigma_{\bar{x}})$$

由式(4.42)，总体平均数 μ 的点估计 L 为

$$L=\bar{x}\pm u_\alpha\sigma_{\bar{x}}$$

当样本为小样本且总体方差 σ^2 未知时，σ^2 需由样本方差 s^2 来估计，于是置信度为 $P=1-\alpha$ 的总体平均数 μ 的置信区间可估计为

$$(\bar{x}-t_\alpha s_{\bar{x}},\bar{x}+t_\alpha s_{\bar{x}}) \tag{4.47}$$

其置信区间的下限 L_1 和上限 L_2 为

$$(L_1=\bar{x}-t_\alpha s_{\bar{x}},L_2=\bar{x}+t_\alpha s_{\bar{x}}) \tag{4.48}$$

总体平均数 μ 的点估计 L 为

$$L=\bar{x}\pm t_\alpha s_{\bar{x}} \tag{4.49}$$

式中，t_α 为 t 分布下置信度 $P=1-\alpha$ 时的 t 临界值，具有 $df=n-1$。

【例 4.16】 测得某批25个小麦样本的平均蛋白质含量 $\bar{x}=14.5\%$，已知 $\sigma=2.50\%$，试进行95%置信度下的蛋白质含量的区间估计和点估计。

本例 σ 为已知，置信度 $P=1-\alpha=0.95$，即 $\alpha=0.05$，查附表2得 $u_{0.05}=1.96$。由 σ 可求出 $\sigma_{\bar{x}}$：

$$\sigma_{\bar{x}}=\frac{\sigma}{\sqrt{n}}=\frac{2.50}{\sqrt{25}}=0.50$$

于是蛋白质含量的区间估计为

$$L_1=\bar{x}-u_\alpha\sigma_{\bar{x}}=14.5-1.96\times0.50=13.52(\%)$$

$$L_2=\bar{x}+u_\alpha\sigma_{\bar{x}}=14.5+1.96\times0.50=15.48(\%)$$

蛋白质含量的点估计为

$$L=\bar{x}\pm u_\alpha\sigma_{\bar{x}}=14.5\pm1.96\times0.50=14.5\pm0.98(\%)$$

因此，这批小麦总体的蛋白质含量为13.52%～15.48%的置信度为95%。

【例 4.17】 从某渔场收虾的总体中，随机取20尾对虾，测得平均体长 $\bar{x}=120\text{mm}$，标准差 $s=15\text{mm}$，试估计置信度为99%的对虾体长总体平均数。

本例中，由于总体方差σ^2未知，$n=20$，需用s^2估计σ^2。置信度$P=1-\alpha=0.99$，即$\alpha=0.01$，查附表3，当$df=20-1=19$时，$t_{0.01}=2.861$。具体计算如下：

$$s_{\bar{x}}=\frac{s}{\sqrt{n}}=\frac{15}{\sqrt{20}}=3.354$$

于是对虾体长的区间估计为

$$L_1=\bar{x}-t_\alpha s_{\bar{x}}=120-2.861\times 3.354=110.4(\text{mm})$$

$$L_2=\bar{x}+t_\alpha s_{\bar{x}}=120+2.861\times 3.354=129.6(\text{mm})$$

对虾体长的点估计为

$$L=\bar{x}\pm t_\alpha s_{\bar{x}}=120\pm 2.861\times 3.354=120\pm 9.6(\text{mm})$$

因此，该渔场对虾体长为110.4～129.6mm的置信度为99%。

三、两个总体平均数差数$\mu_1-\mu_2$的区间估计与点估计

当两个总体方差σ_1^2和σ_2^2为已知，或总体方差σ_1^2和σ_2^2未知但为大样本时，在置信度为$P=1-\alpha$下，两个总体平均数差数$\mu_1-\mu_2$的区间估计为

$$[(\bar{x}_1-\bar{x}_2)-u_\alpha\sigma_{\bar{x}_1-\bar{x}_2},(\bar{x}_1-\bar{x}_2)+u_\alpha\sigma_{\bar{x}_1-\bar{x}_2}] \tag{4.50}$$

其置信区间的下限L_1和上限L_2为

$$[L_1=(\bar{x}_1-\bar{x}_2)-u_\alpha\sigma_{\bar{x}_1-\bar{x}_2},L_2=(\bar{x}_1-\bar{x}_2)+u_\alpha\sigma_{\bar{x}_1-\bar{x}_2}] \tag{4.51}$$

两个总体平均数差数$\mu_1-\mu_2$的点估计L为

$$L=(\bar{x}_1-\bar{x}_2)\pm u_\alpha\sigma_{\bar{x}_1-\bar{x}_2} \tag{4.52}$$

当两个样本为小样本，且两总体方差σ_1^2和σ_2^2未知，但两总体方差相等，即$\sigma_1^2=\sigma_2^2=\sigma^2$时，可由两个样本方差$s_1^2$和$s_2^2$估计总体方差$\sigma_1^2$和$\sigma_2^2$，用$t_\alpha$代替$u_\alpha$，其自由度$df=n_1+n_2-2$。在置信度为$P=1-\alpha$下，两总体平均数差数$\mu_1-\mu_2$的区间估计为

$$[(\bar{x}_1-\bar{x}_2)-t_\alpha s_{\bar{x}_1-\bar{x}_2},(\bar{x}_1-\bar{x}_2)+t_\alpha s_{\bar{x}_1-\bar{x}_2}] \tag{4.53}$$

其置信区间的下限L_1和上限L_2为

$$[L_1=(\bar{x}_1-\bar{x}_2)-t_\alpha s_{\bar{x}_1-\bar{x}_2},L_2=(\bar{x}_1-\bar{x}_2)+t_\alpha s_{\bar{x}_1-\bar{x}_2}] \tag{4.54}$$

两个总体平均数差数$\mu_1-\mu_2$的点估计L为

$$L=(\bar{x}_1-\bar{x}_2)\pm t_\alpha s_{\bar{x}_1-\bar{x}_2} \tag{4.55}$$

当两个样本为小样本，两个总体方差σ_1^2和σ_2^2未知，$\sigma_1^2\neq\sigma_2^2$，但$n_1=n_2=n$时，两个总体平均数差数$\mu_1-\mu_2$的区间估计与点估计计算公式同式(4.53)～式(4.55)，但t_α的自由度$df=n-1$，而不是$2(n-1)$。

当两个样本为小样本，两个总体方差σ_1^2和σ_2^2未知，且两个总体方差与样本容量均不相等，即$\sigma_1^2\neq\sigma_2^2$、$n_1\neq n_2$时，由两个样本方差s_1^2和s_2^2对总体方差σ_1^2和σ_2^2的估计而算出的t值，已不是自由度$df=n_1+n_2-2$的t分布，而是近似服从自由度为df'的t分布，在置信度为$P=1-\alpha$下，两总体平均数差数$\mu_1-\mu_2$的区间估计为

$$[(\bar{x}_1-\bar{x}_2)-t_{\alpha(df')}s_{\bar{x}_1-\bar{x}_2},(\bar{x}_1-\bar{x}_2)+t_{\alpha(df')}s_{\bar{x}_1-\bar{x}_2}] \tag{4.56}$$

其置信区间的下限L_1和上限L_2为

$$[L_1=(\bar{x}_1-\bar{x}_2)-t_{\alpha(df')}s_{\bar{x}_1-\bar{x}_2},L_2=(\bar{x}_1-\bar{x}_2)+t_{\alpha(df')}s_{\bar{x}_1-\bar{x}_2}] \tag{4.57}$$

两个总体平均数差数 $\mu_1-\mu_2$ 的点估计 L 为

$$L=(\bar{x}_1-\bar{x}_2)\pm t_{\alpha(df')}s_{\bar{x}_1-\bar{x}_2} \tag{4.58}$$

式(4.56)～式(4.58)中，$t_{\alpha(df')}$ 为置信度为 $P=1-\alpha$ 时自由度为 df' 的 t 临界值。

当两个样本为成对资料时，在置信度为 $P=1-\alpha$ 时，两个总体平均数差数 $\mu_1-\mu_2$ 的置信区间可估计为

$$(\bar{d}-t_\alpha s_{\bar{d}},\bar{d}+t_\alpha s_{\bar{d}}) \tag{4.59}$$

其置信区间的下限 L_1 和上限 L_2 为

$$(L_1=\bar{d}-t_\alpha s_{\bar{d}},L_2=\bar{d}+t_\alpha s_{\bar{d}}) \tag{4.60}$$

两总体平均数差数 $\mu_1-\mu_2$ 的点估计为

$$L=\bar{d}\pm t_\alpha s_{\bar{d}} \tag{4.61}$$

其中，t_α 具有自由度 $df=n-1$。

【例 4.18】 对例 4.8 数据进行置信度为 95%时两种蛋白质饲料饲养的大白鼠增重差数的区间估计和点估计。

在例 4.8 中，已算得 $\bar{x}_1=120.17$g，$\bar{x}_2=101.00$g，$s_{\bar{x}_1-\bar{x}_2}=10.005$g，并查得附表 3，当 $df=17$ 时，$t_{0.05}=2.110$，所以置信度为 95% 时两种蛋白质饲料饲养的大白鼠增重差数的区间估计为

$$L_1=(\bar{x}_1-\bar{x}_2)-t_\alpha s_{\bar{x}_1-\bar{x}_2}=(120.17-101.00)-2.110\times10.005=-1.94(\text{g})$$

$$L_2=(\bar{x}_1-\bar{x}_2)+t_\alpha s_{\bar{x}_1-\bar{x}_2}=(120.17-101.00)+2.110\times10.005=40.28(\text{g})$$

两种蛋白质饲料饲养的大白鼠增重差数的点估计为

$$L=(\bar{x}_1-\bar{x}_2)\pm t_\alpha s_{\bar{x}_1-\bar{x}_2}=(120.17-101.00)\pm2.110\times10.005$$
$$=19.17\pm21.11(\text{g})$$

因此，高蛋白组大白鼠的增重量比低蛋白组低 1.94g 到高 40.28g，这个估计有 95%的把握。

【例 4.19】 试对例 4.11 资料进行置信度为 99%的区间估计和点估计。

在例 4.11 中，已算得：$\bar{d}=812.500$IU/g，$s_{\bar{d}}=193.130$IU/g，并从附表 3 中查得，当 $df=7$ 时，$t_{0.01}=3.499$。则两种饲料饲养下动物肝中维生素 A 含量差数的区间估计为

$$L_1=\bar{d}-t_\alpha s_{\bar{d}}=812.5-3.499\times193.13=136.74(\text{IU/g})$$

$$L_2=\bar{d}+t_\alpha s_{\bar{d}}=812.5+3.499\times193.13=1488.26(\text{IU/g})$$

两种饲料饲养下动物肝中维生素 A 含量差数的点估计为

$$L=\bar{d}\pm t_\alpha s_{\bar{d}}=812.5\pm3.499\times193.13=812.5\pm675.76(\text{IU/g})$$

因此，正常饲料组饲养的动物肝中维生素 A 含量比维生素 E 缺乏组高 136.74～1488.26IU/g，这个估计的置信度为 99%。

四、一个总体频率 p 的区间估计与点估计

在置信度 $P=1-\alpha$ 下，对一个总体频率 p 的区间估计为

$$(\hat{p}-u_\alpha\sigma_p,\hat{p}+u_\alpha\sigma_p) \tag{4.62}$$

其置信区间的下限 L_1 和上限 L_2 为

$$(L_1=\hat{p}-u_\alpha\sigma_p, L_2=\hat{p}+u_\alpha\sigma_p) \tag{4.63}$$

总体频率 p 的点估计 L 为

$$L=\hat{p}\pm u_\alpha\sigma_p \tag{4.64}$$

当样本容量较小或者 np、nq 小于 30 时，对总体频率 p 进行的区间估计和点估计，需要作连续性矫正，其矫正公式为

$$\left(L_1=\hat{p}-u_\alpha\sigma_p-\frac{0.5}{n}, L_2=\hat{p}+u_\alpha\sigma_p+\frac{0.5}{n}\right) \tag{4.65}$$

总体频率 p 的点估计 L 为

$$L=\hat{p}\pm u_\alpha\sigma_p\pm\frac{0.5}{n} \tag{4.66}$$

当 σ_p 未知时，用 $s_{\hat{p}}$ 来估计 σ_p；当 $n<30$ 时，u_α 值用 t_α 值($df=n-1$) 来代替。

【例 4.20】 调查 100 株玉米，得到受玉米螟为害的植株为 20 株。试进行置信度为 95% 的玉米螟为害率的区间估计和点估计。

本题 $n=100$，$x=20$，$\hat{p}=0.2$，$np=20<30$，需进行连续性矫正；因 σ_p 未知，故用 $s_{\hat{p}}$ 来估计 σ_p。由式(4.28)，可计算 $s_{\hat{p}}$：

$$s_{\hat{p}}=\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}=\sqrt{\frac{0.20\times(1-0.20)}{100}}=0.04$$

当 $\alpha=0.05$ 时，$u_{0.05}=1.96$。于是，置信度为 95% 的玉米螟为害率的区间估计为

$$L_1=\hat{p}-u_\alpha s_{\hat{p}}-\frac{0.5}{n}=0.2-1.96\times0.04-\frac{0.5}{100}=0.117$$

$$L_2=\hat{p}+u_\alpha s_{\hat{p}}+\frac{0.5}{n}=0.2+1.96\times0.04+\frac{0.5}{100}=0.283$$

玉米螟为害率的点估计为

$$L=\hat{p}\pm u_\alpha\sigma_{\hat{p}}\pm\frac{0.5}{n}=0.2\pm1.96\times0.04\pm\frac{0.5}{100}=0.2\pm0.083$$

因此，玉米螟为害率为 0.117～0.283，这个估计的置信度为 95%。

五、两总体频率差数 p_1-p_2 的区间估计与点估计

若总体频率未知，常进行两个样本频率的比较，用 $\sigma_{\hat{p}_1-\hat{p}_2}$ 估计 $s_{p_1-p_2}$。在进行两个总体频率差数 p_1-p_2 的区间估计和点估计时，一般应明确两个频率有显著差异才有意义。在置信度为 $P=1-\alpha$ 下，两个总体频率差数 p_1-p_2 的区间估计为

$$[(\hat{p}_1-\hat{p}_2)-u_\alpha s_{\hat{p}_1-\hat{p}_2}, (\hat{p}_1-\hat{p}_2)+u_\alpha s_{\hat{p}_1-\hat{p}_2}] \tag{4.67}$$

其置信区间的下限 L_1 和上限 L_2 为

$$[L_1=(\hat{p}_1-\hat{p}_2)-u_\alpha s_{\hat{p}_1-\hat{p}_2}, L_2=(\hat{p}_1-\hat{p}_2)+u_\alpha s_{\hat{p}_1-\hat{p}_2}] \tag{4.68}$$

两个总体频率差数 p_1-p_2 的点估计 L 为

$$L=(\hat{p}_1-\hat{p}_2)\pm u_\alpha s_{\hat{p}_1-\hat{p}_2} \tag{4.69}$$

当 $5<np$ 或 $np<30$ 时，需要进行连续性矫正，则两总体频率差数 p_1-p_2 的区间估

计为

$$\left[(\hat{p}_1-\hat{p}_2)-u_\alpha s_{\hat{p}_1-\hat{p}_2}-\frac{0.5}{n_1}-\frac{0.5}{n_2},(\hat{p}_1-\hat{p}_2)+u_\alpha s_{\hat{p}_1-\hat{p}_2}+\frac{0.5}{n_1}+\frac{0.5}{n_2}\right] \tag{4.70}$$

其置信区间的下限 L_1 和上限 L_2 为

$$\left[L_1=(\hat{p}_1-\hat{p}_2)-u_\alpha s_{\hat{p}_1-\hat{p}_2}-\frac{0.5}{n_1}-\frac{0.5}{n_2},L_2=(\hat{p}_1-\hat{p}_2)+u_\alpha s_{\hat{p}_1-\hat{p}_2}+\frac{0.5}{n_1}+\frac{0.5}{n_2}\right] \tag{4.71}$$

两总体频率差数 p_1-p_2 的点估计 L 为

$$L=(\hat{p}_1-\hat{p}_2)\pm u_\alpha s_{\hat{p}_1-\hat{p}_2}\pm\frac{0.5}{n_1}\pm\frac{0.5}{n_2} \tag{4.72}$$

当 n_1 或 n_2 小于 30 时，式中的 u_α 值应以 t_α 值($df=n_1+n_2-2$) 来代替。

【例 4.21】 利用例 4.14 计算结果，试进行置信度为 99% 的两块麦田锈病发病率差数的区间估计和点估计。

在例 4.14 中，已得出：$\hat{p}_1=0.905$，$\hat{p}_2=0.790$，$s_{\hat{p}_1-\hat{p}_2}=0.026$，由于 $n_1>30$，$n_2>30$，且 np、nq 均大于 30，故当 $P=1-\alpha=0.99$ 时，$\alpha=0.01$，$u_{0.01}=2.58$，可以用 $s^2_{\hat{p}_1-\hat{p}_2}$ 估计 $\sigma^2_{p_1-p_2}$，无需进行连续性矫正。所以置信度为 99% 的两块麦田锈病发病率差数的区间估计为

$$L_1=(\hat{p}_1-\hat{p}_2)-u_\alpha s_{\hat{p}_1-\hat{p}_2}=(0.905-0.790)-2.58\times0.026=0.048$$

$$L_2=(\hat{p}_1-\hat{p}_2)+u_\alpha s_{\hat{p}_1-\hat{p}_2}=(0.905-0.790)+2.58\times0.026=0.182$$

两块麦田锈病发病率差数的点估计为

$$L=(\hat{p}_1-\hat{p}_2)\pm u_\alpha s_{\hat{p}_1-\hat{p}_2}=(0.905-0.790)\pm2.58\times0.026=0.115\pm0.067$$

因此，低洼地麦田锈病率比高坡地高 0.048～0.182，这个估计的置信度为 99%。

第五节　样本方差的同质性检验

本章第二节和第三节讨论了样本平均数、频率的假设检验。我们知道，平均数、频率表示的是计量数据资料的中心位置，但其代表性的好坏，与样本资料中各个观测数的变异程度密切相关，而方差是表示变异度的一个重要统计数。事实上，对样本平均数、频率的假设都是以方差的同质性(homogeneity)为前提的，否则假设检验的结论将是不正确的。所谓方差的同质性，又称为方差齐性(homogeneity of variance)，就是指各个总体的方差是相同的。方差同质性检验(homogeneity test)就是要从各样本的方差来推断其总体方差是否相同。

一、一个样本方差的同质性检验

从式(3.47) 中我们知道，从标准正态总体中抽取 k 个独立 u^2 之和为 χ^2，即

$$\chi^2=\sum\left(\frac{x-\mu}{\sigma}\right)^2=\frac{1}{\sigma^2}\sum(x-\mu)^2 \tag{4.73}$$

当用样本平均数 $\bar{x}$ 估计总体平均数 μ 时，则有

$$\chi^2=\frac{1}{\sigma^2}\sum(x-\bar{x})^2 \tag{4.74}$$

根据式(2.9)样本方差 $s^2=\dfrac{\sum(x-\bar{x})^2}{k-1}$，则式(4.74)可变换为

$$\chi^2=\frac{(k-1)s^2}{\sigma^2} \tag{4.75}$$

式中，分子表示样本的离散程度，分母表示总体方差，其 χ^2 服从自由度为 $k-1$ 的 χ^2 分布。

当 $\chi^2<\chi^2_\alpha$ 时，接受 $H_0:\sigma^2=\sigma_0^2$，认为样本所属总体方差与已知总体方差相同；当 $\chi^2>\chi^2_\alpha$ 时，否定 $H_0:\sigma^2=\sigma_0^2$，接受 $H_A:\sigma^2\neq\sigma_0^2$，认为样本所属总体方差与已知总体方差不同。

【例 4.22】 已知某农田受到重金属的污染，经抽样测定其铅浓度为 4.2，4.5，3.6，4.7，4.0，3.8，3.7，4.2(μg/g)，方差为 0.150(μg/g)^2。试检验受到污染的农田铅浓度的方差是否与正常农田铅浓度的方差 0.065(μg/g)^2 相同。

此题中正常农田铅浓度方差 $\sigma_0^2=0.065(\mu g/g)^2$，为一个样本方差与已知总体方差的同质性检验。

(1) 假设 $H_0:\sigma^2=0.065$，即受到污染的农田铅浓度的方差与正常农田铅浓度的方差相同；$H_A:\sigma^2\neq0.065$。

(2) 确定显著水平 $\alpha=0.05$。

(3) 检验计算：

$$\chi^2=\frac{(k-1)s^2}{\sigma^2}=\frac{(8-1)\times0.150}{0.065}=16.154$$

(4) 推断：查附表 4，当 $df=8-1=7$ 时，$\chi^2_{0.05}=14.07$。现实得 $\chi^2>\chi^2_{0.05}$，故否定 H_0，接受 H_A，即样本方差与总体方差是不同质的，认为受到污染的农田铅浓度的方差与正常农田铅浓度的方差有显著差异。

二、两个样本方差的同质性检验

假设两个样本的样本容量分别为 n_1 和 n_2，方差分别为 s_1^2 和 s_2^2(一般把数值较大的样本方差作为 s_1^2)，总体方差分别为 σ_1^2 和 σ_2^2，当检验 σ_1^2 和 σ_2^2 是否同质时，可用 F 检验(F-test)。根据式(3.50)，当两样本所属总体均服从正态分布，且两样本的抽样是随机的和独立的，其 F 值等于两样本方差 s_1^2 和 s_2^2 之比，即

$$F=\frac{s_1^2}{s_2^2}$$

并服从 $df_1=n_1-1$，$df_2=n_2-1$ 的 F 分布。当 $F<F_\alpha$ 时，接受 $H_0:\sigma_1^2=\sigma_2^2$，即认为两样本的方差是同质的；当 $F>F_\alpha$ 时，否定 $H_0:\sigma_1^2=\sigma_2^2$，接受 $H_A:\sigma_1^2\neq\sigma_2^2$，即认为两样本的方差不是同质的。

【例 4.23】 检验例 4.9 中两个小麦品种千粒重的方差是否同质。

该题中，$s_1^2=22.933$，$s_2^2=2.933$，$n_1=n_2=10$，为两个样本方差的同质性检验。

(1) 假设 $H_0:\sigma_1^2=\sigma_2^2$，即两小麦品种千粒重的方差相同；$H_A:\sigma_1^2\neq\sigma_2^2$。

(2) 确定显著水平 $\alpha=0.01$。

(3) 检验计算：

$$F=\frac{s_1^2}{s_2^2}=\frac{22.933}{2.933}=7.819$$

(4) 推断：查附表 5，$df_1=10-1=9$，$df_2=10-1=9$，$F_{0.01}=5.35$，$F>F_{0.01}$，故 $P<0.01$，否定 H_0，接受 H_A，认为两小麦品种千粒重的方差有极显著的差异，不是同质的。

三、多个样本方差的同质性检验

对 3 个或 3 个以上样本方差进行同质性检验，一般采用巴特勒检验法(Bartlett test)。假设 $H_0:\sigma_1^2=\sigma_2^2=\cdots=\sigma_k^2$，即 k 个样本的方差是同质的，对 $H_A:\sigma_1^2,\sigma_2^2,\cdots,\sigma_k^2$ 不相等。对 k 个独立样本方差 $s_1^2,s_2^2,\cdots,s_k^2$，求其合并方差 s_p^2、矫正数 C 和 χ^2：

$$s_p^2=\frac{\sum_{i=1}^{k}s_i^2(n_i-1)}{\sum_{i=1}^{k}(n_i-1)} \tag{4.76}$$

$$C=1+\frac{1}{3(k-1)}\left[\sum_{i=1}^{k}\frac{1}{n_i-1}-\frac{1}{\sum_{i=1}^{k}(n_i-1)}\right] \tag{4.77}$$

$$\chi^2=\frac{2.3026}{C}\left[\lg s_p^2\sum_{i=1}^{k}(n_i-1)-\sum_{i=1}^{k}(n_i-1)\lg s_i^2\right] \tag{4.78}$$

式(4.78) 服从 $df=k-1$ 的 χ^2 分布，其中，$2.3026=\ln 10$。对确定的显著水平 α，如果 $\chi^2<\chi_\alpha^2$，则接受 H_0，认为 $\sigma_1^2=\sigma_2^2=\cdots=\sigma_k^2$ 成立；如果 $\chi^2>\chi_\alpha^2$，则应否定 H_0，接受 H_A，表明这些样本方差不是同质的。

【例 4.24】 在某种树的抗压强度试验中，以相同加压速率测试 4 种不同比重的该树种的抗压强度，所取样本容量分别为 4，3，3，4，计算得样本的方差分别为 144.25，66.34，39.00，158.33。试检验这 4 个样本所来自的总体方差是否相同。

此例为多个样本方差的同质性检验。

(1) 假设 $H_0:\sigma_1^2=\sigma_2^2=\sigma_3^2=\sigma_4^2$，即 4 个方差是同质的；$H_A$：4 个方差不相等。

(2) 确定显著水平 $\alpha=0.05$。

(3) 检验计算：

$$s_p^2=\frac{\sum_{i=1}^{4}s_i^2(n_i-1)}{\sum_{i=1}^{4}(n_i-1)}$$

$$=\frac{(4-1)\times 144.25+(3-1)\times 66.34+(3-1)\times 39.00+(4-1)\times 158.33}{(4-1)+(3-1)+(3-1)+(4-1)}$$

$$=111.842$$

$$C=1+\frac{1}{3\times(4-1)}\times\left[\sum_{i=1}^{4}\frac{1}{n_i-1}-\frac{1}{\sum_{i=1}^{4}(n_i-1)}\right]$$

$$=1+\frac{1}{3\times(4-1)}\times$$

$$\left[\frac{1}{4-1}+\frac{1}{3-1}+\frac{1}{3-1}+\frac{1}{4-1}-\frac{1}{(4-1)+(3-1)+(3-1)+(4-1)}\right]$$

$$=1.174$$

$$\chi^2=\frac{2.3026}{C}\left[\lg s_p^2\sum_{i=1}^{4}(n_i-1)-\sum_{i=1}^{4}(n_i-1)\lg s_i^2\right]$$

$$=\frac{2.3026}{1.174}\times\{\lg 111.842\times[(4-1)+(3-1)+(3-1)+(4-1)]-$$

$$[(4-1)\times\lg 144.25+(3-1)\times\lg 66.34+(3-1)\times\lg 39.00+$$

$$(4-1)\times\lg 158.33]\}=1.146$$

(4) 推断：查附表 4，当 $df=4-1=3$ 时，$\chi^2_{0.05}=7.81$。现实得 $\chi^2<\chi^2_{0.05}$，故 $P>0.05$，接受 H_0，即认为这 4 个样本的方差是同质的。

思考练习题

习题 4.1　什么是统计推断？统计推断有哪两种？其含义各是什么？

习题 4.2　什么是小概率原理？它在假设检验中有何作用？

习题 4.3　假设检验中的两类错误是什么？如何才能少犯两类错误？

习题 4.4　什么叫区间估计？什么叫点估计？置信度与区间估计有什么关系？

习题 4.5　某养殖场以往都用鲜活饵料喂养对虾，经多年的观测资料得知，成虾平均体重为 21g，标准差为 1.2g。现改用鲜活与人工配合饵料各半喂养对虾，随机抽取成虾 100 尾，测得平均体重为 20g。试问改变饵料后，对虾体重有无显著变化，并估计对虾体重的 95%置信区间。

习题 4.6　桃树枝条的常规含氮量为 2.40%，现对一桃树新品种枝条的含氮量进行了 10 次测定，其结果为 2.38，2.38，2.41，2.50，2.47，2.41，2.38，2.26，2.32，2.41(%)。试问该测定结果与桃树枝条常规含氮量有无差别。

习题 4.7　检查三化螟各世代每卵块的卵数，检查第一代 128 个卵块，其平均数为 47.3 粒，标准差为 25.4 粒；检查第二代 69 个卵块，其平均数为 74.9 粒，标准差为 46.8 粒。试检验两代每卵块的卵数有无显著差异。

习题 4.8　假说："北方动物比南方动物具有较短的附肢。"为验证这一假说，调查了如下鸟翅长(mm)资料。北方的：120，113，125，118，116，114，119；南方的：116，117，121，114，116，118，123，120。试检验这一假说。

习题 4.9　用中草药青木香治疗高血压，记录了 13 个病例，所测定的舒张压(mmHg)数据如下：

序号	1	2	3	4	5	6	7	8	9	10	11	12	13
治疗前	110	115	133	133	126	108	110	110	140	104	160	120	120
治疗后	90	116	101	103	110	88	92	104	126	86	114	88	112

试检验该药是否具有降低血压的作用。

习题 4.10　为测定 A、B 两种病毒对烟草的致病力，取 8 株烟草，每一株皆半叶接种 A 病毒，另半叶

接种 B 病毒，以叶面出现枯斑病的多少作为致病力强弱的指标，得结果如下：

株号	1	2	3	4	5	6	7	8
病毒 A	9	17	31	18	7	8	20	10
病毒 B	10	11	18	14	6	7	17	5

试检验两种病毒的致病能力是否有显著差异。

习题 4.11　有一批棉花种子，规定发芽率 $p > 80\%$ 为合格。现随机抽取 100 粒进行发芽试验，有 77 粒发芽。试估计：

(1) 该批棉花种子是否合格？

(2) 该批棉花种子发芽率所属总体的 95% 置信区间。

习题 4.12　调查了甲、乙两医院乳腺癌手术后 5 年的生存情况，甲医院共有 755 例，生存数为 485 人；乙医院共有 383 例，生存数为 257 人。问两医院乳腺癌手术后 5 年的生存率有无显著差别。

习题 4.13　用两种不同的饵料喂养同一品种鱼，一段时间后，测得每小池鱼的体重增加量(g) 如下。A 饵料：130.5，128.9，133.8；B 饵料：147.2，149.3，150.2，151.4。试检验 A、B 两种饵料间方差的同质性。

第五章

χ^2 检验

本章提要

χ^2 检验主要有 3 种用途：一个样本方差的同质性检验、适合性检验和独立性检验。适合性检验和独立性检验适用于离散型资料的假设检验，其基本原理是通过 χ^2 值的大小来检验观测值与理论值之间的偏离程度。适合性检验是比较观测值与理论值是否符合的假设检验。独立性检验是判断两个或两个以上因素之间是否具有关联关系的假设检验，常用列联表进行检验。

对计数资料和属性资料，即离散型资料的假设检验，可以采用第三章二项分布概率计算来进行，也可以采用第四章将次数转化为频率再计算其概率来进行，还可以采用 χ^2 检验(chi-square test)。计数资料和属性资料的 χ^2 检验一般有两种类型，即适合性检验和独立性检验。

第一节 χ^2 检验的原理与方法

从第三章中知道，χ^2 的原意是相互独立的多个正态离差平方值的和，由式(3.47)：

$$\chi^2=\sum_{i=1}^{k}\left(\frac{x-\mu}{\sigma}\right)^2=\frac{1}{\sigma^2}\sum_{i=1}^{k}(x-\mu)^2$$

当用 $\bar{x}$ 估计 μ 时，有

$$\chi^2=\frac{1}{\sigma^2}\sum_{i=1}^{k}(x-\bar{x})^2$$

由于 $s^2=\dfrac{\sum_{i=1}^{k}(x-\bar{x})^2}{k-1}$，可得

$$\chi^2=\frac{df\cdot s^2}{\sigma^2}=\frac{(k-1)s^2}{\sigma^2} \tag{5.1}$$

这是随自由度 $df=k-1$ 而变化的连续型变量的分布。

对计数资料或属性资料进行 χ^2 检验，其基本原理是应用观测值(observed value，O)与理论值(expected value，E)之间的偏离程度来决定其 χ^2 值的大小。观测值与理论值之

间偏差越大，越不符合；偏差越小，越趋于符合；若两个值完全相等时，表明观测值与理论值完全符合。在计算观测值 O 与理论值 E 之间的符合程度时，最简单的方法是比较两者差数的大小，但由于 $O-E$ 有正有负，则 $\sum(O-E)$ 趋近于零，不能真实地反映观测值与理论值差值的大小，故采用 $\sum(O-E)^2$，这样就可以解决正负抵消的问题。观测值与理论值相差越大，则 $\sum(O-E)^2$ 也越大，反之亦然。$\sum(O-E)^2$ 似乎可以度量观测值与理论值的相差程度，实际上这个绝对差异数还不足以表示相差程度。例如，在某动物育种试验中，两次试验得到 F_2 代数据资料如表 5-1 所示。

表 5-1　某动物育种试验 F_2 代资料

	观测值 O	理论值 E	$O-E$
试验一	204	200	4
试验二	24	28	−4

显然两次试验的 $(O-E)^2$ 都是 16，但二者不能等量齐观。对于 k 组资料，采用 $\sum\frac{(O-E)^2}{E}$ 使其转化为相对比值，这个值随 k 的增加渐近于自由度 $df=k-1$ 的 χ^2 值，即

$$\chi^2=\sum_{i=1}^{k}\frac{(O_i-E_i)^2}{E_i} \tag{5.2}$$

式中，O 为观测值；E 为理论值。

由式(5.2)可知，χ^2 最小值为 0，随着 χ^2 值的增大，观测值与理论值符合度越来越小，所以 χ^2 的分布是由 0 到无限大的变数。实际上其符合程度由 χ^2 概率决定，由 χ^2 值表(附表 4)可知，在一定自由度下，χ^2 值与概率 P 成反比，χ^2 值越小，P 值越大；χ^2 越大，P 值越小。因此，可由 χ^2 分布对计数资料或属性资料进行假设检验。χ^2 检验的步骤如下所述：

(1) 提出无效假设 H_0：观测值与理论值的差异由抽样误差引起，即观测值 = 理论值。同时给出相应的备择假设 H_A：观测值与理论值的差值不等于 0，即观测值 ≠ 理论值。

(2) 确定显著水平 α。一般可确定为 0.05 或 0.01。

(3) 计算样本的 χ^2。求得各个理论值 E_i，并根据各观测值 O_i，代入式(5.2)，计算样本的 χ^2。

(4) 进行统计推断。根据 $df=k-1$，从附表 4 中查出 χ^2_α 值，如果实得 $\chi^2<\chi^2_\alpha$，则 $P>\alpha$，应接受 H_0，否定 H_A，表明在 α 显著水平下观测值与理论值差异不显著，二者之间的差异是由抽样误差引起；如果实得 $\chi^2>\chi^2_\alpha$，则 $P<\alpha$，应否定 H_0，接受 H_A，表明在 α 显著水平下观测值与理论值差异是显著的，二者之间的差异是真实存在的。

由于 χ^2 分布是连续的，而计数资料或属性资料是离散的，故所得的 χ^2 值是一个近似值。为了使离散型变量的计算结果与连续型变量 χ^2 分布的概率相吻合，在计算 χ^2 时应注意以下两个问题：

(1) 任何一组的理论值 E_i 都必须大于 5，如果 $E_i\leqslant 5$，统计量会明显偏离 χ^2 分布，则

需要并组或增大样本容量，以满足 $E_i > 5$。

(2) 在自由度 $df = 1$ 时，需进行连续性矫正，其矫正的 χ_c^2 为

$$\chi_c^2 = \sum_{i=1}^{k} \frac{(|O_i - E_i| - 0.5)^2}{E_i} \tag{5.3}$$

对同一资料，进行矫正的 χ_c^2 值要比未矫正的 χ^2 值小。当自由度 $df \geqslant 2$ 时，由于 χ_c^2 与 χ^2 相差不大，所以一般不再进行连续性矫正。

第二节　适合性检验

比较观测值与理论值是否符合的假设检验称为适合性检验(compatibility test)。这种方法是对样本的理论值先通过一定的理论分布推算出来，然后用观测值与理论值比较，从而得出观测值与理论值之间是否吻合的结论，因此适合性检验也称为吻合性检验或拟合优度检验(goodness of fit test)。例如，在遗传学上，常用 χ^2 检验来测定所得的结果是否符合孟德尔分离规律、自由组合规律等。许多与已有理论比率进行比较的资料，也可用 χ^2 来作适合性检验。适合性检验是 χ^2 检验最常用的方法之一。

作适合性检验时，可提出无效假设 $H_0: O - E = 0$，即认为观测值与理论值之间没有差异，再计算样本 χ^2 值，根据规定的显著性水平 α 和自由度 df 从 χ^2 值表中查出 χ_α^2，当 $\chi^2 > \chi_\alpha^2$ 时，拒绝 H_0，接受 H_A；当 $\chi^2 < \chi_\alpha^2$ 时，接受 H_0。

【例 5.1】 有一个鲤鱼遗传试验，以荷包红鲤(红色，隐性)与湘江野鲤(青灰色，显性)杂交，其 F_2 代获得如表 5-2 所列的体色分离尾数，问这一资料的实际观测值是否符合孟德尔一对等位基因的遗传规律，即鲤鱼体色青：红=3：1?

表 5-2　鲤鱼遗传试验 F_2 代观测结果　　(单位：尾)

体色	青灰色	红色	总数
F_2 代观测尾数/尾	1503	99	1602

本例为判断实际观测值与理论比率是否相符的问题，属于典型的适合性检验问题。

(1) H_0：鲤鱼体色 F_2 代性状分离符合 3：1 比率；

H_A：鲤鱼体色 F_2 代性状分离不符合 3：1 比率。

(2) 取显著水平 $\alpha = 0.01$。

(3) 计算统计数 χ^2：由于该资料只有 $k=2$ 组，故自由度 $df = k - 1 = 2 - 1 = 1$，因而计算 χ^2 时需要进行连续性矫正。

在无效假设 H_0 正确的前提下，青灰色鲤鱼的理论值为

$$E_1 = 1602 \times \frac{3}{4} = 1201.5$$

红色鲤鱼的理论值为

$$E_2 = 1602 \times \frac{1}{4} = 400.5$$

将实际观测值与理论值代入式(5.3)，有

$$\chi_c^2=\sum_{i=1}^{2}\frac{(|O_i-E_i|-0.5)^2}{E_i}$$

$$=\frac{(|1503-1201.5|-0.5)^2}{1201.5}+\frac{(|99-400.5|-0.5)^2}{400.5}$$

$$=75.41+226.22=301.63$$

(4) 查 χ^2 值表，当 $df=1$ 时，$\chi^2_{0.01}=6.63$。现实得 $\chi_c^2=301.63$，远大于 $\chi^2_{0.01}$，故应否定 H_0，接受 H_A，即认为鲤鱼体色 F_2 代性状分离不符合 3∶1 比率。

遗传学中，有许多显性、隐性比率可以划分为两组的资料，如欲测其与某种理论比率的适合性，则 χ^2 值也可用表 5-3 中的简式进行计算。

表 5-3　检验两组资料与某种理论比率符合度的 χ^2 值公式

理论比率(显性∶隐性)	χ^2 值计算公式
1∶1	$\frac{(\lvert A-a\rvert-1)^2}{n}$
2∶1	$\frac{(\lvert A-2a\rvert-1.5)^2}{2n}$
3∶1	$\frac{(\lvert A-3a\rvert-2)^2}{3n}$
15∶1	$\frac{(\lvert A-15a\rvert-8)^2}{15n}$
9∶7	$\frac{(\lvert 7A-9a\rvert-8)^2}{63n}$
r∶1	$\frac{\left(\lvert A-ra\rvert-\frac{r+1}{2}\right)^2}{rn}$
r∶m	$\frac{\left(\lvert mA-ra\rvert-\frac{r+m}{2}\right)^2}{rmn}$

注：A 为显性实际观测值，a 为隐性实际观测值，$n=A+a$

【例 5.2】 进行大豆花色的遗传研究，共观测 F_2 代 289 株，其中紫色 208 株，白色 81 株，试检验大豆花色分离是否符合 3∶1 的分离规律？

(1) H_0：大豆花色 F_2 代性状分离符合 3∶1 比率；

H_A：大豆花色 F_2 代性状分离不符合 3∶1 比率。

(2) 取显著水平 $\alpha=0.05$。

(3) 由表 5-3 计算统计数 χ^2 值：

$$\chi^2=\frac{(|A-3a|-2)^2}{3n}=\frac{(|208-3\times81|-2)^2}{3\times289}=1.256$$

(4) 查 χ^2 值表，当 $df=1$ 时，$\chi^2_{0.05}=3.84$。现计算所得 $\chi^2=1.256<\chi^2_{0.05}$，故应接受 H_0，即大豆花色 F_2 代性状分离符合 3∶1 比率。

【例 5.3】 孟德尔用豌豆的两对相对性状进行杂交实验，黄色圆滑种子与绿色皱缩种子的豌豆杂交后，F_2 代分离的情况为：黄圆 315 粒、黄皱 101 粒、绿圆 108 粒、绿皱 32 粒，共 556 粒，问此结果是否符合自由组合规律？

根据自由组合规律，各性状理论分离比为

$$\text{黄圆}:\text{黄皱}:\text{绿圆}:\text{绿皱}=\frac{9}{16}:\frac{3}{16}:\frac{3}{16}:\frac{1}{16}$$

将以上数据进行整理，列于表 5-4。

表 5-4 豌豆杂交实验 F_2 代数据资料计算表

项目	黄圆	黄皱	绿圆	绿皱
观测数(O)	315	101	108	32
理论频数(P)	$\frac{9}{16}$	$\frac{3}{16}$	$\frac{3}{16}$	$\frac{1}{16}$
理论数(E)	312.75	104.25	104.25	34.75
$O-E$	2.25	−3.25	3.75	−2.75
$\frac{(O-E)^2}{E}$	0.016	0.101	0.135	0.218

(1) H_0：豌豆 F_2 代分离比符合 9∶3∶3∶1 的自由组合规律；

H_A：豌豆 F_2 代分离比不符合 9∶3∶3∶1 的自由组合规律。

(2) 取显著水平 $\alpha=0.05$。

(3) 计算统计数 χ^2：

$$\chi^2=\sum_{i=1}^{k}\frac{(O_i-E_i)^2}{E_i}=0.016+0.101+0.135+0.218=0.470$$

(4) 本例中，$df=4-1=3$，查 χ^2 值表，得 $\chi^2_{0.05}=7.81$。由于实得 $\chi^2<\chi^2_{0.05}$，所以应接受 H_0，认为 F_2 代分离比符合 9∶3∶3∶1 的自由组合规律。

对于资料组数多于两组的 χ^2 值，还可通过下面简式进行计算：

$$\chi^2=\frac{1}{n}\sum\frac{O_i^2}{p_i}-n \tag{5.4}$$

式中，O_i 为第 i 组的观测数；p_i 为第 i 组的理论比率；n 为总次数。

按式(5.4)进行 χ^2 值的计算：

$$\begin{aligned}\chi^2&=\frac{1}{n}\sum\frac{O_i^2}{p_i}-n\\&=\frac{1}{556}\times\left(\frac{315^2}{\frac{9}{16}}+\frac{101^2}{\frac{3}{16}}+\frac{108^2}{\frac{3}{16}}+\frac{32^2}{\frac{1}{16}}\right)-556\\&=0.470\end{aligned}$$

对于例 5.3 中两对等位基因 F_2 代的分离，假设 F_2 代性状分离符合 9∶3∶3∶1 的自由组合分离比率，式(5.4)可表示为

$$\chi^2=\frac{16(O_1^2+3O_2^2+3O_3^2+9O_4^2)}{9n}-n \tag{5.5}$$

根据式(5.5)，对例 5.3 进行 χ^2 值的计算如下：

$$\begin{aligned}\chi^2&=\frac{16(O_1^2+3O_2^2+3O_3^2+9O_4^2)}{9n}-n\\&=\frac{16\times(315^2+3\times101^2+3\times108^2+9\times32^2)}{9\times556}-556\\&=0.470\end{aligned}$$

由以上计算结果可知，用式(5.4)和式(5.5)进行计算的χ^2结果与按式(5.2)计算的结果是完全一样的。

第三节　独立性检验

独立性检验(independence test)是研究两个或两个以上因子彼此之间是相互独立的还是相互影响的一类统计方法。例如，检验患慢性气管炎病和吸烟有无关系，若无关系则说明两者是独立的；若有关系，说明吸烟能诱发气管炎病。这种关系是否达到显著呢？可以进行χ^2检验。具体做法是，提出无效假设，假设所观测的各属性之间没有关联，根据无效假设计算理论值，在一定的自由度下以给定的显著性水平作出推断，最后证明无效假设是否成立。若拒绝无效假设，则说明两个因子之间的关联是显著的；若接受无效假设，则说明两个因子之间无关联，是相互独立的。独立性检验的形式有多种，常利用列联表(contingency table)进行检验。

一、2×2列联表的独立性检验

设A、B是一个随机试验中的两个事件，其中A可能出现r_1、r_2个结果，B可能出现c_1、c_2个结果，两因子相互作用形成4格数，分别以O_{11}、O_{12}、O_{21}、O_{22}表示，表5-5即为2×2列联表的一般形式。

表5-5　2×2列联表的一般形式

$A(i)$	$B(j)$		总和
	c_1	c_2	
r_1	O_{11}	O_{12}	$R_1=O_{11}+O_{12}$
r_2	O_{21}	O_{22}	$R_2=O_{21}+O_{22}$
总和	$C_1=O_{11}+O_{21}$	$C_2=O_{12}+O_{22}$	T

2×2列联表的χ^2检验需经以下步骤：

(1) 提出无效假设H_0：事件A和事件B无关，即事件A和事件B相互独立。同时给出H_A：事件A和事件B有关联关系。

(2) 给出显著水平α。

(3) 依据H_0，可以推算出理论值，计算χ^2值。

(4) 确定自由度，$df=(r-1)(c-1)$，即(行−1)(列−1)。查附表4得χ^2_α，进行推断。如果所计算的$\chi^2>\chi^2_\alpha$，则$P<\alpha$，应否定H_0，接受H_A，表明事件A和事件B有关联关系观测值与理论值是不一致；若$\chi^2<\chi^2_\alpha$，则$P>\alpha$，应接受H_0，否定H_A，表明事件A和事件B相互独立。

【例5.4】 现随机抽样对吸烟人群和不吸烟人群是否患有气管炎病进行了调查，其调查结果如表5-6所示，试检验吸烟与患气管炎病有无关联？

表 5-6 不同人群患气管炎病调查资料 （单位：人）

不同人群	患病	不患病	总和(R_i)	患病率/%
吸烟人群	50(33)	250(267)	300	16.67
不吸烟人群	5(22)	195(178)	200	2.50
总和(C_j)	55	445	$T=500$	

注：括号内数据为理论值

(1) H_0：吸烟与患气管炎病无关；H_A：吸烟与患气管炎病有关联。

(2) 确定显著水平 $\alpha=0.01$。

(3) 计算统计数 χ^2。

先计算列联表中各项的理论值。

吸烟且患病人数：$E_{11}=\dfrac{R_1C_1}{T}=\dfrac{300\times55}{500}=33$

吸烟未患病人数：$E_{12}=\dfrac{R_1C_2}{T}=\dfrac{300\times445}{500}=267$

不吸烟且患病人数：$E_{21}=\dfrac{R_2C_1}{T}=\dfrac{200\times55}{500}=22$

不吸烟不患病人数：$E_{22}=\dfrac{R_2C_2}{T}=\dfrac{200\times445}{500}=178$

由于本例中自由度 $df=(r-1)(c-1)=(2-1)\times(2-1)=1$，故所计算的 χ^2 需进行连续性矫正，于是有

$$\chi_c^2=\sum\frac{(|O-E|-0.5)^2}{E}$$

$$=\frac{(|50-33|-0.5)^2}{33}+\frac{(|250-267|-0.5)^2}{267}$$

$$+\frac{(|5-22|-0.5)^2}{22}+\frac{(|195-178|-0.5)^2}{178}$$

$$=8.250+1.020+12.375+1.529=23.174$$

(4) 查 χ^2 表，当 $df=1$ 时，$\chi^2_{0.01}=6.63$，而 $\chi_c^2=23.174>\chi^2_{0.01}$，$P<0.01$，应拒绝 H_0，接受 H_A，说明吸烟与患气管炎病密切相关，吸烟人群和不吸烟人群相比，患病率有极显著的提高。

2×2 列联表的 χ^2 值也可由下面公式计算得出：

$$\chi^2=\frac{\left(|O_{11}O_{22}-O_{12}O_{21}|-\dfrac{T}{2}\right)^2T}{R_1R_2C_1C_2} \tag{5.6}$$

对例 5.4，用式(5.6)进行计算，所得 χ^2 为

$$\chi^2=\frac{\left(|O_{11}O_{22}-O_{12}O_{21}|-\dfrac{T}{2}\right)^2T}{R_1R_2C_1C_2}$$

$$=\frac{\left(|50\times195-250\times5|-\dfrac{500}{2}\right)^2\times500}{300\times200\times55\times445}=23.174$$

其计算结果与前述结果相同。

二、2×c 列联表的独立性检验

生物学研究中，经常遇到的是 2×2 列联表，但有时也会遇到 2×c 列联表，即横行分为两组，纵列分为 $c \geqslant 3$ 组的资料。2×c 列联表的一般形式如表 5-7 所示。

表 5-7　2×c 列联表的一般形式

(i)	(j)				总和
	1	2	…	c	
1	O_{11}	O_{12}	…	O_{1c}	R_1
2	O_{21}	O_{22}	…	O_{2c}	R_2
总和	C_1	C_2	…	C_c	T

2×c 列联表理论值的计算和 2×2 列联表一样，自由度 $df=(2-1)(c-1)=c-1$，由于 $c \geqslant 3$，故 $df \geqslant 2$，因此计算 χ^2 时不需作连续性矫正。

【例 5.5】 检测甲、乙、丙 3 种农药对烟蚜的毒杀效果，结果如表 5-8 所示。试分析这 3 种农药对烟蚜的毒杀效果是否一致？

表 5-8　3 种农药毒杀烟蚜的试验资料　　(单位：只)

烟蚜毒杀效果	甲	乙	丙	总和
死亡数	37(49.00)	49(39.04)	23(20.96)	109
未死亡数	150(138.00)	100(109.96)	57(59.04)	307
总和	187	149	80	416

注：括号内数据为理论值

(1) H_0：对烟蚜毒杀效果与农药类型无关；H_A：二者有关。

(2) 取显著水平 $\alpha=0.05$。

(3) 统计数的计算。

先计算理论值(填入上表括号内)：

$$E_{11}=\frac{109\times 187}{416}=49.00$$

$$E_{12}=\frac{109\times 149}{416}=39.04$$

$$E_{13}=\frac{109\times 80}{416}=20.96$$

$$E_{21}=\frac{307\times 187}{416}=138.00$$

$$E_{22}=\frac{307\times 149}{416}=109.96$$

$$E_{23}=\frac{307\times 80}{416}=59.04$$

再计算 χ^2 值：

$$\chi^2=\frac{(37-49.00)^2}{49.00}+\frac{(49-39.04)^2}{39.04}+\frac{(23-20.96)^2}{20.96}$$
$$+\frac{(150-138.00)^2}{138.00}+\frac{(100-109.96)^2}{109.96}+\frac{(57-59.04)^2}{59.04}$$
$$=2.938+2.541+0.198+1.043+0.902+0.070$$
$$=7.692$$

(4) 查 χ^2 表，当自由度 $df=(2-1)\times(3-1)=2$ 时，$\chi^2_{0.05}=5.99$。现实得 $\chi^2=7.692>\chi^2_{0.05}$，则拒绝 H_0，接受 H_A，说明 3 种农药对烟蚜的毒杀效果不一致。为计算方便，也可不计算理论值，直接代入下面公式：

$$\chi^2=\frac{T^2}{R_1R_2}\left[\sum\left(\frac{O_{1j}^2}{C_j}\right)-\frac{R_1^2}{T}\right] \tag{5.7}$$

将表 5-8 中的数据代入式(5.7)，得

$$\chi^2=\frac{416^2}{109\times307}\times\left[\left(\frac{37^2}{187}+\frac{49^2}{149}+\frac{23^2}{80}\right)-\frac{109^2}{416}\right]=7.692$$

两种计算方法所得结果相同。

三、$r\times c$ 列联表的独立性检验

$r\times c$ 列联表是指 $r\geqslant3$、$c\geqslant3$ 的计数资料，表 5-9 是 $r\times c$ 列联表的一般形式。

表 5-9 $r\times c$ 列联表的一般形式

(i)	(j)				总和
	1	2	…	c	
1	O_{11}	O_{12}	…	O_{1c}	R_1
2	O_{21}	O_{22}	…	O_{2c}	R_2
⋮	⋮	⋮		⋮	⋮
r	O_{r1}	O_{r2}	…	O_{rc}	R_r
总和	C_1	C_2	…	C_c	T

$r\times c$ 列联表各项理论数的计算方法与 2×2 列联表及 $2\times c$ 列联表一样，即 $E_{ij}=\frac{R_iC_j}{T}$，其自由度 $df=(r-1)(c-1)$，由于 $r\geqslant3$，$c\geqslant3$，所以 $df>1$，计算 χ^2 时不需要进行连续性矫正。其 χ^2 值亦可由下式进行计算：

$$\chi^2=T\left[\sum\left(\frac{O_{ij}^2}{R_iC_j}\right)-1\right] \tag{5.8}$$

式中，$i=1,2,\cdots,r$；$j=1,2,\cdots,c$。

【例 5.6】 某医院用碘剂治疗地方性甲状腺肿，不同年龄的治疗效果列于表 5-10 中。试检验不同年龄的治疗效果有无差异？

表 5-10　不同年龄用碘剂治疗甲状腺肿效果比较　　(单位:人)

年龄/岁	治愈	显效	好转	无效	总和
11～30	67(45.29)	9(17.87)	10(22.02)	5(5.82)	91
31～50	32(39.32)	23(15.51)	20(19.12)	4(5.05)	79
50 以上	10(24.39)	11(9.62)	23(11.86)	5(3.13)	49
总和	109	43	53	14	219

注:括号内数据为理论值

(1) H_0:治疗效果与年龄无关;H_A:治疗效果与年龄有关,即不同年龄治疗效果不同。

(2) 确定显著水平 $\alpha=0.01$。

(3) 计算统计数 χ^2:

$$\chi^2=T\left[\sum\left(\frac{O_{ij}^2}{R_iC_j}\right)-1\right]$$

$$=219\times\left(\frac{67^2}{91\times109}+\frac{9^2}{91\times43}+\cdots+\frac{5^2}{49\times14}-1\right)$$

$$=46.988$$

(4) 查 χ^2 表,当 $df=(4-1)\times(3-1)=6$ 时,$\chi^2_{0.01}=16.81$,所以 $\chi^2=46.988>\chi^2_{0.01}$,$P<0.01$,应拒绝 H_0,接受 H_A,说明治疗效果与年龄有关。

在治疗效果与年龄有关的基础上,可以将表 5-10 的 3×4 列联表做成 3 个 2×4 列联表,检验两个年龄段疗效的差异。

a. 11～30 岁与 31～50 岁两个年龄段疗效比较:

$$\chi^2=(91+79)\times\left[\frac{67^2}{91\times(67+32)}+\frac{9^2}{91\times(9+23)}+\cdots+\frac{4^2}{79\times(5+4)}-1\right]$$

$$=21.202$$

b. 11～30 岁与 50 岁以上两个年龄段疗效比较:

$$\chi^2=(91+49)\times\left[\frac{67^2}{91\times(67+10)}+\frac{9^2}{91\times(9+11)}+\cdots+\frac{5^2}{49\times(5+5)}-1\right]$$

$$=38.369$$

c. 31～50 岁与 50 岁以上年龄段疗效比较:

$$\chi^2=(79+49)\times\left[\frac{32^2}{79\times(32+10)}+\frac{23^2}{79\times(23+11)}+\cdots+\frac{5^2}{49\times(4+5)}-1\right]$$

$$=9.574$$

以上 3 个 χ^2 值的自由度 $df=(2-1)\times(4-1)=3$,查 χ^2 值表,$\chi^2_{0.05}=7.81$,$\chi^2_{0.01}=11.34$,表明 11～30 岁与 31～50 岁、50 岁以上年龄段间疗效差异极显著,31～50 岁与 50 岁以上年龄段间疗效差异显著。

思考练习题

习题 5.1　χ^2 主要有几种用途?各自用于什么情况下的假设检验?

习题 5.2　χ^2 检验的主要步骤有哪些?什么情况下 χ^2 需要进行连续性矫正?

习题 5.3　某林场狩猎得到 143 只野兔,其中雄性 57 只,雌性 86 只。试检验该野兔的性别比例是

否符合 1∶1?

习题 5.4 有一大麦杂交组合,F_2 代的芒性状表型有钩芒、长芒和短芒 3 种,观察计得其株数依次分别为 348、115、157。试检验其比率是否符合 9∶3∶4 的理论比率。

习题 5.5 某乡 10 岁以下的 747 名儿童中有 421 名男孩,用 95%的置信水平,估计这群儿童的性别比例是否合理?

习题 5.6 某仓库调查不同品种苹果的耐贮情况,随机抽取'国光'苹果 200 个,腐烂 14 个;'红星'苹果 178 个,腐烂 16 个。试检验这两种苹果耐贮差异是否显著。

习题 5.7 5 个小麦品种感染赤霉病(株)的情况如下表。试分析小麦赤霉病的发生与品种是否有关。

品种	*A*	*B*	*C*	*D*	*E*	总和
健株数	442	460	478	376	494	2250
病株数	78	39	35	298	50	500
总和	520	499	513	674	544	2750

习题 5.8 调查了 3 种灌溉方式下水稻叶片衰老资料(片)如下表所示。试检验叶片衰老与灌溉方式是否有关。

灌溉方式	绿叶数	黄叶数	枯叶数	总和
深水	146	7	7	160
浅水	183	9	13	205
湿润	152	14	16	182
总和	481	30	36	547

第六章

方差分析

本章提要

方差分析是英国统计学家 R.A.Fisher 提出的对两个或多个样本平均数差异显著性检验的方法。它的基本思想是将测量数据的总变异按照变异来源分解为处理(组间)效应和误差(组内)效应,并作出其数量估计,从而确定试验处理对研究结果影响力的大小。按因素划分,可分为单因素方差分析、二因素方差分析和多因素方差分析。单因素方差分析主要对因素的主效应进行分析,而二因素方差分析、多因素方差分析则对因素的主效和互作进行分析。方差分析的基本步骤包括总平方和分解、总自由度分解和 F 检验,若 F 检验显著,需要进行多重比较。常用的多重比较方法有最小显著差数法和最小显著极差法。方差分析必须满足正态性、可加性和方差同质性 3 个基本假定,如果数据不符合这 3 个假定则需要对数据进行转换。对于缺失的数据可以利用误差平方和最小的原则进行弥补。

通过第四章的学习,我们了解了对于样本平均数的假设检验,可将 u 检验(或 t 检验)用于样本平均数与总体平均数及两个样本平均数间的差异显著性检验。在实际研究过程中,常需要对 3 个及 3 个以上样本平均数进行比较。此时如果仍用 u 检验(或 t 检验)对其平均数进行两两相互比较,比较的次数会随着样本平均数个数的增加而剧增。例如,n 个样本平均数需要比较的次数为 C_n^2。这样会导致以下问题出现:① 检验过程繁琐;② 无统一的试验误差,误差估计的精确性和检验的灵敏性低;③ 推断的可靠性降低,犯 α 错误的概率增加。而使用方差分析可以有效解决这些问题。

方差分析(analysis of variance,ANOVA)又称为变量分析,是英国著名统计学家 R.A.Fisher 于 1923 年提出的。方差分析是将所有处理的观测值作为一个整体,一次比较就对所有各组间样本平均数是否有差异作出判断。如果差异不显著,则认为它们都是相同的;如果差异显著,再进一步比较是哪组数据与其他数据不同。

方差分析的用途非常广泛,可用于多个样本平均数的比较、分析多个因素间的交互作用、回归方程的假设检验、方差的同质性检验等。本章主要介绍多个样本平均数的比较,

并对多个因素间的交互作用进行分析。

第一节　方差分析的基本方法

一、方差分析的基本原理

在一个试验中，可以得出一系列不同的观测值。造成观测值不同的原因是多方面的，可能是由于处理因素不同引起的，即处理效应(treatment effect)；也可能是由于试验过程中偶然性因素的干扰和测量误差所致，即误差效应(error effect)。方差分析的基本思想就是将测量数据的总变异按照变异原因不同分解为处理效应和误差效应，并作出其数量估计。

反映测量数据变异性的指标有多个，在方差分析中选用方差，即均方(mean square)来度量资料的变异程度。要正确认识观测值的变异是由处理效应还是误差效应引起的，我们可以分别计算出处理效应的均方和误差效应的均方，在一定显著水平下进行比较，如果二者相差不大，说明试验处理对指标影响不大；如果二者相差较大，处理效应比试验误差大得多，则说明试验处理影响是很大的，不可忽视。

二、数学模型

方差分析的数学模型(mathematical model)就是指试验资料的数据结构，或者是每一个观测值的线性组成。以单因素试验为例，假设试验考察的因素有 k 个水平，每个处理重复 n 次，则共有 nk 个观测值。这类资料的数据模式可用表 6-1 来表示。

表 6-1　每组具 n 个观测值的 k 组样本数据资料

处理	A_1	A_2	…	A_i	…	A_k	
	x_{11}	x_{21}	…	x_{i1}	…	x_{k1}	
	x_{12}	x_{22}	…	x_{i2}	…	x_{k2}	
	⋮	⋮		⋮		⋮	
	x_{1j}	x_{2j}	…	x_{ij}	…	x_{kj}	
	⋮	⋮		⋮		⋮	
	x_{1n}	x_{2n}	…	x_{in}	…	x_{kn}	
总和 $T_i.$	$T_1.$	$T_2.$	…	$T_i.$	…	$T_k.$	$T=\sum x_{ij}$
平均 $\bar{x}_{i.}$	$\bar{x}_{1.}$	$\bar{x}_{2.}$	…	$\bar{x}_{i.}$	…	$\bar{x}_{k.}$	$\bar{x}_{..}$

表6-1中，x_{ij} 表示第 i 个处理的第 j 个观测值($i=1,2,\cdots,k$；$j=1,2,\cdots,n$)，对于任意一个 x_{ij}，可用线性可加模型来进行描述，即

$$x_{ij}=\mu_i+\varepsilon_{ij} \tag{6.1}$$

式中，μ_i 为第 i 个处理观测值总体平均数；ε_{ij} 为试验误差，要求 ε_{ij} 是相互独立的，且服从正态分布 $N(0,\sigma^2)$。

对于总体平均数 μ，有

$$\mu=\frac{1}{k}\sum_{i=1}^{k}\mu_i \tag{6.2}$$

令 τ_i 为第 i 个处理的效应，则

$$\tau_i = \mu_i - \mu \tag{6.3}$$

将式(6.3)代入式(6.1)中，则有

$$x_{ij} = \mu + \tau_i + \varepsilon_{ij} \tag{6.4}$$

式(6.4)就称为单因素试验资料的数学模型(mathematical model)。由式(6.4)可知这类数学模型是一种线性模型(linear model)，它将观测值分解为影响观测值大小的各个因素效应的线性组合。同理，对于由样本估计的线性模型为

$$x_{ij} = \bar{x} + t_i + e_{ij} \tag{6.5}$$

式中，$\bar{x}$ 为样本平均数；t_i 为样本的第 i 处理的效应；e_{ij} 为试验误差。

依据对 τ_i 的不同假定，数学模型可分为固定模型、随机模型和混合模型。

(一) 固定模型

固定模型(fixed model)是指各个处理的效应 τ_i 是固定的一个常量，是由固定因素引起的效应，且 $\sum \tau_i = 0$。在试验中，我们只能讨论参加试验的个体而不是随机选择的样本，也就是说除去随机误差之后每个处理所产生的效应是固定的，分析的目的在于研究 τ_i。试验因素的各水平常常是根据试验目的事先主观选定的，而不是随机选定的，如不同温度条件下小麦籽粒的发芽试验，不同月龄小白鼠抗药性的试验等。在这些试验中，因素的水平是特意选择的，得到的结论仅适合于方差分析中所选定的几个水平，不能扩展到未加考虑的其他水平。

(二) 随机模型

随机模型(random model)是指各处理的效应值 τ_i 不是一个常量，是由随机因素所引起的效应。这里 τ_i 是一个随机变量，是从 $N(0,\sigma^2)$ 的正态总体中得到的一个随机变量，研究的目的不仅是处理效应 τ_i，还有 τ_i 的变异程度。例如，将从美国引进的黑核桃品种在不同纬度生态条件下种植，观察该品种对不同地理条件的适应情况，由于各地的气候、水肥、土壤条件是无法人为控制的，属于随机因素，需要用随机模型来处理。由试验所得出的结论可以推广到随机因素的所有水平上。

(三) 混合模型

在多因素试验中，若既包括固定效应的试验因素，又包括随机效应的试验因素，则该试验对应于混合模型(mixed model)。例如，为推断全国 6 ～ 7 岁男性儿童的身高发育是否平衡，从所有省(直辖市、自治区)中随机抽取 3 个省，每个省又分为城市和农村两类地区，各抽取 20 例数据进行分析。其中城市与农村两个水平组成的地区是固定因素，省份的 3 个水平是通过抽样确定的，是随机因素。该试验资料则对应于混合模型。

不同的模型在平方和及自由度的计算上是相同的，但在进行假设检验时 F 值的计算公式是不同的。另外，模型分析的侧重点也不完全相同。固定模型侧重于效应值 τ_i 的估计和比较，而随机模型则侧重效应方差的估计和检验。对于单因素方差分析来说，固定模

型和随机模型无多大区别。

三、平方和与自由度的分解

表 6-1 中全部观测值的总变异可以用总体方差来度量。方差(即均方)是离均差平方和(sum of square,SS)除以自由度的商。因此,要把一个试验资料的总变异依据变异来源分解为相应的变异,首先要将总平方和(total sum of square)与总自由度(total degree of freedom)分解为各个变异来源的相应部分。

(一) 平方和分解

从方差分析的基本指导思想出发,引起观测值变异的原因有处理效应和误差效应。处理间平均数的差异由处理效应所致,同一处理内的变异则由随机误差引起。根据线性可加数学模型。对于任一观测值 x_{ij} 与总平均数 $\bar{x}_{..}$ 之差可以表示为

$$(x_{ij}-\bar{x}_{..})=(x_{ij}-\bar{x}_{i.})+(\bar{x}_{i.}-\bar{x}_{..})$$

等式两边平方:

$$\begin{aligned}(x_{ij}-\bar{x}_{..})^2&=[(x_{ij}-\bar{x}_{i.})+(\bar{x}_{i.}-\bar{x}_{..})]^2\\&=(x_{ij}-\bar{x}_{i.})^2+2(x_{ij}-\bar{x}_{i.})(\bar{x}_{i.}-\bar{x}_{..})+(\bar{x}_{i.}-\bar{x}_{..})^2\end{aligned}$$

每一处理 n 个观测值离均差平方和累加,有

$$\sum_{j=1}^{n}(x_{ij}-\bar{x}_{..})^2=\sum_{j=1}^{n}(x_{ij}-\bar{x}_{i.})^2+2\sum_{j=1}^{n}(x_{ij}-\bar{x}_{i.})(\bar{x}_{i.}-\bar{x}_{..})+\sum_{j=1}^{n}(\bar{x}_{i.}-\bar{x}_{..})^2$$

由于 $2\sum_{j=1}^{n}(x_{ij}-\bar{x}_{i.})(\bar{x}_{i.}-\bar{x}_{..})=2(\bar{x}_{i.}-\bar{x}_{..})\sum_{j=1}^{n}(x_{ij}-\bar{x}_{i.})=0$,则

$$\sum_{j=1}^{n}(x_{ij}-\bar{x}_{..})^2=\sum_{j=1}^{n}(x_{ij}-\bar{x}_{i.})^2+\sum_{j=1}^{n}(\bar{x}_{i.}-\bar{x}_{..})^2=\sum_{j=1}^{n}(x_{ij}-\bar{x}_{i.})^2+n(\bar{x}_{i.}-\bar{x}_{..})^2$$

把 k 个处理的离均差平方再累加,得

$$\sum_{i=1}^{k}\sum_{j=1}^{n}(x_{ij}-\bar{x}_{..})^2=\sum_{i=1}^{k}\sum_{j=1}^{n}(x_{ij}-\bar{x}_{i.})^2+n\sum_{i=1}^{k}(\bar{x}_{i.}-\bar{x}_{..})^2$$

上式可简写为

$$\sum_{1}^{k}\sum_{1}^{n}(x_{ij}-\bar{x}_{..})^2=\sum_{1}^{k}\sum_{1}^{n}(x_{ij}-\bar{x}_{i.})^2+n\sum_{1}^{k}(\bar{x}_{i.}-\bar{x}_{..})^2 \tag{6.6}$$

式中,$\sum_{1}^{k}\sum_{1}^{n}(x_{ij}-\bar{x}_{..})^2$ 为总平方和,用 SS_T 表示;$n\sum_{1}^{k}(\bar{x}_{i.}-\bar{x}_{..})^2$ 为处理间(组间)平方和,用 SS_t 表示;$\sum_{1}^{k}\sum_{1}^{n}(x_{ij}-\bar{x}_{i.})^2$ 为处理内(组内)平方和,用 SS_e 表示。

因此,式(6.6)可表示为

$$SS_T=SS_t+SS_e \tag{6.7}$$

即总平方和=处理间平方和+处理内平方和。

实际计算时,SS_T 及 SS_t 可用下面的推导公式:

$$SS_T=\sum_1^k\sum_1^n(x_{ij}-\bar{x}_{..})^2$$
$$=\sum(x_{ij})^2-2\sum(x_{ij})\bar{x}_{..}+\sum(\bar{x}_{..})^2$$
$$=\sum(x_{ij})^2-\frac{(\sum x_{ij})^2}{nk}=\sum(x_{ij})^2-\frac{T^2}{nk}$$

令矫正数 $C=\frac{T^2}{nk}$，则

$$SS_T=\sum x_{ij}{}^2-C \tag{6.8}$$

$$SS_t=n\sum_1^k(\bar{x}_{i\cdot}-\bar{x}_{..})^2=n\sum_1^k(\bar{x}_{i\cdot}^2-2\bar{x}_{i\cdot}\bar{x}_{..}+\bar{x}_{..}^2)$$
$$=n\sum_1^k\bar{x}_{i\cdot}^2-2nk\bar{x}_{..}^2+nk\bar{x}_{..}^2=n\sum_1^k\bar{x}_{i\cdot}^2-nk\bar{x}_{..}^2$$
$$=n\sum_1^k\left(\frac{T_{i\cdot}}{n}\right)^2-nk\left(\frac{T}{nk}\right)^2=\frac{\sum_1^k T_{i\cdot}^2}{n}-C$$

即

$$SS_t=\frac{1}{n}\sum T_{i\cdot}^2-C \tag{6.9}$$

$$SS_e=SS_T-SS_t \tag{6.10}$$

(二) 自由度分解

总自由度也可分解为处理间自由度和处理内自由度，即总自由度＝处理间自由度＋处理内自由度，用公式表示为

$$df_T=df_t+df_e \tag{6.11}$$

式中，df_T 为总自由度；df_t 为处理间自由度；df_e 为处理内自由度，其中

$$df_T=nk-1 \tag{6.12}$$

$$df_t=k-1 \tag{6.13}$$

$$df_e=df_T-df_t=(nk-1)-(k-1)=k(n-1) \tag{6.14}$$

(三) 计算方差

根据各变异部分的平方和与自由度，计算处理间方差 s_t^2 和处理内方差 s_e^2：

$$s_t^2=\frac{SS_t}{df_t} \tag{6.15}$$

$$s_e^2=\frac{SS_e}{df_e} \tag{6.16}$$

【例 6.1】 某花卉研究所为促进芦荟生长，提高其经济效益，研究了 4 种不同配方的营养土对芦荟生长的影响。选取初始高度一致的试管苗 20 株，随机分成 4 组，一段时间后测量各处理试管苗株高，数据如表 6-2 所示，试进行方差分析。

表 6-2　4 种不同营养土培养下芦荟的株高　　（单位：cm）

重复	营养土				
	A_1	A_2	A_3	A_4	
1	18.1	17.4	17.3	15.6	
2	18.6	17.9	16.9	15.8	
3	18.7	17.1	18.5	16.7	
4	18.9	16.5	18.2	15.3	
5	18.3	17.5	16.2	16.8	
总和 $T_{i\cdot}$	92.6	86.4	87.1	80.2	$T = 346.3$
平均数 $\bar{x}_{i\cdot}$	18.52	17.28	17.42	16.04	$\bar{x}_{\cdot\cdot} = 17.32$

本例中，营养土种类为 4 种，即处理数 $k = 4$，重复数 $n = 5$，观测数据总数 $nk = 5 \times 4 = 20$。

（1）平方和计算。

$$C = \frac{T^2}{nk} = \frac{346.3^2}{20} = 5996.18$$

$$SS_T = \sum x_{ij}^2 - C = (18.1^2 + 18.6^2 + \cdots + 16.8^2) - 5996.18$$

$$= 6018.49 - 5996.18 = 22.31$$

$$SS_t = \frac{1}{n}\sum T_{i\cdot}^2 - C = \frac{1}{5} \times (92.6^2 + 86.4^2 + 87.1^2 + 80.2^2) - 5996.18$$

$$= 6011.63 - 5996.18 = 15.45$$

$$SS_e = SS_T - SS_t = 22.31 - 15.45 = 6.86$$

（2）自由度计算。

$$df_T = nk - 1 = 5 \times 4 - 1 = 19$$

$$df_t = k - 1 = 4 - 1 = 3$$

$$df_e = k(n-1) = 4 \times (5-1) = 16$$

（3）方差计算。

$$s_t^2 = \frac{SS_t}{df_t} = \frac{15.45}{3} = 5.15$$

$$s_e^2 = \frac{SS_e}{df_e} = \frac{6.86}{16} = 0.43$$

四、统计假设的显著性检验——F 检验

此例中处理内（即营养土内）方差可以估计误差方差，而处理间（即营养土间）方差则可估计营养土对芦荟株高影响的差异。为比较不同营养土之间芦荟株高有无差别，可应用 F 分布进行 F 检验（F-test）。

在方差分析中进行 F 检验的目的在于推断处理间的差异是否存在。因此在计算 F 值时，总是以被检验因素的均方（即处理间均方 s_t^2）作分子，以误差均方（即处理内均方 s_e^2）作分母。无效假设是把各个处理的变量假设来自同一个总体，认为处理间方差 σ_t^2 与

误差方差 σ_e^2 相等，即 $H_0:\sigma_t^2=\sigma_e^2$，同时给出 $H_A:\sigma_t^2\neq\sigma_e^2$。

无效假设是否成立，取决于计算的 F 值在 F 分布中出现的概率。本例中，F 值为

$$F=\frac{s_t^2}{s_e^2}=\frac{5.15}{0.43}=11.98$$

根据确定的显著标准 α，从 F 值表中查出在 df_t 和 df_e 下的 F_α 值。如果所计算的 $F\leqslant F_{0.05}$，则 $P>0.05$，接受 H_0，说明处理间差异不显著，在 F 值右上方标记“ns”或不标记符号；若 $F>F_{0.05}$，则 $P<0.05$，否定 H_0，接受 $H_A:\sigma_t^2>\sigma_e^2$，说明处理间差异达显著水平，在 F 值右上方标记“*”号；如果 $F>F_{0.01}$，则 $P<0.01$，说明处理间差异达到极显著水平，在 F 值右上方标记“**”号。如果处理间方差小于误差方差，则不必进行检验，即可作出接受 H_0 的结论。

本例 $df_t=3$、$df_e=16$，查 F 值表得 $F_{0.05(3,16)}=3.24$、$F_{0.01(3,16)}=5.29$，$F>F_{0.01}$，应否定 $H_0:\sigma_t^2=\sigma_e^2$，接受 $H_A:\sigma_t^2\neq\sigma_e^2$，说明不同营养土培养下芦荟株高的差异达极显著水平。

将方差分析结果列成方差分析表(表 6-3)。

表 6-3　表 6-2 资料中不同营养土培养芦荟株高的方差分析表

变异来源	df	SS	s^2	F	$F_{0.05}$	$F_{0.01}$
营养土间(处理间)	3	15.45	5.15	11.98**	3.24	5.29
营养土内(处理内)	16	6.86	0.43			
总变异	19	22.31				

从此例的分析过程中可以很清楚地看到方差分析的基本思想，那就是不再对数据进行一对对的比较，而是将总体的变异进行分解，通过一次检验即完成了多组处理之间的差异显著性检验。

五、多重比较

F 检验如果否定了 H_0，接受了 H_A，表明试验的总变异主要来源于处理间的变异。这也仅说明 k 个处理的平均数间有显著(或极显著)差异，但并不意味着每两个处理平均数间的差异都是显著(或极显著)的，也不能具体说明哪些平均数间有显著(或极显著)差异。例如，例 6.1 中不同营养土培养芦荟株高有极显著差异，但并不是说所有营养土对芦荟株高的影响都达到极显著水平，有些处理间可能差异显著，也有些处理间可能差异不显著。要比较不同处理平均数两两间差异的显著性，每个处理的平均数都要与其他处理的平均数进行比较。统计上把多个平均数两两间的相互比较称为多重比较(multiple comparison)。

多重比较的方法很多，常用的有最小显著差数法和最小显著极差法。

(一) 最小显著差数法

统计学家 R.A.Fisher 提出了最小显著差数法(the least significant difference method)，又称为 Fisher *LSD* 法或 *LSD* 法，是最早用于检验所有总体均数间两两相等假设的方法，其实质是两个平均数相比较的 t 检验法。

检验时先计算出达到差异显著的最小差数，记为 LSD，然后用两个处理平均数的差值与 LSD 比较，若 $|\bar{x}_1-\bar{x}_2|>LSD$，即为在给定的 α 水平上差异显著，反之，差异不显著。

由 $t=\dfrac{\bar{x}_1-\bar{x}_2}{s_{\bar{x}_1-\bar{x}_2}}$，得

$$\bar{x}_1-\bar{x}_2=t\cdot s_{\bar{x}_1-\bar{x}_2} \tag{6.17}$$

如果式(6.17)的 t 值为 $t_{0.05}$ 或 $t_{0.01}$，则 $\bar{x}_1-\bar{x}_2$ 为两个样本平均数差异达到显著或极显著水平的最小值，记为 LSD，即

$$LSD_{0.05}=t_{0.05}\cdot s_{\bar{x}_1-\bar{x}_2} \tag{6.18}$$

$$LSD_{0.01}=t_{0.01}\cdot s_{\bar{x}_1-\bar{x}_2} \tag{6.19}$$

若 $|\bar{x}_1-\bar{x}_2|>LSD_{0.05}$ 或 $|\bar{x}_1-\bar{x}_2|>LSD_{0.01}$，则认为两个样本平均数的差异达显著或极显著水平。

平均数差数标准误的计算公式为

$$s_{\bar{x}_1-\bar{x}_2}=\sqrt{\frac{s_1^2}{n_1}+\frac{s_2^2}{n_2}}=\sqrt{s_e^2\left(\frac{1}{n_1}+\frac{1}{n_2}\right)} \tag{6.20}$$

式中，s_e^2 为误差方差(即处理内方差)；n 为每一处理观测次数(即重复数)。

当 $n_1=n_2$ 时：

$$s_{\bar{x}_1-\bar{x}_2}=\sqrt{\frac{2s_e^2}{n}} \tag{6.21}$$

根据式(6.21)，例 6.1 资料中平均数差数的标准误为

$$s_{\bar{x}_1-\bar{x}_2}=\sqrt{\frac{2s_e^2}{n}}=\sqrt{\frac{2\times 0.43}{5}}=0.415(\text{cm})$$

查 t 值表，当误差自由度 $df_e=16$ 时，$t_{0.05}=2.120$，$t_{0.01}=2.921$，则

$$LSD_{0.05}=t_{0.05}\times s_{\bar{x}_1-\bar{x}_2}=2.120\times 0.415=0.88(\text{cm})$$

$$LSD_{0.01}=t_{0.01}\times s_{\bar{x}_1-\bar{x}_2}=2.921\times 0.415=1.21(\text{cm})$$

多重比较结果的表示方法有多种，最常用的方法是标记字母法和梯形法。

标记字母法(method of marked letter)：首先将全部平均数从大到小依次排列，然后在最大的平均数后标上字母 a，将该平均数与以下各平均数相比，凡相差不显著的($<LSD_{0.05}$)都标上字母 a，直至某个与之相差显著的则标以字母 b。再以标有 b 的平均数为标准，与各个比它大的平均数比较，凡差数差异不显著的在字母 a 的右边加标字母 b。然后再以标 b 的最大平均数为标准与以下未曾标有字母的平均数比较，凡差数不显著的继续标以字母 b，直至差异显著的平均数标以字母 c，再与上面的平均数比较。如此重复进行，直至最小的平均数有了标记字母，并与上面的平均数比较后为止。这样各平均数间，凡有一个相同标记字母的即为差异不显著，凡具不同标记字母的即为差异显著。差异极显著标记方法同上，差数与 $LSD_{0.01}$ 相比较，用大写字母标记。

例如，对例 6.1 资料用字母标记法表示其多重比较的结果(表 6-4)。先将各平均数按大小顺序排列，并在“A_1”行上标 a，“A_1”与“A_3”相比存在显著差异，故在“A_3”行上标

b。“A_3”与“A_2”相比无显著差异,故在“A_2”行上仍标 b。然后“A_3”与“A_4”相比有显著差异,在“A_4”行上标 c,然后以“A_4”为标准,与“A_2”进行比较有显著差异,则比较结束。同理,差异极显著的结果用大写字母标记,其多重比较结果列于表 6-4。

表 6-4　表 6-2 资料中 4 种营养土培养下芦荟株高的差异显著性(LSD 法,字母标记法)

营养土	平均数 ($\bar{x}_i$)	差异显著性	
		$\alpha = 0.05$	$\alpha = 0.01$
A_1	18.52	a	A
A_3	17.42	b	AB
A_2	17.28	b	B
A_4	16.04	c	C

多重比较还可用梯形法(method of trapezoid)表示。这种方法是将各处理的平均数差数按梯形列于表中,并将这些差数和 LSD 值比较。若差数 $> LSD_{0.05}$,说明处理平均数间的差异达到显著水平,在差数的右上角标上“*”号;差数 $> LSD_{0.01}$,说明处理平均数间差异达到极显著水平,在差数的右上角标上“**”号;差数 $\leqslant LSD_{0.05}$,说明差异不显著。表 6-5 是用梯形法表示的例 6.1 资料中不同营养土培养下芦荟株高的差异显著性结果。梯形表中各个平均数差数构成一个三角形阵列,故又称为三角形法(method of triangle)。此法的优点是简便直观,缺点是所占篇幅较大。

表 6-5　表 6-2 资料中 4 种营养土培养下芦荟株高的差异显著性(LSD 法,梯形法)

营养土	平均数 ($\bar{x}_i$)	差异显著性		
		$\bar{x}_{i\cdot} - 16.04$	$\bar{x}_{i\cdot} - 17.28$	$\bar{x}_{i\cdot} - 17.42$
A_1	18.52	2.48**	1.24**	1.10*
A_3	17.42	1.38**	0.14	
A_2	17.28	1.24**		
A_4	16.04			

多重比较结果表明,A_1 对芦荟株高影响极显著高于 A_2 和 A_4,显著高于 A_3;A_3、A_2 对芦荟株高影响极显著高于 A_4;A_3 与 A_2 处理下芦荟株高差异不显著。

综上,利用 LSD 法进行多重比较,可以分 3 步进行:

(1) 计算最小显著差数 $LSD_{0.05}$ 和 $LSD_{0.01}$。

(2) 列出平均数的多重比较表,表中各处理按其平均数从大到小依次进行排列。

(3) 将两两平均数的差数与 $LSD_{0.05}$ 和 $LSD_{0.01}$ 进行比较,作出统计推断。

对于多个处理平均数所有可能的两两比较,LSD 法的优点是方法比较简单,克服了 t 检验法的某些缺点。但是由于没有考虑相互比较的处理平均数依数值大小排列上的秩次,故仍有推断可靠性低、犯 α 错误概率增加的问题。自 20 世纪 50 年代以来,统计学家提出了各种新的检验法,应用较多的有最小显著极差法。

(二) 最小显著极差法

最小显著极差法(the least significant range method,*LSR* 法)是在一定的显著水平 α 上,根据极差范围内所包含的处理数据(也称为秩次距)M 的不同而采用不同的显著差数标准进行比较。*LSR* 检验又可分为新复极差检验和 q 检验。

1. 新复极差检验

新复极差检验(new multiple range test)是由邓肯(Duncan)于 1955 年提出的,又称为 Duncan 法,也称为 *SSR* 法(the shortest significant range method)。无效假设为 H_0:$\mu_1-\mu_2=0$,具体检验步骤如下所述。

(1) 按相比较的样本容量计算平均数标准误:当 $n_1=n_2=n$ 时,有

$$s_{\bar{x}}=\sqrt{\frac{s_e^2}{n}} \tag{6.22}$$

(2) 查 s_e^2 所具有自由度 df_e 和比较所含平均数个数 M 时的 *SSR* 值(附表 6),然后计算最小显著极差:

$$LSR_\alpha=SSR_\alpha \cdot s_{\bar{x}} \tag{6.23}$$

(3) 将各平均数按大小顺序排列,用各个 M 值的 LSR_α 值即可检验各平均数间差异的显著性。

对例 6.1 中的各组平均值作新复极差检验:

$$s_{\bar{x}}=\sqrt{\frac{s_e^2}{n}}=\sqrt{\frac{0.43}{5}}=0.293(\text{cm})$$

查附表 6,当 $df_e=16$,$M=2$ 时,$SSR_{0.05}=3.00$、$SSR_{0.01}=4.13$,则

$$LSR_{0.05}=0.293\times 3.00=0.88(\text{cm})$$

$$LSR_{0.01}=0.293\times 4.13=1.21(\text{cm})$$

当 $M=3$、$M=4$ 时按同理计算,将结果列于表 6-6。

表 6-6　表 6-2 资料中 4 种营养土培养下芦荟株高多重比较的 *LSR* 值(*SSR* 法)

M	2	3	4
$SSR_{0.05}$	3.00	3.14	3.24
$SSR_{0.01}$	4.13	4.31	4.42
$LSR_{0.05}$	0.88	0.92	0.95
$LSR_{0.01}$	1.21	1.26	1.30

用表 6-6 中的 LSR_α 值即可进行不同 M 的平均数间差异显著性的检验。例如,A_1 与 A_3 进行比较,$M=2$,$0.88<$差值$(1.10)<1.21$,所以 A_1 与 A_3 差异达到显著水平。A_1 与 A_2 进行比较,$M=3$,$0.92<$差值$(1.24)<1.26$,差异达到显著水平。A_1 与 A_4 进行比较,$M=4$,差值$(2.48)>1.30$,差异达到极显著水平。用 *SSR* 法比较 4 种营养土培养下芦荟株高的差异显著性结果列于表 6-7。

表 6-7　表 6-2 资料中 4 种营养土培养下芦荟株高的差异显著性(*SSR* 法)

营养土	平均数 ($\bar{x}_i$)	差异显著性	
		$\alpha = 0.05$	$\alpha = 0.01$
A_1	18.52	a	A
A_3	17.42	b	A
A_2	17.28	b	A
A_4	16.04	c	B

由表 6-7 可以看出，A_1 与 A_4 之间的差异达到极显著水平，与 A_3、A_2 之间的差异达显著水平，A_3、A_2 与 A_4 的差异达极显著水平，A_3 与 A_2 之间的差异没有达到显著水平，检验结果与 *LSD* 检验相同。而 A_1 与 A_2 之间的差异仅达显著水平，这与 *LSD* 检验中二者差异达极显著水平的结果不同。

2. q 检验

q 检验(q test) 法也称为 *SNK* 检验(Student-Newman-Keuls test)，是以统计量 q 的概率分布为基础的，方法与新复极差检验相似，其区别仅在于计算最小显著极差 LSR_α 时不是查 SSR_α，而是查 q_α 值(附表 7)。

$$LSR_\alpha = s_{\bar{x}} \cdot q_\alpha \tag{6.24}$$

查 q 值表，$df_e = 16$，M 为 2、3、4 时，将 $q_{0.05}$、$q_{0.01}$ 的值列于表 6-8，由式(6.24) 计算出相应的最小显著极差 *LSR*：

$$LSR_{0.05} = q_{0.05} \cdot s_{\bar{x}}$$
$$LSR_{0.01} = q_{0.01} \cdot s_{\bar{x}}$$

计算结果列于表 6-8。

表 6-8　表 6-2 资料中 4 种营养土培养下芦荟株高多重比较的 *LSR* 值(q 法)

M	2	3	4
$q_{0.05}$	3.00	3.65	4.05
$q_{0.01}$	4.13	4.78	5.19
$LSR_{0.05}$	0.88	1.07	1.19
$LSR_{0.01}$	1.21	1.40	1.52

根据表 6-8，用 q 法对例 6.1 资料进行差异显著性检验，结果列于表 6-9。

表 6-9　表 6-2 资料中 4 种营养土培养下芦荟株高的差异显著性(q 法)

饲料	平均数 ($\bar{x}_i$)	差异显著性	
		$\alpha = 0.05$	$\alpha = 0.01$
A_1	18.52	a	A
A_3	17.42	b	A
A_2	17.28	b	A
A_4	16.04	c	B

由表6-9和表6-7可知，对于例6.1资料进行多重比较时，q法检验结果与SSR法检验是一致的。

对比所用的这3种检验方法，可以发现在样本数（处理数）$k=2$时，LSD法、SSR法和q法的显著尺度是相同的。当$k\geqslant 3$时，3种检验的显著尺度便不相同，LSD法最低、SSR法次之、q法最高，即这3种检验方法的检验尺度关系为LSD法$\leqslant SSR$法$\leqslant q$法。用LSD法检验显著的差数，用SSR法或q法检验则未必显著；而用q法检验显著的差数，用LSD法进行检验差异必然显著。在实际研究工作中，对于精度要求高的试验应用q法，一般试验可用SSR法，试验中各个处理皆与对照相比的试验资料可用LSD法。

应当注意，无论采用何种方法表示多重比较结果，都应注明采用的是哪一种多重比较方法。

综上所述，方差分析的基本步骤是：

（1）将样本数据的总平方和与总自由度分解为各变异因素的平方和与自由度。

（2）列方差分析表进行F检验，分析各变异因素在总变异中的重要程度。

（3）若F检验显著，对各处理平均数进行多重比较。

第二节　单因素方差分析

单因素试验（single factor experiment）资料的方差分析是方差分析中最基本、最简单的一种，目的在于正确判断该试验因素各水平的相对效果。在单因素方差分析中，根据组内观测数目（重复数）是否相同，可分为组内观测次数相等的方差分析和组内观测次数不等的方差分析。

一、组内观测次数相等的方差分析

k组资料，每一处理组皆含有n个观测值，其方差分析方法在本章第一节已作介绍，这里以方差分析表形式给出有关计算公式（表6-10）。

表6-10　组内观测次数相等（k个处理n次重复）的单因素方差分析

变异来源	df	SS	s^2	F
处理间	$k-1$	$SS_t=\dfrac{\sum T_i^2}{n}-C$	s_t^2	$\dfrac{s_t^2}{s_e^2}$
处理内	$k(n-1)$	$SS_e=SS_T-SS_t$	s_e^2	
总变异	$nk-1$	$SS_T=\sum x^2-C$		

【例6.2】 测定东北、内蒙古、河北、安徽、贵州5个地区黄鼬冬季针毛的长度，每个地区随机抽取4个样本，测定的结果列于表6-11。试比较各地区黄鼬针毛长度的差异显著性。

表 6-11　不同地区黄鼬冬季针毛长度　　(单位:mm)

地区	东北	内蒙古	河北	安徽	贵州	合计
1	32.0	29.2	25.5	23.3	22.3	
2	32.8	27.4	26.1	25.1	22.5	
3	31.2	26.3	25.8	25.1	22.9	
4	30.4	26.7	26.7	25.5	23.7	
$\sum x$	126.4	109.6	104.1	99.0	91.4	530.5
n	4	4	4	4	4	20
$\bar{x}$	31.60	27.40	26.03	24.75	22.85	26.53
$\sum x^2$	3997.44	3007.98	2709.99	2453.16	2089.64	14258.21

在这个例子里,$k=5$,$n=4$。

(1) 整理数据。计算$\sum x$、$\bar{x}$ 及$\sum x^2$,并列于表 6-11 中。

(2) 计算平方和与自由度。

$$C=\frac{T^2}{nk}=\frac{530.5^2}{4\times 5}=14071.51$$

$$SS_T=\sum x^2-C=14258.21-14071.51=186.70$$

$$SS_t=\frac{1}{n}\sum T_i^2-C=\frac{1}{4}\times(126.4^2+109.6^2+\cdots+91.4^2)-14071.51$$

$$=173.71$$

$$SS_e=SS_T-SS_t=186.70-173.71=12.99$$

$$df_T=nk-1=20-1=19$$

$$df_t=k-1=5-1=4$$

$$df_e=k(n-1)=5\times(4-1)=15$$

(3) 计算方差。

$$s_t^2=\frac{SS_t}{df_t}=\frac{173.71}{4}=43.428$$

$$s_e^2=\frac{SS_e}{df_e}=\frac{12.99}{15}=0.866$$

(4) 进行 F 检验。

$$F=\frac{s_t^2}{s_e^2}=\frac{43.428}{0.866}=50.1478$$

查 F 值表,得 $F_{0.05(4,15)}=3.06$、$F_{0.01(4,15)}=4.89$,故 $F>F_{0.01}$,$P<0.01$,说明 5 个地区黄鼬冬季针毛长度差异极显著。

将上面结果记入方差分析表(表 6-12)。

表 6-12　表 6-11 资料中不同地区黄鼬冬季针毛长度方差分析表

变异来源	df	SS	s^2	F	$F_{0.05}$	$F_{0.01}$
地区间	4	173.71	43.428	50.16**	3.06	4.89
地区内	15	12.99	0.866			
总变异	19	186.70				

知道了 5 个地区之间存在极显著性差异，要确定哪些地区之间的差异达到显著或极显著水平，需要进行多重比较。这里用 LSD 法进行检验。

$$s_{\bar{x}_1-\bar{x}_2}=\sqrt{\frac{2s_e^2}{n}}=\sqrt{\frac{2\times 0.866}{4}}=0.658(\text{mm})$$

查附表 3，当 $df=15$ 时，$t_{0.05}=2.131$、$t_{0.01}=2.947$，于是有

$$LSD_{0.05}=2.131\times 0.658=1.402(\text{mm})$$

$$LSD_{0.01}=2.947\times 0.658=1.939(\text{mm})$$

将两组平均数的差值与 $LSD_{0.05}$ 及 $LSD_{0.01}$ 比较，若差数 $>LSD_{0.01}$，说明两地间黄鼬冬季针毛长度差异极显著，标以不同的大写字母；若差数 $>LSD_{0.05}$，说明两地黄鼬冬季针毛长度差异显著，标以不同的小写字母。多重比较的结果列于表 6-13。

表 6-13　不同地区黄鼬冬季针毛长度的差异显著性(LSD 法)

地区	平均数 ($\bar{x}_i$)	差异显著性	
		$\alpha=0.05$	$\alpha=0.01$
东北	31.60	a	A
内蒙古	27.40	b	B
河北	26.03	bc	BC
安徽	24.75	c	CD
贵州	22.85	d	D

结果表明，东北与其他地区，内蒙古与安徽、贵州，河北与贵州黄鼬冬季针毛长度差异达极显著水平，安徽与贵州差异达显著水平，而内蒙古与河北、河北与安徽差异不显著。

二、组内观测次数不相等的方差分析

由于试验条件的限制，不同处理的观测次数不同，对于 k 个处理的观测次数依次是 $n_1,n_2,\cdots,n_k$ 的单因素分组资料，上面所述的方差分析方法仍然可用，但由于总观测次数不是 nk，而是 $\sum_{i=1}^{k}n_i$，计算平方和的公式稍有改变(表 6-14)。

在进行多重比较时，首先应计算平均数(或平均数差数)的标准误。由于各组内观测次数不等，无法直接套用式(6.21)或式(6.22)，需先算得各 n_i 的平均数 n_0：

$$n_0=\frac{\left(\sum n_i\right)^2-\sum n_i^2}{\left(\sum n_i\right)(k-1)} \tag{6.25}$$

表 6-14　组内观测次数不等的方差分析

变异来源	df	SS	s^2	F
处理间	$k-1$	$SS_t=\sum\frac{T_i^2}{n_i}-C$	s_t^2	$\frac{s_t^2}{s_e^2}$
处理内	$\sum n_i-k$	$SS_e=SS_T-SS_t$	s_e^2	
总变异	$\sum n_i-1$	$SS_T=\sum x^2-C$		

然后有 $s_{\bar{x}}=\sqrt{\frac{s_e^2}{n_0}}$，或 $s_{\bar{x}_1-\bar{x}_2}=\sqrt{\frac{2s_e^2}{n_0}}$。

【例 6.3】 园艺研究所调查了 3 个品种草莓的维生素 C 含量(mg/100g)，测定结果列于表 6-15。试分析不同品种草莓之间维生素 C 含量是否有显著差异。

表 6-15　不同品种草莓维生素 C 含量　　(单位：mg/100g)

处理	维生素 C 含量										合计	平均数
	1	2	3	4	5	6	7	8	9	10		
Ⅰ	117	99	107	112	113	106					654	109.0
Ⅱ	81	77	79	76	85	87	74	69	72	80	780	78.0
Ⅲ	80	82	78	84	89	73	86	88			660	82.5

方差分析步骤如下所述。

(1) 平方和计算。

$$C=\frac{\left(\sum T_i\right)^2}{\sum n_i}=\frac{(654+780+660)^2}{6+10+8}=182701.5$$

$$SS_T=\sum x^2-C=117^2+99^2+\cdots+88^2-182701.5=4562.5$$

$$SS_t=\sum\frac{T_i^2}{n_i}-C=\frac{654^2}{6}+\frac{780^2}{10}+\frac{660^2}{8}-182701.5=3874.5$$

$$SS_e=SS_T-SS_t=4562.5-3874.5=688.0$$

(2) 列方差分析表(表 6-16)。

表 6-16　不同品种草莓维生素 C 含量方差分析表

变异来源	df	SS	s^2	F	$F_{0.05(2,21)}$	$F_{0.01(2,21)}$
处理间	2	3874.5	1937.25	59.13**	3.47	5.28
处理内	21	688.0	32.76			
总变异	23	4562.5				

从表 6-16 方差分析结果可知，$F>F_{0.01}$，表明 3 个品种草莓维生素 C 含量差异达极显著水平，需要进一步作多重比较。

(3) 多重比较。

进行多重比较时，需要计算 n_0，并求得 $s_{\bar{x}}$(用于 LSR 检验)或 $s_{\bar{x}_1-\bar{x}_2}$(用于 LSD 检

验），即

$$n_0=\frac{\left(\sum n_i\right)^2-\sum n_i^2}{\left(\sum n_i\right)(k-1)}=\frac{24^2-(6^2+10^2+8^2)}{24\times 2}=7.8\approx 8$$

本题以 LSD 法为例进行多重比较（表 6-17）。

$$s_{\bar{x}_1-\bar{x}_2}=\sqrt{\frac{2s_e^2}{n_0}}=\sqrt{\frac{2\times 32.76}{8}}=2.862(\text{mg/100g})$$

查附表 3，当 $df=21$ 时，$t_{0.05}=2.080$、$t_{0.01}=2.831$，于是有

$$LSD_{0.05}=2.080\times 2.862=5.95(\text{mg/100g})$$

$$LSD_{0.01}=2.831\times 2.862=8.10(\text{mg/100g})$$

表 6-17　不同品种草莓维生素 C 含量的差异显著性（LSD 法）

品种	平均数 ($\bar{x}_i$)	差异显著性	
		$\alpha=0.05$	$\alpha=0.01$
Ⅰ	109.0	a	A
Ⅲ	82.5	b	B
Ⅱ	78.0	b	B

多重比较结果表明，品种Ⅰ与品种Ⅲ、品种Ⅱ维生素 C 含量的差异达到极显著水平。品种Ⅲ与品种Ⅱ之间维生素 C 含量差异不显著。

要注意的是，组内不等观测次数的试验要尽量避免，因为这样的试验数据不仅计算麻烦，而且降低了分析的灵敏度。

第三节　二因素方差分析

在实际工作中经常会遇到两种因素共同影响试验结果的情况。在二因素试验（two-factor experiment）方差分析中，需要对因素的主效应和因素间的互作进行分析。因素间的交互作用显著与否关系到主效应的利用价值，有时互作效应相当大，甚至可以忽略主效应。二因素间是否存在互作可根据专门的统计方法或专业知识进行判断。

一、无重复观测值的二因素方差分析

在有些试验中，如果依据经验或专业知识判断二因素无互作时，每个处理可不设重复。假定 A 因素有 a 个水平，B 因素有 b 个水平，每个处理组合只有一个观测值。这种无重复观测值的二因素分组资料模式如表 6-18 所示。

在无重复观测值的二因素试验资料中，A 因素的每一个水平可看成有 b 个重复，B 因素的每一个水平可看成有 a 个重复。每个观测值既受到 A 因素的影响，又受到 B 因素的影响。二因素方差分析的线性模型可以以单因素模型为基础导出。若因素间不存在互作，则二因素方差分析观测值的线性模型为

表 6-18　无重复观测值的二因素数据资料

因素 A	因素 B				总和 $T_{i\cdot}$	平均数 $\bar{x}_{i\cdot}$
	B_1	B_2	…	B_b		
A_1	x_{11}	x_{12}	…	x_{1b}	$T_{1\cdot}$	$\bar{x}_{1\cdot}$
A_2	x_{21}	x_{22}	…	x_{2b}	$T_{2\cdot}$	$\bar{x}_{2\cdot}$
⋮	⋮	⋮		⋮	⋮	⋮
A_a	x_{a1}	x_{a2}	…	x_{ab}	$T_{a\cdot}$	$\bar{x}_{a\cdot}$
总和 $T_{\cdot j}$	$T_{\cdot 1}$	$T_{\cdot 2}$	…	$T_{\cdot b}$	T	
平均数 $\bar{x}_{\cdot j}$	$\bar{x}_{\cdot 1}$	$\bar{x}_{\cdot 2}$	…	$\bar{x}_{\cdot b}$		$\bar{x}_{\cdot\cdot}$

$$x_{ij}=\mu+\alpha_i+\beta_j+\varepsilon_{ij} \tag{6.26}$$

式中，α_i、β_j 分别是 A 因素、B 因素的效应($i=1,2,\cdots,a$；$j=1,2,\cdots,b$)，可以是固定因素，也可以是随机因素，且 $\sum\alpha_i=\sum\beta_j=0$；$\varepsilon_{ij}$ 是随机误差，彼此独立并且服从 $N(0,\sigma^2)$。

(1) 平方和分解。

$$\left.\begin{aligned} C&=\frac{T^2}{ab}\\ SS_T&=\sum\sum(x_{ij}-\bar{x}_{\cdot\cdot})^2=\sum x_{ij}^2-C\\ SS_A&=b\sum(\bar{x}_{i\cdot}-\bar{x}_{\cdot\cdot})^2=\frac{\sum T_{i\cdot}^2}{b}-C\\ SS_B&=a\sum(\bar{x}_{\cdot j}-\bar{x}_{\cdot\cdot})^2=\frac{\sum T_{\cdot j}^2}{a}-C\\ SS_e&=\sum\sum(x_{ij}-\bar{x}_{i\cdot}-\bar{x}_{\cdot j}+\bar{x}_{\cdot\cdot})^2=SS_T-SS_A-SS_B \end{aligned}\right\} \tag{6.27}$$

(2) 自由度分解。

$$\left.\begin{aligned} df_T&=ab-1\\ df_A&=a-1\\ df_B&=b-1\\ df_e&=(a-1)(b-1) \end{aligned}\right\} \tag{6.28}$$

(3) 各项方差的计算。

$$\left.\begin{aligned} s_A^2&=\frac{SS_A}{df_A}\\ s_B^2&=\frac{SS_B}{df_B}\\ s_e^2&=\frac{SS_e}{df_e} \end{aligned}\right\} \tag{6.29}$$

将以上结果及期望方差列入方差分析表(表 6-19)中。

表 6-19　无重复观测值的二因素方差分析

变异来源	df	SS	s^2	F	期望方差 $E(s^2)$		
					固定模型	随机模型	混合模型*
A 因素	$a-1$	SS_A	s_A^2	$\frac{s_A^2}{s_e^2}$	$\sigma^2+b\eta_\alpha^2$	$\sigma^2+b\sigma_\alpha^2$	$\sigma^2+b\eta_\alpha^2$
B 因素	$b-1$	SS_B	s_B^2	$\frac{s_B^2}{s_e^2}$	$\sigma^2+a\eta_\beta^2$	$\sigma^2+a\sigma_\beta^2$	$\sigma^2+a\sigma_\beta^2$
误差	$(a-1)(b-1)$	SS_e	s_e^2		σ^2	σ^2	σ^2
总变异	$ab-1$	SS_T					

* A 固定，B 随机

【例 6.4】 将一种生长激素配成 M_1、M_2、M_3、M_4、M_5 5 种浓度，并用 H_1、H_2、H_3 3 种时间浸渍某大豆品种的种子，出苗 45 天后得各处理每一植株的平均干物重(g)，结果列于表 6-20。试作方差分析并进行多重比较。

表 6-20　生长激素及浸渍时间对大豆干物重的影响　　(单位：g)

浓度 (A)	时间 (B)			$T_{i\cdot}$	$\bar{x}_{i\cdot}$
	H_1	H_2	H_3		
M_1	13	14	14	41	13.67
M_2	12	12	13	37	12.33
M_3	3	3	3	9	3.00
M_4	10	9	10	29	9.67
M_5	2	5	4	11	3.67
$T_{\cdot j}$	40	43	44	127	
$\bar{x}_{\cdot j}$	8.0	8.6	8.8		8.47

本例主要研究生长激素和时间的效应，这两个因素均为固定因素，因而 α_i 和 β_i 均为固定效应，适应于固定模型。

(1) 平方和计算。

$$C=\frac{T^2}{ab}=\frac{127^2}{5\times 3}=1075.27$$

$$SS_T=\sum x^2-C=13^2+14^2+\cdots+4^2-1075.27=295.73$$

$$SS_A=\frac{\sum T_{i\cdot}^2}{b}-C=\frac{41^2+37^2+\cdots 11^2}{3}-1075.27=289.07$$

$$SS_B=\frac{\sum T_{\cdot j}^2}{a}-C=\frac{40^2+43^2+44^2}{5}-1075.27=1.73$$

$$SS_e=SS_T-SS_A-SS_B=295.73-289.07-1.73=4.93$$

(2) 自由度计算。

$$df_T=ab-1=5\times 3-1=14$$

$$df_A=a-1=5-1=4$$

$$df_B=b-1=3-1=2$$

$$df_e=(a-1)(b-1)=(5-1)\times(3-1)=8$$

(3) 列方差分析表(表 6-21),并进行 F 检验。

表 6-21　生长激素处理对大豆干物重影响的方差分析表

变异来源	df	SS	s^2	F	$F_{0.05}$	$F_{0.01}$
浓度间(A)	4	289.07	72.27	116.56**	3.84	7.01
时间间(B)	2	1.73	0.87	1.40	4.46	8.65
误差	8	4.93	0.62			
总变异	14	295.73				

F 检验结果表明,生长激素处理浓度之间的 F 值大于 $F_{0.01}$,生长激素处理时间之间的 F 值未达到显著水平,表明不同生长激素浓度对大豆干物重有极显著的影响。

(4) 多重比较(用 SSR 检验)。生长激素处理浓度之间的效应达到了极显著差异,生长激素处理时间之间的效应未达到显著水平,只需对 5 种浸渍浓度进行多重比较。根据式(6.22) 可计算出浓度之间的平均数标准误为

$$s_{\bar{x}}=\sqrt{\frac{s_e^2}{b}}=\sqrt{\frac{0.62}{3}}=0.455(\mathrm{g})$$

[这里需注意:上式的 $b=3$ 是每一浓度的观测值数目。如果要比较时间之间的效应,则由于每一时间有 $a=5$ 个观测值,其平均数的标准误为 $s_{\bar{x}}=\sqrt{\frac{s_e^2}{a}}=\sqrt{\frac{0.62}{5}}=0.352(\mathrm{g})$]。查附表 6,当 $df_e=8$,M 为 2、3、4、5 时的 SSR 值及由此计算的 LSR 值列于表 6-22,多重比较结果列于表 6-23。

表 6-22　不同生长激素浓度大豆干物重多重比较 *SSR* 值和 *LSR* 值

M	2	3	4	5
$SSR_{0.05}$	3.26	3.40	3.48	3.52
$SSR_{0.01}$	4.75	4.94	5.06	5.14
$LSR_{0.05}$	1.48	1.55	1.58	1.60
$LSR_{0.01}$	2.16	2.25	2.30	2.34

表 6-23　不同生长激素浓度大豆干物重平均数差异显著性(SSR 法)

浓度	平均数 ($\bar{x}_i$)	差异显著性	
		$\alpha=0.05$	$\alpha=0.01$
M_1	13.67	a	A
M_2	12.33	a	A
M_4	9.67	b	B
M_5	3.67	c	C
M_3	3.00	c	C

多重比较结果表明:5 种生长激素浓度对大豆干物重的影响达到了极显著水平,除

M_1 与 M_2、M_5 与 M_3 之间差异不显著外，其他生长激素浓度之间的大豆干物重均达到极显著差异。5 种生长激素浓度中，以 M_1 和 M_2 的处理效果较好。

二、具有重复观测值的二因素方差分析

以上调查资料是两个因素的作用结果，所估计的误差实际上是这两个因素的相互作用，这是在两个因素不存在互作，或互作很小的情况下进行估计的。但是，如果两个因素存在互作，在进行方差分析时，就需要将互作项和误差项的平方和与自由度分解开来。因此，进行两因素或多因素试验时，一般应设重复。

具有重复观测值的二因素试验的典型设计是：假定 A 因素有 a 个水平，B 因素有 b 个水平，则每一次重复都包括 ab 次实验，设试验重复 n 次，则试验总观测次数为 abn 次。具有重复观测值的二因素试验资料模式如表 6-24 所示。

表 6-24　具有重复观测值的二因素数据资料

因素 A	因素 B				$T_{i\cdot}$	$\bar{x}_{i\cdot}$
	B_1	B_2	…	B_b		
A_1	x_{111} x_{112} ⋮ x_{11n}	x_{121} x_{122} ⋮ x_{12n}	… …	x_{1b1} x_{1b2} ⋮ x_{1bn}	$T_{1\cdot}$	$\bar{x}_{1\cdot}$
A_2	x_{211} x_{212} ⋮ x_{21n}	x_{221} x_{222} ⋮ x_{22n}	… …	x_{2b1} x_{2b2} ⋮ x_{2bn}	$T_{2\cdot}$	$\bar{x}_{2\cdot}$
⋮	⋮	⋮	…	⋮	⋮	⋮
A_a	x_{a11} x_{a12} ⋮ x_{a1n}	x_{a21} x_{a22} ⋮ x_{a2n}	… …	x_{ab1} x_{ab2} ⋮ x_{abn}	$T_{a\cdot}$	$\bar{x}_{a\cdot}$
$T_{\cdot j}$	$T_{\cdot 1}$	$T_{\cdot 2}$	…	$T_{\cdot b}$	T	
$\bar{x}_{\cdot j}$	$\bar{x}_{\cdot 1}$	$\bar{x}_{\cdot 2}$	…	$\bar{x}_{\cdot b}$		$\bar{x}$

具有重复观测值的二因素方差分析可用下面的线性模型来描述：

$$x_{ijk}=\mu+\alpha_i+\beta_j+(\alpha\beta)_{ij}+\varepsilon_{ijk} \tag{6.30}$$

式中，x_{ijk} 为 A 因素第 i 水平、B 因素第 j 水平的第 k 次重复观测值（其中 $i=1,2,\cdots,a$；$j=1,2,\cdots,b$；$k=1,2,\cdots,n$）；μ 为总体平均值；α_i 为 A 因素第 i 水平的效应，β_j 为 B 因素第 j 水平的效应；$(\alpha\beta)_{ij}$ 为 α_i 和 β_j 的交互作用，且有 $\sum\alpha_i=\sum\beta_j=\sum(\alpha\beta)_{ij}=0$；$\varepsilon_{ijk}$ 为随机误差，彼此独立且服从 $N(0,\sigma^2)$。

方差分析的步骤和前面介绍的相类似，唯一不同的是 F 检验的方法。

（1）平方和计算。

$$\left.\begin{aligned} C &= \frac{T^2}{abn} \\ SS_T &= \sum\sum\sum (x_{ijk} - \bar{x})^2 = \sum x^2 - C \\ SS_A &= bn\sum (\bar{x}_{i\cdot} - \bar{x})^2 = \frac{\sum T_{i\cdot}^2}{bn} - C \\ SS_B &= an\sum (\bar{x}_{\cdot j} - \bar{x})^2 = \frac{\sum T_{\cdot j}^2}{an} - C \\ SS_{AB} &= n\sum\sum (\bar{x}_{ij} - \bar{x}_{i\cdot} - \bar{x}_{\cdot j} + \bar{x})^2 \\ &= \frac{\sum T_{ij}^2}{n} - C - SS_A - SS_B \\ SS_e &= SS_T - SS_A - SS_B - SS_{AB} \end{aligned}\right\} \tag{6.31}$$

(2) 自由度计算。

$$\left.\begin{aligned} df_T &= abn - 1 \\ df_A &= a - 1 \\ df_B &= b - 1 \\ df_{AB} &= (a-1)(b-1) \\ df_e &= ab(n-1) \end{aligned}\right\} \tag{6.32}$$

(3) 各项方差的计算。

$$\left.\begin{aligned} s_A^2 &= \frac{SS_A}{df_A} \\ s_B^2 &= \frac{SS_B}{df_B} \\ s_{AB}^2 &= \frac{SS_{AB}}{df_{AB}} \\ s_e^2 &= \frac{SS_e}{df_e} \end{aligned}\right\} \tag{6.33}$$

(4) F 检验。

a. 固定模型:在固定模型中,α_i、β_j 及 $(\alpha\beta)_{ij}$ 均为固定效应。在 F 检验时,A 因素、B 因素和 $A \times B$ 互作项均以 s_e^2 作为分母。

b. 随机模型:对于随机模型,α_i、β_j、$(\alpha\beta)_{ij}$ 和 ε_{ijk} 是相互独立的随机变量,都遵从正态分布。作 F 检验,检验 $A \times B$ 互作时,F 值为

$$F_{AB} = \frac{s_{AB}^2}{s_e^2} \tag{6.34}$$

检验 A 因素、B 因素时,F 值为

$$\left.\begin{aligned} F_A &= \frac{s_A^2}{s_{AB}^2} \\ F_B &= \frac{s_B^2}{s_{AB}^2} \end{aligned}\right\} \tag{6.35}$$

c. 混合模型(以 A 为固定因素、B 为随机因素为例):在混合模型中,A 和 B 的效应为非可加性,α_i 为固定效应,β_j 及 $(\alpha\beta)_{ij}$ 为随机效应。对固定因素(A)作检验时同随机模型,对随机因素(B、$A\times B$)作检验时同固定模型,即

$$\left.\begin{aligned} F_A &= \frac{s_A^2}{s_{AB}^2} \\ F_B &= \frac{s_B^2}{s_e^2} \\ F_{AB} &= \frac{s_{AB}^2}{s_e^2} \end{aligned}\right\} \tag{6.36}$$

为了便于比较,将 3 种模型的方差分析列于表 6-25。

表 6-25　具重复观测值的二因素资料方差分析表

变异来源	SS	df	s^2
因素 A	SS_A	$a-1$	s_A^2
因素 B	SS_B	$b-1$	s_B^2
$A\times B$	SS_{AB}	$(a-1)(b-1)$	s_{AB}^2
误差	SS_e	$ab(n-1)$	s_e^2
总变异	SS_T	$abn-1$	

变异来源	固定模型		随机模型		混合模型(A 固定,B 随机)	
	F	期望方差	F	期望方差	F	期望方差
因素 A	$\frac{s_A^2}{s_e^2}$	$\sigma^2+bn\eta_a^2$	$\frac{s_A^2}{s_{AB}^2}$	$\sigma^2+n\sigma_{a\beta}^2+bn\sigma_a^2$	$\frac{s_A^2}{s_{AB}^2}$	$\sigma^2+n\sigma_{a\beta}^2+bn\eta_a^2$
因素 B	$\frac{s_B^2}{s_e^2}$	$\sigma^2+an\eta_\beta^2$	$\frac{s_B^2}{s_{AB}^2}$	$\sigma^2+n\sigma_{a\beta}^2+an\sigma_\beta^2$	$\frac{s_A^2}{s_e^2}$	$\sigma^2+an\sigma_\beta^2$
$A\times B$	$\frac{s_{AB}^2}{s_e^2}$	$\sigma^2+n\eta_{a\beta}^2$	$\frac{s_{AB}^2}{s_e^2}$	$\sigma^2+n\sigma_{a\beta}^2$	$\frac{s_{AB}^2}{s_e^2}$	$\sigma^2+n\sigma_{a\beta}^2$
误差		σ^2		σ^2		σ^2

在生物学及其相关学科实际应用中,固定模型应用最多,随机模型和混合模型相对较少。

【例 6.5】 为了研究某种昆虫滞育期长短与环境的关系,在给定的温度和光照条件下进行实验室培养,每一处理记录 4 只昆虫的滞育天数,结果列于表 6-26。试对该资料进行方差分析。

本例中,由于温度和光照条件都是人为控制的,均为固定因素,可依固定模型分析。将表 6-26 数字均减去 80,并整理于表 6-27 中。

平方和与自由度的分解:

$$C=\frac{T^2}{abn}=\frac{193^2}{3\times3\times4}=1034.69$$

$$SS_T=\sum x^2-C=(63^2+58^2+\cdots+3^2)-1034.69=14526.31$$

$$SS_A=\frac{\sum T_{i\cdot}^2}{bn}-C=\frac{271^2+(-26)^2+(-52)^2}{3\times4}-1034.69=5367.06$$

表 6-26　不同温度及光照条件下某种昆虫滞育天数　　(单位:d)

光照 (A)	温度 (B)		
	25℃	30℃	35℃
5h/d	143	101	89
	138	100	93
	120	80	101
	107	83	76
10h/d	96	79	80
	103	61	76
	78	83	61
	91	59	67
15h/d	79	60	67
	83	71	58
	96	78	71
	98	64	83

表 6-27　不同温度及光照条件下某昆虫滞育天数资料整理表

光照 (A)	标本号	温度 (B)			$T_{i\cdot}$
		25℃	30℃	35℃	
5h/d	1	63	21	9	271
	2	58	20	13	
	3	40	0	21	
	4	27	3	−4	
	T_{ij}	188	44	39	
10h/d	1	16	−1	0	−26
	2	23	−19	−4	
	3	−2	3	−19	
	4	11	−21	−13	
	T_{ij}	48	−38	−36	
15h/d	1	−1	−20	−13	−52
	2	3	−9	−22	
	3	16	−2	−9	
	4	18	−16	3	
	T_{ij}	36	−47	−41	
$T_{\cdot j}$		272	−41	−38	$T=193$

$$SS_B=\frac{\sum T_{\cdot j}^2}{an}-C=\frac{272^2+(-41)^2+(-38)^2}{3\times 4}-1034.69=5391.06$$

$$SS_{AB}=\frac{\sum T_{ij}^2}{n}-C-SS_A-SS_B$$

$$=\frac{188^2+44^2+\cdots+(-41)^2}{4}-1034.69-5367.06-5391.06=464.94$$

$$SS_e=SS_T-SS_A-SS_B-SS_{AB}$$

$$= 14526.31 - 5367.06 - 5391.06 - 464.94 = 3303.25$$

$$df_T = abn - 1 = 3 \times 3 \times 4 - 1 = 35$$

$$df_A = a - 1 = 3 - 1 = 2$$

$$df_B = b - 1 = 3 - 1 = 2$$

$$df_{AB} = (a-1)(b-1) = (3-1) \times (3-1) = 4$$

$$df_e = ab(n-1) = 3 \times 3 \times (4-1) = 27$$

将结果列入方差分析表(表 6-28)。从表 6-28 可以看出,不同光照和温度间的差异均达到了极显著,即昆虫滞育期长短主要取决于光照和温度,而与两者之间互作关系不大。

表 6-28　昆虫滞育天数方差分析表

变异来源	df	SS	s^2	F	$F_{0.05}$	$F_{0.01}$
光照间	2	5367.06	2683.53	21.93**	3.35	5.49
温度间	2	5391.06	2695.53	22.03**	3.35	5.49
光照×温度	4	464.94	116.24	0.95	2.73	4.11
误差	27	3303.25	122.34			
总变异	35	14526.31				

要了解各种光照时间及温度对滞育期的影响,需进行不同光照之间及不同温度之间的多重比较,其方法可参照前面例子进行。其平均数标准误的计算为:光照(A)间平均数标准误 $s_{\bar{x}} = \sqrt{\frac{s_e^2}{bn}}$,温度($B$)间平均数标准误 $s_{\bar{x}} = \sqrt{\frac{s_e^2}{an}}$。

【例 6.6】 用大麦生产啤酒过程中,需要研究烘烤方式(A)与大麦水分(B)对糖化时间的影响,选择 2 种烘烤方式、4 种大麦水分,共 8 种处理,每一处理重复 3 次,结果列于表 6-29。

表 6-29　不同烘烤方式及大麦水分对糖化时间的影响　　(单位:h)

烘烤方式(A)	水分(B)			
	B_1	B_2	B_3	B_4
A_1	12.0	9.5	16.0	18.0
	13.0	10.0	15.5	19.0
	14.5	12.5	14.0	17.0
A_2	5.0	13.0	17.5	15.0
	6.5	14.0	18.5	16.0
	5.5	15.0	16.0	17.5

本例中,烘烤方式这一因素是固定因素,大麦水分是不均匀的,又不易控制,所以该因素是随机因素,其效应也是随机的。由此可见,本题应采用混合模型进行方差分析。

将表 6-29 中各观测值都减去 10,整理后的数据列于表 6-30。

(1) 平方和与自由度的分解。

$$C = \frac{T^2}{abn} = \frac{90.5^2}{2 \times 4 \times 3} = 341.26$$

表 6-30　不同烘烤方式及水分的糖化时间数据整理表

烘烤方式 (A)	样本号	水分 (B)				$T_{i\cdot}$
		B_1	B_2	B_3	B_4	
A_1	1	2.0	−0.5	6.0	8.0	51.0
	2	3.0	0.0	5.5	9.0	
	3	4.5	2.5	4.0	7.0	
	T_{ij}	9.5	2.0	15.5	24.0	
A_2	1	−5.0	3.0	7.5	5.0	39.5
	2	−3.5	4.0	8.5	6.0	
	3	−4.5	5.0	6.0	7.5	
	T_{ij}	−13.0	12.0	22.0	18.5	
$T_{\cdot j}$		−3.5	14.0	37.5	42.5	$T = 90.5$

$$SS_T = \sum x^2 - C = 2.0^2 + (-0.5)^2 + \cdots + 7.5^2 - 341.26 = 363.99$$

$$SS_A = \frac{\sum T_{i\cdot}^2}{bn} - C = \frac{51.0^2 + 39.5^2}{4 \times 3} - 341.26 = 5.511$$

$$SS_B = \frac{\sum T_{\cdot j}^2}{an} - C = \frac{(-3.5)^2 + 14^2 + \cdots + 42.5^2}{2 \times 3} - 341.26 = 228.865$$

$$SS_{AB} = \frac{\sum T_{ij}^2}{n} - C - SS_A - SS_B$$

$$= \frac{9.5^2 + 2.0^2 + \cdots + 18.5^2}{3} - 341.26 - 5.511 - 228.865 = 107.614$$

$$SS_e = SS_T - SS_A - SS_B - SS_{AB}$$

$$= 363.99 - 5.51 - 228.865 - 107.615 = 22.000$$

$$df_T = abn - 1 = 2 \times 4 \times 3 - 1 = 23$$

$$df_A = a - 1 = 2 - 1 = 1$$

$$df_B = b - 1 = 4 - 1 = 3$$

$$df_{AB} = (a-1)(b-1) = (2-1) \times (4-1) = 3$$

$$df_e = ab(n-1) = 2 \times 4 \times (3-1) = 16$$

(2) 计算 F 值。

$$F_A = \frac{s_A^2}{s_{AB}^2} = \frac{5.511}{35.872} = 0.154$$

$$F_B = \frac{s_B^2}{s_e^2} = \frac{76.288}{1.375} = 55.482$$

$$F_{AB} = \frac{s_{AB}^2}{s_e^2} = \frac{35.872}{1.375} = 26.089$$

(3) 列出方差分析表并进行 F 检验(表 6-31)。

表 6-31　糖化时间方差分析表

变异来源	df	SS	s^2	F	$F_{0.05}$	$F_{0.01}$
烘烤方式(A)	1	5.511	5.511	0.154	10.13	34.12
水分(B)	3	228.865	76.288	55.482**	3.24	5.29
$A\times B$	3	107.614	35.872	26.089**	3.24	5.29
误差	16	22.000	1.375			
总变异	23	363.990				

由表 6-31 可以看出，大麦中的水分及水分与烘烤方式之间的互作对糖化时间的影响达到了极显著水平，而烘烤方式对糖化时间的作用则不显著。在生产中应注意大麦的含水量及根据含水量来选择合适的烘烤方式。

由本例可以看出，由于SS_{AB}一般要大于SS_e，尤其是在互作存在时SS_{AB}更是显著地偏大，因此若不注意区分是随机因素还是固定因素，就有可能错用统计量，导致错误的结论。因此在两个以上因素的方差分析中，区分因素类型显得更为重要。

在随机模型和混合模型中，如果不设重复，同样无法把SS_{AB}与SS_e分开，此时随机模型仍可对主效应进行检验，混合模型中也可以对固定因素的主效应进行检验。但当互作存在时，仅检验主效应是没有太大意义的，因为很可能是互作在起主要作用。因此只要条件许可，不论哪一类模型都应尽可能设置重复，除非有可靠的证据证明互作不存在。

第四节　多因素方差分析

实际工作中，往往需要考察三个或多个因素的效应。这相当于把二因素方差分析扩展到一般情况。本节仅对三因素的情况进行分析。设A因素有a个水平、B因素有b个水平、C因素有c个水平，假设每一处理都有n次重复，那么总观测次数为$abcn$次。对观测值x_{ijkl}，其三因素方差分析的线性数学模型为

$$x_{ijkl}=\mu+\alpha_i+\beta_j+\gamma_k+(\alpha\beta)_{ij}+(\alpha\gamma)_{ik}+(\beta\gamma)_{jk}+(\alpha\beta\gamma)_{ijk}+\varepsilon_{ijkl} \quad (6.37)$$

式中，x_{ijkl}为A因素第i水平、B因素第j水平、C因素第k水平、第l次重复的观测值(其中$i=1,2,\cdots,a$；$j=1,2,\cdots,b$；$k=1,2,\cdots,c$；$l=1,2,\cdots,n$)；μ为总体平均数；α_i、β_j、γ_k分别为A因素、B因素、C因素的效应；$(\alpha\beta)_{ij}$、$(\alpha\gamma)_{ik}$、$(\beta\gamma)_{jk}$分别为$A\times B$、$A\times C$、$B\times C$的交互效应；$(\alpha\beta\gamma)_{ijk}$为$A\times B\times C$的交互效应；$\varepsilon_{ijkl}$为试验误差。同时，应满足条件：① $\sum\alpha_i=\sum\beta_j=\sum\gamma_k=0$；② $\sum(\alpha\beta)_{ij}=\sum(\alpha\gamma)_{ik}=\sum(\beta\gamma)_{jk}=0$；③ $\sum(\alpha\beta\gamma)_{ijk}=0$；④ ε_{ijkl}是独立分布，服从$N(0,\sigma^2)$。

实际分析时，可列出 3 个两向表，把三因素方差分析转化为二因素方差分析。例如，把A、B条件下的全部结果列成一个两向表，如表 6-32 所示。

这样，可用二因素方差分析计算出SS_A、SS_B、SS_{AB}。类似地，也可把A、C，B、C二因素的数据列成两向表，用同样方法计算出SS_A、SS_C和SS_{AC}，以及SS_B、SS_C和SS_{BC}，其中SS_A、SS_B、SS_C不需重复计算。误差平方和SS_e为同一处理下数据的变异平方和，即

表 6-32　三因素数据资料的两向表

		B_j			
A_i	c_1	x_{ij11}	x_{ij12}	…	x_{ij1n}
	c_2	x_{ij21}	x_{ij22}	…	x_{ij2n}
	⋮	⋮	⋮		⋮
	c_c	x_{ijc1}	x_{ijc2}	…	x_{ijcn}

$$SS_e = \sum_i \sum_j \sum_k \sum_l (x_{ijkl} - \bar{x}_{ijk})^2 \tag{6.38}$$

总平方和为全部试验观测值的平方和，即

$$SS_T = \sum_i \sum_j \sum_k \sum_l x_{ijkl}^2 - \frac{T^2}{abcn} \tag{6.39}$$

总平方和可分解为

$$SS_T = SS_A + SS_B + SS_C + SS_{AB} + SS_{AC} + SS_{BC} + SS_{ABC} + SS_e \tag{6.40}$$

三因素方差分析模型列于表 6-33。

表 6-33　三因素数据资料方差分析表

变异来源	SS	df	s^2	固定模型	
				F	期望方差
A	SS_A	$a-1$	s_A^2	$\frac{s_A^2}{s_e^2}$	$\sigma^2 + bcn\eta_\alpha^2$
B	SS_B	$b-1$	s_B^2	$\frac{s_B^2}{s_e^2}$	$\sigma^2 + acn\eta_\beta^2$
C	SS_C	$c-1$	s_C^2	$\frac{s_C^2}{s_e^2}$	$\sigma^2 + abn\eta_\gamma^2$
$A\times B$	SS_{AB}	$(a-1)(b-1)$	s_{AB}^2	$\frac{s_{AB}^2}{s_e^2}$	$\sigma^2 + cn\eta_{\alpha\beta}^2$
$A\times C$	SS_{AC}	$(a-1)(c-1)$	s_{AC}^2	$\frac{s_{AC}^2}{s_e^2}$	$\sigma^2 + bn\eta_{\alpha\gamma}^2$
$B\times C$	SS_{BC}	$(b-1)(c-1)$	s_{BC}^2	$\frac{s_{BC}^2}{s_e^2}$	$\sigma^2 + an\eta_{\beta\gamma}^2$
$A\times B\times C$	SS_{ABC}	$(a-1)(b-1)(c-1)$	s_{ABC}^2	$\frac{s_{ABC}^2}{s_e^2}$	$\sigma^2 + n\eta_{\alpha\beta\gamma}^2$
误差	SS_e	$abc(n-1)$	s_e^2		σ^2

变异来源	随机模型		混合模型(假定 A、B 固定，C 随机)	
	F	期望方差	F	期望方差
A		$\sigma^2 + bcn\sigma_\alpha^2 + cn\sigma_{\alpha\beta}^2 + bn\sigma_{\alpha\gamma}^2 + n\sigma_{\alpha\beta\gamma}^2$	$\frac{s_A^2}{s_{AC}^2}$	$\sigma^2 + bcn\eta_\alpha^2 + bn\sigma_{\alpha\gamma}^2$
B		$\sigma^2 + acn\sigma_\beta^2 + cn\sigma_{\alpha\beta}^2 + an\sigma_{\beta\gamma}^2 + n\sigma_{\alpha\beta\gamma}^2$	$\frac{s_B^2}{s_{BC}^2}$	$\sigma^2 + acn\eta_\beta^2 + an\sigma_{\beta\gamma}^2$
C		$\sigma^2 + abn\sigma_\gamma^2 + bn\sigma_{\alpha\gamma}^2 + an\sigma_{\beta\gamma}^2 + n\sigma_{\alpha\beta\gamma}^2$	$\frac{s_C^2}{s_e^2}$	$\sigma^2 + abn\sigma_\gamma^2$

续表

变异来源	随机模型		混合模型(假定 A、B 固定,C 随机)	
	F	期望方差	F	期望方差
$A\times B$	$\frac{s_{AB}^2}{s_{ABC}^2}$	$\sigma^2+cn\sigma_{\alpha\beta}^2+n\sigma_{\alpha\beta\gamma}^2$	$\frac{s_{AB}^2}{s_{ABC}^2}$	$\sigma^2+cn\eta_{\alpha\beta}^2+n\sigma_{\alpha\beta\gamma}^2$
$A\times C$	$\frac{s_{AC}^2}{s_{ABC}^2}$	$\sigma^2+bn\sigma_{\alpha\gamma}^2+n\sigma_{\alpha\beta\gamma}^2$	$\frac{s_{AC}^2}{s_e^2}$	$\sigma^2+bn\sigma_{\alpha\gamma}^2$
$B\times C$	$\frac{s_{BC}^2}{s_{ABC}^2}$	$\sigma^2+an\sigma_{\beta\gamma}^2+n\sigma_{\alpha\beta\gamma}^2$	$\frac{s_{BC}^2}{s_e^2}$	$\sigma^2+an\sigma_{\beta\gamma}^2$
$A\times B\times C$	$\frac{s_{ABC}^2}{s_e^2}$	$\sigma^2+n\sigma_{\alpha\beta\gamma}^2$	$\frac{s_{ABC}^2}{s_e^2}$	$\sigma^2+n\sigma_{\alpha\beta\gamma}^2$
误差		σ^2		σ^2

【例 6.7】 为了研究在猪饲料中添加胱氨酸(因素 A)、甲硫氨酸(因素 B)和蛋白质(因素 C)对猪日增重的影响,设计了下面的试验,每一组以两头猪作重复,结果如表 6-34 所示。试对该资料进行方差分析。

表 6-34　猪日增重资料

胱氨酸(A)/%	甲硫氨酸(B)/%	蛋白质(C)/%	日增重 /kg		合计 /kg
0	0	12	1.11	0.97	2.08
		14	1.52	1.45	2.97
	0.025	12	1.09	0.99	2.08
		14	1.27	1.22	2.49
	0.05	12	0.85	1.21	2.06
		14	1.67	1.24	2.91
0.05	0	12	1.30	1.00	2.30
		14	1.55	1.53	3.08
	0.025	12	1.03	1.21	2.24
		14	1.24	1.34	2.58
	0.05	12	1.12	0.96	2.08
		14	1.76	1.27	3.03
0.10	0	12	1.22	1.13	2.35
		14	1.38	1.08	2.46
	0.025	12	1.34	1.41	2.75
		14	1.40	1.21	2.61
	0.05	12	1.34	1.19	2.53
		14	1.46	1.39	2.85
0.15	0	12	1.19	1.03	2.22
		14	0.80	1.29	2.09
	0.025	12	1.36	1.16	2.52
		14	1.42	1.39	2.81
	0.05	12	1.46	1.03	2.49
		14	1.62	1.27	2.89
合计			31.50	28.97	60.47

由于胱氨酸、甲硫氨酸和蛋白质添加量都是可控的,所以适用于固定模型。

(1) 将数据分别累加,记入表 6-35 ～ 表 6-37 中。

(2) 平方和计算:这里 $a=4, b=3, c=2, n=2$。

$$C=\frac{T^2}{abcn}=\frac{60.47^2}{4\times3\times2\times2}=76.1796$$

$$SS_T=\sum\sum\sum\sum x_{ijkl}^2-C=(1.11^2+0.97^2+\cdots+1.27^2)-76.1796=2.0409$$

$$SS_t=\frac{1}{n}\sum\sum\sum T_{ijk}^2-C=\frac{2.08^2+2.97^2+\cdots+2.89^2}{2}-76.1796=1.2756$$

$$SS_A=\frac{1}{bcn}\sum T_{i..}^2-C=\frac{1}{3\times2\times2}\times(14.59^2+\cdots+15.02^2)-76.1796=0.0427$$

表 6-35　表 6-34 资料 *A*×*B* 表

甲硫氨酸 (B)	胱氨酸 (A)				$T_{.j.}$
	0	0.05	0.10	0.15	
0	5.05	5.38	4.81	4.31	19.55
0.025	4.57	4.82	5.36	5.33	20.08
0.050	4.97	5.11	5.38	5.38	20.84
$T_{i..}$	14.59	15.31	15.55	15.02	60.47

表 6-36　表 6-34 资料 *A*×*C* 表

蛋白质 (C)	胱氨酸 (A)				$T_{..k}$
	0	0.05	0.10	0.15	
12	6.22	6.62	7.63	7.23	27.70
14	8.37	8.69	7.92	7.79	32.77
$T_{i..}$	14.59	15.31	15.55	15.02	60.47

表 6-37　表 6-34 资料 *B*×*C* 表

甲硫氨酸 (B)	蛋白质 (C)		$T_{.j.}$
	12	14	
0	8.95	10.60	19.55
0.025	9.59	10.49	20.08
0.050	9.16	11.68	20.84
$T_{..k}$	27.70	32.77	60.47

$$SS_B=\frac{1}{acn}\sum T_{.j.}^2-C=\frac{1}{4\times2\times2}\times(19.55^2+\cdots+20.84^2)-76.1796=0.0526$$

$$SS_C=\frac{1}{abn}T_{..k}^2-C=\frac{1}{4\times3\times2}\times(27.70^2+32.77^2)-76.1796=0.5355$$

$$SS_{AB}=\frac{1}{cn}\sum\sum T_{ij.}^2-C-SS_A-SS_B$$

$$=\frac{1}{2\times 2}\times(5.05^2+5.38^2+\cdots+5.38^2)-76.1796-0.0427-0.0526$$
$$=0.2544$$

$$SS_{AC}=\frac{1}{bn}\sum\sum T_{i\cdot k}^2-C-SS_A-SS_C$$
$$=\frac{1}{3\times 2}\times(6.22^2+6.62^2+\cdots+7.79^2)-76.1796-0.0427-0.5355$$
$$=0.2399$$

$$SS_{BC}=\frac{1}{an}\sum\sum T_{\cdot jk}^2-C-SS_B-SS_C$$
$$=\frac{1}{4\times 2}\times(8.95^2+10.60^2+\cdots+11.68^2)-76.1796-0.0526-0.5355$$
$$=0.0821$$

$$SS_{ABC}=\frac{1}{n}\sum\sum\sum T_{ijk}^2-C-SS_A-SS_B-SS_C-SS_{AB}-SS_{AC}-SS_{BC}$$
$$=\frac{2.08^2+2.97^2+\cdots+2.89^2}{2}-76.1796-0.0427-0.0526-0.5355$$
$$-0.2544-0.2399-0.0821=0.0685$$

$$SS_e=SS_T-SS_t=2.0409-1.2756=0.7653$$

(3) 自由度计算。

$$df_T=abcn-1=4\times 3\times 2\times 2-1=47$$
$$df_A=a-1=4-1=3$$
$$df_B=b-1=3-1=2$$
$$df_C=c-1=2-1=1$$
$$df_{AB}=(a-1)(b-1)=(4-1)\times(3-1)=6$$
$$df_{AC}=(a-1)(c-1)=(4-1)\times(2-1)=3$$
$$df_{BC}=(b-1)(c-1)=(3-1)\times(2-1)=2$$
$$df_{ABC}=(a-1)(b-1)(c-1)=(4-1)\times(3-1)\times(2-1)=6$$
$$df_e=abc(n-1)=4\times 3\times 2\times(2-1)=24$$

(4) 将以上结果列成方差分析表(表 6-38)。

表 6-38　表 6-34 猪日增重资料的方差分析表

变异来源	df	SS	s^2	F	$F_{0.05}$	$F_{0.01}$
胱氨酸(A)	3	0.0427	0.0142	0.445	3.01	4.72
蛋氨酸(B)	2	0.0526	0.0263	0.824	3.40	5.61
蛋白质(C)	1	0.5355	0.5355	16.787**	4.26	7.82
$A\times B$	6	0.2543	0.0424	1.329	2.51	3.67
$A\times C$	3	0.2399	0.0800	2.508	3.01	4.72
$B\times C$	2	0.0821	0.0410	1.285	3.40	5.61
$A\times B\times C$	6	0.0685	0.0114	0.357	2.51	3.67
误差	24	0.7653	0.0319			
总变异	47	2.0409				

检验结果表明，蛋白质添加量对猪日增重影响极显著，胱氨酸及甲硫氨酸添加量的影响不显著，可能的原因是在饲料中并不缺乏这两种氨基酸。

第五节　方差分析缺失数据的估计

进行方差分析时，其数据资料体系一般都是按照试验要求事先设计好的，在试验过程中经常会因意外事件使某一个或某几个数据丢失。例如，收获的作物可能遭到毁坏，动物可能有死亡，或者在记录时可能漏记或记错等。数据的缺失使平方和的线性可加模型无效，因此无法直接进行方差分析。缺失的数据可用统计方法从理论上进行估计，然后用前面介绍过的方法进行方差分析。但有一点必须明确，缺失数据估计并不能恢复原来的数据，只能是补足后不致干扰其余数据，估计的数据并不能提供任何新的信息。因此，试验中应尽量避免这类情况发生。弥补缺失数据的原则是，使补上缺失的数据后，误差平方和最小。

一、缺失一个数据的估计方法

假定表 6-39 中的 x_{23} 是缺失的，需要补上。

表 6-39　缺失一个数据的试验资料

	B_1	B_2	B_3	B_4	B_5	B_6	B_7	B_8	合计
A_1	30	39	41	42	42	39	38	38	309
A_2	37	46	x	43	51	44	35	49	$305+x$
A_3	27	37	36	24	37	41	33	43	278
A_4	30	42	35	40	46	47	38	46	324
总和	124	164	$112+x$	149	176	171	144	176	$1216+x$

误差平方和可由下式求出：

$$\begin{aligned} SS_e &= SS_T - SS_A - SS_B \\ &= (30^2 + 37^2 + \cdots + x^2 + \cdots + 46^2) \\ &\quad - \frac{1}{8} \times [309^2 + (305+x)^2 + \cdots + 324^2] \\ &\quad - \frac{1}{4} \times [124^2 + 164^2 + (112+x)^2 + \cdots + 176^2] \\ &\quad + \frac{1}{32} \times (1216+x)^2 \end{aligned}$$

为使 SS_e 达到最小，令 $\frac{\mathrm{d}SS_e}{\mathrm{d}x}=0$，则有

$$2x - \frac{1}{4} \times (305+x) - \frac{1}{2} \times (112+x) + \frac{1}{16} \times (1216+x) = 0$$

解该方程，得 $x = 42.857 \approx 43$。

把这个数据填在表 6-39 内，方差分析时除总自由度 df_T 和误差自由度 df_e 各需减 1 外，其他仍可以按前面介绍的方法进行。

二、缺失两个数据的估计方法

仍以表 6-39 数据为例，假定 x_{23} 和 x_{37} 都缺失，分别称为 x 和 y。其弥补原则和弥补一个数据是一样的，使 SS_e 达到最小。把表 6-39 数据重新整理成表 6-40。

与缺失一个数据的估计方法类似，计算误差平方和。

表 6-40　缺失两个数据的试验资料

	B_1	B_2	B_3	B_4	B_5	B_6	B_7	B_8	合计
A_1	30	39	41	42	42	39	38	38	309
A_2	37	46	x	43	51	44	35	49	$305+x$
A_3	27	37	36	24	37	41	y	43	$245+y$
A_4	30	42	35	40	46	47	38	46	324
总和	124	164	$112+x$	149	176	171	$111+y$	176	$1183+x+y$

$$
\begin{aligned}
SS_e &= SS_T - SS_A - SS_B \\
&= (30^2 + 37^2 + \cdots + x^2 + \cdots + y^2 + \cdots + 46^2) \\
&\quad - \frac{1}{8} \times [309^2 + (305+x)^2 + (245+y)^2 + 324^2] \\
&\quad - \frac{1}{4} \times [124^2 + 164^2 + (112+x)^2 + \cdots + (111+y)^2 + 176^2] \\
&\quad + \frac{1}{32} \times (1183 + x + y)^2
\end{aligned}
$$

为使 SS_e 极小，应满足：

$$
\begin{cases}
\dfrac{\partial SS_e}{\partial x} = 0 \\
\dfrac{\partial SS_e}{\partial y} = 0
\end{cases}
$$

即

$$
\begin{cases}
2x - \dfrac{1}{4} \times (305 + x) - \dfrac{1}{2} \times (112 + x) + \dfrac{1}{16} \times (1183 + x + y) = 0 \\
2y - \dfrac{1}{4} \times (245 + y) - \dfrac{1}{2} \times (111 + y) + \dfrac{1}{16} \times (1183 + x + y) = 0
\end{cases}
$$

经整理，解得：$x = 42.97$，$y = 30.57$。

丢失的两个数据补上后，在进行方差分析时误差自由度 df_e 及总自由度 df_T 均减 2。由于误差自由度减小，F 检验的灵敏度相应降低，对分析问题是不利的。

第六节　方差分析的基本假定和数据转换

一、方差分析的基本假定

对试验数据进行方差分析是有条件的，即方差分析的有效性建立在一些基本假定基础之上。如果分析的数据不符合这些基本假定，得出的结论就不会正确。一般地说，在试验设计时，就应考虑方差分析的条件。

(一) 正态性

正态性(normality)是指试验误差应当是服从正态分布 $N(0,\sigma^2)$ 的独立的随机变量。因为方差分析只能估计随机误差，顺序排列或顺序取样资料不能作方差分析。应用方差分析的资料应服从正态分布，即每一观测值 x_{ij} 应围绕相应的平均数呈正态分布。非正态分布的资料进行适当数据转换后，亦能进行方差分析。

(二) 可加性

可加性(additivity)是指处理效应与误差效应是可加的，并服从方差分析的数学模型，即 $x_{ij}=\mu+\alpha_i+\varepsilon_{ij}$，这样才能将试验的总变异分解为各种原因所引起的变异，以确定各变异在总变异中所占的比例，对试验结果作出客观评价。可加性是否显著有专门的统计方法。

(三) 方差同质性

方差同质性(homogeneity)是指所有试验的误差方差应具备同质性，即不同处理不能影响随机误差的方差，也称为方差齐性(homogeneity of variance)，即 $\sigma_1^2=\sigma_2^2=\cdots=\sigma_n^2$。因为方差分析是将各个处理的试验误差合并以得到一个共同误差方差，从而作为检验各处理平均数差异显著性的误差方差值，所以必须假定资料中这样一个共同方差存在。误差异质将使假设检验中某些处理效应得出不正确的结果。方差的同质性检验已在第四章介绍过。如果发现误差异质，只要不属于研究对象本身的原因，在不影响分析正确性的条件下，可将变异特别明显的数据剔除。当然在剔除数据时应十分小心，以免失掉某些信息，或者将试验分成几个部分进行分析，使每部分具有同质的方差。

二、数据转换

在生物学研究中经常会遇到一些样本，就其本身的性质来说，并不符合方差分析的基本假定。在进行方差分析之前，这些数据必须经过适当处理，即数据转换(transformation of data)以变更测量标尺。样本的非正态性、不可加性和方差异质性通常会连带出现。在进行数据转换中，根据实际经验，主要应考虑处理效应与误差效应的可加性，其次才考虑方差同质性。常用的转换方法如下所述。

(一) 平方根转换

有些生物学观测数据为泊松分布而非正态分布。例如，一定面积上某种杂草株数或昆虫头数等，样本平均数与其方差有某种比例关系。采用平方根转换(square root transformation)可以对方差进行降缩，减少极端大的变量对方差的影响，从而获得同质的方差。一般将原观测值转换成$\sqrt{x}$，数据较小时采用$\sqrt{x+1}$。

例如，表 6-41 中所列的一定面积燕麦田中某杂草的株数。从直观上看，A_1、A_2 和 A_3、A_4 及 A_5 间的数据相差太大，方差同质性是不成立的。

对表6-41资料，如算出误差项的方差，它可能是个平均值，用以检验 A_1、A_2 间差数则太小，用来检验 A_3、A_4 和 A_5 间的差数则太大。如果把表6-41中数据进行平方根转换(表6-42)，可以看出各处理资料的范围就相对减小了。

表 6-41　燕麦田中某种杂草的株数　　(单位：株)

处理	A_1	A_2	A_3	A_4	A_5
1	438	538	77	17	18
2	442	422	61	31	26
3	319	377	151	87	77
4	380	315	52	16	20
$\bar{x}_i$	394.75	413.00	85.25	37.75	35.25

表 6-42　表 6-40 资料的平方根

处理	A_1	A_2	A_3	A_4	A_5
1	20.9	23.2	8.8	4.1	4.2
2	21.0	20.5	7.8	5.6	5.1
3	17.9	19.4	12.3	9.3	8.8
4	19.5	17.7	7.2	4.0	4.5
$\bar{x}_i$	19.8	20.2	9.0	5.8	5.7

对表 6-42 数据进行方差分析，列入表 6-43。

表 6-43　表 6-42 资料方差分析表

变异来源	df	SS	s^2	F	$F_{0.05}$	$F_{0.01}$
处理间	4	866.663	216.666	46.43**	3.06	4.89
误差	15	69.995	4.666			
总变异	19	936.658				

(二) 对数转换

如果已知资料中的效应为相乘性或非相加性，或者标准差(或极差)与平均数成比例时，可以使用对数转换(logarithmic transformation)。一般是将原数据转换为对数($\lg x$ 或 $\ln x$)，从而使方差变成比较一致而且使效应由相乘性变为相加性。如果原始数据包括有 0，可以采用 $\lg(x+1)$ 转换的方法。通常情况下，对数转换对于削弱大变数的作用要比

平方根转换强。例如,1、10、100 进行平方根转换是 1、3.16、10,进行对数转换则为 0、1、2。

表 6-44 是 5 个时期用 3 种捕蛾灯捕获昆虫数目(个)的资料。

表 6-44　捕获昆虫统计资料及捕获数的对数值

时期	捕蛾灯			对数值		
	Ⅰ	Ⅱ	Ⅲ	Ⅰ	Ⅱ	Ⅲ
1	19.1	50.1	123.0	1.28	1.70	2.09
2	23.4	166.0	407.4	1.37	2.22	2.61
3	39.5	223.9	398.1	1.60	2.35	2.60
4	23.4	58.9	229.1	1.37	1.77	2.36
5	16.6	64.6	251.2	1.22	1.81	2.40
$\bar{x}_i$	24.4	112.7	281.8	1.37	1.97	2.41
极差	22.9	173.8	284.4	0.38	0.65	0.52

由表 6-44 可知,原始数据的平均数和极差近于正比关系,经对数转换后 3 个极差则较为接近,且与平均数无关。将对数转换后的数据进行方差分析,结果列于表 6-45。

表 6-45　表 6-44 资料对数转换后数据的方差分析表

变异来源	df	SS	s^2	F	$F_{0.05}$	$F_{0.01}$
时期间	4	0.4876	0.1219	8.08**	3.84	7.01
捕蛾灯	2	2.7504	1.3752	91.17**	4.46	8.65
误差	8	0.1200	0.0150			
总变异	14	3.3603				

结果表明,捕蛾灯及捕蛾时期之间的差异均达到极显著水平。

(三) 反正弦转换

如果数据是比例数或以百分率表示的,其分布趋向于二项分布,方差分析时应作反正弦转换(arcsine transformation),转换后的数值是以度为单位的角度,因此也称为角度转换(angle transformation)。转换的公式为

$$\theta = \sin^{-1}\sqrt{P} \tag{6.41}$$

式中,P 为百分数资料,θ 为相应的角度值。

二项分布的特点是其方差与平均数之间有一定的函数关系,即当平均数处于中间数值附近(即 50% 左右)时方差较大。将资料数据转换成角度以后,接近于 0 和 100% 的数值变异度增大,使方差变大,这样有利于满足方差同质性的要求。如果资料中的百分数为 30% ～ 70% 时,因资料的分布接近于正态分布,通常数据转换与否对分析结果影响不大。

【例 6.8】 研究低温贮藏不同时间对大白菜花粉生活力的影响,花粉置于冰箱中经 2h、4h、6h 后,镜检有生活力花粉的百分数,每处理检查 6 个视野,对照为新鲜花粉,结果如表 6-46 所示,试分析不同处理时间对花粉生活力影响的差异。

表 6-46　不同贮藏时间有生活力花粉百分数　　（单位：%）

处理	2h	4h	6h	对照
1	85	80	55	95
2	80	70	65	90
3	91	75	49	91
4	82	65	52	85
5	90	60	60	80
6	78	65	50	93

对表 6-46 的资料进行反正弦转换，得出各个观测值的反正弦角度 θ 值，列于表 6-47。对表 6-47 数据进行方差分析，列于表 6-48。

表 6-47　有生活力花粉的百分数的反正弦值

处理	2h	4h	6h	对照
1	67.2	63.4	47.9	77.1
2	63.4	56.8	53.7	71.6
3	72.5	60.0	44.4	72.5
4	64.9	53.7	46.1	67.2
5	71.6	50.8	50.7	63.4
6	62.0	53.7	45.0	74.7
$\bar{x}_i$	66.9	56.4	48.0	71.1

表 6-48　表 6-47 资料的方差分析表

变异来源	df	SS	s^2	F	$F_{0.05}$	$F_{0.01}$
处理间	3	1963.515	654.505	33.32**	3.10	4.49
误差	20	392.875	19.644			
总变异	23	2356.39				

用 LSD 法作多重比较：

$$LSD_{0.05}=\sqrt{\frac{2s_e^2}{n}}\times t_{0.05(20)}=\sqrt{\frac{2\times 19.644}{6}}\times 2.086=5.34$$

$$LSD_{0.01}=\sqrt{\frac{2s_e^2}{n}}\times t_{0.01(20)}=\sqrt{\frac{2\times 19.644}{6}}\times 2.845=7.28$$

用 LSD 法进行花粉生活力比较，结果列入表 6-49。

表 6-49　花粉生活力比较表（LSD 法）

处理	$\bar{x}_i$	与对照差异	反转换值
对照	71.1		89.5
2h	66.9	4.2	84.6
4h	56.4	14.7**	69.4
6h	48.0	23.1**	55.2

比较结果表明,贮藏 4h 和 6h 的花粉生活力均极显著地低于对照。表 6-49 最右边一列是将各反正弦平均数再转换为百分数,可以看出贮藏 2h、4h、6h 后,花粉生活力分别比对照降低了 4.9%、20.1%和 34.3%。

无论采用何种数据转换方法,在对转换后的数据进行方差分析时,若经检验差异显著,在进行平均数的多重比较时需用转换后的数据进行计算。但在解释分析其最终结果时,应还原为原来的数值。

以上为数据转换常用的 3 种方法。对于一般非连续性的数据,最好在方差分析前先检查各处理平均数与相应处理内均方是否存在相关性和各处理内均方间的变异是否较大。如果存在相关性,或者变异较大,则应考虑对数据作出转换。有时要确定适当的转换方法并不容易,可事先在试验中选取几个平均数为大、中、小的试验处理作转换,哪种方法能使处理平均数与其均方的相关性最小,哪种方法就是最合适的转换方法。另外,还可以使用其他的数据转换方法。例如,当各处理标准差与其平均数的平方成比例时,可进行倒数转换(reciprocal transformation)。

思考练习题

习题 6.1　什么是方差分析?方差分析的基本思想是什么?进行方差分析一般有哪些步骤?

习题 6.2　什么是多重比较?多重比较有哪些方法?多重比较的结果如何表示?

习题 6.3　方差分析有哪些基本假定?为什么有些数据需经过转换后才能进行方差分析?

习题 6.4　为研究氟对种子发芽的影响,分别用 0(对照),10,50,100(μg/g)4 种不同浓度的氟化钠溶液处理种子(浸种),每一种浓度处理的种子用培养皿进行发芽试验(每皿 50 粒,每处理重复 3 次)。观察它们的发芽情况,测得芽长资料如下表所示。试作方差分析,并用 *LSD* 法、*SSR* 法和 q 法分别进行多重比较。

处理/(μg/g)	芽长		
	1/cm	2/cm	3/cm
0(对照)	8.9	8.4	8.6
10	8.2	7.9	7.5
50	7.0	5.5	6.1
100	5.0	6.3	4.1

习题 6.5　用同一公猪对 3 头母猪进行配种试验,所产各头仔猪断奶时的体重(kg)资料如下:

No. 1:24.0,22.5,24.0,20.0,22.0,23.0,22.0,22.5;

No. 2:19.0,19.5,20.0,23.5,19.0,21.0,16.5;

No. 3:16.0,16.0,15.5,20.5,14.0,17.5,14.5,15.5,19.0。

试分析母猪对仔猪体重效应的差异显著性。

习题 6.6　选取 4 个品种的家兔,每一个品种用兔 7 只,测定其在不同室温下的血糖值,以每 100mg 血液中含葡萄糖的毫克(mg)数表示,试验资料见下表。试分析:各种家兔血糖值间有无差异?室温对家兔的血糖值有无影响?

品种	室温						
	35℃	30℃	25℃	20℃	15℃	10℃	5℃
Ⅰ	140	120	110	82	82	110	130
Ⅱ	160	140	100	83	110	130	120
Ⅲ	160	120	120	110	100	140	150
Ⅳ	130	110	100	82	74	100	120

习题 6.7　为了从 3 种不同原料和 3 种不同发酵温度中选出某物质较为适宜的条件，设计了一个二因素试验，并得到结果如下表所示。试对该资料进行方差分析。

原料(A)	温度(B)											
	B_1(30℃)				B_2(35℃)				B_3(40℃)			
A_1	41	49	23	25	11	13	25	24	6	22	26	18
A_2	47	59	50	40	43	38	33	36	8	22	18	14
A_3	43	35	53	50	55	38	47	44	30	33	26	19

习题 6.8　在药物处理大豆种子试验中，使用了大粒、中粒、小粒 3 种类型种子，分别用 5 种浓度、2 种处理时间进行试验处理，播种后 45d 对每种处理各取两个样本，每个样本取 10 株测定其干物重(g)，求其平均数，结果如下表所示。试进行方差分析。

处理时间(A)	种子类型(C)	浓度(B)				
		B_1(0μg/g)	B_2(10μg/g)	B_3(20μg/g)	B_4(30μg/g)	B_5(40μg/g)
A_1(12h)	C_1(小粒)	7.0	12.8	22.0	21.3	24.2
		6.5	11.4	21.8	20.3	23.2
	C_2(中粒)	13.5	13.2	20.8	19.0	24.6
		13.8	14.2	21.4	19.6	23.8
	C_3(大粒)	10.7	12.4	22.6	21.3	24.5
		10.3	13.2	21.8	22.4	24.2
A_2(24h)	C_1(小粒)	3.6	10.7	4.7	12.4	13.6
		1.5	8.8	3.4	10.5	13.7
	C_2(中粒)	4.7	9.8	2.7	12.4	14.0
		4.9	10.5	4.2	13.2	14.2
	C_3(大粒)	8.7	9.6	3.4	13.0	14.8
		8.5	9.7	4.2	12.7	12.6

第七章

直线回归与相关分析

本章提要

统计上常用回归与相关的方法探讨两个或多个变量之间的关系。直线回归与相关是最基本和最简单的回归和相关分析方法。常采用最小二乘法建立直线回归方程，变量 y 的离差平方和可以分解为回归平方和 U 和离回归平方和 Q，通过 F 检验或 t 检验的方法可检验直线回归关系的显著性。直线回归方程既可以描述两个变量间的依存关系，又可以用来进行预测和控制。相关系数反映了两个变量的相关程度和性质，可根据 t 检验或 r 检验对相关系数进行显著性检验。直线回归与相关之间存在一定的联系，对于两个变量而言，我们可以先计算其相关系数，相关系数通过显著性检验之后，可进一步研究其回归关系。

前面所讨论的统计方法，通常只涉及一个变量。例如，在不同品种的产量比较试验中，每一个品种的平均数反映了产量的集中点，标准差反映了产量的离散程度，方差分析及多重比较可检验不同品种产量平均数间的差异是否显著。在这些研究中，都涉及产量一个变量，而产量不仅与品种有关，还与肥料运筹、播种密度及灌水量等多种因素有关。因此，在试验研究的过程中经常要研究两个或两个以上变量之间的相互关系。

多变量间的相互关系有两类，一类是变量间存在确定的函数关系，如长方形的面积 $S=ab$、气体定律 $PV=RT$ 等。这些变量依公式关系而存在，只要知道了其中一个或多个变量值就可以精确地计算出另外变量的值。这类例子在生物界较少存在。另一类是变量间存在不确定的函数关系，不能用精确的函数式来表示。例如，人的身高和体重的关系，通常身高越高，体重越重。但是身高与体重之间不存在确定的函数关系，知道身高并不能得知准确的体重；同样，知道体重也不会得知准确的身高。就这些变量而言，一个变量发生变化，另一个变量也会跟着发生变化，在统计上常采用回归(regression)与相关(correlation)的分析方法探讨多变量之间的变化规律。

第一节　回归和相关的概念

变量间的相互关系，常见的有因果关系和平行关系。因果关系是指一个变量的变化受另一个变量或几个变量的制约。例如，微生物的繁殖速度受温度、湿度、光照等因素的影响，子女的身高受父母身高的影响等。平行关系是指两个以上变量之间共同受到另外因素的影响。例如，人的身高与体重之间的关系，兄弟身高之间的关系等。

对于两个变量，常用符号 x、y 表示，如果通过 n 次试验或调查获得两个变量的成对观测值，可表示为 $(x_1,y_1),(x_2,y_2),\cdots,(x_n,y_n)$。为了直观地看出 x 和 y 的变化关系，可将每一对观测值在平面直角坐标系中表示成一个点，作成散点图(scatter chart)。从散点图可以看出：① 两个变量间关系的性质和程度；② 两个变量间关系的类型，是直线型还是曲线型；③ 是否有异常观测值的干扰等。图 7-1 是 3 幅两个变量的散点图。从图中可以看出，图 7-1(a)、(b)都是趋向于直线型的，但图 7-1(a)的两个变量关系较图 7-1(b)密切，且是正向的，即随 x 增加 y 也增加；而图 7-1(b)是负向的，即随 x 增加 y 减小；图 7-1(c)的两个变量之间关系则是趋向于曲线型的。用散点图表示两个变量之间的关系只是进行了定性研究，为了定量地探讨它们之间的规律性，必须根据观测值将其理论关系推导出来。

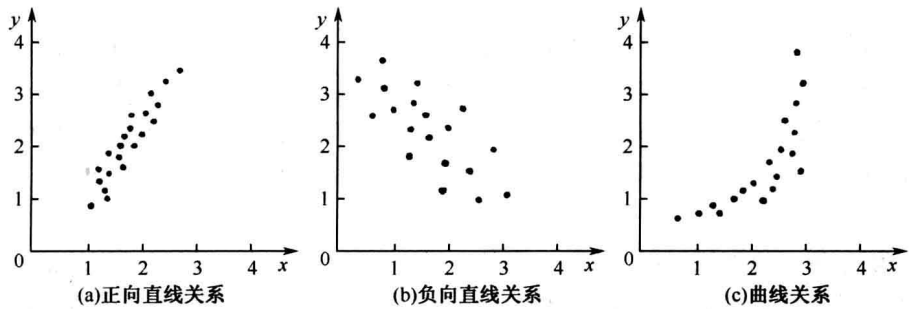

图 7-1　x 与 y 之间的关系

如果两个变量间的关系属于因果关系，一般用回归分析(regression analysis)来研究。表示原因的变量称为自变量(independent variable)，常用 x 表示，一般自变量是固定的(试验时预先确定的)，没有随机误差；表示结果的变量称为因变量或依变量(dependent variable)，常用 y 表示，y 是随 x 的变化而变化的，具有随机误差。例如，作物施肥量和产量之间的关系，前者是表示原因的变量，为事先确定的，是自变量；后者是表示结果的变量，为依变量，且具有随机误差。若对于变量 x 的每一个可能值 x_i，都有随机变量 y_i 的一个分布与之相对应，则称随机变量 y 对变量 x 存在回归关系。研究“一因一果”，即一个自变量与一个依变量的回归分析称为一元回归分析(one factor regression analysis)；研究“多因一果”，即多个自变量与一个依变量的回归分析称为多元回归分析(multiple regression analysis)。一元回归可分为直线回归(linear regression)与曲线回归(curve regression)两种；多元回归可分为多元线性回归(multiple linear regression)与多元非线

性回归(multiple nonlinear regression)两种。回归分析的目的是揭示呈因果关系的变量之间的联系形式,建立回归方程,利用建立的回归方程由自变量来预测和控制依变量。

如果两个变量间的关系属于平行关系,一般用相关分析(correlation analysis)来进行研究。在相关分析中,变量 x 和 y 无自变量和依变量之分,且都具有随机误差。两个随机变量 x 和 y,对于其中任一随机变量的每一个可能的值,另一个随机变量都有一个确定的分布与之相对应,则称这两个随机变量间存在相关关系。对两个变量间的直线关系进行相关分析称为直线相关(linear correlation)分析或简单相关(simple correlation)分析;对多个变量进行相关分析时,研究一个变量与多个变量间的线性相关称为复相关(multiple correlation)分析;研究其余变量保持不变的情况下两个变量间的线性相关称为偏相关(partial correlation)分析。相关分析研究的是两个变量之间相关的程度和性质或一个变量与多个变量之间相关的程度。

本章主要探讨直线回归分析与直线相关分析。

第二节　直线回归分析

直线回归是回归分析中最简单的一种,故又称为简单回归(simple regression)。

一、直线回归方程的建立

研究回归关系时,对自变量 x 的每一个取值 x_i,都有 y 的一个分布与之对应,而不是一个确定的 y_i 与之相对应。当 $x=x_i$ 时,y_i 的平均数 $\mu_{y/x=x_i}$ 与之是相对应的,$\mu_{y/x=x_i}$ 称为 y 的条件平均数(conditional mean)。在这种情况下,我们可以利用直线回归方程(linear regression equation)来描述 x 与 y 的均值的关系,其一般形式为

$$\hat{y}=a+bx \tag{7.1}$$

式(7.1)为"y 依 x 的直线回归方程"。其中,x 为自变量;$\hat{y}$ 为与 x 值相对应的依变量 y 的总体平均数的点估计值;a 为当 $x=0$ 时的 $\hat{y}$ 值,即直线在 y 轴上的截距(intercept),称为回归截距(regression intercept);b 为回归直线的斜率(slope),称为回归系数(regression coefficient),其含义是自变量 x 改变一个单位,依变量 y 平均增加或减少的单位数。

如果两个变量在散点图上呈线性关系,就可用直线回归方程来进行描述。为了使 $\hat{y}=a+bx$ 能最好地反映 y 和 x 两变量间的数量关系,根据最小二乘法(method of least square),a、b 应使依变量的观测值与回归估计值的离均差平方和最小,即

$$Q=\sum_{1}^{n}(y-\hat{y})^2=\sum_{1}^{n}(y-a-bx)^2=\text{最小值} \tag{7.2}$$

根据微积分学中的极值原理,必须使 Q 对 a、b 的一阶偏导数值为 0:

$$\frac{\partial Q}{\partial a}=-2\sum(y-a-bx)=0$$

$$\frac{\partial Q}{\partial b}=-2\sum(y-a-bx)x=0$$

整理得正规方程组(normal equation group):

$$\begin{cases} an + b\sum x = \sum y \\ a\sum x + b\sum x^2 = \sum xy \end{cases}$$

解方程组，得

$$a = \bar{y} - b\bar{x} \tag{7.3}$$

$$b = \frac{\sum xy - \frac{(\sum x)(\sum y)}{n}}{\sum x^2 - \frac{(\sum x)^2}{n}} = \frac{\sum (x-\bar{x})(y-\bar{y})}{\sum (x-\bar{x})^2} = \frac{SP}{SS_x} \tag{7.4}$$

式中，分子$\sum (x-\bar{x})(y-\bar{y})$为$x$的离均差和$y$的离均差乘积和(mean deviation product sum)，简称乘积和(product sum)，记作SP或SS_{xy}；分母$\sum (x-\bar{x})^2$为x的离均差平方和(mean deviation sum of square)，记作SS_x。

回归直线在平面直角坐标系中的位置取决于a、b的取值。由图7-2可以看出，$a>0$，表示回归直线在第Ⅰ象限与y轴相交；$a<0$，表示回归直线在第Ⅰ象限与x轴相交。$b>0$，表示y随x的增加而增加；$b<0$，表示y随x的增加而减小；$b=0$或与0差异不显著时，表示y的变化与x的取值无关，两变量不存在直线回归关系。这只是对a和b的统计学解释，对于具体资料，a和b通常还有专业上的实际意义。

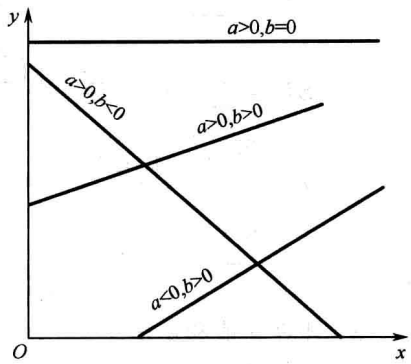

图7-2　直线回归方程$\hat{y} = a + bx$的图像

将x的取值代入直线回归方程，可计算出$\hat{y}$值，研究y和$\hat{y}$之间的关系，可发现回归方程的3个基本性质：

性质1　$Q = \sum (y - \hat{y})^2 =$最小值；

性质2　$\sum (y - \hat{y}) = 0$；

性质3　回归直线通过中心点$(\bar{x}, \bar{y})$。

将式(7.3)代入式(7.1)，得到直线回归方程的另一种形式：

$$\hat{y} = \bar{y} - b\bar{x} + bx = \bar{y} + b(x - \bar{x}) \tag{7.5}$$

【例7.1】　有人研究了黏虫孵化历期平均温度(x，℃)与历期天数(y，d)之间的关系，试验资料列于表7-1。试建立直线回归方程。

表7-1　黏虫孵化历期平均温度与历期天数资料

平均温度(x)/℃	11.8	14.7	15.6	16.8	17.1	18.8	19.5	20.4
历期天数(y)/d	30.1	17.3	16.7	13.6	11.9	10.7	8.3	6.7

(1) 计算回归分析的 6 个一级数据：

$$\sum x = 11.8 + 14.7 + \cdots + 20.4 = 134.70$$

$$\sum x^2 = 11.8^2 + 14.7^2 + \cdots + 20.4^2 = 2323.19$$

$$\sum y = 30.1 + 17.3 + \cdots + 6.7 = 115.30$$

$$\sum y^2 = 30.1^2 + 17.3^2 + \cdots + 6.7^2 = 2039.03$$

$$\sum xy = 11.8 \times 30.1 + 14.7 \times 17.3 + \cdots + 20.4 \times 6.7 = 1801.67$$

$$n = 8$$

(2) 由一级数据计算 5 个二级数据：

$$SS_x = \sum x^2 - \frac{\left(\sum x\right)^2}{n} = 2323.19 - \frac{134.70^2}{8} = 55.1788$$

$$SS_y = \sum y^2 - \frac{\left(\sum y\right)^2}{n} = 2039.03 - \frac{115.30^2}{8} = 377.2688$$

$$SP = \sum xy - \frac{\left(\sum x\right)\left(\sum y\right)}{n} = 1801.67 - \frac{134.70 \times 115.30}{8} = -139.6938$$

$$\bar{x} = \frac{\sum x}{n} = \frac{134.70}{8} = 16.8375$$

$$\bar{y} = \frac{\sum y}{n} = \frac{115.30}{8} = 14.4125$$

(3) 计算 b 值和 a 值：

$$b = \frac{SP}{SS_x} = \frac{-139.6938}{55.1788} = -2.5317$$

$$a = \bar{y} - b\bar{x} = 14.4125 - (-2.5317) \times 16.8375 = 57.0400$$

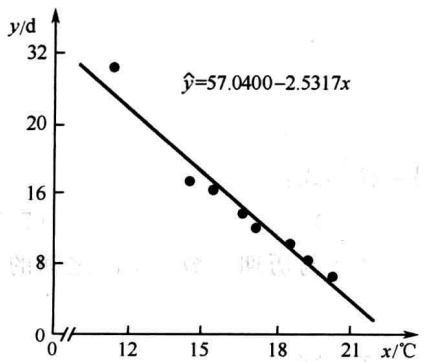

图 7-3　黏虫孵化平均温度与历期天数的关系

(4) 建立黏虫孵化历期天数依历期平均温度的直线回归方程：

$$\hat{y} = 57.0400 - 2.5317x$$

或

$$\hat{y} = 14.4125 - 2.5317(x - 16.8375)$$

从回归方程可知，黏虫孵化历期平均温度每增加 1℃，孵化历期就减少 2.5317d，当历期平均温度为 0℃ 时，孵化历期为 57.04d。但是，由于本例 x 的取值只为 11.8 ～ 20.4℃，$x = 0$ 不在此区间，是否符合 $\hat{y} = 57.0400 - 2.5317x$ 的变化规律，有待于实践进一步验证。

图 7-3 是该资料直线回归方程的图形。从图中可以看出，尽管 $\hat{y} = 57.0400 - 2.5317x$ 可以作为该资料的回归方程，但是并不是所有的

散点均恰好落在回归直线上，而是比较靠近回归直线，这说明用 x 去估计 y 是有随机误差的，因此必须根据回归的数学模型对随机误差进行估计，并对回归方程进行检验。

二、直线回归的数学模型和基本假定

（一）直线回归的数学模型

在直线回归中，y 总体的每一个观测值可分解为 3 个部分，即 y 的总体平均数 μ_y、因 x 引起 y 的变异 $\beta(x-\mu_x)$ 以及 y 的随机误差 ε。因此，直线回归的数学模型为

$$y=\mu_y+\beta(x-\mu_x)+\varepsilon \tag{7.6}$$

或

$$y=\alpha+\beta x+\varepsilon \tag{7.7}$$

式(7.6)和式(7.7)为总体资料直线回归的数学模型，其各部分含义如下所述。

(1) 常量 α。α 是总体回归截距，是回归直线在纵坐标的截距，它是 y 的本底水平，即 x 对 y 没有任何作用时 y 的数量表现。它属于不能用 x 来估计的部分。

(2) βx 部分。β 为总体回归系数，βx 表示依变量 y 的取值改变中，由 y 与自变量 x 的线性回归关系所引起变化的部分，即可以由 x 直接估计的部分。

(3) 回归估计误差 ε。ε 为随机误差，也称为回归估计误差(errors of regression)或残差、剩余(residual)。它表示依变量 y 的取值改变中由自变量 x 以外的其他所有未进入该模型或未知但可能与 y 有关的随机和非随机因素共同引起变化的部分，即不能由 x 直接估计的部分。也就是说，在回归方程中，第 i 个观察对象的残差 ε_i 是其依变量 y 的实测值 y_i 与其估计值 $\hat{y}_i$ 之差。

如果是样本资料，直线回归的数学模型为

$$y=\bar{y}+b(x-\bar{x})+e \tag{7.8}$$

或

$$y=a+bx+e \tag{7.9}$$

式(7.8)和式(7.9)中，a、b、e 分别为 α、β、ε 的估计值。

（二）直线回归的基本假定

按上述直线回归模型进行回归分析，应符合如下基本假定：

(1) x 是没有误差的固定变量，至少和 y 比较起来，x 的误差是小到可以忽略的，而 y 是随机变量，且具有随机误差。

(2) x 的任一值都对应着一个 y 总体，且呈正态分布，其平均数 $\mu_{y/x}=\alpha+\beta x$，方差 $\sigma^2_{y/x}$ 受偶然因素的影响，不因 x 的变化而改变。

(3) 随机误差 ε 是相互独立的，且呈正态分布，服从 $N(0,\sigma^2_\varepsilon)$。

直线回归分析建立在以上这些基本假定之上。如果试验资料不满足这些假定，就不能进行直线回归分析，但有些资料经适当处理后可满足这些假设，然后再进行直线回归分析，下文将作讨论。

三、直线回归的假设检验

任何两个变量之间都可通过前面的方法建立一个直线回归方程，该方程是否有意义，关键在于回归是否达到显著水平。我们知道，即使x、y所在的总体回归系数$\beta=0$，由于抽样误差，其样本回归系数b也不一定为零，因此需用方差分析或t检验进行β是否为零的假设检验。在讨论假设检验之前，我们先来分析依变量y的变异来源。

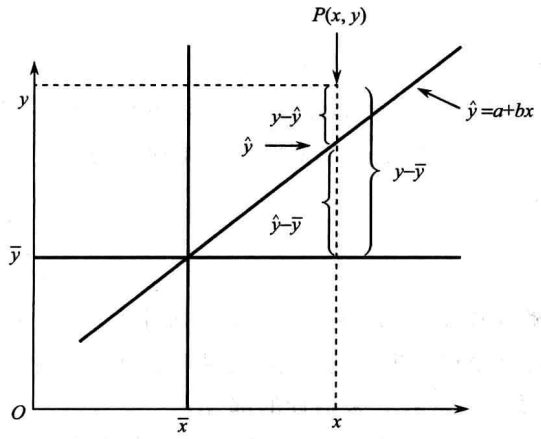

图 7-4　$(y-\bar{y})$的分解图

(一) 直线回归的变异来源

从图 7-4 可以看出，在直线回归中，依变量y是随机变量，y的总变异$(y-\bar{y})$可以分解为两部分，即由x变异引起的变异$(\hat{y}-\bar{y})$和误差所引起的变异$(y-\hat{y})$。因此：

$$\begin{aligned}\sum(y-\bar{y})^2&=\sum[(\hat{y}-\bar{y})+(y-\hat{y})]^2\\&=\sum(\hat{y}-\bar{y})^2+\sum(y-\hat{y})^2+2\sum(\hat{y}-\bar{y})(y-\hat{y})\end{aligned}$$

由直线回归方程

$$\hat{y}=\bar{y}+b(x-\bar{x})$$

得

$$\begin{aligned}\sum(\hat{y}-\bar{y})(y-\hat{y})&=\sum b(x-\bar{x})[(y-\bar{y})-b(x-\bar{x})]\\&=\sum b(x-\bar{x})(y-\bar{y})-b^2\sum(x-\bar{x})^2\\&=bSP-b^2SS_x\\&=bSP-bSP=0\end{aligned}$$

则有

$$\sum(y-\bar{y})^2=\sum(\hat{y}-\bar{y})^2+\sum(y-\hat{y})^2 \qquad (7.10)$$

式中，$\sum(y-\bar{y})^2$为依变量y的离均差的平方和，称为离均差平方和或总平方和，记作SS_y或$SS_{总}$，表明随机变量y的总变异。

$\sum(\hat{y}-\bar{y})^2$为由x变异引起y变异的平方和，称为回归平方和(regression sum of square)，记作U或$SS_{回归}$。它反映在y的总变异中由于x与y的直线关系而引起y变异的部分，也就是在总平方和中可以用x解释的部分。U越大，说明回归效果越好。

$\sum(y-\hat{y})^2$为误差因素引起的平方和，称为离回归平方和或残差平方和(剩余平方和)(residual sum of square)，记作Q、$SS_{离回归}$或$SS_{剩余}$。它反映除去x与y的直线回归关

系外的其余因素使y发生变异的部分，即反映x对y的线性影响之外的其他因素对y变异的作用，也就是在总平方和中无法用x解释的部分。在散点图上，各实测点离回归直线越近，Q值也就越小，说明直线回归的估计误差越小。

因此式(7.10)也可记作：

$$SS_y = U + Q \tag{7.11}$$

其中，

$$\begin{aligned} U &= \sum(\hat{y} - \bar{y})^2 \\ &= \sum[\bar{y} + b(x - \bar{x}) - \bar{y}]^2 \\ &= b^2 \sum(x - \bar{x})^2 \\ &= b^2 SS_x = bSP = \frac{SP^2}{SS_x} \end{aligned} \tag{7.12}$$

$$Q = SS_y - U \tag{7.13}$$

由于直线回归只涉及1个自变量，所以回归平方和的自由度为1。离回归平方和的自由度为$n-1-1=n-2$，离回归平方和除以相应自由度即为离回归方差，记作$s^2_{y/x}$，$s^2_{y/x}$的平方根值即为离回归标准差或残差标准差(residual standard deviation)，习惯上也称之为回归估计标准误(standard error of regression)，即

$$s_{y/x} = \sqrt{\frac{Q}{n-2}} \tag{7.14}$$

【例7.2】 试计算例7.1资料的回归平方和、离回归平方和及回归估计标准误。

根据前面计算结果，可得

$$U = bSP = -2.5317 \times (-139.6937) = 353.6625$$

$$Q = SS_y - U = 377.2688 - 353.6625 = 23.6063$$

$$s_{y/x} = \sqrt{\frac{Q}{n-2}} = \sqrt{\frac{23.6063}{8-2}} = 1.9835$$

(二) F 检验

两个变量是否存在线性关系，可采用F检验法进行。假设H_0：两变量间无线性关系，对H_A：两变量有线性关系。在无效假设下，回归方差与离回归方差的比值服从$df_1 = 1$和$df_2 = n-2$的F分布，可用

$$F = \frac{\frac{U}{1}}{\frac{Q}{n-2}} = \frac{U}{Q} \times (n-2) \tag{7.15}$$

来检验直线回归方程的显著性。

【例7.3】 用F检验的方法检验例7.1资料直线回归关系的显著性。

假设H_0：黏虫孵化历期平均温度x与历期天数y之间无线性关系；H_A：二者存在线性关系。

将 F 检验结果列于表 7-2。

表 7-2　例 7.1 资料回归关系的假设检验

变异来源	df	SS	s^2	F	$F_{0.05}$	$F_{0.01}$
回归	1	353.6625	353.6625	89.890**	5.99	13.74
离回归	6	23.6063	3.9344			
总变异	7	377.2688				

因 $F > F_{0.01}$，所以否定 H_0，接受 H_A，说明黏虫孵化历期平均温度与历期天数之间有极显著的直线回归关系。

(三) t 检验

采用 t 检验也可以检验线性回归关系的显著性。假设 $H_0:\beta=0$，对 $H_A:\beta\neq 0$。该方法是检验样本回归系数 b 是否来自 $\beta=0$ 的双变量总体，以推断线性回归的显著性。

回归系数的标准误 s_b 和 t 值为

$$s_b=\sqrt{\frac{\sum(y-\hat{y})^2}{(n-2)\sum(x-\bar{x})^2}}=\frac{s_{y/x}}{\sqrt{SS_x}} \tag{7.16}$$

$$t=\frac{b-\beta}{s_b}=\frac{b}{s_b} \tag{7.17}$$

式(7.17)遵循 $df=n-2$ 的 t 分布，由 t 值可得出样本回归系数 b 落在 $\beta=0$ 总体中的区间概率。

【例 7.4】　用 t 检验的方法检验例 7.1 资料回归关系的显著性。

前面已计算出 $s_{y/x}=1.9835$，$SS_x=55.1788$，$b=-2.5317$，所以：

$$s_b=\frac{s_{y/x}}{\sqrt{SS_x}}=\frac{1.9835}{\sqrt{55.1788}}=0.2670$$

$$t=\frac{b}{s_b}=\frac{-2.5317}{0.2670}=-9.482$$

查附表 3，当 $df=n-2=8-2=6$ 时，$t_{0.01}=3.707$，$|t|=9.482>t_{0.01}$，应否定 H_0，接受 H_A，认为黏虫孵化历期平均温度与历期天数之间有极显著的直线回归关系。

上述 t 检验和 F 检验，都是对直线回归关系的假设检验，二者的检验结果是完全一致的。因为在同一概率值下，$df_1=1$、$df_2=n-2$ 的一尾 F 值为 $df=n-2$ 的两尾 t 值的平方，且计算出的 F 值也是 t 值的平方。本例中 $t^2=(-9.482)^2=89.908$ 与 $F=89.890$ 的微小差异是在计算过程中有效位数的不同而造成的。由式(7.18)也可以看出：

$$t^2=\left(\frac{b}{s_b}\right)^2=\frac{b^2}{\frac{s^2_{y/x}}{SS_x}}=\frac{b^2SS_x}{s^2_{y/x}}=\frac{U}{\frac{Q}{n-2}}=F \tag{7.18}$$

四、直线回归的区间估计

当直线回归关系显著之后，既可用样本统计数 a、b 来估计总体参数 α、β，又可利用回

归方程去估计某一 x 值对应 y 总体的平均数和预测单个 y 值所在的区间。

(一) 回归截距和回归系数的置信区间

根据公式 $a=\bar{y}-b\bar{x}$，得到回归截距 a 的方差为

$$s_a^2=s_{y/x}^2\left(\frac{1}{n}+\frac{\bar{x}^2}{SS_x}\right)$$

因而回归截距 a 的标准误 s_a 和 t 值为

$$s_a=s_{y/x}\sqrt{\frac{1}{n}+\frac{\bar{x}^2}{SS_x}} \tag{7.19}$$

$$t=\frac{a-\alpha}{s_a} \tag{7.20}$$

式(7.20)服从 $df=n-2$ 的 t 分布，所以总体回归截距 α 的置信区间为

$$(L_1=a-t_as_a,L_2=a+t_as_a) \tag{7.21}$$

由于 $\frac{b-\beta}{s_b}$ 服从 $df=n-2$ 的 t 分布，故总体回归系数 β 的置信区间为

$$(L_1=b-t_as_b,L_2=b+t_as_b) \tag{7.22}$$

【例 7.5】 试计算例 7.1 资料回归截距和回归系数的 95%置信区间。

由式(7.19)，求得

$$s_a=s_{y/x}\sqrt{\frac{1}{n}+\frac{\bar{x}^2}{SS_x}}=1.9835\times\sqrt{\frac{1}{8}+\frac{16.8375^2}{55.1788}}=4.5503$$

查附表 3，$t_{0.05(6)}=2.447$，根据式(7.21)得回归截距 95% 的置信区间为

$$L_1=a-t_{0.05}s_a=57.0400-2.447\times4.5503=45.9054$$

$$L_2=a+t_{0.05}s_a=57.0400+2.447\times4.5503=68.1746$$

表明在研究黏虫孵化历期平均温度与历期天数关系时，将有 95%的总体回归截距在(45.9054,68.1746)这一区间内。

同理，根据式(7.22)，所求回归系数 95%的置信区间为

$$L_1=b-t_{0.05}s_b=-2.5317-2.447\times0.2670=-3.1850$$

$$L_2=b+t_{0.05}s_b=-2.5317+2.447\times0.2670=-1.8784$$

这说明黏虫孵化历期平均温度和历期天数的总体回归系数在(−3.1850，−1.8784) 区间的可靠度为 95%。

(二) $\mu_{y/x}$ 的置信区间和单个 y 的预测区间

由 x 的任一值对应 y 总体的平均数 $\mu_{y/x}$ 的样本估计值为：$\hat{y}=\bar{y}+b(x-\bar{x})$，这一估计值受 $\bar{y}$ 和 b 的抽样误差的影响。对于给定的 x，预测总体平均数 $\mu_{y/x}$ 时 $\hat{y}$ 的方差为

$$s_{\hat{y}}^2=s_{y/x}^2\left[\frac{1}{n}+\frac{(x-\bar{x})^2}{SS_x}\right]$$

于是，$\hat{y}$ 的标准误为

$$s_{\hat{y}}=s_{y/x}\sqrt{\frac{1}{n}+\frac{(x-\bar{x})^2}{SS_x}} \tag{7.23}$$

而且$\frac{\hat{y}-\mu_{y/x}}{s_{\hat{y}}}$服从$df=n-2$的$t$分布，所以$\mu_{y/x}$的置信区间为

$$(L_1=\hat{y}-t_\alpha s_{\hat{y}},L_2=\hat{y}+t_\alpha s_{\hat{y}}) \tag{7.24}$$

如果由回归方程去预测x为某一值时y的观测值所在区间，则y观测值不仅受$\bar{y}$和b的影响，还受随机误差的影响。预测单个y观测值的方差为

$$s_y^2=s_{y/x}^2\left[1+\frac{1}{n}+\frac{(x-\bar{x})^2}{SS_x}\right]$$

单个y值的标准误为

$$s_y=s_{y/x}\sqrt{1+\frac{1}{n}+\frac{(x-\bar{x})^2}{SS_x}} \tag{7.25}$$

而且$\frac{y-\hat{y}}{s_y}$近似服从$df=n-2$的t分布，所以某一x值对应y观测值的预测区间为

$$(L_1=\hat{y}-t_\alpha s_y,L_2=\hat{y}+t_\alpha s_y) \tag{7.26}$$

$\mu_{y/x}$的置信区间和单个y的预测区间的意义相似。但$\mu_{y/x}$的置信区间是对常量(总体参数)的推断，主要用于推断总体平均数；而单个y的预测区间是对变量的推断，主要用于推断单一变量。

【例 7.6】 试根据例 7.1 资料，估计黏虫孵化历期平均温度为 15℃时历期天数为多少天(取 95%置信概率)？若某年的历期平均温度为 15℃，该年黏虫孵化的历期天数为多少天(取 95%置信概率)？

根据题意可知，第一个问题是估计$x=15$时y总体平均数的置信区间，第二个问题是估计$x=15$时对应y观测值所在的观测区间。

当$x=15$时，有

$$\hat{y}=a+bx=57.0400+(-2.5317)\times 15=19.0645$$

根据式(7.23)和式(7.25)，有

$$s_{\hat{y}}=s_{y/x}\sqrt{\frac{1}{n}+\frac{(x-\bar{x})^2}{SS_x}}=1.9835\times\sqrt{\frac{1}{8}+\frac{(15-16.8375)^2}{55.1788}}=0.8559$$

$$s_y=s_{y/x}\sqrt{1+\frac{1}{n}+\frac{(x-\bar{x})^2}{SS_x}}=1.9835\times\sqrt{1+\frac{1}{8}+\frac{(15-16.8375)^2}{55.1788}}=2.1603$$

由式(7.24)，当$x=15$时，$\mu_{y/x}$的 95% 置信区间为

$$L_1=\hat{y}-t_{0.05}s_{\hat{y}}=19.0645-2.447\times 0.8559=16.9701$$

$$L_2=\hat{y}+t_{0.05}s_{\hat{y}}=19.0645+2.447\times 0.8559=21.1589$$

即当黏虫孵化历期平均温度为 15℃时，历期平均天数的 95% 置信区间为(16.9701d,21.1589d)。

由式(7.26)，$x=15$时，对应y观测值的 95% 置信区间为

$$L_1=\hat{y}-t_{0.05}s_y=19.0645-2.447\times 2.1603=13.7782$$

$$L_2=\hat{y}+t_{0.05}s_y=19.0645+2.447\times 2.1603=24.3508$$

即某年黏虫孵化历期平均温度为 15℃时，该年黏虫孵化历期天数的 95% 置信区间

为(13.7782d,24.3508d)。

(三) $\mu_{y/x}$的置信区间和单个 y 观测值预测区间图示

由式(7.23)和式(7.25)可以看出，$s_{\hat{y}}$ 和 s_y 都与$(x-\bar{x})^2$ 有关，它们之间是变形的双曲线关系，所以 $s_{\hat{y}}$ 和 s_y 的估计值因 x 的不同而异，当 $x=\bar{x}$ 时取最小值，即 $\mu_{y/x}$ 和单个 y 的估计区间最小。如果将置信区间制作成图，便可从图上进行推断和预测。

【例 7.7】 制作例 7.1 资料 $\mu_{y/x}$ 的 95% 置信区间和单个 y 的 95% 预测区间图。

首先根据 x 的取值范围选取间距为 1 的 9 个 x 值，将各个 x 值代入回归方程$\hat{y}=57.0400-2.5317x$，得到相应的$\hat{y}$值，然后计算相应的 $s_{\hat{y}}$ 和 s_y 值以及 $t_{0.05}s_{\hat{y}}$ 和 $t_{0.05}s_y$ 值，从而估计出 $\mu_{y/x}$ 置信区间和单个 y 的 95% 预测区间，计算结果见表 7-3。

表 7-3　例 7.1 资料 $\mu_{y/x}$ 95%的置信区间与单个 y 的 95%预测区间

(1) x	(2) $\hat{y}$	$\mu_{y/x}$ 的 95% 置信区间的计算				y 的 95% 预测区间的计算			
		(3) $s_{\hat{y}}$	(4) $t_{0.05}s_{\hat{y}}$	(5)		(6) s_y	(7) $t_{0.05}s_y$	(8)	
				$(L_1$	$L_2)$			$(L_1$	$L_2)$
12	26.7	1.47	3.6	23.1	30.3	2.47	6.0	20.6	32.7
13	24.1	1.24	3.0	21.1	27.2	2.34	5.7	18.4	29.9
14	21.6	1.03	2.5	19.1	24.1	2.24	5.5	16.1	27.1
15	19.1	0.86	2.1	17.0	21.2	2.16	5.3	13.8	24.4
16	16.5	0.74	1.8	14.7	18.3	2.12	5.2	11.4	21.7
17	14.0	0.70	1.7	12.3	15.7	2.10	5.1	8.9	19.2
18	11.5	0.77	1.9	9.6	13.3	2.13	5.2	6.3	16.7
19	8.9	0.91	2.2	6.7	11.2	2.18	5.3	3.6	14.3
20	6.4	1.10	2.7	3.7	9.1	2.27	5.5	0.9	12.0

将表 7-3 中的(1)列 x 的值分别与(5)列的 L_1 和 L_2 的值在坐标系中作成散点，分别连接以 x 与 L_1、x 与 L_2 为坐标的点，得到两条曲线，这两条曲线中间的区域即为 $\mu_{y/x}$ 的 95% 置信区间，简称 $\mu_{y/x}$ 的95%置信带。将表 7-3 中的(1)列 x 的值分别与(8)列的 L_1 和 L_2 的值在坐标系中作成散点，分别连接以 x 与 L_1、x 与 L_2 为坐标的点，也得到两条曲线，这两条曲线中间的区域即为单个 y 的95%预测区间，简称为单个 y 值的 95% 置信带。由图 7-5 可以看出，单个 y 的置信带要比 $\mu_{y/x}$ 的置信带宽；x 偏离 $\bar{x}$ 越远，置信带越宽，预测效果越差。通过图 7-5 中 $\mu_{y/x}$ 与单个 y 的95%置信带，就可由黏虫孵化历期平均温度对孵化历期天数总体平均数的置信区间作出估计及对单个 y 观测值的区间直接作出预报。

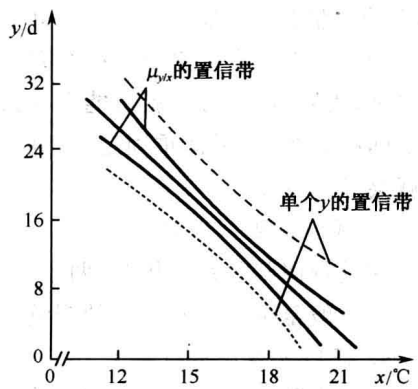

图 7-5　$\mu_{y/x}$ 与单个 y 的 95% 置信带

五、直线回归的应用及注意问题

(一) 直线回归的应用

直线回归方程主要应用于以下 3 个方面。

1. 描述两个变量的依存关系

通过直线回归方程或回归系数的假设检验,若认为两个变量间存在直线回归关系,则可以利用直线回归方程描述 x 和 y 两个变量之间的数量关系。

2. 在一定范围内对依变量 y 进行预测

在自变量 x 的观测范围内对依变量 y 进行估计,就是把自变量 x 代入回归方程对依变量 y 进行估计。一般常用区间估计求出当 x 取某定值时 y 值的波动范围,从而进行预测(forecast)。

3. 通过控制自变量 x 来对依变量 y 进行控制

根据实际工作需求,利用回归方程进行逆运算,通过控制(control)自变量 x 的取值来限定依变量 y 在一定范围内的波动。

(二) 应用直线回归时应注意的问题

1. 进行回归分析要有意义

变量间是否存在直线回归关系,求出的直线回归方程是否有意义,都必须由各具体学科本身来决定,并且还要在实践中进行检验。回归只能作为一种统计分析手段,帮助认识和解释事物的客观规律,绝不能把风马牛不相及的资料凑到一起进行分析,否则将会造成根本性的错误。

2. 回归变量的确定

如果两个有内在联系的变量之间是一种依存的因果关系,应该以"因"的变量为 x,以"果"的变量为 y。如果变量之间并无明显的因果关系,则应以易于测定、较为稳定或变异较小的变量作为自变量 x。在研究两个变量之间的关系时,要求其余变量尽量保持在同一水平,否则,回归分析就可能会导致不可靠甚至完全虚假的结果。例如,人的身高和胸围之间的关系,如果体重固定,身高越高的人,胸围一定较小,但如果体重在变化时,其结果就会发生变化。

3. 观测值要尽可能多

在进行回归关系分析时,两个变量成对观测值应尽可能多一些,这样可提高分析的准确性。一般至少有 5 对以上的观测值,同时变量 x 的取值范围要尽可能大一些。

4. 回归方程应进行检验

回归方程建立后必须作假设检验,只有经检验拒绝了无效假设,回归方程才有意义。一个不显著的回归系数并不意味着变量之间没有回归关系,而只能说明两个变量间没有显著的直线回归关系,这并不排除有能够更好地描述它们关系的非线性方程的存在。

5. 预测和外推要谨慎

使用回归方程计算估计值时,一般不可把估计的范围扩大到建立方程时的自变量的

取值范围之外。如果超出这个取值范围，变量间的关系类型可能会发生改变，所以回归预测必须限制自变量 x 的取值区间，外推要谨慎，否则会得出错误的结果。

第三节　直线相关

一、相关系数和决定系数

如果两个变量间呈线性关系，但不需要由一个变量来估计另一个变量，只需了解两个变量的相关程度(degree of correlation)以及相关性质(character of correlation)，可以通过计算表示两个变量相关程度和性质的统计数——相关系数(correlation coefficient)来进行研究。

直线相关常用于分析双变量正态分布的资料。设有一双变量总体资料，两个变量分别用 x、y 来表示，总体个体数为 N，这 N 对观测值在平面直角坐标系中可用坐标点来表示。如将 x 轴和 y 轴平移，使原点位于点 (μ_x,μ_y) 上，则原坐标 (x,y) 转变为 $(x-\mu_x,y-\mu_y)$。若资料的多数散点在Ⅰ、Ⅲ象限，由于在Ⅰ象限中，$x-\mu_x>0$、$y-\mu_y>0$，在Ⅲ象限中，$x-\mu_x<0$、$y-\mu_y<0$，其离均差的乘积和 $\sum(x-\mu_x)(y-y_y)>0$，因此在Ⅰ、Ⅲ象限散点越多，这个正值的乘积和越大。由于在Ⅱ象限中，$x-\mu_x<0$、$y-\mu_y>0$，在Ⅳ象限中，$x-\mu_x>0$、$y-\mu_y<0$，其离均差的乘积和 $\sum(x-\mu_x)(y-\mu_y)<0$，因此若散点在Ⅱ、Ⅳ象限越多，离均差乘积和的绝对值就越大。若散点均匀地分布在4个象限中，由于正负相消，$\sum(x-\mu_x)(y-\mu_y)=0$ 或接近于0。参见图7-6。

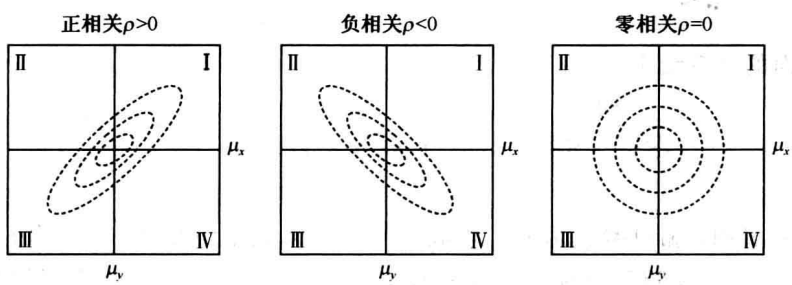

图7-6　3种不同的总体相关散点图

由此可见，乘积和可用以表示直线相关的两个变量的相关程度和性质。但是，不同的双变量资料其乘积和无可比性，因为 x 和 y 的变异程度及其度量单位、N 的大小都会影响乘积和。要消除这种影响，可将离均差转换成各自的标准差，再以 N 除之。因此，定义双变量总体的相关系数 ρ 值为

$$\rho=\frac{1}{N}\sum\left[\left(\frac{x-\mu_x}{\sigma_x}\right)\left(\frac{y-\mu_y}{\sigma_y}\right)\right]=\frac{\sum(x-\mu_x)(y-\mu_y)}{\sqrt{\sum(x-\mu_x)^2\cdot\sum(y-\mu_y)^2}} \tag{7.27}$$

式中，ρ 与两个变量的变异程度、度量单位及 N 的大小均没有关系，因而可用来比较不同双变量总体的相关程度和性质。

当研究的是样本资料时，样本相关系数 r 值为

$$r=\frac{\sum(x-\bar{x})(y-\bar{y})}{\sqrt{\sum(x-\bar{x})^2\cdot\sum(y-\bar{y})^2}}=\frac{SP}{\sqrt{SS_x\cdot SS_y}}=\sqrt{\frac{U}{SS_y}} \tag{7.28}$$

从式(7.28)中可以看出，两个变量在相关系数计算中的地位是平等的，没有自变量和依变量之分，这是与回归的主要区别。相关系数 r 的实质就是变量 x 引起 y 变异的回归平方和占 y 变异总平方和比率的平方根。因此，r 的取值区间为[−1,1]。若 r 的绝对值为 1，称为绝对相关(absolute correlation)或完全相关(complete correlation)；若 r 的绝对值越接近于 1，相关程度越高。若 r 的绝对值为 0，称为绝对无关(absolute irrelevance)或完全无关(complete irrelevance)或零相关(null correlation)；若 r 的绝对值越接近于 0，越无相关性。r 的正与负，是表示相关性质的。r 为正值表示正相关(positive correlation)，即 x 增大时 y 也增大；r 为负值表示负相关(negative correlation)，即 x 增大时 y 反而减小。

统计中还有另外一个表示相关程度的统计数——决定系数(coefficient of determination)。决定系数定义为相关系数 r 的平方，其计算公式为

$$r^2=\frac{SP^2}{SS_xSS_y}=\frac{bSP}{SS_y}=\frac{U}{SS_y}=1-\frac{Q}{SS_y} \tag{7.29}$$

因此，r^2 的含义是变量 x 引起 y 变异的回归平方和占 y 变异总平方和的比率。r^2 的取值范围为[0,1]，它只能表示相关程度而不能表示相关性质。

【例 7.8】 求例 7.1 资料黏虫孵化历期平均温度与历期天数的相关系数和决定系数。

根据前面的计算结果，可得

$$r=\frac{SP}{\sqrt{SS_x\cdot SS_y}}=\frac{-139.6938}{\sqrt{55.1788\times 377.2688}}=-0.9682$$

$$r^2=(-0.9682)^2=0.9374$$

以上结果表明，黏虫孵化历期平均温度与历期天数呈负相关，即平均温度越高，历期天数越少。$r^2=0.9374$ 表明 y 的变异有 93.74% 可用 y 与 x 二者之间的线性关系来解释。

二、相关系数的假设检验

由于抽样误差的存在，从 $\rho=0$ 的双变量正态总体中抽出的样本相关系数 r 不一定等于 0。所以，为了判断 r 所代表的总体是否存在直线相关，必须计算 r 来自 $\rho=0$ 总体的概率。因此，需进行相关系数的假设检验。

相关系数的标准误 s_r 和 t 值为

$$s_r=\sqrt{\frac{1-r^2}{n-2}} \tag{7.30}$$

$$t=\frac{r-\rho}{s_r} \tag{7.31}$$

式(7.31)服从自由度$df=n-2$的t分布。检验时，假设$H_0:\rho=0$；$H_A:\rho\neq 0$。在无效假设下，式(7.31)可写为

$$t=\frac{r}{s_r}=\frac{r\sqrt{n-2}}{\sqrt{1-r^2}} \tag{7.32}$$

【例 7.9】 试检验例 7.8 中所求相关系数的显著性。

首先作统计假设$H_0:\rho=0$；$H_A:\rho\neq 0$。然后计算相关系数的标准误s_r和t值：

$$s_r=\sqrt{\frac{1-r^2}{n-2}}=\sqrt{\frac{1-(-0.9682)^2}{8-2}}=0.1021$$

$$t=\frac{r}{s_r}=\frac{-0.9682}{0.1021}=-9.483$$

查附表3，$t_{0.01(6)}=3.707$，$|t|>t_{0.01}$，应否定H_0，接受H_A，说明黏虫孵化历期平均温度与历期天数之间存在着极显著的负相关关系。

前面对回归系数进行的假设检验中，t值为-9.483，与相关系数所做检验的t值是基本相等的，说明相关的显著性与回归的显著性是一致的，这也可从二者的计算公式推导出来，即

$$t_b=\frac{b}{s_b}=\frac{b\sqrt{SS_x}}{\sqrt{\dfrac{SS_y-bSP}{n-2}}}=\frac{b\sqrt{SS_x}}{\sqrt{\dfrac{SS_y\left(1-\dfrac{bSP}{SS_y}\right)}{n-2}}}$$

$$=\frac{\dfrac{SP}{\sqrt{SS_x\cdot SS_y}}}{\sqrt{\dfrac{1-\dfrac{SP^2}{SS_x\cdot SS_y}}{n-2}}}=\frac{r}{\sqrt{\dfrac{1-r^2}{n-2}}}=\frac{r}{s_r}=t_r \tag{7.33}$$

相关系数的假设检验也可不必计算t值，可直接从附表8中查出$df=n-2$的r_α临界值，从而作出统计推断。

三、相关系数的区间估计

如果相关系数的假设检验达到显著水平，还需要用r去估计ρ所在的区间。但是，相关系数的绝对值不可能大于1，所以只要ρ不等于0，r的抽样分布就不服从t分布或u分布。因此，要估计总体相关系数ρ的置信区间，需要将r转换成z，即Fisher提出的z转换(z-transformation)，z值近似服从正态分布。

$$z=0.5\ln\frac{1+r}{1-r}=1.1513\lg\frac{1+r}{1-r} \tag{7.34}$$

z值的标准误为

$$\sigma_z=\sqrt{\frac{1}{n-3}} \tag{7.35}$$

这样就用 $z \pm u_\alpha \sigma_z$ 求出置信区间：

$$(L_1 = z - u_\alpha \sigma_z, L_2 = z + u_\alpha \sigma_z) \tag{7.36}$$

然后将 L_1 和 L_2 反转换为 ρ 值的置信区间的下限 L'_1 和上限 L'_2。还原时可用下式：

$$L' = \frac{e^{2L} - 1}{e^{2L} + 1} \tag{7.37}$$

【例 7.10】 试求例 7.1 资料中总体 ρ 的 95% 置信区间。

将 $r = -0.9682$ 转换为 z 值：

$$z = 0.5\ln\frac{1+r}{1-r} = 0.5\ln\frac{1-0.9682}{1+0.9682} = -2.0627$$

算出 σ_z，进而可求出 L_1 和 L_2：

$$\sigma_z = \sqrt{\frac{1}{n-3}} = \sqrt{\frac{1}{8-3}} = 0.4472$$

$$L_1 = z - 1.96\sigma_z = -2.0627 - 1.96 \times 0.4472 = -2.9392$$

$$L_2 = z + 1.96\sigma_z = -2.0627 + 1.96 \times 0.4472 = -1.1862$$

然后将 L_1 和 L_2 反转换为 ρ 值的置信限：

$$L'_1 = \frac{e^{2L_1} - 1}{e^{2L_1} + 1} = \frac{e^{2\times(-2.9392)} - 1}{e^{2\times(-2.9392)} + 1} = \frac{-0.9972}{1.0028} = -0.9944$$

$$L'_2 = \frac{e^{2L_2} - 1}{e^{2L_2} + 1} = \frac{e^{2\times(-1.1862)} - 1}{e^{2\times(-1.1862)} + 1} = \frac{-0.9067}{1.0933} = -0.8294$$

黏虫孵化历期平均温度与历期天数的总体相关系数 ρ 的 95% 置信区间为 $(-0.9944, -0.8294)$。

四、应用直线相关的注意事项

1. 直线相关分析时对变量的要求

直线相关分析所涉及的两个变量应该都服从正态分布。如果资料不符合正态分布，应先通过变量转换，使之正态化，再根据转换值分析其相关关系。

2. 相关系数应进行检验

根据公式计算出的相关系数仅是样本相关系数，它是总体相关系数的一个估计值，与总体相关系数之间存在着抽样误差，要判断两个事物之间有无相关及相关的密切程度，必须进行假设检验。只有当检验拒绝了无效假设时，才可认为两个事物间存在着真实的相关关系，然后根据计算出的相关系数的大小来判断相关关系的密切程度。

3. 变量应尽可能多

在进行相关分析时，两个变量成对观测值应尽可能多一些。这是由于在 $\rho = 0$ 的总体中所得 r 的抽样分布，在 $n \geqslant 5$ 时才逐渐转为近似正态分布，所以进行相关分析时一般至少要有 5 对以上的观测值。

4. 正确理解相关系数的含义

相关分析是用相关系数来描述两个变量间相互关系的密切程度和性质，而两个变量之间的关系既可能是因果关系，也可能是平行关系。绝不可以因为两个变量间的相关系

数具有统计学意义，就认为二者之间存在实际意义上的因果关系。不过，当两变量之间的内在联系未被认识之前，相关分析可从数量上为理论研究提供线索。一个不显著的相关系数并不意味着变量之间没有关系，而只能说明两变量间没有显著的直线相关关系。

思考练习题

习题 7.1　什么叫回归分析？回归截距和回归系数的统计学意义是什么？

习题 7.2　直线回归中总变异可分解为哪几部分？每一部分的平方和如何计算？

习题 7.3　什么叫相关分析？相关系数和决定系数各具有什么意义？

习题 7.4　下表是某地区 4 月下旬平均气温与 5 月上旬 50 株棉苗蚜虫头数的资料。

年份	1969	1970	1971	1972	1973	1974	1975	1976	1977	1978	1979	1980
4 月下旬平均气温(x)/℃	19.3	26.6	18.1	17.4	17.5	16.9	16.9	19.1	17.9	17.5	18.1	19.0
5 月上旬 50 株棉蚜虫数(y)/ 头	86	197	8	29	28	29	23	12	14	64	50	112

(1) 建立直线回归方程；

(2) 对回归系数作假设检验；

(3) 该地区 4 月下旬平均温度为 18℃ 时，5 月上旬 50 株棉苗蚜虫预期为多少头？

习题 7.5　在研究代乳粉营养价值时，用大白鼠做实验，得大白鼠进食量(x，g) 和体重增加量(y，g) 数据如下表。

鼠号	1	2	3	4	5	6	7	8
进食量(x)/g	800	780	720	867	690	787	934	750
增重量(y)/g	185	158	130	180	134	167	186	133

(1) 试用直线回归方程描述其关系；

(2) 根据以上计算结果，求其回归系数的 95% 置信区间；

(3) 试估计进食量为 900g 时，大白鼠的体重平均增加多少，计算其 95% 置信区间；

(4) 求进食量为 900g 时，单个 y 的 95% 预测区间。

习题 7.6　用白菜 16 棵，将每棵纵剖两半，一半受冻，一半未受冻，测定其维生素 C 含量(单位：mg/g)，结果如下表。试计算相关系数和决定系数，检验相关系数的显著性，并估计相关系数的 95% 置信区间。

未受冻	39.01	34.23	30.82	32.13	43.03	36.71	28.74	26.03
受冻	33.29	34.75	37.93	34.38	41.52	34.87	34.93	30.95
未受冻	30.15	22.21	30.81	29.58	33.49	30.07	38.52	41.27
受冻	38.90	26.86	34.57	32.02	42.37	31.55	39.08	35.00

第八章

可直线化的非线性回归分析

本章提要

直线关系是两个变量间最简单的一种关系，但其常在变量取值范围较小时适用。当变量的取值范围增大时，变量间就不一定存在直线关系，而是表现出多种多样的曲线关系，根据图示法及直线化法可确定曲线的类型。对于倒数函数、指数函数、对数函数、幂函数及 Logistic 生长曲线等非线性方程，均可通过数据转换变形为线性方程，通过直线回归的方法进行线性回归方程的推导和回归关系的显著性检验，然后再反转换为相应的曲线函数。数据转换后的线性回归模型的各种假定和计算公式，仅适用于转换后的线性化数据，而不适用于原始数据。曲线回归方程拟合程度的好坏，可用相关指数来进行衡量。

直线关系是两个变量间最简单的一种关系。理论上说，如果缩小研究取值范围，则任意非线性关系都可以用线性关系来近似。但是研究范围缩小在使用上很不方便，一是不能对变量间关系有一个整体上的把握，二是在不同取值范围内还要换用不同的方程，因此在许多情况下考虑两个变量间的非线性关系还是很必要的。在研究过程中经常可以遇到变量间的非线性关系，如细菌的繁殖速率与温度、作物产量与施肥量等都属这种类型。可以用来表示两个变量间关系的曲线种类很多，有些曲线类型可以通过数据转换而变形为直线形式，我们称之为直线化(rectification)。这时可用转换后的数据建立直线回归方程，然后再反转换为曲线回归方程(curvilinear regression equation)，这就是可直线化的非线性回归分析。

非线性回归可分为已知曲线(公式)类型和未知曲线(公式)类型两种情况。一般来说，如果已知曲线类型，回归效果会有保证；同时在多数情况下我们对所研究的对象都有一定的了解，可以根据理论或经验得出可能的曲线类型，因此常用的是已知曲线类型的回归。如果曲线类型未知，可以利用多项式回归，通过逐渐增加多项式的高次项来拟合，从而确定最优回归方程。本章仅介绍已知曲线类型的可直线化的非线性回归。

第一节　非线性回归的直线化

一、曲线类型的确定

生物学中变量间的曲线关系通常有倒数函数曲线、指数函数曲线、对数函数曲线、幂函数曲线、S形曲线等多种形式，但是要找出两个变量间恰当的非线性回归方程形式是很不容易的。这往往需要借助于有关专业知识所提供的推断。例如，单细胞生物生长初期数量常按指数函数增长，但若生长时间较长，受营养供应和生存空间等因素的限制，后期生长受到抑制，则会变为S形曲线；酶促反应动力学中的米氏方程是一种双曲线等。这些推断要经过专业实践的验证，而且求得方程的统计数及由此导出的统计表，不应和有关专业实践结果相矛盾，可从专业理论中得到解释，并使这些解释严密化和数量化。所以，找出反映双变量间固有关系的最恰当曲线类型未必总能做到。但是，只要研究工作者对所研究的变量有足够的专业知识和实践经验，并借助于散点图和直线化的数据转换，是可以选出一条符合要求的最优曲线的。

确定曲线类型是非线性回归分析的关键。通常的方法有以下几种。

(1)图示法。根据所获得的试验资料的自然尺度绘出散点图，然后按照散点图的趋势绘出能够反映它们之间变化规律的曲线，并与已知的曲线相比较，找出与之较为相似的曲线图形，该曲线即为选定的类型。

(2)直线化法。根据散点图进行直观的比较，选出一种曲线类型，并将原始数据进行转换，将曲线方程直线化，用转换后的数据绘出散点图，若该图形为直线趋势，即表明选取的曲线类型是恰当的，否则需要重新进行选择。

确定曲线类型时，往往需要从多方面慎重考虑。曲线配合的好坏，通常以所配曲线与实测点吻合程度的高低来衡量，这取决于离回归平方和 $\sum(y-\hat{y})^2$ 与 y 的总平方和 $\sum(y-\bar{y})^2$ 的比例大小。若这个比例小，说明所配曲线与实测点吻合程度高，反之则低。我们把1与这个比值之差定义为曲线回归的相关指数(correlation exponential)，记为 R^2，即

$$R^2=1-\frac{\sum(y-\hat{y})^2}{\sum(y-\bar{y})^2} \tag{8.1}$$

相关指数 R^2 的大小反映了回归曲线拟合度的高低，表示利用曲线回归方程进行估测的可靠程度的高低。

对于同一组实测数据，根据散点图的形状，可用若干相近的曲线进行拟合，同时建立若干曲线回归方程，然后根据 R^2 的大小和生物学等专业知识，选择既符合生物学规律，又有较高拟合度的曲线回归方程来描述两个变量间的曲线回归关系。

二、数据变换的方法

在进行非线性回归曲线的直线化时，对原数据进行转换的方法通常有两种。

(1) 直接引入新变量。这种方法是直接引入新的变量，从而使变量间为直线关系。例如，对数函数曲线方程为

$$\hat{y}=a+b\lg x$$

直接引入新变量 x'，令 $x'=\lg x$，原方程式转换为直线形式，即

$$\hat{y}=a+bx'$$

(2) 方程变换后再引入新变量。这种方法是将原曲线方程进行一定的数学变换后，再引入新变量，从而使变量间的关系变为直线关系。例如，幂函数曲线方程为

$$\hat{y}=ax^b$$

两边取对数，得

$$\lg\hat{y}=\lg a+b\lg x$$

若令 $y'=\lg y$、$a'=\lg a$、$x'=\lg x$，则原方程式变为

$$\hat{y}'=a'+bx'$$

几种常用曲线方程的直线化方法列于表 8-1。

表 8-1　常用曲线方程的直线化方法

曲线回归方程	经尺度转换的新变量及参数			直线化的方程
	y'	x'	a'	
$\hat{y}=\dfrac{a+bx}{x}$	$y'=yx$			$\hat{y}'=a+bx$
$\hat{y}=\dfrac{1}{a+bx}$	$y'=\dfrac{1}{y}$			$\hat{y}'=a+bx$
$\hat{y}=\dfrac{x}{a+bx}$	$y'=\dfrac{x}{y}$			$\hat{y}'=a+bx$
$\hat{y}=ax+bx^2$	$y'=\dfrac{y}{x}$			$\hat{y}'=a+bx$
$\hat{y}=a+b\ln x$		$x'=\ln x$		$\hat{y}=a+bx'$
$\hat{y}=a+b\lg x$		$x'=\lg x$		$\hat{y}=a+bx'$
$\hat{y}=ax^b$	$y'=\ln y$	$x'=\ln x$	$a'=\ln a$	$\hat{y}'=a'+bx'$
$\hat{y}=ae^{bx}$	$y'=\ln y$		$a'=\ln a$	$\hat{y}'=a'+bx$
$\hat{y}=axe^{bx}$	$y'=\ln\dfrac{y}{x}$		$a'=\ln a$	$\hat{y}'=a'+bx$
$\hat{y}=\dfrac{1}{ax^b}$	$y'=\ln\dfrac{1}{y}$	$x'=\ln x$	$a'=\ln a$	$\hat{y}'=a'+bx'$

统计学上已经证明，对于倒数函数曲线、指数函数曲线、对数函数曲线、幂函数曲线和 Logistic 生长曲线这几种曲线方程，只要变量转换以后的直线化回归关系达到显著，变量反转后得到的曲线方程回归关系也较好。

第二节　倒数函数曲线

倒数函数(reciprocal function)常见的表达式有以下几种：

$$\hat{y}=\frac{a+bx}{x} \tag{8.2}$$

$$\hat{y}=\frac{1}{a+bx} \tag{8.3}$$

$$\hat{y}=\frac{x}{a+bx} \tag{8.4}$$

若令 $y'=xy$，则式(8.2)可以写成：

$$\hat{y}'=a+bx \tag{8.5}$$

若令 $y'=\frac{1}{y}$，则式(8.3)可以写成：

$$\hat{y}'=a+bx \tag{8.6}$$

若令 $y'=\frac{x}{y}$，则式(8.4)可以写成：

$$\hat{y}'=a+bx \tag{8.7}$$

式(8.5)、式(8.6)和式(8.7)分别是式(8.2)、式(8.3)和式(8.4)直线化后的表达形式。本节以式(8.2)为例讨论倒数函数方程的拟合过程。

如果两个变量的成对观测值在坐标系中的散点图分布趋势类似于倒数函数曲线图(图 8-1)，可试配 $\hat{y}=\frac{a+bx}{x}$ 型的回归方程。首先引入新的变量 $y'(y'=xy)$，然后用 y' 与 x 进行直线回归分析，求得 a 和 b，经过数据还原即可得倒数函数方程。

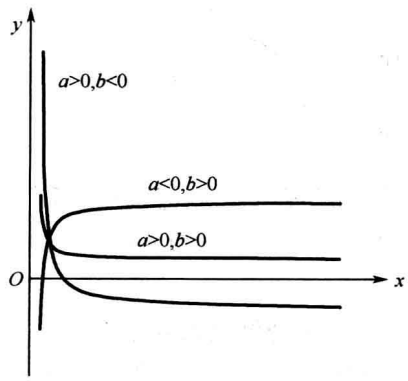

图 8-1　倒数函数 $\hat{y}=\frac{a+bx}{x}$ 的图像

应用 $\hat{y}=\frac{a+bx}{x}$ 的条件如下：

(1) x 的观测值无 0 值。

(2) xy 应具有专业意义，而不是抽象的量。

(3) 以 $y'(y'=xy)$ 和 x 为坐标绘制出的散点图有明显的直线性。

(4) y' 和 x 的相关系数显著。

【例 8.1】 测定'苏品 1 号'玉米在不同密度下的平均株重(x，g/株)和经济系数(y)的关系，结果如表 8-2 所示。试对该资料进行回归分析。

表 8-2　玉米株重(x)和经济系数(y)的关系

密度/(千株/667m²)	x	y	$y'=xy$	x^2	xy'	y'^2	$\hat{y}$	$y-\hat{y}$
1	399	0.380	151.620	159201	60496.380	22988.624	0.384	−0.004
2	329	0.379	124.691	108241	41023.339	15547.845	0.376	0.003
3	247	0.371	91.637	61009	22634.339	8397.340	0.362	0.009
4	191	0.343	65.513	36481	12512.983	4291.953	0.344	−0.001
5	145	0.317	45.965	21025	6664.925	2112.781	0.320	−0.003
6	119	0.301	35.819	14161	4262.461	1283.001	0.298	0.003
8	90	0.248	22.320	8100	2008.800	498.182	0.259	−0.011

(1) 绘制散点图,判断曲线类型。

根据表8-2资料绘制x和y的散点图(图8-2),散点图与图8-1中$a<0$、$b>0$的曲线相似。

为了能够作出更准确的判断,图8-3绘出了x与y'($y'=xy$)的散点图,y'与x之间存在直线关系,这表明选择该倒数函数曲线是适合的。

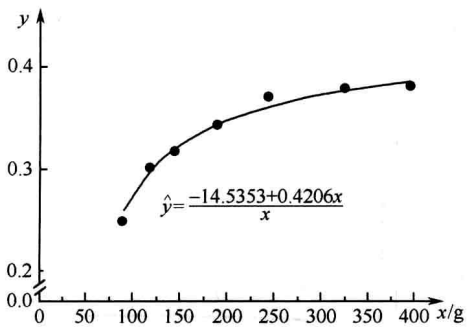

图 8-2　经济系数 y 与玉米株重 x 的关系

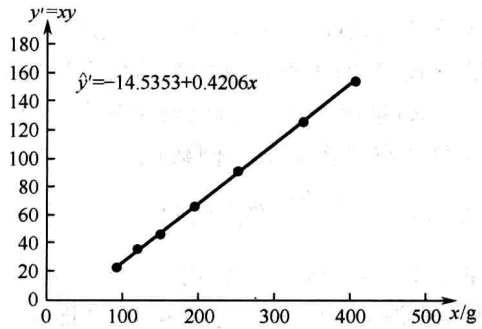

图 8-3　例 8.1 资料 y' 与 x 之间的直线关系

(2) 配合倒数函数方程。

利用y'和x进行直线回归分析,得到a和b值,代入式(8.2)即得倒数函数方程。具体步骤如下所述。

第一步,根据表8-2资料计算6个一级数据:

$$\sum x=1520 \qquad \sum y'=537.565 \qquad \sum x^2=408218$$

$$\sum y'^2=55119.727 \qquad \sum xy'=149603.227 \qquad n=7$$

第二步,由一级数据计算5个二级数据:

$$SS_x=\sum x^2-\frac{\left(\sum x\right)^2}{n}=408218-\frac{1520^2}{7}=78160.857$$

$$SS'_y=\sum y'^2-\frac{\left(\sum y'\right)^2}{n}=55119.727-\frac{537.565^2}{7}=13837.423$$

$$SP_{xy'}=\sum xy'-\frac{\left(\sum x\right)\left(\sum y'\right)}{n}$$

$$=149603.227-\frac{1520\times 537.565}{7}=32874.827$$

$$\bar{x}=\frac{\sum x}{n}=\frac{1520}{7}=217.143$$

$$\bar{y}'=\frac{\sum y'}{n}=\frac{537.565}{7}=76.795$$

第三步，计算回归系数 b 和回归截距 a：

$$b=\frac{SP_{xy'}}{SS_x}=\frac{32874.827}{78160.857}=0.4206$$

$$a=\bar{y}'-b\bar{x}$$

$$=76.795-0.4206\times 217.143$$

$$=-14.5353$$

第四步，将 a 和 b 代入式(8.2)，得到 y 和 x 之间的倒数函数方程：

$$\hat{y}=\frac{-14.5353+0.4206x}{x}$$

(3) 直线化回归方程的显著性检验。

对直线化后的回归方程进行显著性检验时，我们可以计算 x 与 y' 的相关系数并对其进行显著性检验。

$$r_{xy'}=\frac{SP_{xy'}}{\sqrt{SS_x\cdot SS_{y'}}}=\frac{32874.827}{\sqrt{78160.857\times 13837.423}}=0.9996^{**}$$

查附表 8，$r_{0.01(5)}=0.874$，$r_{xy'}>r_{0.01(5)}$ 达极显著水平，表明 x 与 y' 之间存在极显著的直线回归关系。

(4) 计算曲线回归方程的相关指数。

将 x 的每一取值代入倒数方程 $\hat{y}=\frac{-14.5353+0.4206x}{x}$，可以得到相应的 $\hat{y}$，其结果列于表 8-2 中。从每一对 y 和 $\hat{y}$ 值间的差异大小可看出每一对观测值受随机误差影响的大小，差异越大，随机误差就越大。

本例倒数函数的相关指数：

$$R^2=1-\frac{\sum(y-\hat{y})^2}{\sum(y-\bar{y})^2}=1-\frac{0.000246}{0.0144}=0.9829$$

表明玉米株重(x)和经济系数(y)的回归关系用倒数函数方程 $\hat{y}=\frac{-14.5353+0.4206x}{x}$ 进行描述，其相关指数达 0.9829，该倒数函数拟合较好。

第三节　指数函数曲线

指数函数(exponential function)常见的有两种形式：

$$\hat{y}=a\mathrm{e}^{bx} \tag{8.8}$$

$$\hat{y}=ab^{x} \tag{8.9}$$

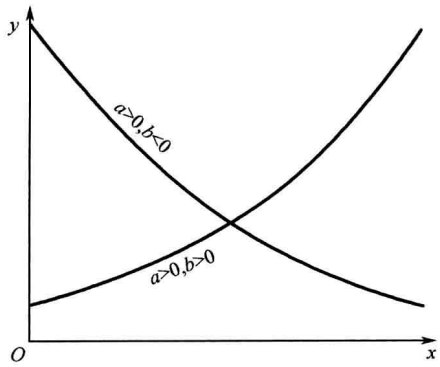

图 8-4　指数曲线 $\hat{y}=a\mathrm{e}^{bx}$ 的图像

在指数函数中，x 是作为指数出现的，系数 b 用以描述增长或衰减速率。如图 8-4 所示，如果曲线方程是式(8.8)，$b>0$，表示增长曲线；$b<0$，表示衰减曲线。如果曲线方程是式(8.9)，$b>1$，表示凹增长曲线；$0<b<1$，表示凸增长曲线；$b<0$，表示衰减曲线。

将式(8.8)两边取自然对数，得到

$$\ln\hat{y}=\ln a+bx \tag{8.10}$$

令 $y'=\ln y$，$a'=\ln a$，式(8.10)变形为

$$\hat{y}'=a'+bx \tag{8.11}$$

式(8.11)即为式(8.8)直线化后的表达式。

【例 8.2】 棉花红铃虫的产卵数与温度有关，试根据表 8-3 中的数据建立棉花红铃虫产卵数与温度的回归方程。

表 8-3　棉花红铃虫产卵数与温度的关系

温度(x)/℃	21	23	25	27	29	32	35
产卵数(y)	7	11	21	24	66	115	325
$y'=\ln y$	1.9459	2.3979	3.0445	3.1781	4.1897	4.7449	5.7838

(1) 绘制散点图，判断曲线类型。

根据表8-3的资料绘制(x，y)散点图(图8-5)。该散点图与图8-4中 $b>0$ 时的曲线相似，选择方程 $\hat{y}=a\mathrm{e}^{bx}$ 进行曲线拟合。同时，以 x 和 y'($y'=\ln y$)的数据绘制散点图(图8-6)，其直线趋势较为明显，说明配合 $\hat{y}=a\mathrm{e}^{bx}$ 的曲线方程是适合的。

(2) 配合指数曲线方程。

以 x 和 y'($y'=\ln y$)进行直线回归分析，求出 b 和 a'，并将 a' 转换为 a，代入 $\hat{y}=a\mathrm{e}^{bx}$ 即可。

具体步骤如下所述。

第一步，计算 6 个一级数据：

$$\sum x=192 \qquad \sum x^{2}=5414 \qquad \sum y'=25.2848$$

$$\sum y'^{2}=102.4258 \qquad \sum xy'=733.7079 \qquad n=7$$

第二步，由一级数据计算 5 个二级数据：

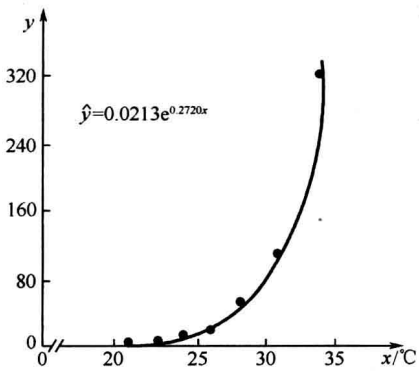

图 8-5　红铃虫产卵数 y 与温度 x 的关系

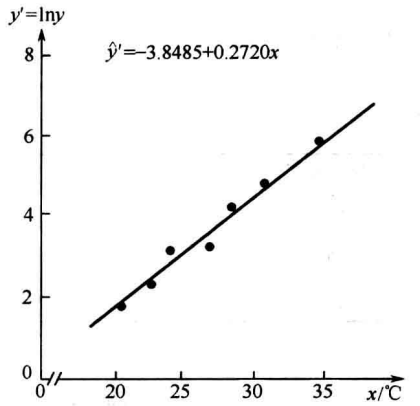

图 8-6　例 8.2 中 y' 与 x 之间的直线关系

$$SS_x=\sum x^2-\frac{\left(\sum x\right)^2}{n}=5414-\frac{192^2}{7}=147.7143$$

$$SS_{y'}=\sum y'^2-\frac{\left(\sum y'\right)^2}{n}=102.4258-\frac{25.2848^2}{7}=11.0942$$

$$SP_{xy'}=\sum xy'-\frac{\left(\sum x\right)\left(\sum y'\right)}{n}=733.7079-\frac{192\times 25.2848}{7}=40.1820$$

$$\bar{x}=\frac{\sum x}{n}=\frac{192}{7}=27.4286$$

$$\bar{y}'=\frac{\sum y'}{n}=\frac{25.2848}{7}=3.6121$$

第三步，计算 b 和 a'：

$$b=\frac{SP_{xy'}}{SS_x}=\frac{40.1820}{147.7143}=0.2720$$

$$a'=\bar{y}'-b'\bar{x}=3.6121-0.2720\times 27.4286=-3.8485$$

第四步，计算 a 值，将 a、b 代入 $\hat{y}=ae^{bx}$，得到曲线方程：

$$a=e^{a'}=e^{-3.8485}=0.0213$$

$$\hat{y}=0.0213e^{0.2720x}$$

(3) 直线化回归方程的显著性检验。

检验 y' 与 x 的回归关系，计算回归与离回归的平方和：

$$U=bSP_{xy'}=0.2720\times 40.1820=10.9295$$

$$Q=SS_y-U=11.0942-10.9295=0.1647$$

$$F=\frac{\dfrac{U}{Q}}{\dfrac{}{n-2}}=\frac{\dfrac{10.9295}{0.1647}}{7-2}=331.800^{**}$$

$F=331.800>F_{0.01}$，回归关系极显著，说明配合曲线方程$\hat{y}=0.0213e^{0.2720x}$是适合的(表 8-4)。

表 8-4　x 和 y'回归关系的显著性检验

变异来源	df	SS	s^2	F	$F_{0.05}$	$F_{0.01}$
回归	1	10.9295	10.9295	331.800**	6.61	16.26
离回归	5	0.1647	0.0329			
总变异	6	11.0942				

第四节　对数函数曲线

对数函数(logarithmic function)的一般表达式为

$$\hat{y}=a+b\lg x \tag{8.12}$$

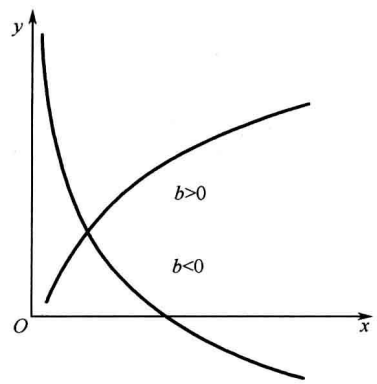

图 8-7　对数曲线$\hat{y}=a+b\lg x$的图像

若令$\lg x=x'$，则式(8.12)可以写成：

$$\hat{y}=a+bx' \tag{8.13}$$

式(8.13)即为式(8.12)直线化后的表达形式。

如果两个变量的成对观测值在坐标系中的散点图分布趋势类似于对数函数曲线(图 8-7)，可配合对数曲线方程$\hat{y}=a+b\lg x$。首先将 x 变量的每一观测值取对数转换为新变量 x'，然后用 x' 与 y 进行直线回归分析，求得 a 和 b，即得到对数函数方程。

【例 8.3】 在水稻育秧中，塑料薄膜青苗床内空气最高温度和室外空气最高温度资料如表 8-5 所示。试求它们之间的函数关系式。

(1) 绘制散点图，判断曲线类型。

根据表 8-5 资料绘出(x，y)的散点图(图 8-8)，与图 8-7 中 $b>0$ 的曲线相似。为了能够作出更准确的判断，图 8-9 绘出了 x'($x'=\lg x$)与 y 的散点图，x' 与 y 之间存在直线关系，这说明选择对数曲线是适合的。

(2) 配合对数函数方程。

利用 x'($x'=\lg x$)和 y 进行直线回归分析，得到 a 和 b 值，并代入式(8.12)即得对数函数方程。

具体步骤如下所述。

第一步，根据表 8-5 资料计算 6 个一级数据：

表 8-5　苗床内最高温度(y,℃)与空气最高温度(x,℃)的关系

序号	x	y	$x'=\lg x$	x'^2	$x'y$	y^2	$\hat{y}$
1	7.2	13.8	0.8573	0.7350	11.8312	190.44	16.79
2	7.9	21.4	0.8976	0.8057	19.2092	457.96	18.79
3	11.8	24.9	1.0719	1.1489	26.6899	620.01	27.45
4	12.0	32.3	1.0792	1.1646	34.8576	1043.29	27.81
5	16.9	33.6	1.2279	1.5077	41.2570	1128.96	35.20
6	18.7	39.5	1.2718	1.6176	50.2377	1560.25	37.38
7	18.9	40.1	1.2765	1.6294	51.1861	1608.01	37.61
8	20.2	36.9	1.3054	1.7039	48.1675	1361.61	39.05
9	21.8	40.2	1.3385	1.7915	53.8060	1616.04	40.69
10	22.7	42.6	1.3560	1.8388	57.7667	1814.76	41.57
11	22.9	44.6	1.3598	1.8492	60.6487	1989.16	41.76
12	23.1	36.6	1.3636	1.8594	49.9082	1339.56	41.94
13	23.3	35.1	1.3674	1.8697	47.9942	1232.01	42.13
14	23.6	44.4	1.3729	1.8849	60.9573	1971.36	42.41
15	23.8	44.1	1.3766	1.8950	60.7070	1944.81	42.59
16	27.0	43.9	1.4314	2.0488	62.8369	1927.21	45.31
17	27.6	48.3	1.4409	2.0762	69.5959	2332.89	45.78
18	28.6	48.5	1.4564	2.1210	70.6338	2352.25	46.55
19	30.7	46.3	1.4871	2.2116	68.8545	2143.69	48.08
20	31.4	50.4	1.4969	2.2408	75.4453	2540.16	48.57
合计	420.1	767.5	25.8350	33.9997	1022.5905	31174.43	

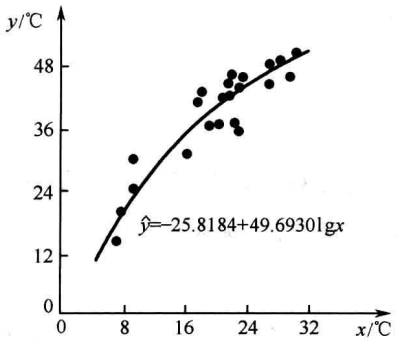

图 8-8　苗床内最高气温 y 与空气最高气温 x 的关系

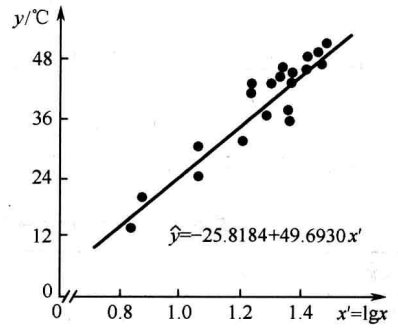

图 8-9　例 8.3 资料 x' 与 y 之间的直线关系

$\sum x'=25.8350$　　$\sum x'^2=33.9997$　　$\sum y=767.5$

$\sum y^2=31174.43$　　$\sum x'y=1022.5905$　　$n=20$

第二步，由一级数据计算 5 个二级数据：

$$SS_{x'}=\sum x'^2-\frac{\left(\sum x'\right)^2}{n}=33.9997-\frac{25.8350^2}{20}=0.6273$$

$$SS_y=\sum y^2-\frac{\left(\sum y\right)^2}{n}=31174.43-\frac{767.5^2}{20}=1721.6175$$

$$SP_{x'y}=\sum x'y-\frac{\left(\sum x'\right)\left(\sum y\right)}{n}=1022.5905-\frac{25.8350\times 767.5}{20}$$

$$=31.1724$$

$$\bar{x}'=\frac{\sum x'}{n}=\frac{25.8350}{20}=1.2918$$

$$\bar{y}=\frac{\sum y}{n}=\frac{767.5}{20}=38.375$$

第三步，计算回归系数 b 和回归截距 a：

$$b=\frac{SP_{x'y}}{SS_{x'}}=\frac{31.1724}{0.6273}=49.6930$$

$$a=\bar{y}-b\bar{x}'=38.375-49.6930\times 1.2918=-25.8184$$

第四步，将 a 和 b 直接代入式(8.12)，得到 y 与 x 的对数函数方程：

$$\hat{y}=-25.8184+49.6930\lg x$$

(3) 直线化回归方程的显著性检验。

计算 y 与 x' 直线回归关系的回归与离回归平方和：

$$U=bSP_{x'y}=49.6930\times 31.1724=1549.0501$$

$$Q=SS_y-U=1721.6175-1549.0501=172.5674$$

$$F=\frac{\frac{U}{1}}{\frac{Q}{n-2}}=\frac{1549.0501}{\frac{172.5674}{20-2}}=161.577^{**}$$

$F=161.577>F_{0.01}$，说明回归关系极显著，配合对数函数方程是适合的(表 8-6)。

表 8-6　例 8.3 资料中 y 与 x' 回归关系的显著性检验

变异来源	df	SS	s^2	F	$F_{0.05}$	$F_{0.01}$
回归	1	1549.0501	1549.0501	161.577**	4.41	8.29
离回归	18	172.5674	9.5871			
总变异	19	1721.6175				

利用曲线回归方程进行预测时，可将每一个 x 值转换成 x' 再通过回归分析方法预测出 y 所在区间。表8-5中最后一列即为每一个 x 值代入曲线回归方程得到相应的 y 估计值 $\hat{y}$。

第五节　幂函数曲线

幂函数(power function)曲线是 y 为 x 某次幂的函数曲线，其方程为

$$\hat{y}=ax^b \tag{8.14}$$

将式(8.14)两边取对数，得

$$\lg \hat{y} = \lg a + b\lg x \tag{8.15}$$

令 $y' = \lg y, x' = \lg x, a' = \lg a$，得到直线方程：

$$\hat{y}' = a' + bx' \tag{8.16}$$

式(8.14)的图形如图 8-10 所示。如果两个变量的散点图类似于图 8-10 中的某一条曲线，说明可用幂函数曲线进行拟合。为了进一步进行验证，可将 x 和 y 都取对数，然后绘出 $x'(x' = \lg x)$ 和 $y'(y' = \lg y)$ 的散点图，如果散点呈直线趋势，即说明选用幂函数曲线是适合的。

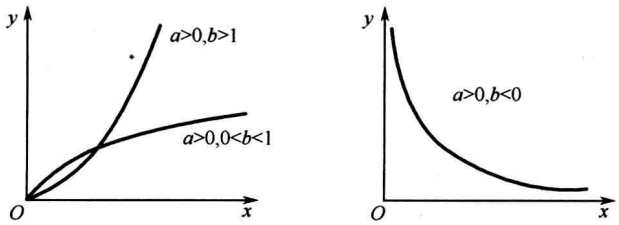

图 8-10　幂函数曲线 $\hat{y} = ax^b$ 的图像

【例 8.4】 为了研究 CO_2 对变黄期烟叶叶绿素降解的影响，在 30 倍 CO_2 浓度下测定了不同烘烤时间(x，h) 下叶绿素含量(y，占干重 %)，其结果列于表 8-7。试对该资料进行回归分析。

表 8-7　烘烤时间与叶绿素含量关系

x	y	$x' = \lg x$	$y' = \lg y$
12	0.17430	1.0792	−0.7587
15	0.11080	1.1761	−0.9555
19	0.06340	1.2788	−1.1979
25	0.05310	1.3979	−1.2749
32	0.04155	1.5051	−1.3814
35	0.04080	1.5441	−1.3893
38	0.04020	1.5798	−1.3958
41	0.03998	1.6128	−1.3982
46	0.03762	1.6628	−1.4246
49	0.03538	1.6902	−1.4512
58	0.03533	1.7634	−1.4519

(1) 绘制散点图，判断曲线类型。

以表 8-7 中 x 和 y 的成对观测值在坐标系中绘制散点图(图 8-11)，该图类似于图 8-10 中 $b < 0$ 的曲线，可试配幂函数曲线。绘出 $x'(x' = \lg x)$ 和 $y'(y' = \lg y)$ 的散点图(图 8-12)，可以看出散点呈直线趋势，说明选用幂函数曲线是适合的。

(2) 配合幂函数曲线方程。

第一步，计算一级数据：

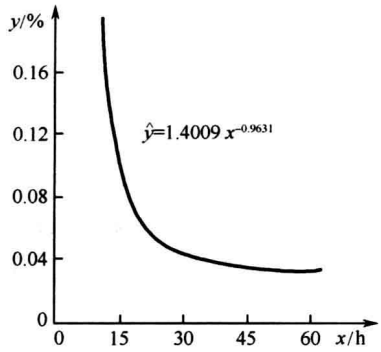

图 8-11　烟叶烘烤时间 x 与叶绿素含量 y 的关系

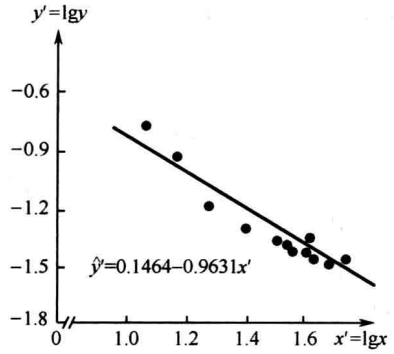

图 8-12　例 8.4 中 y' 与 x' 间的直线关系

$\sum x' = 16.2901$　　$\sum x'^2 = 24.6149$　　$\sum y' = -14.0794$

$\sum y'^2 = 18.5340$　　$\sum x'y' = -21.3229$　　$n = 11$

第二步，计算二级数据：

$$SS_{x'} = \sum x'^2 - \frac{\left(\sum x'\right)^2}{n} = 0.4963$$

$$SS_{y'} = \sum y'^2 - \frac{\left(\sum y'\right)^2}{n} = 0.5131$$

$$SP_{x'y'} = \sum x'y' - \frac{\left(\sum x'\right)\left(\sum y'\right)}{n} = -0.4725$$

$$\bar{x}' = \frac{\sum x'}{n} = 1.4809$$

$$\bar{y}' = \frac{\sum y'}{n} = -1.2799$$

第三步，计算 b 和 a'：

$$b = \frac{SP_{x'y'}}{SS_{x'}} = \frac{-0.4725}{0.4963} = -0.9631$$

$$a' = \bar{y}' - b\bar{x}' = -1.2799 - (-0.9631) \times 1.4809 = 0.1464$$

第四步，将 a' 转换为 a，得到幂函数曲线方程：

$$a = 10^{a'} = 10^{0.1464} = 1.4009$$

$$\hat{y} = 1.4009x^{-0.9631}$$

(3) 直线化回归方程的显著性检验。

$$U = bSP_{x'y'} = -0.9631 \times (-0.4725) = 0.4551$$

$$Q = SS_{y'} - U = 0.5131 - 0.4551 = 0.0580$$

$$F = \frac{\frac{U}{1}}{\frac{Q}{n-2}} = \frac{0.4551}{\frac{0.0580}{11-2}} = 70.619^{**}$$

$F=70.619>F_{0.01}$，表明回归关系极显著，说明以此资料配合的幂函数曲线方程是适合的(表 8-8)。

表 8-8　例 8.4 资料中 x' 与 y' 回归关系的显著性检验

变异来源	df	SS	s^2	F	$F_{0.05}$	$F_{0.01}$
回归	1	0.4551	0.4551	70.619**	5.12	10.56
离回归	9	0.0580	0.0064			
总变异	10	0.5131				

为了更好地说明例 8.4 资料符合幂函数曲线关系，而不是其他类型曲线或直线关系，可将其进行不同曲线方程的拟合，并计算直线化后两个变量之间的相关系数。

幂函数方程：$\hat{y}=1.4009x^{-0.9631}$，$\lg x$ 与 $\lg y$ 之间的 $r=-0.9417$；

对数函数方程：$\hat{y}=0.3147-0.0743\ln x$，$\ln x$ 与 y 之间的 $r=-0.8720$；

指数函数方程：$\hat{y}=0.1457e^{-0.0304x}$，$x$ 与 $\ln y$ 之间的 $r=-0.8562$；

直线函数方程：$\hat{y}=0.1372-0.0023x$，x 与 y 之间的 $r=-0.7652$。

以上 4 个方程，其直线化后两个变量的相关系数均达极显著水平($r_{0.01(9)}=0.735$)，而幂函数曲线直线化后的相关程度最高，表明配合出的幂函数曲线方程 $\hat{y}=1.4009x^{-0.9631}$ 是最适宜的。

第六节　Logistic 生长曲线

一、Logistic 生长曲线的由来和基本特征

Logistic 生长曲线(Logistic growth curve)最初由比利时数学家 P. F. Verhulst 于 1838 年推导出来，但长期被忽视。直到 20 世纪 20 年代才被生物学家和统计学家 R. Pearl 和 L. J. Reed 重新发现，目前它已广泛应用于动植物的饲养、栽培、资源、生态、环保等方面的模拟研究。其特点是开始增长缓慢，而在以后的某一范围内迅速增长，达到某限度后，增长又缓慢下来，曲线略呈拉长的“S”，因此，也称为 S 形曲线。Logistic 生长曲线方程为

$$\hat{y}=\frac{K}{1+ae^{-bx}} \tag{8.17}$$

曲线的图形如图 8-13 所示。Logistic 生长曲线的基本特征如下所述。

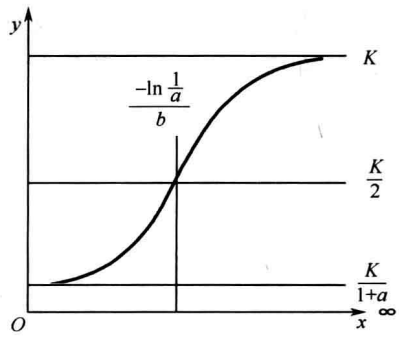

图 8-13　Logistic 生长曲线 $\hat{y}=\frac{K}{1+ae^{-bx}}$ 的图像

(1) 当 $x=0$ 时，$\hat{y}=\frac{K}{1+a}$；当 $x\to\infty$，$\hat{y}=K$。所以时间为 0 的起始量是 $\frac{K}{1+a}$，时间无限延长的终极量是 K。

(2) 式(8.17)的二阶导数$\frac{d^2y}{dx^2}=0$时，$x=\frac{-\ln\frac{1}{a}}{b}$，$\hat{y}=\frac{K}{2}$，这说明$y$是随$x$的增加而增加的。当$x=\frac{-\ln\frac{1}{a}}{b}$时，曲线有一个拐点(knee point)，这时$\hat{y}=\frac{K}{2}$，恰为终极量$K$的一半。所以，$x$在$\left[0,x=\frac{-\ln\frac{1}{a}}{b}\right]$区间内，曲线下凹；$x$在$\left[x=\frac{-\ln\frac{1}{a}}{b},\infty\right]$区间内，曲线上凸。

二、Logistic 生长曲线方程的配合

从式(8.17)可以看出，只要确定了K值，就可利用直线化方法求出方程的两个统计数a和b。式(8.17)移项后可得

$$\frac{K-\hat{y}}{\hat{y}}=ae^{-bx} \tag{8.18}$$

两边取自然对数后得

$$\ln\frac{K-\hat{y}}{\hat{y}}=\ln a-bx \tag{8.19}$$

若令$\hat{y}'=\ln\frac{K-\hat{y}}{\hat{y}}$、$a'=\ln a$、$b'=-b$，式(8.19)即为

$$\hat{y}'=a'+b'x \tag{8.20}$$

因此，可将每一个y观测值转换为y'，用y'与x进行直线回归分析，即可求出a'和b'。在转换时，必须先确定K值，K值的确定方法有下面两种：

(1) 如果依变量y是累积频率，则y无限增大的终极量应为100(%)，可用$K=100$表示。

(2) 当依变量y是生长量或繁殖量时，可取3对自变量为等间距的观测值(x_1,y_1)、(x_2,y_2)和(x_3,y_3)，并将其代入式(8.18)，得到联立方程组：

$$\begin{cases}\frac{K-y_1}{y_1}=ae^{-bx_1}\\ \frac{K-y_2}{y_2}=ae^{-bx_2}\\ \frac{K-y_3}{y_3}=ae^{-bx_3}\end{cases}$$

将方程组中的a和b消去，得

$$\frac{y_2(K-y_1)}{y_1(K-y_2)}=\left[\frac{y_3(K-y_2)}{y_2(K-y_3)}\right]^{\frac{x_1-x_2}{x_2-x_3}}$$

如果令$x_2=\frac{x_1+x_3}{2}$，可得

$$K=\frac{y_2^2(y_1+y_3)-2y_1y_2y_3}{y_2^2-y_1y_3} \tag{8.21}$$

【例 8.5】 表 8-9 是测定某种肉鸡在良好的生长条件下生长过程的数据资料。试配合 Logistic 生长曲线方程。

表 8-9　肉用鸡生长过程的资料

x/周次	y/kg	$\frac{2.827-y}{y}$	$y'=\ln\frac{2.827-y}{y}$
2	0.30	8.4233	2.1310
4	0.86	2.2872	0.8273
6	1.73	0.6341	−0.4555
8	2.20	0.2850	−1.2553
10	2.47	0.1445	−1.9342
12	2.67	0.0588	−2.8336
14	2.80	0.0096	−4.6415

分析步骤如下所述。

(1) 求终极量 K。

取 x 为等间距的 $x_1=2$、$x_2=8$、$x_3=14$ 的生长量 $y_1=0.30$、$y_2=2.20$ 和 $y_3=2.80$，由式(8.21) 得

$$K=\frac{2.20^2\times(0.30+2.80)-2\times0.30\times2.20\times2.80}{2.20^2-0.30\times2.80}=2.827(\text{kg})$$

(2) 将 y 转换为 y'。

计算出 $\frac{2.827-y}{y}$ 和 $y'=\ln\frac{2.827-y}{y}$ 分别列于表 8-9。

(3) 计算 x 和 y' 回归分析的二级数据。

$SS_x=112$

$SS_{y'}=30.8067$

$SP_{xy'}=-58.2363$

$\bar{x}=8$

$\bar{y}'=-1.1660$

(4) 计算 x 和 y' 的相关系数 $r_{xy'}$。

$$r_{xy'}=\frac{-58.2363}{\sqrt{112\times30.8067}}=-0.9914^{**}$$

$|r_{xy'}|=0.9914>r_{0.01(5)}=0.874$，达到极显著水平，说明 x 与 y' 的直线关系是极显著的，对表 8-9 的资料配合 Logistic 生长曲线方程是适合的。

(5) 求 a 和 b，建立 Logistic 方程。

计算 b' 和 a'，并转换成 a 和 b：

$$b'=\frac{SP_{xy'}}{SS_x}=\frac{-58.2363}{112}=-0.5200$$

$$a'=\bar{y}'-b'\bar{x}=-1.1660-(-0.5200)\times8=2.9940$$

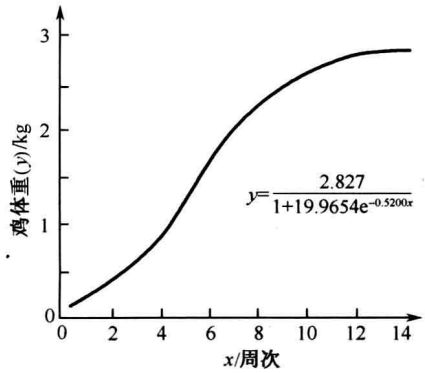

图 8-14　肉鸡的 Logistic 生长曲线

$$a = e^{a'} = e^{2.9940} = 19.9654$$

$$b = -b' = 0.5200$$

所以，有

$$\hat{y} = \frac{2.827}{1 + 19.9654e^{-0.5200x}}$$

此方程的图形如图 8-14 所示，并可求 $\hat{y} = \frac{K}{2} = 1.4135$，$x = \frac{-\ln\frac{1}{a}}{b} = 5.76$(周)时，是曲线的拐点，生长速率从越来越快开始变为越来越慢，这是此种肉鸡生长的关键时期。

思考练习题

习题 8.1　生物学中常见的曲线类型有哪些？如何确定两个变量之间的曲线类型？

习题 8.2　非线性回归曲线进行直线化时，常用的转换方法有哪两种？

习题 8.3　测定细砂土中毛管水的上升高度（y，cm）和经历时数（x，h）的关系，其结果如下表所示。试作回归分析。

经历时数(x)/h	12	24	48	96	144	192	240
上升高度(y)/cm	21	34	42	48	53	57	60

习题 8.4　下表列出了甘薯薯块在生长过程中的鲜重（x，g）和呼吸强度[y，$mgCO_2/(100g\ FW \cdot h)$]的数据资料。为探讨二者的回归关系，试分别建立幂函数方程、指数函数方程及对数函数方程，并分别对方程的拟合效果进行评价。

鲜重(x)/g	10	38	80	125	200	310	445	480
呼吸强度(y)/[$mgCO_2/(100g\ FW \cdot h)$]	92	32	21	12	10	7	7	6

习题 8.5　在动物的饲料配方研究中，得到如下一组试验结果。试对体重与日龄进行回归分析。

日龄(x)/d	0	7	14	21	28	42	56	70
体重(y)/g	105	214	335	560	790	1290	2010	2950

第九章

试验设计及其统计分析

本章提要

试验设计是进行生物学研究的重要工具，需遵循重复、随机和局部控制3项原则。常用的试验设计有对比设计、随机区组设计、拉丁方设计、裂区设计和正交设计等。对比设计比较简单，包括邻比设计和间比设计。随机区组设计是将试验单位按性质不同分成与重复数一样多的区组，每个区组包括全部处理，在进行统计分析时可将区组间变异分解出来，从而降低试验误差，提高试验精度。拉丁方设计是从行和列两个方向进行局部控制，从而可将行、列区组间的变异从试验误差中分离出来。裂区设计是区内再分区的一种设计方法，有主区、副区之分，通常精度要求高的因素安排在副区，精度要求低的因素安排在主区。正交设计是利用正交表，从全部试验处理组合中挑选部分有代表性的处理组合进行试验，以较少的处理组合反映全面试验实施的情况，从而选出较优的处理组合。

在生物学试验或调查中，通过对一些现象观察，将获得一系列数据资料，最终用数据来反映这些现象的变化规律并得出结论。为使所获得的数据能准确可靠地反映事物的真实规律，在进行试验或调查之前，对整个试验或调查过程应做一个全面安排，这就是试验设计(experimental design)。试验设计是由英国统计学家 R. A. Fisher 于 20 世纪 20 年代为满足科学试验的需要而提出的，是数理统计学的一个分支。

第一节　试验设计的基本原理

试验设计包括广义的试验设计和狭义的试验设计。广义的试验设计是指整个研究课题的设计，包括试验方案的拟订，试验单位的选择、分组的排列，试验过程中试验指标的观察记载，试验资料的整理、分析等内容；而狭义的试验设计则仅是指试验单位的选择、分组与排列方法。生物统计学中的试验设计主要指狭义的试验设计。

一、试验设计的意义

合理的试验设计对科学试验非常重要，它不仅能够节省人力、物力、财力和时间，更重要的是它能够减少试验误差，提高试验的精确度，取得真实可靠的试验资料，为统计分析得出正确的推断和结论奠定基础。

在生物学研究中，一项工作要取得客观、理想的结果，必须做到试验目的明确、试验设计合理、试验操作精细，并采用正确的统计方法对试验结果进行分析。

二、生物学试验的基本要求

为了认识生物的生殖和生长发育规律，就必须进行生物学试验。由于生物的生长发育和繁衍受到光、温、水、气、营养等诸多难以控制的环境条件的影响，这就增加了生物学试验的复杂性。为了科学有效地做好试验，发挥其应有的作用，对生物学试验有如下基本要求。

(一) 试验目的要明确

生物学试验要具有实用性、先进性和创新性。安排试验时，需要对试验的预期结果及其在生产和科研中的作用做到心中有数。首先应抓住当前生产和科研中急需解决的问题作为试验项目，同时要有预见性，从发展的观点出发，适当照顾到长远和在不久的将来可能出现的问题。也就是说，在进行试验时，要有明确的试验目的，既要抓住眼前的关键问题，又要兼顾未来。

(二) 试验条件要有代表性

试验条件要能够代表将来准备推广该项试验结果的地区的生产、经济和自然条件。只有这样，试验结果(新品种、新技术等)才能符合实际，才能被推广利用。在考虑目前实际条件的同时，还应放眼未来生产、经济和科学技术水平的发展，使试验结果既能符合当前需要，又能适应未来发展，从而具有较长的应用寿命。

(三) 试验结果要可靠

试验结果是否可靠，依赖于试验的准确度和精确度两个方面。理论上讲，如果试验没有误差，精确度和准确度一致。试验误差越小，则处理间的比较越精确。因此，在试验的全过程中，要严格按试验要求和操作规程执行各项技术环节，力求避免发生人为的错误和系统误差，尤其要注意试验条件的一致性，减少误差，提高试验结果的可靠性。高度的责任心和科学的态度是保证试验结果可靠性的必要条件。

(四) 试验结果要能重演

试验结果的重演(recapitulation)是指在相同的条件下，重复进行相同试验能得到与原试验结果相同或相近的结果。也就是说，试验结果要能经得起实践的考验。这对于推广试验结果至关重要。为了保证试验结果能够重演，首先，必须严格要求试验的正确执行

和试验条件的代表性。其次，必须注意试验的各个环节，全面控制试验条件和试验过程，有详细、完整、及时和准确的试验过程记载，以便分析各种试验结果产生的原因。此外，对生物学试验还必须考虑到生态环境特点，将试验进行 2 次或 3 次，甚至做多年多点试验，以避免年份、地点、环境条件的不一致所带来的影响。

三、试验设计的基本要素

试验设计包括 3 个基本组成部分，即处理因素、受试对象和处理效应。

（一）处理因素

处理因素（treatment factor）包括单因素处理（single factor treatment）和多因素处理（multiple factors treatment）。如果试验只有一个处理因素，称之为单因素试验（single factor experiment）。如果包含两个或两个以上处理因素的试验称为多因素试验（multiple factors experiment）。相对于单因素试验，多因素试验不但可以研究因素的主效应，而且可以研究因素之间的交互作用。

与处理因素相对应的是非处理因素，这是引起试验误差的主要来源，在试验设计时要引起高度重视，尽量加以有效控制。

（二）受试对象

受试对象（tested subject）是处理因素的客体，实际上就是根据研究目的而确定的观测总体，即前面所提到的试验单位。在进行试验设计时，必须对受试对象所要求的具体条件作出严格规定，以保证其同质性。

（三）处理效应

处理效应（treatment effect）是处理因素作用于受试对象的反映，是研究结果的最终体现。由于试验效应包含了处理效应和试验误差，因此，在分析试验效应时，需按照一定的数学模型通过方差分析等方法将处理效应和试验误差进行分解，并进行检验，以确定处理效应是否显著。

四、试验误差及其控制途径

（一）试验误差的概念

在生物科学试验中，试验处理有其真实的效应，但总是受到许多非处理因素的干扰和影响，使试验处理的真实效应不能充分地反映出来。这样，试验中所取得的观测值，既包含处理的真实效应，又包含不能完全一致的许多其他因素的偶然影响。这种在试验中受偶然影响或者说非处理因素影响使观测值偏离试验处理真值的差异称为试验误差（experiment error）或误差（error）。试验误差是衡量试验精确度的依据，误差小表示精确度高；误差大，则试验结果比较的可靠性就较差，而要使处理间的差异达到指定的显著水平就很困难。近代生物学试验的特点在于注意到了试验设计与统计分析的密切结合。为了

对试验资料进行显著性检验,必须计算试验误差。因此在试验的设计与执行过程中,必须注意合理估计和降低试验误差的问题。

试验误差分为系统误差和随机误差两类。统计上所说的试验误差通常是指随机误差。

(二)试验误差的来源

开展任何试验,都不可避免会产生误差,生物学试验也不例外。因为试验材料是变异丰富的生物有机体,试验中的影响因素千变万化,其中有些条件难以控制。虽然要消除试验误差是不可能的,但是我们可以想办法尽量减少误差。生物学试验中,误差的来源主要有下面4个方面。

1. 试验材料固有的差异

这是指试验中各处理的供试材料在其遗传和生长发育方面或多或少存在着差异。例如,试验用的材料基因型不纯,播种的种子大小有差别,试验用的秧苗大小、壮弱不一致,供试动物体重大小不一、生理状况不一致等。

2. 试验条件不一致

这是指各试验单位的构成不一致和各试验单位所处的外部环境条件不一致,即非试验因素的不一致。例如,在田间试验中,小区的土壤肥力不匀是主要的试验误差来源。

3. 操作技术不一致

操作技术不一致包括各处理或处理组合在培养、采样、接种、滴定、比色等操作过程中存在时间上和质量上的差别。

4. 偶然性因素的影响

试验因素以外的人工无法控制的环境差异和遗传差异引起的误差都是偶然性误差。

除此之外,还有试验工作中疏忽大意造成的错误,应尽量避免。在实际工作或试验研究中,试验误差是不可避免的,但是采取一些措施降低试验误差是完全可能的。

(三)控制试验误差的途径

1. 选择纯合一致的试验材料

首先试验材料在遗传上必须是纯合(或杂合)一致;其次在生长发育上体重、壮弱、大小要尽量一致,若有困难,可按生长发育程度,分成几个档次,把同一档次规格安排在同一区组中,通过局部控制减少试验误差。

2. 改进操作管理制度,使之标准化

为了减少试验误差,首先操作要仔细,工作一丝不苟;其次操作管理中贯彻局部控制原则,一个试验尽量由尽可能少的人在尽可能短的时间内完成。

3. 精心选择试验单位

各试验单位的性质和组成要求均匀一致。但要完全达到这一要求确有困难,可根据局部控制原理,将其分成若干组,使组内尽量均匀一致,组间允许存在差异。

4. 采用合理的试验设计

合理的试验设计既可减少试验误差,也可估计试验误差,从而提高试验的精确度和准确度。

五、试验设计的基本原则

进行试验设计的目的在于减少试验误差，提高试验的准确度和精确度，使研究人员能从所开展的试验结果中获得无偏的处理平均值及试验误差的估计量，从而能进行正确而有效的比较。同时通过合理的试验设计，还能以较少的投入获得较为可靠的大量数据，达到“事半功倍”的效果。为了有效地控制和降低试验误差，试验设计必须遵循下面 3 项基本原则。

（一）重复

在试验中，同一处理设置的试验单位数称为重复（repetition）。在田间试验中，每一小区即为一个试验单位，或称试验单元；在动物试验中，一头动物可以构成一个试验单位，有时一群动物构成一个试验单位。每个处理有两个或两个以上的试验单位，称为有重复的试验。

重复的一个主要作用是估计试验误差。试验误差是客观存在的，但只能通过同一处理内不同重复之间的差异来估计。如果每一个处理只有一个试验单元，即只有一个观测值，则无从求得差异，也就无法估计误差。

设置重复的另一个主要作用是降低试验误差，可有效提高试验的精确度。我们已经知道平均数标准误与标准差的关系为 $s_{\bar{x}}=\frac{s}{\sqrt{n}}$，即误差的大小与重复次数的平方根成反比。故重复越多，误差越小。例如，有 4 次重复的试验，其误差将是只有一次重复的同类试验的一半。重复次数的多少，可根据试验的要求和条件而定。一般来说，如果供试样本个体差异小或非处理因素较均匀时，重复数可少些，否则应多些。

（二）随机

随机（random）是指一个重复中的某一个处理或处理组合被安排在哪一个试验单位，不要有主观成见。设置重复固然提供了估计误差的条件，但是为了获得无偏的试验误差估计值，则要求试验中的每一个处理都有同等的机会设置在任何一个试验单位上。只有随机排列才能满足这个要求。因此，随机化与重复相结合，试验就能提供无偏的试验误差估计值。

在具体试验中，随机化体现在以下两个方面。① 用随机方法来确定每个试验单位接受哪种处理，即在试验分组时，不掺杂任何人为的主观因素，使每个试验单位都有相同的机会进入到各试验组或对照组中。② 如果一个试验中试验条件的安排、试验指标测定的顺序等可能影响到试验结果时，应采用随机化的方法。

（三）局部控制

在试验过程中，要求采取各种技术措施，控制和减少非试验因素对试验结果的影响，使试验误差降低到最小。在生物学试验中，把所有非处理因素控制均衡一致是不易做到的。但我们可以根据非处理因素的变化趋势将大的试验环境分解成若干个相对一致的小

环境，称为区组(block)、窝组(fossa)或重复，再在小环境内分成若干个试验单位安排不同的试验处理，在局部对非处理因素进行控制，这就是局部控制(local control)。在田间试验中，所安排的试验单位称为试验小区(experiment areola)，简称为小区(areola)。由于小环境间的变异可通过方差分析剔除，因而局部控制可以最大限度地降低试验误差。例如，随机区组设计就是将试验单位按非处理因素性质不同分成若干区组，以实现局部控制的目的。

综上所述，一个良好的试验设计，必须遵循重复、随机、局部控制三项原则周密安排试验，才能由试验获得真实的处理效应和无偏的、最小的试验误差估计，从而对各处理间的比较得出可靠的结论。试验设计三项原则的关系可用图 9-1 表示。

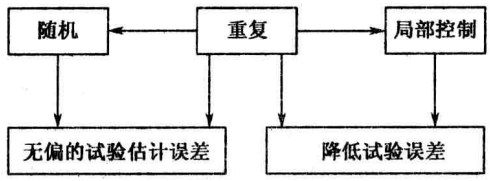

图 9-1　试验设计三项原则间的关系

第二节　对比设计及其统计分析

对比设计(comparison design)是一种最简单的试验设计方法，适用于单因素试验。根据对照(control，CK)区的设置不同，对比设计又可以分为邻比设计(neighbor comparison design)和间比设计(interphase comparison design)两种主要设计方法。

一、对比设计

对比设计是设置一个试验组或几个试验组与许多标准区(对照区)依次比较，在同一个重复内各处理顺序排列，但不同重复排成多排时，应注意不同重复间的相同处理不要排在一条直线上，可采用阶梯式或逆向式排列。

在田间试验中，邻比法排列的特点是每一个处理均直接排列于对照旁边，使每个小区都能与相邻的对照进行比较，能充分反映出处理的效应。在邻比试验中，由于处理区与对照区相连接，土壤、气候条件相差不大，因而，将二者相比时，容易反映出处理与对照之间的真实差异，即使减少重复也能达到应有的精确度。具体做小区排列时，同一个重复内各处理小区顺序排列；每一个重复内的第一个小区应安排为处理区，第二个小区安排为对照区，以后每隔两个处理小区设立一个对照区，同时必须使每一个重复的最后一个处理区的一侧有对照区；不同重复间常采用阶梯式排列(图 9-2)。如果处理数是偶数，一般在每一个重复开头先设一个处理区，再设一个对照区，以后每隔两个处理小区设一个对照区，直至排完为止，这种排列法可以节省一个对照小区。如果处理数是奇数，则每一个重复开头不论先排处理区还是先排对照区，其对照小区数总是相同的。邻比设计最大的优点是简单易行，精度较高，便于观察比较。其缺点是对

照小区太多，一般要占试验地面积的$\frac{1}{3}$。所以，一般在处理数为10以内，或者进行简单对比试验时可采用此法，但如果试验的处理数过多，就不宜采用邻比设计，而可采用对照小区相对较少的间比设计。

Ⅰ	1	CK	2	3	CK	4	5	CK	6
Ⅱ	3	CK	4	5	CK	6	1	CK	2
Ⅲ	5	CK	6	1	CK	2	3	CK	4

图9-2　邻比法排列示意图

Ⅰ、Ⅱ、Ⅲ代表重复；1，2，…，6代表处理；CK为对照

间比设计的特点是，在一条地块上排列的第一小区和末尾的小区一定是对照区；中间每隔相同数目的若干处理小区（通常是4～9个）设置一个对照区；一般设置重复2～4个，每个重复可排成一排或多排，当排成多排时，则多采用逆向式排列（图9-3）。与邻比法相比，间比法试验结果的精度不够高，但在一个试验中可以包括较多的处理。

Ⅰ	CK	1	2	3	4	CK	5	6	7	8	CK
Ⅱ	CK	8	7	6	5	CK	4	3	2	1	CK

图9-3　间比法排列示意图

Ⅰ、Ⅱ代表重复；1，2，…，8代表处理；CK为对照

在动物学试验中，有一种特殊的对比设计，就是把窝别、性别相同及年龄、体重相近的两个动物配成一对，然后用随机的方法将每对的两头动物分别安排到两组处理中。这种试验设计称为配对试验设计（paried experiment design）。在配对试验设计中，应注意同一对动物之间差异要尽量小些，不同对动物之间允许有差异。另外，也可以用同一只动物前后两次进行不同的处理，或对处理前后的结果进行比较，这是一种自身前后配对设计方法。两次不同处理或处理前后在同一只动物身体内进行，条件比两只相似的动物之间的差异要小得多。例如，测定某药物降血压的作用，用药前测一次血压作为对照，用药后再测一次作为处理，前后两次就配成一对数据。配对试验设计方法简单，通过配对降低了干扰因素对试验指标的影响。由于同一对子内两个个体间的试验条件接近，而不同对子间的差异可通过统计处理进行计算，控制了试验误差，提高了试验的精确性。但配对试验设计仅适用于两个处理的试验，具有一定的局限性。

二、对比设计试验结果的统计分析

无论是邻比法还是间比法的对比设计，其试验结果一般采用百分比法（percentage method）与对照相比较分析。首先设对照为100%，邻比试验设计是将各处理与相邻对照进行比较，求出其百分数；间比试验设计是将各处理与前后两个对照的平均数相比求出百分数。

由于对比法试验为顺序排列，未能体现试验设计的随机原则，不能正确地估计出无偏的试验误差，因而理论上其试验结果不能采用方差分析的方法进行显著性检验。

【例 9.1】 某育种站进行水稻品系比较试验，参加 6 个品系，另外设一个对照品种，采用邻比法设计，重复 3 次，产量(kg/6m²)见表 9-1，试作统计分析。

表 9-1　水稻品系比较试验产量分析表

品系	各重复小区产量 /(kg/6m²)			T_i	$\bar{x}_i$	对邻近 CK 的百分数 /%
	Ⅰ	Ⅱ	Ⅲ			
1	19	16	19	54	18.0	105.9
CK	18	17	16	51	17.0	100.0
2	18	18	17	53	17.7	103.9
3	14	15	16	45	15.0	95.7
CK	15	16	16	47	15.7	100.0
4	17	18	17	52	17.3	110.6
5	18	17	18	53	17.7	110.4
CK	16	15	17	48	16.0	100.0
6	17	16	17	50	16.7	104.2

(1) 计算各品系对相邻 CK 的百分数：在表 9-1 中，先将各品系在不同重复中的小区产量相加，得小区产量总和 T_i，然后将各个 T_i 除以重复数，得小区平均产量 $\bar{x}_i$(本步可省略)，再计算各品系产量对邻近 CK 产量的百分数：

$$\text{对邻近 CK 的百分数}(\%)=\frac{\text{某处理总和数}}{\text{邻近 CK 总和数}}\times 100=\frac{\text{某处理平均数}}{\text{邻近 CK 平均数}}\times 100 \quad (9.1)$$

例如，品系 1 对邻近 CK 的百分数(%) $=\frac{54}{51}\times 100=105.9(\%)$，其余品系皆类推。

(2) 试验结论：相对生产力(即对邻近 CK 的百分数)大于 100% 的品种，其百分数越高，就越可能优于对照品种。但也不能认为超过 100% 的所有品种都是显著优于对照的，因为将品种与相邻 CK 相比只是减少了误差，实际上误差仍然存在。一般试验很难察觉处理间差异在 5% 以下的显著性。所以对于对比设计的试验结果，要判断某品种生产力的好坏，其相对生产力一般至少应超过对照 10% 以上；凡相对生产力仅超过对照 5% 左右的品种，均宜继续试验再作结论。当然，由于不同试验的误差大小不同，上述标准仅供参考。

在本例，品系 4、品系 5 的产量超过对照 10% 以上，大体上可以认为它们确实优于对照；品系 1 超过对照 5.9%，尚需进一步试验验证。

第三节　随机区组设计及其统计分析

一、随机区组设计

随机区组设计(randomized blocks design)是根据局部控制和随机原理进行的,将试验单位按性质不同分成与重复数一样多的区组,使区组内非试验因素差异最小而区组间非试验因素差异最大,每个区组均包括全部的处理。区组内各处理随机排列,各区组独立随机排列。

在田间试验中,通常表现为邻近小区土壤肥力相近的特点,如果试验处理数或重复数较多,试验田面积相应增大,土壤差异也要随之增大。如果不同处理的各个重复小区进行完全随机安排,则由于土壤肥力差异增大,即便增加试验重复数,也不能最有效地降低误差。为了克服这种现象,可将整块试验田按照与土壤肥力变化趋势垂直的方向设置与重复数相同的区组。每一个区组内再按处理数目划分成小区,一个小区安排一个处理。因此每一个区组内,即同一个重复的不同处理间土壤差异较小,不同区组(重复)间土壤差异较大。而区组间的差异则可以运用适当的统计方法予以分解,此时能影响试验误差的主要是区组内不同小区间非常小的土壤差异,从而有效减小试验误差,提高试验精度。随机区组设计排列如图 9-4 所示。

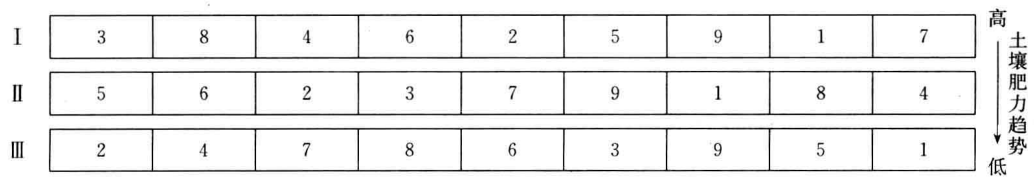

图 9-4　9 处理 3 重复随机区组试验排列示意图

Ⅰ、Ⅱ、Ⅲ表示区组;1,2,…,9 表示处理

随机区组设计在动物试验上称为窝组设计(fossa design)或单位组设计(block design),因为同窝组动物来源相同,不同窝组动物差异较大,所以常以窝组为单位安排试验。在同一个单位组或窝组内各试验动物的安排是随机的。

各试验处理在区组内的随机排列可采用抽签法(lottery)或随机数字法(random digit method)。采用随机数字法时可用如下做法。

(1) 当处理数为一位数字时(设有 9 个处理,分别编号为 1,2,…,9),可以从计算器的随机数字发生器或随机数字表中产生一串随机数字,顺次去掉 0 和重复的数字,直到 1～9 个试验编号全部出现。例如,由随机数字发生器可得到随机数字 3、8、4、4、6、0、6、2、8、4、6、5、8、4、9、4、1、4、9、2、2、4、8、7、6、去掉 0 及重复数字后得到 3、8、4、6、2、5、9、1、7,即为 9 个处理在第一区组内的排列。完成一个区组的排列后,再重复上述做法完成其他区组的排列。

(2) 当处理数目为两位数字时,可以将随机数字串中每相邻两个数字作为一个两位数,再将大于处理数的两位数除以处理数保留余数,然后顺次去掉 0 和重复数字,直到所有处理编号全部出现。然后以同样方法完成其他区组内的排列。

随机区组设计具有以下优点：① 设计简单，比较容易掌握；② 设计富于弹性，单因素、多因素及综合性的试验都可应用该设计方法；③ 能提供无偏的误差估计，在大区域试验中能有效地减少非试验因素的单向差异，有效降低试验误差；④ 对试验区的形状要求不严，不同区组亦可分散设置在不同地段上。该方法只要求每个区组内的非处理因素等试验条件要尽量一致，同区组小区要靠近，同窝组动物所处环境条件也要尽量相同。不足之处是该设计不允许处理数太多，最多不要超过 20 个。因为处理数多，区组的规模必然增大，区组内的误差也会相应增大，这样局部控制的效率就会降低。但在随机区组设计中，处理或处理组合也不能太少，如果太少，误差项的自由度就会太小，误差就会相应增大，也会降低假设检验的灵敏度。

二、随机区组设计试验结果的统计分析

随机区组设计充分体现了试验设计的 3 项基本原则，精确度较高。为了将区组间差异从试验误差中分解出来，其试验结果采用方差分析法进行统计分析。随机区组设计适应范围较广，既适用于单因素试验也适用于多因素试验。下面分别叙述之。

(一) 单因素随机区组试验结果的统计分析

单因素随机区组设计(randomized block design of one-factor)的统计分析是把区组(或窝组)看成一个因素，与处理因素一起作为二因素，按第六章二因素无重复观测值的方差分析方法进行。

在单因素随机区组试验中，设试验有 k 个处理、n 个区组，整个试验共有 nk 个观测值，其每一观测值 x_{ij} 的线性模型为

$$x_{ij}=\mu+\alpha_i+\beta_j+\varepsilon_{ij} \tag{9.2}$$

式中，μ 为总体平均数；α_i 为处理效应($i=1,2,\cdots,k$)；β_j 为区组效应($j=1,2,\cdots,n$)；ε_{ij} 为误差，来自总体 $N(0,\sigma^2)$。

根据式(9.2)，总平方和与总自由度均可分解为区组、处理和误差的相应部分，即

$$\left.\begin{aligned} SS_T&=SS_r+SS_t+SS_e\\ df_T&=df_r+df_t+df_e \end{aligned}\right\} \tag{9.3}$$

式中，T 为总和；r 为区组；t 为处理；e 为随机误差。

各部分自由度的计算公式如下：

$$\left.\begin{aligned} &\text{总自由度}\quad df_T=nk-1\\ &\text{区组自由度}\ df_r=n-1\\ &\text{处理自由度}\ df_t=k-1\\ &\text{误差自由度}\ df_e=(n-1)(k-1) \end{aligned}\right\} \tag{9.4}$$

各部分平方和的计算公式如下：

$$
\left.\begin{aligned}
&\text{矫正数}\quad C=\frac{T^2}{nk}\\
&\text{总平方和}\quad SS_T=\sum_1^k\sum_1^n(x-\bar{x})^2=\sum_1^{nk}x^2-C\\
&\text{区组平方和}\ SS_r=k\sum_1^n(\bar{x}_r-\bar{x})^2=\frac{\sum_1^n T_r^2}{k}-C\\
&\text{处理平方和}\ SS_t=n\sum_1^k(\bar{x}_t-\bar{x})^2=\frac{\sum_1^k T_t^2}{n}-C\\
&\text{误差平方和}\ SS_e=\sum_1^k\sum_1^n(x-\bar{x}_r-\bar{x}_t+\bar{x})^2=SS_T-SS_r-SS_t
\end{aligned}\right\}\qquad(9.5)
$$

下面举一个实例对单因素随机区组设计试验结果的统计分析进行介绍。

【例 9.2】 有一个小麦品系比较试验，共有 8 个品种，用 A、B、C、D、E、F、G、H 作为品种代号，其中 A 为标准品种，试验采用随机区组设计，设置 3 次重复，田间排列及小区计产(kg/40m²) 结果如图 9-5 所示，试作方差分析。

Ⅰ	*B* 10.8	*F* 10.1	*A* 10.9	*E* 11.8	*H* 9.3	*G* 10.0	*C* 11.1	*D* 9.1
Ⅱ	*C* 12.5	*E* 13.9	*G* 11.5	*H* 10.4	*B* 12.3	*A* 9.1	*D* 10.7	*F* 10.6
Ⅲ	*A* 12.2	*C* 10.5	*E* 16.8	*G* 14.1	*D* 10.1	*H* 14.4	*F* 11.8	*B* 14.0

图 9-5　小麦品系比较试验田间排列和产量结果

方差分析的具体步骤如下所述。

(1)原始资料的整理。将图 9-5 中的小区产量结果整理成区组和处理两向表(表 9-2)，分别计算各处理总和 T_t 及平均数 $\bar{x}_t$、各区组总和 T_r 和全试验总和 T。

表 9-2　小麦品系比较试验(随机区组)的产量结果　　(单位：kg/40m²)

品种	区组				
	Ⅰ	Ⅱ	Ⅲ	T_t	$\bar{x}_t$
A	10.9	9.1	12.2	32.2	10.7
B	10.8	12.3	14.0	37.1	12.4
C	11.1	12.5	10.5	34.1	11.4
D	9.1	10.7	10.1	29.9	10.0
E	11.8	13.9	16.8	42.5	14.2
F	10.1	10.6	11.8	32.5	10.8
G	10.0	11.5	14.1	35.6	11.9
H	9.3	10.4	14.4	34.1	11.4
T_r	83.1	91.0	103.9	$T=278.0$	

(2)平方和与自由度的分解。

平方和的分解：

$$C=\frac{T^2}{nk}=\frac{278.0^2}{3\times 8}=3220.17$$

$$SS_T=\sum x^2-C=(10.9^2+9.1^2+\cdots+14.4^2)-3220.17=84.61$$

$$SS_r=\frac{\sum T_r^2}{k}-C=\frac{83.1^2+91.0^2+103.9^2}{8}-3220.17=27.56$$

$$SS_t=\frac{\sum T_t^2}{n}-C=\frac{32.2^2+37.1^2+\cdots+34.1^2}{3}-3220.17=34.08$$

$$SS_e=SS_T-SS_r-SS_t=84.61-27.56-34.08=22.97$$

自由度的分解：

$$df_T=nk-1=3\times 8-1=23$$

$$df_r=n-1=3-1=2$$

$$df_t=k-1=8-1=7$$

$$df_e=(n-1)(k-1)=(3-1)\times(8-1)=14$$

(3) 列方差分析表进行 F 检验。

由表 9-3 可知，品种间的 F 值显著，说明 8 个供试品种的平均数差异显著，需作多重比较。区组间的 F 值极显著，说明本试验中区组作为局部控制手段，对减少误差是相当有效的。由于一般试验的目的不是研究区组效应，所以可不必进行区组间的多重比较。

表 9-3　表 9-2 资料的方差分析

变异来源	df	SS	s^2	F	$F_{0.05}$	$F_{0.01}$
区组间	2	27.56	13.78	8.40**	3.74	6.51
品种间	7	34.08	4.87	2.97*	2.76	4.28
误差	14	22.97	1.64			
总变异	23	84.61				

(4)品种间多重比较。因试验设有对照（标准品种 A），故采用 LSD 法：

$$s_{\bar{x}_1-\bar{x}_2}=\sqrt{\frac{2s_e^2}{n}}=\sqrt{\frac{2\times 1.64}{3}}=1.05(\text{kg}/40\text{m}^2)$$

因误差自由度 $df_e=14$ 时，查附表 3，$t_{0.05}=2.145$、$t_{0.01}=2.977$，进而计算 LSD_α 值：

$$LSD_{0.05}=2.145\times 1.05=2.252(\text{kg}/40\text{m}^2)$$

$$LSD_{0.01}=2.977\times 1.05=3.126(\text{kg}/40\text{m}^2)$$

各品种与 A 品种相比较的差异显著性见表 9-4。

表 9-4　各品种与 CK 相比较的差异显著性

品种	$\bar{x}$/(kg/40m²)	与 CK 差值及显著性
E	14.2	3.5**
B	12.4	1.7
G	11.9	1.2
H	11.4	0.7
C	11.4	0.7
F	10.8	0.1
D	10.0	−0.7
A(CK)	10.7	

结果表明：除品种 E 与对照产量有极显著差异外，其他品种与对照均无显著差异。

（二）二因素随机区组试验结果的统计分析

二因素随机区组设计（randomized block design of two-factor）试验包含两个因素 A、B，设 A 因素有 a 个水平，B 因素有 b 个水平，区组数为 n，试验中两因素各水平组成 ab 个处理组合，每一套处理组合随机分配在 n 个区组内，全部试验三向分组资料共得 abn 个观测值。则其每一观测值 x_{ijk} 的线性模型为

$$x_{ijk}=\mu+\alpha_i+\beta_j+(\alpha\beta)_{ij}+\gamma_k+\varepsilon_{ijk} \tag{9.6}$$

式中，μ 为总体平均数；α_i 为 A 因素主效（$i=1,2,\cdots,a$）；β_j 为 B 因素主效（$j=1,2,\cdots,b$）；$(\alpha\beta)_{ij}$ 为 AB 交互作用效应；γ_k 为区组效应（$k=1,2,\cdots,n$）；ε_{ijk} 为随机误差，具有 $N(0,\sigma^2)$。

由此可知，二因素随机区组试验的处理效应可进一步分解为 A 因素、B 因素和 AB 互作 3 部分效应，因而相应的平方和与自由度可分解为

$$\left.\begin{aligned} SS_T&=SS_r+SS_A+SS_B+SS_{AB}+SS_e\\ df_T&=df_r+df_A+df_B+df_{AB}+df_e \end{aligned}\right\} \tag{9.7}$$

其中，

$$\begin{aligned} SS_A+SS_B+SS_{AB}&=SS_t\\ df_A+df_B+df_{AB}&=df_t \end{aligned}$$

式中，T 为总和；r 为区组；t 为处理；e 为随机误差；A 为 A 因素；B 为 B 因素；AB 为两因素互作。各部分平方和可由下列各式计算：

$$\left.\begin{aligned} C&=\frac{\left(\sum x\right)^2}{abn}=\frac{T^2}{abn}\\ SS_T&=\sum_1^{abn}(x-\bar{x})^2=\sum_1^{abn}x^2-C\\ SS_r&=ab\sum_1^{n}(\bar{x}_r-\bar{x})^2=\frac{\sum_1^{n}T_r^2}{ab}-C\\ SS_t&=n\sum_1^{ab}(\bar{x}_{ij}-\bar{x})^2=\frac{\sum_1^{ab}T_{AB}^2}{n}-C\\ SS_A&=bn\sum_1^{a}(\bar{x}_i-\bar{x})^2=\frac{\sum_1^{a}T_A^2}{bn}-C\\ SS_B&=an\sum_1^{b}(\bar{x}_j-\bar{x})^2=\frac{\sum_1^{b}T_B^2}{an}-C\\ SS_{AB}&=n\sum_1^{ab}(\bar{x}_{ij}-\bar{x}_i-\bar{x}_j+\bar{x})^2=SS_t-SS_A-SS_B\\ SS_e&=\sum_1^{abn}(x-\bar{x}_r-\bar{x}_{ij}+\bar{x})^2=SS_T-SS_r-SS_t \end{aligned}\right\} \tag{9.8}$$

各部分自由度的计算公式如下：

$$\left.\begin{aligned} df_T &= abn-1 \\ df_r &= n-1 \\ df_t &= ab-1 \\ df_A &= a-1 \\ df_B &= b-1 \\ df_{AB} &= (a-1)(b-1) \\ df_e &= (ab-1)(n-1) \end{aligned}\right\} \tag{9.9}$$

以实例对二因素随机区组设计试验的分析进行具体介绍。

【例 9.3】 为探讨橡胶树品系与栽培密度对年产干胶量的影响，现设计了一个 2 因素 4 次重复的随机区组试验，其中参试品系(A 因素)有 2 个品系，栽培密度(B 因素)有 3 种方式(表 9-5)。产量(kg/667m²)结果列于表 9-6。试作方差分析。

表 9-5　橡胶品系及栽培密度对年产干胶量影响试验方案

品系(A)	栽培密度(B)		
	B_1(3m × 6m)	B_2(4m × 6m)	B_3(3.5m × 6m)
A_1	A_1B_1	A_1B_2	A_1B_3
A_2	A_2B_1	A_2B_2	A_2B_3

表 9-6　不同处理的橡胶产量　　(单位：kg/667m²)

处理	区组				T_{AB}
	Ⅰ	Ⅱ	Ⅲ	Ⅳ	
A_1B_1	56	45	43	46	190
A_2B_1	65	61	60	63	249
A_1B_2	60	50	45	48	203
A_2B_2	60	58	56	60	234
A_1B_3	66	57	50	50	223
A_2B_3	53	53	48	55	209
T_r	360	324	302	322	T = 1308

(1) 结果整理：将试验结果按处理和区组两向分组整理成表 9-6，在表 9-6 中计算出处理总和 T_{AB}、区组总和 T_r 和全试验总和 T。按品系和栽培密度整理成两向表(表 9-7)。在表 9-7 中计算出 A 因素(品系)各水平总和 T_A 和 B 因素(栽培密度)各水平总和 T_B。

表 9-7　表 9-6 资料品系(A)和栽培密度(B)的两向表

因素 A	因素 B			T_A
	B_1	B_2	B_3	
A_1	190	203	223	616
A_2	249	234	209	692
T_B	439	437	432	T = 1308

（2）平方和与自由度的分解。

$$C=\frac{T^2}{abn}=\frac{1308^2}{2\times3\times4}=71286$$

$$SS_T=\sum x^2-C=56^2+45^2+\cdots+55^2-71286=1036$$

$$SS_r=\frac{\sum T_r^2}{ab}-C=\frac{360^2+324^2+302^2+322^2}{2\times3}-71286=291.33$$

$$SS_t=\frac{\sum T_{AB}^2}{n}-C=\frac{190^2+249^2+\cdots+209^2}{4}-71286=583$$

$$SS_A=\frac{\sum T_A^2}{bn}-C=\frac{616^2+692^2}{3\times4}-71286=240.67$$

$$SS_B=\frac{\sum T_B^2}{an}-C=\frac{439^2+437^2+432^2}{2\times4}-71286=3.25$$

$$SS_{AB}=SS_t-SS_A-SS_B=583-240.67-3.25=339.08$$

$$SS_e=SS_T-SS_r-SS_t=1036-291.33-583=161.67$$

$$df_T=abn-1=2\times3\times4-1=23$$

$$df_r=n-1=4-1=3$$

$$df_t=ab-1=2\times3-1=5$$

$$df_A=a-1=2-1=1$$

$$df_B=b-1=3-1=2$$

$$df_{AB}=(a-1)(b-1)=(2-1)\times(3-1)=2$$

$$df_e=(ab-1)(n-1)=(2\times3-1)\times(4-1)=15$$

（3）列方差分析表，进行 F 检验：将上述计算结果填入表 9-8。

表 9-8　橡胶产量的方差分析表

变异来源	df	SS	s^2	F	$F_{0.05}$	$F_{0.01}$
区组间	3	291.33	97.11	9.01**	3.29	5.42
品系(A)	1	240.67	240.67	22.33**	4.54	8.68
栽培密度(B)	2	3.25	1.63	<1	3.68	6.36
$A\times B$	2	339.08	169.54	15.73**	3.68	6.36
误差	15	161.67	10.78			
总变异	23	1036				

按固定模型分析，除栽培密度差异未达显著外，区组间、品系间、品系×栽培密度的互作差异均达极显著水平，因而需进行多重比较。其中，区组间的显著性不是统计分析的目的，故区组间的比较可免去；对于品系，只有两个水平，不必进行多重比较，因 $T_{A_2}=692$ 大于 $T_{A_1}=616$，故品系 A_2 极显著优于品系 A_1。因此只需对品系×栽培密度互作进行多重比较。

（4）多重比较。由于橡胶品系×栽培密度的互作间差异极显著，所以在不同品系条件下，不同栽培密度的橡胶年产干胶量并非一样，因此需要比较不同品系下各栽培密度的

橡胶产量(*LSD* 法)。首先求出:

$$s_{\bar{x}_1-\bar{x}_2}=\sqrt{\frac{2s_e^2}{n}}=\sqrt{\frac{2\times 10.78}{4}}=2.32(\text{kg}/667\text{m}^2)$$

按试验误差自由度 $df_e=15$,查表得 $t_{0.05}=2.131$、$t_{0.01}=2.947$,因而:

$$LSD_{0.05}=t_{0.05}s_{\bar{x}_1-\bar{x}_2}=2.131\times 2.32=4.94(\text{kg}/667\text{m}^2)$$

$$LSD_{0.01}=t_{0.01}s_{\bar{x}_1-\bar{x}_2}=2.947\times 2.32=6.84(\text{kg}/667\text{m}^2)$$

表 9-9　不同橡胶品系下栽培密度对产量作用的差异显著性

密度	品系 A_1			密度	品系 A_2		
	平均产量 /(kg/667m²)	差异显著性			平均产量 /(kg/667m²)	差异显著性	
		$\alpha=0.05$	$\alpha=0.01$			$\alpha=0.05$	$\alpha=0.01$
B_3(3.5m×6m)	55.75	*a*	*A*	B_1(3m×6m)	62.25	*a*	*A*
B_2(4m×6m)	50.75	*b*	*AB*	B_2(4m×6m)	58.50	*a*	*AB*
B_1(3m×6m)	47.50	*b*	*B*	B_3(3.5m×6m)	52.25	*b*	*B*

从表 9-9 可以看出,品系 A_1 以 3.5m×6m 密度的产量最高,显著高于 4m×6m,极显著高于 3m×6m;品系 A_2 以 3m×6m 密度的产量最高,极显著高于 3.5m×6m;4m×6m 的产量显著高于 3.5m×6m。综合来看,以 A_2B_1 和 A_2B_2 效果最好,且二者间无显著差异,从节约成本角度看,则优先选择 A_2B_2,即选择品系 2,且栽培密度为 4m×6m。

第四节　拉丁方设计及其统计分析

"拉丁方"(latin square)一词最早是由英国统计学家 R. A. Fisher 提出的。其含义为,将 k 个不同符号排成一个 k 阶方阵,使每一个符号在每一行、每一列都仅出现一次,这个方阵称为 $k\times k$ 拉丁方。

一、拉丁方设计

拉丁方设计(latin square design),就是在行和列两个方向上都进行局部控制,使行、列两向皆成完全区组或重复,是比随机区组设计多一个区组的设计。处理数、重复数、行数、列数都相等是拉丁方设计的特点。当行间、列间皆有明显差异时,其行、列两个区组的变异可以从试验误差中分解出来。因此在控制试验误差、提高试验精确度方面,应用拉丁方设计比随机区组设计更为有效。Cochran 经过 8 年的田间试验表明,拉丁方试验的误差方差约为随机区组试验的 73%。但拉丁方设计需保持行、列、处理数三者相等如正方形的试验空间,缺乏伸缩性。因此,试验处理数一般不能太多,以 5 ～ 10 个为宜,且在对试验精确度有较高要求时使用。处理数大于 10 个,试验庞大,很难实施;处理数小于等于 4,误差项自由度不足。为了较精确地估计试验误差和检验处理效应,拉丁方试验要求误差自由度不小于 12,最好大于 20。

在动物实验中,如要控制来自两个方面的系统误差,且在动物头数较少情况下常采用这种设计方法。例如,研究 5 种不同饲料(分别用 1 号、2 号、3 号、4 号、5 号表示)对

乳牛产乳量影响的试验，选择5头乳牛(分别为Ⅰ号、Ⅱ号、Ⅲ号、Ⅳ号、Ⅴ号)，每头乳牛的泌乳期分为5个阶段(分别为1月、2月、3月、4月、5月)，随机分配饲料的5个水平。在这个试验中，由于乳牛个体及牛的泌乳期不同对产乳量都会有影响，故可以把其分别作为区组设置，采用一个5×5的拉丁方设计(表9-10)。下面以此为例说明拉丁方的设计方法。

表9-10　饲料类型对乳牛产乳量影响的拉丁方设计

牛号	泌乳时间				
	1月	2月	3月	4月	5月
Ⅰ	*A*	*B*	*C*	*D*	*E*
Ⅱ	*B*	*A*	*E*	*C*	*D*
Ⅲ	*C*	*D*	*A*	*E*	*B*
Ⅳ	*D*	*E*	*B*	*A*	*C*
Ⅴ	*E*	*C*	*D*	*B*	*A*

拉丁方试验设计的方法步骤如下所述。

1. 选择标准方

所谓标准方(standard square)是指代表处理的字母，在第一行和第一列皆为顺序排列的拉丁方。标准方的数目较多。附表9列出了3×3、4×4、5×5、7×7、8×8的拉丁方，供进行拉丁方试验设计时选用。

拉丁方设计时，首先根据试验的处理数k选一个$k\times k$的标准方。本例处理数为5，需要选一个5×5的标准方，如可以选附表9中5×5的Ⅳ如图9-6(1)所示。在此基础上还要对标准方的列、行和处理进行随机化排列。可用计算器中随机数字发生器或用抽签的方法依次得到若干个数，凡有“0”及“6”以上的数均不要，重复的也不要，满5个数为一组，这样可得到3组5位数，如得到的3组随机数依次为32145、25431、51342。

2. 列随机

用第一组随机数字32145调整标准方的列顺序，即把第3列调至第1列，第1列调至第3列，其余列不动，如图9-6(2)所示。

3. 行随机

用第二组随机数字25431调整第二步得到的拉丁方，即第2行调至第1行，第5行调至第2行，第4行调至第3行，第3行调至第4行，第1行调至第5行。如图9-6(3)所示。

4. 处理随机

将处理(饲料)的编号按第三组数51342的顺序进行随机排列，即5号＝A、1号＝B、3号＝C、4号＝D、2号＝E，则经过随机重排后的拉丁方中，A处理为5号饲料、B处理为1号饲料、C处理为3号饲料、D处理为4号饲料、E处理为2号饲料。如图9-6(4)所示。

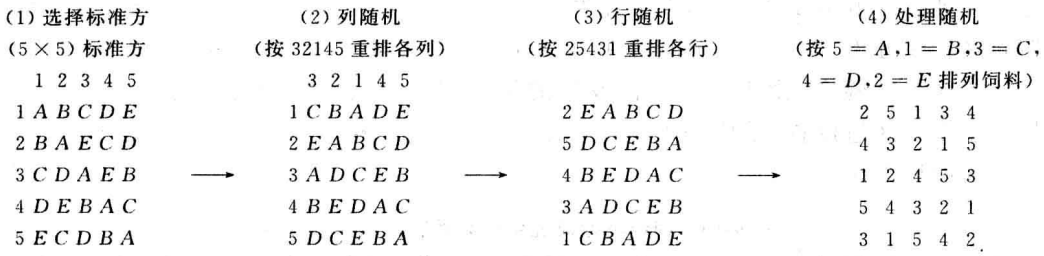

图 9-6　拉丁方试验设计的步骤图示

表 9-10 中饲料类型对乳牛产乳量影响试验经上述随机重排后，最终可得到表 9-11 的拉丁方试验设计及试验结果。

表 9-11　饲料类型对乳牛产乳量影响的试验结果　　(单位：kg)

牛号	月份					T_r
	1	2	3	4	5	
Ⅰ	*E* 300	*A* 320	*B* 390	*C* 390	*D* 380	1780
Ⅱ	*D* 420	*C* 390	*E* 280	*B* 370	*A* 270	1730
Ⅲ	*B* 350	*E* 360	*D* 400	*A* 260	*C* 400	1770
Ⅳ	*A* 280	*D* 400	*C* 390	*E* 280	*B* 370	1720
Ⅴ	*C* 400	*B* 380	*A* 350	*D* 430	*E* 320	1880
T_c	1750	1850	1810	1730	1740	$T = 8880$

二、拉丁方设计试验结果的统计分析

假定以 x_{ij} 代表拉丁方的 i 横行、j 纵列的交叉观测值，再以 t 代表处理，则拉丁方试验的线性模型为

$$x_{ij(t)} = \mu + \alpha_i + \beta_j + \gamma_{(t)} + \varepsilon_{ij(t)} \tag{9.10}$$

式中，$\varepsilon_{ij(t)}$ 为随机误差，并服从正态分布$(0,\sigma^2)$，才能用来进行正确的检验。如果处理与纵列或横行区组有交互作用存在，则交互作用与误差相混杂，不能得到正确的误差估计，难以进行正确的检验。不过，只要非试验因素差异不太大，一般假定不存在互作。

拉丁方试验中行、列皆成区组，根据式(9.10)，在试验结果统计分析中比随机区组多一项区组间变异，即总变异可分解为处理间、行区组间、列区组间和试验误差 4 个部分。其自由度与平方和可按下式进行分解：

$$\begin{aligned} df_T &= df_{横行} + df_{纵列} + df_t + df_e \\ k^2 - 1 &= (k-1) + (k-1) + (k-1) + (k-1)(k-2) \\ SS_T &= SS_{横行} + SS_{纵列} + SS_t + SS_e \end{aligned} \tag{9.11}$$

$$\sum_1^{k^2}(x-\bar{x})^2 = k\sum_1^k(\bar{x}_r-\bar{x})^2 + k\sum_1^k(\bar{x}_c-\bar{x})^2 + k\sum_1^k(\bar{x}_t-\bar{x})^2$$

$$+\sum_{1}^{k^2}(x-\bar{x}_r-\bar{x}_c-\bar{x}_t+2\bar{x})^2 \tag{9.12}$$

式中，x 为各处理观测值；$\bar{x}_r$ 为行区组平均数；$\bar{x}_c$ 为列区组平均数；$\bar{x}_t$ 为处理平均数；$\bar{x}$ 为全试验平均数。

以具体实例介绍拉丁方设计试验结果的统计分析方法。

【例 9.4】 上述饲料类型对乳牛产乳量 5×5 拉丁方试验，乳牛产乳量(kg)结果如表 9-11 所示，试进行统计分析。

(1) 结果整理：将试验资料按横行、纵列排列，并计算总和，整理成表 9-11，饲料处理的总和(T_t) 和平均数($\bar{x}_t$) 列于表 9-12。

表 9-12　例 9.4 资料中不同饲料处理的总和(T_t)和平均数($\bar{x}_t$)

饲料	5 号(A)	1 号(B)	3 号(C)	4 号(D)	2 号(E)	总和
T_t	1480	1860	1970	2030	1540	8880
$\bar{x}_t$	296	372	394	406	308	

(2) 自由度和平方和的分解。

总自由度　　$df_T=5\times5-1=24$

纵列(月份) 自由度 $df_c=5-1=4$

横行(乳牛) 自由度 $df_r=5-1=4$

处理(饲料) 自由度 $df_t=5-1=4$

误差自由度　　$df_e=24-4-4-4=12$

矫正数　　$C=\dfrac{T^2}{k\times k}=\dfrac{8880^2}{5\times5}=3154176$

总平方和　　$SS_T=\sum x^2-C=300^2+320^2+\cdots+320^2-3154176$

$=63224$

纵列(月份) 平方和 $SS_c=\dfrac{1}{k}\times\sum T_c^2-C$

$=\dfrac{1}{5}\times(1750^2+1850^2+\cdots+1740^2)-3154176=2144$

横行(乳牛) 平方和 $SS_r=\dfrac{1}{k}\times\sum T_r^2-C$

$=\dfrac{1}{5}\times(1780^2+1730^2+\cdots+1880^2)-3154176=3224$

处理(饲料) 平方和 $SS_t=\dfrac{1}{k}\times\sum T_t^2-C$

$=\dfrac{1}{5}\times(1480^2+1860^2+\cdots+1540^2)-3154176$

$=50504$

误差平方和　　$SS_e=SS_T-SS_c-SS_r-SS_t$

$$=63224-2144-3224-50504=7352$$

(3) 列出方差分析表,计算 F 值:将上述计算结果填入表 9-13。

表 9-13　饲料类型对乳牛产乳量影响的方差分析表

变异来源	df	SS	s^2	F	$F_{0.05}$	$F_{0.01}$
纵列(月份)间	4	2144	536.00			
横行(乳牛)间	4	3224	806.00			
处理(饲料)间	4	50504	12626.00	20.61**	3.26	5.41
误差	12	7352	612.67			
总变异	24	63224				

查附表 5,当 $df_1=4$、$df_2=12$ 时,$F_{0.05}=3.26$、$F_{0.01}=5.41$,现 $F=20.61>5.41$,即 $P<0.01$,表示 5 种不同的饲料间存在极显著的差异。

(4) 比较各处理(饲料)间的差异,采用 q 检验法。

$$\text{饲料平均数标准误 } s_{\bar{x}}=\sqrt{\frac{s_e^2}{k}}=\sqrt{\frac{612.67}{5}}=11.07(\text{kg})$$

当 $df_e=12$ 时,由 q 值表查得 M 为 2、3、4、5 时的 $q_{0.05}$ 和 $q_{0.01}$ 值,并算得 $LSR_{0.05}$ 和 $LSR_{0.01}$ 列于表 9-14。

表 9-14　例 9.4 资料 q 检验的 LSR 值

M	$q_{0.05}$	$q_{0.01}$	$LSR_{0.05}$	$LSR_{0.01}$
2	3.08	4.32	34.096	47.822
3	3.77	5.04	41.734	55.793
4	4.20	5.50	46.494	60.885
5	4.51	5.84	49.926	64.649

以表 9-14 的 LSR 值对各饲料组的乳牛产乳量进行检验,其差异显著性结果列于表 9-15。

表 9-15　不同饲料的乳牛产乳量比较(q 法)

饲料名称	平均产乳量 $(\bar{x}_{t_i})$	差异显著性	
		$\alpha=0.05$	$\alpha=0.01$
4 号(D)	406	a	A
3 号(C)	394	a	A
1 号(B)	372	a	A
2 号(E)	308	b	B
5 号(A)	296	b	B

由不同饲料处理乳牛产乳量的 q 检验结果可以看出,4 号、3 号、1 号饲料与 2 号、5 号饲料之间的差异都达极显著水平。从平均数来看,4 号饲料效果最好,其次是 3 号饲料和 1 号饲料,5 号饲料最差。

第五节　裂区设计及其统计分析

裂区设计(split plot design)是多因素试验设计的一种形式。当试验处理组合数太多,而不同试验因素重要性不一样或因素可控性存在差异等特殊条件下,常常用裂区设计。本节介绍二因素裂区设计(two-factor split plot design)或称为二裂式裂区设计及其统计分析。

一、裂区设计

进行裂区设计时,首先是将每一区组按第一因素的处理数划分小区,称为主区(main plot),亦称为整区,在主区里随机安排主处理(main treatment);然后在主区内引进第二个因素的各个处理,即副处理(secondary treatment),就是主处理的小区内分设与副处理数相等的更小的小区,称为副区(secondary plot),又称为裂区(split plot),在副区里随机排列副处理。在这种试验设计中,从第二个因素来讲,主区就是一个区组;但是从整个试验所有处理组合来讲,主区又是一个不完全区组。由于这种设计将主区分裂为副区,故称为裂区设计。其设计特点是主处理分设在主区,副处理分设于主区内的副区,副区之间比主区之间的试验空间更为接近。因此进行统计分析时,可分别估算主区与副区的试验误差,而后者常小于前者,即副区的比较比主区的比较更为精确。在应用裂区设计时应适当考虑这一点。

裂区设计通常在下列情况下应用。

(1) 一个因素的各处理比另一个因素的各处理需要更大区域时,为了实施和管理上的方便而应用裂区设计。需要较大区域的因素宜作为主处理,设在主区,而另一个需要区域较小的因素可设置于副区。

(2) 试验中某一个因素的主效比另一个因素的主效更为重要,而且要求更精确的比较,或两个因素的交互作用比其主效更为重要时,宜采用裂区设计,将要求精度较高的因素作为副处理,另一个因素作为主处理。

(3) 根据以往的研究,知道某些因素的效应比另一些因素的效应更大时也可采用裂区设计,将可能表现较大差异的因素作为主处理。

(4) 试验设计需临时改动再加入一个试验因素时,可在原试验设计中的小区(主区)中再划分若干个小区(副区),增加一个试验因素,这样就成了裂区设计。当然,一般情况下我们还是要强调事先的周密设计,这种临时再改变设计方案的做法只是一种在可能情况下的补救措施。

二、裂区设计试验结果的统计分析

在裂区试验中,设有 A 和 B 两个试验因素,A 因素为主处理,具 a 个水平;B 因素为副处理,具 b 个水平;区组数为 n,整个试验共有 abn 个观测值。其任一观测值 x_{ijk} 的线性模型为

$$x_{ijk}=\mu+\gamma_k+\alpha_i+\delta_{ik}+\beta_j+(\alpha\beta)_{ij}+\varepsilon_{ijk} \tag{9.13}$$

式中，μ 为总体平均数；γ_k 为区组效应($k=1,2,\cdots,n$)；α_i 为主处理(A 因素)效应($i=1,2,\cdots,a$)；β_j 为副处理(B 因素)效应($j=1,2,\cdots,b$)；$(\alpha\beta)_{ij}$ 为 $A\times B$ 互作效应；δ_{ik} 和 ε_{ijk} 分别为主区误差和副区误差，并分别服从 $N(0,\sigma_1^2)$ 和 $N(0,\sigma_2^2)$。

根据式(9.13)，裂区设计的平方和可分解为

$$\left.\begin{aligned} SS_T&=SS_r+SS_A+SS_{e_a}+SS_B+SS_{AB}+SS_{e_b}\\ df_T&=df_r+df_A+df_{e_a}+df_B+df_{AB}+df_{e_b}\end{aligned}\right\} \tag{9.14}$$

其中，

$$\left.\begin{aligned} &SS_m+SS_s=SS_T\\ &SS_A+SS_B+SS_{AB}=SS_t\\ &SS_A+SS_r+SS_{e_a}=SS_m\\ &SS_B+SS_{AB}+SS_{e_b}=SS_s\\ &SS_{e_a}+SS_{e_b}=SS_e\\ &df_m+df_s=df_T\\ &df_A+df_B+df_{AB}=df_t\\ &df_A+df_r+df_{e_a}=df_m\\ &df_B+df_{AB}+df_{e_b}=df_s\\ &df_{e_a}+df_{e_b}=df_e\end{aligned}\right\} \tag{9.15}$$

式(9.14)和式(9.15)中，T 为总和；r 为区组；t 为处理；m 为主处理；s 为副处理；A 为 A 因素；B 为 B 因素；AB 为两因素互作；e 为试验误差；e_a 为主区误差(即误差 a)；e_b 为副区误差(即误差 b)。则各部分平方和计算公式如下所述。

主区部分：

$$\left.\begin{aligned} &\text{矫正数}\quad C=\frac{T^2}{abn}\\ &\text{总平方和}\quad SS_T=\sum x^2-C\\ &\text{主区平方和}\quad SS_m=\frac{1}{b}\sum T_m^2-C\\ &A\text{ 因素平方和}\quad SS_A=\frac{1}{bn}\sum T_A^2-C\\ &\text{区组平方和}\quad SS_r=\frac{1}{ab}\sum T_r^2-C\\ &\text{主区误差平方和}\quad SS_{e_a}=SS_m-SS_A-SS_r\end{aligned}\right\} \tag{9.16}$$

副区部分：

$$
\left.\begin{aligned}
&\text{处理间平方和} \quad SS_t = \frac{1}{n}\sum T_t^2 - C \\
&\text{副区平方和} \quad SS_s = \sum x^2 - \frac{1}{b}\sum T_m^2 = SS_T - SS_m \\
&B\text{ 因素平方和} \quad SS_B = \frac{1}{an}\sum T_B^2 - C \\
&A \times B\text{ 平方和} \quad SS_{AB} = SS_t - SS_A - SS_B \\
&\text{副区误差平方和} \quad SS_{e_b} = SS_T - SS_r - SS_A - SS_{e_a} - SS_B - SS_{AB} \\
&\qquad\qquad = SS_T - SS_r - SS_t - SS_{e_a}
\end{aligned}\right\} \tag{9.17}
$$

裂区设计各项变异来源和相应的自由度见表 9-16。

表 9-16　二裂式裂区试验设计自由度的分解

变异来源		df
主区部分	区组	$n-1$
	A	$a-1$
	误差 a	$(a-1)(n-1)$
	主区变异	$an-1$
副区部分	处理	$ab-1$
	B	$b-1$
	$A \times B$	$(a-1)(b-1)$
	误差 b	$a(b-1)(n-1)$
	副区变异	$an(b-1)$
总变异		$abn-1$

由表 9-16 可见，二裂式裂区试验和二因素随机区组试验在分析上的不同，仅在于前者有主区部分和副区部分，因而有主区误差(error of main plot) 和副区误差(error of secondary plot)，分别用于检验主区处理以及副区处理和主、副处理互作的显著性。又由式(9.14) ～ 式(9.17) 知，df_r、SS_r 分别为随机区组设计误差项的自由度和平方和，df_{e_a}、df_{e_b} 分别为裂区设计误差a 和误差b 的自由度，SS_{e_a}、SS_{e_b} 分别为误差a 和误差b 的平方和。而其余各个变异项目的自由度和平方和皆与随机区组设计相同。由此说明，裂区试验和二因素随机区组试验在变异来源上的区别为：前者有误差项的再分解。这是由裂区设计的每一个主区都包括一套副处理的特点决定的。

具体计算时，裂区试验需以副区为基本单位。另外，在多重比较时，还需注意裂区试验中有以下 4 类平均数差数的比较，其差数标准误的计算也不同。以 LSD 法为例进行说明。

(1) 主区因子两水平平均数差数标准误 $s_{\bar{a}_1-\bar{a}_2}$ 为

$$
s_{\bar{a}_1-\bar{a}_2} = \sqrt{\frac{2s_{e_a}^2}{bn}} \tag{9.18}
$$

(2) 副区因子两水平平均数差数标准误 $s_{\bar{b}_1-\bar{b}_2}$ 为

$$
s_{\bar{b}_1-\bar{b}_2} = \sqrt{\frac{2s_{e_b}^2}{an}} \tag{9.19}
$$

(3) 同一主区因子水平的两个副区因子水平平均数差数标准误 $s_{\overline{a_ib_1}-\overline{a_ib_2}}$ 为

$$s_{\overline{a_ib_1}-\overline{a_ib_2}}=\sqrt{\frac{2s_{e_b}^2}{n}} \tag{9.20}$$

(4) 同一副区因子水平的两个主区因子水平平均数差数标准误 $s_{\overline{a_1b_j}-\overline{a_2b_j}}$ 为

$$s_{\overline{a_1b_j}-\overline{a_2b_j}}=\sqrt{\frac{2[(b-1)s_{e_b}^2+s_{e_a}^2]}{bn}} \tag{9.21}$$

前 3 种情况下 t 检验的方法为 $t=\dfrac{\bar{x}_1-\bar{x}_2}{s_{\bar{x}_1-\bar{x}_2}}$，需要解释的是最后一种比较包括 $s_{e_a}^2$ 和 $s_{e_b}^2$ 两种误差，因为这两种误差并不相等，需采取加权方法来计算。因此进行 t 检验时也应对 df_{e_a} 下的 t 值 t_a 与 df_{e_b} 下的 t 值 t_b 加权，于是有

$$t=\frac{(b-1)s_{e_b}^2t_b+s_{e_a}^2t_a}{(b-1)s_{e_b}^2+s_{e_a}^2} \tag{9.22}$$

下面以具体实例对裂区设计试验的统计分析进行介绍。

【例 9.5】 有一个甜菜试验，研究绿肥耕翻时期(A 因素)与施用氮肥量(B 因素)对甜菜产量的影响。采用二裂式裂区设计，A 因素(绿肥翻耕时期)分为早、晚两个水平(A_1、A_2)，置于主区。B 因素(氮肥施用量)分为 4 个水平(B_1、B_2、B_3、B_4)，置于副区。主区、副区均采用随机区组设计，主区重复 3 次，田间种植如图 9-7 所示。小区产量(kg)数据列于表 9-17，试作方差分析。

Ⅰ				Ⅱ				Ⅲ							
A_2				A_1				A_1				A_2			
B_4	B_3	B_1	B_2	B_2	B_4	B_1	B_3	B_1	B_4	B_3	B_2	B_3	B_1	B_4	B_2

Ⅲ							
A_2				A_1			
B_4	B_1	B_2	B_3	B_3	B_4	B_2	B_1

图 9-7　甜菜绿肥耕翻时期与氮肥施用量裂区试验设计方案

表 9-17　甜菜绿肥耕翻时期与氮肥施用量裂区试验区组和处理两向表

主区因子(A)	副区因子(B)	区组			T_t	$\bar{x}_t$
		Ⅰ	Ⅱ	Ⅲ		
A_1	B_1	13.8	13.5	13.2	40.5	13.5
	B_2	15.5	15.0	15.2	45.7	15.2
	B_3	21.0	22.7	22.3	66.0	22.0
	B_4	18.9	18.3	19.6	56.8	18.9
	T_m	69.2	69.5	70.3	$T_{A_1}=209.0$	$\bar{x}_{A_1}=17.4$
A_2	B_1	19.3	18.0	20.5	57.8	19.3
	B_2	22.2	24.2	25.4	71.8	23.9
	B_3	25.3	24.8	28.4	78.5	26.2
	B_4	25.9	26.7	27.6	80.2	26.7
	T_m	92.7	93.7	101.9	$T_{A_2}=288.3$	$\bar{x}_{A_2}=24.0$
T_r		161.9	163.2	172.2	$T=497.3$	

(1) 结果整理：首先将试验资料整理成表 9-17，并进一步按 A 因素和 B 因素作两向分类，整理成表 9-18。

表 9-18　表 9-17 资料主区因素与副区因素两向表

	B	B_1	B_2	B_3	B_4	T_A	$\bar{x}_A$
A	A_1	40.5	45.7	66.0	56.8	209.0	17.4
	A_2	57.8	71.8	78.5	80.2	288.3	24.0
	T_B	98.3	117.5	144.5	137.0	$T=497.3$	
	$\bar{x}_B$	16.4	19.6	24.1	22.8		$\bar{x}=20.7$

表 9-17 和表 9-18 中，T_r 为各区组总和，T_t 为各处理总和，T_A 为 A 因素各水平总和，T_B 为 B 因素各水平总和，T_m 为各主区总和，T 为全试验总和，$\bar{x}_A$、$\bar{x}_B$、$\bar{x}_t$、$\bar{x}$ 分别为主区、副区、处理、全试验平均值。

(2) 平方和与自由度的分解：根据表 9-16，将各项变异来源的自由度直接填入表 9-19 中。以下为平方和的分解：

$$C=\frac{T^2}{abn}=\frac{497.3^2}{2\times4\times3}=10304.47$$

$$SS_T=\sum x^2-C=13.8^2+13.5^2+\cdots+27.6^2-10304.47$$
$$=10820.59-10304.47=516.12$$

$$SS_m=\frac{1}{b}\sum T_m^2-C=\frac{1}{4}\times(69.2^2+69.5^2+\cdots+101.9^2)-10304.47$$
$$=10579.39-10304.47=274.92$$

$$SS_A=\frac{1}{bn}\sum T_A^2-C=\frac{1}{4\times3}\times(209.0^2+288.3^2)-10304.47$$
$$=10566.49-10304.47=262.02$$

$$SS_r=\frac{1}{ab}\sum T_r^2-C=\frac{1}{2\times4}\times(161.9^2+163.2^2+172.2^2)-10304.47$$
$$=10312.34-10304.47=7.87$$

$$SS_{e_a}=SS_m-SS_A-SS_r=274.92-262.02-7.87=5.03$$

$$SS_t=\frac{1}{n}\sum T_t^2-C=\frac{1}{3}\times(40.5^2+45.7^2+\cdots+80.2^2)-10304.47$$
$$=10800.45-10304.47=495.98$$

$$SS_B=\frac{1}{an}\sum T_B^2-C=\frac{1}{2\times3}\times(98.3^2+117.5^2+\cdots+137^2)-10304.47$$
$$=10519.73-10304.47=215.26$$

$$SS_{AB}=SS_t-SS_A-SS_B$$
$$=495.98-262.02-215.26=18.70$$

$$SS_{e_b}=SS_T-SS_r-SS_t-SS_{e_a}$$
$$=516.12-7.87-495.98-5.03=7.24$$

表 9-19　甜菜绿肥耕翻时期与氮肥施用量裂区试验方差分析表

	变异来源	df	SS	s^2	F	$F_{0.05}$	$F_{0.01}$
主区部分	区组	2	7.87	3.94	1.56	19.00	99.00
	耕翻时期(A)	1	262.02	262.02	103.98**	18.51	98.49
	主区误差 e_a	2	5.03	2.52			
副区部分	氮肥用量(B)	3	215.26	71.75	119.58**	3.49	5.95
	$A\times B$	3	18.70	6.23	10.38**	3.49	5.95
	副区误差 e_b	12	7.24	0.60			
	总变异	23	516.12				

(3) 列方差分析表,进行 F 检验:按变异来源将上述计算结果填入表 9-19。

表 9-19 中,e_a 为主区误差,用以检验区组间和主处理(A)方差的显著性;e_b 为副区误差,用以检验副处理(B)和 $A\times B$ 互作方差的显著性。表 9-19 中 F 检验结果表明:① 区组间差异不显著,说明本试验区组的设置未能很好地控制试验误差;② 不同绿肥耕翻时期之间有极显著差异;③ 不同施氮量间有极显著差异;④ 不同施氮量的作用因前茬绿肥耕翻时期而异,即前茬绿肥耕翻时期与氮肥施用量互作对甜菜的产量有极显著的影响。

(4) 多重比较:对 F 检验达显著的效应,还必须分别进行各效应产量平均数间差异显著性检验,即进行多重比较。

a. 不同绿肥耕翻时期(A)间比较。因为只有两个水平,因此不必进行多重比较。F 检验表明,晚耕翻($\bar{x}_{A_2}=24.0$kg)极显著优于早耕翻($\bar{x}_{A_1}=17.4$kg)。

b. 施氮量(B)间比较,以不同施氮量小区产量平均值进行 LSD 检验:

$$s_{\bar{b}_1-\bar{b}_2}=\sqrt{\frac{2s_{e_b}^2}{an}}=\sqrt{\frac{2\times 0.60}{2\times 3}}=0.447(\text{kg})$$

查 t 值表,当自由度 $df_{e_b}=12$ 时,$t_{0.05}=2.179$,$t_{0.01}=3.056$,故:

$$LSD_{0.05}=t_{0.05}\times s_{\bar{b}_1-\bar{b}_2}=2.179\times 0.447=0.97(\text{kg})$$

$$LSD_{0.01}=t_{0.01}\times s_{\bar{b}_1-\bar{b}_2}=3.056\times 0.447=1.37(\text{kg})$$

由此对各氮肥施用量小区平均产量进行显著性检验,结果列于表 9-20。

表 9-20　4 种施氮量甜菜小区产量平均值及其差异显著性(LSD 法)

氮肥施用量	小区产量 ($\bar{x}_{B_i}$)	差异显著性	
		$\alpha=0.05$	$\alpha=0.01$
B_3	24.1	a	A
B_4	22.8	b	A
B_2	19.6	c	B
B_1	16.4	d	C

检验结果表明,各施氮量之间除 B_3 与 B_4 达到显著差异外,其他均存在着极显著的差异。其中以 B_3 为最好,其次是 B_4,再次是 B_2,B_1 效果最差。

c. 绿肥耕翻时期×氮肥施用量互作的比较。同一绿肥耕翻时期内不同施氮水平的比较,该项比较的平均数差数标准误为

$$s_{\overline{a_ib_1}-\overline{a_ib_2}}=\sqrt{\frac{2s_{e_b}^2}{n}}=\sqrt{\frac{2\times 0.60}{3}}=0.632(\text{kg})$$

查附表 3，当自由度 $df_{e_b}=12$ 时，$t_{0.05}=2.179$、$t_{0.01}=3.056$，故：

$$LSD_{0.05}=2.179\times 0.632=1.38(\text{kg})$$

$$LSD_{0.01}=3.056\times 0.632=1.93(\text{kg})$$

由此对绿肥耕翻时期与氮肥施用量互作的小区平均产量进行显著性检验，结果列于表 9-21。

因此，绿肥早耕翻以 B_3 施氮量的增产效果为最佳，晚耕翻以 B_3 和 B_4 施氮量的增产效果为最佳。若把表 9-21 左右两部分综合起来看，显然最合适的措施是晚耕翻绿肥再加上施氮量 B_4、B_3 的增产效果为最好。

表 9-21　不同绿肥耕翻时期条件下施氮量的差异显著性（*LSD* 法）

A_1（早耕翻）				A_2（晚耕翻）			
施氮量	产量	差异显著性		施氮量	产量	差异显著性	
	($\bar{x}_{t_i}$)	$\alpha=0.05$	$\alpha=0.01$		($\bar{x}_{t_i}$)	$\alpha=0.05$	$\alpha=0.01$
B_3	22.0	a	A	B_4	26.7	a	A
B_4	18.9	b	B	B_3	26.2	a	A
B_2	15.2	c	C	B_2	23.9	b	B
B_1	13.5	d	C	B_1	19.3	c	C

同一施氮量水平下不同绿肥耕翻时期效应的比较：A_1B_1 与 A_2B_1、A_1B_2 与 A_2B_2、A_1B_3 与 A_2B_3 及 A_1B_4 与 A_2B_4 的比较属此类。其平均数差数标准误为：

$$s_{\overline{a_1b_j}-\overline{a_2b_j}}=\sqrt{\frac{2[(b-1)s_{e_b}^2+s_{e_a}^2]}{bn}}=\sqrt{\frac{2\times[(4-1)\times 0.60+2.52]}{4\times 3}}=0.849$$

查附表 3，当自由度 $df_{e_a}=2$ 时，$t_{0.05}=4.303$、$t_{0.01}=9.925$；当自由度 $df_{e_b}=12$ 时，$t_{0.05}=2.179$、$t_{0.01}=3.056$，于是有：

$$t_{0.05}=\frac{(b-1)s_{e_b}^2t_b+s_{e_a}^2t_a}{(b-1)s_{e_b}^2+s_{e_a}^2}=\frac{(4-1)\times 0.60\times 2.179+2.52\times 4.303}{(4-1)\times 0.60+2.52}$$

$$=\frac{14.766}{4.32}=3.418$$

$$t_{0.01}=\frac{(b-1)s_{e_b}^2t_b+s_{e_a}^2t_a}{(b-1)s_{e_b}^2+s_{e_a}^2}=\frac{(4-1)\times 0.60\times 3.056+2.52\times 9.925}{(4-1)\times 0.60+2.52}$$

$$=\frac{30.512}{4.32}=7.063$$

$$LSD_{0.05}=3.418\times 0.849=2.902(\text{kg})$$

$$LSD_{0.01}=7.063\times 0.849=5.996(\text{kg})$$

同一施氮量水平下不同绿肥耕翻时期效应比较列于表 9-22。结果表明，在施氮量 B_1、B_3 水平下，绿肥的两种耕翻时期间有显著差异；在施氮量 B_2、B_4 水平下，绿肥的两种耕翻时期间有极显著差异。

表 9-22　同一施氮量下不同绿肥耕翻时期的差异显著性(LSD 法)

施氮量	绿肥耕翻期平均值 /kg		$\bar{x}_{tA_1}-\bar{x}_{tA_2}$
	早耕翻 $\bar{x}_{tA_1}$	晚耕翻 $\bar{x}_{tA_2}$	
B_1	13.5	19.3	5.8*
B_2	15.2	23.9	8.7**
B_3	22.0	26.2	4.2*
B_4	18.9	26.7	7.8**

(5) 结论:本试验中,绿肥晚耕翻的增产效果优于早耕翻;施氮量以 B_3 效果最好;在晚耕翻条件下,以施氮量 B_3 和 B_4 产量最高;甜菜增产的最优处理组合为 A_2B_3 或 A_2B_4,即绿肥晚耕翻+施氮量 B_3 或绿肥晚耕翻+施氮量 B_4 处理为最优的处理组合。

第六节　正交设计及其统计分析

正交设计(orthogonal design)是一种研究多因素试验的设计方法。在多因素试验中,随着试验因素和水平数的增加,处理组合数急剧增加。例如,3 因素 3 水平的试验,有 $3^3=27$ 个处理组合;3 因素 4 水平的试验,有 $4^3=64$ 个处理组合。要全面实施这么庞大的试验是相当困难的。因而,D. J. Finney 倡议了部分试验法。而后日本学者倡导利用正交式设计部分试验,称为正交试验。

正交试验是利用一套规格化的表格——正交表(orthogonal table)来科学合理地安排试验的设计方法。这种设计的特点是在全部试验处理组合中,挑选部分有代表性的水平组合(处理组合)进行试验。通过部分实施了解全面试验情况,从中找出较优的处理组合。这样可以大大节省人、财、物和时间,使一些难以实施的多因素试验得以实施。例如,要进行一个 4 因素 3 水平的多因素试验,如果全面实施则需要 $3^4=81$ 个处理组合,在试验中因规模太大而难以实施。但是,如果采用一张 $L_9(3^4)$ 的正交表安排试验,则只要 9 个处理组合就够了。

一、正交表及其特点

正交表是正交设计的基本工具。在正交设计中,安排试验、分析结果,均在正交表上进行。常用的正交表,已由数学工作者制定出来(附表 10),试验时只要根据试验条件直接套用就行了,不需要另行编制。

现以 $L_9(3^4)$ 正交表为例,说明正交表的概念与特点。L 表示一张正交表,括号内下面的 3 表示因素的水平数,3 的右上方为指数 4,表示最多可以安排因素(包括互作)的个数。L 右下角的数字 9 表示试验次数(水平组合数)。总起来说,$L_9(3^4)$ 的意思是,用这张表进行试验设计,最多可以安排 4 个因素,每个因素取 3 个水平,一共做 9 次试验。$L_9(3^4)$ 的正交表列于表 9-23,并在右侧一列具体列出了需做的各个水平组合。

表 9-23　$L_9(3^4)$正交表

列号		A	B	C	D	水平组合
		1	2	3	4	
试验号	1	1	1	1	1	$A_1B_1C_1D_1$
	2	1	2	2	2	$A_1B_2C_2D_2$
	3	1	3	3	3	$A_1B_3C_3D_3$
	4	2	1	2	3	$A_2B_1C_2D_3$
	5	2	2	3	1	$A_2B_2C_3D_1$
	6	2	3	1	2	$A_2B_3C_1D_2$
	7	3	1	3	2	$A_3B_1C_3D_2$
	8	3	2	1	3	$A_3B_2C_1D_3$
	9	3	3	2	1	$A_3B_3C_2D_1$

此表共有 4 列，允许安排 4 个因素；每一列都有 1、2、3 三种数字，代表各因素的 3 个水平；表中有 9 个横行，代表 9 个不同处理组合(treatment unit)。$L_9(3^4)$正交表有以下两个性质。

(1) 每一列中，不同数字出现的次数相等，这里不同数字只有 3 个：1、2、3，它们在每列中各出现 3 次。

(2) 任两列中，将同一横行的两个数字看成有序数对时，每一个有序数对出现的次数相等。这里有序数对共有 9 种：(1,1)、(1,2)、(1,3)、(2,1)、(2,2)、(2,3)、(3,1)、(3,2)、(3,3)，它们各出现一次，也就是说每个因素的每一水平与另一个因素的各个水平各碰到一次，也仅碰到一次，表明任何两因素的搭配是均衡的。

由于正交表具有的这两个特点，用正交表进行试验安排具有以下两个特性。

(1) 均衡分散性：正交表挑出来的这部分水平组合，在全部可能的水平组合中分布均匀，因此代表性强，能较好地反映全面情况。例如，设有一个 3 因素 3 水平试验，则若做全面试验为 $3^3=27$ 次，它们的水平组合为

$$A_1B_1\begin{cases}C_1 & ①\\ C_2\\ C_3\end{cases}\qquad A_2B_1\begin{cases}C_1\\ C_2 & ④\\ C_3\end{cases}\qquad A_3B_1\begin{cases}C_1\\ C_2\\ C_3 & ⑦\end{cases}$$

$$A_1B_2\begin{cases}C_1\\ C_2 & ②\\ C_3\end{cases}\qquad A_2B_2\begin{cases}C_1\\ C_2\\ C_3 & ⑤\end{cases}\qquad A_3B_2\begin{cases}C_1 & ⑧\\ C_2\\ C_3\end{cases}$$

$$A_1B_3\begin{cases}C_1\\ C_2\\ C_3 & ③\end{cases}\qquad A_2B_3\begin{cases}C_1 & ⑥\\ C_2\\ C_3\end{cases}\qquad A_3B_3\begin{cases}C_1\\ C_2 & ⑨\\ C_3\end{cases}$$

若选用$L_9(3^4)$正交表，用①、②、…、⑨表示的 9 个水平组合就是表 9-23 中正交表所选出的试验号。显然，它们非常均衡地分散在全面试验的 27 个试验组合之中。

(2)整齐可比性：由于正交表中各因素的水平是两两正交的，任一因素任一水平下都必须均衡地包含着其他因素的各水平。例如，A_1、A_2、A_3 条件下各有 3 种 B 水平、3 种 C 水平，即

$$A_1\begin{cases}B_1C_1\\B_2C_2\\B_3C_3\end{cases}\qquad A_2\begin{cases}B_1C_2\\B_2C_3\\B_3C_1\end{cases}\qquad A_3\begin{cases}B_1C_3\\B_2C_1\\B_3C_2\end{cases}$$

所以，当比较 A_1、A_2 和 A_3 时，其余两个因素的效应都彼此抵消，余下的只有 A 效应和试验误差，此时 3 组的区别仅在于 A 的水平不同，因此这 3 个水平组就具有明显的可比性。在比较 B_1、B_2、B_3 或 C_1、C_2、C_3 时也是同样情况。

常用正交表中，适用于 2 水平试验的有 $L_4(2^3)$、$L_8(2^7)$，适用于 3 水平试验的有 $L_9(3^4)$、$L_{27}(3^{13})$ 等，还有适用于 4 水平、5 水平及水平数不等的正交表，供设计时选用。

二、正交试验的基本方法

正交试验的安排、分析均是借助于正交表进行的。利用正交表安排试验，一般可分以下几个步骤。

(一) 确定试验因素数和水平数

根据试验目的确定试验要研究的因素。生物体的生长发育会涉及较多的影响因素。生物学试验中，如果对研究的问题了解较少，可多选一些因素；对研究的问题了解较多，可少选一些因素，抓住主要因素进行研究。因素选好后定水平，每个因素的水平可以相等，也可以不等，重要的或需要详细了解的因素，水平可适当多一些，而对另一些需要相对粗放了解的因素，水平可适当少一些。

【例 9.6】 为解决花菜留种问题，进一步提高花菜种子的产量和质量，科技人员考察了浇水、施肥、病害防治和移入温室时间对花菜留种的影响，进行了一个 4 因素 2 水平的正交试验。各因素及其水平见表 9-24。

表 9-24　花菜留种正交试验的因素与水平表

因素	水平 1	水平 2
A：浇水次数	不干死为原则，整个生长期只浇 1 次或 2 次水	根据生长需水量和自然条件浇水，但不过湿
B：喷药次数	发现病害即喷药	每半月喷一次
C：施肥次数	开花期施硫酸铵	进室发根期、抽薹期、开花期和结实期各施肥一次
D：进室时间	11 月初	11 月 15 日

(二) 选用合适的正交表

进行正交设计时，需根据试验因素和水平数以及是否需要估计因素间的互作来选择合适的正交表。其基本的原则是：所选的正交表既要能安排下全部试验因素，又要使部分试验的水平组合数尽可能少。在正交试验中，各因素的水平数减 1 之和加 1，即为所需的最少试验次数或处理组合数；如果考虑试验因素间的交互作用，需要再加上交互作用的自由度。对于上述 4 因素 2 水平试验，最少的试验次数，即处理组合数 $=(2-1)\times4+1=5$，然后从 2^n 因素正交表中选用处理组合数稍多于 5 的正交表安排试验，因此，选用 $L_8(2^7)$ 正交表比较合适。

例如，某制药厂进行了提高抗生素发酵单位的试验，设有 8 个试验因素，各设 3 个水平。如果采用正交设计试验，并考虑 $A\times B$、$A\times C$ 互作效应，则最少需要做的试验次数 $=(3-1)\times 8+(3-1)\times(3-1)\times 2+1=25$，因此应选用 $L_{27}(3^{13})$ 正交表安排试验。

对于各因素水平数不相等的试验，处理组合数也依照上述原则确定。例如，要进行一个 $4^1(A)\times 2^3(B、C、D)$ 的多因素试验，全面实施的处理组合数为 $4^1\times 2^3=32$ 次。若采用正交设计，最少的试验次数为 $(4-1)+(2-1)\times 3+1=7$，若考虑 $A\times B$、$A\times C$ 互作，则最少的试验数为：$(4-1)+(2-1)\times 3+(4-1)\times(2-1)\times 2+1=13$，因而选用 $L_{16}(4^1\times 2^{12})$ 正交表安排试验比较合适。

（三）进行表头设计，列出试验方案

所谓表头设计（table heading design），就是把试验中确定研究的各因素填到正交表的表头各列。表头设计原则如下所述。① 不要让主效应间、主效应与交互作用间有混杂现象。由于正交表中一般都有交互列，因此当因素数少于列数时，尽量不在交互列中安排试验因素，以防发生混杂。② 当存在交互作用时，需查交互作用表，将交互作用安排在合适的列上。例如，例 9.6 所述的花菜留种试验，若只考虑 $A\times B$ 和 $A\times C$ 互作，可选用 $L_8(2^7)$ 正交表，其表头设计见表 9-25。

表 9-25　花菜留种正交试验的表头设计

列号	1	2	3	4	5	6	7
因素	A	B	$A\times B$	C	$A\times C$		D

表头设计好后，把该正交表 $L_8(2^7)$ 中各列水平号换成各试验因素的具体水平就成为试验方案。例如，第 1 列放 A 因素（浇水次数），就把第 1 列中数字 1 都换成 A 的第一水平（浇水 1 次或 2 次），数字 2 都换成 A 的第二水平（需要就浇），余类推。该正交试验方案列于表 9-26。

表 9-26　花菜留种的正交试验方案

试验号（处理组合）	1 列：浇水次数（A）	2 列：喷药次数（B）	4 列：施肥方法（C）	7 列：进室时间（D）
1	1　浇水 1 次或 2 次	1　发病喷药	1　开花施	1　11 月初
2	1　浇水 1 次或 2 次	1　发病喷药	2　施 4 次	2　11 月 15 日
3	1　浇水 1 次或 2 次	2　半月喷药 1 次	1　开花施	2　11 月 15 日
4	1　浇水 1 次或 2 次	2　半月喷药 1 次	2　施 4 次	1　11 月初
5	2　需要就浇	1　发病喷药	1　开花施	2　11 月 15 日
6	2　需要就浇	1　发病喷药	2　施 4 次	1　11 月初
7	2　需要就浇	2　半月喷药 1 次	1　开花施	1　11 月初
8	2　需要就浇	2　半月喷药 1 次	2　施 4 次	2　11 月 15 日

（四）试验

正交试验方案做出后，就可按试验方案进行试验。如果选用的正交表较小，各列都被

安排了试验因素，对试验结果进行方差分析时，无法估算试验误差，若选用较大的正交表，则试验的处理组合数会急剧增加。为了解决这个问题，可采用重复试验或重复抽样的方法解决这一问题。重复抽样不同于重复试验，重复抽样是从同一次试验中抽取几个样品进行观测或测试，结果每个处理组合就可得到几个数据。

三、正交设计试验结果的统计分析

正交试验结果可进行直观分析(visual analysis)和方差分析。这两种方法各有所长，现分述如下。

(一) 正交试验结果的直观分析

【例 9.7】 将例 9.6 花菜留种的正交试验结果列于表 9-27，试进行直观分析。

表 9-27　花菜留种正交试验结果的直观分析

试验号＼列号(水平)	A	B	$A\times B$	C	$A\times C$	D	种子产量/(g/10m²)
	1	2	3	4	5	7	
1	1	1	1	1	1	1	350
2	1	1	1	2	2	2	325
3	1	2	2	1	1	2	425
4	1	2	2	2	2	1	425
5	2	1	2	1	2	2	200
6	2	1	2	2	1	1	250
7	2	2	1	1	2	1	275
8	2	2	1	2	1	2	375
T_1	1525	1125	1325	1250	1400	1300	$T=2625$
T_2	1100	1500	1300	1375	1225	1325	
$\bar{x}_1$	381.25	281.25	331.25	312.50	350.00	325.00	
$\bar{x}_2$	275.00	375.00	325.00	343.75	306.25	331.25	
R	106.25	−93.75	6.25	−31.25	43.75	−6.25	

(1) 逐列计算各因素同一水平之和。第 1 列 A 因素各水平之和：

$$T_1=350+325+425+425=1525$$

$$T_2=200+250+275+375=1100$$

第 2 列 B 因素各水平之和：

$$T_1=350+325+200+250=1125$$

$$T_2=425+425+275+375=1500$$

同样可求其他因素各水平之和(结果列于表 9-27)。

(2) 逐列计算各水平的平均数。

第 1 列 A 因素各水平的平均数分别为

$$\bar{x}_1=\frac{T_1}{\frac{n}{2}}=\frac{1525}{\frac{8}{2}}=381.25(\text{g}/10\text{m}^2)$$

$$\bar{x}_2=\frac{T_2}{\frac{n}{2}}=\frac{1100}{\frac{8}{2}}=275.00(\mathrm{g/10m^2})$$

第 2 列 B 因素各水平的平均数分别为

$$\bar{x}_1=\frac{T_1}{\frac{n}{2}}=\frac{1125}{\frac{8}{2}}=281.25(\mathrm{g/10m^2})$$

$$\bar{x}_2=\frac{T_2}{\frac{n}{2}}=\frac{1500}{\frac{8}{2}}=375.00(\mathrm{g/10m^2})$$

同理可计算第 3、4、5、7 列各水平的平均数(表 9-27)。

(3) 逐列计算各水平平均数的差值。

第 1 列 A 因子各水平平均数的差值为

$$R=\bar{x}_1-\bar{x}_2=381.25-275.00=106.25(\mathrm{g/10m^2})$$

第 2 列 B 因子各水平平均数的差值为

$$R=\bar{x}_1-\bar{x}_2=281.25-375.00=-93.75(\mathrm{g/10m^2})$$

同理可计算出第 3、4、5、7 列各水平平均数的差值(表 9-27)。

(4) 比较差值,确定各因子或交互作用对结果的影响。从表 9-27 可以看出,浇水次数(A)和喷药次数(B)的差值 $|R|$ 分居第一、二位,是影响花菜种子产量的关键性因子,其次是 $A\times C$ 互作和施肥方法(C),进室时间(D)和 $A\times B$ 互作影响较小。

(5) 水平选优与组合选优。根据各试验因子的总和或平均数可以看出:A 取 A_1、B 取 B_2、C 取 C_2、D 取 D_2 为好,即花菜留种最好的栽培管理方式为:$A_1B_2C_2D_2$。但由于 $A\times C$ 对产量影响较大,所以花菜留种条件还不能这样选取。而 A 和 C 究竟选哪个水平,应根据 A 与 C 的最好组合来确定。所以还要对 $A\times C$ 的交互作用进行分析。$A\times C$ 交互作用的直观分析是求 A 与 C 形成的处理组合平均数:

$$A_1C_1:\quad\frac{350+425}{2}=387.5(\mathrm{g/10m^2})$$

$$A_1C_2:\quad\frac{325+425}{2}=375.0(\mathrm{g/10m^2})$$

$$A_2C_1:\quad\frac{200+275}{2}=237.5(\mathrm{g/10m^2})$$

$$A_2C_2:\quad\frac{250+375}{2}=312.5(\mathrm{g/10m^2})$$

由此可知,A_1 与 C_1 水平配合时花菜种子产量最高。因此,在考虑 $A\times C$ 交互作用的情况下,花菜留种的最适条件应为 $A_1B_2C_1D_2$。它正是 3 号处理组合,也是 8 个处理组合中产量最高者。但 4 号处理组合与 3 号处理组合产量一样,二者有无差异,尚需方差分析。若选出的处理组合不在试验中,还需要再进行一次试验,以确定选出的处理组合是否最优。

(二) 正交试验结果的方差分析

(1) 平方和与自由度的分解。在方差分析的平方和计算中,若一个因素只有两个水

平，其平方和 $SS=\dfrac{(T_1-T_2)^2}{n}$，$T_1$ 和 T_2 为两个水平各自的总和，n 为整个试验的数据总个数，在例 9.7 中 $n=8$。所以：

$$C=\frac{T^2}{n}=\frac{2625^2}{8}=861328.125$$

$$SS_T=\sum x^2-C=(350^2+325^2+\cdots+375^2)-861328.12=46796.875$$

$$SS_A=\frac{(1525-1100)^2}{8}=22578.125$$

$$SS_B=\frac{(1125-1500)^2}{8}=17578.125$$

$$SS_C=\frac{(1250-1375)^2}{8}=1953.125$$

$$SS_D=\frac{(1300-1325)^2}{8}=78.125$$

$$SS_{AB}=\frac{(1325-1300)^2}{8}=78.125$$

$$SS_{AC}=\frac{(1400-1225)^2}{8}=3828.125$$

$$\begin{aligned}SS_e&=SS_T-SS_A-SS_B-SS_C-SS_D-SS_{AB}-SS_{AC}\\&=46796.875-22578.125-17578.125-1953.125-78.125-78.125-3828.125\\&=703.125\end{aligned}$$

$$df_T=8-1=7$$

$$df_A=df_B=df_C=df_D=df_{AB}=df_{AC}=2-1=1$$

$$\begin{aligned}df_e&=df_T-df_A-df_B-df_C-df_D-df_{AB}-df_{AC}\\&=7-1-1-1-1-1-1=1\end{aligned}$$

(2) 列方差分析表进行 F 检验：从表 9-28 可以看出，各项变异来源的 F 值均不显著，其主要原因是误差项自由度偏小。解决这个问题的根本办法是增加试验的重复数，也可以将 F 值小于 1 的变异项(即 D 因素和 $A\times B$ 互作)的平方和与自由度与误差项的平方和与自由

表 9-28　花菜留种正交试验结果方差分析

变异来源	df	SS	s^2	F	$F_{0.05}$	$F_{0.01}$
浇水次数(A)	1	22578.125	22578.125	32.11	161	405
喷药次数(B)	1	17578.125	17578.125	25.00	161	405
施肥方法(C)	1	1953.125	1953.125	2.78	161	405
进室时间(D)	1	78.125	78.125	<1	161	405
$A\times B$	1	78.125	78.125	<1	161	405
$A\times C$	1	3828.125	3828.125	5.44	161	405
试验误差	1	703.125	703.125			
总变异	7	46796.875				

度合并，作为误差项平方和的估计值(SS'_e)，这样既可以增加试验误差的自由度(df'_e)，又可以减少误差项的方差，从而提高假设检验的灵敏度。合并后的误差项平方和为

$$SS'_e = SS_e + SS_D + SS_{AB} = 703.125 + 78.125 + 78.125 = 859.375$$

而自由度为 3，合并后的方差分析结果列入表 9-29。

表 9-29　花菜留种正交试验的方差分析(去掉 $F<1$ 因子后)

变异来源	df	SS	s^2	F	$F_{0.05}$	$F_{0.01}$
浇水次数(A)	1	22578.125	22578.125	78.82**	10.13	34.12
喷药次数(B)	1	17578.125	17578.125	61.36**	10.13	34.12
施肥方法(C)	1	1953.125	1953.125	6.82	10.13	34.12
$A\times C$	1	3828.125	3828.125	13.36*	10.13	34.12
试验误差	3	859.375	286.458			
总变异	7	46796.875				

由表 9-29 可知，浇水次数(A)、喷药次数(B)的 F 值均达极显著水平；$A\times C$ 互作的 F 值达显著水平。可见，假设检验的灵敏度明显提高。

(3) 互作分析与处理组合选优：由于浇水次数(A)极显著、施肥方法(C)不显著、$A\times C$ 显著，所以浇水次数(A)和施肥方法(C)的最优水平应根据 $A\times C$ 而定，即在 A_1 确定为最优水平后，在 A_1 水平上比较 C_1 和 C_2，确定施肥方法(C)的最优水平。

$$A_1C_1 \text{ 的平均数为：}\frac{350+425}{2}=387.5(\text{g}/10\text{m}^2)$$

$$A_1C_2 \text{ 的平均数为：}\frac{325+425}{2}=375.0(\text{g}/10\text{m}^2)$$

因此，施肥方法(C)取 C_1 水平较好；喷药次数(B)取 B_2 较好；进室时间(D)水平间差异不显著，取哪一个水平都行，所以最优处理组合为：$A_1B_2C_1D_1$ 或 $A_1B_2C_1D_2$。

思考练习题

习题 9.1　何谓试验设计？生物学试验的基本要求是什么？

习题 9.2　试验误差的来源有哪些，如何进行控制？

习题 9.3　试验设计的基本原则和各项原则的作用是什么？

习题 9.4　本章讲述的常用试验设计有哪几种？这些方法各适宜在什么情况下使用？

习题 9.5　正交表与正交试验的特点分别是什么？

习题 9.6　用对比设计进行大豆品种比较试验，产量(kg/100m²)结果如下表所示，试作统计分析。

品种	CK	A	B	CK	C	D	CK	E	F	CK
Ⅰ	20.3	20.1	19.0	15.7	20.7	21.6	17.8	20.7	17.3	19.1
Ⅱ	20.0	18.4	20.0	16.8	17.8	18.1	16.4	14.9	14.9	16.2
Ⅲ	16.8	17.3	17.0	14.7	16.9	15.6	13.9	12.8	18.6	14.8

习题 9.7　下表为某养殖场使用 4 种不同饲料饲喂猪的增重(kg)结果。试作统计分析。

窝组	A	B	C	D	T_r
Ⅰ	14	14	16	15	59
Ⅱ	16	15	14	12	57
Ⅲ	16	12	15	12	55
Ⅳ	15	13	14	13	55
Ⅴ	15	14	15	13	57
T_t	76	68	74	65	$T = 283$

习题 9.8　为了研究 5 种不同温度对蛋鸡产蛋量的影响，将 5 栋鸡舍的温度设为 A、B、C、D、E，把各栋鸡舍的鸡群产蛋期分为 5 期，由于各鸡群和产蛋期的不同对产蛋量(枚)有较大的影响，因此采用拉丁方设计，把鸡群和产蛋期作为单位组设置，得到 5 × 5 拉丁方设计，其试验设计及试验结果如下表所示。表中括号内数值为产蛋量(枚)。试对该资料进行统计分析。

产蛋期	鸡群				
	1	2	3	4	5
Ⅰ	D(23)	E(21)	A(24)	B(21)	C(19)
Ⅱ	A(22)	C(20)	E(20)	D(21)	B(22)
Ⅲ	E(20)	A(25)	B(26)	C(22)	D(23)
Ⅳ	B(25)	D(22)	C(25)	E(21)	A(23)
Ⅴ	C(19)	B(20)	D(24)	A(22)	E(19)

习题 9.9　为了研究湿度和温度对黏虫卵发育历期(d)的影响，用 3 种湿度 4 种温度处理黏虫卵，采用随机区组设计，重复 4 次，结果如下表所示。试进行方差分析。

相对湿度/%	温度/℃	历期/d			
		Ⅰ	Ⅱ	Ⅲ	Ⅳ
100	26	93.2	91.2	90.7	92.2
	28	87.6	85.7	84.2	82.4
	30	79.2	74.5	79.3	70.4
	32	67.7	69.3	67.6	68.1
70	26	89.4	88.7	86.3	88.5
	28	86.4	85.3	86.7	84.2
	30	77.2	76.3	74.5	75.7
	32	70.1	72.1	70.3	69.5
40	26	99.9	99.2	93.3	94.5
	28	91.3	94.6	92.3	91.1
	30	82.7	81.3	84.5	86.8
	32	75.3	74.1	72.3	71.4

习题 9.10　以提取方法为 A 因素、提取浓度为 B 因素进行细胞转化(个 /mm^2)试验，所得植物重量(g)结果如下表所示。试作统计分析。

区组		Ⅰ			Ⅱ			Ⅲ		
提取方法(A)		A_1	A_2	A_3	A_1	A_2	A_3	A_1	A_2	A_3
提取浓度(B)	B_1	43	47	42	41	44	44	44	48	45
	B_2	48	54	39	45	49	43	50	53	54
	B_3	50	51	46	53	55	45	54	52	52
	B_4	49	55	49	54	53	53	53	57	58

习题 9.11　某校在研究利用木霉酶解稻草粉的优良工艺条件时，发现曲种比例、水量多少、pH 大小等因素取不同水平时对稻草粉糖化的质量有很大影响，因此做了 3 因素 3 水平的正交设计试验，其试验设计及结果如下表所示。试用直观分析及方差分析的方法对试验结果进行分析。

试验号	因素			测定指标（酶解得糖率，%）
	A（曲比）	B（水量）	C（pH）	
1	1(3∶7)	1(7)	1(4)	8.89
2	1(3∶7)	2(9)	2(4.5)	7.00
3	1(3∶7)	3(5)	3(5)	7.50
4	2(5∶5)	1(7)	2(4.5)	10.08
5	2(5∶5)	2(9)	3(5)	7.56
6	2(5∶5)	3(5)	1(4)	8.00
7	3(7∶3)	1(7)	3(5)	6.72
8	3(7∶3)	2(9)	1(4)	11.34
9	3(7∶3)	3(5)	2(4.5)	9.50

第十章

协方差分析

本章提要

协方差分析是将方差分析和回归分析结合应用的一种综合统计分析方法，它将乘积和与平方和同时按照变异来源进行分解，利用协变量来降低试验误差，矫正处理平均数，实现统计控制。协方差分析还可分析不同变异来源的相关关系，并对缺失数据进行估计。在满足协变量(x)为固定变量、离回归方差同质、各个处理(x，y)的总体为线性且具有共同的回归系数3个基本假定的基础上，可对单因素、二因素及多因素分组资料进行协方差分析，计算变量各变异来源的平方和、乘积和与自由度，检验x和y之间是否存在直线回归关系，并对矫正后的y值进行差异显著性检验和多重比较。

第六章所介绍的方差分析方法，是对某一种性状的变量进行分析，根据变异来源将总变异的自由度与平方和分解为相应部分的自由度与平方和。但是在方差分析中，常会遇到所分析的变量本身就是一个受到另一个或多个自变量影响的依变量。有时对这些自变量难以进行有效控制，但又要消除其对依变量的影响，以提高试验结果的可靠程度。例如，在动物饲喂试验中，为比较不同饲料对动物增重的影响，应选用初始体重相同(或相近)的动物来进行试验。因为不同初始体重动物的增重速度是不同的，如果选用初始体重有差异的动物来进行试验，则不同动物个体增重的差异除了处理效应(饲料效应)和误差效应外，还受到初始体重差异的影响。这个影响既可能会增大处理间(组间)差异，使不同饲料的差异不能被真正体现，也可能会增大处理内(组内)差异，从而降低检验功效。由于客观条件的限制，有时无法找到足够数量的初始体重相近的动物进行试验，这时可用统计学的方法将这种由于初始体重差异所造成的影响降到最低。此时，如果初始体重对增重的影响可以通过回归分析来度量，可以用回归分析先对初始体重的影响进行矫正，然后再进行方差分析。这种把回归分析与方差分析结合起来的分析方法，就称为协方差分析(analysis of covariance)。

协方差分析用于比较一个变量y在一个或几个因素不同水平上的差异。与方差分析不同的是，y在受这些因素影响的同时，还受到另一个变量x的影响，而且x变量的取值

难以人为控制，不能作为方差分析中的一个因素处理。此时，如果 x 与 y 之间可以建立回归关系，则可用回归分析的方法排除 x 对 y 的影响，然后用方差分析的方法对各因素水平的影响作出统计推断。在协方差分析中，我们称 y 为依变量，x 为协变量(covariate)。由此可见，协方差分析也是用于分析多组均数间的差异有无显著性意义，只是多考虑了一个协变量的因素。

协方差分析可以用于单因素试验资料，也可以用于二因素或多因素试验资料。本章仅介绍单因素和二因素试验资料的协方差分析。

第一节　协方差分析的作用

协方差分析作用主要有以下 3 个方面。

一、降低试验误差，实现统计控制

要提高试验的精确度和灵敏度，必须严格控制试验条件的均匀性，使各处理处于尽可能一致的条件下，这称为试验控制(experimental control)。但是在某些情况下，即使做出很大努力也难使试验控制达到预期要求。例如，研究植物生长调节剂对减少棉花蕾铃脱落的效应，要求各处理的单株有相同的蕾铃数，而这是不易达到的。如果单株蕾铃数(x)和蕾铃脱落率(y)之间存在直线回归关系，则可以利用这种直线回归关系将各处理 y 的观测值都矫正到 x 相同时的结果，使得处理间 y 的比较能够在相同的 x 基础上进行，从而得出正解的结论，实现统计控制(statistical control)。统计控制是试验控制的一种辅助手段，是用统计方法来矫正因自变量的不同而对依变量所产生的影响。经过矫正，使试验误差减小，对试验处理效应的估计更为准确。

二、分析不同变异来源的相关关系

在第七章直线回归与相关一章，已经介绍过相关系数可以表示两个相关变量线性相关的性质与程度。相关系数的计算公式为

$$r=\frac{\sum(x-\bar{x})(y-\bar{y})}{\sqrt{\sum(x-\bar{x})^2\sum(y-\bar{y})^2}}$$

将该式的分子和分母同时除以$(n-1)$，可得

$$r=\frac{\dfrac{\sum(x-\bar{x})(y-\bar{y})}{n-1}}{\sqrt{\dfrac{\sum(x-\bar{x})^2}{n-1}\dfrac{\sum(y-\bar{y})^2}{n-1}}} \tag{10.1}$$

式中，$\dfrac{\sum(x-\bar{x})^2}{n-1}$ 为 x 的均方(mean square)，记作 MS_x，它是变量 x 总体方差 σ_x^2 的无偏估计量；$\dfrac{\sum(y-\bar{y})^2}{n-1}$ 为 y 的均方，记作 MS_y，它是变量 y 总体方差 σ_y^2 的无偏估计量；

$\frac{\sum(x-\bar{x})(y-\bar{y})}{n-1}$ 为 x 与 y 的平均的离均差的乘积和，简称为均积(mean product)，记作 MP_{xy}。

$$MP_{xy}=\frac{\sum(x-\bar{x})(y-\bar{y})}{n-1}=\frac{\sum xy-\frac{\sum x\sum y}{n}}{n-1} \tag{10.2}$$

与均积相应的总体参数称为协方差(covariance)，记作 COV_{xy} 或 σ_{xy}^2。

$$COV_{xy}=\frac{\sum(x-\mu_x)(y-\mu_y)}{N} \tag{10.3}$$

统计学上已经证明均积 MP_{xy} 是总体协方差 COV_{xy} 的无偏估计量。

因此样本相关系数 r 可用均方 MS_x、MS_y 和均积 MP_{xy} 表示：

$$r=\frac{MP_{xy}}{\sqrt{MS_xMS_y}} \tag{10.4}$$

相应的总体相关系数 ρ 可用 x 与 y 的总体方差与总体协方差表示：

$$\rho=\frac{COV_{xy}}{\sqrt{\sigma_x^2\sigma_y^2}}=\frac{COV_{xy}}{\sigma_x\sigma_y} \tag{10.5}$$

在随机模型的方差分析中，根据方差和期望方差的关系，可以得到不同来源的方差组分的估计值。同样，在随机模型的协方差分析中，根据均积和期望均积的关系，可以得到不同变异来源的协方差组分的估计值。有了这些估计值，就可进一步估算出两个变量 x 与 y 之间各个变异来源的相关系数，从而进行相应的总体相关分析。这些分析在遗传、育种、生态和环保等方面的研究上是很有用处的。

三、估计缺失数据

利用方差分析的方法对缺失数据进行估计，是建立在误差平方和最小的基础上的，但处理平方和却向上偏倚。如果用协方差分析的方法估计缺失数据，则既可保证误差平方和最小，又能得到无偏的处理平方和。

第二节　单因素试验资料的协方差分析

由式(10.2)可以看出，均积与均方有相似的形式，同时二者也具有相似的性质。在方差分析中，一个变量的总平方和与自由度可以按照变异来源进行分解，从而求得相应的均方。统计学已证明，两个变量的总乘积和与自由度也可按照变异来源进行分解从而获得相应的均积。

设有 k 组双变量资料，每组样本皆有 n 对(x，y)观测值，那么该资料共有 nk 对观测值，其数据模式如表 10-1 所示。

表 10-1　k 组两个变量资料的数据模式

组别	观测值						总和	平均
1	x_{11}	x_{12}	…	x_{1j}	…	x_{1n}	$T_{x_1\cdot}$	$\bar{x}_{1\cdot}$
	y_{11}	y_{12}	…	y_{1j}	…	y_{1n}	$T_{y_1\cdot}$	$\bar{y}_{1\cdot}$
2	x_{21}	x_{22}	…	x_{2j}	…	x_{2n}	$T_{x_2\cdot}$	$\bar{x}_{2\cdot}$
	y_{21}	y_{22}	…	y_{2j}	…	y_{2n}	$T_{y_2\cdot}$	$\bar{y}_{2\cdot}$
⋮	⋮	⋮		⋮		⋮	⋮	⋮
i	x_{i1}	x_{i2}	…	x_{ij}	…	x_{in}	$T_{x_i\cdot}$	$\bar{x}_{i\cdot}$
	y_{i1}	y_{i2}	…	y_{ij}	…	y_{in}	$T_{y_i\cdot}$	$\bar{y}_{i\cdot}$
⋮	⋮	⋮		⋮		⋮	⋮	⋮
k	x_{k1}	x_{k2}	…	x_{kj}	…	x_{kn}	$T_{x_k\cdot}$	$\bar{x}_{k\cdot}$
	y_{k1}	y_{k2}	…	y_{kj}	…	y_{kn}	$T_{y_k\cdot}$	$\bar{y}_{k\cdot}$
总计							T_x	$\bar{x}$
							T_y	$\bar{y}$

表10-1中，x 和 y 的总平方和与总自由度皆可按方差分析分解为组间和组内两部分，此处不再赘述。相应地，总乘积和(total sum of products) 也可分解为组间乘积和(sum of products between groups) 和组内乘积和(sum of products within groups) 两部分。总乘积和用 $SP_{总}$ 或 SP_T 表示，组间乘积和用 $SP_{组间}$ 或 SP_t 表示，组内乘积和用 $SP_{组内}$ 或 SP_e 表示，则有

$$SP_T = SP_t + SP_e \tag{10.6}$$

各部分相应的自由度为

$$nk - 1 = (k-1) + k(n-1) \tag{10.7}$$

乘积和的计算公式为

$$\left.\begin{aligned} SP_T &= \sum_{i=1}^{k}\sum_{j=1}^{n}(x_{ij}-\bar{x})(y_{ij}-\bar{y}) = \sum_{i=1}^{k}\sum_{j=1}^{n}x_{ij}y_{ij} - \frac{1}{nk}(T_xT_y) \\ SP_t &= n\sum_{i=1}^{k}(\bar{x}_{i\cdot}-\bar{x})(\bar{y}_{i\cdot}-\bar{y}) = \frac{1}{n}\sum_{i=1}^{k}(T_{x_{i\cdot}}T_{y_{i\cdot}}) - \frac{1}{nk}(T_xT_y) \\ SP_e &= \sum_{i=1}^{k}\sum_{j=1}^{n}(x_{ij}-\bar{x}_{i\cdot})(y_{ij}-\bar{y}_{i\cdot}) = \sum_{i=1}^{k}\sum_{j=1}^{n}x_{ij}y_{ij} - \frac{1}{n}\sum_{i=1}^{k}(T_{x_{i\cdot}}T_{y_{i\cdot}}) \end{aligned}\right\} \tag{10.8}$$

式(10.8) 代入式(10.6)，则有

$$\sum_{i=1}^{k}\sum_{j=1}^{n}(x_{ij}-\bar{x})(y_{ij}-\bar{y}) = n\sum_{i=1}^{k}(\bar{x}_{i\cdot}-\bar{x})(\bar{y}_{i\cdot}-\bar{y}) + \sum_{i=1}^{k}\sum_{j=1}^{n}(x_{ij}-\bar{x}_{i\cdot})(y_{ij}-\bar{y}_{i\cdot}) \tag{10.9}$$

【例 10.1】 为比较 3 种不同配合饲料的效应，现将 24 头猪随机分成 3 组进行不同饲料喂养试验，测定结果列于表 10-2。试分析 3 种配合饲料对猪的增重差异是否显著。

表 10-2　3 种饲料饲喂试验中猪的始重与增重资料　　(单位:kg)

饲料		观测值								总和	平均
A_1	x(始重)	18	16	11	14	14	13	17	17	120	15
	y(增重)	85	89	65	80	78	83	91	85	656	82
A_2	x(始重)	17	18	18	19	21	21	16	22	152	19
	y(增重)	95	100	94	98	104	97	90	106	784	98
A_3	x(始重)	18	23	23	20	24	25	25	26	184	23
	y(增重)	91	89	98	82	100	98	102	108	768	96
总计	x									456	19
	y									2208	92

对于表 10-2 的资料可先直接对增重 y 进行方差分析,结果列于表 10-3。方差分析结果表明,3 种配合饲料对猪的增重影响差异达极显著水平。但是,我们不能轻易相信这一推断。由表 10-2 资料可以看出,各组猪的始重相差较大。而始重不同对猪的增重亦有影响,一般始重大的猪,增重快;始重小的猪,增重慢。方差分析的方法忽略了始重不同的影响,将始重与饲料对增重的效应混在一起,从而不能反映饲料的真实效应。因此,需用协方差分析的方法,矫正始重对增重的影响,获得真实的饲料效应。

表 10-3　不考虑始重时的方差分析表

变异来源	df	SS	s^2	F	$F_{0.05}$	$F_{0.01}$
饲料间	2	1216	608.00	11.34**	3.47	5.78
误差	21	1126	53.62			
总变异	23	2342				

下面结合本例详述协方差分析的方法步骤。

一、计算变量各变异来源的平方和、乘积和与自由度

根据表 10-2 的数据资料,首先计算分析所需的 6 个数据,即

$$\sum x = 456 \qquad \sum x^2 = 9044 \qquad nk = 24$$

$$\sum y = 2208 \qquad \sum y^2 = 205478 \qquad \sum xy = 42701$$

(1) x 变量的平方和。

$$\text{总变异:} SS_{T_x} = \sum x^2 - \frac{\left(\sum x\right)^2}{nk} = 9044 - \frac{456^2}{24} = 380$$

$$\text{饲料间:} SS_{t_x} = \frac{\sum T_{x_{i\cdot}}^2}{n} - \frac{\left(\sum x\right)^2}{nk} = \frac{120^2 + 152^2 + 184^2}{8} - \frac{456^2}{24} = 256$$

$$\text{误差:} SS_{e_x} = SS_{T_x} - SS_{t_x} = 380 - 256 = 124$$

(2) y 变量的平方和。

$$\text{总变异:} SS_{T_y} = \sum y^2 - \frac{\left(\sum y\right)^2}{nk} = 205478 - \frac{2208^2}{24} = 2342$$

饲料间：$SS_{t_y}=\dfrac{\sum T_{y_{i\cdot}}^2}{n}-\dfrac{\left(\sum y\right)^2}{nk}=\dfrac{656^2+784^2+768^2}{8}-\dfrac{2208^2}{24}=1216$

误差：$SS_{e_y}=SS_{T_y}-SS_{t_y}=2342-1216=1126$

(3) x 与 y 的乘积和。

总变异：$SP_T=\sum xy-\dfrac{\sum x\sum y}{nk}=42701-\dfrac{456\times 2208}{24}=749$

饲料间：$SP_t=\dfrac{\sum T_{x_{i\cdot}}T_{y_{i\cdot}}}{n}-\dfrac{\sum x\sum y}{nk}$

$=\dfrac{120\times 656+152\times 784+184\times 768}{8}-\dfrac{456\times 2208}{24}=448$

误差：$SP_e=SP_T-SP_t=749-448=301$

(4) 相应的自由度。

总变异：$df_T=nk-1=8\times 3-1=23$

饲料间：$df_t=k-1=3-1=2$

误差：$df_e=k(n-1)=3\times(8-1)=21$

将以上结果列于表 10-4。

表 10-4　始重 x 与增重 y 协方差分析表

变异来源	df	SS_x	SS_y	SP_{xy}	$b_{e(y/x)}$	矫正值(离回归部分)变异的分析			
						df	Q	s^2	F
总变异	23	380	2342	749		22	865.6816		
饲料组	2	256	1216	448					
组内	21	124	1126	301	2.4274	20	395.3468	19.7673	
矫正组(饲料组)间变异						2	470.3348	235.1674	11.90**

二、检验 x 和 y 是否存在直线回归关系

计算误差项(处理内项)的回归系数 $b_{e(y/x)}$，并对线性回归关系进行显著性检验，其目的是要从组内项变异中找出始重 x 与增重 y 之间是否存在真实的线性回归关系。在对回归系数进行显著性检验时，假设 $H_0:\beta=0$，$H_A:\beta\neq 0$。若接受 $H_0:\beta=0$，则二者之间回归关系不显著，说明增重 y 不受始重 x 的影响，即 y 与 x 无关，可以不用考虑始重 x，而直接对增重 y 进行方差分析；若否定 $H_0:\beta=0$，则二者之间存在显著的直线回归关系，表明增重 y 受始重 x 的影响，应当用线性回归关系来矫正 y 值以消除因 x 的不同而产生的影响，然后根据矫正后的 y 值进行方差分析。

(一) 计算误差项回归系数、回归平方和、离回归平方和与相应的自由度

误差项回归系数：

$$b_{e(y/x)}=\frac{SP_e}{SS_{e_x}}=\frac{301}{124}=2.4274$$

误差项回归平方和与自由度：

$$U_e=\frac{SP_e^2}{SS_{e_x}}=\frac{301^2}{124}=730.6532$$

$$df_{e(U)}=1$$

误差项离回归平方和与自由度：

$$Q_e=SS_{e_y}-U_e=SS_{e_y}-\frac{SP_e^2}{SS_{e_x}}=1126-\frac{301^2}{124}=395.3468$$

$$df_{e(Q)}=df_e-df_{e(U)}=k(n-1)-1=3\times(8-1)-1=20$$

(二) 检验误差项回归系数 b_e 的显著性(t 检验)

$$s_{e(y/x)}=\sqrt{\frac{Q_e}{df_{e(Q)}}}=\sqrt{\frac{395.3468}{20}}=4.4460$$

$$s_{b_e}=\frac{s_{e(y/x)}}{\sqrt{SS_{e_x}}}=\frac{4.4460}{\sqrt{124}}=0.3993$$

$$t=\frac{b_e}{s_{b_e}}=\frac{2.4274}{0.3993}=6.0791$$

查附表 3，$t_{0.01(20)}=2.845$，该 t 值达到极显著水平，应该否定 $H_0:\beta=0$，接受 $H_A:\beta\neq 0$。推断：y 依 x 有极显著的直线回归关系，即猪的增重确实受到始重的影响。

三、检验矫正平均数 $\bar{y}_{i(x=\bar{x})}$ 间的差异显著性

误差项(组内项)回归关系显著时，需用误差项回归系数对增重 y 进行矫正，消除始重 x 不同对增重 y 的影响，从而使各种不同的饲料效应处于始重 x 相同水平的基础上进行比较。也就是说，在消除协变量 x 的影响后，比较各处理矫正 y 值的差异显著性。

检验矫正后 y 值的差异显著性，在进行平方和的计算时，并不需要将各个 y 的矫正值求出后再进行计算。由回归分析可知，依变量 y 的平方和可分解为回归平方和与离回归平方和。回归平方和是 y 受 x 影响而产生的变异部分，离回归平方和则是 y 去除了 x 影响后剩余的变异部分。而矫正增重 y 计算出的各项平方和，实际上就是去除了始重 x 影响的部分。统计学上已证明，矫正后 y 的各项平方和及自由度等于其相应变异项的离回归平方和及自由度。

其具体分析过程为：对总变异项作回归分析，求得其离回归平方和 Q'_T 和自由度 $df'_{T(Q)}$，再由 $Q'_T-Q'_e$ 和 $df'_{T(Q)}-df'_{e(Q)}$ 即得到矫正 y 值的平方和与自由度，进而可对矫正平均数 $\bar{y}_{i(x=\bar{x})}$ 间的差异显著性进行 F 检验。由此可以看出，在对矫正 y 值进行方差分析时，并不需要对各处理的矫正 y 值进行计算。

(一) 计算矫正增重 y 的各项平方和与自由度

矫正 y 值的总平方和与自由度，即总离回归和与自由度：

$$Q'_T=SS_{T_y}-\frac{SP_T^2}{SS_{T_x}}=2342-\frac{749^2}{380}=865.6816$$

$$df'_{T(Q)}=(nk-1)-1=nk-2=8\times3-2=22$$

矫正 y 值的误差项(组内项)平方和与自由度,即误差项离回归平方和与自由度:

$$Q'_e=Q_e=SS_{e_y}-\frac{SP_e^2}{SS_{e_x}}=1126-\frac{301^2}{124}=395.3468$$

$$df'_{e(Q)}=df_{e(Q)}=k(n-1)-1=3\times(8-1)-1=20$$

矫正 y 值处理项(组间项)的平方和与自由度:

$$Q'_t=Q'_T-Q'_e=865.6816-395.3468=470.3348$$

$$df'_{t(Q)}=df'_{T(Q)}-df'_{e(Q)}=22-20=2$$

(二) 列出协方差分析表,进行矫正值的方差分析

将矫正增重 y 的各项平方和与自由度列入表 10-4,即得到完整的协方差分析表。

$$\text{矫正(饲料)组间方差}=\frac{470.3348}{2}=235.1674$$

$$\text{矫正(饲料)组内方差}=\frac{395.3468}{20}=19.7673$$

则有

$$F=\frac{235.1674}{19.7673}=11.90$$

查 F 值表,$F_{0.01(2,20)}=5.85$,$F>F_{0.01(2,20)}$,F 值达极显著水平。通过矫正消除始重影响后,各饲料组间矫正增重差异达极显著水平,需进行多重比较。

四、矫正平均数 $\bar{y}_{i(x=\bar{x})}$ 间的多重比较

(一) 计算各矫正增重的平均数

误差项(组内项)回归系数 $b_{e(y/x)}$ 表示始重 x 对增重 y 影响的性质和程度,且不包含处理间差异的影响,因此可用 $b_{e(y/x)}$ 根据平均始重的不同来矫正每一处理的增重平均值。

矫正平均数 $\bar{y}_{i(x=\bar{x})}$ 的公式为:

$$\bar{y}_{i(x=\bar{x})}=\bar{y}_i-b_{e(y/x)}(\bar{x}_i-\bar{x}) \tag{10.10}$$

式中,$\bar{y}_{i(x=\bar{x})}$ 为第 i 处理 y 的矫正平均数;$\bar{y}_i$ 为第 i 处理实际观测值 y 的平均数;$\bar{x}_i$ 为自变量 x 第 i 处理的平均数;$\bar{x}$ 为自变量 x 的总平均数。

将表 10-2 数据代入式(10.10),计算各处理组矫正平均增重如下:

$$\bar{y}_{1(x=\bar{x})}=\bar{y}_1-b_{e(y/x)}(\bar{x}_1-\bar{x})=82-2.4274\times(15-19)=91.7096$$

$$\bar{y}_{2(x=\bar{x})}=\bar{y}_2-b_{e(y/x)}(\bar{x}_2-\bar{x})=98-2.4274\times(19-19)=98.0000$$

$$\bar{y}_{3(x=\bar{x})}=\bar{y}_3-b_{e(y/x)}(\bar{x}_3-\bar{x})=96-2.4274\times(23-19)=86.2904$$

由此可见,消除初始重量影响后,$\bar{y}_i$ 与 $\bar{y}_{i(x=\bar{x})}$ 不仅数值不同,而且次序也发生改变。饲料 A_1 的平均增重由原第三位上升为第二位,而饲料 A_3 的平均增重则由第二位降为第三位。若不进行矫正,则会得出饲料 A_3 优于饲料 A_1 的假象。

(二) 矫正平均数间的多重比较

1. t 检验

当矫正均数的误差项自由度小于20,且变量 x 的变异较大时,可采用两两比较的 t 检验法。

$$t=\frac{\bar{y}_{i(x=\bar{x})}-\bar{y}_{l(x=\bar{x})}}{s_D} \tag{10.11}$$

式中,s_D 为两矫正平均数间差数的标准误,其公式为

$$s_D=\sqrt{s^2_{e(y/x)}\left[\frac{1}{n_i}+\frac{1}{n_l}+\frac{(\bar{x}_i-\bar{x}_l)^2}{SS_{e_x}}\right]} \tag{10.12}$$

式中,$s^2_{e(y/x)}$ 为误差项离回归方差;n_i、n_l 为比较的两个样本容量;$\bar{x}_i$、$\bar{x}_l$ 为两个相比较样本的 x 变量平均数;SS_{e_x} 为 x 变量的组内项平方和。

如果两个样本容量相同,即 $n_i=n_l=n$ 时,式(10.12)可以表示为

$$s_D=\sqrt{s^2_{e(y/x)}\left[\frac{2}{n}+\frac{(\bar{x}_i-\bar{x}_l)^2}{SS_{e_x}}\right]} \tag{10.13}$$

在本例中,检验 A_1 与 A_2 平均数差异显著性。已知 $\bar{y}_{1(x=\bar{x})}=91.7096$,$\bar{y}_{2(x=\bar{x})}=98.0000$,$s^2_{e(y/x)}=19.7673$,$df_{e(Q)}=20$,$n_1=n_2=8$,$\bar{x}_1=15$,$\bar{x}_2=19$,$SS_{e_x}=124$。由式(10.13)得

$$s_D=\sqrt{19.7673\times\left[\frac{2}{8}+\frac{(15-19)^2}{124}\right]}=2.7372$$

$$t=\frac{\bar{y}_{i(x=\bar{x})}-\bar{y}_{l(x=\bar{x})}}{s_D}=\frac{91.7096-98.0000}{2.7372}=-2.298$$

由于 $|t|=2.298>t_{0.05(20)}=2.086$,达显著水平。表明饲料 A_1 与 A_2 对猪增重效果有明显差别,即 A_2 优于 A_1。同理可对 A_1 与 A_3、A_2 与 A_3 进行比较。

2. LSD 法

由于每次比较都要分别计算两个矫正平均数差数的标准误 s_D,显然比较麻烦。为简便起见,当误差项自由度在20或20以上,且 x 变量的变异较小时,可用一个平均数差数标准误进行比较。此时:

$$s_D=\sqrt{s^2_{e(y/x)}\left[1+\frac{SS_{t_x}}{(k-1)SS_{e_x}}\right]\left(\frac{1}{n_i}+\frac{1}{n_l}\right)} \tag{10.14}$$

式中,SS_{t_x} 为 x 变量组间平方和,k 为组数。

当 $n_i=n_l=n$ 时,式(10.14)可以表示为

$$s_D=\sqrt{s^2_{e(y/x)}\times\left[1+\frac{SS_{t_x}}{(k-1)SS_{e_x}}\right]\times\frac{2}{n}} \tag{10.15}$$

按公式 $LSD_\alpha=t_\alpha\cdot s_D$,计算出最小显著差数,并与各组均数矫正值的差数进行比较,即可检验它们的差异显著性。

本例中,其误差项自由度为20,但不满足"x 变量变异较小"这一条件,因此不宜采用

此法进行多重比较。为了便于学习和掌握该种方法，仍以本例的数据来进行说明。

$$s_D=\sqrt{19.7673\times\left[1+\frac{256}{(3-1)\times 124}\right]\times\left(\frac{1}{8}+\frac{1}{8}\right)}=3.1691$$

$$LSD_{0.05}=2.086\times 3.1691=6.6107$$

$$LSD_{0.01}=2.845\times 3.1691=9.0161$$

将平均数差异显著性结果列入表 10-5。

检验结果表明，饲料 A_2 与 A_3 差异达极显著水平，其余皆不显著。3 种饲料中以 A_2 最好，A_1 与 A_3 次之 。

表 10-5　3 种饲料效应的差异显著性比较（*LSD* 法）

饲料	矫正 y 值平均数 $\bar{y}_{i(x=\bar{x})}$	差异显著性	
		$\bar{y}_{i(x=\bar{x})}-86.2904$	$\bar{y}_{i(x=\bar{x})}-91.7096$
A_2	98.0000	11.7096**	6.2904
A_1	91.7096	5.4192	
A_3	86.2904		

由于变量 x 的变异较大，而在检验时使用一个共同的平均数差数标准误，因而出现了与 t 检验不完全一致的结果。用 t 检验时，A_1 与 A_2 之间存在显著差异，而用 *LSD* 法进行比较时，二者差异未达显著水平。

第三节　二因素试验资料的协方差分析

若试验设有 k 个处理，每个处理设 n 个类别（重复），则 nk 对观测值可以按两向进行分组，其数据模式如表 10-6 所示。

表 10-6　二因素试验资料的数据模式

组	类										总和		平均	
	1		2		…	j		…	n					
1	x_{11}	y_{11}	x_{12}	y_{12}	…	x_{1j}	y_{1j}	…	x_{1n}	y_{1n}	$T_{x_1\cdot}$	$T_{y_1\cdot}$	$\bar{x}_{1\cdot}$	$\bar{y}_{1\cdot}$
2	x_{21}	y_{21}	x_{22}	y_{22}	…	x_{2j}	y_{2j}	…	x_{2n}	y_{2n}	$T_{x_2\cdot}$	$T_{y_2\cdot}$	$\bar{x}_{2\cdot}$	$\bar{y}_{2\cdot}$
⋮	⋮	⋮	⋮	⋮		⋮	⋮		⋮	⋮	⋮	⋮	⋮	⋮
i	x_{i1}	y_{i1}	x_{i2}	y_{i2}	…	x_{ij}	y_{ij}	…	x_{in}	y_{in}	$T_{x_i\cdot}$	$T_{y_i\cdot}$	$\bar{x}_{i\cdot}$	$\bar{y}_{i\cdot}$
⋮	⋮	⋮	⋮	⋮		⋮	⋮		⋮	⋮	⋮	⋮	⋮	⋮
k	x_{k1}	y_{k1}	x_{k2}	y_{k2}	…	x_{kj}	y_{kj}	…	x_{kn}	y_{kn}	$T_{x_k\cdot}$	$T_{y_k\cdot}$	$\bar{x}_{k\cdot}$	$\bar{y}_{k\cdot}$
总和	$T_{x\cdot 1}$	$T_{y\cdot 1}$	$T_{x\cdot 2}$	$T_{y\cdot 2}$	…	$T_{x\cdot j}$	$T_{y\cdot j}$	…	$T_{x\cdot n}$	$T_{y\cdot n}$	T_x	T_y		
平均	$\bar{x}_{\cdot 1}$	$\bar{y}_{\cdot 1}$	$\bar{x}_{\cdot 2}$	$\bar{y}_{\cdot 2}$	…	$\bar{x}_{\cdot j}$	$\bar{y}_{\cdot j}$	…	$\bar{x}_{\cdot n}$	$\bar{y}_{\cdot n}$			$\bar{x}$	$\bar{y}$

表 10-6 的总 *SP* 可分解为类间、组间和误差 3 个部分，其值为

$$\left.\begin{aligned}
&\text{总 } SP=\sum_{1}^{nk}(x_{ij}-\bar{x})(y_{ij}-\bar{y})=\sum_{1}^{nk}x_{ij}y_{ij}-\frac{T_xT_y}{nk}\\
&\text{类间 } SP=k\sum_{1}^{n}(\bar{x}_{\cdot j}-\bar{x})(\bar{y}_{\cdot j}-\bar{y})=\frac{1}{k}\sum_{1}^{n}(T_{x\cdot j}T_{y\cdot j})-\frac{T_xT_y}{nk}\\
&\text{组间 } SP=n\sum_{1}^{k}(\bar{x}_{i\cdot}-\bar{x})(\bar{y}_{i\cdot}-\bar{y})=\frac{1}{n}\sum_{1}^{k}(T_{x_i\cdot}T_{y_i\cdot})-\frac{T_xT_y}{nk}\\
&\text{误差 } SP=\text{总 } SP-\text{类间 } SP-\text{组间 } SP
\end{aligned}\right\}\quad(10.16)$$

式中，$i=1,2,\cdots,k$；$j=1,2,\cdots,n$。各 SP 的相应自由度依次为 $nk-1$、$n-1$、$k-1$ 和 $(n-1)(k-1)$。

根据这些 SP 和用第六章方法得到的 SS，就可进行协方差分析。

下面以例 10.2 为例，介绍其协方差分析的方法。

【例 10.2】 表 10-7 是施肥期和施肥量对杂交水稻'南优 3 号'结实率影响的部分结果，共 14 个处理，两个区组，随机区组设计。在试验过程中发现单位面积上的颖花数对结实率有明显的回归关系，因此将颖花数(x，万 /m^2) 和结实率(y，%) 一起测定，其结果列于表 10-7。试作协方差分析。

表 10-7 '南优 3 号'颖花数(x)和结实率(y)部分资料

处理	区组								
	Ⅰ		Ⅱ		总和		平均		矫正值
	x	y	x	y	$T_{x_i\cdot}$	$T_{y_i\cdot}$	$\bar{x}_{i\cdot}$	$\bar{y}_{i\cdot}$	$\bar{y}_{i(x=\bar{x})}$
1	4.59	58	4.32	61	8.91	119	4.455	59.5	64.76
2	4.09	65	4.11	62	8.20	127	4.100	63.5	66.03
3	3.94	64	4.11	64	8.05	128	4.025	64.0	65.95
4	3.90	66	3.57	69	7.47	135	3.735	67.5	67.22
5	3.45	71	3.79	67	7.24	138	3.620	69.0	67.83
6	3.48	71	3.38	72	6.86	143	3.430	71.5	68.87
7	3.39	71	3.03	74	6.42	145	3.210	72.5	68.18
8	3.14	72	3.24	69	6.38	141	3.190	70.5	66.02
9	3.34	69	3.04	69	6.38	138	3.190	69.0	64.52
10	4.12	61	4.76	54	8.88	115	4.440	57.5	62.65
11	4.12	63	4.75	56	8.87	119	4.435	59.5	64.61
12	3.84	67	3.60	62	7.44	129	3.720	64.5	64.10
13	3.96	64	4.50	60	8.46	124	4.230	62.0	65.53
14	3.03	75	3.01	71	6.04	146	3.020	73.0	67.22
$T_{\cdot j}$	52.39	937	53.21	910					
总和 T					105.60	1847			
平均值							3.7714	65.9643	

一、乘积和与自由度的分解

首先用二因素资料的通常方法计算表10-7资料的各项平方和列于表10-8，乘积和则由式(10.16)算出：

$$\text{总 } SP=\sum_{1}^{nk}x_{ij}y_{ij}-\frac{T_xT_y}{nk}$$

$$=4.59\times58+4.09\times65+\cdots+3.01\times71-\frac{1}{28}\times(105.60\times1847)$$

$$=-73.5986$$

$$\text{区组 } SP=\frac{1}{k}\sum_{1}^{n}(T_{x\cdot j}T_{y\cdot j})-\frac{T_xT_y}{nk}$$

$$=\frac{52.39\times937+53.21\times910}{14}-\frac{1}{28}\times(105.60\times1847)$$

$$=-0.7907$$

$$\text{处理 } SP=\frac{1}{n}\sum_{1}^{k}(T_{x_i\cdot}T_{y_i\cdot})-\frac{T_xT_y}{nk}$$

$$=\frac{8.91\times119+8.20\times127+\cdots+6.04\times146}{2}-\frac{1}{28}\times(105.6\times1847)$$

$$=-66.3636$$

$$\text{误差 } SP=\text{总 } SP-\text{区组 } SP-\text{处理 } SP$$

$$=-73.5986-(-0.7907)-(-66.3636)=-6.4443$$

表10-8　表10-7资料的平方和与乘积和

变异来源	SS_x	SS_y	SP
总变异	7.7343	802.9643	−73.5986
区组间	0.0240	26.0357	−0.7907
处理间	6.8731	694.4643	−66.3636
误差	0.8372	82.4643	−6.4443

有了上述结果，可先对x变量和y变量分别进行方差分析，结果列于表10-9。

表10-9　表10-7资料的方差分析

变异来源	df	x变量			y变量			$F_{0.05}$	$F_{0.01}$
		SS	s^2	F	SS	s^2	F		
区组间	1	0.0240	0.0240	0.3727	26.0357	26.0357	4.1044	4.67	9.07
处理间	13	6.8731	0.5287	8.2096**	694.4643	53.4203	8.4214**	2.57	3.90
误差	13	0.8372	0.0644		82.4643	6.3434			

表10-9表明，不同区组的颖花数(x)和结实率(y)都没有显著差异，但不同施肥处理的x和y的差异均达极显著水平。在单因素资料的协方差分析中，我们已经知道，如果y和x无关，上述推断将是正确的；如果y和x有关，则不一定正确。因此，首先应明确y和x是否有线性关系。

二、检验 x 和 y 是否存在直线回归关系

由表 10-8 的误差项可得线性回归的 U_e 和 Q_e：

$$U_e=\frac{SP_e^2}{SS_{e_x}}=\frac{(-6.4443)^2}{0.8372}=49.6046$$

$$Q_e=SS_{e_y}-U_e=82.4643-49.6046=32.8597$$

将线性回归进行 F 检验(表 10-10)，$F=18.1151$，达极显著水平。因此应对 y 值进行矫正，并对矫正平均数进行差异显著性检验，才能明确不同区组或处理对于结实率的效应。

表 10-10　表 10-7 资料误差项线性回归的显著性检验

变异来源	df	SS	s^2	F
线性回归	1	49.6046	49.6046	18.1151**
离回归	12	32.8597	2.7383	
总变异	13	82.4643		

三、检验矫正平均数 $\bar{y}_{i(x=\bar{x})}$ 间的差异显著性

表 10-7 的资料分为区组和处理两项，因此，检验矫正平均数的差异显著性需一项一项地进行。检验处理的矫正平均数 $\bar{y}_{i\cdot(x=\bar{x})}$ 的差异显著性时，需将处理间和误差项的 df、SS 和 SP 相加以代替总变异的 df、SS 和 SP；检验区组的矫正平均数 $\bar{y}_{\cdot j(x=\bar{x})}$ 的差异显著性时，需将区组间和误差项的 df、SS 和 SP 相加以代替总变异的 df、SS 和 SP(这里的“处理间＋误差项”和“区组间＋误差项”相当于表 10-4 中的总变异)。由此，可以分别对两项矫正平均数间的差异进行显著性检验。区组只是局部控制的一种手段，在结果分析上只需剔除其影响，而不必研究其效应，因此这里仅对处理项的矫正平均数 $\bar{y}_{i\cdot(x=\bar{x})}$ 之间的差异显著性进行检验，结果列于表 10-11。

表 10-11　表 10-7 资料处理间矫正平均数的显著性检验

变异来源	df	SS_x	SS_y	SP	b_e	矫正值(离回归)变异的分析				
						df	Q	s^2	F	$F_{0.05}$
处理＋误差	26	7.7103	776.9286	−72.8079		25	89.4080			
处理	13	6.8731	694.4643	−66.3636						
误差	13	0.8372	82.4643	−6.4443	−7.6974	12	32.8597	2.7383		
矫正平均数的差异						13	56.5483	4.3499	1.5885	2.66

由表 10-10 可知，误差项线性回归达到极显著水平，所以可用表 10-11 中误差项回归系数 $b_{e(y/x)}=-7.6974$ 对各处理的 $\bar{y}_i$ 进行矫正。$b_{e(y/x)}=-7.6974$ 表示颖花数每增加 1 万 /m²，结实率 y 将下降 7.6974%。将 $b_{e(y/x)}=-7.6974$ 代入式(10.10)，即有方程：

$$\bar{y}_{i(x=\bar{x})}=\bar{y}_i+7.6974(\bar{x}_i-3.7714)$$

上式可将各处理的结实率都矫正到颖花数为每平方米 3.7714 万个的结实率，由此可计算各处理矫正平均数：

处理 1：$\bar{y}_{1(x=\bar{x})}=59.5+7.6974\times(4.455-3.7714)=64.76(\%)$

处理 2：$\bar{y}_{2(x=\bar{x})}=63.5+7.6974\times(4.100-3.7714)=66.03(\%)$

……

计算出的 $\bar{y}_{i(x=\bar{x})}$ 列于表 10-7 末列。它们已和单位面积上颖花数的多少无关，故在相互比较时更为真实。

但是，在未算出 $\bar{y}_{i(x=\bar{x})}$ 之前，我们已由表 10-11 可知，其 F 值未达到显著水平。说明各处理矫正平均数 $\bar{y}_{i(x=\bar{x})}$ 之间并无显著差异，因而不需要再对各矫正平均数间进行多重比较（如果 $\bar{y}_{i(x=\bar{x})}$ 间的 F 检验是显著的，则需要进行矫正平均数间的多重比较）。

综上所述，本试验的基本结论是：不同的施肥期和施肥量，对‘南优 3 号’单位面积上的颖花数和结实率都有极显著的影响。但是，颖花数和结实率有极显著的线性回归关系，将各处理每平方米的颖花数都矫正到同一水平，则不同的结实率没有显著差异。因此，在本例中，不同施肥期和施肥量，对‘南优 3 号’的结实率只有间接效应，而没有显著的直接效应，即不同的施肥期和施肥量造成了单位面积上颖花的差异，进而造成结实率的差异。

第四节　协方差分析的数学模型和基本假定

一、协方差分析的数学模型

表 10-1 数据资料协方差分析的线性数学模型为

$$y_{ij}=\mu_y+\alpha_i+\beta(x_{ij}-\mu_x)+\varepsilon_{ij} \tag{10.17}$$

式中，μ_y 和 μ_x 分别为 y 和 x 的总体平均数；α_i 为第 i 个处理的效应；β 为 y 依 x 的总体回归系数；ε_{ij} 为随机误差。式(10.17) 移项可得

$$y_{ij}-\alpha_i=\mu_y+\beta(x_{ij}-\mu_x)+\varepsilon_{ij} \tag{10.18}$$

$$y_{ij}-\beta(x_{ij}-\mu_x)=\mu_y+\alpha_i+\varepsilon_{ij} \tag{10.19}$$

式中，若令 $y'_{ij}=y_{ij}-\alpha_i$，y'_{ij} 表示在观测值中剔除了处理效应，即误差项，此时协方差分析即为 y'_{ij} 与 x_{ij} 的线性回归分析。式(10.19) 中，若令 $y''_{ij}=y_{ij}-\beta(x_{ij}-\mu_x)$，$y''_{ij}$ 表示对观测值进行了回归矫正，此时协方差分析即为 y''_{ij} 的方差分析，并且是消除了 x_{ij} 不一致对 y_{ij} 影响之后的方差分析。由此说明协方差分析是回归分析与方差分析的结合。

二、协方差分析的基本假定

当应用上述模型检验矫正平均数时，必须满足下面 3 个基本假定。

(1) x 是固定的变量，因而处理效应 α_i 属固定模型。

(2) ε_{ij} 是独立的（与处理效应无关），且服从 $N(0,\sigma^2_{y/x})$。从样本来说，即各处理的离回归方差 $s^2_{y/x}=\dfrac{Q_i}{n-2}$ 没有显著差异，即离回归方差同质。

(3) 各处理的 (x,y) 总体都是线性的，且具有共同的回归系数 β，因而各处理总体的回归是一组平行的直线。对样本来说，各误差项的回归系数本身是显著的，但各回归系数 b_i 之间的差异不显著，即误差项的线性回归是显著的，而回归系数 b_i 的差异是不显著的。

应该注意的是，前面所介绍的协方差分析，并没有检验 $H_0:\beta_1=\beta_2=\cdots=\beta_k$，即没有

检验各处理回归系数之间的差异显著性。根据协方差分析的基本假定，各处理回归系数 b_i 间差异不显著时，才能用误差项的回归系数 b_e 对各处理平均数进行矫正。这是因为我们的目的仅在于明确 y 和 x 是否有线性关系，以及在存在这一关系时以之矫正 y 的效果，所以省掉了各个回归系数 b_i 的齐性检验。同时，处理内回归显著亦包含了 b_i 间差异不显著的部分信息。但是，如果各 b_i 是否同质亦是研究的目的，则该步骤是不可省略的。至于如何检验各回归系数 b_i 的同质性，本章不再作介绍。

思考练习题

习题 10.1　什么是协方差分析？协方差分析的主要作用是什么？

习题 10.2　为研究 A_1、A_2、A_3、A_4 4 种不同肥料对梨树单株产量的影响，选择 40 株梨树进行试验。将 40 株梨树完全随机分为 4 组，每组包含 10 株，每组施用一种肥料。各株梨树的起始干周(x，cm)和单株产量(y，kg)如下表所示。试检验 4 种肥料对梨树单株产量的影响是否有差异。

肥料		观测值										总和	平均
A_1	x_{1j}	36	30	26	23	26	30	20	19	20	16	246	24.6
	y_{1j}	89	80	74	80	85	68	73	68	80	58	755	75.5
A_2	x_{2j}	28	27	27	24	25	23	20	18	17	20	229	22.9
	y_{2j}	64	81	73	67	77	67	64	65	59	57	674	67.4
A_3	x_{3j}	28	33	26	22	23	20	22	23	18	17	232	23.2
	y_{3j}	55	62	58	58	66	55	60	71	55	48	588	58.5
A_4	x_{4j}	32	23	27	23	27	28	20	24	19	17	240	24.0
	y_{4j}	52	58	64	62	54	54	55	44	51	51	545	54.5
总计	x											949	23.675
	y											2562	64.05

习题 10.3　对 6 个菜豆品种进行了维生素 C 含量(y，mg/100g)比较试验，4 次重复，随机区组试验设计。根据已有的研究结果，菜豆维生素 C 的含量不仅与品种有关，而且与豆荚的成熟度有关。但是在试验中无法使所有小区的豆荚同时成熟，所以同时测定了 100g 所采豆荚干物质重百分率(x)，作为豆荚成熟度的指标。测定结果如下表所示，试对该资料进行协方差分析。

品种		区组				总和	平均
A_1	x_{1j}	34.0	33.4	34.7	38.9	141.0	35.25
	y_{1j}	93.0	94.8	91.7	80.8	360.3	90.075
A_2	x_{2j}	39.6	39.8	51.2	52.0	182.6	45.65
	y_{2j}	47.3	51.5	33.3	27.2	159.3	39.825
A_3	x_{3j}	31.7	30.1	33.8	39.6	135.2	33.80
	y_{3j}	81.4	109.0	71.6	57.5	319.5	79.875
A_4	x_{4j}	37.7	38.2	40.3	39.4	155.6	38.90
	y_{4j}	66.9	74.1	64.7	69.3	275.0	68.75
A_5	x_{5j}	24.9	24.0	24.9	23.5	97.3	24.325
	y_{5j}	119.5	128.5	125.6	129.0	502.6	125.65
A_6	x_{6j}	30.3	29.1	31.7	28.3	119.4	29.85
	y_{6j}	106.6	111.4	99.0	126.1	443.1	110.775
总和	$x_{\cdot j}$	198.2	194.6	216.6	221.7	$\sum x = 831.1$	
	$y_{\cdot j}$	514.7	569.3	485.9	489.9	$\sum y = 2059.8$	
平均	$x_{\cdot j}$	33.033	32.433	36.100	36.950	$\bar{x} = 34.629$	
	$y_{\cdot j}$	85.783	94.883	80.983	81.650	$\bar{y} = 85.825$	

第十一章

多元线性回归与多元相关分析

本章提要

多元线性回归是指两个或两个以上自变量(且自变量均为一次项)与依变量之间的回归。多元线性回归的分析,也可以像直线回归一样利用最小二乘法通过建立正规方程组求出偏回归系数,建立多元线性回归方程。通过计算回归估计标准误,可对多元线性回归方程进行 F 检验,偏回归系数的假设检验则是通过计算各自系数的标准误,进行 F 检验或 t 检验。

多元相关是表示多个自变量与依变量之间总的密切程度,可用多元相关系数(亦称复相关系数)来进行度量。在研究两变量之间的相关关系时,须排除其他变量的影响,从而得到二者之间真实的关系,即进行偏相关分析。多元相关系数的假设检验须用 F 检验,而偏相关系数的假设检验可采用 t 检验。二者也均可通过与一定显著水平 α 下的临界 r 值或 R 值比较进行检验。

本书第七章和第八章所讨论的回归和相关,无论是线性还是非线性的,都是依变量 y 在一个自变量 x 上的回归或相关,统称为一元回归或一元相关。但在实际问题中,影响依变量的因素常常不只是一个,而是两个或两个以上。例如,影响昆虫种群变化的生态因素有温度、湿度、雨量等;作物籽粒产量与其 3 个构成因素,即穗数、粒数、粒重有关;家畜体重与其体长、胸围有关等。因此,为了清楚了解依变量 y 与多个自变量 x 之间的关系,必须在一元回归与相关分析的基础上,进行多元回归与多元相关分析。其中最为常用的是多元线性回归分析和多元线性相关分析。多元回归与多元相关也称为复回归与复相关。

第一节　多元线性回归分析

多元线性回归分析的基本方法是:以多元线性回归模型为基础,根据最小二乘法建立正规方程,求解得出多元线性回归方程,并对回归方程和偏回归系数进行检验,作出回归

方程的区间估计。

一、多元线性回归模型

多元回归有多种模型，这里仅讨论其中最基本的模型——多元线性回归(multiple linear regression)模型。多元线性回归是指具一个依变量与两个或两个以上自变量，且各自变量均为一次项的回归。设自变量 $x_1, x_2, \cdots, x_m$ 与依变量 y 皆呈线性关系，则一个 m 元线性回归的数学模型可表示为

$$y_i = \mu_y + \beta_{y1\cdot23\cdots m}(x_1 - \mu_{x_1}) + \beta_{y2\cdot13\cdots m}(x_2 - \mu_{x_2}) + \cdots + \beta_{ym\cdot12\cdots(m-1)}(x_m - \mu_{x_m}) + \varepsilon_i \tag{11.1}$$

式中，$\mu_y, \mu_{x_1}, \mu_{x_2}, \cdots, \mu_{x_m}$ 依次为 $y, x_1, x_2, \cdots, x_m$ 的总体平均数，其样本估计值依次为 $\bar{y}, \bar{x}_1, \bar{x}_2, \cdots, \bar{x}_m$；$\beta_{y1\cdot23\cdots m}$ 为 $x_2, x_3, \cdots, x_m$ 固定不变时，x_1 每变动一个单位 y 平均变动的相应单位数，称为 $x_2, x_3, \cdots, x_m$ 固定不变时 x_1 对 y 的偏回归系数(partial regression coefficient)，简记作 β_1，其样本估计值简记作 b_1，余下类推；ε_i 为随机误差，服从 $N(0, \sigma^2_{y/x_1,x_2,\cdots,x_m})$ 的正态分布，$\sigma^2_{y/x_1,x_2,\cdots,x_m}$ 为离回归方差，其平方根为离回归标准差或者称为回归估计标准误。

若令 $\alpha = \mu_y - \beta_1\mu_{x_1} - \beta_2\mu_{x_2} - \cdots - \beta_m\mu_{x_m}$，则多元线性回归的数学模型为

$$y_i = \alpha + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_m x_m + \varepsilon_i \tag{11.2}$$

于是样本多元线性回归方程为

$$\hat{y} = \bar{y} + b_1(x_1 - \bar{x}_1) + b_2(x_2 - \bar{x}_2) + \cdots + b_m(x_m - \bar{x}_m) \tag{11.3}$$

或

$$\hat{y} = a + b_1 x_1 + b_2 x_2 + \cdots + b_m x_m \tag{11.4}$$

式中，a 为 α 的样本估计值，a 可由下式求出：

$$a = \bar{y} - b_1\bar{x}_1 - b_2\bar{x}_2 - \cdots - b_m\bar{x}_m \tag{11.5}$$

二、多元线性回归方程的建立

同直线回归方程一样，多元线性回归方程也可根据最小二乘法建立，必须使：

$$Q = \sum(y - \hat{y})^2$$

$$= \sum[y - \bar{y} - b_1(x_1 - \bar{x}_1) - b_2(x_2 - \bar{x}_2) - \cdots - b_m(x_m - \bar{x}_m)]^2 = \text{最小值}$$

令 $Y = y - \bar{y}, X_1 = x_1 - \bar{x}_1, X_2 = x_2 - \bar{x}_2, \cdots, X_m = x_m - \bar{x}_m$，则有

$$Q = \sum(Y - b_1X_1 - b_2X_2 - \cdots - b_mX_m)^2 = \text{最小值}$$

要使 Q 达到最小，就必须使 $b_1, b_2, \cdots, b_m$ 的偏微分方程皆等于 0，即有

$$\frac{\partial Q}{\partial b_1} = -2\sum(Y - b_1X_1 - b_2X_2 - \cdots - b_mX_m)X_1 = 0$$

$$\frac{\partial Q}{\partial b_2} = -2\sum(Y - b_1X_1 - b_2X_2 - \cdots - b_mX_m)X_2 = 0$$

$$\vdots \qquad\qquad \vdots \qquad\qquad \vdots$$

$$\frac{\partial Q}{\partial b_m} = -2\sum(Y - b_1X_1 - b_2X_2 - \cdots - b_mX_m)X_m = 0$$

经整理，得到如下正规方程组(normal equation group)：

$$\left.\begin{aligned} b_1\sum X_1^2+b_2\sum X_1X_2+\cdots+b_m\sum X_1X_m&=\sum X_1Y\\ b_1\sum X_1X_2+b_2\sum X_2^2+\cdots+b_m\sum X_2X_m&=\sum X_2Y\\ \vdots\qquad\qquad\vdots&\qquad\qquad\vdots\\ b_1\sum X_1X_m+b_2\sum X_2X_m+\cdots+b_m\sum X_m^2&=\sum X_mY \end{aligned}\right\}$$

由于 $SS_1=\sum X_1^2, SS_2=\sum X_2^2,\cdots,SS_m=\sum X_m^2; SP_{12}=\sum X_1X_2,\cdots,SP_{1m}=\sum X_1X_m, SP_{2m}=\sum X_2X_m,\cdots; SP_{1y}=\sum X_1Y, SP_{2y}=\sum X_2Y,\cdots,SP_{my}=\sum X_mY$。则可得如下方程组：

$$\left.\begin{aligned} b_1SS_1+b_2SP_{12}+\cdots+b_mSP_{1m}&=SP_{1y}\\ b_1SP_{12}+b_2SS_2+\cdots+b_mSP_{2m}&=SP_{2y}\\ \vdots\qquad\qquad\vdots&\qquad\qquad\vdots\\ b_1SP_{1m}+b_2SP_{2m}+\cdots+b_mSS_m&=SP_{my} \end{aligned}\right\} \tag{11.6}$$

这个正规方程组可用矩阵(matrix)表示为

$$\begin{pmatrix} SS_1 & SP_{12} & \cdots & SP_{1m}\\ SP_{12} & SS_2 & \cdots & SP_{2m}\\ \vdots & \vdots & & \vdots\\ SP_{1m} & SP_{2m} & \cdots & SS_m \end{pmatrix}\times\begin{pmatrix} b_1\\ b_2\\ \vdots\\ b_m \end{pmatrix}=\begin{pmatrix} SP_{1y}\\ SP_{2y}\\ \vdots\\ SP_{my} \end{pmatrix} \tag{11.7}$$

若系数矩阵(coefficient matrix)用 $\boldsymbol{A}$ 表示，未知元矩阵(matrix of unknown elements)用 $\boldsymbol{b}$ 表示，常数矩阵(constant matrix)用 $\boldsymbol{K}$ 表示，则式(11.7)可写为

$$\boldsymbol{Ab}=\boldsymbol{K} \tag{11.8}$$

为求解式(11.8)中的 $\boldsymbol{b}$，一般应先求出 $\boldsymbol{A}$ 的逆矩阵(inverse matrix) $\boldsymbol{A}^{-1}$，令：

$$\boldsymbol{A}^{-1}=(c_{ij})=\begin{pmatrix} c_{11} & c_{12} & \cdots & c_{1m}\\ c_{21} & c_{22} & \cdots & c_{2m}\\ \vdots & \vdots & & \vdots\\ c_{m1} & c_{m2} & \cdots & c_{mm} \end{pmatrix} \tag{11.9}$$

式中，$\boldsymbol{A}^{-1}$ 是一个 m 阶的对称矩阵(symmetric matrix)，即有 $c_{ij}=c_{ji}$，由于 $\boldsymbol{A}^{-1}$ 是 A 的逆矩阵，故有

$$\boldsymbol{A}^{-1}\boldsymbol{A}=\boldsymbol{I} \tag{11.10}$$

其中 $\boldsymbol{I}$ 为单位矩阵(identity matrix)，即

$$\boldsymbol{I}=\begin{pmatrix} 1 & 0 & \cdots & 0\\ 0 & 1 & \cdots & 0\\ \vdots & \vdots & & \vdots\\ 0 & 0 & \cdots & 1 \end{pmatrix} \tag{11.11}$$

式(11.8)两边同乘以 $\boldsymbol{A}^{-1}$，可得

$$\boldsymbol{b}=\boldsymbol{A}^{-1}\boldsymbol{K} \tag{11.12}$$

即

$$\begin{pmatrix} b_1 \\ b_2 \\ \vdots \\ b_m \end{pmatrix} = \begin{pmatrix} c_{11} & c_{12} & \cdots & c_{1m} \\ c_{21} & c_{22} & \cdots & c_{2m} \\ \vdots & \vdots & & \vdots \\ c_{m1} & c_{m2} & \cdots & c_{mm} \end{pmatrix} \times \begin{pmatrix} SP_{1y} \\ SP_{2y} \\ \vdots \\ SP_{my} \end{pmatrix} \tag{11.13}$$

由此可见，求算偏回归系数建立多元线性回归方程，首先要解出系数矩阵 $\boldsymbol{A}$ 的逆矩阵 $\boldsymbol{A}^{-1}$，然后由 $\boldsymbol{A}^{-1}$ 求出 b_i 和 a。$\boldsymbol{A}^{-1}$ 可采用表解法求得，现举一例，说明其具体方法。

【例 11.1】 表 11-1 是广西玉林地区 1956 ～ 1963 年三化螟越冬虫口密度(头 /667m² 取其对数为 x_1)、3 ～ 4 月日平均降水量(x_2，mm) 和降水天数(x_3，d) 与第一代虫口密度(头 /667m²，取其对数为 y)，试建立多元回归方程。

表 11-1　三化螟越冬虫口密度、3～4 月日平均降水量、降水天数与第一代幼虫发生量

年份	越冬虫口密度		3 ～ 4 月日平均降水量(x_2)	3 ～ 4 月降水天数(x_3)	第一代幼虫虫口密度	
	头 /667m²	对数值(x_1)			头 /667m²	对数值(y)
1956	637	2.80	1.9	32	366	2.56
1957	1063	3.03	4.6	38	213	2.33
1958	1492	3.17	1.6	18	256	3.35
1959	854	2.93	7.8	38	36	1.56
1960	263	2.42	2.2	27	178	2.25
1961	43	1.63	5.2	33	10	1.00
1962	786	2.90	2.0	29	1262	3.10
1963	525	2.72	1.4	25	299	2.48

根据表 11-1 数据，其计算过程如下。

(1)计算回归分析的一、二级数据。

一级数据：$\sum x_1 = 21.60$　$\sum x_2 = 26.7$　$\sum x_3 = 240$

$\sum y = 18.63$　$\sum x_1^2 = 59.9764$　$\sum x_2^2 = 126.01$

$\sum x_3^2 = 7520$　$\sum y^2 = 47.4615$　$\sum x_1 x_2 = 70.592$

$\sum x_1 x_3 = 644.37$　$\sum x_2 x_3 = 884.8$　$\sum x_1 y = 52.2288$

$\sum x_2 y = 52.932$　$\sum x_3 y = 535.69$　$n = 8$

二级数据：$SS_1 = 1.6564$　$SS_2 = 36.89875$　$SS_3 = 320$

$SS_y = 4.0769$　$SP_{12} = -1.498$　$SP_{13} = -3.63$

$SP_{23} = 83.8$　$SP_{1y} = 1.9278$　$SP_{2y} = -9.24562$

$SP_{3y} = -23.21$　$\bar{x}_1 = 2.70$　$\bar{x}_2 = 3.3375$

$\bar{x}_3 = 30$　$\bar{y} = 2.32875$

(2) 根据式(11.6) 建立三元正规方程组。

$$\begin{cases} 1.65640b_1 - 1.49800b_2 - 3.63000b_3 = 1.92780 \\ -1.49800b_1 + 36.89875b_2 + 83.80000b_3 = -9.24562 \\ -3.63000b_1 + 83.80000b_2 + 320.00000b_3 = -23.21000 \end{cases}$$

其系数矩阵 $\boldsymbol{A}$ 为

$$\boldsymbol{A} = \begin{pmatrix} 1.65640 & -1.49800 & -3.63000 \\ -1.49800 & 36.89875 & 83.80000 \\ -3.63000 & 83.80000 & 320.00000 \end{pmatrix}$$

(3)利用表解法求系数矩阵的逆矩阵 $\boldsymbol{A}^{-1}$(表 11-2)。

表 11-2　表 11-1 资料 $\boldsymbol{A}^{-1}$ 的求解

说明	(i) \ (j)	1	2	3	K_1	K_2	K_3
算阵 $\boldsymbol{A}$ (a_{ij})	1	1.65640	−1.49800	−3.63000	1	0	0
	2	−1.49800	36.89875	83.80000	0	1	0
	3	−3.63000	83.80000	320.00000	0	0	1
算阵 $\boldsymbol{B}$ (b_{ij})	1	1.656400	−0.904371	−2.191500	0.603719	0	0
	2	−1.498000	35.544000	2.265280	0.025444	0.028134	0
	3	−3.630000	80.517140	129.651000	0.001102	−0.017472	0.007713
$\boldsymbol{A}^{-1}$ (c_{ij})	1	0.626887	0.022948	0.001102			
	2	0.022948	0.067713	−0.017472			
	3	0.001102	−0.017472	0.007713			

第一步，将系数矩阵抄入算阵 $\boldsymbol{A}$，将其右边的 K_1、K_2、K_3 列入一个单位矩阵。

第二步，由算阵 $\boldsymbol{A}$ 计算算阵 $\boldsymbol{B}$ 的各个值，其算法按 b_{ij} 所处位置不同分为两种类型。

类型Ⅰ：是 $\boldsymbol{B}$ 阵主对角线及主对角线以下（$i \geqslant j$）的元素，b_{ij} 等于 a_{ij} 减去 b_{ij} 所在行左边（次序由左到右）的 $b_{i.}$ 与所在列上边（由上向下）的 $b_{.j}$ 的依次乘积和，即

$$b_{ij} = a_{ij} - \sum b_{i.}b_{.j} \tag{11.14}$$

当 b_{ij} 左边或上边无数字时，则视为 0。

类型Ⅱ：是 $\boldsymbol{B}$ 阵主对角线以上（$i < j$）的元素，b_{ij} 等于 a_{ij} 减去所在行左边的 $b_{i.}$ 与所在列上边的 $b_{.j}$ 的依次乘积和除以主对角线元素 b_{ii}，即

$$b_{ij} = \frac{a_{ij} - \sum b_{i.}b_{.j}}{b_{ii}} \tag{11.15}$$

$\boldsymbol{B}$ 阵第 1 列元素 b_{i1} 属于类型Ⅰ，由于其左边无数字，故 $b_{i.}=0$，$\sum b_{i.}b_{.j}=0$，从而有 $b_{i1}=a_{i1}$。其余按两种类型一般求法计算。

因而 $\boldsymbol{B}$ 阵的数值计算如下：

$$b_{11} = a_{11} = 1.656400$$

$$b_{21} = a_{21} = -1.498000$$

$$b_{31} = a_{31} = -3.630000$$

$$b_{12} = \frac{a_{12}}{b_{11}} = \frac{-1.49800}{1.656400} = -0.904371$$

$$b_{13}=\frac{a_{13}}{b_{11}}=\frac{-3.63000}{1.656400}=-2.191500$$

$$b_{1K_1}=\frac{a_{1K_1}}{b_{11}}=\frac{1}{1.656400}=0.603719$$

$$b_{1K_2}=\frac{a_{1K_2}}{b_{11}}=\frac{0}{1.656400}=0$$

$$b_{1K_3}=\frac{a_{1K_3}}{b_{11}}=\frac{0}{1.656400}=0$$

$$b_{22}=a_{22}-b_{21}b_{12}=36.89875-(-1.498000)\times(-0.904371)$$
$$=35.544000$$

$$b_{32}=a_{32}-b_{31}b_{12}=83.80000-(-3.630000)\times(-0.9044371)$$
$$=80.517140$$

$$b_{23}=\frac{a_{23}-b_{21}b_{13}}{b_{22}}=\frac{83.80000-(-1.49800)\times(-2.191500)}{35.544000}$$
$$=2.265280$$

$$b_{33}=a_{33}-b_{31}b_{13}-b_{32}b_{23}$$
$$=320.00000-(-3.630000)\times(-2.191500)-80.517000\times2.2652800$$
$$=139.651000$$

$$b_{2K_1}=\frac{a_{2K_1}-b_{21}b_{1K_1}}{b_{22}}=\frac{0-(-1.498000)\times0.603719}{35.544000}=0.025444$$

$$b_{3K_1}=\frac{a_{3K_1}-b_{31}b_{1K_1}-b_{32}b_{2K_1}}{b_{33}}$$
$$=\frac{0-(-3.630000)\times0.603719-80.517140\times0.025444}{129.651000}$$
$$=0.001102$$

$$b_{2K_2}=\frac{a_{2K_2}-b_{21}b_{1K_2}}{b_{22}}=\frac{1-(-1.498000)\times0}{35.544000}=0.028134$$

$$b_{3K_2}=\frac{a_{3K_2}-b_{31}b_{1K_2}-b_{32}b_{2K_2}}{b_{33}}$$
$$=\frac{0-(3.630000)\times0-80.51714\times0.028134}{129.651000}=-0.017472$$

$$b_{2K_3}=\frac{a_{2K_3}-b_{21}b_{1K_3}}{b_{22}}=\frac{0-(-1.498000)\times0}{35.544000}=0$$

$$b_{3K_3}=\frac{a_{3K_3}-b_{31}b_{1K_3}-b_{32}b_{2K_3}}{b_{33}}=\frac{1-(3.630000)\times0-80.517000\times0}{129.65100}$$
$$=0.007713$$

第三步，计算逆矩阵 $\boldsymbol{A}^{-1}$ 各元素 c_{ij} 值，可由矩阵 $\boldsymbol{B}$ 和 K_1,K_2,K_3 直接解得 c_{ij}。

a. 由算阵 $\boldsymbol{B}$ 主对角线上方元素和 K_1 得

$$\begin{cases}c_{11}-0.904371c_{12}-2.191500c_{13}=0.603719\\ c_{12}+2.265280c_{13}=0.025444\\ c_{13}=0.001102\end{cases}$$

解之，得：

$$c_{13}=b_{3K_1}=0.001102$$
$$c_{12}=b_{2K_1}-b_{23}c_{13}=0.025444-2.26528\times 0.001102=0.022948$$
$$\begin{aligned}c_{11}&=b_{1K_1}-b_{12}c_{12}-b_{13}c_{13}\\&=0.603719-(-0.904371)\times 0.022948-(-2.191500)\times 0.001102\\&=0.626887\end{aligned}$$

b. 由算阵 $\boldsymbol{B}$ 主对角线上方元素和 K_2 得

$$\begin{cases}c_{21}-0.904371c_{22}-2.191500c_{23}=0\\c_{22}+2.265280c_{23}=0.028134\\c_{23}=-0.017472\end{cases}$$

解之，得

$$c_{23}=b_{3K_2}=-0.017472$$
$$c_{22}=b_{2K_2}-b_{23}c_{23}=0.028134-2.265280\times(-0.017472)=0.067713$$
$$\begin{aligned}c_{21}&=b_{1K_2}-b_{12}c_{22}-b_{13}c_{23}\\&=0-(-0.904371)\times 0.067713-(-2.191500)\times(-0.017472)\\&=0.022948\end{aligned}$$

c. 由算阵 $\boldsymbol{B}$ 主对角线上方元素和 K_3 得

$$\begin{cases}c_{31}-0.904371c_{32}-2.191500c_{33}=0\\c_{32}+2.265280c_{33}=0\\c_{33}=0.007713\end{cases}$$

解之，得

$$c_{33}=b_{3K_3}=0.007713$$
$$c_{32}=b_{2K_3}-b_{23}c_{33}=0-2.265280\times 0.007713=-0.017472$$
$$\begin{aligned}c_{31}&=b_{1K_3}-b_{12}c_{32}-b_{13}c_{33}\\&=0-(-0.904371)\times(-0.017472)-(-2.191500)\times 0.007713\\&=0.001102\end{aligned}$$

因而，可以得到

$$\boldsymbol{A}^{-1}=\begin{pmatrix}0.626887 & 0.022948 & 0.001102\\0.022948 & 0.067713 & -0.017472\\0.001102 & -0.017472 & 0.007713\end{pmatrix}$$

(4)求偏回归系数和回归截距，建立多元线性回归方程。根据式(11.13)，有

$$\begin{pmatrix}b_1\\b_2\\b_3\end{pmatrix}=\begin{pmatrix}0.626887 & 0.022948 & 0.001102\\0.022948 & 0.067713 & -0.017472\\0.001102 & -0.017472 & 0.007713\end{pmatrix}\begin{pmatrix}1.92780\\-9.24562\\-23.21000\end{pmatrix}$$

解之，得：$b_1=0.9708$，$b_2=-0.1763$，$b_3=-0.01534$。因此，由式(11.5)得

$$\begin{aligned}a&=\bar{y}-b_1\bar{x}_1-b_2\bar{x}_2-b_3\bar{x}_3\\&=2.32875-0.9708\times 2.70-(-0.1763)\times 3.3375-(-0.01534)\times 30\\&=0.7562\end{aligned}$$

把 a、b_1、b_2、b_3 代入式(11.4),得出三化螟第一代幼虫虫口密度三元线性回归方程:

$$\hat{y}=0.7562+0.9708x_1-0.1763x_2-0.01534x_3$$

三、多元线性回归的假设检验和置信区间

(一) 多元线性回归方程的估计标准误

在建立多元线性回归方程时,由于实际观测值 y 与多元回归方程的点估计值 $\hat{y}$ 存在差异,其差值的平方和称为多元回归方程的离回归平方和,记为 $Q_{y/12\cdots m}$。因为在计算多元回归方程时,已用去 $a,b_1,b_2,\cdots,b_m$ 共 $m+1$ 个统计数,因而 $Q_{y/12\cdots m}$ 的自由度 $df=n-(m+1)=n-m-1$,因此,多元回归方程的估计标准误可定义为

$$s_{y/12\cdots m}=\sqrt{\frac{Q_{y/12\cdots m}}{n-m-1}} \tag{11.16}$$

与直线回归分析类似,多元回归中依变量 y 的总平方和(SS_y)也可分解为离回归平方和与回归平方和($U_{y/12\cdots m}$),即

$$Q_{y/12\cdots m}=SS_y-U_{y/12\cdots m} \tag{11.17}$$

$$U_{y/12\cdots m}=b_1SP_{1y}+b_2SP_{2y}+\cdots+b_mSP_{my} \tag{11.18}$$

【例 11.2】 试计算例 11.1 所建立的三元一次回归方程的估计标准误。

前面已经求得:$b_1=0.9708$,$b_2=-0.1763$,$b_3=-0.01534$,$SS_y=4.0769$,$SP_{1y}=1.9278$,$SP_{2y}=-9.24562$,$SP_{3y}=-23.21$,因而有

$$\begin{aligned}U_{y/123}&=b_1SP_{1y}+b_2SP_{2y}+b_3SP_{3y}\\&=0.9708\times1.9278+(-0.1763)\times(-9.24562)\\&\quad+(-0.01534)\times(-23.21)=3.8576\end{aligned}$$

$$Q_{y/123}=SS_y-U_{y/123}=4.0769-3.8576=0.2193$$

$$s_{y/123}=\sqrt{\frac{Q_{y/123}}{n-m-1}}=\sqrt{\frac{0.2193}{8-3-1}}=0.2341$$

(二) 多元线性回归方程的假设检验

多元线性回归关系假设检验的原理和方法与直线回归关系的假设检验是一样的。其假设为 $H_0:\beta_1=\beta_2=\cdots=\beta_m=0$;$H_A:\beta_1,\beta_2,\cdots,\beta_m$ 不全为 0。可通过 F 检验来实现:

$$F=\frac{\dfrac{U_{y/12\cdots m}}{m}}{\dfrac{Q_{y/12\cdots m}}{n-m-1}} \tag{11.19}$$

式(11.19)中,分子自由度 $df_1=m$,分母自由度 $df_2=n-m-1$。

【例 11.3】 试对例 11.1 资料作多元线性回归关系的假设检验。

根据前面已算得的结果,列方差分析表(表 11-3)。

表 11-3　例 11.1 资料三元线性回归关系的方差分析

变异来源	df	SS	s^2	F	$F_{0.05}$	$F_{0.01}$
回归	3	3.8576	1.2859	23.4653**	6.59	16.69
离回归	4	0.2193	0.0548			
总变异	7	4.0769				

$$F=\frac{\frac{U_{y/123}}{m}}{\frac{Q_{y/123}}{n-m-1}}=\frac{\frac{3.8576}{3}}{\frac{0.2193}{8-3-1}}=23.4653^{**}$$

由于所得 $F>F_{0.01}$，故应拒绝 H_0，接受 H_A，所作推断为：第一代幼虫虫口密度依越冬虫口密度、3～4 月日平均降水量和 3～4 月降水天数的三元线性回归方程达到极显著水平。

这里应注意两个问题：第一，多元线性回归关系显著不排斥有更合理的多元非线性回归方程的存在；第二，多元线性回归关系显著不排斥其中存在着与依变量 y 无线性关系的自变量，因此有必要对各偏回归系数逐个进行假设检验。因为 H_A 是 $\beta_1,\beta_2,\cdots,\beta_m$ 不全等于 0，它并未肯定所有的 $\beta_i\neq 0$。所以必须逐一对各偏回归系数作假设检验，才能发现和剔除 $\beta=0$ 的自变量。一般来说，只有当多元回归方程自变量的偏回归系数均达到显著时，多元回归检验的 F 值才有确定的意义。

（三）偏回归系数的假设检验

偏回归系数的假设检验是分别计算各偏回归系数 b_i 来自 $\beta_i=0$ 的总体的概率。所作的假设为 $H_0:\beta_i=0$；$H_A:\beta_i\neq 0$。偏回归系数的假设检验方法有 t 检验和 F 检验两种。

1. t 检验

偏回归系数 b_i 的标准误为

$$s_{b_i}=s_{y/12\cdots m}\sqrt{c_{ii}} \tag{11.20}$$

由于 $\frac{b_i-\beta_i}{s_{b_i}}$ 符合 $df=n-m-1$ 的 t 分布，故在 $H_0:\beta_i=0$ 的假设下，由

$$t=\frac{b_i}{s_{b_i}} \tag{11.21}$$

可知 b_i 抽自 β_i 的总体的概率。

2. F 检验

在多元回归中，$U_{y/12\cdots m}$ 总是随着 m 的增多而有所增大，而绝不会减少（这是由于应用最小平方和法的缘故），如果去掉一个自变量 x_i，则 $U_{y/12\cdots(m-1)}$ 要比 $U_{y/12\cdots m}$ 减少 U_i：

$$U_i=\frac{b_i^2}{c_{ii}} \tag{11.22}$$

这个 U_i 称为 y 在 x_i 上的偏回归平方和。显然，U_i 就是因添入 x_i 而增加的回归部分平方和，具有 1 个自由度。因此，由

$$F=\frac{U_i}{\frac{Q_{y/12\cdots m}}{n-m-1}} \tag{11.23}$$

可确定 b_i 来自 $\beta_i=0$ 的总体的概率。

【例 11.4】 试检验例 11.1 资料所建立的多元回归方程中的 3 个偏回归系数($b_1=0.9708, b_2=-0.1763, b_3=-0.01534$)的显著性。

t 检验:由前面计算已知 $c_{11}=0.626887, c_{22}=0.067713, c_{33}=0.007713, s_{y/123}=0.2341$。

对 b_1:　$s_{b_1}=s_{y/123}\sqrt{c_{11}}=0.2341\times\sqrt{0.626887}=0.1854$

$$t=\frac{b_1}{s_{b_1}}=\frac{0.9708}{0.1854}=5.2362^{**}$$

对 b_2:　$s_{b_2}=s_{y/123}\sqrt{c_{22}}=0.2341\times\sqrt{0.067713}=0.06092$

$$t=\frac{b_2}{s_{b_2}}=\frac{-0.1763}{0.06092}=-2.8940^{*}$$

对 b_3:　$s_{b_3}=s_{y/123}\sqrt{c_{33}}=0.2341\times\sqrt{0.007713}=0.02056$

$$t=\frac{b_3}{s_{b_3}}=\frac{-0.01534}{0.02056}=-0.7461$$

查附表 3 得 $t_{0.05(4)}=2.776, t_{0.01(4)}=4.604$,由于检验 b_1 的 t 值大于 $t_{0.01}$,b_2 的 t 值绝对值大于 $t_{0.05}$,故否定 $H_0:\beta_1=0$ 和 $H_0:\beta_2=0$;由于检验 b_3 的 t 值绝对值小于 $t_{0.05}$,故接受 $H_0:\beta_3=0$。推断:越冬虫口密度对三化螟第一代幼虫虫口密度的偏回归系数达极显著水平,3 ~4 月日平均降水量对三化螟第一代幼虫虫口密度的偏回归系数达显著水平,3 ~ 4 月降水天数与三化螟第一代幼虫虫口密度偏回归系数未达显著。

F 检验:首先由式(11.22)计算各自变量的偏回归平方和。

因 x_1 的偏回归平方和:　$U_1=\frac{b_1^2}{c_{11}}=\frac{0.9708^2}{0.626887}=1.5034$

因 x_2 的偏回归平方和:　$U_2=\frac{b_2^2}{c_{22}}=\frac{(-0.1763)^2}{0.067713}=0.4590$

因 x_3 的偏回归平方和:　$U_3=\frac{b_3^2}{c_{33}}=\frac{(-0.01534)^2}{0.007713}=0.0305$

因此得方差分析表(表 11-4)。从表 11-4 中可以看出,因 x_1 的偏回归系数的 F 值达到了极显著水平,x_2 的偏回归系数的 F 值达显著水平,x_3 的偏回归系数的 F 值不显著,这与上述的 t 检验结果是相同的。

表 11-4　例 11.1 资料偏回归关系的方差分析

变异来源	df	SS	s^2	F	$F_{0.05}$	$F_{0.01}$
三元线性回归	3	3.8576	1.2859	23.4653**	6.59	16.69
因 x_1 的偏回归	1	1.5034	1.5034	27.4343**	7.71	21.20
因 x_2 的偏回归	1	0.4590	0.4590	8.3759*	7.71	21.20
因 x_3 的偏回归	1	0.0305	0.0305	0.5566	7.71	21.20
离回归	4	0.2193	0.0548			
总变异	8	4.0769				

这里也有两个问题值得注意。

(1) 由于对各偏回归系数的 F 检验中分子自由度为 1，故其平方根值等于相应的 t 值绝对值，数学证明如下：

$$\sqrt{F}=\sqrt{\frac{U_{p_i}}{\frac{Q_{y/12\cdots m}}{n-m-1}}}=\sqrt{\frac{\frac{b_i^2}{c_{ii}}}{s_{y/12\cdots m}^2}}=\sqrt{\frac{b_i^2}{s_{b_i}^2}}=|t| \tag{11.24}$$

从以上计算的各偏回归系数 t 值和 F 值来看，其各自的 t^2 值和 F 值基本一样(其误差是四舍五入所致)，所以对偏回归系数的 t 检验和 F 检验结果是一样的，实际应用时可任选一种。

(2) 在表 11-4 中，3 个偏回归平方和的总和不等于三元回归的平方和，这并非计算错误，它表明该多元回归方程中的各自变量并非完全独立，即 $r_{ij}\neq 0$。一般而言，在 m 元线性回归中，如果各自变量间没有相关，即 $r_{ij}=0(i,j=1,2,\cdots,m)$，则

$$U_{y/12\cdots m}=\sum_{i=1}^{m}U_i \tag{11.25}$$

但是，如果各自变量间有着不同程度的相关，即 $r_{ij}\neq 0$，则

$$U_{y/12\cdots m}\neq\sum_{i=1}^{m}U_i \tag{11.26}$$

这是由于自变量间的相关使其对 y 的作用发生了改变。以两个自变量 x_1 和 x_2 为例，若其相关系数等于 0，即 $r_{12}=0$，则一定是

$$U_{y/12}=U_1+U_2 \tag{11.27}$$

若 $r_{12}>0$，则

$$U_{y/12}>U_1+U_2 \tag{11.28}$$

若 $r_{12}<0$，则

$$U_{y/12}<U_1+U_2 \tag{11.29}$$

(四) 多元线性回归的区间估计

多元线性回归中依变量 y 的估计一般有两种：一种是对各自变量的一组取值所对应的 y 总体平均数 $\mu_{y/12\cdots m}$ 的估计；另一种是对各自变量的一组取值所对应的单个 y 的估计。$\mu_{y/12\cdots m}$ 的置信区间可用下式估计：

$$\hat{y}\pm t_{\alpha(n-m-1)}s_{y/12\cdots m}\sqrt{\frac{1}{n}+\sum_i c_{ii}(x_i-\bar{x}_i)^2+2\sum_{i<j}c_{ij}(x_i-\bar{x}_i)(x_j-\bar{x}_j)} \tag{11.30}$$

单个 $\hat{y}$ 的置信区间可用下式估计：

$$\hat{y}\pm t_{\alpha(n-m-1)}s_{y/12\cdots m}\sqrt{1+\frac{1}{n}+\sum_i c_{ii}(x_i-\bar{x}_i)^2+2\sum_{i<j}c_{ij}(x_i-\bar{x}_i)(x_j-\bar{x}_j)} \tag{11.31}$$

【例 11.5】 对例 11.1 资料在 95% 的置信度下估计出当 $x_1=2.5$、$x_2=3.0$、$x_3=30$ 时，三化螟第一代幼虫虫口密度的置信区间；若某年份的 3 个影响因素为这些值时，求其

第一代幼虫虫口密度的置信区间。

首先将 $x_1=2.5$、$x_2=3.0$、$x_3=30$ 代入第一代幼虫虫口密度方程，得

$$\hat{y}=0.7562+0.9708\times 2.5-0.1763\times 3.0-0.01534\times 30=2.1941$$

$$\sum c_{ii}(x_i-\bar{x}_i)^2=0.626887\times(2.5-2.70)^2+0.067713\times(3.0-3.3375)^2+0.007713\times(30-30)^2=0.03279$$

$$2\sum_{i<j}c_{ij}(x_i-\bar{x}_i)(x_j-\bar{x}_j)=2\times 0.022948\times(2.5-2.70)\times(3.0-3.3375)+2\times 0.001102\times(2.5-2.70)\times(30-30)+2\times(-0.017472)\times(3.0-3.3375)\times(30-30)=0.003098$$

查 t 值表，得 $t_{0.05(8-3-1)}=2.776$，因此有

$$\hat{y}\pm t_{0.05}s_{y/123}\sqrt{\frac{1}{n}+\sum_i c_{ii}(x_i-\bar{x}_i)^2+2\sum_{i<j}c_{ij}(x_i-\bar{x}_i)(x_j-\bar{x}_j)}$$

$$=2.1941\pm 2.776\times 0.2341\times\sqrt{\frac{1}{8}+0.03279+0.003098}$$

$$=2.1941\pm 0.2607$$

$$\hat{y}\pm t_{0.05}s_{y/123}\sqrt{1+\frac{1}{n}+\sum_i c_{ii}(x_i-\bar{x}_i)^2+2\sum_{i<j}c_{ij}(x_i-\bar{x}_i)(x_j-\bar{x}_j)}$$

$$=2.1941\pm 2.776\times 0.2341\times\sqrt{1+\frac{1}{8}+0.03279+0.003098}$$

$$=2.1941\pm 0.7002$$

即当 $x_1=2.5$、$x_2=3.0$、$x_3=30$ 时，三化螟第一代幼虫虫口密度(对数值)的95%置信区间为(1.9334，2.4548)；而当某年份的影响因素为这些值时，该年份三化螟第一代幼虫虫口密度(对数值)95%置信区间为(1.4939，2.8943)。如果用三化螟第一代幼虫虫口密度的绝对数(头/667m²)表示，需将上述其上、下限进行转换，即将上限值作为10的指数，则当 $x_1=2.5$、$x_2=3.0$、$x_3=30$ 时，三化螟第一代幼虫虫口密度(绝对数，头/667m²)的95%置信区间为(85.7828，284.9706)；而当某年份的影响因素为这些值时，该年份三化螟第一代幼虫虫口密度(绝对数，头/667m²)95%置信区间为(31.1817，783.9710)。

第二节　多元相关分析

一、多元相关分析

多元相关或复相关(multiple correlation)为 m 个自变量和依变量的总相关。多元相关系数又称为复相关系数(multiple correlation coefficient)，它是表示多个自变量与依变量总的密切程度的量值，以 $R_{y/12\cdots m}$ 表示，称之为依变量 y 与 m 个自变量的多元相关系数。由于 m 个自变量对 y 的回归平方和为 $U_{y/12\cdots m}$，$U_{y/12\cdots m}$ 占 y 平方和 SS_y 的比例越大，则表明 y 和 m 个自变量的总相关越密切，因此定义 $R_{y/12\cdots m}$ 为

$$R_{y/12\cdots m}=\sqrt{\frac{U_{y/12\cdots m}}{SS_y}} \tag{11.32}$$

即多元相关系数为多元回归平方和与总变异平方和之比的平方根。由于 $U_{y/12\cdots m}$ 为 SS_y 的一部分，故 $R_{y/12\cdots m}$ 的取值区间为[0,1]。在一定的自由度下，$R_{y/12\cdots m}$ 的值越接近于 1，总相关越密切；越接近于 0，总相关越不密切。由于多元回归平方和一定大于任意一个自变量对 y 的回归平方和，故多元相关系数一定比各自变量和 y 的简单相关系数的绝对值都大。为方便起见，多元相关系数 $R_{y/12\cdots m}$ 简记为 R。

多元相关系数的假设检验用 F 检验，而不能用 t 检验，检验的假设为 $H_0:\rho=0$，对 $H_A:\rho\neq 0$。其 F 值为

$$F=\frac{df_2R^2}{df_1(1-R^2)} \tag{11.33}$$

式中，$df_1=m$、$df_2=n-m-1$。

多元相关系数的显著性与多元回归方程的显著性一致，即 $R_{y/12\cdots m}$ 显著，多元回归方程必显著。对于同一资料，多元相关与多元回归的假设检验只需要进行一种。

由于在 $df_1=m$、$df_2=n-m-1$ 一定时，给定显著水平下 α 的 F 值也一定，所以将式(11.33)移项整理，可得显著水平为 α 时的临界 R_α 值：

$$R_\alpha=\sqrt{\frac{df_1F_\alpha}{df_1F_\alpha+df_2}} \tag{11.34}$$

【例 11.6】 试计算表 11-1 所给资料中 y 与 x_1、x_2、x_3 的多元相关系数并进行假设检验。

已知 $SS_y=4.0769$，$U_{y/123}=3.8576$，根据式(11.32)和式(11.33)，则有

$$R_{y/123}=\sqrt{\frac{U_{y/123}}{SS_y}}=\sqrt{\frac{3.8576}{4.0769}}=0.9727$$

$$F=\frac{df_2R^2}{df_1(1-R^2)}=\frac{4\times 0.9727^2}{3\times(1-0.9727^2)}=23.4246^{**}$$

查附表 5，$F_{0.01(3,4)}=16.69$，所以接受 $H_A:\rho\neq 0$。推断：$R_{y/123}$ 达极显著水平。

复相关系数 $R_{y/123}=0.9727$ 的显著性也可用临界 R_α 值检验：

$$R_{0.01}=\sqrt{\frac{df_1F_{0.01}}{df_1F_{0.01}+df_2}}=\sqrt{\frac{3\times 16.69}{3\times 16.69+4}}=0.962$$

实得 $R_{y/123}=0.9727$，大于 $R_{0.01}=0.962$，所以 $R_{y/123}$ 达极显著水平。

R_α 也可按自由度 $df=n-m-1$ 和变量的个数 $M=m+1$ 查附表 8，而不必直接计算。本例 $df=4$，$M=3+1=4$，查附表 8，$R_{0.01}=0.962$，与上述计算结果一致。

多元相关系数的平方称为决定系数(coefficient of determination)。它是多元回归平方和占 y 的总变异平方和的比率。上例的决定系数为 $R^2_{y/123}=0.9461$，表示表 11-1 资料的三化螟第一代幼虫虫口密度有 94.61% 可由越冬虫口密度、3～4 月日平均降水量和 3～4 月降水天数的变异决定。

二、偏相关分析

在生物学研究中，任何两个变量间的相关经常受到其他变量的影响。为消除这些影响，使两个变量间的相关关系能得到真实的反映，必须在排除其他变量影响的情况下进行

两个变量间的相关分析,这种排除其他变量影响下的两个变量间的相关分析称为偏相关分析(partial correlation analysis)。在其他变量都保持一定时,表示指定的两个变量之间相关密切程度的量值称为偏相关系数(partial correlation coefficient)。

偏相关系数用 r 加下标表示。例如,有 3 个变量 x_1、x_2、x_3,则 $r_{12\cdot3}$ 表示 x_3 保持一定时,x_1 和 x_2 的偏相关系数;$r_{13\cdot2}$ 表示 x_2 保持一定时,x_1 和 x_3 的偏相关系数;$r_{23\cdot1}$ 表示 x_1 保持一定时,x_2 和 x_3 的偏相关系数。同理可推 4 个变量、5 个变量等偏相关系数的表示方法。偏相关系数的取值范围和简单相关系数一样,也是[−1,1]。

(一) 偏相关系数的一般解法

其求解过程可分 3 步。

第一步,计算由简单相关系数构成的相关矩阵 $\boldsymbol{R}$:

$$\boldsymbol{R}=\begin{pmatrix} r_{11} & r_{12} & \cdots & r_{1m} \\ r_{21} & r_{22} & \cdots & r_{2m} \\ \vdots & \vdots & & \vdots \\ r_{m1} & r_{m2} & \cdots & r_{mm} \end{pmatrix}$$

第二步,求其逆矩阵 $\boldsymbol{R}^{-1}$:

$$\boldsymbol{R}^{-1}=\begin{pmatrix} c_{11} & c_{12} & \cdots & c_{1m} \\ c_{21} & c_{22} & \cdots & c_{2m} \\ \vdots & \vdots & & \vdots \\ c_{m1} & c_{m2} & \cdots & c_{mm} \end{pmatrix}$$

第三步,计算偏相关系数 $r_{ij\cdot}$:

$$r_{ij\cdot}=\frac{-c_{ij}}{\sqrt{c_{ii}c_{jj}}} \tag{11.35}$$

【例 11.7】 试计算例 11.1 资料变量 x_1、x_2、x_3 和 y 的偏相关系数。

(1) 求相关矩阵 $\boldsymbol{R}$:

$$\boldsymbol{R}=\begin{pmatrix} 1 & -0.191612 & -0.157670 & 0.741847 \\ -0.191612 & 1 & 0.771193 & -0.753814 \\ -0.157670 & 0.771193 & 1 & -0.642592 \\ 0.741847 & -0.753814 & -0.642592 & 1 \end{pmatrix}$$

(2) 用表解法求相关矩阵的逆矩阵 $\boldsymbol{R}^{-1}$(表 11-5):

表 11-5　例 11.1 资料(设 $y=x_4$)相关矩阵的逆矩阵计算

说明	列 / 行	1	2	3	4	K_1	K_2	K_3	K_4
算阵 $\boldsymbol{A}$	1	1	−0.191612	−0.157670	0.741847	1	0	0	0
	2	−0.191612	1	0.771193	−0.753814	0	1	0	0
	3	−0.157670	0.771193	1	−0.642592	0	0	1	0
	4	0.741847	−0.753814	−0.642592	1	0	0	0	1

续表

说明	行＼列	1	2	3	4	K_1	K_2	K_3	K_4
算阵 B	1	1	−0.191612	−0.157670	0.741847	1	0	0	0
	2	−0.191612	0.963285	0.769224	−0.634981	0.198915	1.038115	0	0
	3	−0.157670	0.740982	0.405160	−0.136035	0.025367	−1.898570	2.468163	0
	4	0.741847	−0.611667	−0.055116	0.053769	−11.50820	9.863374	2.530020	18.598250
(c_{ij})	1	8.159410	−5.923845	−1.540157	−11.50820				
	2	−5.923845	7.729471	−0.556802	9.863374				
	3	−1.540157	−0.556802	2.812336	2.530020				
	4	−11.50820	9.863374	2.530020	18.598250				

(3) 计算偏相关系数：

$$r_{12\cdot 3y}=\frac{-(-5.923845)}{\sqrt{8.159410\times 7.729471}}=0.7459$$

同理，可以得出：$r_{13\cdot 2y}=0.3215$，$r_{23\cdot 1y}=0.1194$，$r_{1y\cdot 23}=0.9342$，$r_{2y\cdot 13}=-0.8226$，$r_{3y\cdot 12}=-0.3498$。

(二) 偏相关系数的间接解法

当只有3个变量时，可以用简单相关系数间接计算偏相关系数。设3个变量为 x_i、x_j 和 x_k，则 x_k 保持一定时，x_i 和 x_j 间的偏相关系数为

$$r_{ij\cdot k}=\frac{r_{ij}-r_{ik}r_{jk}}{\sqrt{(1-r_{ik}^2)(1-r_{jk}^2)}} \tag{11.36}$$

$r_{ik\cdot j}$ 和 $r_{jk\cdot i}$ 可依此类推。

【例 11.8】 用间接法求例 11.1 资料变量(x_1、x_3 和 y) 间的各偏相关系数。

根据例 11.1 资料的二级数据所计算的各变量间的单相关系数为 $r_{13}=-0.1577$、$r_{1y}=0.7418$、$r_{3y}=-0.6426$，将其代入式(11.36)，有

$$r_{13\cdot y}=\frac{r_{13}-r_{1y}r_{3y}}{\sqrt{(1-r_{1y}^2)(1-r_{3y}^2)}}=\frac{-0.1577-0.7418\times(-0.6426)}{\sqrt{(1-0.7418^2)\times[1-(-0.6429)^2]}}$$
$$=0.6208$$

$$r_{1y\cdot 3}=\frac{r_{1y}-r_{13}r_{3y}}{\sqrt{(1-r_{13}^2)(1-r_{3y}^2)}}=\frac{0.7418-(-0.1577)\times(-0.6426)}{\sqrt{[1-(-0.1577)^2]\times[1-(-0.6426)^2]}}$$
$$=0.8465$$

$$r_{3y\cdot 1}=\frac{r_{3y}-r_{13}r_{1y}}{\sqrt{(1-r_{13}^2)(1-r_{1y}^2)}}=\frac{(-0.6426)-(-0.1577)\times 0.7418}{\sqrt{[1-(-0.1577)^2]\times(1-0.7418^2)}}$$
$$=-0.7937$$

对于4个变量的偏相关系数，也可以用低一级偏相关系数间接进行计算，若4个变量分别为 x_i、x_j、x_k 和 x_l，那么有

$$r_{ij\cdot kl}=\frac{r_{ij\cdot k}-r_{il\cdot k}r_{jl\cdot k}}{\sqrt{(1-r_{il\cdot k}^2)(1-r_{jl\cdot k}^2)}} \tag{11.37}$$

其余依此类推。同理,对于具有 M 个变量的 $M-2$ 级偏相关,其偏相关系数为

$$r_{12\cdot 34\cdots M}=\frac{r_{12\cdot 34\cdots(M-1)}-r_{1M\cdot 34\cdots(M-1)}r_{2M\cdot 34\cdots(M-1)}}{\sqrt{(1-r_{1M\cdot 34\cdots(M-1)}^2)(1-r_{2M\cdot 34\cdots(M-1)}^2)}} \tag{11.38}$$

对于 4 个以上变量的偏相关,虽然可以利用低一级的偏相关系数进行间接计算,但随着变量个数的增加,要计算的简单相关系数和偏相关系数将急剧增加,因而当变量在 4 个以上时宜采用前面介绍的一般解法。

(三) 偏相关系数的假设检验

偏相关系数的假设检验可采用 t 检验,同简单相关系数的假设检验类似,检验的假设为 $H_0:\rho_{ij}=0$,对 $H_A:\rho_{ij}\neq 0$。其 t 值为

$$t=\frac{r_{ij\cdot}}{\sqrt{1-r_{ij\cdot}^2}}\cdot\sqrt{n-M} \tag{11.39}$$

它服从自由度为 $df=n-M=n-m-1$ 的 t 分布。

在实践中,并不需要计算此 t 值,而是将 $r_{ij\cdot}$ 与一定显著水平 α 下的临界 r_α 值进行比较。r_α 临界值的计算可由式(11.39)推出:

$$r_\alpha=\sqrt{\frac{t_\alpha^2}{(n-M)+t_\alpha^2}} \tag{11.40}$$

这些 r_α 值已列入附表 8 的 $M=2$ 列。因此,只需按自由度 $n-M$ 查附表 8,即可得到 $r_{0.05}$ 和 $r_{0.01}$ 的临界值。若实际算得的 $|r_{ij\cdot}|>r_{0.05}$ 或 $r_{0.01}$,则 $r_{ij\cdot}$ 为显著或极显著;若 $|r_{ij\cdot}|<r_{0.05}$,则 $r_{ij\cdot}$ 为不显著。

【例 11.9】 试检验例 11.8 中的 3 个偏相关系数的显著性。

查附表 8,$df=n-M=8-3=5$ 时,$r_{0.05}=0.754$、$r_{0.01}=0.874$。因此,$r_{13\cdot y}=0.6208$ 为不显著,$r_{1y\cdot 3}=0.8465$ 为显著,$r_{3y\cdot 1}=-0.7937$ 为显著。

如果根据式(11.39)计算 t 值,对于 $r_{13\cdot y}$:

$$t=\frac{r_{13\cdot y}}{\sqrt{1-r_{13\cdot y}^2}}\cdot\sqrt{n-M}=\frac{0.6208}{\sqrt{1-0.6208^2}}\times\sqrt{8-3}=1.7707$$

同理可得 $r_{1y\cdot 3}$ 的 $t=3.5554^*$,$r_{3y\cdot 1}$ 的 $t=-2.9175^*$。与 $t_{0.05(5)}=2.571$ 和 $t_{0.01(5)}=4.032$ 相比,$r_{1y\cdot 3}$ 和 $r_{3y\cdot 1}$ 达到显著水平,$r_{13\cdot y}$ 为不显著。其结果与用临界 r_α 值检验完全一样。

(四) 偏相关与简单相关的区别

将例 11.7 中简单相关系数与偏相关系数作比较(表 11-6)可以看出,偏相关系数与简单相关系数不仅数据有异,而且符号也可能不同,如 $r_{12\cdot 3y}=0.7459$、$r_{12}=-0.1916$。这是因为简单相关系数没有排除其他变量的影响,其中混有其他变量的效应。当其他变量与它呈正相关时,便混有正效应,简单相关系数会高于偏相关系数;当其他变量与它呈负相关时,便混有负效应,简单相关系数会低于偏相关系数。所以,偏相关系数与简单相关

系数相比，能排除假象，反映变量间真实的相关密切程度。因此，对于多变量资料，必须采用多元相关分析。

表 11-6　例 11.7 中的偏相关系数 $r_{ij.}$ 和简单相关系数的比较

简单相关系数	偏相关系数
$r_{12} = -0.1916$	$r_{12\cdot 3y} = 0.7459$
$r_{13} = -0.1577$	$r_{13\cdot 2y} = 0.3215$
$r_{1y} = 0.7418^{*}$	$r_{1y\cdot 23} = 0.9342^{**}$
$r_{23} = 0.7712^{*}$	$r_{23\cdot 1y} = 0.1194$
$r_{2y} = -0.7538^{*}$	$r_{2y\cdot 13} = -0.8226^{*}$
$r_{3y} = -0.6426$	$r_{3y\cdot 12} = -0.3498$
$r_{0.05(6)} = 0.707$	$r_{0.05(4)} = 0.811$
$r_{0.01(6)} = 0.834$	$r_{0.01(4)} = 0.917$

思考练习题

习题 11.1　什么叫多元回归？多元线性回归与一元线性回归相比较有何异同？

习题 11.2　什么是复相关系数？其意义是什么？

习题 11.3　抽测某渔场16次放养记录，其中 x_1 是投饵量，x_2 是放养量，y 是鱼产量，单位是kg。结果如下表所示。试求：

x_1	9.5	8.0	9.5	9.8	9.7	13.5	9.5	12.5	9.4	11.4	7.7	8.3	12.5	8.0	6.5	12.9
x_2	1.9	2.0	2.6	2.7	2.0	2.4	2.3	2.2	3.3	2.3	3.6	2.1	2.5	2.4	3.2	1.9
y	7.1	6.4	10.4	10.9	7.0	10.0	7.9	9.3	12.8	7.5	10.3	6.6	9.5	7.7	7.0	9.5

(1) 鱼产量对投饵量、放养量的回归方程和该方程的离回归标准误；

(2) 因 x_1 和 x_2 的偏回归显著性。

习题 11.4　研究水稻穗数(x_1，万穗 /667m^2)、穗粒数(x_2) 与结实率(y，%) 的关系，结果如下表所示。

x_1	16.6	15.9	18.8	19.9	23.5	14.4	16.4	17.3	18.4	19.3	19.9
x_2	146.5	163.5	140.0	122.4	140.0	174.3	145.9	147.5	139.1	126.8	125.2
y	81.3	77.2	78.0	82.6	66.2	77.9	80.4	77.7	79.7	80.6	83.3

(1) 试建立水稻结实率对穗数、穗粒数的回归方程；

(2) 求该方程的离回归标准误并进行 F 检验；

(3) 对各偏回归系数进行显著性检验。

习题 11.5　下表是 20 位 25 ～ 34 岁健康妇女的测试资料，其中 x_1 是三头肌皮褶厚度、x_2 是大腿围、x_3 是中臂长、y 是身体脂肪。试进行多元线性回归分析。

编号	x_1	x_2	x_3	y	编号	x_1	x_2	x_3	y
1	19.5	43.1	29.1	11.9	11	31.1	56.6	30.0	25.4
2	27.7	49.8	28.2	22.8	12	30.4	56.7	28.3	27.2
3	30.7	51.9	37.0	18.7	13	18.7	46.5	23.0	11.7
4	29.8	54.3	31.1	20.1	14	19.7	44.2	28.6	17.8
5	19.1	42.2	30.9	12.9	15	14.6	42.7	21.3	12.8
6	25.6	53.9	23.7	21.7	16	29.5	54.4	30.1	23.9
7	31.4	58.5	27.6	27.1	17	27.7	55.3	25.7	22.6
8	27.9	52.1	30.6	25.4	18	30.2	58.6	24.6	25.4
9	22.1	49.9	23.2	21.3	19	22.7	48.2	27.1	14.8
10	25.5	53.5	24.8	19.3	20	25.2	51.0	27.5	21.1

习题 11.6　先由思考练习题 11.4 资料得到变量间的简单相关系数(r_{12}、r_{1y}、r_{2y})。试求：

(1)y 依 x_1、x_2 的复相关系数；

(2)y 和 x_1、x_2 的偏相关系数，并分析偏相关系数和简单相关系数有何不同？

第十二章

逐步回归与通径分析

本章提要

逐步回归分析方法是针对多个自变量建立最优回归方程的一种统计方法。利用逐步回归获得最优回归方程可通过逐个淘汰不显著自变量、逐个选入显著自变量两种方法来实现。

通径分析是把每个自变量 x_i 与依变量 y 的相关系数分成自变量 x_i 对依变量 y 的直接作用和自变量 x_i 通过其他自变量 x_j 对依变量 y 的间接影响的统计方法。通径系数 P_{iy} 是表示自变量 x_i 对依变量 y 直接作用的统计量，可在偏回归系数的基础上导出，而 x_i 通过其他自变量 x_j 对 y 的间接作用则用 $r_{ij}P_{jy}$ 来表示。

第十一章详细介绍了利用多元线性回归分析和偏相关分析研究多个相关变量间的线性关系。对于一个多变量资料，在很多情况下，往往既包含对依变量 y 具有显著线性效应的自变量，又包含对 y 不具有显著线性效应的自变量。在进行多元线性回归分析时，必须将不具有显著效应的自变量予以舍去，以使所得到的多元线性回归方程中的自变量对依变量 y 均具有显著效应，这样的回归方程称为最优多元线性回归方程(the best multiple linear regression equation)，可通过逐步回归方法建立最优回归方程。只有用最优回归方程才能比较简洁准确地分析和预测依变量 y 的反应。

通径分析是另一种研究多个相关变量间线性关系的统计方法，具有精确、直观的特点。1921 年，S. Wright 首先提出了通径系数的概念，后经不断完善和改进，通径分析已在研究遗传相关、遗传力和确定选择指数、性状的直接作用及间接作用等方面广泛应用。

第一节　逐步回归分析

利用逐步回归(stepwise regression)分析方法获得最优回归方程(the best regression equation)可以通过两个基本途径完成。

(1) 从 m 元回归分析开始，每步舍去一个不显著且偏回归平方和为最小的自变量，在每次舍去一个偏回归不显著且平方和最小的自变量之后，需对回归方程和各自变量重新

进行假设检验，如此反复，直到回归方程所包含的自变量全部显著为止，此时所建立的回归方程即为最优回归方程。当自变量个数较多，而显著的自变量又较少时，采用这种方法的工作量就比较大，计算麻烦，但当自变量较少，且大多都显著时，这种方法就比较实用。

(2) 从一元回归分析开始，按各自变量对 y 作用的秩次，依次每步仅选入一个对 y 作用显著的自变量，且每引入一个自变量后，对在此之前已引入的自变量进行重新检验，有不显著者即舍弃，直到选入的自变量都显著，而未被选入的自变量都不显著为止，此时建立的回归方程即为最优回归方程。

上述两种方法都是逐步回归，但通常特称第二种方法为逐步回归方法。下面分述之。

一、逐个淘汰不显著自变量的回归方法

逐个淘汰不显著自变量的回归方法的具体步骤如下所述。

第一步，m 元回归分析。若各自变量的偏回归皆显著，分析结束；若有一个或一个以上自变量的偏回归不显著，则舍弃偏回归平方和最小的自变量，进入第二步分析。

第二步，$m-1$ 元回归分析。即在算阵 $\boldsymbol{A}$ 中将舍弃的自变量所在的行、列及其 K 列划去，重新计算 $m-1$ 阶系数矩阵的逆矩阵元素。如果这一步仍有一个以上自变量的偏回归不显著，则再将偏回归平方和最小的那个自变量舍去，进一步进行分析。

……

如此重复进行，直至留下所有自变量的偏回归系数皆显著，即得最优回归方程。

下面通过具体例子介绍逐步回归分析方法。

【例 12.1】 测定了'丰产 3 号'小麦 15 株的单株穗数 x_1、每穗结实小穗数 x_2、百粒重 x_3(g)、株高 x_4(cm) 和单株籽粒产量 y(g)，结果列于表 12-1，试建立 y 依 x_i 的最优回归方程。

表 12-1　'丰产 3 号'小麦单株性状调查结果

株号	单株穗数(x_1)	每穗结实小穗数(x_2)	百粒重(x_3)/g	株高(x_4)/cm	单株籽粒产量(y)/g
1	10	23	3.6	113	15.7
2	9	20	3.6	106	14.5
3	10	22	3.7	111	17.5
4	13	21	3.7	109	22.5
5	10	22	3.6	110	15.5
6	10	23	3.5	103	16.9
7	8	23	3.3	100	8.6
8	10	24	3.4	114	17.0
9	10	20	3.4	104	13.7
10	10	21	3.4	110	13.4
11	10	23	3.9	104	20.3
12	8	21	3.5	109	10.2
13	6	23	3.2	114	7.4
14	8	21	3.7	113	11.6
15	9	22	3.6	105	12.3

(1) 建立 m 元线性回归方程：本例中，$m=4$、$n=15$，从实际观测数据出发可以建立四元线性回归方程。

第一，由表 12-1 算出一级数据和二级数据，并列于表 12-2。

表 12-2　表 12-1 资料四元线性回归分析的一级数据和二级数据

一级数据		二级数据	
$\sum x_1 = 141$	$\sum x_1x_2 = 3089$	$SS_1 = 33.6$	$SP_{24} = 9.333333$
$\sum x_2 = 329$	$\sum x_1x_3 = 501.1$	$SS_2 = 20.933333$	$SP_{2y} = 3.273333$
$\sum x_3 = 53.1$	$\sum x_1x_4 = 15266$	$SS_3 = 0.456$	$SP_{34} = -0.4$
$\sum x_4 = 1625$	$\sum x_1y = 2121.3$	$SS_4 = 273.333333$	$SP_{3y} = 7.206$
$\sum y = 217.1$	$\sum x_2x_3 = 1164.2$	$SS_y = 239.889333$	$SP_{4y} = -1.666667$
$\sum x_1^2 = 1359$	$\sum x_2x_4 = 35651$	$SP_{12} = -3.6$	$\bar{x}_1 = 9.4$
$\sum x_2^2 = 7237$	$\sum x_2y = 4765$	$SP_{13} = 1.96$	$\bar{x}_2 = 21.933333$
$\sum x_3^2 = 188.43$	$\sum x_3x_4 = 5752.1$	$SP_{14} = -9$	$\bar{x}_3 = 3.54$
$\sum x_4^2 = 176315$	$\sum x_3y = 775.74$	$SP_{1y} = 80.56$	$\bar{x}_4 = 108.333333$
$\sum y^2 = 3382.05$	$\sum x_4y = 23517.5$	$SP_{23} = -0.46$	$\bar{y} = 14.473333$

第二，根据式(11.7)将四元正规方程组的系数矩阵和一个四阶单位矩阵填入表 12-3，组成算阵 $\boldsymbol{A}$，并求解 $\boldsymbol{A}$ 阵的逆矩阵 $\boldsymbol{A}^{-1}$ 的各 c_{ij} 值，列入表 12-3。

表 12-3　表 12-1 资料的四元线性回归计算

说明	列 / 行	1	2	3	4	K_1	K_2	K_3	K_4
算阵 $\boldsymbol{A}$	1	33.6	−3.6	1.96	−9	1	0	0	0
	2	−3.6	20.933333	−0.46	9.333333	0	1	0	0
	3	1.96	−0.46	0.456	−0.4	0	0	1	0
	4	−9	9.333333	−0.4	273.333333	0	0	0	1
算阵 $\boldsymbol{B}$	1	33.6	−0.107143	0.058333	−0.267857	0.029761	0	0	0
	2	−3.6	20.547619	−0.012167	0.407300	0.005214	0.048667	0	0
	3	1.96	−0.250000	0.338625	0.669841	−0.168416	0.035930	2.953120	0
	4	−9	8.369047	0.226825	267.361970	0.000982	−0.001554	0.002505	0.003740
(c_{ij})	1	0.040183	0.002758	−0.169073	0.000982				
	2	0.002757	0.049750	0.036971	−0.001554				
	3	−0.169073	0.036971	2.954798	−0.002505				
	4	0.000982	−0.001554	−0.002505	0.003740				

第三，根据式(11.13)，由

$$\begin{pmatrix} b_1 \\ b_2 \\ b_3 \\ b_4 \end{pmatrix} = \begin{pmatrix} 0.040183 & 0.002758 & -0.169073 & 0.000982 \\ 0.002757 & 0.049750 & 0.036971 & -0.001554 \\ -0.169073 & 0.036971 & 2.954798 & -0.002505 \\ 0.000982 & -0.001554 & -0.002505 & 0.003740 \end{pmatrix} \times \begin{pmatrix} 80.56 \\ 3.27333 \\ 7.206 \\ -1.666667 \end{pmatrix}$$

解得，$b_1 = 2.026180$、$b_2 = 0.653997$、$b_3 = 7.796938$、$b_4 = 0.049697$。

第四，根据式(11.22)，计算 U_i：

$$U_1 = \frac{b_1^2}{c_{11}} = \frac{2.026180^2}{0.040183} = 102.1677$$

$$U_2=\frac{b_2^2}{c_{22}}=\frac{0.653997^2}{0.049750}=8.5972$$

$$U_3=\frac{b_3^2}{c_{33}}=\frac{7.796938^2}{2.954798}=20.5741$$

$$U_4=\frac{b_4^2}{c_{44}}=\frac{0.049697^2}{0.003740}=0.6603$$

第五，根据式(11.17)和式(11.18)，计算 $U_{y/1234}$ 和 $Q_{y/1234}$：

$$U_{y/1234}=b_1SP_{1y}+b_2SP_{2y}+b_3SP_{3y}+b_4SP_{4y}=221.4717$$

$$Q_{y/1234}=SS_y-U_{y/1234}=239.8893-221.4717=18.4176$$

第六，多元线性回归方程和偏回归系数的假设检验：四元线性回归方程系数的假设检验均采用 F 检验，结果列于表 12-4。

表 12-4　表 12-1 资料四元线性回归和偏回归系数的假设检验

变异来源	df	SS	s^2	F	$F_{0.05}$	$F_{0.01}$
四元线性回归	4	221.4717	55.3679	30.06**	3.48	5.99
因 x_1 的偏回归	1	102.1677	102.1677	55.47**	4.96	10.04
因 x_2 的偏回归	1	8.5972	8.5972	4.67	4.96	10.04
因 x_3 的偏回归	1	20.5741	20.5741	11.17**	4.96	10.04
因 x_4 的偏回归	1	0.6603	0.6603	<1	4.96	10.04
离回归	10	18.4176	1.8418			
总变异	14	239.8893				

表 12-4 表明，四元线性回归方程达极显著，但 x_2 和 x_4 偏回归系数都不显著，其中以 x_4 的偏回归平方和最小，所以，应首先剔除 x_4。

(2) 建立 $m-1$ 元线性回归方程：本例 $m-1=4-1=3$，$n=15$。

将表 12-3 算阵 $\boldsymbol{A}$ 的第 4 行和第 4 列划去，得到三元系数矩阵，再将 K_4 列划去，得到三阶单位矩阵，这样可求得系数矩阵的逆矩阵(c_{ij})的各个元素值，结果列于表 12-5。

表 12-5　表 12-1 资料的三元线性回归计算(剔除 x_4)

说明	行＼列	1	2	3	K_1	K_2	K_3
算阵 $\boldsymbol{A}$	1	33.6	−3.6	1.96	1	0	0
	2	−3.6	20.933333	−0.46	0	1	0
	3	1.96	−0.46	0.456	0	0	1
算阵 $\boldsymbol{B}$	1	33.6	−0.107143	0.058333	0.029761	0	0
	2	−3.6	20.547619	−0.012167	0.005214	0.048667	0
	3	1.96	−0.250000	0.338625	−0.168416	0.035930	2.953120
(c_{ij})	1	0.039926	0.003165	−0.168416			
	2	0.003165	0.049105	0.035930			
	3	−0.168416	0.035930	2.953120			

第一，由

$$\begin{pmatrix}b_1\\b_2\\b_3\end{pmatrix}=\begin{pmatrix}0.039926 & 0.003165 & -0.168416\\0.003165 & 0.049105 & 0.035930\\-0.168416 & 0.035930 & 2.953120\end{pmatrix}\times\begin{pmatrix}80.56\\3.27333\\7.206\end{pmatrix}$$

解得：$b_1=2.013139$，$b_2=0.674643$，$b_3=7.830227$。

第二，计算 U_i：

$$U_1=\frac{b_1^2}{c_{11}}=\frac{2.013139^2}{0.039926}=101.5060$$

$$U_2=\frac{b_2^2}{c_{22}}=\frac{0.674643^2}{0.049105}=9.2688$$

$$U_3=\frac{b_3^2}{c_{33}}=\frac{7.830227^2}{2.953120}=20.7619$$

第三，计算 $U_{y/123}$ 和 $Q_{y/123}$：

$$U_{y/1234}=b_1SP_{1y}+b_2SP_{2y}+b_3SP_{3y}=220.8114$$

$$Q_{y/123}=SS_y-U_{y/1234}=239.8893-220.8114=19.0779$$

第四，多元线性回归方程和偏回归系数的假设检验：三元线性回归方程系数的假设检验仍然采用 F 检验，结果列于表 12-6。

表 12-6　表 12-1 资料三元线性回归和偏回归系数的假设检验

变异来源	df	SS	s^2	F	$F_{0.05}$	$F_{0.01}$
三元线性回归	3	220.8114	73.6038	42.44**	3.59	6.22
因 x_1 的偏回归	1	101.5060	101.5060	58.53**	4.84	9.65
因 x_2 的偏回归	1	9.2688	9.2688	5.34*	4.84	9.65
因 x_3 的偏回归	1	20.7619	20.7619	11.97**	4.84	9.65
离回归	11	19.0779	1.7344			

表 12-6 表明，三元线性回归方程和 3 个自变量的偏回归系数均极显著或显著，因此不需要再作自变量的剔除。对于回归截距 a，根据式(11.5)，则有

$$\begin{aligned}a&=\bar{y}-b_1\bar{x}_1-b_2\bar{x}_2-b_3\bar{x}_3\\&=14.473333-2.013139\times9.4-0.674643\times21.933333-7.830227\times3.54\\&=-46.9663\end{aligned}$$

因此，最优线性回归方程为

$$\hat{y}=-46.9663+2.013139x_1+0.674643x_2+7.830227x_3$$

该方程的估计标准误 $s_{y/123}$ 为

$$s_{y/123}=\sqrt{\frac{Q_{y/123}}{n-m-1}}=\sqrt{\frac{19.0779}{15-3-1}}=1.32(\text{g})$$

该方程的意义是：当 x_2、x_3 保持一定时(平均水平)，x_1(每株穗数)每增加一穗，y 平均增加 2.01g；当 x_1、x_3 保持一定时(平均水平)，x_2(每穗结实小穗数)每增加一个小穗，y 平均增加 0.67g；当 x_1、x_2 保持一定时(平均水平)，x_3(百粒重)每增加 1g，y 平均增加 7.83g。用 x_1、x_2、x_3 估计单株籽粒产量的标准误为 1.32g。

对于逐个淘汰不显著自变量，建立最优回归方程，还可以采用下面的方法，即在进行 m 元回归分析的基础上，余下自变量的偏回归系数和逆矩阵 $\boldsymbol{A}^{-1}$ 中 c_{ij} 的计算，可根据舍弃前的偏回归系数和 c_{ij}，通过公式直接求出。设 x_k 为舍弃的自变量，则

$$b_i^*=b_i-\frac{c_{ik}b_k}{c_{kk}}\quad(i\neq k)\tag{12.1}$$

$$c_{ij}^{*}=c_{ij}-\frac{c_{ik}c_{kj}}{c_{kk}}\quad(i,j\neq k)\tag{12.2}$$

下面结合例子说明这一方法的应用。

【例 12.2】 试对例 11.1 资料采用逐个淘汰不显著自变量方法建立最优回归方程。

根据前面偏回归系数假设检验的结果，x_3 的偏回归系数不显著，故应舍弃 x_3。舍弃 x_3 后，有

$$b_1^{*}=b_1-\frac{c_{13}}{c_{33}}b_3=0.9708-\frac{0.001102}{0.007713}\times(-0.01538)=0.9730$$

$$b_2^{*}=b_2-\frac{c_{23}}{c_{33}}b_3=-0.1763-\frac{-0.017472}{0.007713}\times(-0.1538)=-0.2111$$

$$c_{11}^{*}=c_{11}-\frac{c_{13}c_{31}}{c_{33}}=0.626887-\frac{0.001102\times0.001102}{0.007713}=0.626730$$

$$c_{12}^{*}=c_{21}^{*}=c_{12}-\frac{c_{13}c_{32}}{c_{33}}=0.022948-\frac{0.001102\times(-0.017472)}{0.007713}=0.025437$$

$$c_{22}^{*}=c_{22}-\frac{c_{23}c_{32}}{c_{33}}=0.067713-\frac{(-0.017472)\times(-0.017472)}{0.007713}=0.028134$$

$$a^{*}=\bar{y}-b_1^{*}\bar{x}_1-b_2^{*}\bar{x}_2$$
$$=2.32875-0.9730\times2.70-(-0.2111)\times3.3375=0.4062$$

因 x_1 的偏回归平方和为：$U_{p_1}^{*}=\dfrac{b_1^{*2}}{c_{11}^{*}}=\dfrac{0.9730^2}{0.626730}=1.5106$

因 x_2 的偏回归平方和为：$U_{p_2}^{*}=\dfrac{b_2^{*2}}{c_{22}^{*}}=\dfrac{(-0.2111)^2}{0.028134}=1.5845$

$U_{y/12}^{*}$ 和 $Q_{y/12}^{*}$ 为

$$U_{y/12}^{*}=b_1^{*}SP_{1y}+b_2^{*}SP_{2y}$$
$$=0.9730\times1.9278+(-0.2111)\times(-9.24562)=3.8279$$

$$Q_{y/12}^{*}=SS_y-U_{y/12}^{*}=4.0769-3.8279=0.2490$$

剔除 x_3 后的二元线性回归 F 检验结果列于表 12-7。

表 12-7　例 11.1 资料舍弃 x_3 后的二元回归和偏回归系数的 F 检验

变异来源	df	SS	s^2	F	$F_{0.05}$	$F_{0.01}$
二元线性回归	2	3.8279	1.9140	38.4327**	5.79	13.27
因 x_1 偏回归	1	1.5106	1.5106	30.3333**	6.61	16.26
因 x_2 偏回归	1	1.5845	1.5845	31.8173**	6.61	16.26
离回归	5	0.2490	0.0498			
总变异	7	4.0769				

从表 12-7 可以看出，剔除 x_3 后，x_1 和 x_2 的偏回归均达极显著，所以第一代幼虫虫口密度的最优回归方程为

$$\hat{y}=0.4062+0.9730x_1-0.2111x_2$$

该方程的估计标准误为

$$s_{y/12}=\sqrt{\frac{Q_{y/12}^{*}}{n-m-1}}=\sqrt{\frac{0.2490}{8-2-1}}=0.2232$$

二、逐个选入显著自变量的回归方法

这种方法是每一次都选入一个显著的自变量，其方法步骤如下所述。

(一) 计算各变量的简单相关系数，得 $m+1$ 阶相关矩阵 $\boldsymbol{R}^{(0)}$

$$\boldsymbol{R}^{(0)}=\begin{pmatrix} r_{11}^{(0)} & r_{12}^{(0)} & \cdots & r_{1m}^{(0)} & r_{1y}^{(0)} \\ r_{21}^{(0)} & r_{22}^{(0)} & \cdots & r_{2m}^{(0)} & r_{2y}^{(0)} \\ \vdots & \vdots & & \vdots & \vdots \\ r_{m1}^{(0)} & r_{m2}^{(0)} & \cdots & r_{mm}^{(0)} & r_{my}^{(0)} \\ r_{y1}^{(0)} & r_{y2}^{(0)} & \cdots & r_{ym}^{(0)} & r_{yy}^{(0)} \end{pmatrix} \tag{12.3}$$

或简记为 $\boldsymbol{R}^{(0)}=(r_{ij}^{(0)})(i,j=1,2,\cdots,m,y)$。

(二) 选入自变量逐步回归

以 $\boldsymbol{R}^{(0)}$ 为基础，每进行一步回归选入一个显著的自变量，并对相关矩阵作一次变换。例如，在第一步，将 $\boldsymbol{R}^{(0)}=(r_{ij}^{(0)})$ 变为 $\boldsymbol{R}^{(1)}=(r_{ij}^{(1)})$；第二步，将 $\boldsymbol{R}^{(1)}=(r_{ij}^{(1)})$ 变为 $\boldsymbol{R}^{(2)}=(r_{ij}^{(2)})$；…；第 k 步，将 $\boldsymbol{R}^{(k-1)}=(r_{ij}^{(k-1)})$ 变为 $\boldsymbol{R}^{(k)}=(r_{ij}^{(k)})$。下面对变换方法和信息来源进行介绍。

在第 k 步($k=1,2,\cdots,m+1$)，由下式算得任一尚未入选自变量 x_i 的标准偏回归平方和：

$$U_i^{(k)}=\frac{(r_{iy}^{(k-1)})^2}{r_{ii}^{(k-1)}} \tag{12.4}$$

设最大 $U_i^{(k)}$ 的自变量为 $x_l(i=l)$，则 x_l 在第 k 步是否入选由

$$F=\frac{U_l^{(k)}}{\dfrac{r_{yy}^{(k-1)}-U_l^{(k)}}{n-m-1}} \tag{12.5}$$

决定。若 $F>F_\alpha(df_1=1,df_2=n-m-1,m$ 为第 k 步已入选的自变量的个数)，则引入自变量 x_l，并将 $\boldsymbol{R}^{(k-1)}$ 变换成 $\boldsymbol{R}^{(k)}$。变换时由元素 $r_{ij}^{(k-1)}$ 计算元素 $r_{ij}^{(k)}$ 的通式为

$$\left.\begin{aligned} r_{ll}^{(k)}&=\frac{1}{r_{ll}^{(k-1)}} && (i=l,j=l)\\ r_{lj}^{(k)}&=\frac{r_{lj}^{(k-1)}}{r_{ll}^{(k-1)}} && (i=l,j\neq l)\\ r_{il}^{(k)}&=-\frac{r_{il}^{(k-1)}}{r_{ll}^{(k-1)}} && (i\neq l,j=l)\\ r_{ij}^{(k)}&=r_{ij}^{(k-1)}-\left(\frac{r_{il}^{(k-1)}r_{lj}^{(k-1)}}{r_{ll}^{(k-1)}}\right) && (i,j\neq l) \end{aligned}\right\} \tag{12.6}$$

由 $\boldsymbol{R}^{(k)}$ 可得到任一已经入选自变量 x_i(包括 x_l)的标准偏回归系数、偏回归平方和、离回归平方和及 F 值：

$$b_i^k=r_{iy}^{(k)} \tag{12.7}$$

$$U_i^{(k)}=\frac{(b_i^{(k)})^2}{r_{ii}^{(k)}} \tag{12.8}$$

$$Q^{(k)}=r_{yy}^{(k)} \tag{12.9}$$

$$F=\frac{\dfrac{(b_i^{(k)})^2}{r_{ii}^{(k)}}}{\dfrac{r_{yy}^{(k)}}{n-m-1}} \tag{12.10}$$

可决定在 x_l 前入选的自变量是否需要剔除。

逐步回归的每一步计算都是重复上述程序，直至余下自变量的最大 U_i 不显著为止。

(三) 计算偏回归系数，建立最优回归方程

自变量挑选结束即可建立最优回归方程，但由于上述程序所得的各种统计数都是标准化的，最后还应将其还原为原来单位的统计数。在第 k 步，原来单位的统计数和标准化统计数的关系为

$$U_{p_i}=U_i^{(k)}SS_y \tag{12.11}$$

$$Q=Q^{(k)}SS_y \tag{12.12}$$

而偏回归系数 b_i 和标准偏回归系数 $b_i^{(k)}$ 的关系则为

$$b_i=b_i^{(k)}\sqrt{\frac{SS_y}{SS_i}} \tag{12.13}$$

回归方程的估计标准误为

$$s_{y/12\cdots m}=\sqrt{\frac{Q^{(k)}SS_y}{n-m-1}} \tag{12.14}$$

【例 12.3】 对例 12.1 资料，采用逐步选入显著自变量回归方法，建立最优回归方程。

(1)计算相关矩阵。根据该资料的二级数据(表 12-2)，计算各变量间的简单相关系数，得相关矩阵 $\boldsymbol{R}^{(0)}$：

$$\boldsymbol{R}^{(0)}=\begin{pmatrix} 1 & -0.135742 & 0.500730 & -0.093913 & 0.897314 \\ -0.135742 & 1 & -0.148887 & 0.123388 & 0.046192 \\ 0.500730 & -0.148887 & 1 & -0.035829 & 0.688980 \\ -0.093913 & 0.123388 & -0.035829 & 1 & -0.006509 \\ 0.897314 & 0.046192 & 0.688980 & -0.006509 & 1 \end{pmatrix}$$

(2)选择第一个自变量。计算各自变量的标准偏回归平方和。由式(12.4)，得

$$U_1^{(1)}=\frac{0.897314^2}{1}=0.805172$$

$$U_2^{(1)}=\frac{0.046192^2}{1}=0.002134$$

$$U_3^{(1)}=\frac{0.688980^2}{1}=0.474693$$

$$U_4^{(1)}=\frac{(-0.006509)^2}{1}=0.000042$$

因 x_1 的偏回归平方和最大，所以对其进行 F 检验。由式(12.5)，得

$$F=\frac{\dfrac{0.805172}{1-0.805172}}{15-1-1}=53.73^{**}$$

由于 $F>F_{0.01(1,13)}=9.07$，故引入自变量 x_1。

然后，变换相关矩阵。以 $l=1$ 代入式(12.6)，计算 $r_{ij}^{(1)}$ 的值，将 $\boldsymbol{R}^{(0)}$ 变换成 $\boldsymbol{R}^{(1)}$：

$$\boldsymbol{R}^{(1)}=\begin{pmatrix}1 & -0.135742 & 0.500730 & -0.093913 & 0.897314\\ 0.135742 & 0.981574 & -0.080917 & 0.110640 & 0.167995\\ -0.500730 & -0.080917 & 0.749269 & 0.011196 & 0.239668\\ 0.093913 & 0.110640 & 0.011196 & 0.991180 & 0.077760\\ -0.897314 & 0.167995 & 0.239668 & 0.077760 & 0.194828\end{pmatrix}$$

(3) 选择第二个自变量。先计算余下自变量的标准偏回归平方和。由式(12.4)，得

$$U_2^{(2)}=\frac{0.167995^2}{0.981574}=0.028752$$

$$U_3^{(2)}=\frac{0.239668^2}{0.749269}=0.076662$$

$$U_4^{(2)}=\frac{0.077760^2}{0.991180}=0.006100$$

因 x_3 的偏回归平方和最大，所以对其进行 F 检验。由式(12.5)，得

$$F=\frac{\dfrac{0.076662}{0.194828-0.076662}}{15-2-1}=7.79^{*}$$

由于 $F>F_{0.05(1,12)}=4.75$，故本步引入自变量 x_3 之后，进行相关矩阵变换。将 $l=3$ 代入式(12.6)，把 $\boldsymbol{R}^{(1)}$ 变换成 $\boldsymbol{R}^{(2)}$：

$$\boldsymbol{R}^{(2)}=\begin{pmatrix}1.334634 & -0.081666 & -0.668291 & -0.101395 & 0.737146\\ 0.081666 & 0.972835 & 0.107995 & 0.111849 & 0.193878\\ -0.668291 & -0.107995 & 1.334634 & 0.014943 & 0.319869\\ 0.101395 & 0.111849 & -0.014943 & 0.991013 & 0.074179\\ -0.737146 & 0.193878 & -0.319869 & 0.074179 & 0.118166\end{pmatrix}$$

然后检验在 x_3 入选前已入选的自变量 x_1 的偏回归显著性。由式(12.7)，得

$$b_1^{(2)}=r_{1y}^{(2)}=0.737146$$

由式(12.10)，得

$$F=\frac{\dfrac{(b_1^{(2)})^2}{r_{11}^{(2)}}}{\dfrac{r_{yy}^{(2)}}{n-m-1}}=\frac{\dfrac{0.737146^2}{1.334634}}{\dfrac{0.118166}{15-2-1}}=41.35^{**}$$

由于 $F>F_{0.01(1,12)}=9.33$，故自变量 x_1 不应剔除。

(4) 选择第三个自变量。先计算余下自变量的标准偏回归平方和。由式(12.4)得

$$U_2^{(3)}=\frac{0.193878^2}{0.972835}=0.038638$$

$$U_4^{(3)}=\frac{0.074179^2}{0.991013}=0.005552$$

其中，x_2 的标准偏回归平方和最大，故对其进行 F 检验。由式(12.5)，得

$$F=\frac{0.038638}{\dfrac{0.118166-0.038638}{15-3-1}}=5.34^*$$

因 $F>F_{0.05(1,11)}=4.84$，故本步选入自变量 x_2，并进行相关矩阵变换。以 $l=2$ 代入式(12.6)，将 $\boldsymbol{R}^{(2)}$ 变换为 $\boldsymbol{R}^{(3)}$：

$$\boldsymbol{R}^{(3)}=\begin{pmatrix}1.341490 & 0.083946 & -0.659225 & -0.092006 & 0.753421\\ 0.083946 & 1.027924 & 0.111011 & 0.114972 & 0.199292\\ -0.659225 & 0.111011 & 1.346623 & 0.027359 & 0.341391\\ 0.092006 & -0.114972 & -0.027359 & 0.978153 & 0.051888\\ -0.753421 & -0.199292 & -0.341391 & 0.051888 & 0.079528\end{pmatrix}$$

对 x_2 入选前已入选的自变量 x_1 和 x_3 的偏回归显著性进行检验。由式(12.7)，得

$$b_1^{(3)}=r_{1y}^{(3)}=0.753421$$

$$b_3^{(3)}=r_{3y}^{(3)}=0.341391$$

由式(12.10)，对 x_1，有

$$F=\frac{\dfrac{(b_1^{(3)})^2}{r_{11}^{(3)}}}{\dfrac{r_{yy}^{(3)}}{n-m-1}}=\frac{\dfrac{0.753421^2}{1.341490}}{\dfrac{0.079528}{15-3-1}}=58.53^{**}$$

对 x_3，有

$$F=\frac{\dfrac{(b_3^{(3)})^2}{r_{33}^{(3)}}}{\dfrac{r_{yy}^{(3)}}{n-m-1}}=\frac{\dfrac{0.341391^2}{1.346623}}{\dfrac{0.079528}{15-3-1}}=11.97^{**}$$

以上两个 F 值均大于 $F_{0.01(1,11)}=9.65$，故 x_1 和 x_3 不应剔除。

(5) 选择第四个自变量。计算余下自变量(x_4)的标准偏回归平方和和 F 值：

$$U_4^{(4)}=\frac{0.051888^2}{0.978153}=0.002752$$

$$F=\frac{0.002752}{\dfrac{0.079528-0.002752}{15-4-1}}=0.36$$

由于 $F<F_{0.05(1,10)}=4.96$，故自变量 x_4 不应入选。到此，自变量的选取结束，所选入的 3 个自变量为 x_1、x_2 和 x_3。

(6)计算偏回归系数，建立最优回归方程：根据式(12.13)，得

$$b_1 = b_1^{(3)}\sqrt{\frac{SS_y}{SS_1}} = 0.753421 \times \sqrt{\frac{239.889333}{33.6}} = 2.0131$$

$$b_2 = b_2^{(3)}\sqrt{\frac{SS_y}{SS_2}} = 0.199292 \times \sqrt{\frac{239.889333}{20.933333}} = 0.6746$$

$$b_3 = b_3^{(3)}\sqrt{\frac{SS_y}{SS_3}} = 0.341391 \times \sqrt{\frac{239.889333}{0.456}} = 7.8302$$

由式(11.5),得

$$a = \bar{y} - b_1\bar{x}_1 - b_2\bar{x}_2 - b_3\bar{x}_3 = 14.473333 - 2.0131 \times 9.4$$
$$- 0.6746 \times 21.933333 - 7.8320 \times 3.54 = -46.9713$$

故表 12-1 资料单株籽粒产量的最优回归方程为

$$\hat{y} = -46.9713 + 2.0131x_1 + 0.6746x_2 + 7.8302x_3$$

由式(12.9),可求得该方程的离回归平方和:

$$Q^{(3)} = r_{yy}^{(3)} = 0.079528$$

由式(12.14),求得该方程的估计标准误:

$$s_{y/123} = \sqrt{\frac{Q^{(3)}SS_y}{n-m-1}} = \sqrt{\frac{0.079528 \times 239.889333}{15-3-1}} = 1.32(\text{g})$$

上述结果与例 12.1 计算结果是基本一样的(结果稍有误差是小数四舍五入所致)。

上面介绍了两种建立最优多元线性回归方程的步骤,这里必须说明两点:一是自变量的选择,主要应根据专业知识和前人已开展的研究,从专业角度选择有关自变量;二是应在认真搜集可靠数据的基础上,再作多元线性回归分析,用数学方法得到最优回归方程。

第二节　通径分析

从多元线性回归分析中我们知道,偏回归系数是依变量 y 随自变量 x_i 变化而变化的反应量。但是,由于各个 x_i 单位不同和 x_i 变异度(标准差)不同,各个 x_i 对 y 的贡献大小就不能直接进行比较。相关分析中,变量之间是一种平等关系(互为因果)。例如,x_i 和 y 之间的相关系数的大小仅表示 x_i 与 y 两个变量之间关系的密切程度,但无法解释和分析这种关系的构成和来源。通过通径分析(path analysis),可将相关系数 r_{iy} 剖分为 x_i 对 y 的直接作用(即通径系数)和 x_i 通过与其相关的各个 x_j 对 y 的间接作用(即间接通径系数),也可以说通径分析是分析相关变量间因果关系的一种统计方法。

一、通径与通径系数的概念

设依变量 y 与自变量 $x_1, x_2, \cdots, x_m$ 之间存在线性关系,且 $x_1, x_2, \cdots, x_m$ 彼此相关,根据式(11.4),则有

$$\hat{y} = a + b_1x_1 + b_2x_2 + \cdots + b_mx_m \tag{12.15}$$

或

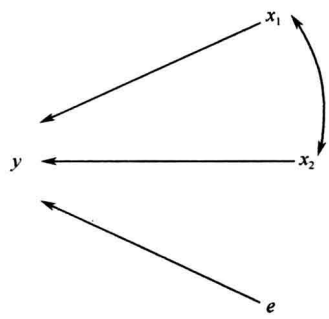

图 12-1　自变量 x_i 与依变量 y 的通径图

$$y = a + b_1x_1 + b_2x_2 + \cdots + b_mx_m + e \quad (12.16)$$

式中，e 为 y 与 $\hat{y}$ 之间误差，也称为剩余因子(residual factor)。可用图 12-1 表示变量间的关系。

从图 12-1 可以看出，图中存在两种路径，一种是表示 x_i 到 y 之间的单向路径(单箭头线)，即从因到果的路径，我们称之为通径(path)；另一种是表示自变量间平行关系的双向路径(双向箭头)，即互为因果的路径，我们称之为相关线(correlation line)。因此，对于 $x_i \rightarrow y$ 的通径可称之为直接通径；对于包含相关线，如 $x_i \leftrightarrow x_j \rightarrow y$ 的通径可称之为间接通径。这种用来表示相关变量间的因果关系与平行关系的图形称为通径图(path chart)。

为从数量关系上表示通径的相对重要程度与性质，我们将 x_i 对 y 直接作用的统计量称为通径系数(path coefficient)，用 P_{iy} 表示。由于偏回归系数 b_i 带有单位，一般不能直接比较各个自变量 x_i 对 y 影响重要程度的大小，因此，须对 y、x_i 和剩余项 e 进行标准化变换，使 y、x_i 和 e 转变为不带单位的相对数。

将通径系数进行平方，我们称之为决定系数(coefficient of determination)，用 R^2 表示。决定系数可以用来表示自变量或误差对依变量的相对决定程度。

二、通径系数的求解方法

由式(12.15)可得

$$\bar{y} = a + b_1\bar{x}_1 + b_2\bar{x}_2 + \cdots + b_m\bar{x}_m \quad (12.17)$$

式(12.16)和式(12.17)两式相减，可得

$$y - \bar{y} = b_1(x_1 - \bar{x}_1) + b_2(x_2 - \bar{x}_2) + \cdots + b_m(x_m - \bar{x}_m) + e \quad (12.18)$$

将式(12.18)等号两端各除以 s_y，并作恒等变形，有

$$\frac{(y-\bar{y})}{s_y} = b_1\frac{s_1}{s_y}\cdot\frac{x_1-\bar{x}_1}{s_1} + b_2\frac{s_2}{s_y}\cdot\frac{x_2-\bar{x}_2}{s_2} + \cdots + b_m\frac{s_m}{s_y}\cdot\frac{x_m-\bar{x}_m}{s_m} + \frac{s_e}{s_y}\cdot\frac{e}{s_e} \quad (12.19)$$

式中，$s_1, s_2, \cdots, s_m$ 和 s_e 分别为 $x_1, x_2, \cdots, x_m$ 和 e 的标准差。$b_1\frac{s_1}{s_y}, b_2\frac{s_2}{s_y}, \cdots, b_m\frac{s_m}{s_y}$ 即为自变量 $x_1, x_2, \cdots, x_m$ 通径系数，分别用 $P_{1y}, P_{2y}, \cdots, P_{my}$ 表示，代表自变量 $x_1, x_2, \cdots, x_m$ 对 y 影响的相对重要程度和性质，即

$$P_{iy} = b_i\sqrt{\frac{SS_i}{SS_y}} \quad (12.20)$$

对于 $\frac{s_e}{s_y}$ 则为剩余项 e 的通径系数，用 P_{ey} 表示，即

$$P_{ey} = \sqrt{\frac{SS_e}{SS_y}} \quad (12.21)$$

将(12.20)变换可得

$$b_i = P_{iy}\sqrt{\frac{SS_y}{SS_i}} \tag{12.22}$$

式(12.22)实际上就是式(12.13)，仅是将 $b_i^{(k)}$ 改写成了 P_{iy}，因此 P_{iy} 就是标准化了的偏回归系数。

将式(12.22)代入到式(11.6)，再对第 i 个方程等号两边各除以 $\sqrt{SS_i \cdot SS_y}$，则式(11.6)可变形为如下正规方程组：

$$\left.\begin{aligned} P_{1y} + r_{12}P_{2y} + \cdots + r_{1m}P_{my} &= r_{1y} \\ r_{12}P_{1y} + P_{2y} + \cdots + r_{2m}P_{my} &= r_{2y} \\ \vdots \qquad\quad \vdots \qquad\qquad \vdots \quad & \quad \vdots \\ r_{1m}P_{1y} + r_{2m}P_{2y} + \cdots + P_{my} &= r_{my} \end{aligned}\right\} \tag{12.23}$$

式(12.23)说明，每个自变量 x_i 与依变量 y 的相关系数均可剖分为自变量 x_i 对依变量 y 的直接作用与间接作用的代数和，即 x_i 与 y 的相关系数 r_{iy} 等于 x_i 到 y 的直接通径系数 P_{iy} 和通过与其相关的各个 $x_j(j=1,2,\cdots,m;j\neq i)$ 对 y 的所有间接通径系数 $\sum\limits_{(j\neq i)}^{m} r_{ij}P_{jy}$ 之和。

式(12.23)可写成如下矩阵形式：

$$\begin{pmatrix} r_{11} & r_{12} & \cdots & r_{1m} \\ r_{21} & r_{22} & \cdots & r_{2m} \\ \vdots & \vdots & & \vdots \\ r_{m1} & r_{m2} & \cdots & r_{mm} \end{pmatrix} \times \begin{pmatrix} P_{1y} \\ P_{2y} \\ \vdots \\ P_{my} \end{pmatrix} = \begin{pmatrix} r_{1y} \\ r_{2y} \\ \vdots \\ r_{my} \end{pmatrix} \tag{12.24}$$

于是，如果将相关系数 r_{ij}、r_{iy} 计算出来，便可以按式(12.23)或式(12.24)求出所对应的通径系数 P_{iy}。

从以上讨论可知，表示 x_i 对 y 直接作用的通径系数 P_{iy} 既可以通过对偏回归系数 b_i 进行标准化得出，也可以利用相关系数 r_{ij}、r_{iy} 来求出，而 x_i 对 y 间接作用(即间接通径系数)则可由 $r_{ij}P_{iy}$ 算出，从而进行原因对结果的直接作用、间接作用的分析。

【例 12.4】 试计算例 12.1 资料的通径系数。

在例 12.3 中，该资料的相关系数已经算出，将其直接代入式(12.23)，得标准正规方程组(由于 x_4 已剔除，不再参加通径分析)。

$$\begin{cases} P_{1y} - 0.135752P_{2y} + 0.500703P_{3y} = 0.897314 \\ -0.135742P_{1y} + P_{2y} - 0.148887P_{3y} = 0.046192 \\ 0.500730P_{1y} - 0.148887P_{2y} + P_{3y} = 0.688980 \end{cases}$$

对上述正规方程组用简化表解法求解(表 12-8)：将系数矩阵抄入表 12-8 的算阵 $\boldsymbol{A}$，并将乘积和列向量 $\boldsymbol{K}$ 伴随其后。算阵 $\boldsymbol{B}$ 各元素的计算方法同多元回归一样，其计算结果也列于表 12-8 中。

表 12-8　例 12.1 资料(x_4 已剔除)通径系数的求解

说明	(i) \ (j)	1	2	3	K
算阵 $\boldsymbol{A}$	1	1	−0.135742	0.500730	0.897314
	2	−0.135742	1	−0.148887	0.046192
	3	0.500730	−0.148887	1	0.688980
算阵 B	1	1	−0.135742	0.500730	0.897314
	2	−0.135742	0.981574	−0.082436	0.171149
	3	0.500730	−0.080917	0.742599	0.341391
P_{iy}		0.753421	0.199292	0.341391	

表 12-8 中 P_{1y}、P_{2y}、P_{3y} 的计算方法与多元回归中逆矩阵各元素的算法相同，即由算阵 $\boldsymbol{B}$ 可建立如下方程组：

$$\begin{cases} P_{1y} - 0.135752P_{2y} + 0.500730P_{3y} = 0.897314 \\ P_{2y} - 0.082436P_{3y} = 0.171149 \\ P_{3y} = 0.341391 \end{cases}$$

解方程组，得 $P_{1y}=0.753421$、$P_{2y}=0.199292$、$P_{3y}=0.341391$。实际上，这些数值就是例 12.3 中得到的标准偏回归系数。

根据以上求得的通径系数，可分别得到 6 个间接通径系数：

$$r_{12}P_{2y} = -0.135742 \times 0.199292 = -0.027052$$
$$r_{13}P_{3y} = 0.500730 \times 0.341391 = 0.170945$$
$$r_{21}P_{1y} = -0.135742 \times 0.753421 = -0.102271$$
$$r_{23}P_{3y} = -0.148887 \times 0.341391 = -0.050829$$
$$r_{31}P_{1y} = 0.500730 \times 0.753421 = 0.377260$$
$$r_{32}P_{2y} = -0.148887 \times 0.199292 = -0.029672$$

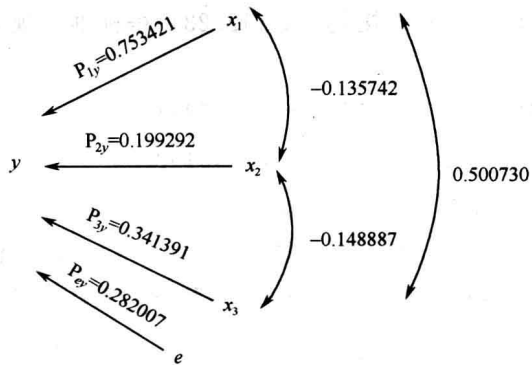

图 12-2　每株穗数 x_1、每穗结实小穗数 x_2、百粒重 x_3 与单株产量 y 之间的通径关系

以上计算结果可用图 12-2 进行说明。通过计算结果和图 12-2 可以看出，3 个自变量对单株产量 y 的直接影响中，每株穗数 x_1 的直接作用最大，其 $P_{1y}=0.753421$；其次是百粒重 x_3，其 $P_{3y}=0.341391$；每穗结实小穗数 x_2 的直接作用最小，其 $P_{2y}=0.199292$。对各个间接通径系数的分析发现，每株穗数 x_1 通过百粒重 x_3 对产量 y 所产生的间接作用较大，其 $r_{13}P_{3y}=0.170945$；尽管每株穗数 x_1 通过 x_2 对单株产量 y 产生一定负值的

间接作用($r_{12}P_{2y}=-0.027052$),但由于P_{1y}和$r_{13}P_{3y}$的值较大,就使每株穗数x_1对y的贡献较大,二者的相关系数达到了0.897314;百粒重x_3对y的间接作用分别为$r_{31}P_{1y}=0.377260$、$r_{32}P_{2y}=-0.029672$,连同x_3对y的直接作用,使得x_3与y也产生了比较密切的正相关,二者之间的相关系数达到了0.688980。因此,每株穗数x_1和百粒重x_3对增加单株产量具有重要的作用。至于每穗结实小穗数x_2,其直接通径系数和间接通径系数均较小,对单株产量的改变无大的影响,可不必过多考虑。

三、通径分析的假设检验

综上所述,通径分析就是标准化变量的多元线性回归分析。通径分析的假设检验包括回归方程的检验和通径系数的检验。

对于式(12.15)中的依变量y和自变量x_i分别进行标准化变换,令:

$$y'=\frac{y-\bar{y}}{\sqrt{SS_y}},x'_i=\frac{x_i-\bar{x}_i}{\sqrt{SS_i}}\qquad(i=1,2,\cdots,m)$$

则标准化变量的m元线性回归方程为

$$\hat{y}'=b'_1x'_1+b'_2x'_2+\cdots+b'_mx'_m \tag{12.25}$$

式中,$b'_i=b_i\frac{\sqrt{SS_i}}{\sqrt{SS_y}}=b_i\frac{s_i}{s_y}(i=1,2,\cdots,m)$为标准化变量的偏回归系数,即通径系数。

令$P_{iy}=b'_i$,式(12.25)可改为

$$\hat{y}'=P_{1y}x'_1+P_{2y}x'_2+\cdots+P_{my}x'_m \tag{12.26}$$

对每个直接通径系数P_{iy}进行平方,可得出每个自变量x_i的直接决定系数R_i^2,即

$$R_i^2=P_{iy}^2 \tag{12.27}$$

自变量x_i通过x_j对依变量y的间接决定系数R_{ij}^2为

$$R_{ij}^2=2P_{iy}r_{ij}P_{jy} \tag{12.28}$$

而总的决定系数R^2等于各直接与间接决定系数之和,即

$$\begin{aligned}R^2&=P_{1y}r_{1y}+P_{2y}r_{2y}+\cdots+P_{my}r_{my}\\&=\sum_{i=1}^{m}P_{iy}^2+2\sum_{i<j}^{m}P_{iy}r_{ij}P_{jy}\\&=\sum_{i=1}^{m}R_i^2+\sum_{i<j}^{m}R_{ij}{}^2\end{aligned} \tag{12.29}$$

对标准化变量的多元线性回归,其总变差$r_{yy}=1$,回归平方和为决定系数R^2,则回归平方和U':

$$U'=P_{1y}r_{1y}+P_{2y}r_{2y}+\cdots+P_{my}r_{my}=R^2 \tag{12.30}$$

对剩余因子e,假定它与各个x_i独立,其通径系数P_{e_y}为

$$P_{e_y}=\sqrt{1-R^2} \tag{12.31}$$

将剩余因子的通径系数P_{e_y}平方即为剩余平方和Q',也就是剩余因子P_{e_y}的决定系数R_e^2。因此有

$$Q'=R_e^2=P_{e_y}^2=1-R^2 \tag{12.32}$$

则对标准化变量多元线性回归方程检验的 F 值为

$$F=\frac{\frac{R^2}{m}}{\frac{1-R^2}{n-m-1}} \tag{12.33}$$

式(12.33)服从 $df_1=m$、$df_2=n-m-1$ 的 F 分布。

各 x_i 对 y 的通径系数 P_{iy} 的检验可用 F 检验和 t 检验两种方法。其 F_i 值为

$$F_i=\frac{\frac{P_{iy}^2}{c_{ii}}}{\frac{1-R^2}{n-m-1}} \tag{12.34}$$

式中，c_{ii} 为相关矩阵 $\boldsymbol{R}$ 的逆矩阵 $\boldsymbol{R}^{-1}$ 的主对角线的元素。式(12.34)服从 $df_1=1$、$df_2=n-m-1$ 的 F 分布。

对通径系数作 t 检验时，先求出通径系数的标准误 $s_{P_{iy}}$：

$$s_{P_{iy}}=\sqrt{\frac{1-R^2}{n-m-1}}\cdot\sqrt{c_{ii}} \tag{12.35}$$

其 t 值为

$$t_i=\frac{P_{iy}}{s_{P_{iy}}}\qquad(df=n-m-1) \tag{12.36}$$

注意，这里介绍的 F 检验和 t 检验是等价的，在实际进行通径系数假设检验时，只须选其中一种方法即可。

【例 12.5】 试对例 12.4 所计算的通径系数进行显著性检验。

例 12.4 已将各个自变量 x_i 的通径系数算出，分别为 $P_{1y}=0.753421$、$P_{2y}=0.199292$、$P_{3y}=0.341391$。

根据式(12.26)，可建立标准变量的多元线性回归方程为

$$\hat{y}'=0.753421x'_1+0.199292x'_2+0.341391x'_3$$

由式(12.30)，有

$$\begin{aligned}U'=R^2&=P_{1y}r_{1y}+P_{2y}r_{2y}+P_{3y}r_{3y}\\&=0.753421\times0.897314+0.199292\times0.046192+0.341391\times0.688980\\&=0.920472\end{aligned}$$

剩余平方和为

$$Q'=1-R^2=1-0.920472=0.079528$$

剩余项的通径系数为

$$P_{ey}=\sqrt{1-R^2}=\sqrt{1-0.920472}=0.282007$$

因此，对上述标准化变量多元线性回归方程检验的 F 值为

$$F=\frac{\frac{R^2}{m}}{\frac{1-R^2}{n-m-1}}=\frac{\frac{0.920472}{3}}{\frac{1-0.920472}{15-3-1}}=42.4388^{**}$$

查附表5，$F_{0.05(3,11)}=3.59$，$F_{0.01(3,11)}=6.22$，$F>F_{0.01}$，说明每株穗数x_1、每穗结实小穗数x_2、百粒重x_3标准化后的多元线性回归方程呈极显著水平。

对于通径系数的检验可根据式(12.34)或式(12.36)进行检验。利用例12.3的相关矩阵$\boldsymbol{R}^{(0)}$的前三列、前三行中与x_1、x_2、x_3有关的相关系数r_{ij}，建立相关矩阵$\boldsymbol{R}_{(3\times3)}$，求其逆矩阵$\boldsymbol{R}_{(3\times3)}^{-1}$，得$c_{11}=1.341489$、$c_{22}=1.027923$、$c_{33}=1.346622$，于是有

$$F_1=\frac{\dfrac{P_{1y}^2}{c_{11}}}{\dfrac{1-R^2}{n-m-1}}=\frac{\dfrac{0.753421^2}{1.341489}}{\dfrac{1-0.920472}{15-3-1}}=58.5278^{**}$$

$$F_2=\frac{\dfrac{P_{2y}^2}{c_{22}}}{\dfrac{1-R^2}{n-m-1}}=\frac{\dfrac{0.199292^2}{1.027923}}{\dfrac{1-0.920472}{15-3-1}}=5.3443^{*}$$

$$F_3=\frac{\dfrac{P_{3y}^2}{c_{33}}}{\dfrac{1-R^2}{n-m-1}}=\frac{\dfrac{0.341391^2}{1.346622}}{\dfrac{1-0.920472}{15-3-1}}=11.9710^{**}$$

查附表5，$F_{0.05(1,11)}=4.84$、$F_{0.01(1,11)}=9.65$，F_1、F_3均大于$F_{0.01}$，$F_2>F_{0.05}$，说明通径系数P_{1y}、P_{3y}均达到极显著水平，P_{2y}仅达显著水平。

同样，可用t检验法检验通径系数，先求出通径系数标准误：

$$s_{P_{1y}}=\sqrt{\frac{1-R^2}{n-m-1}}\cdot\sqrt{c_{11}}=\sqrt{\frac{1-0.920472}{15-3-1}}\cdot\sqrt{1.341489}=0.098482$$

$$s_{P_{2y}}=\sqrt{\frac{1-R^2}{n-m-1}}\cdot\sqrt{c_{22}}=\sqrt{\frac{1-0.920472}{15-3-1}}\cdot\sqrt{1.027923}=0.086207$$

$$s_{P_{3y}}=\sqrt{\frac{1-R^2}{n-m-1}}\cdot\sqrt{c_{33}}=\sqrt{\frac{1-0.920472}{15-3-1}}\cdot\sqrt{1.346622}=0.098670$$

再求t值：

$$t_1=\frac{P_{1y}}{s_{P_{1y}}}=\frac{0.753421}{0.098482}=7.6503^{**}$$

$$t_2=\frac{P_{2y}}{s_{P_{2y}}}=\frac{0.199292}{0.086207}=2.3118^{*}$$

$$t_3=\frac{P_{3y}}{s_{P_{3y}}}=\frac{0.341391}{0.098670}=3.4599^{**}$$

查附表3，$t_{0.05(11)}=2.201$、$t_{0.01(11)}=3.106$，t_1、t_3均大于$t_{0.01}$，$t_2>t_{0.05}$，即通径系数P_{1y}、P_{3y}均达到极显著水平，P_{2y}仅达到显著水平。

从以上数据可看出，F检验和t检验的结果是一样的。

思考练习题

习题12.1　什么叫逐步回归？什么是最优多元回归方程？在多元线性回归分析中，应用逐步回归方法建立多元线性回归最优方程有哪两种方法？如何剔除不显著的自变量？

习题 12.2　什么是通径系数？怎样计算通径系数？通径分析的基本含义是什么？

习题 12.3　下表为某县 1960～1971 年的 1 月雨量（x_1，mm）、3 月上旬平均温度（x_2，℃）、3 月中旬平均温度（x_3，℃）、2 月雨量（x_4，mm）和第一代三化螟高峰期（y，以 4 月 30 日为 0）的测定结果。试应用逐步回归方法求预报第一代三化螟高峰期的最优线性回归方程及该方程的离回归标准误。

x_1	x_2	x_3	x_4	y
47.5	11.1	9.0	30.6	17
42.9	8.1	9.5	32.3	21
20.2	6.7	11.1	37.4	26
0.2	8.5	8.9	21.5	23
67.0	6.8	9.4	61.6	20
5.5	5.0	9.5	83.5	30
44.4	10.0	11.1	24.1	22
8.9	6.1	9.5	24.9	26
39.0	7.1	10.8	10.2	27
74.2	4.4	6.8	54.9	23
15.9	4.6	3.8	74.2	23
26.4	4.1	5.8	50.7	27

习题 12.4　根据习题 12.3 资料，试进行第一代三化螟高峰期（y）与 1 月雨量（x_1）、3 月上旬平均温度（x_2）、3 月中旬平均温度（x_3）、2 月雨量（x_4）的通径分析，并对通径系数进行显著性检验。

第十三章

多项式回归分析

本章提要

多项式回归是研究依变量y与自变量x为非线性关系的一种回归分析方法，其最大优点就是可以通过增加x的项次对实际观测值进行逼近。多项式回归问题可以通过变量转变为多元线性回归问题，用最小二乘法进行求解，建立多项式回归方程，用相关指数表示k次多项式的决定系数。如果x的取值为等差数列，且对应于每一对x、y都有相等的观测次数，则可转换为正交多项式，进行正交多项式回归分析。

在生物学研究中，大多数双变量资料并非表现为简单的线性关系，而常常表现为各种各样的非线性关系。有关可化为直线的非线性回归问题已在第八章中讨论过了，这里仅讨论非线性关系的另一种形式——多项式回归。

第一节　多项式回归的数学模型

如果y对x的关系为非线性，但又找不到适当的变量转换形式使其转化为线性，则可选用多项式回归方程进行描述。像这种研究一个依变量与一个或多个自变量间多项式的回归分析方法，称为多项式回归(polynomial regression)，所建立的方程称为多项式回归方程(polynomial regression equation)。

k次多项式回归模型可以定义为

$$\begin{aligned} y_i &= \mu_y + \beta_1(x_i - \mu_x) + \beta_2(x_i^2 - \mu_{x^2}) + \cdots + \beta_k(x_i^k - \mu_{x^k}) + \varepsilon_i \\ &= \alpha + \beta_1 x_i + \beta_2 x_i^2 + \cdots + \beta_k x_i^k + \varepsilon_i \end{aligned} \tag{13.1}$$

式中，$\mu_y, \mu_x, \mu_{x^2}, \cdots, \mu_{x^k}$依次为$y, x, x^2, \cdots, x^k$的总体平均数；$\alpha$为回归截距，$\alpha = \mu_y - \beta_1\mu_x - \beta_2\mu_{x^2} - \cdots - \beta_k\mu_{x^k}$；$\beta_1, \beta_2, \cdots, \beta_k$依次为$x$的一次项、二次项、…、$k$次项的总体回归系数；$\mu_{y/x,x^2,\cdots,x^k}$为任一$x$上$k$次多项式回归的$y$总体平均数，即

$$\mu_{y/x,x^2,\cdots,x^k} = \alpha + \beta_1 x + \beta_2 x^2 + \cdots + \beta_k x^k \tag{13.2}$$

ε_i为随机误差，遵循$N(0, \sigma^2_{y/x,x^2,\cdots,x^k})$。

当由样本估计时，式(13.1)变为

$$\begin{aligned} y_i &= \bar{y} + b_1(x_i - \bar{x}) + b_2(x_i^2 - \bar{x}^2) + \cdots + b_k(x_i^k - \bar{x}^k) + e_i \\ &= a + b_1 x_i + b_2 x_i^2 + \cdots + b_k x_i^k + e_i \\ &= a + \sum_{j=1}^{k} b_j x_i^j + e_i \\ &= \hat{y} + e_i \end{aligned} \tag{13.3}$$

式中，$\bar{y} = \sum y/n, \bar{x} = \sum x/n, \bar{x}^2 = \sum x^2/n, \cdots, \bar{x}^k = \sum x^k/n$，依次估计 $\mu_y, \mu_x, \mu_{x^2}, \cdots, \mu_{x^k}$；$a, b_1, b_2, \cdots, b_k$ 依次估计 $\alpha, \beta_1, \beta_2, \cdots, \beta_k$；$\hat{y}$ 则估计 $\mu_{y/x,x^2,\cdots,x^k}$，即

$$\hat{y} = a + b_1 x + b_2 x^2 + \cdots + b_k x^k = a + \sum_{j=1}^{k} b_j x^j \tag{13.4}$$

e_i 则为 ε_i 的估计值。对 $\sigma_{y/x,x^2,\cdots,x^k}$，其样本估计值为

$$s_{y/x,x^2,\cdots,x^k} = \sqrt{\frac{\sum (y - \hat{y}_k)^2}{n-k-1}} = \sqrt{\frac{Q_k}{n-k-1}} \tag{13.5}$$

式(13.5)称为 k 次多项式的离回归标准误，其中 Q_k 为 k 次多项式的离回归平方和：

$$Q_k = \sum_{1}^{n} (y - \hat{y}_k)^2 = \sum (y - a - b_1 x - b_2 x^2 - \cdots - b_k x^k)^2 \tag{13.6}$$

多项式的一个特例为 $k=1$，这时 $\hat{y} = a + b_1 x$，即直线方程；若 $k=2$，则称为二次多项式方程或二次曲线方程；若 $k=3$，则称为三次多项式方程或三次曲线方程 ……

多项式回归模型的最大优点是可对任何双变量数据资料进行回归逼近。但 n 对观测值最多只能配到 $k=n-1$ 次多项式。k 越大，包含的统计数越多，计算越麻烦。一个多项式回归方程应取多少项次为宜，应根据资料的二维散点图确定。散点图中曲线趋势的“峰”+“谷”+1，即为多项式回归方程的次数，若散点波动大或峰谷两侧不对称，可再高一次或二次。多项式回归方程通常用于描述试验取值范围内的 y 依 x 的变化关系，外推一般不可靠。

第二节　多项式回归方程的建立

一、多项式回归方程的建立与求解

根据最小二乘法，式(13.6)中的统计数 $a, b_1, b_2, \cdots, b_k$ 必须满足：

$$Q_k = \sum_{1}^{n} (y - \hat{y}_k)^2 = \sum_{1}^{n} (y - a - b_1 x - b_2 x^2 - \cdots - b_k x^k)^2 = \text{最小值}$$

因此，需分别对 $a, b_1, b_2, \cdots, b_k$ 求偏导数，并令之为 0，即有

$$\frac{\partial Q_k}{\partial a} = -2\sum_{1}^{n} (y - a - b_1 x - b_2 x^2 - \cdots - b_k x^k) = 0$$

$$\frac{\partial Q_k}{\partial b_1} = -2\sum_{1}^{n} (y - a - b_1 x - b_2 x^2 - \cdots - b_k x^k) x = 0$$

$$\frac{\partial Q_k}{\partial b_2} = -2\sum_{1}^{n} (y - a - b_1 x - b_2 x^2 - \cdots - b_k x^k) x^2 = 0$$

$$\vdots \qquad \vdots \qquad \vdots$$

$$\frac{\partial Q_k}{\partial b_k} = -2\sum_1^n (y - a - b_1 x - b_2 x^2 - \cdots - b_k x^k) x^k = 0$$

整理得多项式回归统计数的正规方程组为

$$\left.\begin{aligned} an + b_1\sum x + b_2\sum x^2 + \cdots + b_k\sum x^k &= \sum y \\ a\sum x + b_1\sum x^2 + b_2\sum x^3 + \cdots + b_k\sum x^{k+1} &= \sum xy \\ a\sum x^2 + b_1\sum x^3 + b_2\sum x^4 + \cdots + b_k\sum x^{k+2} &= \sum x^2 y \\ \vdots \qquad\qquad \vdots \qquad\qquad \vdots \qquad\qquad \vdots \qquad\qquad \vdots & \\ a\sum x^k + b_1\sum x^{k+1} + b_2\sum x^{k+2} + \cdots + b_k\sum x^{2k} &= \sum x^k y \end{aligned}\right\} \tag{13.7}$$

式(13.7)是求解 k 次多项式统计数 $a, b_1, b_2, \cdots, b_k$ 的一般形式，具体形式因 k 而异。例如，当 $k=2$($\hat{y}_2 = a + b_1 x + b_2 x^2$)时，其 a、b_1 和 b_2 由方程组

$$\left.\begin{aligned} an + b_1\sum x + b_2\sum x^2 &= \sum y \\ a\sum x + b_1\sum x^2 + b_2\sum x^3 &= \sum xy \\ a\sum x^2 + b_1\sum x^3 + b_2\sum x^4 &= \sum x^2 y \end{aligned}\right\} \tag{13.8}$$

解出；当 $k=3$($\hat{y}_3 = a + b_1 x + b_2 x^2 + b_3 x^3$)时，其 a、b_1、b_2 和 b_3 由方程组

$$\left.\begin{aligned} an + b_1\sum x + b_2\sum x^2 + b_3\sum x^3 &= \sum y \\ a\sum x + b_1\sum x^2 + b_2\sum x^3 + b_3\sum x^4 &= \sum xy \\ a\sum x^2 + b_1\sum x^3 + b_2\sum x^4 + b_3\sum x^5 &= \sum x^2 y \\ a\sum x^3 + b_1\sum x^4 + b_2\sum x^5 + b_3\sum x^6 &= \sum x^3 y \end{aligned}\right\} \tag{13.9}$$

解出；依此类推。

上述多项式正规方程组的求解解法很多，如消元法、换元法、行列式法等。这里结合实例介绍用简化表格法解多项式正规方程组，求回归系数和回归截距，建立回归方程的方法。

【例 13.1】 为研究温度对黑木耳菌丝生长的影响，在 7 种温度条件下培养黑木耳，其菌丝平均生长情况列于表 13-1。试建立黑木耳菌丝长度依温度变化的多项式回归方程。

表 13-1　黑木耳菌丝生长与温度的关系

温度(x)/℃	10	15	20	25	30	35	40
菌丝长度(y)/cm	1.33	1.60	3.64	5.48	6.16	4.25	0.64
菌丝长度($\hat{y}$)/cm	1.88	1.91	3.60	5.27	5.95	4.66	0.44

该资料的散点图(图 13-1)有一个向上的凸起，且峰两侧不对称，故以配合三次多项式方程拟合较为合适。

(1) 根据表 13-1 计算出以下数据。

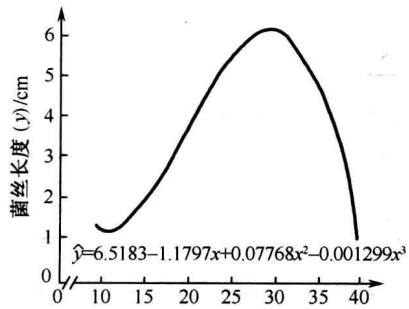

图 13-1　黑木耳菌丝长度与温度的关系

$$\sum x = 175 \qquad \sum x^2 = 5075 \qquad \sum x^3 = 161875$$

$$\sum x^4 = 5481875 \qquad \sum x^5 = 193046875 \qquad \sum x^6 = 6983796875$$

$$\sum y = 23.1 \qquad \sum xy = 606.25 \qquad \sum x^2 y = 17148.25$$

$$\sum x^3 y = 510973.75 \qquad \sum y^2 = 104.0266 \qquad n = 7$$

因而，依变量的总变异平方和为

$$SS_y = \sum y^2 - \frac{\left(\sum y\right)^2}{n} = 104.0266 - \frac{23.1^2}{7} = 27.7966$$

(2) 建立正规方程组。将上面一级数据代入式(13.9)，建立正规方程组：

$$\begin{cases} 7a + 175b_1 + 5075b_2 + 161875b_3 = 23.1 \\ 175a + 5075b_1 + 161875b_2 + 5481875b_3 = 606.25 \\ 5075a + 161875b_1 + 5481875b_2 + 193046875b_3 = 17148.25 \\ 161875a + 5481875b_1 + 193046875b_2 + 6983796875b_3 = 510973.75 \end{cases}$$

(3) 采用简化表解法解正规方程组。

将系数矩阵抄入表 13-2 的算阵 $\boldsymbol{A}$，并将乘积和列向量 $\boldsymbol{K}$ 伴随其后。算阵 $\boldsymbol{B}$ 各元素的计算方法同多元回归一样，结果也列于表 13-2 中。表 13-2 中 a、b_1、b_2、b_3 的算法与多元回归中逆矩阵各元素的算法相同，即由算阵 $\boldsymbol{B}$ 主对角线以上各元素和 $\boldsymbol{B}$ 阵 K 列建立方程组：

表 13-2　例 13.1 资料多项式回归统计数的解出

说明	列 / 行	1	2	3	4	K
算阵 $\boldsymbol{A}$	1	7	175	5075	161875	23.1
	2	175	5075	161875	5481875	606.25
	3	5075	161875	5481875	193046875	17148.25
	4	161875	5481875	193046875	6983796875	510973.75

续表

说明	列 / 行	1	2	3	4	K
算阵 $\boldsymbol{B}$	1	7	25	725	23125	3.3
	2	175	700	50	2050	0.04107
	3	5075	35000	52500	75	−0.01975
	4	161875	1435000	3937500	3375000	−0.001299
解		$a=6.51825$	$b_1=-1.17973$	$b_2=0.077675$	$b_3=-0.001299$	

$$\begin{cases} a+25b_1+725b_2+23125b_3=3.3 \\ b_1+50b_2+2050b_3=0.04107 \\ b_2+75b_3=-0.01975 \\ b_3=-0.001299 \end{cases}$$

解此方程组，得 $b_1=-1.17973$、$b_2=0.077675$、$b_3=-0.001299$、$a=6.51825$。因而表13-1资料的多项式回归方程为

$$\hat{y}=6.5183-1.1797x+0.07768x^2-0.001299x^3$$

二、多项式回归方程的图示

将表13-1观测值代入所求方程$\hat{y}=6.5183-1.1797x+0.07768x^2-0.001299x^3$，得出各观测值所对应的$\hat{y}$值，列于表13-1中，其轨迹如图13-1所示。

根据方程$\hat{y}=6.5183-1.1797x+0.07768x^2-0.001299x^3$，可得出图13-1所示曲线在自变量 $x=\dfrac{-b_2}{3b_3}=\dfrac{-0.07768}{3\times(-0.001299)}=19.93$(℃) 上有一拐点，当自变量 $x=\dfrac{-b_2-\sqrt{b_2^2-3b_1b_3}}{3b_3}=\dfrac{-0.07768-\sqrt{0.07768^2-3\times(-1.1797)\times(-0.001299)}}{3\times(-0.001299)}=29.665$(℃) 上，即温度在29.665℃时，黑木耳菌丝长度最大，其估计值为

$$\begin{aligned}\hat{y}&=6.5183-1.1797\times29.665+0.07768\times29.665^2-0.001299\times29.665^3\\&=5.9707(\text{cm})\end{aligned}$$

第三节　多项式回归方程的假设检验

同其他回归一样，多项式回归中依变量 y 的离均差总平方和也可以分解为回归平方和与离回归平方和，回归平方和又可以分解为因一次项回归平方和、因二次项回归平方和、…、因 k 次项的回归平方和。设 U_1、U_2、…、U_k 分别为一次、二次、…、k 次多项式的回归平方和，则 U_2-U_1 为二次式比一次式增加的回归平方和、U_3-U_2 为三次式比二次式增加的回归平方和、…、U_k-U_{k-1} 为 k 次式比 $k-1$ 次式增加的回归平方和。这些回归平方和利用表13-2算阵 $\boldsymbol{B}$ 的一些信息可以很容易给出：

$$\left.\begin{aligned} U_1 &= b_{22}b_{2K}^2 \\ U_2 &= b_{22}b_{2K}^2 + b_{33}b_{3K}^2 = \sum_{i=2}^{3} b_{ii}b_{iK}^2 \\ U_3 &= b_{22}b_{2K}^2 + b_{33}b_{3K}^2 + b_{44}b_{4K}^2 = \sum_{i=2}^{4} b_{ii}b_{iK}^2 \\ &\vdots \qquad\qquad \vdots \qquad\qquad \vdots \\ U_k &= \sum_{i=2}^{k+1} b_{ii}b_{iK}^2 \end{aligned}\right\} \tag{13.10}$$

$$\left.\begin{aligned} U_2 - U_1 &= b_{33}b_{3K}^2 \\ U_3 - U_2 &= b_{44}b_{4K}^2 \\ U_4 - U_3 &= b_{55}b_{5K}^2 \\ &\vdots \quad \vdots \quad\quad \vdots \\ U_k - U_{k-1} &= b_{(k+1)(k+1)}b_{(k+1)K}^2 \end{aligned}\right\} \tag{13.11}$$

进行多项式回归分析时，y 的总变异可以分解为回归和离回归两部分。即

$$SS_y = U_k + Q_k \tag{13.12}$$

在多项式回归中 $H_0:\beta_j = 0(j = 1,2,\cdots,k)$，对 $H_A:\beta_j \neq 0$，用下式进行检验：

$$F = \frac{U_k - U_{k-1}}{\dfrac{Q_k}{n-k-1}} \tag{13.13}$$

自由度 $df_1 = 1$、$df_2 = n-k-1$，经 F 检验略去不显著项，即为所建多项式回归方程。

【例 13.2】 试对例 13.1 所建多项式回归方程进行假设检验。

首先利用表 13-2 中算阵 $\boldsymbol{B}$ 的结果计算各次分量的回归平方和及 3 次多项式的回归平方和与离回归平方和。

$$U_1 = b_{22}b_{2K}^2 = 700 \times 0.04107^2 = 1.1807$$

$$U_2 - U_1 = b_{33}b_{3K}^2 = 52500 \times (-0.01975)^2 = 20.4783$$

$$U_3 - U_2 = b_{44}b_{4K}^2 = 3375000 \times (-0.001299)^2 = 5.6950$$

$$U_3 = \sum_{i=2}^{4} b_{ii}b_{iK}^2 = 700 \times 0.04107^2 + 52500 \times (-0.01975)^2 + 3375000 \times (-0.001299)^2 = 27.3540$$

$$Q_3 = SS_y - U_3 = 27.7966 - 27.3540 = 0.4426$$

将计算结果列入方差分析表(表 13-3) 进行 F 检验。

表 13-3　黑木耳菌丝长度依温度多项式回归的假设检验

变异来源	df	SS	s^2	F	$F_{0.05}$	$F_{0.01}$
回归	3	27.3540	9.1180	61.82**	9.28	29.46
一次分量	1	1.1807	1.1807	8.00	10.13	34.12
二次分量	1	20.4783	20.4783	138.84**	10.13	34.12
三次分量	1	5.6950	5.6950	38.61**	10.13	34.12
离回归	3	0.4426	0.1475			
总变异	6	27.7966				

F 检验表明，二次、三次分量均达极显著水平，一次分量接近显著水平，三次多项式回归达极显著水平，可见配合三次多项式是合适的。其回归估计标准误：

$$s_{y/x,x^2,x^3}=\sqrt{\frac{Q_3}{n-k-1}}=\sqrt{\frac{0.4426}{7-3-1}}=0.3841$$

第四节　相关指数

在多元线性相关分析中，我们曾用多元相关系数表示各自变量与依变量的相关程度。同样，k 次多项式的回归平方和占总变异平方和的比率的平方根值，亦可用来表示依变量 y 和自变量 x 的多项式的相关密切程度，即有

$$R_k=\sqrt{\frac{U_k}{SS_y}}=\sqrt{\frac{SS_y-Q_k}{SS_y}} \tag{13.14}$$

式中，R_k 称为相关指数(correlation exponential)。

和线性相关时的情况一样，

$$R_k^2=\frac{U_k}{SS_y} \tag{13.15}$$

表示 k 次多项式的决定系数(coefficient of determination)。它表明在 y 的总变异平方和中，可由 x 的 k 次多项式说明的部分所占的比率。

【例 13.3】 试求例 13.1 资料温度和黑木耳菌丝生长的相关指数。

$$R_3=\sqrt{\frac{27.3540}{27.7966}}=0.9920^{**}$$

查附表 8，$df=7-3-1=3$ 时，$R_{0.01}=0.959$。现 $R_3=0.9920>0.959$，故 y 和 x 的三次多项式的相关为极显著。对于决定系数，则有

$$R_3^2=\frac{27.3540}{27.7966}=0.9841$$

这表明，该黑木耳生长总变异有 98.41%可由温度的三次多项式说明。

第五节　正交多项式回归分析

一、正交多项式回归分析原理

在多项式回归分析中，计算自变量 x 的高次方和解正规方程组等都有一定的工作量。如果 x 的取值为一等差数列(或可转化成等差数列)，且对应于每一个 x、y 都有相等的观测次数，则可将多项式回归模型中 x 的各次幂都转换成一组特定的正交多项式(orthogonal polynomial)，以简化分析。这种分析方法称为正交多项式回归(orthogonal polynomial regression)，即将式(13.4)转换为

$$\hat{y}=\bar{y}+b'_1\varphi_1(x)+b'_2\varphi_2(x)+\cdots+b'_k\varphi_k(x)=\bar{y}+\sum_{j=1}^{k}b'_j\varphi_j(x) \tag{13.16}$$

式中，$\varphi_1(x)$、$\varphi_2(x)$、…、$\varphi_k(x)$ 都是 x 的函数，分别表示 1 次、2 次、…、k 次正交多项式。为保证正交性(orthogonality)，该转换须满足：

$$\sum\varphi_1(x)=\sum\varphi_2(x)=\cdots=\sum\varphi_k(x)=0$$

$$\sum\varphi_i(x)\sum\varphi_j(x)=0 \qquad (i,j=1,2,\cdots,k,i\neq j)$$

可以证明，当 x 数列可用：

$$x_{i+1}=x_i+h_i \qquad (h\text{ 为公差},i=1,2,\cdots,n) \tag{13.17}$$

表示时，满足正交条件的 $x_j(j=1,2,\cdots,k)$ 的 $\varphi_j(x)$ 为

$$\left.\begin{aligned}
\varphi_1(x)&=\frac{x-\bar{x}}{h}\\
\varphi_2(x)&=\left(\frac{x-\bar{x}}{h}\right)^2-\frac{n^2-1}{12}\\
\varphi_3(x)&=\left(\frac{x-\bar{x}}{h}\right)^3-\frac{3n^2-7}{20}\left(\frac{x-\bar{x}}{h}\right)\\
\varphi_4(x)&=\left(\frac{x-\bar{x}}{h}\right)^4-\frac{3n^2-13}{14}\left(\frac{x-\bar{x}}{h}\right)^2+\frac{3(n^2-1)(n^2-9)}{560}\\
\varphi_5(x)&=\left(\frac{x-\bar{x}}{h}\right)^5-\frac{5(n^2-7)}{18}\left(\frac{x-\bar{x}}{h}\right)^3+\frac{15n^2-230n+407}{1008}\left(\frac{x-\bar{x}}{h}\right)\\
&\vdots\qquad\qquad\vdots\qquad\qquad\vdots\qquad\qquad\vdots\\
\varphi_{k+1}(x)&=\varphi_1(x)\varphi_k(x)-\frac{k^2(n^2-k^2)}{4(4k^2-1)}\varphi_{k-1}(x)
\end{aligned}\right\} \tag{13.18}$$

例如，设 x 变量的取值为 3、5、7、9、11，可表示为 $x_i=1+2i$，其对应的 $\varphi_i(x)$ 为

$$\begin{aligned}
\varphi_1(x)&:\ -2,-1,\ \ 0,\ \ \ 1,\ \ 2\\
\varphi_2(x)&:\ \ \ 2,-1,-2,\ \ -1,\ \ 2\\
\varphi_3(x)&:-1.2,2.4,\ \ 0,-2.4,1.2
\end{aligned}$$

以上 $\varphi_j(x)$ 都满足正交的两个条件，但不一定是整数，为避免正交系数有小数和分数，可再作一次转换，即选择一个适当的因数 λ_j，使

$$c_j=\lambda_j\varphi_j(x) \qquad (j=1,2,\cdots,k) \tag{13.19}$$

为绝对值尽可能小的整数。c_j 值称为 j 次多项式的正交系数(orthogonal coefficient)，上述将 x_j 转换成 c_j 的实质是将多项式的正规方程组转换成对角阵：

$$\left.\begin{aligned}
b_1'\sum c_1^2+\ 0\ +\ 0\ +\cdots+\ 0\ &=c_1y\\
0\ +b_2'\sum c_2^2+\ 0\ +\cdots+\ 0\ &=c_2y\\
0\ +\ 0\ +b_3'\sum c_3^2+\cdots+\ 0\ &=c_3y\\
\vdots\quad\vdots\quad\vdots\quad\vdots\ &\\
0\ +\ 0\ +\ 0\ +\cdots+b_k'\sum c_k^2&=c_ky
\end{aligned}\right\} \tag{13.20}$$

因而

$$b_j'=\frac{\sum c_jy}{\sum c_j^2} \qquad (j=1,2,\cdots,k) \tag{13.21}$$

则所得多项式回归方程为

$$\hat{y}=\bar{y}+b'_1c_1+b'_2c_2+\cdots+b'_kc_k=\bar{y}+\sum_{j=1}^{k}b'_jc_j \tag{13.22}$$

将 $c_j=\lambda_j\varphi_j(x)$ 代入式(13.22)，得 y 依 x 的 k 次多项式回归方程为

$$\hat{y}=\bar{y}+b'_1\lambda_1\varphi_1(x)+b'_2\lambda_2\varphi_2(x)+\cdots+b'_k\lambda_k\varphi_k(x)=\bar{y}+\sum_{j=1}^{k}b'_j\lambda_j\varphi_j(x) \tag{13.23}$$

因各次分量的回归平方和为

$$U_j-U_{j-1}=\frac{\left(\sum c_jy\right)^2}{\sum c_j^2} \tag{13.24}$$

因此，根据附表 11，可以很方便地作出 $k\leqslant 5$ 的多项式回归分析。

当自变量的取值为不等间距(即非等差数列)时，可以经一定的转化变为等间距的，再应用正交多项式回归的分析方法，但这增加了计算工作量。因此，我们在进行试验时，最好使各处理等间距，这在统计分析上是很有益处的。

二、正交多项式回归分析示例

【例 13.4】 例 13.1 的自变量 x 为等间距，试用正交系数作正交多项式回归分析。

如前所述，对例 13.1 数据资料配合三次多项式较为合适。现将该资料的 x 放在表 13-4 的前一列，y 放在最后一列。该资料 $n=7$，$h=5$。故从附表 11 抄下 $n=7$ 的 c_1、c_2、c_3 值分别放在表 13-4 的中间三列。这些 c_j 值即为各相应的 x_j 正交转换值，然后计算各个 $\sum c_jy$。

表 13-4　例 13.1 资料的正交多项式回归计算

x	c_1	c_2	c_3	y
10	−3	5	−1	1.33
15	−2	0	1	1.60
20	−1	−3	1	3.64
25	0	−4	0	5.48
30	1	−3	−1	6.16
35	2	0	−1	4.25
40	3	5	1	0.64
$\sum c_j^2$	28	84	6	
λ_j	1	1	1/6	$\bar{x}=25$
$\sum c_jy$	5.75	−41.47	−5.86	$\bar{y}=3.3$
b'_j	0.205357	−0.493690	−0.976667	$SS_y=27.7966$
U_j-U_{j-1}	1.1808	20.4733	5.7233	

$$\sum c_1y=(-3)\times 1.33+(-2)\times 1.60+\cdots+3\times 0.64=5.75$$

$$\sum c_2y=5\times 1.33+0\times 1.60+\cdots+5\times 0.64=-41.47$$

$$\sum c_3 y = (-1) \times 1.33 + 1 \times 1.60 + \cdots + 1 \times 0.64 = -5.86$$

各次分量的偏回归平方和为

$$U_1 = \frac{\left(\sum c_1 y\right)^2}{\sum c_1^2} = \frac{5.75^2}{28} = 1.1808$$

$$U_2 - U_1 = \frac{\left(\sum c_2 y\right)^2}{\sum c_2^2} = \frac{(-41.47)^2}{84} = 20.4733$$

$$U_3 - U_2 = \frac{\left(\sum c_3 y\right)^2}{\sum c_3^2} = \frac{(-5.86)^2}{6} = 5.7233$$

而三次多项式的回归平方和与离回归平方和为

$$U_3 = U_1 + (U_2 - U_1) + (U_3 - U_2)$$
$$= 1.1808 + 20.4733 + 5.7233 = 27.3774$$
$$Q_3 = SS_y - U_3 = 27.7966 - 27.3774 = 0.4192$$

将计算结果列入方差分析表(表 13-5),并进行 F 检验:

表 13-5　黑木耳丝长度依温度的正交多项式回归的假设检验

变异来源	df	SS	s^2	F	$F_{0.05}$	$F_{0.01}$
回归	3	27.3774	9.1258	65.32**	9.28	29.46
一次分量	1	1.1808	1.1808	8.45	10.13	34.12
二次分量	1	20.4733	20.4733	146.55**	10.13	34.12
三次分量	1	5.7233	5.7233	40.97**	10.13	34.12
离回归	3	0.4192	0.1397			
总变异	6	27.7966				

各次分量的偏回归系数为

$$b_1' = \frac{\sum c_1 y}{\sum c_1^2} = \frac{5.75}{28} = 0.205357$$

$$b_2' = \frac{\sum c_2 y}{\sum c_2^2} = \frac{-41.47}{84} = -0.493690$$

$$b_3' = \frac{\sum c_3 y}{\sum c_3^2} = \frac{-5.86}{6} = -0.976667$$

因此,有

$$\hat{y} = 3.3 + 0.205357 c_1 - 0.493690 c_2 - 0.976667 c_3$$

由于

$$c_1 = \lambda_1 \left(\frac{x - \bar{x}}{h}\right) = 1 \times \left(\frac{x - 25}{5}\right) = \frac{x - 25}{5}$$

$$c_2 = \lambda_2 \left[\left(\frac{x - \bar{x}}{h}\right)^2 - \frac{n^2 - 1}{12}\right] = 1 \times \left[\left(\frac{x - 25}{5}\right)^2 - \frac{7^2 - 1}{12}\right]$$

$$=\frac{(x-25)^2}{25}-4$$

$$c_3=\lambda_3\left[\left(\frac{x-\bar{x}}{h}\right)^3-\frac{3n^2-7}{20}\left(\frac{x-\bar{x}}{h}\right)\right]$$

$$=\frac{1}{6}\times\left[\left(\frac{x-25}{5}\right)^3-\frac{3\times7^2-7}{20}\times\left(\frac{x-25}{5}\right)\right]$$

$$=\frac{(x-25)^3}{750}-\frac{7\times(x-25)}{30}$$

则所求多项式回归方程为

$$\hat{y}=3.3+0.205357\times\left(\frac{x-25}{5}\right)-0.493690\times\left[\frac{(x-25)^2}{25}-4\right]$$

$$-0.976667\times\left[\frac{(x-25)^3}{750}-\frac{7\times(x-25)}{30}\right]$$

$$=6.552-1.1849x+0.077902x^2-0.001302x^3$$

以上结果与本章第二节求解正规方程组的结果基本一样，稍有出入是由于计算误差所致，但如果采用正交系数分析则可减少很多计算工作量。

思考练习题

习题 13.1　建立多项式回归的基本方法是什么？

习题 13.2　什么是相关指数？如何求解？

习题 13.3　正交性必须满足的条件是什么？如何进行正交多项式回归的分析？

习题 13.4　取连年施用有机肥的水稻土(pH=5.5)，加入 HCl 或 Na_2CO_3 改变其 pH (x)，在 30℃下放置28d，然后中和之，测定每100g烘干土中 NH_4^+ 的毫克数(y)，结果如下表所示。试确定 y 依 x 变化的多项式回归方程，并进行检验。

x	2	3	4	5	6	7	8	9
y	13.0	9.2	6.6	4.7	4.0	7.1	13.2	20.0

习题 13.5　根据习题 13.4 数据，试建立正交多项式回归方程。

主要参考文献

北京大学数学力学系数学专业概率统计组.正交设计.北京:人民教育出版社,1976

陈兰荪.生物数学引论.北京:科学出版社,1988

陈庆富. 生物统计学. 北京:高等教育出版社,2011

崔党群.生物统计学.北京:中国科学技术出版社,1994

丁岩钦.昆虫种群生态学原理与应用.北京:科学出版社,1980

董德元,杨节,苏教文.试验研究的数理统计方法.北京:中国计量出版社,1987

董时富.生物统计学.北京:科学出版社,2002

杜荣骞.生物统计学(第三版).北京:高等教育出版社,2009

范濂.农业试验统计方法.郑州:河南科学技术出版社,1983

范剑青,林希虹,刘军. 生物统计学和生物信息学最新进展. 北京:高等教育出版社,2009

方积乾. 卫生统计学(第六版). 北京:人民卫生出版社,2008

高惠璇.应用多元统计分析.北京:北京大学出版社,2005

耿修林,谢兆茹.应用统计学(第二版).北京:科学出版社,2008

顾志峰,叶乃好,石辉华. 实用生物统计学. 北京:科学出版社,2012

贵州农学院.生物统计附试验设计.北京:农业出版社,1980

郭平毅. 生物统计学. 北京:中国林业出版社,2006

洪伟.林业试验设计技术与方法.北京:中国林业出版社,1993

黄嘉佑.气象统计分析与预报方法(第二版) .北京:气象出版社,2000

江三多,吕宝忠.医学遗传数理统计方法.北京:科学出版社,1998

姜启源,谢金皇,叶俊.数学模型(第三版) .北京:高等教育出版社,2008

金丕焕.医用统计方法.上海:上海医科大学出版社,1993

李松岗. 实用生物统计(第二版). 北京: 北京大学出版社,2007

刘来福,程书肖,李仲来. 生物统计(第二版). 北京: 北京师范大学出版社,2007

林德光.生物统计的数学原理.沈阳:辽宁人民出版社,1982

陆建身.生物统计学.北京:科学出版社,2003

马斌荣.医学统计学(第五版) .北京:人民卫生出版社,2008

马育华.试验统计.北京:农业出版社,1982

么枕生.气候统计.北京:气象出版社,1990

明道绪.田间试验与统计分析(第二版).北京:科学出版社,2008

莫惠栋.农业试验统计.上海:上海科学技术出版社,1984

南京农业大学.田间试验和统计方法(第二版) .北京:农业出版社,1987

倪宗瓒.卫生统计学(第四版) .北京:人民卫生出版社,2002

欧阳叙向. 生物统计附试验设计. 重庆:重庆大学出版社,2007

上海师范大学数学系概率统计教研组.回归分析及其试验设计.上海:上海教育出版社,1978

宋素芳,秦豪荣,赵聘. 生物统计学(第二版). 北京:中国农业大学出版社,2011

斯皮格尔 M R,斯蒂芬斯 L J. 统计学(第三版) .杨纪龙,杜秀丽,姚奕,等译.北京:科学出版社、麦格劳希尔教育出版集团,2002

苏胜宝. 试验设计与生物统计. 北京:中央广播电视大学出版社,2010

唐守正,郎奎建,李海奎. 统计和生物数学模型计算(ForStat 教程). 北京:科学出版社,2009

童一中.生物统计法.长沙:湖南科学技术出版社,1987

王芳,李传仁. 田间试验与生物统计. 北京:化学工业出版社,2009

王福亭.农业试验设计与统计分析.北京:农村读物出版社,1993
王宏年.生物统计学.兰州:兰州大学出版社,1987
王鉴明.生物统计学.北京:农业出版社,1988
乌祥光.昆虫生态学的常用数学分析方法(修订版).北京:农业出版社,1985
吴贵生.试验设计与数据处理.北京:冶金工业出版社,1991
吴占福,王艳立. 生物统计与试验设计. 北京:化学工业出版社,2010
徐端正.生物统计在实验和临床药理学中的应用.北京:科学出版社,2004
徐继初.生物统计及试验设计.北京:农业出版社,1994
徐克学.生物数学.北京:科学出版社,2002
徐魁英.食品研究与数据分析.北京:中国轻工业出版社,2005
续九如,黄智慧.林业试验设计.北京:中国林业出版社,1995
杨纪珂,齐翔林.现代生物统计.合肥:安徽科学技术出版社,1985
杨永年.畜牧统计学.哈尔滨:东北林业大学出版社,1990
杨永岐.农业气象中的统计方法.北京:气象出版社,1983
叶子弘,陈春. 生物统计学. 北京:化学工业出版社,2012
袁志发,宋世德.多元统计分析(第二版).北京:科学出版社,2009
张春华,严云良.医药数理统计.北京:科学出版社,2001
张勤.生物统计学(第二版).北京:中国农业大学出版社,2008
张全德,胡秉民.农业试验统计模型和 BASIC 程序.杭州:浙江科学技术出版社,1985
张尧庭,方开泰.多元统计分析引论.北京:科学出版社,1982
张应芬.应用统计方法.郑州:中原农民出版社,1994
赵仁熔.田间试验方法.北京:农业出版社,1979
中国科学院计算中心.概率统计计算.北京:科学出版社,1979
中国科学院数学研究所.回归分析方法.北京:科学出版社,1975
中国科学院数学研究所统计组.常用数理统计表.北京:科学出版社,1974
周海龙,周开兵. SAS 生物统计分析应用教程. 北京:化学工业出版社,2011
朱长山,徐通模.试验设计与数据处理.西安:西安交通大学,1988
朱明德,余光辉.统计预测与控制.北京:中国林业出版社,1993
朱明哲.田间试验及统计分析.北京:农业出版社,1992
Altman D G .Practical Statistics for Medical Research .London:Chapman & Hall ,1991
Bailey T J .Statistics Method in Biology (2nd ed) .London:Hodder and Stoughton ,1981
Bernard R. 生物统计学基础(第五版).孙尚拱译.北京:科学出版社,2004
Bishop O N .Statistics of Biology(3rd ed .) .London :Longman Group Lincital ,1980
Damaraju R .Statistical Techniques in Agricultural and Biological Research .London :Oxford and I .B .H .Publication Co .,1983
Gail F, Dawson. Easy Interpretation of Biostatistics: The Vital Linh to Applying Evidence in Medical Decisions. New York:Saunders,2008
Geoffrey R. N,David L S. 生物统计学基础(第三版). 凌莉译. 北京:人民卫生出版社,2010
Georga W S, William G C. Statistical Methods .Ames: Iowa State University Press ,1989
Jerrold H Z .Biostatistical Analysis(4th ed) .New York :Prentice Hall Upper Saddle River,1999
Miroslav K, William L. 动物科学生物统计导论(第二版). 于向春,张豪,张文广,等译.北京:中国农业大学出版社,2011
Robert D G,Duncan G S, Leopold B,等. 数理统计的原理和方法(适用于生物科学).杨纪珂等译.北京:科学出版社,1979
Sunil K M. Statistical Bioinformatics. Salt Lake City:Academic Press,2010
Thomas G ,Kevin M .An Introduction to Biostatistics .New York :McGraw-Hill Education Co .,2008

附　表

附表 1　正态分布的累积函数 $F(u)$值表

u	−0.09	−0.08	−0.07	−0.06	−0.05	−0.04	−0.03	−0.02	−0.01	−0.00
−3.9	0.000033	0.000034	0.000036	0.000037	0.000039	0.000041	0.000042	0.000044	0.000046	0.000048
−3.8	0.000050	0.000052	0.000054	0.000057	0.000059	0.000062	0.000064	0.000067	0.000069	0.000072
−3.7	0.000075	0.000078	0.000082	0.000085	0.000088	0.000092	0.000096	0.000100	0.000104	0.000108
−3.6	0.000112	0.000117	0.000121	0.000126	0.000131	0.000136	0.000142	0.000147	0.000153	0.000159
−3.5	0.000165	0.000172	0.000179	0.000185	0.000193	0.000200	0.000208	0.000216	0.000224	0.000233
−3.4	0.000242	0.000251	0.000260	0.000270	0.000280	0.000291	0.000302	0.000313	0.000325	0.000337
−3.3	0.000350	0.000362	0.000376	0.000390	0.000404	0.000419	0.000434	0.000450	0.000467	0.000483
−3.2	0.000501	0.000519	0.000538	0.000557	0.000577	0.000598	0.000619	0.000641	0.000664	0.000687
−3.1	0.000711	0.000736	0.000762	0.000789	0.000816	0.000845	0.000874	0.000904	0.000935	0.000968
−3.0	0.001001	0.001035	0.001070	0.001107	0.001144	0.001183	0.001223	0.001264	0.001306	0.001350
−2.9	0.001395	0.001441	0.001489	0.001538	0.001589	0.001641	0.001695	0.001750	0.001807	0.001866
−2.8	0.001926	0.001988	0.002052	0.002118	0.002186	0.002256	0.002327	0.002401	0.002477	0.002555
−2.7	0.002635	0.002718	0.002803	0.002890	0.002980	0.003072	0.003167	0.003264	0.003364	0.003467
−2.6	0.003573	0.003681	0.003793	0.003907	0.004025	0.004145	0.004269	0.004396	0.004527	0.004661
−2.5	0.004799	0.004940	0.005085	0.005234	0.005386	0.005543	0.005703	0.005868	0.006037	0.006210
−2.4	0.006387	0.006569	0.006756	0.006947	0.007143	0.007344	0.007549	0.007760	0.007976	0.008198
−2.3	0.008424	0.008656	0.008894	0.009137	0.009387	0.009642	0.009903	0.01017	0.01044	0.01072
−2.2	0.01101	0.01130	0.01160	0.01191	0.01222	0.01255	0.01287	0.01321	0.01355	0.01390
−2.1	0.01426	0.01463	0.01500	0.01539	0.01578	0.01618	0.01659	0.01700	0.01743	0.01786
−2.0	0.01831	0.01876	0.01923	0.01970	0.02018	0.02068	0.02118	0.02169	0.02222	0.02275
−1.9	0.02330	0.02385	0.02442	0.02500	0.02559	0.02619	0.02680	0.02743	0.02807	0.02872
−1.8	0.02938	0.03005	0.03074	0.03144	0.03216	0.03288	0.03362	0.03438	0.03515	0.03593
−1.7	0.03673	0.03754	0.03836	0.03920	0.04006	0.04093	0.04182	0.04272	0.04363	0.04457
−1.6	0.04551	0.04648	0.04746	0.04846	0.04947	0.05050	0.05155	0.05262	0.05370	0.05480
−1.5	0.05592	0.05705	0.05821	0.05938	0.06057	0.06178	0.06301	0.06426	0.06552	0.06681
−1.4	0.06811	0.06944	0.07078	0.07215	0.07353	0.07493	0.07636	0.07780	0.07927	0.08076
−1.3	0.08226	0.08379	0.08534	0.08691	0.08851	0.09012	0.09176	0.09342	0.09510	0.09680
−1.2	0.09853	0.1003	0.1020	0.1038	0.1056	0.1075	0.1093	0.1112	0.1131	0.1151
−1.1	0.1170	0.1190	0.1210	0.1230	0.1251	0.1271	0.1292	0.1314	0.1335	0.1357
−1.0	0.1379	0.1401	0.1423	0.1446	0.1469	0.1492	0.1515	0.1539	0.1562	0.1587
−0.9	0.1611	0.1635	0.1660	0.1685	0.1711	0.1736	0.1762	0.1788	0.1814	0.1841
−0.8	0.1867	0.1894	0.1922	0.1949	0.1977	0.2005	0.2033	0.2061	0.2090	0.2119
−0.7	0.2148	0.2177	0.2206	0.2236	0.2266	0.2297	0.2327	0.2358	0.2389	0.2420
−0.6	0.2451	0.2483	0.2514	0.2546	0.2578	0.2611	0.2643	0.2676	0.2709	0.2743
−0.5	0.2776	0.2810	0.2843	0.2877	0.2912	0.2946	0.2981	0.3015	0.3050	0.3085
−0.4	0.3121	0.3156	0.3192	0.3228	0.3264	0.3300	0.3336	0.3372	0.3409	0.3446
−0.3	0.3483	0.3520	0.3557	0.3594	0.3632	0.3669	0.3707	0.3745	0.3783	0.3821
−0.2	0.3859	0.3897	0.3936	0.3974	0.4013	0.4052	0.4090	0.4129	0.4168	0.4207
−0.1	0.4247	0.4286	0.4325	0.4364	0.4404	0.4443	0.4483	0.4522	0.4562	0.4602
−0.0	0.4641	0.4681	0.4721	0.4761	0.4801	0.4840	0.4880	0.4920	0.4960	0.5000

续表

u	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
0.0	0.5000	0.5040	0.5080	0.5120	0.5160	0.5199	0.5239	0.5279	0.5319	0.5359
0.1	0.5398	0.5438	0.5478	0.5517	0.5557	0.5596	0.5636	0.5675	0.5714	0.5753
0.2	0.5793	0.5832	0.5871	0.5910	0.5948	0.5987	0.6026	0.6064	0.6103	0.6141
0.3	0.6179	0.6217	0.6255	0.6293	0.6331	0.6368	0.6406	0.6443	0.6480	0.6517
0.4	0.6554	0.6591	0.6628	0.6664	0.6700	0.6736	0.6772	0.6808	0.6844	0.6879
0.5	0.6915	0.6950	0.6985	0.7019	0.7054	0.7088	0.7123	0.7157	0.7190	0.7224
0.6	0.7257	0.7291	0.7324	0.7357	0.7389	0.7422	0.7454	0.7486	0.7517	0.7549
0.7	0.7580	0.7611	0.7642	0.7673	0.7703	0.7734	0.7764	0.7794	0.7823	0.7852
0.8	0.7881	0.7910	0.7939	0.7967	0.7995	0.8023	0.8051	0.8078	0.8106	0.8133
0.9	0.8159	0.8186	0.8212	0.8238	0.8264	0.8289	0.8315	0.8340	0.8365	0.8389
1.0	0.8413	0.8438	0.8461	0.8485	0.8508	0.8531	0.8554	0.8577	0.8599	0.8621
1.1	0.8643	0.8665	0.8686	0.8708	0.8729	0.8749	0.8770	0.8790	0.8810	0.8830
1.2	0.8849	0.8869	0.8888	0.8907	0.8925	0.8944	0.8962	0.8980	0.8997	0.90147
1.3	0.90320	0.90490	0.90658	0.90824	0.90988	0.91149	0.91309	0.91466	0.91621	0.91774
1.4	0.91924	0.92073	0.92220	0.92364	0.92507	0.92647	0.92785	0.92922	0.93056	0.93189
1.5	0.93319	0.93448	0.93574	0.93699	0.93822	0.93943	0.94062	0.94179	0.94295	0.94408
1.6	0.94520	0.94630	0.94738	0.94845	0.94950	0.95053	0.95154	0.95254	0.95352	0.95449
1.7	0.95543	0.95637	0.95728	0.95818	0.95908	0.95994	0.96080	0.96164	0.96246	0.96327
1.8	0.96407	0.96485	0.96562	0.96638	0.96712	0.96784	0.96856	0.96926	0.96995	0.97062
1.9	0.97128	0.97193	0.97257	0.97320	0.97381	0.97441	0.97500	0.97558	0.97615	0.97670
2.0	0.97725	0.97778	0.97831	0.97882	0.97932	0.97982	0.98030	0.98077	0.98124	0.98169
2.1	0.98214	0.98257	0.98300	0.98341	0.98382	0.98422	0.98461	0.98500	0.98537	0.98574
2.2	0.98610	0.98645	0.98679	0.98713	0.98745	0.98778	0.98809	0.98840	0.98870	0.98899
2.3	0.98928	0.98956	0.98988	0.990097	0.990358	0.990613	0.990863	0.991106	0.991344	0.991576
2.4	0.991802	0.992024	0.992240	0.992451	0.992656	0.992857	0.993053	0.993244	0.993431	0.993613
2.5	0.993790	0.993963	0.994132	0.994297	0.994457	0.994614	0.994766	0.994915	0.995060	0.995201
2.6	0.995339	0.995473	0.995604	0.995731	0.995855	0.995975	0.996093	0.996207	0.996319	0.996427
2.7	0.996533	0.996636	0.996736	0.996833	0.996928	0.997020	0.997110	0.997197	0.997282	0.997365
2.8	0.997445	0.997523	0.997599	0.997673	0.997744	0.997814	0.997882	0.997948	0.998012	0.998074
2.9	0.998134	0.998193	0.998250	0.998305	0.998359	0.998411	0.998462	0.998511	0.998559	0.998605
3.0	0.998650	0.998694	0.998736	0.998777	0.998817	0.998856	0.998893	0.998930	0.998965	0.998999
3.1	0.999032	0.999065	0.999096	0.999126	0.999155	0.999184	0.999211	0.999238	0.999264	0.999289
3.2	0.999313	0.999336	0.999359	0.999381	0.999402	0.999423	0.999443	0.999462	0.999481	0.999499
3.3	0.999517	0.999534	0.999550	0.999566	0.999581	0.999596	0.999610	0.999624	0.999638	0.999651
3.4	0.999663	0.999675	0.999687	0.999698	0.999709	0.999720	0.999730	0.999740	0.999750	0.999759
3.5	0.999767	0.999776	0.999784	0.999792	0.999800	0.999807	0.999815	0.999822	0.999828	0.999835
3.6	0.999841	0.999847	0.999853	0.999858	0.999864	0.999869	0.999874	0.999879	0.999883	0.999888
3.7	0.999892	0.999896	0.999900	0.999904	0.999908	0.999912	0.999915	0.999918	0.999922	0.999925
3.8	0.999928	0.999931	0.999933	0.999936	0.999938	0.999941	0.999943	0.999946	0.999948	0.999950
3.9	0.999952	0.999954	0.999956	0.999958	0.999959	0.999961	0.999963	0.999964	0.999966	0.999967

附表 2　正态离差(u)值表(双尾)

P	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
0.0	∞	2.575829	2.326348	2.170090	2.053749	1.959964	1.880794	1.811911	1.750686	1.695398
0.1	1.644854	1.598193	1.554774	1.514102	1.475791	1.439531	1.405072	1.372204	1.340755	1.310579
0.2	1.281552	1.253565	1.226528	1.200359	1.174987	1.150349	1.126391	1.103063	1.080319	1.058122
0.3	1.036433	1.015222	0.994458	0.974114	0.954165	0.934589	0.915365	0.896473	0.877896	0.859617
0.4	0.841621	0.823894	0.806421	0.789192	0.772193	0.755415	0.738847	0.722479	0.706303	0.690309
0.5	0.674490	0.658838	0.643345	0.628006	0.612813	0.597760	0.582841	0.568051	0.553385	0.538836
0.6	0.524401	0.510073	0.495850	0.481727	0.467699	0.453762	0.439913	0.426148	0.412463	0.398855
0.7	0.385320	0.371856	0.358459	0.345125	0.331853	0.318639	0.305481	0.292375	0.279319	0.266311
0.8	0.253347	0.240426	0.227545	0.214702	0.201893	0.189113	0.176374	0.163658	0.150969	0.138304
0.9	0.125661	0.113039	0.100434	0.087845	0.075270	0.062707	0.050154	0.037608	0.025069	0.012533

P	0.001	0.0001	0.00001	0.000001	0.0000001	0.00000001
u	3.29053	3.89059	4.41717	4.89164	5.32672	5.73073

附表 3　t 值表(双尾)

自由度	概率值(P)								
(df)	0.500	0.400	0.200	0.100	0.050	0.025	0.010	0.005	0.001
1	1.000	1.376	3.078	6.314	12.706	25.452	63.657		
2	0.816	1.061	1.886	2.920	4.303	6.205	9.925	14.089	31.598
3	0.765	0.978	1.638	2.353	3.182	4.176	5.841	7.453	12.941
4	0.741	0.941	1.533	2.132	2.776	3.495	4.604	5.598	8.610
5	0.727	0.920	1.476	2.015	2.571	3.163	4.032	4.773	6.859
6	0.718	0.906	1.440	1.943	2.447	2.969	3.707	4.317	5.959
7	0.711	0.896	1.415	1.895	2.365	2.841	3.499	4.029	5.405
8	0.706	0.889	1.397	1.860	2.306	2.752	3.355	3.832	5.041
9	0.703	0.883	1.383	1.833	2.262	2.685	3.250	3.690	4.781
10	0.700	0.879	1.372	1.812	2.228	2.634	3.169	3.581	4.587
11	0.697	0.876	1.363	1.796	2.201	2.593	3.106	3.497	4.437
12	0.695	0.873	1.356	1.782	2.179	2.560	3.056	3.428	4.318
13	0.694	0.870	1.350	1.771	2.160	2.533	3.012	3.372	4.221
14	0.692	0.868	1.345	1.761	2.145	2.510	2.977	3.326	4.140
15	0.691	0.866	1.341	1.753	2.131	2.490	2.947	3.286	4.073
16	0.690	0.865	1.337	1.746	2.120	2.473	2.921	3.252	4.015
17	0.689	0.863	1.333	1.740	2.110	2.458	2.898	3.222	3.965
18	0.688	0.862	1.330	1.734	2.101	2.445	2.878	3.197	3.922
19	0.688	0.861	1.328	1.729	2.093	2.433	2.861	3.174	3.883
20	0.687	0.860	1.325	1.725	2.086	2.423	2.845	3.153	3.850
21	0.686	0.859	1.323	1.721	2.080	2.414	2.831	3.135	3.819
22	0.686	0.858	1.321	1.717	2.074	2.406	2.819	3.119	3.792
23	0.685	0.858	1.319	1.714	2.069	2.398	2.807	3.104	3.767
24	0.685	0.857	1.318	1.711	2.064	2.391	2.797	3.090	3.745
25	0.684	0.856	1.316	1.708	2.060	2.385	2.787	3.078	3.725
26	0.684	0.856	1.315	1.706	2.056	2.379	2.779	3.067	3.707
27	0.684	0.855	1.314	1.703	2.052	2.373	2.771	3.056	3.690
28	0.683	0.855	1.313	1.701	2.048	2.368	2.763	3.047	3.674
29	0.683	0.854	1.311	1.699	2.045	2.364	2.756	3.038	3.659
30	0.683	0.854	1.310	1.697	2.042	2.360	2.750	3.030	3.646
40	0.681	0.851	1.303	1.684	2.021	2.329	2.704	2.971	3.551
60	0.679	0.848	1.296	1.671	2.000	2.299	2.660	2.915	3.460
80	0.678	0.847	1.293	1.665	1.989	2.284	2.638	2.887	3.415
120	0.677	0.845	1.289	1.658	1.980	2.270	2.617	2.860	3.373
∞	0.675	0.842	1.282	1.645	1.960	2.241	2.576	2.807	3.291

附表 4　χ^2 值表(右尾)

自由度	概率值(P)												
(df)	0.995	0.990	0.975	0.950	0.900	0.750	0.500	0.250	0.100	0.050	0.025	0.010	0.005
1					0.02	0.10	0.45	1.32	2.71	3.84	5.02	6.63	7.88
2	0.01	0.02	0.05	0.10	0.21	0.58	1.39	2.77	4.61	5.99	7.38	9.21	10.60
3	0.07	0.11	0.22	0.35	0.58	1.21	2.37	4.11	6.25	7.81	9.35	11.34	12.84
4	0.21	0.30	0.48	0.71	1.06	1.92	3.36	5.39	7.78	9.49	11.14	13.28	14.86
5	0.41	0.55	0.83	1.15	1.61	2.67	4.35	6.63	9.24	11.07	12.83	15.09	16.75
6	0.68	0.87	1.24	1.64	2.20	3.45	5.35	7.84	10.64	12.59	14.45	16.81	18.55
7	0.99	1.24	1.69	2.17	2.83	4.25	6.35	9.04	12.02	14.07	16.01	18.48	20.28
8	1.34	1.65	2.18	2.73	3.49	5.07	7.34	10.22	13.36	15.51	17.53	20.09	21.96
9	1.73	2.09	2.70	3.33	4.17	5.90	8.34	11.39	14.68	16.92	19.02	21.67	23.59
10	2.16	2.56	3.25	3.94	4.87	6.74	9.34	12.55	15.99	18.31	20.48	23.21	25.19
11	2.60	3.05	3.82	4.57	5.58	7.58	10.34	13.70	17.28	19.68	21.92	24.72	26.76
12	3.07	3.57	4.40	5.23	6.30	8.44	11.34	14.85	18.55	21.03	23.34	26.22	28.30
13	3.57	4.11	5.01	5.89	7.04	9.30	12.34	15.98	19.81	22.36	24.74	27.69	29.82
14	4.07	4.66	5.63	6.57	7.79	10.17	13.34	17.12	21.06	23.68	26.12	29.14	31.32
15	4.60	5.23	6.27	7.26	8.55	11.04	14.34	18.25	22.31	25.00	27.49	30.58	32.80
16	5.14	5.81	6.91	7.96	9.31	11.91	15.34	19.37	23.54	26.30	28.85	32.00	34.27
17	5.70	6.41	7.56	8.67	10.09	12.79	16.34	20.49	24.77	27.59	30.19	33.41	35.72
18	6.26	7.01	8.23	9.39	10.86	13.68	17.34	21.60	25.99	28.87	31.53	34.81	37.16
19	6.84	7.63	8.91	10.12	11.65	14.56	18.34	22.72	27.20	30.14	32.85	36.19	38.58
20	7.43	8.26	9.59	10.85	12.44	15.45	19.34	23.83	28.41	31.41	34.17	37.57	40.00
21	8.03	8.90	10.28	11.59	13.24	16.34	20.34	24.93	29.62	32.67	35.48	38.93	41.40
22	8.64	9.54	10.98	12.34	14.04	17.24	21.34	26.04	30.81	33.92	36.78	40.29	42.80
23	9.26	10.20	11.69	13.09	14.85	18.14	22.34	27.14	32.01	35.17	38.08	41.64	44.18
24	9.89	10.86	12.40	13.85	15.66	19.04	23.34	28.24	33.20	36.42	39.36	42.98	45.56
25	10.52	11.52	13.12	14.61	16.47	19.94	24.34	29.34	34.38	37.65	40.65	44.31	46.93
26	11.16	12.20	13.84	15.38	17.29	20.84	25.34	30.43	35.56	38.89	41.92	45.64	48.29
27	11.81	12.88	14.57	16.15	18.11	21.75	26.34	31.53	36.74	40.11	43.19	49.96	49.64
28	12.46	13.56	15.31	16.93	18.94	22.66	27.34	32.62	37.92	41.34	44.46	48.28	50.99
29	13.12	14.26	16.05	17.71	19.77	23.57	28.34	33.71	39.09	42.56	45.72	49.59	52.34
30	13.79	14.95	16.79	18.49	20.60	24.48	29.34	34.80	40.26	43.77	46.98	50.89	53.67
40	20.71	22.16	24.43	26.51	29.05	33.66	39.34	45.62	51.80	55.76	59.34	63.69	66.77
50	27.99	29.71	32.36	34.76	37.69	42.94	49.33	56.33	63.17	67.50	71.42	76.15	79.49
60	35.53	37.48	40.48	43.19	46.46	52.29	59.33	66.98	74.40	79.08	83.30	88.38	91.95
80	51.17	53.54	57.15	60.39	64.28	71.14	79.33	88.13	96.58	101.88	106.63	112.33	116.32
100	67.33	70.06	74.22	77.93	82.36	90.13	99.33	109.14	118.50	124.34	129.56	135.81	140.17

附表 5　F 值表(右尾)

$P = 0.05$

df_2	df_1(大方差自由度)														
	1	2	3	4	5	6	7	8	9	10	12	14	16	18	20
1	161	200	216	225	230	234	237	239	241	242	244	245	246	247	248
2	18.51	19.00	19.16	19.25	19.30	19.33	19.36	19.37	19.38	19.39	19.41	19.42	19.43	19.44	19.44
3	10.13	9.55	9.28	9.12	9.01	8.94	8.89	8.85	8.81	8.79	8.74	8.71	8.69	8.67	5.80
4	7.71	6.94	6.59	6.39	6.26	6.16	6.09	6.04	6.00	5.96	5.91	5.87	5.84	5.82	5.80
5	6.61	5.79	5.41	5.19	5.05	4.95	4.88	4.82	4.77	4.74	4.68	4.64	4.60	4.58	4.56
6	5.99	5.14	4.76	4.53	4.39	4.28	4.21	4.15	4.10	4.06	4.00	3.96	3.92	3.90	3.87
7	5.59	4.74	4.35	4.12	3.97	3.87	3.79	3.73	3.68	3.64	3.57	3.53	3.49	3.47	3.44
8	5.32	4.46	4.07	3.84	3.69	3.58	3.50	3.44	3.39	3.35	3.28	3.24	3.20	3.17	3.15
9	5.12	4.26	3.86	3.63	3.48	3.37	3.29	3.23	3.18	3.14	3.07	3.03	2.99	2.96	2.94
10	4.96	4.10	3.71	3.48	3.33	3.22	3.14	3.07	3.02	2.98	2.91	2.86	2.83	2.80	2.77
11	4.84	3.98	3.59	3.36	3.20	3.09	3.01	2.95	2.90	2.85	2.79	2.74	2.70	2.67	2.65
12	4.75	3.89	3.49	3.26	3.11	3.00	2.91	2.85	2.80	2.75	2.69	2.64	2.60	2.57	2.54
13	4.67	3.81	3.41	3.18	3.03	2.92	2.83	2.77	2.71	2.67	2.60	2.55	2.51	2.48	2.46
14	4.60	3.74	3.34	3.11	2.96	2.85	2.76	2.70	2.65	2.60	2.53	2.48	2.44	2.41	2.39
15	4.54	3.68	3.29	3.06	2.90	2.79	2.71	2.64	2.59	2.54	2.48	2.42	2.38	2.35	2.33
16	4.49	3.63	3.24	3.01	2.85	2.74	2.66	2.59	2.54	2.49	2.42	2.37	2.33	2.30	2.28
17	4.45	3.59	3.20	2.96	2.81	2.70	2.61	2.55	2.49	2.45	2.38	2.33	2.29	2.26	2.23
18	4.41	3.55	3.16	2.93	2.77	2.66	2.58	2.51	2.46	2.41	2.34	2.29	2.25	2.22	2.19
19	4.38	3.52	3.13	2.90	2.74	2.63	2.54	2.48	2.42	2.38	2.31	2.26	2.21	2.18	2.16
20	4.35	3.49	3.10	2.87	2.71	2.60	2.51	2.45	2.39	2.35	2.28	2.22	2.18	2.15	2.12
21	4.32	3.47	3.07	2.84	2.68	2.57	2.49	2.42	2.37	2.32	2.25	2.20	2.16	2.12	2.10
22	4.30	3.44	3.05	2.82	2.66	2.55	2.46	2.40	2.34	2.30	2.23	2.17	2.13	2.10	2.07
23	4.28	3.42	3.03	2.80	2.64	2.53	2.44	2.37	2.32	2.27	2.20	2.15	2.11	2.07	2.05
24	4.26	3.40	3.01	2.78	2.62	2.51	2.42	2.36	2.30	2.25	2.18	2.13	2.09	2.05	2.03
25	4.24	3.39	2.99	2.76	2.60	2.49	2.40	2.34	2.28	2.24	2.16	2.11	2.07	2.04	2.01
26	4.23	3.37	2.98	2.74	2.59	2.47	2.39	2.32	2.27	2.22	2.15	2.09	2.05	2.02	1.99
27	4.21	3.35	2.96	2.73	2.57	2.46	2.37	2.31	2.25	2.20	2.13	2.08	2.04	2.00	1.97
28	4.20	3.34	2.95	2.71	2.56	2.45	2.36	2.29	2.24	2.19	2.12	2.06	2.02	1.99	1.96
29	4.18	3.33	2.93	2.70	2.55	2.43	2.35	2.28	2.22	2.18	2.10	2.05	2.01	1.97	1.94
30	4.17	3.32	2.92	2.69	2.53	2.42	2.33	2.27	2.21	2.16	2.09	2.04	1.99	1.96	1.93
32	4.15	3.29	2.90	2.67	2.51	2.40	2.31	2.24	2.19	2.14	2.07	2.01	1.97	1.94	1.91
34	4.13	3.28	2.88	2.65	2.49	2.38	2.29	2.23	2.17	2.12	2.05	1.99	1.95	1.92	1.89
36	4.11	3.26	2.87	2.63	2.48	2.36	2.28	2.21	2.15	2.11	2.03	1.98	1.93	1.90	1.87
38	4.10	3.24	2.85	2.62	2.46	2.35	2.26	2.19	2.14	2.09	2.02	1.96	1.92	1.88	1.85
40	4.08	3.23	2.84	2.61	2.45	2.34	2.25	2.18	2.12	2.08	2.00	1.95	1.90	1.87	1.84
42	4.07	3.22	2.83	2.59	2.44	2.32	2.24	2.17	2.11	2.06	1.99	1.93	1.89	1.86	1.83
44	4.06	3.21	2.82	2.58	2.43	2.31	2.23	2.16	2.10	2.05	1.98	1.92	1.88	1.84	1.81
46	4.05	3.20	2.81	2.57	2.42	2.30	2.22	2.15	2.09	2.04	1.97	1.91	1.87	1.83	1.80
48	4.04	3.19	2.80	2.57	2.41	2.29	2.21	2.14	2.08	2.03	1.96	1.90	1.86	1.82	1.79
50	4.03	3.18	2.79	2.56	2.40	2.29	2.20	2.13	2.07	2.03	1.95	1.89	1.85	1.81	1.78
60	4.00	3.15	2.76	2.53	2.37	2.25	2.17	2.10	2.04	1.99	1.92	1.86	1.82	1.78	1.75
80	3.96	3.11	2.72	2.49	2.33	2.21	2.13	2.06	2.00	1.95	1.88	1.82	1.77	1.73	1.70
100	3.94	3.09	2.70	2.46	2.31	2.19	2.10	2.03	1.97	1.93	1.85	1.79	1.75	1.71	1.68
125	3.92	3.07	2.68	2.44	2.29	2.17	2.08	2.01	1.96	1.91	1.83	1.77	1.72	1.69	1.65
150	3.90	3.06	2.66	2.43	2.27	2.16	2.07	2.00	1.94	1.89	1.82	1.76	1.71	1.67	1.64
200	3.89	3.04	2.65	2.42	2.26	2.14	2.06	1.98	1.93	1.88	1.80	1.74	1.69	1.66	1.62
300	3.87	3.03	2.63	2.40	2.24	2.13	2.04	1.97	1.91	1.86	1.78	1.72	1.68	1.64	1.61
500	3.86	3.01	2.62	2.39	2.23	2.12	2.03	1.96	1.90	1.85	1.77	1.71	1.66	1.62	1.59
1000	3.85	3.00	2.61	2.38	2.22	2.11	2.02	1.95	1.89	1.84	1.76	1.70	1.65	1.61	1.58
∞	3.84	3.00	2.60	2.37	2.21	2.10	2.01	1.94	1.88	1.83	1.75	1.69	1.64	1.60	1.57

续表

$P = 0.05$

df_2	df_1（大方差自由度）														
	22	24	26	28	30	35	40	45	50	60	80	100	200	500	∞
1	249	249	249	250	250	251	251	251	252	252	22	253	254	254	254
2	19.45	19.45	19.45	19.46	19.46	19.46	19.47	19.47	19.47	19.48	19.48	19.49	19.49	19.50	19.50
3	8.65	8.64	8.63	8.62	8.62	8.60	8.59	8.59	8.58	8.57	8.56	8.55	8.54	8.53	8.53
4	5.79	5.77	5.76	5.75	5.75	5.73	5.72	5.71	5.70	5.69	5.67	5.66	5.65	5.64	5.63
5	4.54	4.53	4.52	4.50	4.50	4.48	4.46	4.45	4.55	4.43	4.41	4.41	4.39	4.37	4.37
6	3.86	3.84	3.83	3.82	3.81	3.79	3.77	3.76	3.75	3.74	3.72	3.71	3.69	3.68	3.67
7	3.43	3.41	3.40	3.39	3.38	3.36	3.34	3.33	3.32	3.30	3.29	3.27	3.25	3.24	3.23
8	3.13	3.12	3.10	3.09	3.08	3.06	3.04	3.03	3.02	3.01	2.99	2.97	2.95	2.94	2.93
9	2.92	2.90	2.89	2.87	2.86	2.84	2.83	2.81	2.80	2.79	2.77	2.76	2.73	2.72	7.71
10	2.75	2.74	2.72	2.71	2.70	2.68	2.66	2.65	2.64	2.62	2.60	2.59	2.56	2.55	2.54
11	2.63	2.61	2.59	2.58	2.57	2.55	2.53	2.52	2.51	2.49	2.47	2.46	2.43	2.42	2.40
12	2.52	2.51	2.49	2.48	2.47	2.44	2.43	2.41	2.40	2.38	2.36	2.35	2.32	2.31	2.30
13	2.44	2.42	2.41	2.39	2.38	2.36	2.34	2.33	2.31	2.30	2.27	2.26	2.23	2.22	2.21
14	2.37	2.35	2.33	2.32	2.31	2.28	2.27	2.25	2.24	2.22	2.20	2.19	2.16	2.14	2.13
15	2.13	2.29	2.27	2.26	2.25	2.22	2.20	2.19	2.18	2.16	2.14	2.12	2.10	2.08	2.07
16	2.25	2.24	2.22	2.21	2.19	2.17	2.15	2.14	2.12	2.11	2.08	2.07	2.04	2.02	2.01
17	2.21	2.19	2.17	2.16	2.15	2.12	2.10	2.09	2.08	2.06	2.03	2.02	1.99	1.97	1.92
18	2.17	2.15	2.13	2.12	2.11	2.08	2.06	2.05	2.04	2.02	1.99	1.98	1.95	1.93	1.92
19	2.13	2.11	2.10	2.08	2.07	2.05	2.03	2.01	2.00	1.98	1.96	1.94	1.91	1.89	1.88
20	2.10	2.08	2.07	2.05	2.04	2.01	1.99	1.98	1.97	1.95	1.92	1.91	1.88	1.86	1.84
21	2.07	2.05	2.04	2.02	2.01	1.98	1.96	1.95	1.94	1.92	1.89	1.88	1.84	1.82	1.81
22	2.05	2.03	2.01	2.00	1.98	1.96	1.94	1.92	1.91	1.89	1.86	1.85	1.82	1.80	1.78
23	2.02	2.00	1.99	1.97	1.96	1.93	1.91	1.90	1.88	1.86	1.84	1.82	1.79	1.77	1.76
24	2.00	1.98	1.97	1.95	1.94	1.91	1.89	1.88	1.86	1.84	1.82	1.80	1.77	1.75	1.73
25	1.98	1.96	1.95	1.93	1.92	1.89	1.87	1.86	1.84	1.82	1.80	1.78	1.75	1.73	1.71
26	1.97	1.95	1.93	1.91	1.90	1.87	1.85	1.84	1.82	1.80	1.78	1.76	1.73	1.71	1.69
27	1.95	1.93	1.91	1.90	1.88	1.86	1.84	1.82	1.81	1.79	1.76	1.74	1.71	1.69	1.67
28	1.93	1.91	1.90	1.88	1.87	1.84	1.82	1.80	1.79	1.77	1.74	1.73	1.69	1.67	1.65
29	1.92	1.90	1.88	1.87	1.85	1.83	1.81	1.79	1.77	1.75	1.73	1.71	1.67	1.65	1.64
30	1.91	1.89	1.87	1.85	1.84	1.81	1.79	1.77	1.76	1.74	1.71	1.70	1.66	1.64	1.62
32	1.88	1.86	1.85	1.83	1.82	1.79	1.77	1.75	1.74	1.71	1.69	1.67	1.63	1.61	1.59
34	1.86	1.84	1.82	1.80	1.80	1.77	1.75	1.73	1.71	1.69	1.66	1.65	1.61	1.59	1.57
36	1.85	1.82	1.91	1.79	1.78	1.75	1.73	1.71	1.69	1.67	1364	1.62	1.59	1.56	1.55
38	1.83	1.81	1.79	1.77	1.76	1.73	1.71	1.69	1.68	1.65	1.62	1.61	1.57	1.54	1.53
40	1.81	1.79	1.77	1.76	1.74	1.72	1.69	1.67	1.66	1.64	1.61	1.59	1.55	1.53	1.51
42	1.80	1.78	1.76	1.74	1.73	1.70	1.68	1.66	1.65	1.62	1.59	1.57	1.53	1.51	1.49
44	1.79	1.77	1.75	1.73	1.72	1.69	1.67	1.65	1.63	1.61	1.58	1.56	1.52	1.49	1.48
46	1.78	1.76	1.74	1.72	1.71	1.68	1.65	1.64	1.62	1.60	1.57	1.55	1.51	1.48	1.46
48	1.77	1.75	1.73	1.71	1.70	1.67	1.64	1.62	1.61	1.59	1.56	1.54	1.49	1.47	1.45
50	1.76	1.74	1.72	1.70	1.69	1.66	1.63	1.61	1.60	1.58	1.54	1.52	1.48	1.46	1.44
60	1.72	1.70	1.68	1.66	1.65	1.62	1.59	1.57	1.56	1.53	1.50	1.48	1.44	1.41	1.39
80	1.68	1.65	1.63	1.62	1.60	1.57	1.54	1.52	1.51	1.48	1.45	1.43	1.38	1.35	1.32
100	1.65	1.63	1.61	1.59	1.57	1.54	1.52	1.49	1.48	1.45	1.41	1.39	1.34	1.31	1.28
125	1.63	1.60	1.58	1.57	1.55	1.52	1.49	1.47	1.45	1.42	1.39	1.36	1.31	1.27	1.25
150	1.61	1.59	1.57	1.55	1.53	1.50	1.48	1.45	1.44	1.41	1.37	1.34	1.29	1.25	1.22
200	1.60	1.57	1.55	1.53	1.52	1.48	1.46	1.43	1.41	1.39	1.35	1.32	1.26	1.22	1.19
300	1.58	1.55	1.53	1.51	1.50	1.46	1.43	1.41	1.39	1.36	1.32	1.30	1.23	1.19	1.15
500	1.56	1.54	1.52	1.50	1.48	1.45	1.42	1.40	1.38	1.34	1.30	1.28	1.21	1.16	1.11
1000	1.55	1.5	1.51	1.49	1.47	1.44	1.41	1.38	1.36	1.33	1.29	1.26	1.19	1.13	1.08
∞	1.54	1.52	1.50	1.48	1.46	1.42	1.39	1.37	1.35	1.32	1.27	1.24	1.17	1.11	1.00

续表

$P = 0.01$

df_2	df_1(大方差自由度)														
	1	2	3	4	5	6	7	8	9	10	12	14	16	18	20
1	405	500	540	563	576	586	593	598	602	606	611	614	617	619	621
2	98.49	99.00	99.17	99.25	99.30	99.33	99.34	99.36	99.38	99.40	99.42	99.43	99.44	99.44	99.45
3	34.12	30.82	29.46	28.71	28.24	27.91	27.67	27.49	27.34	27.23	27.05	26.92	26.83	26.75	26.69
4	21.20	18.00	16.69	15.98	15.52	15.21	14.98	14.80	14.66	14.54	14.37	14.24	14.15	14.07	14.02
5	16.26	13.27	12.06	11.39	10.97	10.67	10.45	10.27	10.15	10.05	9.89	9.77	9.68	9.61	9.55
6	13.74	10.92	9.78	9.15	8.75	8.47	8.26	8.10	7.93	7.87	7.72	7.60	7.52	7.45	7.40
7	12.25	9.55	8.45	7.85	7.46	7.19	6.99	6.84	6.72	6.62	6.47	6.36	6.27	6.21	6.16
8	11.26	8.65	7.59	7.01	6.63	6.37	6.18	6.03	5.91	5.81	5.67	5.56	5.48	5.41	5.36
9	10.56	8.02	6.99	6.42	6.06	5.80	5.61	5.47	5.35	5.26	5.11	5.00	4.92	4.86	4.81
10	10.04	7.56	6.55	5.99	5.64	5.39	5.20	5.06	4.94	4.85	4.71	4.60	4.52	4.46	4.41
11	9.65	7.21	6.22	5.67	5.32	5.07	4.89	4.74	4.63	4.54	4.40	4.29	4.21	4.15	4.10
12	9.33	6.93	5.95	5.41	5.06	4.82	4.64	4.50	4.39	4.30	4.16	4.05	3.97	3.91	3.86
13	9.07	6.70	5.74	5.21	4.86	4.62	4.44	4.30	4.19	4.10	3.96	3.86	3.78	3.71	3.66
14	8.86	6.51	5.56	5.04	5.70	4.46	4.28	4.14	4.03	3.94	3.80	3.70	3.62	3.56	3.51
15	8.68	6.36	5.42	4.89	4.56	4.32	4.14	4.00	3.38	3.80	3.67	3.56	3.49	3.42	3.37
16	8.53	6.23	5.29	4.77	4.44	4.20	4.03	3.89	3.78	3.69	3.55	3.45	3.37	3.31	3.26
17	8.40	6.11	5.18	4.67	4.34	4.10	3.93	3.79	3.68	3.59	3.46	3.35	3.27	3.21	3.16
18	8.29	6.01	5.09	4.58	4.25	4.01	3.84	3.71	3.60	3.51	3.37	3.27	3.19	3.13	3.08
19	8.18	5.93	5.01	4.50	4.17	3.94	3.77	3.63	3.52	3.43	3.30	3.19	3.12	3.05	3.00
20	8.10	5.85	4.94	4.43	4.10	3.87	3.70	3.56	3.46	3.37	3.23	3.13	3.05	2.99	2.94
21	8.02	5.78	4.87	4.37	4.04	3.81	3.64	3.51	3.40	3.31	3.17	3.07	2.99	2.93	2.88
22	7.95	5.72	4.82	4.31	3.99	3.76	3.59	3.45	3.35	3.26	3.12	3.02	2.94	2.83	2.83
23	7.88	5.66	4.76	4.26	3.94	3.71	3.54	3.41	3.30	3.21	3.07	2.97	2.89	2.83	2.78
24	7.82	5.61	4.72	4.22	3.90	3.67	3.50	3.36	3.26	3.17	3.03	2.93	2.85	2.79	2.74
25	7.77	5.57	4.68	4.18	3.86	3.63	3.46	3.32	3.22	3.13	2.99	2.89	2.81	2.75	2.70
26	7.72	5.53	4.64	4.14	3.82	3.59	3.42	3.29	3.18	3.09	2.96	2.86	2.78	2.72	2.66
27	7.68	5.49	4.60	4.11	3.78	3.56	3.39	3.26	3.15	3.06	2.93	2.79	2.75	2.68	2.63
28	7.64	5.45	4.57	4.07	3.75	3.53	3.36	3.23	3.12	3.03	2.90	2.79	2.72	2.65	2.60
29	7.60	5.42	4.54	4.04	3.73	3.50	3.33	3.20	3.09	3.00	2.87	2.77	2.69	2.62	2.57
30	7.56	5.39	4.51	4.02	3.70	3.47	3.30	3.17	3.07	2.98	2.84	2.74	2.66	2.60	2.55
32	7.50	5.34	4.46	3.97	3.65	3.43	3.26	3.13	3.02	2.93	2.80	2.70	2.62	2.55	2.50
34	7.44	5.29	4.42	3.93	3.61	3.39	3.22	3.09	2.98	2.89	2.76	2.66	2.58	2.51	2.46
36	7.40	5.25	4.38	3.89	3.57	3.35	3.18	3.05	2.95	2.86	2.72	2.62	2.54	2.48	2.43
38	7.35	5.21	4.34	3.86	3.54	3.32	3.15	3.02	2.92	2.83	2.69	2.59	2.51	2.45	2.40
40	7.31	5.18	4.31	3.83	3.51	3.29	3.12	2.99	2.89	2.80	2.66	2.56	2.48	2.42	2.37
42	7.28	5.15	4.29	3.80	3.49	3.27	3.10	2.97	2.86	2.78	2.64	2.54	2.46	2.40	2.34
44	7.25	5.12	4.26	3.78	3.47	3.24	3.08	2.95	2.84	2.75	2.62	2.52	2.44	2.37	2.32
46	7.22	5.10	4.24	3.76	3.44	3.22	3.06	2.93	2.82	2.73	2.60	2.50	2.42	2.35	2.30
48	7.20	5.08	4.22	3.74	3.43	3.20	3.04	2.91	2.80	2.72	2.58	2.48	2.40	2.33	2.28
50	7.17	5.06	4.20	3.72	3.41	3.19	3.02	2.89	2.79	2.70	2.56	2.46	2.38	2.32	2.27
60	7.08	4.98	4.13	3.65	3.34	3.12	2.95	2.82	2.72	2.63	2.50	2.39	2.31	2.25	2.20
80	6.96	4.88	4.04	3.56	3.26	3.04	2.87	2.74	2.64	2.55	2.42	2.31	2.23	2.17	2.12
100	6.90	4.82	3.98	3.51	3.21	2.99	2.82	2.69	2.59	2.50	2.37	2.26	2.19	2.12	2.07
125	6.84	4.78	3.94	3.47	3.17	2.95	2.79	2.66	2.55	2.47	2.33	2.23	2.15	2.08	2.03
150	6.81	4.75	3.92	3.45	3.14	2.92	2.76	2.63	2.53	2.44	2.31	2.20	2.12	2.06	2.00
200	6.76	4.71	3.88	3.41	3.11	2.89	2.73	2.60	2.50	2.41	2.27	2.17	2.09	2.02	1.97
300	6.72	4.68	3.85	3.38	3.08	2.86	2.70	2.57	2.47	2.38	2.24	2.14	2.06	1.99	1.94
500	6.69	4.65	3.82	3.36	3.05	2.84	2.68	2.55	2.44	2.36	2.22	2.12	2.04	1.97	1.92
1000	6.66	4.63	3.80	3.34	3.04	2.82	2.66	2.53	2.43	2.34	2.20	2.10	2.02	1.95	1.90
∞	6.63	4.61	3.78	3.32	3.02	2.80	2.64	2.51	2.41	2.32	2.18	2.08	2.00	1.93	1.88

续表

$P = 0.01$

df_2	df_1（大方差自由度）														
	22	24	26	28	30	35	40	45	50	60	80	100	200	500	∞
1	622	623	624	625	626	628	629	630	630	631	633	633	635	636	637
2	99.45	99.45	99.46	99.46	99.47	99.47	99.48	99.48	99.48	99.48	99.49	99.49	99.49	99.50	99.50
3	26.65	26.60	26.57	26.54	26.50	26.46	26.41	26.39	26.35	26.30	26.25	26.23	26.18	26.14	26.12
4	13.98	13.93	13.90	13.86	13.83	13.79	13.74	13.72	13.69	13.65	13.60	13.57	13.52	13.48	13.46
5	9.51	9.47	9.43	9.40	9.38	9.33	9.29	9.26	9.24	9.20	9.16	9.13	9.08	9.04	9.02
6	7.35	7.31	7.28	7.25	7.23	7.18	7.14	7.11	7.09	7.06	7.01	6.99	6.93	6.90	6.88
7	6.11	6.07	6.04	6.02	5.99	5.94	5.91	5.88	5.86	5.82	5.78	5.75	5.70	5.67	5.65
8	5.32	5.28	5.25	5.22	5.20	5.15	5.12	5.00	5.07	5.03	4.99	4.96	4.91	4.88	4.86
9	4.77	4.73	4.70	4.67	4.65	4.60	4.57	4.54	4.52	4.48	4.44	4.42	4.36	4.33	4.31
10	4.36	4.33	4.30	4.27	4.25	4.20	4.17	4.14	4.12	4.08	4.04	4.01	3.96	3.93	3.91
11	4.06	4.02	3.99	3.96	3.94	3.89	3.86	3.83	3.81	3.78	3.73	3.71	3.66	3.62	3.60
12	3.82	3.78	3.75	3.72	3.70	3.65	3.62	3.59	3.57	3.54	3.49	3.47	3.41	3.38	3.36
13	3.62	3.59	3.56	3.53	3.51	3.46	3.43	3.40	3.38	3.34	3.30	3.27	3.22	3.19	3.17
14	3.46	3.43	3.40	3.37	3.35	3.30	3.27	3.24	3.22	3.18	3.14	3.11	3.06	3.03	3.00
15	3.33	3.29	3.26	3.24	3.21	3.17	3.13	3.10	3.08	3.05	3.00	2.98	2.92	2.89	2.87
16	3.22	3.18	3.15	3.12	3.10	3.05	3.02	2.99	2.97	2.93	2.89	2.86	2.81	2.78	2.75
17	3.12	3.08	3.05	3.03	3.00	2.96	2.92	2.89	2.87	2.83	2.79	2.76	2.71	2.68	2.65
18	3.03	3.00	2.97	2.94	2.92	2.87	2.84	2.81	2.78	2.75	2.70	2.68	2.62	2.59	2.57
19	2.96	2.92	2.89	2.87	2.84	2.80	2.76	2.73	2.71	2.67	2.63	2.60	2.55	2.51	2.49
20	2.90	2.86	2.83	2.80	2.78	2.73	2.69	2.67	2.64	2.61	2.56	2.54	2.48	2.44	2.42
21	2.84	2.80	2.77	2.74	2.72	2.67	2.64	2.61	2.58	2.55	2.50	2.48	2.42	2.38	2.36
22	2.78	2.75	2.72	2.69	2.67	2.62	2.58	2.55	2.53	2.50	2.45	2.42	2.36	2.33	2.31
23	2.74	2.70	2.67	2.64	2.62	2.57	2.54	2.51	2.48	2.45	2.40	2.37	2.32	2.28	2.26
24	2.70	2.66	2.63	2.60	2.58	2.53	2.49	2.46	2.44	2.40	2.36	2.33	2.27	2.24	2.21
25	2.66	2.62	2.59	2.56	2.54	2.49	2.45	2.42	2.40	2.36	2.32	2.29	2.23	2.19	2.17
26	2.62	2.58	2.55	2.53	2.50	2.45	2.42	2.39	2.36	2.33	2.28	2.25	2.19	2.16	2.13
27	2.59	2.55	2.52	2.49	2.47	2.42	2.38	2.35	2.33	2.29	2.25	2.22	2.16	2.12	2.10
28	2.56	2.52	2.49	2.46	2.44	2.39	2.35	2.32	2.30	2.26	2.22	2.19	2.13	2.09	2.06
29	2.53	2.49	2.46	2.44	2.41	2.36	2.33	2.30	2.27	2.23	2.19	2.16	2.10	2.06	2.03
30	2.51	2.47	2.44	2.41	2.39	2.34	2.30	2.27	2.25	2.21	2.16	2.13	2.07	2.03	2.01
32	2.46	2.42	2.39	2.36	2.34	2.29	2.25	2.22	2.20	2.16	2.11	2.08	2.02	1.98	1.96
34	2.42	2.38	2.35	2.32	2.30	2.25	2.21	2.18	2.16	2.12	2.07	2.04	1.98	1.94	1.91
36	2.38	2.35	2.32	2.29	2.26	2.21	2.17	2.14	2.12	2.08	2.03	2.00	1.94	1.90	1.87
38	2.35	2.32	2.28	2.26	2.23	2.18	2.14	2.11	2.09	2.05	2.00	1.97	1.90	1.86	1.84
40	2.33	2.29	2.26	2.23	2.20	2.15	2.11	2.08	2.06	2.02	1.97	1.94	1.87	1.83	1.80
42	2.30	2.26	2.23	2.20	2.18	2.13	2.09	2.06	2.03	1.99	1.94	1.91	1.85	1.80	1.78
44	2.28	2.24	2.21	2.18	2.15	2.10	2.06	2.03	2.01	1.97	1.92	1.89	1.82	1.78	1.75
46	2.26	2.22	2.19	2.16	2.13	2.08	2.04	2.01	1.99	1.95	1.90	1.86	1.80	1.75	1.73
48	2.24	2.20	2.17	2.14	2.12	2.06	2.02	1.99	1.97	1.93	1.88	1.84	1.78	1.73	1.70
50	2.22	2.18	2.15	2.12	2.10	2.05	2.01	1.97	1.95	1.91	1.86	1.82	1.76	1.71	1.68
60	2.15	2.12	2.08	2.05	2.03	1.98	1.94	1.90	1.88	1.94	1.78	1.75	1.68	1.68	1.60
80	2.07	2.03	2.00	1.97	1.94	1.89	1.85	1.81	1.79	1.75	1.69	1.66	1.58	1.53	1.49
100	2.02	1.98	1.94	1.92	1.89	1.84	1.80	1.76	1.73	1.69	1.63	1.60	1.52	1.47	1.43
125	1.98	1.94	1.91	1.88	1.85	1.80	1.76	1.72	1.69	1.65	1.59	1.55	1.47	1.41	1.37
150	1.96	1.92	1.88	1.85	1.83	1.77	1.73	1.69	1.66	1.62	1.56	1.52	1.48	1.38	1.33
200	1.93	1.89	1.85	1.82	1.79	1.74	1.69	1.66	1.63	1.58	1.52	1.48	1.39	1.33	1.23
300	1.89	1.85	1.82	1.79	1.76	1.71	1.66	1.62	1.59	1.55	1.48	1.44	1.35	1.28	1.22
500	1.87	1.83	1.79	1.76	1.74	1.68	1.63	1.60	1.56	1.52	1.45	1.41	1.31	1.23	1.16
1000	1.85	1.81	1.77	1.74	1.72	1.66	1.61	1.57	1.54	1.50	1.43	1.38	1.28	1.19	1.11
∞	1.83	1.79	1.76	1.72	1.70	1.64	1.59	1.55	1.52	1.47	1.40	1.36	1.25	1.15	1.00

附表 6　新复极差检验 *SSR* 值表

（上为 $SSR_{0.05}$，下为 $SSR_{0.01}$）

df	M(检验极差的平均数个数)													
	2	3	4	5	6	7	8	9	10	12	14	16	18	20
3	4.50	4.52	4.52	4.52	4.52	4.52	4.52	4.52	4.52	4.52	4.52	4.52	4.52	4.52
	8.26	8.32	8.32	8.32	8.32	8.32	8.32	8.32	8.32	8.32	8.32	8.32	8.32	8.32
4	3.93	4.01	4.03	4.03	4.03	4.03	4.03	4.03	4.03	4.03	4.03	4.03	4.03	4.03
	6.51	6.68	6.74	6.76	6.76	6.76	6.76	6.76	6.76	6.76	6.76	6.76	6.76	6.76
5	3.64	3.75	3.80	3.81	3.81	3.81	3.81	3.81	3.81	3.81	3.81	3.81	3.81	3.81
	5.70	5.89	6.00	6.04	6.06	6.07	6.07	6.07	6.07	6.07	6.07	6.07	6.07	6.07
6	3.46	3.59	3.65	3.68	3.69	3.70	3.70	3.70	3.70	3.70	3.70	3.70	3.70	3.70
	5.25	5.44	5.55	5.61	5.66	5.68	5.69	5.70	5.70	5.70	5.70	5.70	5.70	5.70
7	3.34	3.48	3.55	3.59	3.61	3.62	3.63	3.63	3.63	3.63	3.63	3.63	3.63	3.63
	4.95	5.14	5.26	5.33	5.38	5.42	5.44	5.45	5.46	5.47	5.47	5.47	5.47	5.47
8	3.26	3.40	3.48	3.52	3.55	3.57	3.58	3.58	3.58	3.58	3.58	3.58	3.58	3.58
	4.75	4.94	5.06	5.14	5.19	5.23	5.26	5.28	5.29	5.31	5.32	5.32	5.32	5.32
9	3.20	3.34	3.42	3.47	3.50	3.52	3.54	3.54	3.55	3.55	3.55	3.55	3.55	3.55
	4.60	4.79	4.91	4.99	5.04	5.09	5.12	5.14	5.16	5.18	5.20	5.20	5.21	5.21
10	3.15	3.29	3.38	3.43	3.46	3.49	3.50	3.52	3.52	3.53	3.53	3.53	3.53	3.53
	4.48	4.67	4.79	4.87	4.93	4.98	5.01	5.04	5.06	5.09	5.11	5.12	5.12	5.12
11	3.11	3.26	3.34	3.40	3.44	3.46	3.48	3.49	3.50	3.51	3.51	3.51	3.51	3.51
	4.39	4.58	4.70	4.78	4.84	4.89	4.92	4.95	4.98	5.01	5.03	5.04	5.05	5.06
12	3.08	3.22	3.31	3.37	3.41	3.44	3.46	3.47	3.48	3.50	3.50	3.50	3.50	3.50
	4.32	4.50	4.62	4.71	4.77	4.82	4.85	4.88	4.91	4.94	4.97	4.99	5.00	5.01
13	3.06	3.20	3.29	3.35	3.39	3.42	3.44	3.46	3.47	3.48	3.49	3.49	3.49	3.49
	4.26	4.44	4.56	4.64	4.71	4.76	4.79	4.82	4.85	4.89	4.92	4.94	4.95	4.96
14	3.03	3.18	3.27	3.33	3.37	3.40	3.43	3.44	3.46	3.47	3.48	3.48	3.48	3.48
	4.21	4.39	4.51	4.59	4.65	4.70	4.74	4.78	4.80	4.84	4.87	4.89	4.91	4.92
15	3.01	3.16	3.25	3.31	3.36	3.39	3.41	3.43	3.45	3.46	3.48	3.48	3.48	3.48
	4.17	4.35	4.46	4.55	4.61	4.66	4.70	4.73	4.76	4.80	4.83	4.86	4.87	4.89
16	3.00	3.14	3.24	3.30	3.34	3.38	3.40	3.42	3.44	3.46	3.47	3.48	3.48	3.48
	4.13	4.31	4.42	4.51	4.57	4.62	4.66	4.70	4.72	4.77	4.80	4.82	4.84	4.86
17	2.98	3.13	3.22	3.28	3.33	3.37	3.39	3.41	3.43	3.45	3.46	3.47	3.48	3.48
	4.10	4.28	4.39	4.48	4.54	4.59	4.63	4.66	4.69	4.74	4.77	4.80	4.82	4.83
18	2.97	3.12	3.21	3.27	3.32	3.36	3.38	3.40	3.42	3.44	3.46	3.47	3.47	3.47
	4.07	4.25	4.36	4.44	4.51	4.56	4.60	4.64	4.66	4.71	4.74	4.77	4.79	4.81
19	2.96	3.11	3.20	3.26	3.31	3.35	3.38	3.40	3.42	3.44	3.46	3.47	3.47	3.47
	4.05	4.22	4.34	4.42	4.48	4.53	4.58	4.61	4.64	4.69	4.72	4.75	4.77	4.79
20	2.95	3.10	3.19	3.26	3.30	3.34	3.37	3.39	3.41	3.44	3.45	3.46	3.47	3.47
	4.02	4.20	4.31	4.40	4.46	4.51	4.55	4.59	4.62	4.66	4.70	4.73	4.75	4.77
24	2.92	3.07	3.16	3.23	3.28	3.32	3.34	3.37	3.39	3.42	3.44	3.46	3.46	3.47
	3.96	4.13	4.24	4.32	4.39	4.44	4.48	4.52	4.55	4.60	4.63	4.66	4.69	4.71
30	2.89	3.04	3.13	3.20	3.25	3.29	3.32	3.35	3.37	3.40	3.43	3.44	3.46	3.47
	3.89	4.06	4.17	4.25	4.31	4.37	4.41	4.44	4.48	4.53	4.57	4.60	4.63	4.65
40	2.86	3.01	3.10	3.17	3.22	3.27	3.30	3.33	3.35	3.39	3.42	3.44	3.46	3.47
	3.82	3.99	4.10	4.18	4.24	4.30	4.34	4.38	4.41	4.46	4.50	4.54	4.57	4.59
60	2.83	2.98	3.07	3.14	3.20	3.24	3.28	3.31	3.33	3.37	3.41	3.43	3.45	3.47
	3.76	3.92	4.03	4.11	4.17	4.23	4.27	4.31	4.34	4.39	4.44	4.47	4.50	4.53
120	2.80	2.95	3.04	3.12	3.17	3.22	3.25	3.29	3.31	3.36	3.39	3.42	3.45	3.47
	3.70	3.86	3.96	4.04	4.11	4.16	4.20	4.24	4.27	4.33	4.37	4.41	4.44	4.47
∞	2.77	2.92	3.02	3.09	3.15	3.19	3.23	3.26	3.29	3.34	3.38	3.41	3.44	3.47
	3.64	3.80	3.90	3.98	4.04	4.09	4.14	4.17	4.20	4.26	4.31	4.34	4.38	4.41

附表 7　q 值表(双尾)

(上为 $q_{0.05}$,下为 $q_{0.01}$)

df	M(检验极差的平均数个数)																		
	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20
3	4.50	5.88	6.83	7.51	8.04	8.47	8.85	9.18	9.46	9.72	9.95	10.16	10.35	10.72	10.69	10.84	10.98	11.12	11.24
	8.26	10.62	12.17	13.33	14.24	15.00	15.64	16.20	16.69	17.13	17.53	17.89	18.22	18.52	18.81	19.07	19.32	19.55	19.77
4	3.93	5.00	5.76	6.31	6.73	7.06	7.35	7.60	7.83	8.03	8.21	8.37	8.52	8.67	8.80	8.92	9.03	9.14	9.24
	6.51	8.12	9.17	9.96	10.58	11.10	11.55	11.93	12.27	12.57	12.84	13.09	13.32	13.53	13.73	13.91	14.08	14.24	14.40
5	3.64	4.54	5.18	5.64	5.99	6.28	6.52	6.74	6.93	7.10	7.25	7.39	7.52	7.64	7.75	7.86	7.95	8.04	8.18
	5.70	6.97	7.80	8.42	8.91	9.32	9.67	9.97	10.24	10.48	10.70	10.89	11.08	11.24	11.40	11.55	11.68	11.81	11.93
6	3.46	4.34	4.90	5.31	5.63	5.89	6.12	6.32	6.49	6.65	6.79	6.92	7.04	7.14	7.24	7.34	7.43	7.51	7.59
	5.24	6.33	7.03	7.56	7.97	8.32	8.61	8.87	9.10	9.30	9.48	9.65	9.81	9.95	10.08	10.21	10.32	10.43	10.54
7	3.34	4.16	4.68	5.06	5.35	5.59	5.80	5.99	6.15	6.29	6.42	6.54	6.65	6.75	6.84	6.93	7.01	7.08	7.16
	4.95	5.92	6.54	7.01	7.37	7.68	7.94	8.17	8.37	8.55	8.71	8.86	9.00	9.12	9.24	9.35	9.46	9.55	9.65
8	3.26	4.04	4.53	4.89	5.17	5.40	5.60	5.77	5.92	6.05	6.18	6.29	6.39	6.48	6.57	6.65	6.73	6.80	6.87
	4.74	5.63	6.20	6.63	6.96	7.24	7.47	7.68	7.87	8.03	8.18	8.31	8.44	8.55	8.66	8.76	8.85	8.94	9.03
9	3.20	3.95	4.42	4.76	5.02	5.24	5.43	5.60	5.74	5.87	5.98	6.09	6.19	6.28	6.36	6.44	6.51	6.58	6.65
	4.60	5.43	5.96	6.35	6.66	6.91	7.13	7.32	7.49	7.65	7.78	7.91	8.03	8.13	8.23	8.32	8.41	8.49	8.57
10	3.15	3.88	4.33	4.66	4.91	5.12	5.30	5.46	5.60	5.72	5.83	5.93	6.03	6.12	6.20	6.27	6.34	6.41	6.47
	4.48	5.27	5.77	6.14	6.43	6.67	6.87	7.05	7.21	7.36	7.48	7.60	7.71	7.81	7.91	7.99	8.07	8.15	8.22
11	3.11	3.82	4.26	4.58	4.82	5.03	5.20	5.35	5.49	5.61	5.71	5.81	5.90	5.98	6.06	6.14	6.20	6.27	6.33
	4.39	5.14	5.62	5.97	6.25	6.48	6.67	6.84	6.99	7.13	7.25	7.36	7.46	7.56	7.65	7.73	7.81	7.88	7.95
12	3.08	3.77	4.20	4.51	4.75	4.95	5.12	5.27	5.40	5.51	5.61	5.71	5.80	5.88	5.95	6.02	6.09	6.15	6.21
	4.32	5.04	5.50	5.84	6.10	6.32	6.51	6.67	6.81	6.94	7.06	7.17	7.26	7.36	7.44	7.52	7.59	7.66	7.73
13	3.06	3.73	4.15	4.46	4.69	4.88	5.05	5.19	5.32	5.43	5.53	5.63	5.71	5.79	5.86	5.93	6.00	6.06	6.11
	4.26	4.96	5.40	5.73	5.98	6.19	6.37	6.53	6.67	6.79	6.90	7.01	7.10	7.19	7.27	7.34	7.42	7.48	7.55
14	3.03	3.70	4.11	4.41	4.64	4.83	4.99	5.13	5.25	5.36	5.46	5.56	5.64	5.72	5.79	5.86	5.92	5.98	6.03
	4.21	4.89	5.32	5.63	5.88	6.08	6.26	6.41	6.54	6.66	6.77	6.87	6.96	7.05	7.12	7.20	7.27	7.33	7.39
15	3.01	3.67	4.08	4.37	4.59	4.78	4.94	5.08	5.20	5.31	5.40	5.49	5.57	5.65	5.72	5.79	5.85	5.91	5.96
	4.17	4.83	5.25	5.56	5.80	5.99	6.16	6.31	6.44	6.55	6.66	6.76	6.84	6.93	7.00	7.07	7.14	7.20	7.26
16	3.00	3.65	4.05	4.34	4.56	4.74	4.90	5.03	5.15	5.26	5.35	5.44	5.52	5.59	5.66	5.73	5.79	5.84	5.90
	4.13	4.78	5.19	5.49	5.72	5.92	6.08	6.22	6.35	6.46	6.56	6.66	6.74	6.82	6.90	6.97	7.03	7.09	7.15
17	2.98	3.62	4.02	4.31	4.52	4.70	4.86	4.99	5.11	5.21	5.31	5.39	5.47	5.55	5.61	5.68	5.74	5.79	5.84
	4.10	4.74	5.14	5.43	5.66	5.85	6.01	6.15	6.27	6.38	6.48	6.57	6.66	6.73	6.80	6.87	6.94	7.00	7.05
18	2.97	3.61	4.00	4.28	4.49	4.67	4.83	4.96	5.07	5.17	5.27	5.35	5.43	5.50	5.57	5.63	5.69	5.74	5.79
	4.07	4.70	5.05	5.38	5.60	5.79	5.94	6.08	6.20	6.31	6.41	6.50	6.58	6.65	6.72	6.79	6.85	6.91	6.96
19	2.96	3.59	3.98	4.26	4.47	4.64	4.79	4.92	5.04	5.14	5.23	5.32	5.39	5.46	5.53	5.59	5.65	5.70	5.75
	4.05	4.67	5.09	5.33	5.55	5.73	5.89	6.02	6.14	6.25	6.34	6.43	6.51	6.58	6.65	6.72	6.78	6.84	6.89
20	2.95	3.58	3.96	4.24	4.45	4.62	4.77	4.90	5.01	5.11	5.20	5.28	5.36	5.43	5.50	5.56	5.61	5.66	5.71
	4.02	4.64	5.02	5.29	5.51	5.69	5.84	5.97	6.09	6.19	6.29	6.37	6.45	6.52	6.59	6.65	6.71	6.76	6.82
24	2.92	3.53	3.90	4.17	4.37	4.54	4.68	4.81	4.92	5.01	5.10	5.18	5.25	5.32	5.38	5.44	5.50	5.55	5.59
	3.96	4.54	4.91	5.17	5.37	5.54	5.69	5.81	5.92	6.02	6.11	6.19	6.26	6.33	6.39	6.45	6.51	6.56	6.61
30	2.89	3.48	3.84	4.11	4.30	4.46	4.60	4.72	4.83	4.92	5.00	5.08	5.15	5.21	5.27	5.33	5.38	5.43	5.48
	3.89	4.45	4.80	5.05	5.24	5.40	5.54	5.65	5.76	5.85	5.93	6.01	6.08	6.14	6.20	6.26	6.31	6.36	6.41
40	2.86	3.44	3.79	4.04	4.23	4.39	4.52	4.63	4.74	4.82	4.90	4.98	5.05	5.11	5.17	5.22	5.27	5.32	5.36
	3.82	4.37	4.70	4.93	5.11	5.27	5.39	5.50	5.60	5.69	5.77	5.84	5.90	5.96	6.02	6.07	6.12	6.17	6.21
60	2.83	3.40	3.74	3.98	4.16	4.31	4.44	4.55	4.65	4.73	4.81	4.88	4.94	5.00	5.06	5.11	5.15	5.20	5.24
	3.76	4.28	4.60	4.82	4.99	5.13	5.25	5.36	5.45	5.53	5.60	5.67	5.73	5.79	5.84	5.89	5.93	5.98	6.02
120	2.80	3.36	3.69	3.92	4.10	4.24	4.36	4.47	4.56	4.64	4.71	4.78	4.84	4.90	4.95	5.00	5.04	5.09	5.13
	3.70	4.20	4.50	4.71	4.87	5.01	5.12	5.21	5.30	5.38	5.44	5.51	5.56	5.61	5.66	5.71	5.75	5.79	5.83
∞	2.77	3.32	3.63	3.86	4.03	4.17	4.29	4.39	4.47	4.55	4.62	4.68	4.74	4.80	4.84	4.89	4.93	4.97	5.01
	3.64	4.12	4.40	4.60	4.76	4.88	4.99	5.08	5.16	5.23	5.29	5.35	5.40	5.45	5.49	5.54	5.57	5.61	5.65

附表 8　r 与 R 的临界值表

df	α	变量的个数(M)				df	α	变量的个数(M)			
		2	3	4	5			2	3	4	5
1	0.05	0.997	0.999	0.999	0.999	24	0.05	0.388	0.470	0.523	0.562
	0.01	1.000	1.000	1.000	1.000		0.01	0.496	0.565	0.609	0.642
2	0.05	0.950	0.975	0.983	0.987	25	0.05	0.381	0.462	0.514	0.553
	0.01	0.990	0.995	0.997	0.998		0.01	0.487	0.555	0.600	0.633
3	0.05	0.878	0.930	0.950	0.961	26	0.05	0.374	0.454	0.506	0.545
	0.01	0.959	0.976	0.983	0.987		0.01	0.478	0.546	0.590	0.624
4	0.05	0.811	0.881	0.912	0.930	27	0.05	0.367	0.446	0.498	0.536
	0.01	0.917	0.949	0.962	0.970		0.01	0.470	0.538	0.582	0.615
5	0.05	0.754	0.863	0.874	0.898	28	0.05	0.361	0.439	0.490	0.529
	0.01	0.874	0.917	0.937	0.949		0.01	0.463	0.530	0.573	0.606
6	0.05	0.707	0.795	0.839	0.867	29	0.05	0.355	0.432	0.482	0.521
	0.01	0.834	0.886	0.911	0.927		0.01	0.456	0.522	0.565	0.598
7	0.05	0.666	0.758	0.807	0.838	30	0.05	0.349	0.426	0.476	0.514
	0.01	0.798	0.855	0.885	0.904		0.01	0.449	0.514	0.558	0.591
8	0.05	0.632	0.726	0.777	0.811	35	0.05	0.325	0.397	0.445	0.482
	0.01	0.765	0.827	0.860	0.882		0.01	0.418	0.481	0.523	0.556
9	0.05	0.602	0.697	0.750	0.786	40	0.05	0.304	0.373	0.419	0.455
	0.01	0.735	0.800	0.836	0.861		0.01	0.393	0.454	0.494	0.526
10	0.05	0.576	0.671	0.726	0.763	45	0.05	0.288	0.353	0.397	0.432
	0.01	0.708	0.776	0.814	0.840		0.01	0.372	0.430	0.470	0.501
11	0.05	0.553	0.648	0.703	0.741	50	0.05	0.273	0.336	0.379	0.412
	0.01	0.684	0.753	0.793	0.821		0.01	0.354	0.410	0.449	0.479
12	0.05	0.532	0.627	0.683	0.722	60	0.05	0.250	0.308	0.348	0.380
	0.01	0.661	0.732	0.773	0.802		0.01	0.325	0.377	0.414	0.442
13	0.05	0.514	0.608	0.664	0.703	70	0.05	0.232	0.286	0.324	0.354
	0.01	0.641	0.712	0.755	0.785		0.01	0.302	0.351	0.386	0.413
14	0.05	0.497	0.590	0.646	0.686	80	0.05	0.217	0.269	0.304	0.332
	0.01	0.623	0.694	0.737	0.768		0.01	0.283	0.330	0.362	0.389
15	0.05	0.482	0.574	0.630	0.670	90	0.05	0.205	0.254	0.288	0.315
	0.01	0.606	0.677	0.721	0.752		0.01	0.267	0.312	0.343	0.368
16	0.05	0.468	0.559	0.615	0.655	100	0.05	0.195	0.241	0.274	0.300
	0.01	0.590	0.662	0.706	0.738		0.01	0.254	0.297	0.327	0.351
17	0.05	0.456	0.545	0.601	0.641	125	0.05	0.174	0.216	0.246	0.269
	0.01	0.575	0.647	0.691	0.724		0.01	0.228	0.266	0.294	0.316
18	0.05	0.444	0.532	0.587	0.628	150	0.05	0.159	0.198	0.225	0.247
	0.01	0.561	0.633	0.678	0.710		0.01	0.208	0.244	0.270	0.290
19	0.05	0.433	0.520	0.575	0.615	200	0.05	0.138	0.172	0.196	0.215
	0.01	0.549	0.620	0.665	0.698		0.01	0.181	0.212	0.234	0.253
20	0.05	0.423	0.509	0.563	0.604	300	0.05	0.113	0.141	0.160	0.176
	0.01	0.537	0.608	0.652	0.685		0.01	0.148	0.174	0.192	0.208
21	0.05	0.413	0.498	0.522	0.592	400	0.05	0.098	0.122	0.139	0.153
	0.01	0.526	0.596	0.641	0.674		0.01	0.128	0.151	0.167	0.180
22	0.05	0.404	0.488	0.542	0.582	500	0.05	0.088	0.109	0.124	0.137
	0.01	0.515	0.585	0.630	0.663		0.01	0.115	0.135	0.150	0.162
23	0.05	0.396	0.479	0.532	0.572	1000	0.05	0.062	0.077	0.088	0.097
	0.01	0.505	0.574	0.619	0.652		0.01	0.081	0.096	0.106	0.115

附表 9　正交拉丁方表

正交拉丁方的完全系

3×3

Ⅰ

$$\begin{matrix} A & B & C \\ B & C & A \\ C & A & B \end{matrix}$$

Ⅱ

$$\begin{matrix} A & B & C \\ C & A & B \\ B & C & A \end{matrix}$$

4×4

Ⅰ

$$\begin{matrix} A & B & C & D \\ B & A & D & C \\ C & D & A & B \\ D & C & B & A \end{matrix}$$

Ⅱ

$$\begin{matrix} A & B & C & D \\ C & D & A & B \\ D & C & B & A \\ B & A & D & C \end{matrix}$$

Ⅲ

$$\begin{matrix} A & B & C & D \\ D & C & B & A \\ B & A & D & C \\ C & D & A & B \end{matrix}$$

5×5

Ⅰ

$$\begin{matrix} A & B & C & D & E \\ B & C & D & E & A \\ C & D & E & A & B \\ D & E & A & B & C \\ E & A & B & C & D \end{matrix}$$

Ⅱ

$$\begin{matrix} A & B & C & D & E \\ C & D & E & A & B \\ E & A & B & C & D \\ B & C & D & E & A \\ D & E & A & B & C \end{matrix}$$

Ⅲ

$$\begin{matrix} A & B & C & D & E \\ D & E & A & B & C \\ B & C & D & E & A \\ E & A & B & C & D \\ C & D & E & A & B \end{matrix}$$

Ⅳ

$$\begin{matrix} A & B & C & D & E \\ B & A & E & C & D \\ C & D & A & E & B \\ D & E & B & A & C \\ E & C & D & B & A \end{matrix}$$

7×7

Ⅰ

$$\begin{matrix} A & B & C & D & E & F & G \\ B & C & D & E & F & G & A \\ C & D & E & F & G & A & B \\ D & E & F & G & A & B & C \\ E & F & G & A & B & C & D \\ F & G & A & B & C & D & E \\ G & A & B & C & D & E & F \end{matrix}$$

Ⅱ

$$\begin{matrix} A & B & C & D & E & F & G \\ C & D & E & F & G & A & B \\ E & F & G & A & B & C & D \\ G & A & B & C & D & E & F \\ B & C & D & E & F & G & A \\ D & E & F & G & A & B & C \\ F & G & A & B & C & D & E \end{matrix}$$

Ⅲ

$$\begin{matrix} A & B & C & D & E & F & G \\ D & E & F & G & A & B & C \\ G & A & B & C & D & E & F \\ C & D & E & F & G & A & B \\ F & G & A & B & C & D & E \\ B & C & D & E & F & G & A \\ E & F & G & A & B & C & D \end{matrix}$$

Ⅳ

$$\begin{matrix} A & B & C & D & E & F & G \\ E & F & G & A & B & C & D \\ B & C & D & E & F & G & A \\ F & G & A & B & C & D & E \\ C & D & E & F & G & A & B \\ G & A & B & C & D & E & F \\ D & E & F & G & A & B & C \end{matrix}$$

Ⅴ

$$\begin{matrix} A & B & C & D & E & F & G \\ F & G & A & B & C & D & E \\ D & E & F & G & A & B & C \\ B & C & D & E & F & G & A \\ G & A & B & C & D & E & F \\ E & F & G & A & B & C & D \\ C & D & E & F & G & A & B \end{matrix}$$

Ⅵ

$$\begin{matrix} A & B & C & D & E & F & G \\ G & A & B & C & D & E & F \\ F & G & A & B & C & D & E \\ E & F & G & A & B & C & D \\ D & E & F & G & A & B & C \\ C & D & E & F & G & A & B \\ B & C & D & E & F & G & A \end{matrix}$$

8×8

Ⅰ

$$\begin{matrix} A & B & C & D & E & F & G & H \\ B & A & D & C & F & E & H & G \\ C & D & A & B & G & H & E & F \\ D & C & B & A & H & G & F & E \\ E & F & G & H & A & B & C & D \\ F & E & H & G & B & A & D & C \\ G & H & E & F & C & D & A & B \\ H & G & F & E & D & C & B & A \end{matrix}$$

Ⅱ

$$\begin{matrix} A & B & C & D & E & F & G & H \\ E & F & G & H & A & B & C & D \\ B & A & D & C & F & E & H & G \\ F & E & H & G & B & A & D & C \\ G & H & E & F & C & D & A & B \\ C & D & A & B & G & H & E & F \\ H & G & F & E & D & C & B & A \\ D & C & B & A & H & G & F & E \end{matrix}$$

Ⅲ

$$\begin{matrix} A & B & C & D & E & F & G & H \\ G & H & E & F & C & D & A & B \\ E & F & G & H & A & B & C & D \\ C & D & A & B & G & H & E & F \\ H & G & F & E & D & C & B & A \\ B & A & D & C & F & E & H & G \\ D & C & B & A & H & G & F & E \\ F & E & H & G & B & A & D & C \end{matrix}$$

Ⅳ

$$\begin{matrix} A & B & C & D & E & F & G & H \\ H & G & F & E & D & C & B & A \\ G & H & E & F & C & D & A & B \\ B & A & D & C & F & E & H & G \\ C & D & A & B & G & H & E & F \\ F & E & H & G & B & A & D & C \\ E & F & G & H & A & B & C & D \\ D & C & B & A & H & G & F & E \end{matrix}$$

Ⅴ

$$\begin{matrix} A & B & C & D & E & F & G & H \\ D & C & B & A & H & G & F & E \\ H & G & F & E & D & C & B & A \\ E & F & G & H & A & B & C & D \\ F & E & H & G & B & A & D & C \\ G & H & E & F & C & D & A & B \\ C & D & A & B & G & H & E & F \\ B & A & D & C & F & E & H & G \end{matrix}$$

Ⅵ

$$\begin{matrix} A & B & C & D & E & F & G & H \\ F & E & H & G & B & A & D & C \\ D & C & B & A & H & G & F & E \\ G & H & E & F & C & D & A & B \\ C & D & A & B & G & H & E & F \\ H & G & F & E & D & C & B & A \\ B & A & D & C & F & E & H & G \\ E & F & G & H & A & B & C & D \end{matrix}$$

Ⅶ

$$\begin{matrix} A & B & C & D & E & F & G & H \\ C & D & A & B & G & H & E & F \\ F & E & H & G & B & A & D & C \\ H & G & F & E & D & C & B & A \\ B & A & D & C & F & E & H & G \\ D & C & B & A & H & G & F & E \\ E & F & G & H & A & B & C & D \\ G & H & E & F & C & D & A & B \end{matrix}$$

附表 10　常用正交表

$L_4(2^3)$

列号 / 试验号	1	2	3
1	1	1	1
2	1	2	2
3	2	1	2
4	2	2	1

注:任意二列间的交互作用出现在另一列

$L_8(2^7)$

列号 / 试验号	1	2	3	4	5	6	7
1	1	1	1	1	1	1	1
2	1	1	1	2	2	2	2
3	1	2	2	1	1	2	2
4	1	2	2	2	2	1	1
5	2	1	2	1	2	1	2
6	2	1	2	2	1	2	1
7	2	2	1	1	2	2	1
8	2	2	1	2	1	1	2

$L_8(2^7)$ 二列间的交互作用

列号 / 列号	1	2	3	4	5	6	7
	(1)	3	2	5	4	7	6
		(2)	1	6	7	4	5
			(3)	7	6	5	4
				(4)	1	2	3
					(5)	3	2
						(6)	1

$L_8(2^7)$ 表头设计

列号 / 因素数	1	2	3	4	5	6	7
3	A	B	$A\times B$	C	$A\times C$	$B\times C$	
4	A	B	$A\times B$ $C\times D$	C	$A\times C$ $B\times D$	$B\times C$ $A\times D$	D
4	A	B $C\times D$	$A\times B$	C $B\times D$	$A\times C$	D $B\times C$	$A\times D$
5	A $D\times E$	B $C\times D$	$A\times B$ $C\times E$	C $B\times D$	$A\times C$ $B\times E$	D $A\times E$ $B\times C$	E $A\times D$

续表

$L_{12}(2^{11})$

试验号＼列号	1	2	3	4	5	6	7	8	9	10	11
1	1	1	1	1	1	1	1	1	1	1	1
2	1	1	1	1	1	2	2	2	2	2	2
3	1	1	2	2	2	1	1	1	2	2	2
4	1	2	1	2	2	1	2	2	1	1	2
5	1	2	2	1	2	2	1	2	1	2	1
6	1	2	2	2	1	2	2	1	2	1	1
7	2	1	2	2	1	1	2	2	1	2	1
8	2	1	2	1	2	2	2	1	1	1	2
9	2	1	1	2	2	2	1	2	2	1	1
10	2	2	2	1	1	1	1	2	2	1	2
11	2	2	1	2	1	2	1	1	1	2	2
12	2	2	1	1	2	1	2	1	2	2	1

$L_{16}(2^{15})$

试验号＼列号	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1
2	1	1	1	1	1	1	1	2	2	2	2	2	2	2	2
3	1	1	1	2	2	2	2	1	1	1	1	2	2	2	2
4	1	1	1	2	2	2	2	2	2	2	2	1	1	1	1
5	1	2	2	1	1	2	2	1	1	2	2	1	1	2	2
6	1	2	2	1	1	2	2	2	2	1	1	2	2	1	1
7	1	2	2	2	2	1	1	1	1	2	2	2	2	1	1
8	1	2	2	2	2	1	1	2	2	1	1	1	1	2	2
9	2	1	2	1	2	1	2	1	2	1	2	1	2	1	2
10	2	1	2	1	2	1	2	2	1	2	1	2	1	2	1
11	2	1	2	2	1	2	1	1	2	1	2	2	1	2	1
12	2	1	2	2	1	2	1	2	1	2	1	1	2	1	2
13	2	2	1	1	2	2	1	1	2	2	1	1	2	2	1
14	2	2	1	1	2	2	1	2	1	1	2	2	1	1	2
15	2	2	1	2	1	1	2	1	2	2	1	2	1	1	2
16	2	2	1	2	1	1	2	2	1	1	2	1	2	2	1

$L_{16}(2^{15})$ 二列间的交互作用

列号＼列号	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
	(1)	3	2	5	4	7	6	9	8	11	10	13	12	15	14
		(2)	1	6	7	4	5	10	11	8	9	14	15	12	13
			(3)	7	6	5	4	11	10	9	8	15	14	13	12
				(4)	1	2	3	12	13	14	15	8	9	10	11
					(5)	3	2	13	12	15	14	9	8	11	10
						(6)	1	14	15	12	13	10	11	8	9
							(7)	15	14	13	12	11	10	9	8
								(8)	1	2	3	4	5	6	7
									(9)	3	2	5	4	7	6
										(10)	1	6	7	4	5
											(11)	7	6	5	4
												(12)	1	2	3
													(13)	3	2
														(14)	1

续表

$L_{16}(2^{15})$ 表头设计

因素数＼列号	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
4	A	B	$A\times B$	C	$A\times C$	$B\times C$		D	$A\times D$	$B\times D$		$C\times D$			
5	A	B	$A\times B$	C	$A\times C$	$B\times C$	$D\times E$	D	$A\times D$	$B\times D$	$C\times E$	$C\times D$	$B\times E$	$A\times E$	E
6	A	B	$A\times B$ $D\times E$	C	$A\times C$ $D\times F$	$B\times C$ $E\times F$		D	$A\times D$ $B\times E$ $C\times F$	$B\times D$ $A\times E$	E	$C\times D$ $A\times F$	F		$C\times E$ $B\times F$
7	A	B	$A\times B$ $D\times E$ $F\times G$	C	$A\times C$ $D\times F$ $E\times G$	$B\times C$ $E\times F$ $D\times G$		D	$A\times D$ $B\times E$ $C\times F$	$B\times D$ $A\times E$ $C\times G$	E	$C\times D$ $A\times F$ $B\times G$	F	G	$C\times E$ $B\times F$ $A\times G$
8	A	B	$A\times B$ $D\times E$ $F\times G$ $C\times H$	C	$A\times C$ $D\times F$ $E\times G$ $B\times H$	$B\times C$ $E\times F$ $D\times G$ $A\times H$	H	D	$A\times D$ $B\times E$ $C\times F$ $G\times H$	$B\times D$ $A\times E$ $C\times G$ $F\times H$	E	$C\times D$ $A\times F$ $B\times G$ $F\times H$	F	G	$C\times E$ $B\times F$ $A\times G$ $D\times H$

$L_9(3^4)$

试验号＼列号	1	2	3	4
1	1	1	1	1
2	1	2	2	2
3	1	3	3	3
4	2	1	2	3
5	2	2	3	1
6	2	3	1	2
7	3	1	3	2
8	3	2	1	3
9	3	3	2	1

注:任意二列的交互作用出现在另外二列

$L_{18}(3^7)$

试验号＼列号	1	2	3	4	5	6	7
1	1	1	1	1	1	1	1
2	1	2	2	2	2	2	2
3	1	3	3	3	3	3	3
4	2	1	1	2	2	3	3
5	2	2	2	3	3	1	1
6	2	3	3	1	1	2	2
7	3	1	2	1	3	2	3
8	3	2	3	2	1	3	1
9	3	3	1	3	2	1	2
10	1	1	3	3	2	2	1
11	1	2	1	1	3	3	2
12	1	3	2	2	1	1	3
13	2	1	2	3	1	3	2
14	2	2	3	1	2	1	3
15	2	3	1	2	3	2	1
16	3	1	3	2	3	1	2
17	3	2	1	3	1	2	3
18	3	3	2	1	2	3	1

续表

$L_{27}(3^{13})$

试验号＼列号	1	2	3	4	5	6	7	8	9	10	11	12	13
1	1	1	1	1	1	1	1	1	1	1	1	1	1
2	1	1	1	1	2	2	2	2	2	2	2	2	2
3	1	1	1	1	3	3	3	3	3	3	3	3	3
4	1	2	2	2	1	1	1	2	2	2	3	3	3
5	1	2	2	2	2	2	2	3	3	3	1	1	1
6	1	2	2	2	3	3	3	1	1	1	2	2	2
7	1	3	3	3	1	1	1	3	3	3	2	2	2
8	1	3	3	3	2	2	2	1	1	1	3	3	3
9	1	3	3	3	3	3	3	2	2	2	1	1	1
10	2	1	2	3	1	2	3	1	2	3	1	2	3
11	2	1	2	3	2	3	1	2	3	1	2	3	1
12	2	1	2	3	3	1	2	3	1	2	3	1	2
13	2	2	3	1	1	2	3	2	3	1	3	1	2
14	2	2	3	1	2	3	1	3	1	2	1	2	3
15	2	2	3	1	3	1	2	1	2	3	2	3	1
16	2	3	1	2	1	2	3	3	1	2	2	3	1
17	2	3	1	2	2	3	1	1	2	3	3	1	2
18	2	3	1	2	3	1	2	2	3	1	1	2	3
19	3	1	3	2	1	3	2	1	3	2	1	3	2
20	3	1	3	2	2	1	3	2	1	3	2	1	3
21	3	1	3	2	3	2	1	3	2	1	3	2	1
22	3	2	1	3	1	3	2	2	1	3	3	2	1
23	3	2	1	3	2	1	3	3	2	1	1	3	2
24	3	2	1	3	3	2	1	1	3	2	2	1	3
25	3	3	2	1	1	3	2	3	2	1	2	1	3
26	3	3	2	1	2	1	3	1	3	2	3	2	1
27	3	3	2	1	3	2	1	2	1	3	1	3	2

$L_{27}(3^{13})$ 二列间的交互作用

列号＼列号	1	2	3	4	5	6	7	8	9	10	11	12	13
	(1)	3 4 (2)	2 4 1 4 (3)	2 3 1 3 1 2 (4)	6 7 8 11 9 13 10 12 (5)	5 7 9 12 10 11 8 13 1 7 (6)	5 6 10 13 8 12 9 11 1 6 1 5 (7)	9 10 5 11 7 12 6 13 2 11 4 13 3 12 (8)	8 10 6 12 5 13 7 11 3 13 2 12 4 11 1 10 (9)	8 9 7 13 6 11 5 12 4 12 3 11 2 13 1 9 1 8 (10)	12 13 5 8 6 10 7 9 2 8 3 10 4 9 2 5 4 7 3 6 (11)	11 13 6 9 7 8 5 10 4 10 2 9 3 8 3 7 2 6 4 5 1 13 (12)	11 12 7 10 5 9 6 8 3 9 4 8 2 10 4 6 3 5 2 7 1 12 1 11

续表

$L_{27}(3^{13})$ 表头设计

因素数＼列号	1	2	3	4	5	6	7	8	9	10	11	12	13
3	A	B	$(A\times B)_1$	$(A\times B)_2$	C	$(A\times C)_1$	$(A\times C)_2$	$(B\times C)_1$			$(B\times C)_2$		
4	A	B	$(A\times B)_1$ $(C\times D)_2$	$(A\times B)_2$	C	$(A\times C)_1$ $(B\times D)_2$	$(A\times C)_2$	$(B\times C)_1$ $(A\times D)_2$	D	$(A\times D)_1$	$(B\times C)_2$	$(B\times D)_1$	$(C\times D)_1$

$L_{16}(4^5)$

试验号＼列号	1	2	3	4	5
1	1	1	1	1	1
2	1	2	2	2	2
3	1	3	3	3	3
4	1	4	4	4	4
5	2	1	2	3	4
6	2	2	1	4	3
7	2	3	4	1	2
8	2	4	3	2	1
9	3	1	3	4	2
10	3	2	4	3	1
11	3	3	1	2	4
12	3	4	2	1	3
13	4	1	4	2	3
14	4	2	3	1	4
15	4	3	2	4	1
16	4	4	1	3	2

注:任意二列的交互作用出现在另外三列

$L_{25}(5^6)$

试验号＼列号	1	2	3	4	5	6
1	1	1	1	1	1	1
2	1	2	2	2	2	2
3	1	3	3	3	3	3
4	1	4	4	4	4	4
5	1	5	5	5	5	5
6	2	1	2	3	4	5
7	2	2	3	4	5	1
8	2	3	4	5	1	2
9	2	4	5	1	2	3
10	2	5	1	2	3	4
11	3	1	3	5	2	4
12	3	2	4	1	3	5
13	3	3	5	2	4	1
14	3	4	1	3	5	2
15	3	5	2	4	1	3
16	4	1	4	2	5	3
17	4	2	5	3	1	4
18	4	3	1	4	2	5
19	4	4	2	5	3	1
20	4	5	3	1	4	2
21	5	1	5	4	3	2
22	5	2	1	5	4	3
23	5	3	2	1	5	4
24	5	4	3	2	1	5
25	5	5	4	3	2	1

注:任意二列的交互作用出现在另外四列

续表

$L_8(4\times2^4)$

列号 / 试验号	1	2	3	4	5
1	1	1	1	1	1
2	1	2	2	2	2
3	2	1	1	2	2
4	2	2	2	1	1
5	3	1	2	1	2
6	3	2	1	2	1
7	4	1	2	2	1
8	4	2	1	1	2

$L_8(4\times2^4)$ 表头设计

列号 / 因素数	1	2	3	4	5
2	A	B	$(A\times B)_1$	$(A\times B)_2$	$(A\times B)_3$
3	A	B	C		
4	A	B	C	D	
5	A	B	C	D	E

$L_{16}(4\times2^{12})$

列号 / 试验号	1	2	3	4	5	6	7	8	9	10	11	12	13
1	1	1	1	1	1	1	1	1	1	1	1	1	1
2	1	1	1	1	1	2	2	2	2	2	2	2	2
3	1	2	2	2	2	1	1	1	1	2	2	2	2
4	1	2	2	2	2	2	2	2	2	1	1	1	1
5	2	1	1	2	2	1	1	2	2	1	1	2	2
6	2	1	1	2	2	2	2	1	1	2	2	1	1
7	2	2	2	1	1	1	1	2	2	2	2	1	1
8	2	2	2	1	1	2	2	1	1	1	1	2	2
9	3	1	2	1	2	1	2	1	2	1	2	1	2
10	3	1	2	1	2	2	1	2	1	2	1	2	1
11	3	2	1	2	1	1	2	1	2	2	1	2	1
12	3	2	1	2	1	2	1	2	1	1	2	1	2
13	4	1	2	2	1	1	2	2	1	1	2	2	1
14	4	1	2	2	1	2	1	1	2	2	1	1	2
15	4	2	1	1	2	1	2	2	1	2	1	1	2
16	4	2	1	1	2	2	1	1	2	1	2	2	1

$L_{16}(4\times2^{12})$ 表头设计

列号 / 因素数	1	2	3	4	5	6	7	8	9	10	11	12	13
3	A	B	$(A\times B)_1$	$(A\times B)_2$	$(A\times B)_3$	C	$(A\times C)_1$	$(A\times C)_2$	$(A\times C)_3$	$B\times C$			
4	A	B	$(A\times B)_1$ $C\times D$	$(A\times B)_2$	$(A\times B)_3$	C	$(A\times C)_1$ $B\times D$	$(A\times C)_2$	$(A\times C)_3$	$B\times C$ $(A\times D)_1$	D	$(A\times D)_3$	$(A\times D)_2$
5	A	B	$(A\times B)_1$ $C\times D$	$(A\times B)_2$ $C\times E$	$(A\times B)_3$	C	$(A\times C)_1$ $B\times D$	$(A\times C)_2$ $B\times E$	$(A\times C)_3$	$B\times C$ $(A\times D)_1$ $(A\times E)_2$	D $(A\times E)_3$	E $(A\times D)_3$	$(A\times E)_1$ $(A\times D)_2$

续表

$L_{16}(4^2 \times 2^9)$

试验号＼列号	1	2	3	4	5	6	7	8	9	10	11
1	1	1	1	1	1	1	1	1	1	1	1
2	1	2	1	1	1	2	2	2	2	2	2
3	1	3	2	2	2	1	1	1	2	2	2
4	1	4	2	2	2	2	2	2	1	1	1
5	2	1	1	2	2	1	2	2	1	2	2
6	2	2	1	2	2	2	1	1	2	1	1
7	2	3	2	1	1	1	2	2	2	1	1
8	2	4	2	1	1	2	1	1	1	2	2
9	3	1	2	1	2	2	1	2	2	1	2
10	3	2	2	1	2	1	2	1	1	2	1
11	3	3	1	2	1	2	1	2	1	2	1
12	3	4	1	2	1	1	2	1	2	1	2
13	4	1	2	2	1	2	2	1	2	2	1
14	4	2	2	2	1	1	1	2	1	1	2
15	4	3	1	1	2	2	2	1	1	1	2
16	4	4	1	1	2	1	1	2	2	2	1

$L_{16}(4^3 \times 2^6)$

试验号＼列号	1	2	3	4	5	6	7	8	9
1	1	1	1	1	1	1	1	1	1
2	1	2	2	1	1	2	2	2	2
3	1	3	3	2	2	1	1	2	2
4	1	4	4	2	2	2	2	1	1
5	2	1	2	2	2	1	2	1	2
6	2	2	1	2	2	2	1	2	1
7	2	3	4	1	1	1	2	2	1
8	2	4	3	1	1	2	1	1	2
9	3	1	3	1	2	2	2	2	1
10	3	2	4	1	2	1	1	1	2
11	3	3	1	2	1	2	2	1	2
12	3	4	2	2	1	1	1	2	1
13	4	1	4	2	1	2	1	2	2
14	4	2	3	2	1	1	2	1	1
15	4	3	2	1	2	2	1	1	1
16	4	4	1	1	2	1	2	2	2

$L_{16}(4^4 \times 2^3)$

试验号＼列号	1	2	3	4	5	6	7
1	1	1	1	1	1	1	1
2	1	2	2	2	1	2	2
3	1	3	3	3	2	1	2
4	1	4	4	4	2	2	1
5	2	1	2	3	2	2	1
6	2	2	1	4	2	1	2
7	2	3	4	1	1	2	2
8	2	4	3	2	1	1	1
9	3	1	3	4	1	2	2
10	3	2	4	3	1	1	1
11	3	3	1	2	2	2	1
12	3	4	2	1	2	1	2
13	4	1	4	2	2	1	2
14	4	2	3	1	2	2	1
15	4	3	2	4	1	1	1
16	4	4	1	3	1	2	2

续表

$L_{12}(3\times 2^4)$

列号 / 试验号	1	2	3	4	5
1	1	1	1	1	1
2	1	1	1	2	2
3	1	2	2	1	2
4	1	2	2	2	1
5	2	1	2	1	1
6	2	1	2	2	2
7	2	2	1	1	1
8	2	2	1	2	2
9	3	1	2	1	2
10	3	1	1	2	1
11	3	2	1	1	2
12	3	2	2	2	1

$L_{12}(6\times 2^2)$

列号 / 试验号	1	2	3
1	2	1	1
2	5	1	2
3	5	2	1
4	2	2	2
5	4	1	1
6	1	1	2
7	1	2	1
8	4	2	2
9	3	1	1
10	6	1	2
11	6	2	1
12	3	2	2

$L_{18}(2\times 3^7)$

列号 / 试验号	1	2	3	4	5	6	7	8
1	1	1	1	1	1	1	1	1
2	1	1	2	2	2	2	2	2
3	1	1	3	3	3	3	3	3
4	1	2	1	1	2	2	3	3
5	1	2	2	2	3	3	1	1
6	1	2	3	3	1	1	2	2
7	1	3	1	2	1	3	2	3
8	1	3	2	3	2	1	3	1
9	1	3	3	1	3	2	1	2
10	2	1	1	3	3	2	2	1
11	2	1	2	1	1	3	3	2
12	2	1	3	2	2	1	1	3
13	2	2	1	2	3	1	3	2
14	2	2	2	3	1	2	1	3
15	2	2	3	1	2	3	2	1
16	2	3	1	3	2	3	1	2
17	2	3	2	1	3	1	2	3
18	2	3	3	2	1	2	3	1

续表

$L_{12}(6\times 2^2)$

试验号＼列号	1	2	3
1	2	1	1
2	5	1	2
3	5	2	1
4	2	2	2
5	4	1	1
6	1	1	2
7	1	2	1
8	4	2	2
9	3	1	1
10	6	1	2
11	6	2	1
12	3	2	2

$L_{24}(3\times 4\times 2^4)$

试验号＼列号	1	2	3	4	5	6
1	1	1	1	1	1	1
2	1	2	1	1	2	2
3	1	3	1	2	2	1
4	1	4	1	2	1	2
5	1	1	2	2	2	2
6	1	2	2	2	1	1
7	1	3	2	1	1	2
8	1	4	2	1	2	1
9	2	1	1	1	1	2
10	2	2	1	1	2	1
11	2	3	1	2	2	2
12	2	4	1	2	1	1
13	2	3	2	2	2	1
14	2	2	2	2	1	2
15	2	3	2	1	1	1
16	2	4	2	1	2	2
17	3	1	1	1	1	2
18	3	2	1	1	2	1
19	3	3	1	2	2	2
20	3	4	1	2	1	1
21	3	1	2	2	2	1
22	3	2	2	2	1	2
23	3	3	2	1	1	1
24	3	4	2	1	2	2

附表 11　正交多项式系数表*

n	2	3		4			5				6				
c_j	c_1	c_1	c_2	c_1	c_2	c_3	c_1	c_2	c_3	c_4	c_1	c_2	c_3	c_4	c_5
	−1	−1	+1	−3	+1	−1	−2	+2	−1	+1	−5	+5	−5	+1	−1
	+1	0	−2	−1	−1	+3	−1	−1	+2	−4	−3	−1	+7	−3	+5
		+1	+1	+1	−1	−3	0	−2	0	+6	−1	−4	+4	+2	−10
				+3	+1	+1	+1	−1	−2	−4	+1	−4	−4	+2	+10
							+2	+2	+1	+1	+3	−1	−7	−3	−5
											+5	+5	+5	+1	+1
$\sum c_j$	2	2	6	20	4	20	10	14	10	70	70	84	180	28	252
λ_j	2	1	3	2	1	$\frac{10}{3}$	1	1	$\frac{5}{6}$	$\frac{35}{12}$	2	$\frac{3}{2}$	$\frac{5}{3}$	$\frac{7}{12}$	$\frac{21}{10}$

n	7					8					9				
c_j	c_1	c_2	c_3	c_4	c_5	c_1	c_2	c_3	c_4	c_5	c_1	c_2	c_3	c_4	c_5
	−3	+5	−1	+3	−1	−7	+7	−7	+7	−7	−4	+28	−14	+14	−4
	−2	0	+1	−7	+4	−5	+1	+5	−13	+23	−3	+7	+7	−21	+11
	−1	−3	+1	+1	−5	−3	−3	+7	−3	−17	−2	−8	+13	−11	−4
	0	−4	0	+6	0	−1	−5	+3	+9	−15	−1	−17	+9	+9	−9
	+1	−3	−1	+1	+5	+1	−5	−3	+9	+15	0	−20	0	+18	0
	+2	0	−1	−7	−4	+3	−3	−7	−3	+17	+1	−17	−9	+9	+9
	+3	+5	+1	+3	+1	+5	+1	−5	−13	−23	+2	−8	−13	−11	+4
						+7	+7	+7	+7	+7	+3	+7	−7	−21	−11
											+4	+28	+14	+14	+4
$\sum c_j$	28	84	6	154	84	168	168	264	616	2184	60	2772	990	2002	468
λ_j	1	1	$\frac{1}{6}$	$\frac{7}{12}$	$\frac{7}{20}$	2	1	$\frac{2}{3}$	$\frac{7}{12}$	$\frac{7}{10}$	1	3	$\frac{5}{6}$	$\frac{7}{12}$	$\frac{3}{20}$

n	10					11					12				
c_j	c_1	c_2	c_3	c_4	c_5	c_1	c_2	c_3	c_4	c_5	c_1	c_2	c_3	c_4	c_5
	−9	+6	−42	+18	−6	−5	+15	−30	+6	−3	−11	+55	−33	+33	−33
	−7	+2	+14	−22	+14	−4	+6	+6	−6	+6	−9	+25	+3	−27	+57
	−5	−1	+35	−17	−1	−3	−1	+22	−6	+1	−7	+1	+21	−33	+21
	−3	−3	+31	+3	−11	−2	−6	+23	−1	−4	−5	−17	+25	−13	−19
	−1	−4	+12	+18	−6	−1	−9	+14	+4	−4	−3	−29	+19	+12	−44
	+1	−4	−12	+18	+6	0	−10	0	+6	0	−1	−35	+7	+28	−20
	+3	−3	−31	+3	+11	+1	−9	−14	+4	+4	+1	−35	−7	+28	+20
	+5	−1	−35	−17	+1	+2	−6	−23	−1	+4	+3	−29	−19	+12	+44
	+7	+2	−14	−22	−14	+3	−1	−22	−6	−1	+5	−17	−25	−13	+29
	+9	+6	+42	+18	+6	+4	+6	−6	−6	−6	+7	+1	−21	−33	−21
						+5	+15	+30	+6	+3	+9	+25	−3	−27	−57
											+11	+55	+33	+33	+33
$\sum c_j$	330	132	8580	2860	780	110	858	4290	286	156	572	12012	5148	8008	15912
λ_j	2	$\frac{1}{2}$	$\frac{5}{3}$	$\frac{5}{12}$	$\frac{1}{10}$	1	1	$\frac{5}{6}$	$\frac{1}{12}$	$\frac{1}{40}$	2	3	$\frac{2}{3}$	$\frac{7}{24}$	$\frac{3}{20}$

续表

n	13					14				
c_j	c_1	c_2	c_3	c_4	c_5	c_1	c_2	c_3	c_4	c_5
	−6	+22	−11	+99	−22	−13	+13	−143	+143	−143
	−5	+11	0	−66	+33	−11	+7	−11	−77	+187
	−4	+2	+6	−96	+18	−9	+2	+66	−132	+132
	−3	−5	+8	−54	−11	−7	−2	+98	−92	−28
	−2	−10	+7	+11	−26	−5	−5	+95	−13	−139
	−1	−13	+4	+64	−20	−3	−7	+67	+63	−145
	0	−14	0	+84	0	−1	−8	+24	+108	−60
	+1	−13	−4	+64	+20	+1	−8	−24	+108	+60
	+2	−10	−7	+11	+26	+3	−7	−67	+63	+145
	+3	−5	−8	−54	+11	+5	−5	−95	−13	+139
	+4	+2	−6	−96	−18	+7	−2	−98	−92	+28
	+5	+11	0	−66	−33	+9	+2	−66	−132	−132
	+6	+22	+11	+99	+22	+11	+7	+11	−77	−187
						+13	+13	+143	+143	+143
$\sum c_j$	182	2002	572	68068	6188	910	728	97240	136136	235144
λ_j	1	1	$\frac{1}{6}$	$\frac{7}{12}$	$\frac{7}{120}$	2	$\frac{1}{2}$	$\frac{5}{3}$	$\frac{7}{12}$	$\frac{7}{30}$

n	15					16*				
c_j	c_1	c_2	c_3	c_4	c_5	c_1	c_2	c_3	c_4	c_5
	−7	+91	−91	+1001	−1001	−15	+35	−455	+273	−143
	−6	+52	−13	−429	+1144	−13	+21	−91	−91	+143
	−5	+19	+35	−869	+979	−11	+9	+143	−221	+143
	−4	−8	+58	−704	+44	−9	−1	+267	−201	+33
	−3	−29	+61	−249	−751	−7	−9	+301	−101	−77
	−2	−44	+49	+251	−1000	−5	−15	+265	+23	−131
	−1	−53	+27	+621	−675	−3	−19	+179	+129	−115
	0	−56	0	+756	0	−1	−21	+63	+189	−45
	+1	−53	−27	+621	+675					
	+2	−44	−49	+251	+1000					
	+3	−29	−61	−249	+751					
	+4	−8	−58	−704	−44					
	+5	+19	−35	−869	−979					
	+6	+52	+13	−429	−1144					
	+7	+91	+91	+1001	+1001					
$\sum c_j$	280	37128	39780	6466460	10581480	1360	5712	1007760	470288	201552
λ_j	1	3	$\frac{5}{6}$	$\frac{35}{12}$	$\frac{21}{20}$	2	1	$\frac{10}{3}$	$\frac{7}{12}$	$\frac{1}{10}$

n	17					18				
c_j	c_1	c_2	c_3	c_4	c_5	c_1	c_2	c_3	c_4	c_5
	−8	+40	−28	+52	−104	−17	+68	−68	+68	−884
	−7	+25	−7	−13	+91	−15	+44	−20	−12	+676
	−6	+12	+7	−39	+104	−13	+23	+13	−47	+871
	−5	+1	+15	−39	+39	−11	+5	+33	−51	+429
	−4	−8	+18	−24	−36	−9	−10	+42	−36	−156
	−3	−15	+17	−3	−83	−7	−22	+42	−12	−588
	−2	−20	+13	+17	−88	−5	−31	+35	+13	−733
	−1	−23	+7	+31	−55	−3	−37	+23	+33	−583
	0	−24	0	+36	0	−1	−40	+8	+44	−220
$\sum c_j$	408	7752	3876	16796	100776	1938	23256	23256	28424	6953544
λ_j	1	1	$\frac{1}{6}$	$\frac{1}{12}$	$\frac{1}{20}$	2	$\frac{3}{2}$	$\frac{1}{3}$	$\frac{1}{12}$	$\frac{3}{10}$

* 当 $n \geqslant 16$ 时，只列出前一半的 c_j 的数值及 n 为奇数时的中间数值。当 j 为偶数时，后一半与前一半对称；当 j 为奇数时，后一半与前一半反对称(即数值对称，但符号相反)

续表

n	19					20				
c_j	c_1	c_2	c_3	c_4	c_5	c_1	c_2	c_3	c_4	c_5
	−9	+51	−204	+612	−102	−19	+57	−969	+1938	−1938
	−8	+34	−68	−68	+68	−17	+39	−357	−102	+1122
	−7	+19	+28	−388	+98	−15	+23	+85	−1122	+1802
	−6	+6	+89	−453	+58	−13	+9	+377	−1402	+1222
	−5	−5	+120	−354	−3	−11	−3	+539	−1187	+187
	−4	−14	+126	−168	−54	−9	−13	+591	−687	−771
	−3	−21	+112	+42	−79	−7	−21	+553	−77	−1351
	−2	−26	+83	+227	−74	−5	−27	+445	+503	−1441
	−1	−29	+44	+352	−44	−3	−31	+287	+948	−1076
	0	−30	0	+396	0	−1	−33	+99	+1188	−396
$\sum c_j$	570	13566	213180	2288132	89148	2660	17556	4903140	22881320	31201800
λ_j	1	1	$\frac{5}{6}$	$\frac{7}{12}$	$\frac{1}{40}$	2	1	$\frac{10}{3}$	$\frac{35}{24}$	$\frac{7}{20}$

n	21					22				
c_j	c_1	c_2	c_3	c_4	c_5	c_1	c_2	c_3	c_4	c_5
	−10	+190	−285	+969	−3876	−21	+35	−133	+1197	−2261
	−9	+133	−114	0	+1938	−19	+25	−57	+57	+969
	−8	+82	+12	−510	+3468	−17	+16	0	−570	+1938
	−7	+37	+98	−680	+2618	−15	+8	+40	−810	+1598
	−6	−2	+149	−615	+788	−13	+1	+65	−775	+663
	−5	−35	+170	−406	−1063	−11	−5	+77	−563	−363
	−4	−62	+166	−130	−2354	−9	−10	+78	−258	−1158
	−3	−83	+142	+150	−2819	−7	−14	+70	+70	−1554
	−2	−98	+103	+385	−2444	−5	−17	+55	+365	−1509
	−1	−107	+54	+540	−1404	−3	−19	+35	+585	−1079
	0	−110	0	+594	0	−1	−20	+12	+702	−390
$\sum c_j$	770	201894	432630	5720330	121687020	3542	7084	96140	8748740	40562340
λ_j	1	3	$\frac{5}{6}$	$\frac{7}{12}$	$\frac{21}{40}$	2	$\frac{1}{2}$	$\frac{1}{3}$	$\frac{7}{12}$	$\frac{7}{30}$

n	23					24				
c_j	c_1	c_2	c_3	c_4	c_5	c_1	c_2	c_3	c_4	c_5
	−11	+77	−77	+1463	−209	−23	+253	−1171	+253	−4807
	−10	+56	−35	+133	+76	−21	+187	−847	+33	+1463
	−9	+37	−3	−627	+171	−19	+127	−133	−97	+3743
	−8	+20	+20	−950	+152	−17	+73	+391	−157	+3553
	−7	+5	+35	−955	+77	−15	+25	+745	−165	+2071
	−6	−8	+43	−747	−12	−13	−17	+949	−137	+169
	−5	−19	+45	−417	−87	−11	−53	+1023	−87	−1551
	−4	−28	+42	−42	−132	−9	−83	+987	−27	−2721
	−3	−35	+35	+315	−141	−7	−107	+861	+33	−3171
	−2	−40	+25	+605	−116	−5	−125	+665	+85	−2893
	−1	−43	+13	+793	−65	−3	−137	+419	+123	−2005
	0	−44	0	+858	0	−1	−143	+143	+143	−715
$\sum c_j$	1012	35420	32890	13123110	340860	4600	394680	17760600	394680	177928920
λ_j	1	1	$\frac{1}{6}$	$\frac{7}{12}$	$\frac{1}{60}$	2	3	$\frac{10}{3}$	$\frac{1}{12}$	$\frac{3}{10}$

续表

n	25					26				
c_j	c_1	c_2	c_3	c_4	c_5	c_1	c_2	c_3	c_4	c_5
	−12	+92	−506	+1518	−1012	−25	+50	−1150	+2530	−2530
	−11	+69	−253	+253	+253	−23	+38	−598	+506	+506
	−10	+48	−55	−517	+748	−21	+27	−161	−759	+1771
	−9	+29	+93	−897	+753	−19	+17	+171	−1419	+1881
	−8	+12	+196	−982	+488	−17	+8	+408	−1614	+1326
	−7	−3	+259	−857	+119	−15	0	+560	−1470	+482
	−6	−16	+287	−597	−236	−13	−7	+637	−1099	−377
	−5	−27	+285	−267	−501	−11	−13	+649	−599	−1067
	−4	−36	+258	+78	−636	−9	−18	+606	−54	−1482
	−3	−43	+211	+393	−631	−7	−22	+518	+466	−1582
	−2	−48	+149	+643	−500	−5	−25	+395	+905	−1381
	−1	−51	+77	+803	−275	−3	−27	+247	+1221	−935
	0	−52	0	+858	0	−1	−28	+84	+1386	−330
$\sum c_j$	1300	53820	1480050	14307150	7803900	5850	16380	7803900	40060020	48384180
λ_j	1	1	$\frac{5}{6}$	$\frac{5}{12}$	$\frac{1}{20}$	2	$\frac{1}{2}$	$\frac{5}{3}$	$\frac{7}{12}$	$\frac{1}{10}$

n	27					28				
c_j	c_1	c_2	c_3	c_4	c_5	c_1	c_2	c_3	c_4	c_5
	−13	+325	−130	+2990	−16445	−27	+117	−585	+1755	−13455
	−12	+250	−70	+690	+2530	−25	+91	−325	+455	+1495
	−11	+181	−22	−782	+10879	−23	+67	−115	−395	+8395
	−10	+118	+15	−1587	+12144	−21	+45	+49	−879	+9821
	−9	+61	+42	−1872	+9174	−19	+25	+171	−1074	+7866
	−8	+10	+60	−1770	+4188	−17	+7	+255	−1050	+4182
	−7	−35	+70	−1400	−1162	−15	−9	+305	−870	+22
	−6	−74	+73	−867	−5728	−13	−23	+325	−590	−3718
	−5	−107	+70	−262	−8803	−11	−35	+319	−259	−6457
	−4	−134	+62	+338	−10058	−9	−45	+291	+81	−7887
	−3	−155	+50	+870	−9479	−7	−53	+245	+395	−7931
	−2	−170	+35	+1285	−7304	−5	−59	+185	+655	−6701
	−1	−179	+18	+1548	−3960	−3	−63	+115	+840	−4456
	0	−182	0	+1638	0	−1	−65	+39	+936	−1560
$\sum c_j$	1638	712530	101790	56448210	2032135560	7308	95004	2103660	19634160	1354757040
λ_j	1	3	$\frac{1}{6}$	$\frac{7}{12}$	$\frac{21}{40}$	2	1	$\frac{2}{3}$	$\frac{7}{24}$	$\frac{7}{20}$

n	29					30				
c_j	c_1	c_2	c_3	c_4	c_5	c_1	c_2	c_3	c_4	c_5
	−14	+126	−819	+4095	−8190	−29	+203	−1827	+23751	−16965
	−13	+99	−468	+1170	+585	−27	+161	−1071	+7371	+585
	−12	+74	−182	−780	+4810	−25	+122	−450	−3744	+9360
	−11	+51	+44	−1930	+5885	−23	+86	+46	−10504	+11960
	−10	+30	+215	−2441	+4958	−21	+53	+427	−13749	+10535
	−9	+11	+336	−2460	+2946	−19	+23	+703	−14249	+6821
	−8	−6	+412	−2120	+556	−17	−4	+884	−12704	+2176
	−7	−21	+448	−1540	−1694	−15	−28	+980	−9744	−2384
	−6	−34	+449	−825	−3454	−13	−49	+1001	−5929	−6149
	−5	−45	+420	−66	−4521	−11	−67	+957	−1749	−8679
	−4	−54	+366	+660	−4818	−9	−82	+858	+2376	−9768
	−3	−61	+292	+1290	−4373	−7	−94	+714	+6096	−9408
	−2	−66	+203	+1775	−3298	−5	−103	+535	+9131	−7753
	−1	−69	+104	+2080	−1768	−3	−109	+331	+11271	−5083
	0	−70	0	+2184	0	−1	−112	+112	+12376	−1768
$\sum c_j$	2030	113274	4207320	107987880	500671080	8990	302064	21360240	3671587920	2145733200
λ_j	1	1	$\frac{5}{6}$	$\frac{7}{12}$	$\frac{7}{40}$	2	$\frac{2}{3}$	$\frac{5}{3}$	$\frac{35}{12}$	$\frac{3}{10}$

索　引

A

α 错误(α error) 58

B

β 错误(β error) 58
巴特勒检验法(Bartlett test) 80
百分比法(percentage method) 173
百分数(percentage) 39,69
备择假设(alternative hypothesis) 52
伯努利大数定律(Bernoulli theorem) 34
伯努利分布(Bernoulli distribution) 36
比例配置(proportional allocation) 12
必然事件(certain event) 29
变量,变数(variable) 5
变量值(value of variable) 5
变异数(variance) 24
变异系数(coefficient of variability) 27
变异性(variability) 24
标记字母法(method of marked letter) 101
标准差(standard deviation,*Sd*) 25
标准方(standard square) 183
标准化(standardization) 42
标准误差(standard error) 48
标准正态分布(standard normal distribution) 43
标准正态分布方程(standard normal distribution equation) 43
标准正态离差(standard normal deviate) 43
表头设计(table heading design) 196
饼图(pie chart) 19
泊松分布(Piosson distribution) 39
不可能事件(impossible event) 29

C

残差,剩余(residual) 137
残差标准差,离回归标准差(residual standard deviation) 139
残差平方和,离回归平方和,剩余平方和(residual sum of square) 138
参数,参量(parameter) 4
参数估计(estimation of parameter) 73
差异(difference) 57
常量(constant) 5
常数矩阵(constant matrix) 221
乘法定理(multiplicative theorem) 32
乘积和(product sum) 135
成对数据(paried data) 67
成组数据(pooled data) 64
重复(repetition) 6,171
重复性(repeatability) 36
重演(recapitulation) 168
抽签法(lottery) 12,175
抽样分数(sampling fraction) 12
抽样调查(sampling survey) 11
抽样试验(sampling experiment) 46
抽样误差(sampling error) 7
处理(treatment) 6
处理效应(treatment effect) 95,169
处理因素(treatment factor) 5,169
处理组合(treatment unit) 195
次数(frequency) 10
次数分布表(frequency table) 15
次数分布图(frequency chart) 15,18
次数资料(frequency data) 10
错误(mistake) 7

D

Duncan 法,*SSR* 法(the shortest significant range method) 103
大数定律(law of large number) 34
单位矩阵(identity matrix) 221
单位组设计(block design) 175
单尾概率(one-tailed probability) 45
单尾检验(one-tailed test) 58
单项式分组法(grouping method of monomial) 15
单因素处理(single factor treatment) 6,169
单因素试验(single factor experiment) 105,169
单因素随机区组设计(randomized blocks design of one-factor) 176
倒数函数(reciprocal function) 153

倒数转换(reciprocal transformation) 130
等距抽样(systematic sampling) 14
第二类错误(type Ⅱ error) 58
第一类错误(type Ⅰ error) 58
点估计(point estimation) 73
典型抽样(typical sampling) 14
调查(survey) 10
定量变量(quantitative variable) 5
定性变量(qualitative variable) 5
独立事件(independent event) 31
独立事件群(independent event group) 31
独立性(independence) 36
独立性检验(independence test) 88
对比设计(comparison design) 172
对称矩阵(symmetric matrix) 221
对立事件(contrary event) 31
对数函数(logarithmic equation) 158
对数转换(logarithmic transformation) 127
对照(control,CK) 172
多边形图(polygon chart) 19
多重比较(multiple comparison) 100
多项式回归(polynomial regression) 254
多项式回归方程(polynomial regression equation) 254
多因素处理(multiple factors treatment) 6,169
多因素试验(multiple factors experiment) 169
多元非线性回归(multiple nonlinear regression) 134
多元回归分析(multiple regression analysis) 133
多元线性回归(multiple linear regression) 133,220
多元相关,复相关(multiple correlation) 230
多元相关系数,复相关系数(multiple correlation coefficient) 230

E

二项分布(binomial distribution) 35
二项总体(binomial population) 35
二因素裂区设计、二裂式裂区设计(two-factor split plot design) 187
二因素试验(two-factor experiment) 109
二因素随机区组设计(randomized blocks design of two-factor) 179

F

F 分布(F-distribution) 52
F 检验(F-test) 79,99
反正弦转换(arcsine transformation) 128
方差(variance) 24,95
方差分析(analysis of variance) 94
方差齐性(homogeneity of variance) 78,126
放回式抽样,复置抽样(sampling with replacement) 12,46
非控因素(uncontrollable factor) 6
非连续变量(discontinuous variable) 5
非连续变量资料(data of discontinous variable) 9
分布函数(distribution function) 35
分层随机抽样(stratified random sampling) 12
分类变量(categorical variable) 5
分位数(fractile) 45,51
分组(class fication) 18
否定区(rejection region) 57
副处理(secondary treatment) 187
副区(secondary plot) 187
副区误差(error of secondary plot) 189
负相关(negative correlation) 146
复相关,多元相关(multiple correlation) 134,229
复相关系数,多元相关系数(multiple correlation coefficient) 229
复置抽样,放回式抽样(sampling with replacement) 12,46

G

Guass 分布(Guass distribution) 41
概率(probability) 29,30
概率抽样(probability sampling) 11
概率分布(probability distribution) 29,32
概率累积函数(probability cumulative function) 36
概率密度函数(probability density function) 33
概率密度曲线(probability density curve) 33
概率水平(probability level) 56
个体(individual) 4
观测值(observed value) 5,83
固定模型(fixed model) 96
固定因素(fixed factor) 6
拐点(knee point) 42,164
过失性误差(gross error) 7

H

和事件(sum event) 31

回归(regression) 132
回归分析(regression analysis) 133
回归估计标准误(standard error of regression) 139
回归估计误差(errors of regression) 137
回归截距(regression intercept) 134
回归平方和(regression sum of squares) 138
回归系数(regression coefficient) 134
互斥事件(mutually exclusive event) 31
互作效应(interaction effect) 7
互作,连应(interaction) 7
混合模型(mixed model) 96

J

机械抽样(systematic sampling) 14
几何平均数(geometric mean) 21
计量资料(measurement data) 10
计数资料(enumenation data) 9
集中性(centrality) 20
记录统计学(record statistics) 2
积事件(product event) 31
极差,全距(range) 17,24
极显著标准(highly significance standard) 57
极显著水平(highly significance level) 57
加法定理(additive theorem) 32
加权平均数(weighted mean) 22
假设检验(hypothesis test) 55
间比设计(interphase comparison design) 172
简单回归(simple regression) 134
简单随机抽样(simple random sampling) 11
简单相关(simple correlation) 134
角度转换(angle transformation) 128
截距(intercept) 134
接受区(acceptance region) 57
精确性,精确度(precision) 7
均方(mean squares) 24,95,205
均积(mean products) 205
均数,平均数(mean) 21
绝对无关(absolute irrelevance) 146
绝对相关(absolute correlation) 146
决定系数(coefficient of determination) 146,230,247,261
局部控制(local control) 172
矩形图,直方图(histogram) 19
矩阵(matrix) 221

K

可加性(additivity) 126
可控因素(controllable factor) 6
控制(control) 144

L

Logistic 生长曲线(Logistic growth curve) 163
LSD 法,最小显著差数法(the least significant difference) 100
LSR 法,最小显著极差法(the least significant ranges) 103
拉丁方(latin square) 182
拉丁方设计(latin square design) 182
累积频率(cumulative frequency) 16
理论分布(theoretical distribution) 35
理论值(expected value) 83
离回归标准差,残差标准差(residual standard deviation) 139
离回归平方和,残差平方和,剩余平方和(residual sum of square) 138
离均差(deviation from mean) 23
离均差乘积和(mean deviation product sum) 135
离均差平方和(mean deviation sum of square) 23,135,138
离散型变量(discrete variable) 5
离散型随机变量(discrete random variable) 32
离散性(discreteness) 20
连续变量(continuous variable) 5
连续变量资料(data of continuous variable) 10
连续型随机变量(continuous random variable) 33
连续性矫正(continuity correction) 69
连应,互作(interaction) 7
联合概率密度函数(joint probability density function) 52
列联表(contingency table) 88
裂区(split plot) 187
裂区设计(split plot design) 187
邻比设计(neighbor comparison design) 172
临界值(critical value) 45,51,58
零假设(null hypothesis) 55
零相关(null correlation) 146

M

幂函数(power function) 160

名义变量(nominative variable) 5
描述统计学(description statistics) 2

N

纳伪错误(error of accepting mistake) 59
拟合优度检验,吻合性检验(goodness of fit test) 85
逆矩阵(inverse matrix) 221
牛顿二项式(Newton binomial) 36

O

偶然误差(accidental error) 7

P

配对试验设计(paried experiment design) 173
片面误差(lopsided error) 7
偏回归系数(partial regression coefficient) 220
偏相关(partial correlation) 134
偏相关分析(partial correlation analysis) 232
偏相关系数(partial correlation coefficient) 232
偏斜度(skewness) 51
偏斜分布(skewness distribution) 51
频率,频数(frequency) 10,16,30,69
频数分布表(frequency table) 15
频数分布图(frequency chart) 15,18
平方根转换(square root transformation) 127
平方和(sum of square) 97
平均数,均数(mean) 21
平均数标准误(standard error of mean) 48
评分法(point system) 10
普查(census) 11

Q

q 检验(q-test) 104
弃真错误(error of abandoning trueness) 58
全距,极差(range) 17,24
全面调查(complete survey) 11
权数(weight) 22
区层(strata) 12
区间估计(interval estimation) 73
区组(block) 171
曲线回归(curve regression) 133
曲线回归方程(curvilinear regression equation) 150

S

SNK 检验(Student-Newman-Keuls test) 104
SSR 法,Duncan 法(the shortest significant range method) 103
散点图,散布图(scatter chart) 19,133
三角形法(method of triangle) 102
生物统计学(biostatistics) 1
剩余,残差(residual) 137
剩余平方和,残差平方和,离回归平方和(residual sum of squares) 138
剩余因子(residuals factor) 248
适合性检验(compatibility test) 85
试验(experiment) 14
试验处理(experimental treatment) 6
试验单位,试验单元(experimental unit) 6
试验控制(experimental control) 205
试验设计(experimental design) 8,167
试验误差(experimental error) 7,169
试验小区(experiment areola) 172
试验因素(experimental factor) 5
事件(event) 30
受试对象(tested subject) 6,169
数理统计(mathematical statistics) 1
数量性状(quantitative character) 9
数量性状资料(data of quantitative character) 9
数学模型(mathematical model) 95,96
数据(data) 5
数据转换(transformation of data) 126
数值变量(numerical variable) 5
属性资料(attribute data) 10
顺序抽样(ordinal sampling) 14
双重抽样(double sampling) 13
双尾概率(two-tailed probability) 45
双尾检验(two-tailed test) 58
水平(level) 6
搜集(collection) 10
算术平均数(arithmetic mean) 21
随机(random) 11,171
随机抽样(random sampling) 11
随机模型(random model) 96
随机区组设计(randomized blocks design) 175
随机事件(random event) 30
随机数字(random digit) 12
随机数字法(random digit method) 175
随机误差(random error) 7
随机因素(random factor) 6

T

t 分布,学生氏 t 分布(t-distribution) 50
t 检验(t-test) 61
特征数(eigenvalue) 21
梯形法(method of trapezoid) 102
条件平均数(conditional mean) 134
条形图,柱形图(bar chart) 19
同质性(homogeneity) 78,126
同质性检验(homogeneity test) 78
统计次数法(frequency counting) 10
统计分析(statistical analysis) 8
统计控制(statistical control) 205
统计数(statistic) 5
统计推断(statistical inference) 29,46,54
统计学(statistics) 1
通径(path) 248
通径分析(path analysis) 247
通径图(path chart) 248
通径系数(path coefficient) 248
推断统计学(inference statistics) 3

U

u 分布(u-distribution) 43
u 分布方程(u-distribution equation) 43
u 检验(u-test) 59

W

未知元矩阵(matrix of unknown elements) 221
吻合性检验,拟合优度检验(goodness of fit test) 85
窝组(fossa) 171
窝组设计(fossa design) 175
误差(error) 7,169
误差效应(error effect) 95
无偏估计值(unbiased estimated value) 47
无限总体(infinite population) 4
无效假设(ineffective hypothesis) 55
完全事件系(complete event system) 31
完全无关(complete irrelevance) 146
完全相关(complete correlation) 146

X

χ^2(chi-square) 51
χ^2 分布(chi-square distribution) 51
χ^2 检验(chi-square test) 83
系统抽样(systematic sampling) 14
系数矩阵(coefficient matrix) 221
系统误差(systematic error) 7
显著标准(significance standard) 57
显著水平(significance level) 56,57
显著性检验(significance test) 55
线性模型(linear model) 35,96
相等配置(equal allocation) 12
相关(correlation) 132
相关程度(degree of correlation) 145
相关分析(correlation analysis) 134
相关系数(correlation coefficient) 145
相关线(correlation line) 248
相关性质(character of correlation) 145
相关指数(correlation exponential) 151,261
小概率(little probability) 55
小概率原理(little probability principle) 56
小区(areola) 172
效应(effection) 7
协变量(covariate) 205
协方差(covariance) 206
协方差分析(analysis of covariance) 204
斜率(slope) 134
新复极差检验(new multiple range test) 103
辛钦大数定律(Khinchine theorem) 34
学生氏 t 分布,t 分布(t-distribution) 50

Y

样本(sample) 4
样本标准差(standard deviation of the sample) 25
样本差数平均数标准误(standard error of the sample difference mean) 67
样本单位(sample unit) 4
样本方差(sample variance) 24
样本频率差数标准误(standard error of the sample frequency difference) 71
样本平均数差数标准误(standard error of the sample mean difference) 49
样本平均数差数分布(distribution of the sample mean difference) 49
样本平均数的分布(distribution of the sample mean) 47
样本容量(sample size) 4

样本算术平均数(arithmetic mean of the sample) 21
一元回归分析(one factor regression analysis) 133
依变量,因变量(dependent variable) 133
因素,因子(factor) 5
因素水平(level of factor) 6
有限总体(finite population) 4
右尾否定区(right-tailed rejection region) 58
预测(forecast) 144
原始资料(row data) 15

Z

z 转换(z-transformation) 147
折线图(broken-line chart) 19
整理(collation) 15
整区(main plot) 187
整体抽样,整群抽样(cluster sampling) 13
正规方程组(normal equation group) 134,221
正相关(positive correlation) 146
正交表(orthogonal table) 194
正交多项式(orthogonal polynomial) 261
正交多项式回归(orthogonal polynomial regression) 261
正交设计(orthogonal design) 194
正交系数(orthogonal coefficient) 262
正交性(orthogonality) 262
正态分布(normal distribution) 41
正态分布曲线(normal distribution curve) 41
正态性(normality) 126
质量性状(qualitative character) 9
质量性状资料(data of qualitative character) 10
直方图,矩形图(histogram) 19
直观分析(visual analysis) 198
直线化(rectification) 150
直线回归(linear regression) 133
直线回归方程(linear regression equation) 134
直线相关(linear correlation) 134
指数函数(exponential function) 156
置信度(degree of confidence) 73
置信区间(confidence interval) 73
中位数(median) 21
中心极限定理(central-limit theorem) 48
众数(mode) 21
逐步回归(stepwise regression) 237
主处理(main treatment) 187
主观抽样(subjective sampling) 14
主区(main plot) 187
主区误差(error of main plot) 189
主效应,主效(main effect) 7
柱形图,条形图(bar chart) 19
准确性,准确度(accuracy) 7
资料(data) 5,19
自变量(independent variable) 133
自由度(degree of freedom) 24
总乘积和(total sum of products) 207
总平方和(total sum of squares) 97
总体(population) 4
总体标准差(standard deviation of the population) 25
总体方差(population variance) 24
总体频率标准误(standard error of the population frequency) 69
总体算术平均数(arithmetic mean of the population) 21
总自由度(total degree of freedom) 97
组间乘积和(sum of products between groups) 207
组距(class interval) 17
组距式分组法(grouping method of class interval) 16
组内乘积和(sum of products within group) 207
组数(number of classes) 17
组限(class limit) 18
组中值(class midvalue) 18
最小二乘法(method of least square) 134
最小显著差数法(the least significant difference,*LSD*) 100
最小显著极差法(the least significant ranges,*LSR*) 103
最优多元线性回归方程(the best multiple linear regression equation) 237
最优回归方程(the best regression equation) 237
最优配置(optimum allocation) 12
左尾否定区(left-tailed rejection region) 57

(Q-3124.0101)

生物统计学

（第五版）

www.sciencep.c

ISBN 978-7-03-037502-5

9 787030 375025 >

定 价：38.00 元

高等教育出版中心　农林与生命科学分社
联系电话：010-64034871
E-mail：bio@mail.sciencep.com